

扩散薛定谔桥及其在基于分数的生成建模中的应用

Valentin De Bortoli
Department of Statistics,
University of Oxford, UK

James Thornton
Department of Statistics,
University of Oxford, UK

Jeremy Heng
ESSEC Business School,
Singapore

Arnaud Doucet
Department of Statistics,
University of Oxford, UK

摘要

逐步施加高斯噪声可将复杂数据分布转化为近似高斯分布。逆转这一动态过程即可定义生成模型。当前向加噪过程由随机微分方程（Stochastic Differential Equation, SDE）给出时，Song 等人（2021）展示了如何利用分数匹配估计相应逆向时间 SDE 的时间非齐次漂移项。该方法的一个局限性在于，前向时间 SDE 必须运行足够长的时间，以使最终分布近似高斯，同时还需控制相应的时间离散化误差。相比之下，求解薛定谔桥（Schrödinger Bridge, SB）问题，即路径空间上的熵正则化最优传输问题，可得到在有限时间内从数据分布生成样本的扩散过程。本文提出扩散薛定谔桥（Diffusion SB, DSB），这是对迭代比例拟合（Iterative Proportional Fitting, IPF）过程的一种原创近似方法，用于求解 SB 问题，并提供理论分析及生成建模实验。第一次 DSB 迭代恢复了 Song 等人（2021）提出的方法，但具有使用更短时间间隔的灵活性，因为后续 DSB 迭代减小了前向（或后向）SDE 的最终时间边缘分布相对于高斯先验（或数据）分布的差异。除生成建模外，DSB 还提供了一种计算最优传输工具，可作为流行的 Sinkhorn 算法（Cuturi, 2013）在连续状态空间中的类比。

1 引言

基于分数的生成建模（Score-Based Generative Modeling, SGM）是近年来发展起来的一种概率生成建模方法，在多项音频和图像合成任务中展现出最先进的性能；参见例如 Song 和 Ermon（2019）；Cai 等人（2020）；Chen 等人（2021a）；Kong 等人（2021）；Gao 等人（2020）；Jolicœur-Martineau 等人（2021b）；Ho 等人（2020）；Song 和 Ermon（2020）；Song 等人（2020, 2021）；Niu 等人（2020）；Durkan 和 Song（2021）；Hoogeboom 等人（2021）；Saharia 等人（2021）；Luhman 和 Luhman（2021, 2020）；Nichol 和 Dhariwal（2021）；Popov 等人（2021）；Dhariwal 和 Nichol（2021）。现有的 SGM 通常由两部分组成。首先，逐步向数据中添加噪声，以获得近似易于采样的先验分布（例如高斯分布）的扰动数据分布。其次，使用神经网络学习逆向去噪动力学，当从该先验分布初始化时，便定义了一个生成模型（Sohl-Dickstein 等人，2015；Ho 等人，2020；Song 和 Ermon，2019；Song 等人，2021）。Song 等人（2021）表明，可以有效地将加噪过程视为一个随机微分方程（Stochastic Differential Equation, SDE），该方程逐步将初始数据分布扰动为近似高斯分布。




图 1: 从二维数据分布初始化的参考前向扩散未能在 $T = 0.2$ 扩散时间 ($N = 20$ 个离散时间步) 内收敛到高斯先验, 并且从高斯先验初始化的逆向扩散也未收敛到数据分布。然而, 经过 5 次 DSB 迭代后收敛确实发生。

相应的逆向时间 SDE 是一个非齐次扩散过程, 其漂移项依赖于扰动数据分布的对数梯度, 即分数。在实践中, 这些分数通过神经网络和分数匹配技术 (Hyvärinen 和 Dayan, 2005; Vincent, 2011) 来近似, 而采样过程则使用数值 SDE 积分器。

尽管基于分数的生成模型 (Score-based Generative Model, SGM) 提供了最先进的结果 (Dhariwal 和 Nichol, 2021), 但样本生成的计算成本高昂。为了从先验分布 (即生成模型) 学习逆向时间随机微分方程 (SDE), 正向加噪 SDE 必须运行足够长的时间以收敛到先验分布, 并且步长必须足够小以获得该 SDE 的良好数值近似。通过将生成建模重新表述为薛定谔桥 (Schrödinger Bridge, SB) 问题, 我们缓解了这一问题, 并提出了一种新颖的算法来求解 SB 问题。我们的详细贡献如下。

将生成建模作为薛定谔桥问题。 SB 问题是由薛定谔 (1932) 提出的著名熵正则化最优传输 (Optimal Transport, OT) 问题; 参见例如 (Léonard, 2014b; Chen 等, 2021b) 的综述。给定一个具有有限时间范围的参考扩散 T 、一个数据分布和一个先验分布, 求解 SB 等价于在路径空间上以 Kullback-Leibler 散度衡量, 找到与参考扩散最接近的扩散, 该扩散在时间 $t = 0$ 处具有数据分布作为边缘分布, 在时间 $t = T$ 处具有先验分布。求解该 SB 问题的逆向时间扩散提供了一种新的 SGM 算法, 与原始 SGM 方法相比, 该算法能够使用更短的时间间隔从数据分布中近似生成样本。我们的方法不同于 (Genevay 等, 2018) 中的熵正则化 OT 公式, 后者处理离散分布并依赖于 SB 的静态公式, 而我们的动态方法针对连续分布并在路径空间上操作。它也不同于 (Finlay 等, 2020), 后者通过使用 SB 对偶公式的势函数计算漂移的扩散来近似 SB 解。最后, Wang 等 (2021) 最近提出通过求解两个而非一个 SB 问题来执行生成建模。与我们不同, 他们没有将生成建模表述为计算数据分布与先验分布之间的 SB。

使用基于分数的扩散求解薛定谔桥问题。 薛定谔桥问题可通过迭代比例拟合 (Iterative Proportional Fitting, IPF) 求解 (Fortet, 1940; Kullback, 1968; Chen et al., 2021b)。本文提出扩散薛定谔桥 (Diffusion SB, DSB), 一种利用基于分数的扩散技术实现 IPF 的新颖方法。DSB 无需离散化状态空间 (Chen et al., 2016; Reich, 2019), 无需通过回归近似势函数 (Bernton et al., 2019; Dessein et al., 2017; Pavon et al., 2021), 也无需进行核密度估计 (Pavon et al., 2021)。DSB 的首次迭代恢复了 Song et al. (2021) 提出的方法, 并具有使用更短时间间隔的灵活性, 因为额外的 DSB 迭代减小了前向 (分别地, 后向) 随机微分方程最终时间边缘分布相对于先验 (分别地, 数据) 分布的差异; 见图 1 的说明。Vargas et al. (2021) 同时独立地提出了一种类似于 DSB 的算法; 主要区别

在于我们的算法使用神经网络和分数匹配思想来估计随机微分方程的漂移项，而他们使用高斯过程。

理论结果。本文首次为 Song et al. (2021) 的方法论提供了定量收敛结果。特别地，我们证明，尽管在可能极高维的空间中模拟朗之万型扩散，基于分数的生成模型方法不会遭受混合时间过长的问题。此外，我们推导了连续状态空间中 IPF 的新颖定量收敛结果，这些结果不依赖于经典的紧性假设 (Chen et al., 2016; Ruschendorf et al., 1995)，并改进了 Léger (2020) 的近期结果。最后，我们证明 DSB 可视为基于前向/后向扩散的路径空间上动态 IPF 的时间离散化。

实验。我们通过生成图像数据集（如 MNIST 和 CelebA）来验证我们的方法论。特别地，我们证明使用多个 DSB 步骤总能改进生成模型。我们还展示了 DSB 如何用于在两个数据分布之间进行插值。

符号说明。在连续时间设定下，我们设 $\mathcal{C} = C([0, T], \mathbb{R}^d)$ 为从 $[0, T]$ 到 $\mathbb{R}^d$ 的连续函数空间， $B(\mathcal{C})$ 为 $\mathcal{C}$ 上的博雷尔集。对于任意可测空间 $(E, \mathcal{E})$ ，我们用 $\mathcal{P}(E)$ 表示 $(E, \mathcal{E})$ 上的概率测度空间。对于任意 $\ell \in \mathbb{N}$ ，令 $\mathcal{P}_\ell = \mathcal{P}((\mathbb{R}^d)^\ell)$ 。当有定义时，我们记 $H(p) = -\int_{\mathbb{R}^d} p(x) \log p(x) dx$ 为 p 的熵与 $KL(p|q)$ 作为 p 和 q 之间的库尔贝克-莱布勒发散。当没有歧义时，我们对分布及其密度使用相同的符号。所有证明均推迟到补充材料中。

2 去噪扩散、得分匹配与逆向时间随机微分方程

2.1 离散时间：马尔可夫链与时间反演

考虑一个具有正密度 p_{data} 的数据分布，一个关于勒贝格测度的正先验密度 p_{prior} ，两者支撑集均在 $\mathbb{R}^d$ 上，以及一个初始密度为 $p_0 = p_{\text{data}}$ 、在 $\mathbb{R}^d$ 上演化、具有正转移密度 $p_{k+1|k}$ （对于 $k \in \{0, \dots, N-1\}$ ）的马尔可夫链。因此，对于任意 $x_{0:N} = \{x_k\}_{k=0}^N \in \mathcal{X} = (\mathbb{R}^d)^{N+1}$ ，联合密度可表示为

$$p(x_{0:N}) = p_0(x_0) \prod_{k=0}^{N-1} p_{k+1|k}(x_{k+1}|x_k). \quad (1)$$

该联合密度也允许如下后向分解

$$p(x_{0:N}) = p_N(x_N) \prod_{k=0}^{N-1} p_{k|k+1}(x_k|x_{k+1}), \quad p_{k|k+1}(x_k|x_{k+1}) = \frac{p_k(x_k)p_{k+1|k}(x_{k+1}|x_k)}{p_{k+1}(x_{k+1})}, \quad (2)$$

其中 $p_k(x_k) = \int p_{k|k-1}(x_k|x_{k-1})p_{k-1}(x_{k-1})dx_{k-1}$ 是第 $k \geq 1$ 步的边际密度。出于生成建模的目的，我们将选择转移密度，使得对于较大的 N ，有 $p_N(x_N) = \int p(x_{0:N})dx_{0:N-1} \approx p_{\text{prior}}(x_N)$ ，其中 p_{prior} 是一个易于采样的先验密度。可以使用逆向时间分解

(2) 通过祖先采样近似地从 p_{data} 采样，即首先采样 $X_N \sim p_{\text{prior}}$ ，然后对 $k \in \{N-1, \dots, 0\}$ 采样 $X_k \sim p_{k|k+1}(\cdot|X_{k+1})$ 。这一思想是所有近期得分生成方法的核心。式 (2) 中的逆向时间转移无法精确模拟，但若考虑如下形式的前向转移密度，则可进行近似

$$p_{k+1|k}(x_{k+1}|x_k) = \mathcal{N}(x_{k+1}; x_k + \gamma_{k+1}f(x_k), 2\gamma_{k+1}\mathbf{I}), \quad (3)$$

具有漂移 $f: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 和步长 $\gamma_{k+1} > 0$ 。我们首先从式 (2) 做出如下近似

$$\begin{aligned} p_{k|k+1}(x_k|x_{k+1}) &= p_{k+1|k}(x_{k+1}|x_k) \exp[\log p_k(x_k) - \log p_{k+1}(x_{k+1})] \\ &\approx \mathcal{N}(x_k; x_{k+1} - \gamma_{k+1}f(x_{k+1}) + 2\gamma_{k+1}\nabla \log p_{k+1}(x_{k+1}), 2\gamma_{k+1}\mathbf{I}), \end{aligned} \quad (4)$$

利用 $p_k \approx p_{k+1}$ 、 $\log p_{k+1}$ 在 x_{k+1} 处的泰勒展开以及 $f(x_k) \approx f(x_{k+1})$ 。实际上，若 $\|x_{k+1} - x_k\|$ 足够小，该近似成立，这可通过选择足够小的 γ_{k+1} 来保证。

尽管 $\nabla \log p_{k+1}$ 不可得，但可以利用去噪得分匹配方法 (Hyvärinen 和 Dayan, 2005; Vincent, 2011; Song 等, 2021) 获得近似。

假设条件密度 $p_{k+1|0}(x_{k+1}|x_0)$ 如 (Ho 等, 2020; Song 等, 2021) 中那样可解析获得。我们有

$$p_{k+1}(x_{k+1}) = \int p_0(x_0)p_{k+1|0}(x_{k+1}|x_0)dx_0, \text{ 且基本计算表明}$$

$\nabla \log p_{k+1}(x_{k+1}) = \mathbb{E}_{p_{0|k+1}}[\nabla_{x_{k+1}} \log p_{k+1|0}(x_{k+1}|X_0)]$ 。因此，我们可以¹在本表述中，为简单起见，假设所有分布关于勒贝格测度都有密度。然而，这里提出的算法仅需要能够从 p_{data} 和 p_{prior} 中采样。

将得分估计表述为回归问题，并使用灵活的函数类（例如神经网络）来参数化近似 $s_{\theta^*}(k, x_k) \approx \nabla \log p_k(x_k)$ ，使得

$$\theta^* = \arg \min_{\theta} \sum_{k=1}^N \mathbb{E}_{p_{0,k}} [\|s_{\theta}(k, X_k) - \nabla_{x_k} \log p_{k|0}(X_k|X_0)\|^2],$$

其中 $p_{0,k}(x_0, x_k) = p_0(x_0)p_{k|0}(x_k|x_0)$ 是步骤 0 和 k 处的联合密度。如果 $p_{k|0}$ 不可得，我们使用 $\theta^* = \arg \min_{\theta} \sum_{k=1}^N \mathbb{E}_{p_{k-1,k}} [\|s_{\theta}(k, X_k) - \nabla_{x_k} \log p_{k|k-1}(X_k|X_{k-1})\|^2]$ 。总之，得分生成模型 (SGM) 首先从含噪数据中估计得分函数 s_{θ^*} ，然后使用 $X_N \sim p_{\text{prior}}$ 和近似式 (4) 采样 X_0 ，即

$$X_k = X_{k+1} - \gamma_{k+1} f(X_{k+1}) + 2\gamma_{k+1} s_{\theta^*}(k+1, X_{k+1}) + \sqrt{2\gamma_{k+1}} Z_{k+1}, Z_{k+1} \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \mathbf{I}). \quad (5)$$

随机变量 X_0 近似服从 $p_0 = p_{\text{data}}$ 分布，如果 $p_N(x_N) \approx p_{\text{prior}}(x_N)$ 。在下文中，我们令 $\{Y_k\}_{k=0}^N = \{X_{N-k}\}_{k=0}^N$ 并指出 $\{Y_k\}_{k=0}^N$ 满足前向递归。

2.2 连续时间：随机微分方程、逆向随机微分方程与理论结果

对于适当的转移密度，Song 等 (2021) 证明了前向和逆向马尔可夫链可视为离散化的扩散过程。我们推导第 2.1 节所述过程的连续时间极限，并建立收敛结果。具有核 (3) 的马尔可夫链对应于 $(\mathbf{X}_t)_{t \in [0, T]}$ 的欧拉-丸山离散化，求解以下随机微分方程

$$d\mathbf{X}_t = f(\mathbf{X}_t)dt + \sqrt{2}d\mathbf{B}_t, \quad \mathbf{X}_0 \sim p_0 = p_{\text{data}}, \quad (6)$$

其中 $(\mathbf{B}_t)_{t \in [0, T]}$ 是布朗运动， $f: \mathbb{R}^d \rightarrow \mathbb{R}^d$ 足够正则以保证 (强) 解存在。在关于 f 的条件下，众所周知 (参见 Haussmann 和 Pardoux (1986)；Föllmer (1985)；Cattiaux 等 (2021))，逆向时间过程 $(\mathbf{Y}_t)_{t \in [0, T]} = (\mathbf{X}_{T-t})_{t \in [0, T]}$ 满足

$$d\mathbf{Y}_t = \{-f(\mathbf{Y}_t) + 2\nabla \log p_{T-t}(\mathbf{Y}_t)\} dt + \sqrt{2}d\mathbf{B}_t, \quad (7)$$

以初始化 $\mathbf{Y}_0 \sim p_T$ ，其中 p_t 表示 $\mathbf{X}_t$ 的边缘密度。与 (5) 相关的逆向时间马尔可夫链 $\{Y_k\}_{k=0}^N$ 对应于 (7) 的欧拉-丸山离散化，其中得分函数 $\nabla \log p_t(x)$ 由 $s_{\theta^*}(t, x)$ 近似。

在下文中，我们考虑 $f(x) = -\alpha x$ 对于 $\alpha \geq 0$ 。该框架包括 Song 和 Ermon (2019) ($\alpha = 0, p_{\text{prior}}(x) = \mathcal{N}(x; 0, 2T\mathbf{I})$) 的框架，其中 $(\mathbf{X}_t)_{t \in [0, T]}$ 仅为布朗运动，以及 Ho et al. (2020) ($\alpha > 0, p_{\text{prior}}(x) = \mathcal{N}(x; 0, \mathbf{I}/\alpha)$) 的框架，其中为奥恩斯坦-乌伦贝克过程，更多细节见附录 C.3。与 Song 等人 (2021) 不同，我们考虑时间齐次扩散。两种方法使用不同的离散化来近似 (5)，但我们的设置利用奥恩斯坦-乌伦贝克过程的遍历性质来建立定理 1。

定理 1。 假设存在 $M \geq 0$ 使得对于任意 $t \in [0, T]$ 和 $x \in \mathbb{R}^d$

$$\|s_{\theta^*}(t, x) - \nabla \log p_t(x)\| \leq M, \quad (8)$$

以 $s_{\theta^*} \in C([0, T] \times \mathbb{R}^d, \mathbb{R}^d)$ 。假设 $p_{\text{data}} \in C^3(\mathbb{R}^d, (0, +\infty))$ 有界且存在

exist $d_1, A_1, A_2, A_3 \geq 0, \beta_1, \beta_2, \beta_3 \in \mathbb{N}$ $m_1 > 0$ 使得对于任意 $x \in \mathbb{R}^d$ 及 $i \in \{1, 2, 3\}$

$\|\nabla^i \log p_{\text{data}}(x)\| \leq A_i(1 + \|x\|^{\beta_i})$, $\langle \nabla \log p_{\text{data}}(x), x \rangle \leq -m_1 \|x\|^2 + d_1 \|x\|$, 以 $\beta_1 = 1$ 。则对于任意 $\alpha \geq 0$ ，存在 $B_\alpha, C_\alpha, D_\alpha \geq 0$ 使得对于任意 $N \in \mathbb{N}$ 和 $\{\gamma_k\}_{k=1}^N$ 以 $\gamma_k > 0$ 对于任意 $k \in \{1, \dots, N\}$ ，以下关于全变差距离的界成立：

(a) if $\alpha > 0$ ，我们有 $\|\mathcal{L}(X_0) - p_{\text{data}}\|_{\text{TV}} \leq C_\alpha(M + \bar{\gamma}^{1/2}) \exp[D_\alpha T] + B_\alpha \exp[-\alpha^{1/2} T]$;

(b) if $\alpha = 0$ ，我们有 $\|\mathcal{L}(X_0) - p_{\text{data}}\|_{\text{TV}} \leq C_0(M + \bar{\gamma}^{1/2}) \exp[D_0 T] + B_0(T^{-1} + T^{-1/2})$;

where $T = \sum_{k=1}^N \gamma_k$, $\bar{\gamma} = \sup_{k \in \{1, \dots, N\}} \gamma_k$ and $\mathcal{L}(X_0)$ is the distribution of X_0 given in (5).

证明。本文在此给出证明概要。完整证明详见附录 C.2。记 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 为与 (6) 式相关的路径测度， $\mathbb{P}^R$ 为其时间反演。记 Q_N 为由 (5) 式诱导的从 Y_0 到 Y_N 的马尔可夫核。我们有

$$\|p_{\text{prior}} Q_N - p_{\text{data}}\|_{\text{TV}} = \|p_{\text{prior}} Q_N - p_{\text{data}} \mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0}\|_{\text{TV}}$$

$$\begin{aligned} &\leq \|p_{\text{prior}}Q_N - p_{\text{prior}}(\mathbb{P}^R)_{T|0}\|_{\text{TV}} + \|p_{\text{prior}}(\mathbb{P}^R)_{T|0} - p_{\text{data}}\mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0}\|_{\text{TV}} \\ &\leq \|p_{\text{prior}}Q_N - p_{\text{prior}}(\mathbb{P}^R)_{T|0}\|_{\text{TV}} + \|p_{\text{prior}} - p_T\|_{\text{TV}}. \end{aligned}$$

本文通过吉萨诺夫定理控制第一项，即 Q_N 与 $(\mathbb{P}^R)_{T|0}$ 相比的离散化误差。第二项则利用前向扩散过程的混合性质加以控制。 $\square$

条件 (8) 确保神经网络以给定精度 $M \geq 0$ 逼近得分。在 (8) 式及关于 p_{data} 的条件下，定理 1 阐述了由 (5) 式定义的马尔可夫链如何在总变差范数 $\|\cdot\|_{\text{TV}}$ 下逼近 p_{data} 。定理 1 的界表明，前向扩散的混合性质与离散时间近似的质量之间存在权衡：前者随 α 增大而增强，后者则随 α 和 T 增大而恶化，因为 $B_\alpha, C_\alpha D_\alpha \rightarrow_{\alpha \rightarrow +\infty} +\infty$ 。实际上，增大 α 会使漂移更陡峭，连续时间过程收敛更快，但需要更小的步长以控制离散与连续时间过程之间的误差。定理 1 是首个评估得分生成模型方法收敛性的理论结果。虽然 Block 等人 (2020) 针对时间齐次朗之万扩散建立了收敛结果，其目标密度的得分由神经网络逼近，但实际使用的所有得分生成模型方法都依赖于时间非齐次过程。与时间齐次情形不同，该方法不受混合时间差的困扰，因为定理 1 界中对混合时间的依赖完全由前向过程的混合时间决定，而前向过程由简单的布朗运动或奥恩斯坦-乌伦贝克过程给出，且与维度无关。最后，注意 (8) 式是一个强假设。在实践中，我们期望以关于数据分布的高概率在 X 上取得期望意义下的此类界，如 (Block 等人, 2020, 命题 9) 所述。本文结果也与 (Tzen 和 Raginsky, 2019, 定理 3.1) 相关，后者利用随机控制工具建立了相关生成模型的表达能力。

3 扩散薛定谔桥与生成建模

3.1 薛定谔桥

The SB problem is a classical problem appearing in applied mathematics, optimal control and probability; see *e.g.* Föllmer (1988); Léonard (2014b); Chen et al. (2021b). In the discrete-time setting, it takes the following (dynamic) form. Consider as *reference* density $p(x_{0:N})$ given by (1), describing the process adding noise to the data. We aim to find $\pi^* \in \mathcal{P}_{N+1}$ such that

$$\pi^* = \arg \min \{ \text{KL}(\pi|p) : \pi \in \mathcal{P}_{N+1}, \pi_0 = p_{\text{data}}, \pi_N = p_{\text{prior}} \}. \quad (9)$$

假设 π^* 可用，则可通过采样 $X_N \sim p_{\text{prior}}$ ，随后沿反向时间动力学 $X_k \sim \pi_{k|k+1}^*(\cdot|X_{k+1})$ (对 $k \in \{N-1, \dots, 0\}$) 得到一个生成模型。在第 3.2 节推导逼近 π^* 的方法之前，本文先强调薛定谔桥的一些理想特性。

静态薛定谔桥问题。首先，我们回顾动态公式 (9) 存在静态对应形式。例如，根据莱昂纳德 (Léonard, 2014a, 定理 2.4)，对于任意

$\pi \in \mathcal{P}_{N+1}$, $\text{KL}(\pi|p) = \text{KL}(\pi_{0,N}|p_{0,N}) + \mathbb{E}_{\pi_{0,N}}[\text{KL}(\pi_{|0,N}|p_{|0,N})]$ ，以下分解成立，其中对于任意 $\mu \in \mathcal{P}_{N+1}$ ，我们有 $\mu = \mu_{0,N}\mu_{|0,N}$ ，且 $\mu_{|0,N}$ 是给定 X_0, X_N 时 $X_{1:N-1}$ 的条件分布。因此，我们有 $\pi^*(x_{0:N}) = \pi^{s,*}(x_0, x_N)p_{|0,N}(x_{1:N-1}|x_0, x_N)$ ，其中 $\pi^{s,*} \in \mathcal{P}_2$ 具有边缘分布 $\pi_0^{s,*}$ 和 $\pi_N^{s,*}$ ， $\pi^{s,*}$ 是静态薛定谔桥问题的解。

$$\pi^{s,*} = \arg \min \{ \text{KL}(\pi^s|p_{0,N}) : \pi^s \in \mathcal{P}_2, \pi_0^s = p_{\text{data}}, \pi_N^s = p_{\text{prior}} \}. \quad (10)$$

与最优传输的联系。在温和假设下，静态薛定谔桥问题可视为熵正则化的最优传输问题，因为 (10) 等价于

$$\pi^{s,*} = \arg \min \{ -\mathbb{E}_{\pi^s}[\log p_{N|0}(X_N|X_0)] - H(\pi^s) : \pi^s \in \mathcal{P}_2, \pi_0^s = p_{\text{data}}, \pi_N^s = p_{\text{prior}} \}.$$

If $p_{k+1|k}(x_{k+1}|x_k) = \mathcal{N}(x_{k+1}; x_k, \sigma_{k+1}^2)$ 如宋和埃尔蒙 (Song and Ermon) 所述 (2019), then $p_{N|0}(x_N|x_0) = \mathcal{N}(x_N; x_0, \sigma^2)$ $\sigma^2 = \sum_{k=1}^N \sigma_k^2$ 这诱导出二次代价，并且

$$\pi^{s,*} = \arg \min \{ \mathbb{E}_{\pi^s}[\|X_0 - X_N\|^2] - 2\sigma^2 H(\pi^s) : \pi^s \in \mathcal{P}_2, \pi_0^s = p_{\text{data}}, \pi_N^s = p_{\text{prior}} \}.$$

2 参见附录 D.1，其中利用概率测度的分解定理进行了严格阐述。

Mikami (2004) showed that $\pi^{s,*} \rightarrow \pi_{\mathcal{W}}^*$ weakly and $2\sigma^2 \text{KL}(\pi^{s,*}|p_{0,N}) \rightarrow \mathcal{W}_2^2(p_{\text{data}}, p_{\text{prior}})$ as $\sigma \rightarrow 0$, where $\pi_{\mathcal{W}}^*$ is the optimal transport plan between p_{data} and p_{prior} and $\mathcal{W}_2$ is the 2-Wasserstein distance. Note that the transport cost $c(x, x') = -\log p_{N|0}(x'|x)$ is not necessarily symmetric.

3.2 迭代比例拟合与时间反演

除平凡情形外，薛定谔桥问题不存在闭式解。然而，可通过迭代比例拟合（Iterative Proportional Fitting, IPF）求解（Fortet, 1940; Kullback, 1968; Ruschendorf et al., 1995），其由以下递归定义 $n \in \mathbb{N}$ ，初始化 $\pi^0 = p$ 如式 (1) 所示：

$$\begin{aligned}\pi^{2n+1} &= \arg \min \{ \text{KL}(\pi|\pi^{2n}) : \pi \in \mathcal{P}_{N+1}, \pi_N = p_{\text{prior}} \}, \\ \pi^{2n+2} &= \arg \min \{ \text{KL}(\pi|\pi^{2n+1}) : \pi \in \mathcal{P}_{N+1}, \pi_0 = p_{\text{data}} \}.\end{aligned}\quad (11)$$

This sequence is well-defined if there exists $\tilde{\pi} \in \mathcal{P}_{N+1}$ such that $\tilde{\pi}_0 = p_{\text{data}}$, $\tilde{\pi}_N = p_{\text{prior}}$ and $\text{KL}(\tilde{\pi}|p) < +\infty$. A standard representation of π^n is obtained by updating the joint density p using potential functions, see Appendix D.2 for details. However, this representation of the IPF iterates is difficult to approximate as it requires approximating the potentials. Our methodology builds upon an alternative representation that is better suited to numerical approximations for generative modeling where one has access to samples of p_{data} and p_{prior} .

Proposition 2. Assume that $\text{KL}(p_{\text{data}} \otimes p_{\text{prior}}|p_{0,N}) < +\infty$. Then for any $n \in \mathbb{N}$, π^{2n} and π^{2n+1} admit positive densities w.r.t. the Lebesgue measure denoted as p^n resp. q^n and for any $x_{0:N} \in \mathcal{X}$, we have $p^0(x_{0:N}) = p(x_{0:N})$ and

$$q^n(x_{0:N}) = p_{\text{prior}}(x_N) \prod_{k=0}^{N-1} p_{k|k+1}^n(x_k|x_{k+1}), p^{n+1}(x_{0:N}) = p_{\text{data}}(x_0) \prod_{k=0}^{N-1} q_{k+1|k}^n(x_{k+1}|x_k).$$

In practice we have access to $p_{k+1|k}^n$ and $q_{k+1|k}^n$. Hence, to compute $p_{k|k+1}^n$ and $q_{k+1|k}^n$ we use

$$p_{k|k+1}^n(x_k|x_{k+1}) = \frac{p_{k+1|k}^n(x_{k+1}|x_k)p_k^n(x_k)}{p_{k+1}^n(x_{k+1})}, q_{k+1|k}^n(x_{k+1}|x_k) = \frac{q_{k|k+1}^n(x_k|x_{k+1})q_{k+1}^n(x_{k+1})}{q_k^n(x_k)}.$$

To the best of our knowledge, this representation of the IPF iterates has surprisingly neither been presented nor explored in the literature. One may interpret these formulas as follows. At iteration $2n$, we have $\pi^{2n} = p^n$ with $p^0 = p$ given by the noising process (1). This forward process initialized with $p_0^n = p_{\text{data}}$ defines reverse-time transitions $p_{k|k+1}^n$, which, when combined with an initialization p_{prior} at step N defines the reverse-time process $\pi^{2n+1} = q^n$. The forward transitions $q_{k+1|k}^n$ associated to q^n are then used to obtain $\pi^{2n+2} = p^{n+1}$. IPF then iterates this procedure.

3.3 扩散薛定谔桥作为迭代均值匹配比例拟合

为近似命题 2 中定义的 IPF 递归，我们采用与第 2.1 节类似的近似方法。若在第 $n \in \mathbb{N}$ 步有 p_k^n

$$1|_k(x_{k+1}|x_k) = \mathcal{N}(x_{k+1}; x_k + \gamma_{k+1}f_k^n(x_k), 2\gamma_{k+1}\mathbf{I})$$

其中 $p^0 = p$ 和 $f_k^0 = f$ ，则可将命题 2 中的反向时间转移近似为 $q_{k+1|k}^n(x_k|x_{k+1}) = p_{k+1|k}^n(x_{k+1}|x_k) \exp[\log p_k^n(x_k) - \log p_{k+1}^n(x_{k+1})] \approx \mathcal{N}(x_k; x_{k+1} + \gamma_{k+1}b_{k+1}^n(x_{k+1}), 2\gamma_{k+1}\mathbf{I})$ ，其中 $b_{k+1}^n(x_{k+1}) = -f_{k+1}^n(x_{k+1}) + 2\nabla \log p_{k+1}^n(x_{k+1})$ 。也可将命题 2 中的正向转移近似为 $p_{k+1|k}^n(x_{k+1}|x_k) \approx \mathcal{N}(x_{k+1}; x_k + \gamma_{k+1}f_{k+1}^{n+1}(x_k), 2\gamma_{k+1}\mathbf{I})$ ，其中 $f_{k+1}^{n+1}(x_k) = -b_{k+1}^n(x_k) + 2\nabla \log q_{k+1}^n(x_k)$ 。因此有 $f_{k+1}^{n+1}(x_k) = f_k^n(x_k) - 2\nabla \log p_{k+1}^n(x_k) + 2\nabla \log q_{k+1}^n(x_k)$ 。由此，可通过得分匹配近似 $\{\nabla \log p_{k+1}^i(x)\}_{i=0}^n, \{\nabla \log q_{k+1}^i(x)\}_{i=0}^n$ 来估计 f_{k+1}^{n+1} 和 b_{k+1}^n 。该方法在内存和计算方面代价过高，见附录 E。我们采用另一种避免这些困难的替代方法。

命题 3. 假设对任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$,

$$q_{k|k+1}^n(x_k|x_{k+1}) = \mathcal{N}(x_k; B_{k+1}^n(x_{k+1}), 2\gamma_{k+1}\mathbf{I}), p_{k+1|k}^n(x_{k+1}|x_k) = \mathcal{N}(x_{k+1}; F_k^n(x_k), 2\gamma_{k+1}\mathbf{I}),$$

with $B_{k+1}^n(x) = x + \gamma_{k+1}b_{k+1}^n(x)$, $F_k^n(x) = x + \gamma_{k+1}f_k^n(x)$ for any $x \in \mathbb{R}^d$. Then we have for any $n \in \mathbb{N}$ and $k \in \{0, \dots, N-1\}$

$$B_{k+1}^n = \arg \min_{B \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k+1}^n} [\|B(X_{k+1}) - (X_{k+1} + F_k^n(X_k) - F_k^n(X_{k+1}))\|^2], \quad (12)$$

$$F_k^{n+1} = \arg \min_{F \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{q_{k+1}^n} [\|F(X_k) - (X_k + B_{k+1}^n(X_{k+1}) - B_{k+1}^n(X_k))\|^2]. \quad (13)$$

命题 3 展示了如何递归近似 B_{k+1}^n 和 F_k^{n+1} 。实践中，我们使用神经网络 $B_{\beta^n}(k, x) \approx B_k^n(x)$ 和 $F_{\alpha^n}(k, x) \approx F_k^n(x)$ 。注意，这些网络也可联合学习。此时，在平衡状态下，我们将得到 p_{data} 与 p_{prior} 之间的桥，但不一定是薛定谔桥。

网络参数 α^n, β^n 通过梯度下降学习，以最小化由 (12) 和 (13) 给出的损失函数在 k 上的经验版本之和，该和利用 M 个样本计算，记为 $\hat{\ell}_n^b(\beta)$ 和 $\hat{\ell}_{n+1}^f(\alpha)$ 。由此得到的近似 $L \in \mathbb{N}$ 次 IPF 迭代的算法称为扩散薛定谔桥 (Diffusion Schrödinger Bridge, DSB)，总结于算法 1 中，其中 $Z_k^j, \tilde{Z}_k^j$ 独立同分布 $\stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \mathbf{I})$ ，见图 1 的示意。

Algorithm 1 Diffusion Schrödinger Bridge

```

1: for  $n \in \{0, \dots, L\}$  do
2:   while not converged do
3:     Sample  $\{X_k^j\}_{k,j=0}^{N,M}$ , where  $X_0^j \sim p_{\text{data}}$ , and
        $X_{k+1}^j = F_{\alpha^n}(k, X_k^j) + \sqrt{2\gamma_{k+1}}Z_{k+1}^j$ 
4:     Compute  $\hat{\ell}_n^b(\beta^n)$  approximating (12)
5:      $\beta^n \leftarrow \text{Gradient Step}(\hat{\ell}_n^b(\beta^n))$ 
6:   end while
7:   while not converged do
8:     Sample  $\{X_k^j\}_{k,j=0}^{N,M}$ , where  $X_N^j \sim p_{\text{prior}}$ , and
        $X_{k-1}^j = B_{\beta^n}(k, X_k^j) + \sqrt{2\gamma_k}\tilde{Z}_k^j$ 
9:     Compute  $\hat{\ell}_{n+1}^f(\alpha^{n+1})$  approximating (13)
10:     $\alpha^{n+1} \leftarrow \text{Gradient Step}(\hat{\ell}_{n+1}^f(\alpha^{n+1}))$ 
11:   end while
12: end for
13: Output:  $(\alpha^{L+1}, \beta^L)$ 

```

DSB 算法使用参考动力学 $f_{\alpha^0}(k, x) =$ 进行初始化。一旦学习到 β^L ，我们可以通过 $f(x)$ 采样 $X_N \sim p_{\text{prior}}$ ，然后利用它来轻松地 p_{data} 进行近似采样。
 $X_{k-1} = B_{\beta^L}(k, X_k) + \sqrt{2\gamma_k}Z_k$ 其中 $Z_k \stackrel{\text{i.i.d.}}{\sim} \mathcal{N}(0, \mathbf{I})$ 所得样本将近似地从 X_0 p_{data} 分布。尽管去噪扩散桥 (DSB) 需要学习一系列网络参数 α^n, β^n ，但与标准得分生成模型 (SGM) 相比，所需的扩散步骤更少。此外，如附录 I， β^0 所述，可以以类似于先前 SGM 的方式进行高效训练。后续 $\alpha^{n+1}, \beta^{n+1}$ 是……的细化 α^n, β^n ，因此可以从先前模型进行微调 iterations.

3.4 迭代比例拟合的收敛性

在本节中，我们研究迭代比例拟合 (IPF) 的理论性质。当状态空间离散且有限 (Franklin 和 Lorenz, 1989; Peyré 和 Cuturi, 2019) 或当 p_{data} 和 p_{prior} 具有紧支撑时 (Chen 等人, 2016)，IPF 关于希尔伯特-伯克霍夫度量以几何速率收敛，其定义参见 Lemmens 和 Nussbaum (2014)。除 Léger (2020) 最近的工作外，在 p_{data} 或 p_{prior} 不具有紧支撑的一般情形下，仅有定性结果 (Ruschendorf 等人, 1995; Ruschendorf 和 Thomsen, 1993)。本文在此非紧支撑情形下建立了 IPF 的定量收敛性以及新颖的单调性结果。我们仅需以下温和假设。

A1. $p_N, p_{\text{prior}} > 0$, $|\mathbf{H}(p_{\text{prior}})| < +\infty$, $\int_{\mathbb{R}^d} |\log p_N|_0(x_N|x_0)|p_{\text{data}}(x_0)p_{\text{prior}}(x_N)dx_0dx_N < +\infty$ 。假设

A1 在我们所有的实验设置中均满足。我们回顾，对于 $\mu, \nu \in \mathcal{P}(\mathbf{E})$ ，其中 $(\mathbf{E}, \mathcal{E})$ 为可测空间，杰弗里散度由 $J(\mu, \nu) = \text{KL}(\mu|\nu) + \text{KL}(\nu|\mu)$ 给出。

命题 4. 假设 **A1** 成立。则 $(\pi^n)_{n \in \mathbb{N}}$ 是良定义的，且对任意 $n \geq 1$ ，我们有

$$\text{KL}(\pi^{n+1}|\pi^n) \leq \text{KL}(\pi^{n-1}|\pi^n), \quad \text{KL}(\pi^n|\pi^{n+1}) \leq \text{KL}(\pi^n|\pi^{n-1}).$$

此外， $(\|\pi^{n+1} - \pi^n\|_{\text{TV}})_{n \in \mathbb{N}}$ 和

$\lim_{n \rightarrow +\infty} n \{ \text{KL}(\pi_0^n|p_{\text{data}}) + \text{KL}(\pi_N^n|p_{\text{prior}}) \} = 0$ 。 $(J(\pi^{n+1}, \pi^n))_{n \in \mathbb{N}}$ 是非增的。最后，我们有

附录 F 中给出了一个具有额外单调性性质的更一般结果。在类似假设下，Léger (2020, 推论 1) 利用布雷格曼散度梯度下降的视角建立了 $\text{KL}(\pi_0^n|p_0) \leq C/n$ ，其中 $C \geq 0$ 。相比之下，我们的证明仅依赖于信息几何的工具。此外，我们改进了收敛速率，并证明了 $(\pi^n)_{n \in \mathbb{N}}$ 在全变差意义下收敛于 π^∞ ，i.e.，我们不仅得到了边缘分布的收敛，还得到了联合分布的收敛。在对 p_{data} 和 p_{prior} 施加限制性条件下，Ruschendorf 等人 (1995) 证明了 π^∞ 是薛定谔桥。在下面的命题中，我们利用测度自同构的结果 (Beurling, 1960) 避免了这一假设。

命题 5。 假设 **A1** 成立。则薛定谔桥问题存在解 $\pi^* \in \mathcal{P}_{N+1}$ ，且我们有 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\|_{TV} = 0$ ，其中 $\pi^\infty \in \mathcal{P}_{N+1}$ 。令 $h = p_{0,N}/(p_0 \otimes p_N)$ ，并假设 $h \in C((\mathbb{R}^d)^2, (0, +\infty))$ ，且存在 $\Phi_0, \Phi_N \in C(\mathbb{R}^d, (0, +\infty))$ 使得 $\int_{\mathbb{R}^d \times \mathbb{R}^d} (|\log h(x_0, x_N)| + |\log \Phi_0(x_0)| + |\log \Phi_N(x_N)|) p_{\text{data}}(x_0) p_{\text{prior}}(x_N) dx_0 dx_N < +\infty$ ，其中 $h(x_0, x_N) \leq \Phi_0(x_0) \Phi_N(x_N)$ 。若 p 关于 π^∞ 绝对连续，则 $\pi^\infty = \pi^*$ 。

命题 5 扩展了先前在没有假设映射 h 有下界的条件下的 IPF 收敛结果，参见 Ruschendorf 等人 (1995)；Chen 等人 (2016)。我们对 h 的假设可以放宽，并由对 π^∞ 的更严格条件替代，参见附录 F.2。命题 4 表明在非紧致情形下 IPF 的收敛速率为 $o(n)$ 阶。然而，在某些情况下，我们恢复了具有问题常数的显式依赖的几何收敛速率，参见附录 G。在实践中，我们并不对 $p_{\text{data}}, p_{\text{prior}}$ 运行 IPF，而是使用这些分布的经验版本。Deligiannidis 等人 (2021) 的最新结果表明，基于经验分布的 IPF 迭代在时间上一致地保持接近使用真实分布所得到的迭代。特别地，当样本数量趋于无穷时，使用经验分布计算的薛定谔桥收敛于使用真实分布计算的薛定谔桥。

3.5 连续时间 IPF

我们描述了一种用于在连续时间下求解薛定谔桥问题的 IPF 算法。我们证明了算法 1 中提出的 DSB 可以看作是 IPF 的离散化。给定参考测度 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ ，薛定谔桥的连续形式涉及求解以下问题

$$\Pi^* = \arg \min \{ \text{KL}(\Pi | \mathbb{P}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_0 = p_{\text{data}}, \Pi_T = p_{\text{prior}} \}, \quad T = \sum_{k=0}^{N-1} \gamma_{k+1}. \quad (14)$$

与式 (11) 类似，我们定义 IPF $(\Pi^n)_{n \in \mathbb{N}}$ ，其中 $\Pi^0 = \mathbb{P}$ 与式 (6) 相关联，且对任意 $n \in \mathbb{N}$

$$\begin{aligned} \Pi^{2n+1} &= \arg \min \{ \text{KL}(\Pi | \Pi^{2n}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_T = p_{\text{prior}} \}, \\ \Pi^{2n+2} &= \arg \min \{ \text{KL}(\Pi | \Pi^{2n+1}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_0 = p_{\text{data}} \}. \end{aligned}$$

可以证明，对任意 $n \in \mathbb{N}$ ， $\Pi^n = \pi^{s,n} \mathbb{P}|_{[0,T]}$ 是静态薛定谔桥问题的 IPF，其中 $(\pi^{s,n})_{n \in \mathbb{N}}$ 。特别地，命题 4 和命题 5 可推广到连续 IPF 框架。在下文中，对任意 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ ，我们定义 $\mathbb{P}^R$ 为逆向时间测度，即对任意 $A \in \mathcal{B}(\mathcal{C})$ ，有 $A^R = \{t \mapsto \omega(T-t) : \omega \in A\}$ 。以下结果是命题 2 的连续对应版本，表明每次 IPF 迭代都与一个扩散过程相关联，说明 DSB 可视为连续 IPF 的离散化。

命题 6。 假设 **A1** 成立，且存在 $\mathbb{M} \in \mathcal{P}(\mathcal{C})$ ， $U \in C^1(\mathbb{R}^d, \mathbb{R})$ ， $C \geq 0$ ，使得对任意 $n \in \mathbb{N}$ ， $x \in \mathbb{R}^d$ ， $\text{KL}(\Pi^n | \mathbb{M}) < +\infty$ ， $\langle x, \nabla U(x) \rangle \geq -C(1 + \|x\|^2)$ 与 $\mathbb{M}$ 相关联

$$\begin{aligned} & \frac{d}{dt} \mathbb{M}_t = \mathbb{M}_t \left(\frac{1}{2} \Delta + \nabla \cdot (U \nabla) \right) \\ & \text{其中 } \mathbb{X}_0 \text{ 服从式 (15) 的不变分布。则对任意 } n \in \mathbb{N} \text{，有：} \end{aligned} \quad (15)$$

其中 $\mathbb{X}_0$ 服从式 (15) 的不变分布。则对任意 $n \in \mathbb{N}$ ，有：与 d 相关联

$$(a) \quad (\Pi^{2n+1})^R \quad \mathbf{Y}_t^{2n+1} = b_{T-t}^{2n+1} (\mathbf{Y}_t^{2n+1}) dt + \sqrt{2} d\mathbf{B}_t \text{ with } \mathbf{Y}_0^{2n+1} \sim p_{\text{prior}};$$

$$(b) \quad \Pi^{2n+2} \text{ is associated with } d\mathbf{X}_t^{2n+2} = f_t^{n+1}(\mathbf{X}_t^{2n+2}) dt + \sqrt{2} d\mathbf{B}_t \text{ with } \mathbf{X}_0^{2n+2} \sim p_{\text{data}};$$

where for any $n \in \mathbb{N}$ ， $t \in [0, T]$ and $x \in \mathbb{R}^d$ ， $b_t^n(x) = -f_t^n(x) + 2\nabla \log p_t^n(x)$ ， $f_t^{n+1}(x) = -b_t^n(x) + 2\nabla \log q_t^n(x)$ ，with $f_t^0(x) = f(x)$ ，see (6)，and p_t^n, q_t^n the densities of Π_t^{2n} and Π_t^{2n+1} .

4 实验

高斯示例。 我们首先在具有真实解的高斯设定中验证算法能够恢复真实的薛定谔桥。设 $p_{\text{prior}} = \mathcal{N}(-a, \mathbf{I})$ ， $p_{\text{data}} = \mathcal{N}(a, \mathbf{I})$ ，其中 $a \in \mathbb{R}^d$ ，并以布朗运动作为参考动力学。静态薛定谔桥的解析表达式为 $\mathcal{N}((-a, a), \Sigma)$ ，其中 $\Sigma \in \mathbb{R}^{2d \times 2d}$ 见附录 G.2。我们令 $a = 0.1 \times \mathbf{1}$ ，其中 $d = 50$ 或 $d = 5$ 。在图 2 中，我们展示了 DSB 的收敛情况。每个 DSB 的训练批大小为 128， $N = 20$ ， $\gamma = 1/40$ 。我们比较了两种网络配置：“小”网络如图 9 所示 (30k 参数)，而“大”网络结构相同但潜在维度加倍 (240k 参数)。小网络在低维设定 ($d = 5$) 下能够恢复薛定谔桥的统计量，但在 $d = 50$ 时无法恢复方差和协方差。增大网络规模可解决此问题。




图 2: DSB 向真实值的收敛过程。从左至右依次为: 每次 DSB 迭代后估计的均值、方差和协方差 (第一分量)。各场景中真实值由虚线表示。

二维玩具实验。我们在二维玩具示例上评估了所提方法的有效性。与现有的得分生成模型 (SGM) 方法不同, 我们不要求步数足够大以满足 $p_N \approx p_{\text{prior}}$ 。我们使用带有位置编码的全连接网络 (Vaswani et al., 2017) 来近似 B_k^n 和 F_k^n , 实现细节见附录 J.1 和我们的代码 3。DSB 迭代的动画图可在我们的项目网页 4 上在线查看。在图 3 中, 我们展示了 DSB 相对于经典 SGM 的优势。我们固定 $f(x) = -\alpha x$ 并选择 $p_{\text{prior}} = \mathcal{N}(0, \sigma_{\text{data}}^2 \mathbf{I})$, 因此 $\alpha = 1/\sigma_{\text{data}}^2$, 其中 σ_{data}^2 是数据集的方差。我们令 $N = 20$ 和 $\gamma_k = 0.01$, i.e. $T = 0.2$ 。由于 T 较小, 我们无法满足 $p_N \approx p_{\text{prior}}$, 第一次 DSB 迭代 (对应原始 SGM 方法) 后得到的逆时间过程不能产生令人满意的生成模型。然而, 多次 DSB 迭代提高了综合质量。




图 3: 数据分布 p_{data} 与 $t = 0$ 处的分布对比, 针对 $T = 0.2$ 在 1 次和 20 次 DSB 迭代后。

生成建模。DSB 是首个在高维空间中近似求解薛定谔桥 (SB) 问题的实用算法 ($d = 3072$ 用于 CelebA 数据集)。尽管我们的实现尚未与最先进的方法相媲美, 但与最初的得分生成模型 (Song 和 Ermon, 2019) 相比, 我们展示了在更少扩散步骤下具有前景的结果, 并在 MNIST (LeCun 和 Cortes, 2010) 和 CelebA (Liu 等人, 2015) 数据集上验证了其性能。




图 4: CelebA 32×32 的生成模型, 经过 10 次 DSB 迭代 $N = 50$ ($T = 0.63$)

采用基于尼科尔和达里瓦尔 (2021) 的简化 U 型网络架构来近似 B_k^n 和 F_k^n 。更多细节见附录 J.2。我们的方法在降采样的人脸数据集 (CelebA) 上进行了验证, 如图 4 所示。图 5 展示了仅用 $N = 12$ 个扩散步骤, 经过 8 次去噪扩散采样 (DSB) 迭代后的定性改进。注意, 如附录 J.2 所示, 使用更高的 N 可获得更好的结果, 但仍远少于原始得分生成模型 (SGM) 流程 (宋和埃尔蒙, 2020, 2019) 中的步骤数。代码可在此获取

https://github.com/JTT94/diffusion_schrodinger_bridge
https://vdeborto.github.io/publication/schrodinger_bridge/

使用 $N = 100$ 。图 6 展示了样本质量如何随 DSB 迭代次数提升，该质量以 Fréchet Inception 距离 (FID) (Heusel 等人, 2017) 定量衡量，针对不同步数 N 。




图 5: 生成的样本 ($N = 12$)




图 6: FID 与 DSB 迭代次数。

数据集插值。 薛定谔桥不仅减少了 SGM 方法中的步数，还为先验密度的选择提供了灵活性 p_{prior} 。与以往 SGM 工作不同，我们的方法对非高斯 p_{prior} 仍然有效，并且可以设置为任何其他数据分布 p'_{data} 。在这种情况下，DSB 收敛于 p_{data} 与 p'_{data} 之间的桥，见图 7。这些实验为任意数据分布之间的高维最优传输铺平了道路。




图 7: 第一行: 瑞士卷到 S 曲线 (2D)。DSB 的第 9 次迭代, 使用 $T = 1$ ($N = 50$)。从左到右: $t = 0, 0.4, 0.6, 1$ 。第二行: EMNIST (Cohen 等人, 2017) 到 MNIST。DSB 的第 10 次迭代, 使用 $T = 1.5$ ($N = 30$)。从左到右: $t = 0, 0.4, 1.25, 1.5$ 。

5 讨论

基于评分的生成建模 (Score-based Generative Modeling, SGM) 可视为求解薛定谔桥问题的第一阶段。基于这一解释，我们开发了一种新颖的方法论——扩散薛定谔桥 (Diffusion Schrödinger Bridge, DSB)，它扩展了 SGM 方法，并允许以更少的扩散步骤进行生成建模。DSB 补充了近期加速现有 SGM 方法的技术，这些技术依赖于不同的噪声调度 (Nichol 和 Dhariwal, 2021; San-Roman 等, 2021; Watson 等, 2021)、替代离散化 (Jolicœur-Martineau 等, 2021a) 或知识蒸馏 (Luhman 和 Luhman, 2021)。此外，由于薛定谔问题的解是一个扩散过程，如 Song 等 (2021, 第 4.3 节) 所述，可以获得一个等价的神经常微分方程，该方程具有与扩散过程相同的边缘分布，但能够进行精确的似然计算，见附录 H.3。尽管 DSB 中的最终时间 $T > 0$ 可以任意小，但我们观察到这存在局限性，因为选择 T 过于接近 0 会降低生成模型的质量。这种行为的一个原因是，如果原始前向过程的终点距离目标分布 p_{prior} 太远，那么即使在 DSB 中，学习 p_{prior} 支撑集附近的评分也是困难的。从理论角度来看，我们为 SGM 方法提供了定量的收敛结果，并为迭代比例拟合 (IPF) 推导出了新的最先进的收敛界以及新颖的单调性结果。我们已在生成建模和数据插值任务上展示了 DSB。最后，尽管这项工作是由生成建模驱动的，但 DSB 的适用范围要广泛得多，因为它可以被视为著名的 Sinkhorn 算法 (Cuturi, 2013; Peyré 和 Cuturi, 2019) 在连续状态空间中的对应物。例如，DSB 可用于求解多边际薛定谔桥问题 (Di Marino 和 Gerolin, 2020)、计算 Wasserstein 重心、寻找熵正则化 Gromov-Wasserstein 问题 (Mémoli, 2011) 的最小化器，或在连续状态空间中执行领域自适应。

致谢与资金披露

Valentin De Bortoli 和 Arnaud Doucet 由 EPSRC CoSIInES (工程与安全计算统计推断) 项目 EP/R034710/1 资助, James Thornton 由 OxWaSP CDT 项目 EP/L016710/1 资助, Jeremy Heng 由 CY Initiative of Excellence (“Investissements d’Avenir” ANR-16-IDEX-0008 项目) 资助。计算资源由 Google Cloud 研究学分计划提供。Arnaud Doucet 还感谢英国国防科学与技术实验室 (DSTL) 和 EPSRC 在项目 EP/R013616/1 下的支持。这是美国国防部、英国国防部和英国 EPSRC 在多学科大学研究计划下的合作的一部分。

参考文献

- Ambrosio, L., Gigli, N., and Savaré, G. (2008). *Gradient Flows in Metric Spaces and in the Space of Probability Measures*. Lectures in Mathematics ETH Zürich. Birkhäuser Verlag, Basel, second edition.
- Bakry, D., Gentil, I., and Ledoux, M. (2014). *Analysis and Geometry of Markov Diffusion Operators*, volume 348. Springer.
- Bernton, E., Heng, J., Doucet, A., and Jacob, P. E. (2019). Schrödinger bridge samplers. *arXiv preprint arXiv:1912.13170*.
- Beurling, A. (1960). An automorphism of product measures. *Annals of Mathematics*, 72(1):189–200.
- Block, A., Mroueh, Y., and Rakhlin, A. (2020). Generative modeling with denoising auto-encoders and Langevin sampling. *arXiv preprint arXiv:2002.00107*.
- Cai, R., Yang, G., Averbuch-Elor, H., Hao, Z., Belongie, S., Snively, N., and Hariharan, B. (2020). Learning gradient fields for shape generation. *European Conference on Computer Vision*.
- Cattiaux, P., Conforti, G., Gentil, I., and Léonard, C. (2021). Time reversal of diffusion processes under a finite entropy condition. *arXiv preprint arXiv:2104.07708*.
- Chen, N., Zhang, Y., Zen, H., Weiss, R. J., Norouzi, M., and Chan, W. (2021a). Wavegrad: Estimating gradients for waveform generation. *International Conference on Learning Representations*.
- Chen, R. T., Rubanova, Y., Bettencourt, J., and Duvenaud, D. (2018). Neural ordinary differential equations. *arXiv preprint arXiv:1806.07366*.
- Chen, Y., Georgiou, T., and Pavon, M. (2016). Entropic and displacement interpolation: a computational approach using the Hilbert metric. *SIAM Journal on Applied Mathematics*, 76(6):2375–2396.
- Chen, Y., Georgiou, T. T., and Pavon, M. (2021b). Optimal transport in systems and control. *Annual Review of Control, Robotics, and Autonomous Systems*, 4.
- Cohen, G., Afshar, S., Tapson, J., and van Schaik, A. (2017). EMNIST: an extension of MNIST to handwritten letters. *arXiv preprint arXiv:1702.05373*.
- Constantine, G. M. and Savits, T. H. (1996). A multivariate Faà di Bruno formula with applications. *Transactions of the American Mathematical Society*, 348(2):503–520.
- Csiszár, I. (1975). I-divergence geometry of probability distributions and minimization problems. *The Annals of Probability*, 3(1):146–158.
- Cuturi, M. (2013). Sinkhorn distances: Lightspeed computation of optimal transport. In *Advances in Neural Information Processing Systems*.
- Deligiannidis, G., De Bortoli, V., and Doucet, A. (2021). Quantitative uniform stability of the iterative proportional fitting procedure. *arXiv preprint arXiv:2108.08129*.
- Dellacherie, C. and Meyer, P.-A. (1988). *Probabilities and Potential. C*, volume 151 of *North-Holland Mathematics Studies*. North-Holland Publishing Co., Amsterdam. Potential theory for discrete and continuous semigroups, Translated from the French by J. Norris.

- Deming, W. E. and Stephan, F. F. (1940). On a least squares adjustment of a sampled frequency table when the expected marginal totals are known. *The Annals of Mathematical Statistics*, 11(4):427–444.
- Dessein, A., Papadakis, N., and Deledalle, C.-A. (2017). Parameter estimation in finite mixture models by regularized optimal transport: A unified framework for hard and soft clustering. *arXiv preprint arXiv:1711.04366*.
- Dhariwal, P. and Nichol, A. (2021). Diffusion models beat GAN on image synthesis. *arXiv preprint arXiv:2105.05233*.
- Di Marino, S. and Gerolin, A. (2020). An optimal transport approach for the Schrödinger bridge problem and convergence of Sinkhorn algorithm. *Journal of Scientific Computing*, 85(2):1–28.
- Douc, R., Moulines, E., Priouret, P., and Soulier, P. (2019). *Markov Chains*. Springer.
- Durkan, C. and Song, Y. (2021). On maximum likelihood training of score-based generative models. *arXiv preprint arXiv:2101.09258*.
- Durmus, A. and Moulines, E. (2017). Nonasymptotic convergence analysis for the unadjusted Langevin algorithm. *The Annals of Applied Probability*, 27(3):1551–1587.
- Enderton, H. B. (1977). *Elements of Set Theory*. Academic Pres, New York-London.
- Ethier, S. N. and Kurtz, T. G. (1986). *Markov Processes*. Wiley Series in Probability and Mathematical Statistics: Probability and Mathematical Statistics. John Wiley & Sons, Inc., New York. Characterization and convergence.
- Finlay, C., Gerolin, A., Oberman, A. M., and Pooladian, A.-A. (2020). Learning normalizing flows from entropy-Kantorovich potentials. *arXiv preprint arXiv:2006.06033*.
- Föllmer, H. (1985). An entropy approach to the time reversal of diffusion processes. In *Stochastic Differential Systems: Filtering and Control*, pages 156–163. Springer.
- Föllmer, H. (1988). Random fields and diffusion processes. In *École d’Été de Probabilités de Saint-Flour XV–XVII, 1985–87*, pages 101–203. Springer.
- Fortet, R. (1940). Résolution d’un système d’équations de M. Schrödinger. *Journal de Mathématiques Pures et Appliquées*, 1:83–105.
- Franklin, J. and Lorenz, J. (1989). On the scaling of multidimensional matrices. *Linear Algebra and Its Applications*, 114:717–735.
- Gao, R., Song, Y., Poole, B., Wu, Y. N., and Kingma, D. P. (2020). Learning energy-based models by diffusion recovery likelihood. *arXiv preprint arXiv:2012.08125*.
- Genevay, A., Peyré, G., and Cuturi, M. (2018). Learning generative models with Sinkhorn divergences. In *International Conference on Artificial Intelligence and Statistics*.
- Hausmann, U. G. and Pardoux, E. (1986). Time reversal of diffusions. *The Annals of Probability*, 14(4):1188–1205.
- Heusel, M., Ramsauer, H., Unterthiner, T., Nessler, B., and Hochreiter, S. (2017). GANs trained by a two time-scale update rule converge to a local Nash equilibrium. *arXiv preprint arXiv:1706.08500*.
- Ho, J., Jain, A., and Abbeel, P. (2020). Denoising diffusion probabilistic models. *Advances in Neural Information Processing Systems*.
- Hoogeboom, E., Nielsen, D., Jaini, P., Forré, P., and Welling, M. (2021). Argmax flows and multinomial diffusion: Towards non-autoregressive language models. *arXiv preprint arXiv:2102.05379*.
- Hutchinson, M. F. (1989). A stochastic estimator of the trace of the influence matrix for laplacian smoothing splines. *Communications in Statistics-Simulation and Computation*, 18(3):1059–1076.

- Hyvärinen, A. and Dayan, P. (2005). Estimation of non-normalized statistical models by score matching. *Journal of Machine Learning Research*, 6(4).
- Ikeda, N. and Watanabe, S. (1989). *Stochastic Differential Equations and Diffusion Processes*, volume 24 of *North-Holland Mathematical Library*. North-Holland Publishing Co., Amsterdam; Kodansha, Ltd., Tokyo, second edition.
- Jolicœur-Martineau, A., Li, K., Piché-Taillefer, R., Kachman, T., and Mitliagkas, I. (2021a). Gotta go fast when generating data with score-based models. *arXiv preprint arXiv:2105.14080*.
- Jolicœur-Martineau, A., Piché-Taillefer, R., Tachet des Combes, R., and Mitliagkas, I. (2021b). Adversarial score matching and improved sampling for image generation. *International Conference on Learning Representations*.
- Kingma, D. P. and Ba, J. (2014). Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*.
- Kober, H. (1939). A theorem on Banach spaces. *Compositio Mathematica*, 7:135–140.
- Kong, Z., Ping, W., Huang, J., Zhao, K., and Catanzaro, B. (2021). Diffwave: A versatile diffusion model for audio synthesis. *International Conference on Learning Representations*.
- Kruihof, J. (1937). Telefoonverkeersrekening. *De Ingenieur*, 52:15–25.
- Kullback, S. (1968). Probability densities with given marginals. *The Annals of Mathematical Statistics*, 39(4):1236–1243.
- Kullback, S. (1997). *Information Theory and Statistics*. Dover Publications, Inc., Mineola, NY. Reprint of the second (1968) edition.
- Laumont, R., De Bortoli, V., Almansa, A., Delon, J., Durmus, A., and Pereyra, M. (2021). Bayesian imaging using plug & play priors: when Langevin meets Tweedie. *arXiv preprint arXiv:2103.04715*.
- LeCun, Y. and Cortes, C. (2010). MNIST handwritten digit database.
- Léger, F. (2020). A gradient descent perspective on Sinkhorn. *Applied Mathematics & Optimization*, pages 1–13.
- Leha, G. and Ritter, G. (1984). On diffusion processes and their semigroups in Hilbert spaces with an application to interacting stochastic systems. *The Annals of Probability*, 12(4):1077–1112.
- Lemmens, B. and Nussbaum, R. D. (2014). Birkhoff’s version of Hilbert’s metric and its applications in analysis. *Handbook of Hilbert Geometry*, pages 275–303.
- Léonard, C. (2011). Stochastic derivatives and generalized h-transforms of markov processes. *arXiv preprint arXiv:1102.3172*.
- Léonard, C. (2014a). Some properties of path measures. In *Séminaire de Probabilités XLVI*, pages 207–230. Springer.
- Léonard, C. (2014b). A survey of the Schrödinger problem and some of its connections with optimal transport. *Discrete & Continuous Dynamical Systems-A*, 34(4):1533–1574.
- Léonard, C. (2019). Revisiting Fortet’s proof of existence of a solution to the Schrödinger system. *arXiv preprint arXiv:1904.13211*.
- Liptser, R. S. and Shiryaev, A. N. (2001). *Statistics of Random Processes. I*, volume 5 of *Applications of Mathematics (New York)*. Springer-Verlag, Berlin, expanded edition. General theory, Translated from the 1974 Russian original by A. B. Aries, Stochastic Modelling and Applied Probability.
- Liu, Z., Luo, P., Wang, X., and Tang, X. (2015). Deep learning face attributes in the wild. In *International Conference on Computer Vision*.
- Luhman, E. and Luhman, T. (2021). Knowledge distillation in iterative generative models for improved sampling speed. *arXiv preprint arXiv:2101.02388*.

- Luhman, T. and Luhman, E. (2020). Diffusion models for handwriting generation. *arXiv preprint arXiv:2011.06704*.
- Mémoli, F. (2011). Gromov–Wasserstein distances and the metric approach to object matching. *Foundations of Computational Mathematics*, 11(4):417–487.
- Meyn, S. P. and Tweedie, R. L. (1993). Stability of Markovian processes. III. Foster-Lyapunov criteria for continuous-time processes. *Advances in Applied Probability*, 25(3):518–548.
- Mikami, T. (2004). Monge’s problem with a quadratic cost by the zero-noise limit of h -path processes. *Probability Theory and Related Fields*, 129(2):245–260.
- Nichol, A. and Dhariwal, P. (2021). Improved denoising diffusion probabilistic models. *arXiv preprint arXiv:2102.09672*.
- Niu, C., Song, Y., Song, J., Zhao, S., Grover, A., and Ermon, S. (2020). Permutation invariant graph generation via score-based generative modeling. In *International Conference on Artificial Intelligence and Statistics*.
- Pavon, M., Trigila, G., and Tabak, E. G. (2021). The data-driven Schrödinger bridge. *Communications on Pure and Applied Mathematics*, 74:1545–1573.
- Petersen, K. B., Pedersen, M. S., et al. (2008). The matrix cookbook. *Technical University of Denmark*, 7(15):510.
- Peyré, G. and Cuturi, M. (2019). Computational optimal transport. *Foundations and Trends® in Machine Learning*, 11(5-6):355–607.
- Popov, V., Vovk, I., Gogoryan, V., Sadekova, T., and Kudinov, M. (2021). Grad-tts: A diffusion probabilistic model for text-to-speech. *arXiv preprint arXiv:2105.06337*.
- Reich, S. (2019). Data assimilation: the Schrödinger perspective. *Acta Numerica*, 28:635–711.
- Revuz, D. and Yor, M. (1999). *Continuous Martingales and Brownian Motion*, volume 293 of *Grundlehren der Mathematischen Wissenschaften [Fundamental Principles of Mathematical Sciences]*. Springer-Verlag, Berlin, third edition.
- Rogers, L. C. G. and Williams, D. (2000). *Diffusions, Markov processes, and martingales. Vol. 2*. Cambridge Mathematical Library. Cambridge University Press, Cambridge. Itô calculus, Reprint of the second (1994) edition.
- Ruschendorf, L. et al. (1995). Convergence of the iterative proportional fitting procedure. *The Annals of Statistics*, 23(4):1160–1174.
- Rüschendorf, L. and Thomsen, W. (1993). Note on the Schrödinger equation and i -projections. *Statistics & Probability letters*, 17(5):369–375.
- Saharia, C., Ho, J., Chan, W., Salimans, T., Fleet, D. J., and Norouzi, M. (2021). Image super-resolution via iterative refinement. *arXiv preprint arXiv:2104.07636*.
- San-Roman, R., Nachmani, E., and Wolf, L. (2021). Noise estimation for generative diffusion models. *arXiv preprint arXiv:2104.02600*.
- Schrödinger, E. (1932). Sur la théorie relativiste de l’électron et l’interprétation de la mécanique quantique. *Annales de l’Institut Henri Poincaré*, 2(4):269–310.
- Sinkhorn, R. and Knopp, P. (1967). Concerning nonnegative matrices and doubly stochastic matrices. *Pacific Journal of Mathematics*, 21(2):343–348.
- Skilling, J. (1989). The eigenvalues of mega-dimensional matrices. In *Maximum Entropy and Bayesian Methods*, pages 455–466. Springer.
- Sohl-Dickstein, J., Weiss, E., Maheswaranathan, N., and Ganguli, S. (2015). Deep unsupervised learning using nonequilibrium thermodynamics. In *International Conference on Machine Learning*.

- Song, J., Meng, C., and Ermon, S. (2020). Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*.
- Song, Y. and Ermon, S. (2019). Generative modeling by estimating gradients of the data distribution. In *Advances in Neural Information Processing Systems*.
- Song, Y. and Ermon, S. (2020). Improved techniques for training score-based generative models. In *Advances in Neural Information Processing Systems*.
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., and Poole, B. (2021). Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*.
- Tzen, B. and Raginsky, M. (2019). Theoretical guarantees for sampling and inference in generative models with latent diffusions. *Conference on Learning Theory*, 99:3084–3114.
- Vargas, F., Thodoroff, P., Lawrence, N. D., and Lamacraft, A. (2021). Solving Schrödinger bridges via maximum likelihood. *arXiv preprint arXiv:2106.02081*.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., and Polosukhin, I. (2017). Attention is all you need. In *Advances in Neural Information Processing Systems*.
- Vincent, P. (2011). A connection between score matching and denoising autoencoders. *Neural Computation*, 23(7):1661–1674.
- Wang, G., Jiao, Y., Xu, Q., Wang, Y., and Yang, C. (2021). Deep generative learning via Schrödinger bridge. In *International Conference on Machine Learning*.
- Watson, D., Ho, J., Norouzi, M., and Chan, W. (2021). Learning to efficiently sample from diffusion probabilistic models. *arXiv preprint arXiv:2106.03802*.

A 补充材料的组织

补充材料的组织如下。我们在附录 B 中定义符号。在附录 C 中，我们证明定理 1，并建立我们的 SGM 方法与现有工作之间的联系。我们在附录 D 中回顾 IPF 的经典公式，证明命题 2，并建立与自编码器的联系。在附录 E 中，我们提出算法 1 的替代变分公式，并证明

命题 3。我们在附录 F 中汇总了薛定谔桥理论研究的证明（命题 4 和命题 5）。附录 G 给出了高斯目标和参考测度下 IPF 的定量研究。特别地，我们证明了在这种情况下 IPF 的收敛速度是几何的。在附录 H 中，我们研究连续时间与离散时间 IPF 之间的联系，并证明命题 6。我们还提供了由薛定谔桥获得的生成模型的似然计算细节。我们在附录 I 中详细介绍了改善训练时间的训练技巧，然后在附录 J 中给出架构细节和额外实验。

B 符号

为了便于阅读，我们在本节中回顾并详细说明第 1 节中引入的一些符号。对于任意可测空间 $(E, \mathcal{E})$ ，我们用 $\mathcal{P}(E)$ 表示 E 上的概率测度空间。对于任意 $\ell \in \mathbb{N}$ ，我们也用 $\mathcal{P}_\ell = \mathcal{P}((\mathbb{R}^d)^\ell)$ 表示。对于任意 $\pi \in \mathcal{P}(E)$ 和马尔可夫核 $K: E \times \mathcal{F} \rightarrow [0, 1]$ ，其中 $(F, \mathcal{F})$ 是可测空间，我们定义 $\pi K \in \mathcal{P}(F)$ ，使得对于任意 $A \in \mathcal{F}$ ，有 $\pi K(A) = \int_E K(x, A) d\pi(x)$ 。如果 $E = \mathcal{C}$ ，那么对于任意 $\mathbb{P} \in \mathcal{P}(E)$ 和 $s, t \in [0, T]$ ，我们用 $\mathbb{P}_{s,t}$ 表示 $\mathbb{P}$ 在时间 s 和 t 的边缘分布。此外，我们用 $\mathbb{P}_{|s,t}$ 表示由映射 $\omega \mapsto (\omega(s), \omega(t))$ 给出的分解马尔可夫核，定义见附录 D.1。特别地，我们有 $\mathbb{P} = \mathbb{P}_{s,t} \mathbb{P}_{|s,t}$ 。除非另有说明，所有定义的映射均视为可测的。

对于任意 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ ，我们定义 $\mathbb{P}^R$ 为逆向时间测度，即对于任意 $A \in \mathcal{B}(\mathcal{C})$ ，有 $\mathbb{P}^R(A) = \mathbb{P}(A^R)$ ，其中 $A^R = \{t \mapsto \omega(T-t) : \omega \in A\}$ 。若 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 满足相应的鞅问题，则称其为一个扩散过程相关联。更精确地， $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 与 $d\mathbf{X}_t = b(t, \mathbf{X}_t)dt + \sqrt{2}d\mathbf{B}_t$ 相关联，其中 $b: [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 可测，若对于任意 $v \in C^2$ ， $(M_t^v)_{t \in [0, T]}$ 是 $\mathbb{P}$ -局部鞅，其中对于任意 $t \in [0, T]$

$$M_t^v = v(\mathbf{X}_t) - \int_0^t \mathcal{A}_s(v)(\mathbf{X}_s) ds \quad (16)$$

对于任意 $v \in C^2(\mathbb{R}^d, \mathbb{R})$ ， $t \in [0, t]$ 和 $x \in \mathbb{R}^d$

$$\mathcal{A}_t(v)(x) = \langle b(t, x), \nabla v(x) \rangle + \Delta v(x).$$

关于局部鞅的严格处理，我们参考 Revuz 和 Yor (1999)。注意，对于任何满足 $t \geq s$ 的 $s, t \in [0, T]$ ，式 (16) 唯一地定义了 $\mathbb{P}_{t|s}$ 。因此， $\mathbb{P}$ 在 $\mathbb{P}_0$ 意义下是唯一确定的。

在某些情况下，若 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 满足相应初值条件下的鞅问题，则称其为一个扩散过程相关联。更精确地说，若 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 与 $d\mathbf{X}_t = b(t, \mathbf{X}_t)dt + \sqrt{2}d\mathbf{B}_t$ 及 $\mathbf{X}_0 \sim \mu_0 \in \mathcal{P}(\mathbb{R}^d)$ 相关联，当且仅当它解决该鞅问题且 $\mathbb{P}_0 = \mu_0$ 。注意此时 $\mathbb{P}$ 被唯一确定。

最后，对于任意可测空间 $(E, \mathcal{E})$ 和 $\mu, \nu \in \mathcal{P}(E)$ ，我们回顾杰弗里发散 (Jeffrey's divergence) 由 $J(\mu, \nu) = \text{KL}(\mu|\nu) + \text{KL}(\nu|\mu)$ 给出。

C 时间反演与现有工作

在给出定理 1 的证明之前，我们首先在附录 C.1 中，在初始密度满足增长条件的前提下，推导奥恩斯坦-乌伦贝克过程密度的对数导数估计。注意，我们的估计关于时间变量是一致的。我们给出定理 1 见附录 C.2。最后，我们在附录 C.3 中与现有工作建立联系。

C.1 对数导数的估计

我们首先回顾以下多元法阿·迪·布鲁诺公式及一个有用的技术引理。随后，在附录 C.1.1 中，我们推导出对于小时间非零的对数导数界。

在附录 C.1.2 中，我们推导出对于大时间非空的对数导数界。我们在附录 C.1.3 中将它们结合起来。对于任意 $\alpha \in \mathbb{N}^d$ ，我们记 $|\alpha| = \sum_{i=1}^d \alpha_i$ 以及 $\alpha! = \prod_{i=1}^d \alpha_i!$ 。如果 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 是 m 可微的且 $m \in \mathbb{N}$ ，那么对于任意具有 $|\lambda| \leq m$ 的 $\lambda \in \mathbb{N}^d$ ，我们对任意 $x \in \mathbb{R}^d$ ， $\partial_\lambda f(x) = \partial_1^{\lambda_1} \dots \partial_d^{\lambda_d} f(x)$ 记。与康斯坦丁和萨维茨 (1996) 类似，我们定义 $\prec$ 在 $\mathbb{N}^d$ 上的序，使得对于任意

$$\lambda, \lambda' \in \mathbb{N}^d, \lambda^1 \prec \lambda'^1 \text{ if } |\lambda^1| < |\lambda'^1| \text{ or } |\lambda^1| = |\lambda'^1| \text{ 并且存在 } j \in \{1, \dots, d\} \text{ 使得 } \lambda_j^1 < \lambda_j'^1 \text{ 并且对于任意 } i \in \{1, \dots, j\}, \lambda_i^1 = \lambda_i'^1.$$

命题 7. 设 $U \subset \mathbb{R}^d$ **open**, $N \in \mathbb{N}$, $f \in C^N(U, \mathbb{R})$, $g \in C^N(\mathbb{R}^d, \mathbb{R})$ 及 $h = f \circ g$ 。那么对于任意具有 $|\lambda| \leq N$ 和 $x \in \mathbb{R}^d$ 的 $\lambda \in \mathbb{N}^d$ ，我们有

$$\partial_\lambda h(x) = \sum_{k,s=1}^{|\lambda|} \sum_{p_s(\lambda,k)} f^{(k)}(g(x)) \lambda! \prod_{j=1}^s \partial_{\ell_j} g(x)^{m_j} / (m_j! \ell_j^{m_j}),$$

其中

$$p_s(\lambda, k) = \{ \{\ell_i\}_{i=1}^s \in (\mathbb{N}^d)^s, \{m_i\}_{i=1}^s \in \mathbb{N}^s : \ell_1 \prec \dots \prec \ell_s, \sum_{i=1}^s m_i = k, \sum_{i=1}^s m_i \ell_i = \lambda \}.$$

证明。该命题是康斯坦丁和萨维茨 (1996) 结果的直接应用。 $\square$

从这个多元法阿·迪·布鲁诺公式中，我们推导出以下引理，建立了指数导数与对数导数之间的联系。

引理 8. 设 $N \in \mathbb{N}$, $g_1 \in C^N(\mathbb{R}^d, \mathbb{R})$, $g_2 \in C^N(\mathbb{R}^d, (0, +\infty))$, $h_1 = \exp[g_1]$ 且 $h_2 = \log(g_2)$ 。则对于任意 $\lambda \in \mathbb{N}^d$ ，其中 $|\lambda| \leq N$ ，令 $c_{d,\lambda} = \sum_{k=1}^{|\lambda|} d^k$ ，以下结论成立：(a) 存在 $P_{\lambda, \exp}$ ，一个具有 $c_{d,\lambda}$ 个变量的实多项式，使得对于任意 $x \in \mathbb{R}^d$

$$\partial_\lambda h_1(x) = P_{\lambda, \exp}((\partial_\ell g_1(x))_{|\ell| \leq |\lambda|}) h_1(x).$$

(b) 存在 $P_{\lambda, \log}$ ，一个具有 $c_{d,\lambda}$ 个变量的实多项式，使得对于任意 $x \in \mathbb{R}^d$

$$\partial_\lambda h_2(x) = P_{\lambda, \log}((\partial_\ell g_2(x)/g_2(x))_{|\ell| \leq |\lambda|}).$$

证明。(a) 的证明是命题 7 的直接应用，注意到对于任意 $k \in \mathbb{N}$ ， $f^{(k)} = \exp$ ，若 $f = \exp$ 。类似地，(b) 的证明也是命题 7 的直接应用，注意到在 $f = \log$ 的情况下，对于任意 $k \in \mathbb{N}$ 和 $x > 0$ ， $f^{(k)}(x) = (-1)^{k-1} (k-1)! x^{-k}$ ，并且对于任意 $s \in \{1, \dots, |\lambda|\}$ 和 $(\ell_1, \dots, \ell_s, m_1, \dots, m_s) \in p_s(\lambda, k)$ ，我们有 $\sum_{i=1}^s m_i = k$ 。 $\square$

我们还将使用以下技术性引理。

引理 9. 设 $p \in \mathbb{N}$ 。则对于任意 $a \geq 0, b > 0$ 和 $x \in \mathbb{R}^d$ ，我们有

$$-b\|x\|^{2p} + a\|x\|^{2p-1} \leq -(b/2)\|x\|^{2p} + a(2a/b)^{2p-1}, \quad (17)$$

$$-b\|x\|^{2p} + a\|x\|^{2p-2} \leq -(b/2)\|x\|^{2p} + a(2a/b)^{p-1}. \quad (18)$$

此外，对于任意 $a \geq 0, b > 0$ 和 $x \in \mathbb{R}^d$ ，我们有

$$-b\|x\|^{2p} + a\|x\|^{2p-1} \leq (2p-1)^{2p-1} (2p)^{-2p} a^{2p} b^{1-2p}.$$

证明。对于证明的第一部分，我们仅证明 (17)。(18) 的证明类似。设 $a \geq 0$ 。对于任意 $b > 0$ 满足 $\|x\| \leq (b/2a)^{-1}$ 的 $x \in \mathbb{R}^d$ ，我们有 $a\|x\|^{2p-1} \leq a(b/2a)^{-2p+1}$ 。对于任意 $x \in \mathbb{R}^d$ 利用 $\|x\| \geq (b/2a)^{-1}$ 可得 $a\|x\|^{2p-1} \leq (b/2)\|x\|^{2p}$ 。因此，对于任意 $x \in \mathbb{R}^d$ ，我们有

$$a\|x\|^{2p-1} - b\|x\|^{2p} \leq a(b/2a)^{-2p+1} - (b/2)\|x\|^{2p},$$

这完成了证明的第一部分。对于证明的第二部分，注意到 $h: t \mapsto -bt^{2p} + at^{2p-1}$ 的最大值在 $t^* = (2p-1)/(2p)(a/b)$ 处取得。我们通过注意到 $h(t^*) = (2p-1)^{2p-1} (2p)^{-2p} a^{2p} b^{1-2p}$ 得出结论。 $\square$

C.1.1 小时间估计

引理 8 在以下命题中起关键作用，该命题建立了奥恩斯坦-乌伦贝格过程密度对数导数的上界。在下文中，我们定义 $(p_t)_{t \in [0, T]}$ 为关于勒贝格测度的 $\mathbf{X}_t$ 的密度，满足 $d\mathbf{X}_t = -\alpha \mathbf{X}_t dt + \sqrt{c_t} d\mathbf{B}_t$ ，且 $\alpha \geq 0$ 。在本节其余部分， α 固定。

命题 10. 设 $N \in \mathbb{N}$ 。假设 $p_{\text{data}} \in C^N(\mathbb{R}^d, (0, +\infty))$ 有界，且对于任意 $\ell \in \{1, \dots, N\}$ ，存在 $A_\ell \geq 0$ 和 $\alpha_\ell \in \mathbb{N}$ ，使得对于任意 $x \in \mathbb{R}^d$

$$\|\nabla^\ell \log p_{\text{data}}(x)\| \leq A_\ell(1 + \|x\|^{\alpha_\ell}). \quad (19)$$

则对于任意以及对于任意 $C^N(\mathbb{R}^d, (0, +\infty))$ $\ell \in \{1, \dots, N\}$ ，存在 $B_\ell \geq 0$ 以及 $\beta_\ell \in \mathbb{N}$ ，使得对于任意 $t \geq 0$

$$\|\nabla^\ell \log p_t(x)\| \leq c_t^{-2\beta_\ell} B_\ell(1 + \int_{\mathbb{R}^d} \|x_0\|^{\beta_\ell} p_{0|t}(x_0|x_t) dx_0),$$

含 $c_t^2 = \exp[-2\alpha t]$ 。

证明。首先注意到对于任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$ ，我们有

$$p_t(x_t) = \int_{\mathbb{R}^d} p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0, \quad (20)$$

对于任意 $\tilde{x} \in \mathbb{R}^d$

$$c_t = \exp[-\alpha t], \quad g(\tilde{x}) = (2\pi\sigma_t^2)^{-d/2} \exp[-\|\tilde{x}\|^2/(2\sigma_t^2)], \quad \sigma_t^2 = (1 - \exp[-2\alpha t])/\alpha.$$

设 $t \geq 0$ 。结合 p_{data} 有界这一事实，(20) 式以及控制收敛定理，我们得到 $p_t \in C^N(\mathbb{R}^d, (0, +\infty))$ 。设 $\ell \in \{1, \dots, N\}$ 和 $\lambda \in \mathbb{N}^d$ 使得 $|\lambda| \leq \ell$ 。利用引理 8-(b)，对于任意 $x_t \in \mathbb{R}^d$ 我们有

$$\partial_\lambda \log p_t(x_t) = P_{\lambda, \log}((\partial_m p_t(x_t)/p_t(x_t))_{|m| \leq |\lambda|}). \quad (21)$$

利用 (20) 式并作变量替换

$z = x_t - c_t x_0$ ，对于任意 $x_t \in \mathbb{R}^d$ 我们有

$\int_{\mathbb{R}^d} p_{\text{data}}((x_t - z)/c_t) g(z) dz p_t(x_t) = c_t^{-1}$ 。因此，结合该结果、控制收敛定理以及引理 8-(a)，我们得到对于任意 $x_t \in \mathbb{R}^d$ 和 $m \in \mathbb{N}^d$ 且满足 $|m| \leq \ell$ 时

$$\begin{aligned} \partial_m p_t(x_t) &= c_t^{-|m|} \int_{\mathbb{R}^d} \partial_m p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0 \\ &= c_t^{-|m|} \int_{\mathbb{R}^d} P_{m, \exp}((\partial_j \log p_{\text{data}}(x_0))_{|j| \leq |m|}) p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0. \end{aligned}$$

We conclude the proof upon combining this result, (19), (21) and the fact that $c_t \leq 1$. $\square$

对于任意 $t \geq 0$ $x_t \in \mathbb{R}^d$ 我们引入无穷小生成元

$$\mathcal{A}_{t, x_t} : C_2(\mathbb{R}^d, \mathbb{R}) \rightarrow C_2(\mathbb{R}^d, \mathbb{R})$$

对于任意 $\varphi \in C^2(\mathbb{R}^d, \mathbb{R})$ 及 $x_0 \in \mathbb{R}^d$ by

$$\mathcal{A}_{t, x_t}(\varphi)(x_0) = \langle \nabla_{x_0} \log p_{0|t}(x_0|x_t), \nabla \varphi(x_0) \rangle + \Delta \varphi(x_0) \quad (22)$$

$= \langle \nabla \log p_{\text{data}}(x_0), \nabla \varphi(x_0) \rangle + (c_t/\sigma_t^2) \langle x_t - c_t x_0, \nabla \varphi(x_0) \rangle + \Delta \varphi(x_0)$ 。为该无穷小生成元建立福斯特-李雅普诺夫漂移条件，将使我们能够推导出 $x_0 \mapsto p_{0|t}(x_0|x_t)$ 的矩界。现在引入李雅普诺夫泛函，以控制这些矩。对于任意 $p \in \mathbb{N}$, $t > 0$ 和 $x_t \in \mathbb{R}^d$ ，令 $V_{p, t, x_t} : \mathbb{R}^d \rightarrow [1, +\infty)$ 对任意 $x_0 \in \mathbb{R}^d$ 由 $V_{p, t, x_t}(x_0) = 1 + \|x_0 - x_t/c_t\|^{2p}$ ， $c_t = \exp[-\alpha t]$ 给出。

命题 11. 假设

$p_{\text{data}} \in C^1(\mathbb{R}^d, \mathbb{R})$ ，且存在

$m_0 > 0, d_0, C_0 \geq 0$ 使得对于我们

任意 $x_0 \in \mathbb{R}^d$

$$\langle x_0, \nabla \log p_{\text{data}}(x_0) \rangle \leq -m_0 \|x_0\|^2 + d_0 \|x_0\|, \quad \|\nabla \log p_{\text{data}}(x_0)\| \leq C_0(1 + \|x_0\|). \quad (23)$$

则对于任意 $t > 0, x_t \in \mathbb{R}^d$ 和 $p \in \mathbb{N}$ ，存在 $\beta_p \in \mathbb{N}$, $a_p > 0$ 和 $b_p \geq 0$ （与 t 和 x_t 无关），使得对于任意 $x_0 \in \mathbb{R}^d$ 我们有 $\mathcal{A}_{t, x_t}(V_{p, t, x_t})(x_0) \leq -a_p V_{p, t, x_t}(x_0) + b_p(1 + \|x_t/c_t\|^{\beta_p})$ ，其中 $\beta_p = 2p$ 。

证明。令 $t \geq 0, x_0, x_t \in \mathbb{R}^d$ 和 $p \in \mathbb{N}$ 。首先，对于任意 $x_0 \in \mathbb{R}^d$ 我们有

$$\begin{aligned} V_{p,t,x_t}(x_0) &= \|x_0 - x_t/c_t\|^{2p}, \quad \nabla V_{p,t,x_t}(x_0) = 2p(x_0 - x_t/c_t)\|x_0 - x_t/c_t\|^{2(p-1)}, \\ \Delta V_{p,t,x_t}(x_0) &= 2p(2p-1)\|x_0 - x_t/c_t\|^{2(p-1)}. \end{aligned} \quad (24)$$

其次，利用引理 9、柯西-施瓦茨不等式和 (23)，对于任意 $x_0 \in \mathbb{R}^d$ 我们有

$$\begin{aligned} \langle \nabla \log p_{\text{data}}(x_0), x_0 - x_t/c_t \rangle &\leq -\mathfrak{m}_0 \|x_0\|^2 + d_0 \|x_0\| + \|\nabla \log p_{\text{data}}(x_0)\| \|x_t/c_t\| \\ &\leq -\mathfrak{m}_0 \|x_0 - x_t/c_t\|^2 + 2\mathfrak{m}_0 \|x_0\| \|x_t\|/c_t + C_0(1 + \|x_0\|) \|x_t\|/c_t \\ &\quad + d_0 \|x_0 - x_t/c_t\| + d_0 \|x_t\|/c_t + \mathfrak{m}_0 \|x_t\|^2/c_t^2 \\ &\leq -\mathfrak{m}_0 \|x_0 - x_t/c_t\|^2 + \{(2\mathfrak{m}_0 + C_0)\|x_t\|/c_t + d_0\} \|x_0 - x_t/c_t\| \\ &\quad + (3\mathfrak{m}_0 + C_0) \|x_t\|^2/c_t^2 + (C_0 + d_0) \|x_t\|/c_t. \end{aligned}$$

结合该结果与 (24)，对于任意 $x_0 \in \mathbb{R}^d$ 我们有

$$\begin{aligned} \langle \nabla \log p_{\text{data}}(x_0), \nabla V_{p,t,x_t}(x_0) \rangle &\leq -2p\mathfrak{m}_0 \|x_0 - x_t/c_t\|^{2p} + 2p\{(2\mathfrak{m}_0 + C_0)\|x_t\|/c_t + d_0\} \|x_0 - x_t/c_t\|^{2p-1} \\ &\quad + 2p((3\mathfrak{m}_0 + C_0)\|x_t\|^2/c_t^2 + (C_0 + d_0)\|x_t\|/c_t) \|x_0 - x_t/c_t\|^{2p-2}. \end{aligned}$$

结合该结果与 (22) 以及对于任意 $x_0 \in \mathbb{R}^d, (c_t/\sigma^2 \rightarrow 0)$ 的事实，我们得 $\langle x_t - c_t x_0, \nabla V_{p,t,x_t}(x_0) \rangle \leq 0$ 对于任意 $x_0 \in \mathbb{R}^d$

$$\begin{aligned} \mathcal{A}_{t,x_t}(V_{p,t,x_t})(x_0) &\leq -2p\mathfrak{m}_0 \|x_0 - x_t/c_t\|^{2p} + 2p\{(2\mathfrak{m}_0 + C_0)\|x_t\|/c_t + d_0\} \|x_0 - x_t/c_t\|^{2p-1} \\ &\quad + 2p((3\mathfrak{m}_0 + C_0)\|x_t\|^2/c_t^2 + (C_0 + d_0)\|x_t\|/c_t) \|x_0 - x_t/c_t\|^{2p-2}. \end{aligned}$$

利用引理 9，存在 $\beta_p \in \mathbb{N}, a_p > 0$ 和 $b_p \geq 0$ （与 x_t 和 t 无关），使得对于任意 $x_0 \in \mathbb{R}^d$ 我们有

$$\mathcal{A}_{t,x_t}(V_{p,t,x_t})(x_0) \leq -a_p V_{p,t,x_t}(x_0) + b_p(1 + (\|x_t\|/c_t)^{\beta_p}),$$

这完成了证明。 $\square$

利用该福斯特-李雅普诺夫漂移，我们现在可以界定 $x_0 \mapsto p_{0|t}(x_0|x_t)$ 的矩。

命题 12. 假设 $p_{\text{data}} \in C^2(\mathbb{R}^d, \mathbb{R})$ 且存在 $\mathfrak{m}_0 > 0, d_0, C_0 \geq 0$ 使得对任意 $x_0 \in \mathbb{R}^d$ 有

$$\langle x_0, \nabla \log p_{\text{data}}(x_0) \rangle \leq -\mathfrak{m}_0 \|x_0\|^2 + d_0 \|x_0\|, \quad \|\nabla \log p_{\text{data}}(x_0)\| \leq C_0(1 + \|x_0\|).$$

那么，对任意 $p \in \mathbb{N}$ 存在 $C_p \geq 0$ 和 $\beta_p \in \mathbb{N}$ 使得对任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$

$$\int_{\mathbb{R}^d} \|x_0\|^p p(x_0|x_t) dx_0 \leq C_p c_t^{-2\beta_p} (1 + \|x_t\|^{\beta_p}), \quad (25)$$

含 $c_t^2 = \exp[-2\alpha t]$ 及 $\beta_p = p$ 。

证明。令 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$ 。利用 (Ikeda 和 Watanabe, 1989, 定理 2.3, 定理 3.1)、命题 11 和 (Meyn 和 Tweedie, 1993, 定理 2.1)，对任意 $x \in \mathbb{R}^d$ ，存在唯一强解 $(\mathbf{X}_u^x)_{u \geq 0}$ 使得及

$$\mathbf{X}_0^x \sim \delta_x$$

$$d\mathbf{X}_u^x = \nabla \log p_{0|t}(\mathbf{X}_u^x|x_t) du + \sqrt{2} dB_u.$$

利用 (Leha 和 Ritter, 1984, 定理 5.19) 可得 $\{(\mathbf{X}_u^x)_{u \geq 0} : x \in \mathbb{R}^d\}$ 与一个费勒半群相关联。此外，对任意 $f \in C^2$ 有 $\int_{\mathbb{R}^d} \mathcal{A}_{t,x_t}(f)(x_0) p_{0|t}(x_0|x_t) dx_0 = 0$ 。因此，利用 (Revuz 和 Yor, 1999, 命题 1.5) 和 (Ethier 和 Kurtz, 1986, 定理 9.17) 可得，密度为 $x_0 \mapsto p_{0|t}(x_0|x_t)$ 的概率分布是与 $\{(\mathbf{X}_u^x)_{u \geq 0} : x \in \mathbb{R}^d\}$ 相关联的半群的不变分布。因此，利用命题 11 和 (Meyn 和 Tweedie, 1993, 定理 4.6) 可得，对任意 $p \in \mathbb{N}$ 有

$\int_{\mathbb{R}^d} (1 + \|x_0 - c_t^{-1} x_t\|^{2p}) p_{0|t}(x_0|x_t) dx_0 \leq b_p(1 + \|x_t/c_t\|^{\beta_p})/a_p$ ，再利用 $c_t \leq 1$ 和詹森不等式即完成证明。 $\square$

C.1.2 长时间估计 在命题 12 中, (25) 中的界当 $t \rightarrow +\infty$ 时趋于 $+\infty$, 因为 $\lim_{t \rightarrow +\infty} c_t^{-1} = +\infty$ (若 $\alpha > 0$). 这在我们设定中不会产生退化, 因为我们考虑固定时间范围 $T > 0$ 。然而, 我们可以通过推导另一个界来改进结果, 该界在 $t \rightarrow +\infty$ 处有界, 但在 $t \rightarrow 0$ 处发散。本节假设 $h: u \mapsto (\exp[u] - 1)/u$ 通过连续性延拓到 0, 且 $h(0) = 1$ 。

以下命题是命题 10 的等价形式, 其界在 $t \rightarrow 0$ 处发散而非 $t \rightarrow +\infty$ 处。注意, 与命题 10 不同, 我们不需要初始分布 p_{data} 的任何可微性条件。

命题 13. 设 $N \in \mathbb{N}$ 。假设 $p_{\text{data}} \in C^0(\mathbb{R}^d, (0, +\infty))$ 有界。则对任意 $t \geq 0$, $p_t \in C^N(\mathbb{R}^d, (0, +\infty))$ 及任意 $\ell \in \{1, \dots, N\}$, 存在 $B_\ell \geq 0$ 和 $\beta_\ell \in \mathbb{N}$ 使得对任意 $t \geq 0$

$$\begin{aligned} \|\nabla^\ell \log p_t(x)\| &\leq \sigma_t^{-\beta_\ell} B_\ell (1 + \int_{\mathbb{R}^d} \|x_t - c_t x_0\|^{\beta_\ell} p_{0|t}(x_0|x_t) dx_0) \\ &\leq \sigma_t^{-\beta_\ell} B_\ell (1 + \int_{\mathbb{R}^d} \|x_t - x_0\|^{\beta_\ell} q_{0|t}(x_0|x_t) dx_0). \\ \sigma_t^2 &= (1 - \exp[-2\alpha t])/\alpha \text{ 其中且对任意 } \tilde{x} \in \mathbb{R}^d \\ q_{0|t}(x_0|x_t) &= p_{\text{data}}(x_0/c_t) g(x_t - x_0) / \int_{\mathbb{R}^d} p_{\text{data}}(x_0/c_t) g(x_t - x_0) dx_0, \\ g(\tilde{x}) &= (2\pi\sigma_t^2)^{-d/2} \exp[-\|\tilde{x}\|^2/(2\sigma_t^2)]. \end{aligned}$$

证明。首先注意到对于任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$, 我们有

$$p_t(x_t) = \int_{\mathbb{R}^d} p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0, \quad (26)$$

其中

$$c_t = \exp[-\alpha t], \quad g(\tilde{x}) = (2\pi\sigma_t^2)^{-d/2} \exp[-\|\tilde{x}\|^2/(2\sigma_t^2)], \quad \sigma_t^2 = (1 - \exp[-2\alpha t])/\alpha.$$

设 $t \geq 0$ 。结合 p_{data} 有界、(26) 式及控制收敛定理, 可得 $p_t \in C^N(\mathbb{R}^d, (0, +\infty))$ 。设 $\ell \in \{0, \dots, N\}$ 和 $\lambda \in \mathbb{N}^d$ 使得 $|\lambda| \leq \ell$ 。利用引理 8-(b), 对任意 $x_t \in \mathbb{R}^d$ 有

$$\partial_\lambda \log p_t(x_t) = P_{\lambda, \log}((\partial_m p_t(x_t)/p_t(x_t))_{|m| \leq |\lambda|}).$$

对任意满足 $|m| \leq |\lambda|$ 的 $m \in \mathbb{N}^d$, 利用控制收敛定理, 存在 $C_m \geq 0$ 和 $\beta_m \in \mathbb{N}$ 使得对任意 $x_t \in \mathbb{R}^d$ 有

$$|\partial_m p_t(x_t)| \leq C_m \sigma_t^{-2\beta_m} \int_{\mathbb{R}^d} (1 + \|x_t - c_t x_0\|^{\beta_m}) p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0,$$

这完成了证明。 $\square$

对任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$, 引入无穷小生成元 $\tilde{\mathcal{A}}_{t, x_t}$, 其定义为对任 $\varphi \in C_c^\infty(\mathbb{R}^d, \mathbb{R})$ $x_0 \in \mathbb{R}^d$ 有及

$$\begin{aligned} \tilde{\mathcal{A}}_{t, x_t}(f)(x_0) &= \langle \nabla \log q_{0|t}(x_0|x_t), \nabla \varphi(x_0) \rangle + \Delta \varphi(x_0) \\ &= c_t^{-1} \langle \nabla \log p_{\text{data}}(x_0/c_t), \nabla \varphi(x_0) \rangle + \sigma_t^{-2} \langle x_t - x_0, \nabla \varphi(x_0) \rangle + \Delta \varphi(x_0). \end{aligned}$$

$p \in \mathbb{N}$, let $V_p: \mathbb{R}^d \rightarrow [1, +\infty)$ 对任意给定的对任意 $x_0 \in \mathbb{R}^d$ by

$$V_p(x_0) = 1 + \|x_0\|^{2p}.$$

以下命题是命题 11 的对应版本。

命题 14. 假设 $\text{Ass } p_{\text{data}} \in C^1(\mathbb{R}^d, \mathbb{R})$, 且存在 $m_0 > 0, d_0 \geq 0$ 使得对于 any $x_0 \in \mathbb{R}^d$ we have

$$\langle x_0, \nabla \log p_{\text{data}}(x_0) \rangle \leq -m_0 \|x_0\|^2 + d_0 \|x_0\|. \quad (27)$$

Then for any $t > 0, x_t \in \mathbb{R}^d$ and $p \in \mathbb{N}$ there exist $\beta_p \in \mathbb{N}, a_p > 0$ and $b_p \geq 0$ (independent of t and x_t) such that for any $x_0 \in \mathbb{R}^d$ we have

$$\tilde{\mathcal{A}}_{t, x_t}(V_p)(x_0) \leq -a_p \sigma_t^{-2} V_p(x_0) + b_p (1 + \|x_t/\sigma_t\|^{2\beta_p}),$$

含 $\beta_p = 2p$.

证明。令 $t \geq 0, x_0, x_t \in \mathbb{R}^d$ 和 $p \in \mathbb{N}$ 。首先，对于任意 $x_0 \in \mathbb{R}^d$ 我们有

$$V_p(x_0) = 1 + \|x_0\|^{2p}, \quad \nabla V_p(x_0) = 2p \|x_0\|^{2(p-1)} x_0, \quad \Delta V_p(x_0) = 2p(2p-1) \|x_0\|^{2(p-1)}.$$

利用该结果、(27) 式及引理 9，可得对于任意 $x_0 \in \mathbb{R}^d$

$$\begin{aligned} 2p \langle \nabla \log p_{\text{data}}(x_0/c_t), x_0/c_t \rangle \|x_0\|^{2(p-1)} &\leq 2pc_t^{-1} (-\mathfrak{m}_0 \|x_0\|^{2p}/c_t + d_0 \|x_0\|^{2p-1}) \\ &\leq c_t^{-1} (2p-1)^{2p-1} (2p)^{1-2p} (\mathfrak{m}_0/c_t)^{1-2p} d_0^{2p}. \end{aligned}$$

结合该结果与 $c_t \leq 1$ 的事实，存在 $d_p \geq 0$ （独立于 t 和 x_t ）使得对于任意 $x_0 \in \mathbb{R}^d$

$$2p \langle \nabla \log p_{\text{data}}(x_0/c_t), x_0/c_t \rangle \|x_0\|^{2(p-1)} \leq d_p. \quad (28)$$

In addition, we have for any $x_0 \in \mathbb{R}^d$

$$\begin{aligned} (2p/\sigma_t^2) \langle x_0, x_t - x_0 \rangle \|x_0\|^{2(p-1)} + 2p(2p-1) \|x_0\|^{2(p-1)} \\ \leq -(2p/\sigma_t^2) \|x_0\|^{2p} + (2p/\sigma_t^2) \|x_0\|^{2p-1} \|x_t\| + 2p(2p-1) \|x_0\|^{2p-1} + 2p(2p-1). \end{aligned}$$

结合该结果与 (28) 式，可得对于任意 $x_0 \in \mathbb{R}^d$

$$\begin{aligned} \tilde{\mathcal{A}}_{t,x_t}(V_p)(x_0) \\ \leq -(2p/\sigma_t^2) \|x_0\|^{2p} + (2p/\sigma_t^2) \|x_0\|^{2p-1} \|x_t\| + 2p(2p-1) \|x_0\|^{2p-1} + 2p(2p-1) + d_p. \end{aligned}$$

利用引理 9 即可得出结论。 $\square$

下一个命题是命题 12 的对应版本。

命题 15。 假设 $\text{Ass } p_{\text{data}} \in C^2(\mathbb{R}^d, \mathbb{R})$ ，且存在 $\mathfrak{m}_0 > 0, d_0 \geq 0$ 使得对于 any $x_0 \in \mathbb{R}^d$ we have

$$\langle x_0, \nabla \log p_{\text{data}}(x_0) \rangle \leq -\mathfrak{m}_0 \|x_0\|^2 + d_0 \|x_0\|.$$

那么，对任意 $p \in \mathbb{N}$ 存在 $C_p \geq 0$ 和 $\beta_p \in \mathbb{N}$ 使得对任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$

$$\int_{\mathbb{R}^d} \|x_t - x_0\|^p q_{0|t}(x_0|x_t) dx_0 \leq C_p \sigma_t^{-2\beta_p} (1 + \|x_t\|^{\beta_p}),$$

含 $\sigma_t^2 = (1 - \exp[-2\alpha t])/\alpha$ 及 $\beta_p = p$.

证明。该证明与命题 12 的证明类似。 $\square$

C.1.3 时间一致的对数导数估计

在本节中，我们结合附录 C.1.2 和附录 C.1.1 的结果，建立奥恩斯坦-乌伦贝克扩散密度对数导数的时间一致估计。

定理 16。 设 $N \in \mathbb{N}$ 且 $N \geq 2$ 。假设 $p_{\text{data}} \in C^N(\mathbb{R}^d, \mathbb{R})$ 且存在 $\mathfrak{m}_0 > 0, d_0, C_0 \geq 0$ 使得对任意 $x_0 \in \mathbb{R}^d$ 有

$$\langle x_0, \nabla \log p_{\text{data}}(x_0) \rangle \leq -\mathfrak{m}_0 \|x_0\|^2 + d_0 \|x_0\|, \quad \|\nabla \log p_{\text{data}}(x_0)\| \leq C_0(1 + \|x_0\|).$$

此外，假设 p_{data} 有界，且对任意 $\ell \in \{1, \dots, N\}$ 存在 $A_\ell \geq 0$ 和 $\alpha_\ell \in \mathbb{N}$ 使得对任意 $x_0 \in \mathbb{R}^d$ 有

$$\|\nabla^\ell \log p_{\text{data}}(x_0)\| \leq A_\ell(1 + \|x_0\|^{\alpha_\ell}). \quad (29)$$

则对于任意以及对于任意 $C^N(\mathbb{R}^d, (0, +\infty))$ $\ell \in \{1, \dots, N\}$ ，存在 $D_\ell \geq 0$

以及 $\beta_\ell \in \mathbb{N}$ ，使得对于任意 $t \geq 0$

$$\|\nabla^\ell \log p_t(x_t)\| \leq D_\ell(1 + \|x_t\|^{\beta_\ell}).$$

In particular if $\alpha_1 = 1$ then $\beta_1 = 1$.

证明。设 $t \geq 0$ 和 $\ell \in \{1, \dots, N\}$ 。利用命题 10 和命题 12, 存在 $D_\ell^1 \geq 0$ 和 $\beta_\ell^1 \in \mathbb{N}$ 使得对任意 $x_t \in \mathbb{R}^d$ 有

$$\|\nabla^\ell \log p_t(x_t)\| \leq D_\ell^1 c_t^{-2\beta_\ell^1} (1 + \|x_t\|^{\beta_\ell^1}).$$

Similarly, using Proposition 13 and Proposition 15 there exist $D_\ell^2 \geq 0$ and $\beta_\ell^2 \in \mathbb{N}$ such that for any $x_t \in \mathbb{R}^d$ we have

$$\|\nabla^\ell \log p_t(x_t)\| \leq D_\ell^2 (\alpha^{1/2} \sigma_t)^{-2\beta_\ell^2} (1 + \|x_t\|^{\beta_\ell^2}).$$

因此, 存在 $\tilde{D}_\ell \geq 0$ 和 $\beta_\ell \in \mathbb{N}$ 使得对任意 $x_t \in \mathbb{R}^d$ 有

$$\|\nabla^\ell \log p_t(x_t)\| \leq \tilde{D}_\ell \min(\alpha^{-1} \sigma_t^{-2}, c_t^{-2})^{\beta_\ell} (1 + \|x_t\|^{\beta_\ell}).$$

Since for any $c_t^{-2} = \exp[2\alpha t]$ 及 $\alpha^{-1} \sigma_t^{-2} = (1 - \exp[-2\alpha t])^{-1} \min(\alpha^{-1} \sigma_t^{-2}, c_t^{-2})^{\beta_\ell} \leq \max\{\min(1/u, 1/(1-u)) : u \in [0, 1]\} \leq 2^{\beta_\ell}$, , 这完成了第一部分的证明。我们现在证明若 $\alpha_1 = 1$ 则 $\beta_1 = 1$ 。回顾对任意 $t \geq 0$ 和 $x_t \in \mathbb{R}^d$ 有

$$p_t(x_t) = \int_{\mathbb{R}^d} p_{\text{data}}(x_0) g(x_t - c_t x_0) dx_0,$$

对于任意 $\tilde{x} \in \mathbb{R}^d$

$$c_t = \exp[-\alpha t], \quad g(\tilde{x}) = (2\pi\sigma_t^2)^{-d/2} \exp[-\|\tilde{x}\|^2 / (2\sigma_t^2)], \quad \sigma_t^2 = (1 - \exp[-2\alpha t]) / \alpha.$$

因此, 利用控制收敛定理可得, 对任意 $x_t \in \mathbb{R}^d$

$$\nabla \log p_t(x_t) = \sigma_t^{-2} \int_{\mathbb{R}^d} (x_t - c_t x_0) p_{0|t}(x_0 | x_t) dx_0 = \sigma_t^{-2} \int_{\mathbb{R}^d} (x_t - c_t x_0) q_{0|t}(x_0 | x_t) dx_0. \quad (30)$$

类似地, 利用控制收敛定理与变量替换 $z = x_t - c_t x_0$, 可得对任意 $x_t \in \mathbb{R}^d$

$$\nabla \log p_t(x_t) = c_t^{-1} \int_{\mathbb{R}^d} \nabla \log p_{\text{data}}(x_0) p_{0|t}(x_0 | x_t) dx_0.$$

结合该结果、(30)、(29) 与 $\alpha_1 = 1$ 、命题 15 及命题 12, 证明完成。特别地, 此处用到 $\beta_1 = 1$ 。□

C.2 定理 1 的证明

首先回顾以下基本引理。

引理 17。 设 $(E, \mathcal{E})$ 与 $(F, \mathcal{F})$ 为两个可测空间, $K : E \times F \rightarrow [0, 1]$ 为马尔可夫核。则对任意 $\mu_0, \mu_1 \in \mathcal{P}(E)$, 有

$$\|\mu_0 K - \mu_1 K\|_{\text{TV}} \leq \|\mu_0 - \mu_1\|_{\text{TV}}.$$

此外, 对任意可测的 $\varphi : E \rightarrow F$, 可得

$$\|\varphi_\# \mu_0 - \varphi_\# \mu_1\|_{\text{TV}} \leq \|\mu_0 - \mu_1\|_{\text{TV}},$$

当 φ 为单射时等号成立。

证明。我们将证明分为两部分。

- (a) 注意到对于任意满足 $\|f\|_\infty \leq 1$ 的 $f : F \rightarrow \mathbb{R}$, 我们有 $\|Kf\|_\infty \leq 1$ 。利用这一结果可得
- $$\begin{aligned} \|\mu_0 K - \mu_1 K\|_{\text{TV}} &= \sup\{\int_F f(y) d(\mu_0 K)(y) - \int_F f(y) d(\mu_1 K)(y) : \|f\|_\infty \leq 1\} \\ &= \sup\{\int_E Kf(x) d\mu_0(x) - \int_E Kf(x) d\mu_1(x) : \|f\|_\infty \leq 1\} \leq \|\mu_0 - \mu_1\|_{\text{TV}}. \end{aligned}$$

(b) 我们有

$$\begin{aligned} \|\varphi_\# \mu_0 - \varphi_\# \mu_1\|_{\text{TV}} &= \sup\{\int_E f(\varphi(x)) d\mu_0(x) - \int_E f(\varphi(x)) d\mu_1(x) : \|f\|_\infty \leq 1\} \\ &\leq \sup\{\int_E f(x) d\mu_0(x) - \int_E f(x) d\mu_1(x) : \|f\|_\infty \leq 1\} \leq \|\mu_0 - \mu_1\|_{\text{TV}}. \end{aligned}$$

若 φ 为单射, 则存在 (可测的) $\varphi^{-1} : F \rightarrow E$ 使得 $\varphi^{-1} \circ \varphi = \text{Id}$ 。因此, 对于任意满足 $\|f\|_\infty \leq 1$ 的 $f : E \rightarrow \mathbb{R}$, 我们有 $f = (f \circ \varphi^{-1}) \circ \varphi$ 和 $\|f \circ \varphi^{-1}\|_\infty \leq 1$ 。于是我们得到

$$\begin{aligned} \|\mu_0 - \mu_1\|_{\text{TV}} &= \sup\{\int_E f(x) d\mu_0(x) - \int_E f(x) d\mu_1(x) : \|f\|_\infty \leq 1\} \\ &\leq \sup\{\int_E f(\varphi(x)) d\mu_0(x) - \int_E f(\varphi(x)) d\mu_1(x) : \|f\|_\infty \leq 1\} \leq \|\varphi_\# \mu_0 - \varphi_\# \mu_1\|_{\text{TV}}, \end{aligned}$$

这完成了证明。

□

我们还将利用以下不等式。

引理 18. *Let $\varepsilon > 0$, $x, y \in \mathbb{R}^d$, $t > 2/\varepsilon$ and $\varphi : [0, 1] \rightarrow \mathbb{R}$ such that for any $s \in [0, 1]$, $\varphi(s) = \exp[-\|x - sy\|^2/(4t)]$. 则 $\varphi \in C^1([0, 1], \mathbb{R})$, 且对于任意 $s \in [0, 1]$*

$$|\varphi'(s)| \leq 2(1 + \varepsilon^{-1})(1 + \|x\|) \exp[-\|x\|^2/(8t)] \exp[\varepsilon \|y\|^2/t].$$

证明。令 $s \in [0, 1]$, 我们有

$$\varphi'(s) = (\langle x, y \rangle - s \|y\|^2) \exp[-\|x - sy\|^2/(4t)]/(2t).$$

利用柯西-施瓦茨不等式以及对于任意 $a, b \in \mathbb{R}^d$, $-\|a + b\|^2 \leq -\|a\|^2/2 + \|b\|^2$

we get

$$|\varphi'(s)| \leq (\|x\| \|y\| + \|y\|^2) \exp[-\|x\|^2/(8t) + \|y\|^2/(4t)]/(2t). \quad (31)$$

In addition, we have

$$\|y\| \exp[\|y\|^2/(4t)] \leq \|y\| \exp[\varepsilon \|y\|^2/2] \leq (1 + \|y\|^2) \exp[\varepsilon \|y\|^2/2] \leq 2(1 + \varepsilon^{-1}) \exp[\varepsilon \|y\|^2]. \quad (32)$$

最后我们还有 $\|y\|^2 \exp[\|y\|^2/(4t)] \leq (1 + \varepsilon^{-1}) \exp[\varepsilon \|y\|^2]$ 。结合这一结果、(31) 和 (32) 即可完成证明。□

最后, 我们展示以下引理, 它是吉尔萨诺夫定理 (Liptser 和 Shiryaev, 2001, 定理 7.7) 的直接推论。该引理的一个类似版本可在 (Durmus 和 Moulines, 2017, 命题 2) 的证明以及 (Laumont 等, 2021, 引理 26) 中找到 (其中漂移项对 $w \in C([0, T], \mathbb{R}^d)$ 的依赖被替换为对 $x \in \mathbb{R}^d$ 的 (更简单的) 依赖)。关于半群、非预期过程和扩散型过程的定义, 我们参考 (Liptser 和 Shiryaev, 2001, 第 4 节)。可测且使得对于

Lemma 19. *Let $T > 0$, $b_1, b_2 : [0, +\infty) \times C([0, T], \mathbb{R}^d) \rightarrow \mathbb{R}^d$*

any $i \in \{1, 2\}$ and $x \in \mathbb{R}^d$, $d\mathbf{X}_t^{(i)} = b_i(t, (\mathbf{X}_s^{(i)})_{s \in [0, T]})dt + \sqrt{2}d\mathbf{B}_t$ 存在唯一的强解

solution with $\mathbf{X}_0^{(i)} = x$ 及 $(b_i(t, (\mathbf{X}_s^{(i)})_{s \in [0, T]}))_{t \in [0, T]}$ 是非预期的, 具有马

$(P_t^{(i)})_{t \geq 0}$ 尔可夫半群。此外, 假设对于任意 $x \in \mathbb{R}^d$ 和 $i \in \{1, 2\}$, $\mathbb{P}(\int_0^T \{\|b_i(t, (\mathbf{X}_s^{(i)})_{s \in [0, T]})\|^2 + \|b_i(t, (\mathbf{B}_s)_{s \in [0, T]})\|^2\} dt < +\infty) = 1$ 。那么对于任意 $x \in \mathbb{R}^d$ 我们有

$$\|\delta_x P_T^{(1)} - \delta_x P_T^{(2)}\|_{TV}^2 \leq (1/2) \int_0^T \mathbb{E}[\|b_1(t, (\mathbf{X}_s^{(1)})_{s \in [0, T]}) - b_2(t, (\mathbf{X}_s^{(1)})_{s \in [0, T]})\|^2] dt.$$

证明。 令 $\mu_x^{(i)} = \mathbb{P}((\mathbf{X}_t^{(i)})_{t \in [0, T]} \in \cdot | \mathbf{X}_0^{(i)} = x)$ 和 $\mu_B^{(i)} = \mathbb{P}((\mathbf{B}_t)_{t \in [0, T]} \in \cdot)$ 为 $(\mathbf{B}_t)_{t \in [0, T]}$ 的分布, 其中 $\mathbf{B}_0 = x$, 此处我们回顾

$(\mathbf{B}_t)_{t \in [0, T]}$ is a d 维布朗运动。利用平斯克不等式 (Pinsker's Inequality) (Bakry 等, 2014, 方程 5.2.2) 和转移定理 (Transfer Theorem) (Kullback, 1997, 定理 4.1), 我们得到 $\|\delta_x P_T^{(1)} - \delta_x P_T^{(2)}\|_{TV}^2 \leq 2 \text{KL}(\mu_{(1)} | \mu_{(2)})$ 。

由于对任意 $i \in \{1, 2\}$, $\mathbb{P}(\int_0^T \{\|b_i(t, (\mathbf{X}_s^{(i)})_{s \in [0, T]})\|^2 + \|b_i(t, (\mathbf{B}_s)_{s \in [0, T]})\|^2\} dt < +\infty) = 1$, 且过程 $(\mathbf{X}_t^{(i)})_{t \in [0, T]}$ 对 $i \in \{1, 2\}$ 为扩散型, 因此可应用吉尔萨诺夫定理 (Girsanov's Theorem) (Liptser 和 Shiryaev, 2001, 定理 7.7), 且 μ_B 几乎必然对任意 $w \in C([0, T], \mathbb{R})$, 我们得到

$$\begin{aligned} & (d\mu_{(1)}^x/d\mu_{(2)}^x)((w_t)_{t \in [0, T]}) \\ &= \exp[(1/2) \int_0^T \langle b_1(t, (w_s)_{s \in [0, T]}), dw_t \rangle - (1/4) \int_0^T \|b_1(t, (w_s)_{s \in [0, T]})\|^2 dt] \\ & (d\mu_B^x/d\mu_{(2)}^x)((w_t)_{t \in [0, T]}) \\ &= \exp[-(1/2) \int_0^T \langle b_2(t, (w_s)_{s \in [0, T]}), dw_t \rangle + (1/4) \int_0^T \|b_2(t, (w_s)_{s \in [0, T]})\|^2 dt]. \end{aligned}$$

因此, 我们得到

$$\text{KL}(\mu_{(1)}^x | \mu_{(2)}^x) = \mathbb{E}[\log((d\mu_{(1)}^x/d\mu_{(2)}^x)((\mathbf{X}_t^{(1)})_{t \in [0, T]}))]$$

$$= (1/4) \int_0^T \mathbb{E}[\|b_1(t, (\mathbf{X}_s^{(1)})_{s \in [0, T]}) - b_2(t, (\mathbf{X}_s^{(1)})_{s \in [0, T]})\|^2] dt$$

这完成了证明。 $\square$

本文研究满足某种曲率假设的分布，并证明它们是次高斯的。更精确地，我们证明以下命题。

引理 20。 设 $q \in C^1(\mathbb{R}^d, (0, +\infty))$ 和 $m > 0$ 以及 $c \geq 0$ ，使得 $\langle \nabla \log q(x), x \rangle \leq -m \|x\| + c \|x\|$ 对任意 $x \in \mathbb{R}^d$ ，我们有。则对任意 $\varepsilon \in [0, m/2)$ ，我们有

$$\int_{\mathbb{R}^d} \exp[\varepsilon \|x\|^2] q(x) dx < +\infty.$$

证明。对任意 $x \in \mathbb{R}^d$ ，我们有

$$\begin{aligned} \log q(x) &= \log q(0) + \int_0^1 \langle \nabla \log q(tx), x \rangle dt \\ &\leq \log q(0) - m \int_0^1 t \|x\|^2 dt + c \|x\| \leq \log q(0) + c \|x\| - m \|x\|^2. \end{aligned}$$

这完成了证明。 $\square$

最后，我们将使用以下基本引理。

引理 21。 设 $\mu \in \mathcal{P}(\mathbb{R}^d)$ ， $\alpha_1 \in \mathbb{R}$ ， $\beta_1 > 0$ 与 $(\mathbf{X}_t)_{t \geq 0}$ 使得 $\mathbf{X}_0$ 具有分布 μ ，且

$$d\mathbf{X}_t = \alpha_1 \mathbf{X}_t dt + \beta_1^{1/2} d\mathbf{B}_t,$$

其中 $(\mathbf{B}_t)_{t \geq 0}$ 为布朗运动。则对任意 $\alpha_2 \in \mathbb{R}$ 与 $\beta_2 > 0$ ，我们有 $(\mathbf{Y}_t)_{t \geq 0}$ ，给定任意 $t \geq 0$ by $\mathbf{Y}_t = \alpha_2 \mathbf{X}_{\beta_2 t}$ 满足

$$d\mathbf{Y}_t = \beta_2 \alpha_1 \mathbf{Y}_t dt + \alpha_2 (\beta_2 \beta_1)^{1/2} d\tilde{\mathbf{B}}_t,$$

其中 $(\tilde{\mathbf{B}}_t)_{t \geq 0}$ 为布朗运动，且 $\mathbf{Y}_0$ 具有分布 $(\tau_{\alpha_2}) \# \mu$ ，其中对任意 $x \in \mathbb{R}^d$ ， $\tau_{\alpha_2}(x) = \alpha_2 x$ 。

证明：设 $t \geq 0$ 。利用变量替换 $u \mapsto \beta_2 u$ ，以下等式在分布意义下成立

$$\begin{aligned} \mathbf{Y}_t &= \alpha_2 \alpha_1 \int_0^{\beta_2 t} \mathbf{X}_s ds + \alpha_2 \beta_1^{1/2} \mathbf{B}_{\beta_2 t} \\ &= \beta_2 \alpha_2 \alpha_1 \int_0^t \mathbf{X}_{\beta_2 s} ds + \alpha_2 (\beta_1 \beta_2)^{1/2} \mathbf{B}_t = \beta_2 \alpha_1 \int_0^t \mathbf{Y}_s ds + \alpha_2 (\beta_1 \beta_2)^{1/2} \mathbf{B}_t, \end{aligned}$$

这完成了证明。 $\square$

我们现在转向定理 1 的证明

证明：设 $\alpha \geq 0$ 。对任意 $k \in \{1, \dots, N\}$ ，记 R_k 为马尔可夫核，使得对任 $A \in \mathcal{B}(\mathbb{R}^d)$ $k \in \{0, \dots, N-1\}$ 我们有 $\int \mathbf{1}_A R_k(x) d\mu_k(x) = \int \mathbf{1}_A d\mu_k$ ，与

$$R_{k+1}(x, A) = (4\pi\gamma_{k+1})^{-1/2} \int_A \exp[-\|\tilde{x} - \mathcal{T}_{k+1}(x)\|^2 / (4\gamma_{k+1})] d\tilde{x},$$

其中对于任意 $x \in \mathbb{R}^d$ ， $\mathcal{T}_{k+1}(x) = x + \gamma_{k+1} \{\alpha x + 2s_\theta(t_k, x)\}$ ，其中 $t_k = \sum_{\ell=0}^{k-1} \gamma_\ell$ 。对于任意 $k_0, k_1 \in \{1, \dots, N\}$ ，其中 $k_1 \geq k_0$ $Q_{k_0, k_1} = \prod_{\ell=k_0}^{k_1} R_\ell$ ，定义。最后，为了记号简便，对于任意 $k \in \{1, \dots, N\}$ ， $Q_k = Q_{1, k}$ ，我们也定义。注意，对于任意 $k \in \{1, \dots, N\}$ ， Y_k ，其分布为 $\pi_\infty Q_k$ ，其中 $\pi_\infty \in \mathcal{P}(\mathbb{R}^d)$ 具有关于勒贝格测度的密度 p_{data} 。令 $\mathbb{P} \in \mathcal{P}(\mathcal{C})$ 为与扩散过程相关的概率测度

$$d\mathbf{X}_t = -\alpha \mathbf{X}_t dt + \sqrt{2} d\mathbf{B}_t, \quad \mathbf{X}_0 \sim \pi_0,$$

其中 $\pi_0 \in \mathcal{P}(\mathbb{R}^d)$ 具有关于勒贝格测度的密度，由 p_{data} 给出。首先注意，利用 $\mathbb{P}_0 = \pi_0$ ，对于任意 $A \in \mathcal{B}(\mathbb{R}^d)$ ，我们有

$$\pi_0 \mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0}(A) = \mathbb{P}_T(\mathbb{P}^R)_{T|0}(A) = (\mathbb{P}^R)_0(\mathbb{P}^R)_{T|0}(A) = (\mathbb{P}^R)_T(A) = \pi_0(A).$$

因此 $\pi_0 = \pi_0 \mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0}$ 。利用这一结果和引理 17，我们有

$$\|\pi_0 - \pi_\infty Q_N\|_{\text{TV}} = \|\pi_0 \mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0} - \pi_\infty Q_N\|_{\text{TV}}$$

$$\begin{aligned} &\leq \|\pi_0 \mathbb{P}_{T|0}(\mathbb{P}^R)_{T|0} - \pi_\infty(\mathbb{P}^R)_{T|0}\|_{\text{TV}} + \|\pi_\infty(\mathbb{P}^R)_{T|0} - \pi_\infty \mathbb{Q}_N\|_{\text{TV}} \\ &\leq \|\pi_0 \mathbb{P}_{T|0} - \pi_\infty\|_{\text{TV}} + \|\pi_\infty(\mathbb{P}^R)_{T|0} - \pi_\infty \mathbb{Q}_N\|_{\text{TV}}. \end{aligned}$$

注意 $\mathcal{L}(X_0) = \mathcal{L}(Y_N) = \pi_\infty \mathbb{Q}_N$ ，因此

$$\|\mathcal{L}(X_0) - \pi_0\|_{\text{TV}} \leq \|\pi_0 \mathbb{P}_{T|0} - \pi_\infty\|_{\text{TV}} + \|\pi_\infty(\mathbb{P}^R)_{T|0} - \pi_\infty \mathbb{Q}_N\|_{\text{TV}}.$$

我们现在逐项界定这些项。

(a) 首先，假设 $\alpha > 0$ 。令 $T_\alpha = \alpha T$ 和 $\tilde{\mathbb{P}} \in \mathcal{P}(\mathcal{C}([0, T_\alpha], \mathbb{R}^d))$ 与 $(\mathbf{Z}_t)_{t \in [0, T_\alpha]}$ 相关联，即经典的奥恩斯坦-乌伦贝克过程，其中 $\mathbf{Z}_0 \sim (\tau_\alpha) \# \pi_0$ ，其中对于任意 $x \in \mathbb{R}^d$

我们有 $\tau_\alpha(x) = \alpha^{1/2}x$ ，满足以下随机微分方程： $d\mathbf{Z}_t = -\mathbf{Z}_t dt + \sqrt{2}d\mathbf{B}_t$ 。我们记 $\pi_0^\alpha = (\tau_\alpha) \# \pi_0$ ， $\mu = (\tau_\alpha) \# \pi_\infty$ 。注意，由于 p_{prior} 是均值为零、协方差矩阵为 $(1/\alpha)\text{Id}$ ， μ 的高斯密度，因此是均值为零、协方差矩阵为单位阵的高斯分布。首先，利用 (Bakry 等入, 2014, 命题 4.1.1, 命题 4.3.1, 定理 4.2.5)，我们得到对于 any $t \in [0, T_\alpha]$ ， $f \in L^1(\mu)$ 及 $x \in \mathbb{R}^d$

$$\int_{\mathbb{R}^d} (\tilde{\mathbb{P}}_{t|0} g(x))^2 d\mu(x) \leq \exp[-2t] \int_{\mathbb{R}^d} g^2(x) d\mu(x), \quad g(x) = f(x) - \int_{\mathbb{R}^d} f(\tilde{x}) d\mu(\tilde{x}). \quad (33)$$

其中回顾 $(\mathbf{X}_t)_{t \geq 0}$ 满足 $d\mathbf{X}_t = -\alpha \mathbf{X}_t dt + d\mathbf{B}_t$ 。利用引理 21，我们有对于任意 $t \in [0, T]$ ， $\mathbf{Z}_t$ 和 $\alpha^{1/2} \mathbf{X}_{\alpha^{-1}t}$ 具有相同的分布。因此对于任意 $t \in [0, T]$ ，我们有 $\mathbb{P}_t = (\tau_\alpha^{-1}) \# \tilde{\mathbb{P}}_{\alpha t}$ 。因此，利用 $(\tau_\alpha) \# \pi_\infty = \mu$ ， $\tilde{\mathbb{P}}$ 是马尔可夫的以及引理 17，我们得到

$$\begin{aligned} \|\pi_0 \mathbb{P}_{t|0} - \pi_\infty\|_{\text{TV}} &= \|\mathbb{P}_t - \pi_\infty\|_{\text{TV}} = \|(\tau_\alpha) \# \mathbb{P}_t - (\tau_\alpha) \# \pi_\infty\|_{\text{TV}} \\ &= \|\tilde{\mathbb{P}}_{\alpha t} - \mu\|_{\text{TV}} = \|\tilde{\mathbb{P}}_{\alpha t_0} \tilde{\mathbb{P}}_{\alpha(t-t_0)|0} - \mu\|_{\text{TV}}. \end{aligned}$$

最后，注意到对于任意 $t \geq t_0 \in [0, T]$ 和 $x \in \mathbb{R}^d$ ，我们有

$$(d(\tilde{\mathbb{P}}_{\alpha t_0} \tilde{\mathbb{P}}_{\alpha(t-t_0)|0})/d\mu)(x) = \tilde{\mathbb{P}}_{\alpha(t-t_0)|0} f(x), \quad \text{with } f(x) = (d\tilde{\mathbb{P}}_{\alpha t_0}/d\mu)(x). \quad (34)$$

设 $g = f - 1$ 。利用 (34)、(33) 以及 $(\tau_\alpha) \# \pi_\infty = \mu$ ，我们得到对于任意满足 $t \in [0, T]$ 的 $t \geq t_0$

$$\begin{aligned} \|\pi_0 \mathbb{P}_{t|0} - \pi_\infty\|_{\text{TV}} &\leq \|\tilde{\mathbb{P}}_{\alpha t_0} \tilde{\mathbb{P}}_{\alpha(t-t_0)|0} - \mu\|_{\text{TV}} \\ &\leq \int_{\mathbb{R}^d} |\tilde{\mathbb{P}}_{\alpha(t-t_0)|0} f(x) - 1| d\mu(x) \\ &\leq (\int_{\mathbb{R}^d} (\tilde{\mathbb{P}}_{\alpha(t-t_0)|0} g(x))^2 d\mu(x))^{1/2} \\ &\leq \exp[-\alpha(t-t_0)] (\int_{\mathbb{R}^d} g^2(x) d\mu(x))^{1/2} \\ &\leq \exp[-\alpha(t-t_0)] (\int_{\mathbb{R}^d} g^2(\alpha^{1/2}x) d\pi_\infty(x))^{1/2}. \end{aligned} \quad (35)$$

In addition, we have for any $\varphi \in C_c(\mathbb{R}^d, \mathbb{R})$

$$\begin{aligned} \int_{\mathbb{R}^d} \varphi(x) f(\alpha^{1/2}x) d\pi_\infty(x) &= \int_{\mathbb{R}^d} \varphi(\alpha^{-1/2}x) f(x) d\mu(x) \\ &= \int_{\mathbb{R}^d} \varphi(\alpha^{-1/2}x) d\tilde{\mathbb{P}}_{\alpha t_0}(x) = \int_{\mathbb{R}^d} \varphi(x) d\mathbb{P}_{t_0}(x). \end{aligned}$$

因此，对于任意 $x \in \mathbb{R}^d$ ， $g(\alpha^{1/2}x) = (d\mathbb{P}_{t_0}/d\pi_\infty)(x) - 1$ 。结合此结果与 (35)，我们得到对于任意满足 $t \in [0, T]$ 的 $t \geq t_0$

$$\|\pi_0 \mathbb{P}_{t|0} - \pi_\infty\|_{\text{TV}} \leq \sqrt{2} \exp[-\alpha(t-t_0)] \left(1 + \int_{\mathbb{R}^d} (d\mathbb{P}_{t_0}/d\pi_\infty)(x)^2 d\pi_\infty(x)\right)^{1/2}. \quad (36)$$

设 $t_0 \in [0, T]$ 。我们现在推导 f 的上界。我们回顾 $\mathbb{P}_{t_0}$ 和 π_∞ 关于勒贝格测度 $\mathbb{R}^d$ ($d\mathbb{P}_{t_0}/d\pi_\infty$) 具有密度，分别记为 p_{t_0} 和 p_∞ ，使得对于任意 $x \in \mathbb{R}^d$

$$p_{t_0}(x) = \int_{\mathbb{R}^d} G_{t_0}(x, \tilde{x}) d\pi_0(\tilde{x}), \quad p_\infty(x) = (2\pi/\alpha)^{-d/2} \exp[-\alpha \|x\|^2/2],$$

其中对于任意 $x, \tilde{x} \in \mathbb{R}^d$

$$\begin{aligned} G_{t_0}(x, \tilde{x}) &= (2\pi\sigma_{t_0}^2)^{-d/2} \exp[-\|x - m_{t_0}(\tilde{x})\|^2/(2\sigma_{t_0}^2)], \\ \sigma_{t_0}^2 &= (1 - \exp[-2\alpha t_0])/\alpha, \quad m_{t_0}(\tilde{x}) = \exp[-\alpha t_0] \tilde{x}. \end{aligned}$$

结合此结果与詹森不等式 (Jensen's inequality) , 我们得到

$$\int_{\mathbb{R}^d} p_{t_0}^2(x) p_{\infty}^{-1}(x) dx \leq \alpha^{-d/2} (2\pi)^{-d/2} \sigma_{t_0}^{-2d} \int_{\mathbb{R}^d} \exp[-\|x - m_{t_0}(\tilde{x})\|^2 / \sigma_{t_0}^2 + \alpha \|x\|^2 / 2] dx d\pi_0(\tilde{x}). \quad (37)$$

For any $x, \tilde{x} \in \mathbb{R}^d$ we have

$$\|x - m_{t_0}(\tilde{x})\|^2 / \sigma_{t_0}^2 - \alpha \|x\|^2 / 2 = \|x - m_{t_0}(\tilde{x})(2\tilde{\sigma}_{t_0}^2 / \sigma_{t_0}^2)\|^2 / (2\tilde{\sigma}_{t_0}^2) - \|\tilde{x}\|^2 \phi(\alpha, t_0) / \sigma_{t_0}^2,$$

with $\tilde{\sigma}_{t_0}^2 = (\sigma_{t_0}^2 / 2)(1 - \alpha \sigma_{t_0}^2 / 2)^{-1}$ and $\phi(\alpha, t_0) = \alpha \sigma_{t_0}^2 (1 - \sigma_{t_0}^2 \alpha) / (2 - \sigma_{t_0}^2 \alpha)$. Using this result, we get that

$$\int_{\mathbb{R}^d} \exp[-\|x - m_{t_0}(\tilde{x})\|^2 / \sigma_{t_0}^2 + \alpha \|x\|^2 / 2] dx d\pi_0(\tilde{x}) \leq (2\pi \tilde{\sigma}_{t_0}^2)^{d/2} \int_{\mathbb{R}^d} \exp[\phi(\alpha, t_0) \|\tilde{x}\|^2] d\pi_0(\tilde{x}),$$

设 $\varepsilon = \mathfrak{m}/4$ 且 $t_0 \geq 0$ 使得 $\phi(\alpha, t_0) \leq \varepsilon$ 。利用引理 20, 可得

$$\int_{\mathbb{R}^d} \exp[-\|x - m_{t_0}(\tilde{x})\|^2 / \sigma_{t_0}^2 + \alpha \|x\|^2 / 2] dx d\pi_0(\tilde{x}) \leq (2\pi \tilde{\sigma}_{t_0}^2)^{d/2} \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}).$$

结合该结果、事实以及对于任意

$$\sigma_{t_0}^2 \leq \alpha^{-1}, \quad (37)$$

$$t \geq 0, (1 - e^{-t})^{-1} \leq 1 + 1/t,$$

我们得到

$$\begin{aligned} \int_{\mathbb{R}^d} p_{t_0}^2(x) p_{\infty}^{-1}(x) dx &\leq (\alpha^{-1} \tilde{\sigma}_{t_0}^2 \sigma_{t_0}^{-4})^{d/2} \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}) \\ &\leq (1 - \exp[-2\alpha t_0])^{-d/2} \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}) \\ &\leq (1 + 1/(2\alpha t_0))^{d/2} \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}). \end{aligned}$$

结合该结果与式 (36), 可得对于任意 $t > t_0$

$$\|\pi_0 \mathbb{P}_{t|0} - \pi_{\infty}\|_{\text{TV}} \leq C_1^a \exp[-\alpha t],$$

含

$$C_1^a = \sqrt{2}(1 + 1/(2\alpha t_0))^{d/2} (1 + (\int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}))^{1/2}) \exp[\alpha t_0].$$

For $t \leq t_0$, using that $\|\pi_0 \mathbb{P}_{t|0} - \pi_{\infty}\|_{\text{TV}} \leq 1$ we have

$$\|\pi_0 \mathbb{P}_{t|0} - \pi_{\infty}\|_{\text{TV}} \leq C_1^b \exp[-\alpha t], \quad \text{含} \quad C_1^b = \exp[\alpha t_0].$$

Let $C_1 = C_1^a + C_1^b$ 并且对于任意 $t \in [0, T]$, 我们有

$$\|\pi_0 \mathbb{P}_{t|0} - \pi_{\infty}\|_{\text{TV}} \leq C_1 \exp[-\alpha t]. \quad (38)$$

(b) 其次假设 $\alpha = 0$ 。

$$\|\pi_0 \mathbb{P}_{T|0} - \pi_{\infty}\|_{\text{TV}} \leq \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} (4\pi T)^{-d/2} |\exp[-\|x - \tilde{x}\|^2 / (4T)] - \exp[-\|x\|^2 / (4T)]| dx d\pi_0(\tilde{x}).$$

对于任意 $x, \tilde{x} \in \mathbb{R}^d$, 设 $\varphi \in C^1([0, 1], \mathbb{R})$, 其中对于任意 $s \in [0, 1]$

, $\varphi(s) = \exp[-\|x - s\tilde{x}\|^2 / (4T)]$ 。首先, 假设 $T \geq 2/\varepsilon$ 。利用引理 18, 可得对于任意 $s \in [0, 1]$

$$|\varphi'(s)| \leq (1 + \varepsilon^{-1})(1 + \|x\|) \exp[-\|x\|^2 / (8T)] \exp[\varepsilon \|y\|^2 / T].$$

利用该结果, 我们得到

$$\begin{aligned} \|\pi_0 \mathbb{P}_{T|0} - \pi_{\infty}\|_{\text{TV}} &\leq \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} (4\pi T)^{-d/2} |\exp[-\|x - \tilde{x}\|^2 / (4T)] - \exp[-\|x\|^2 / (4T)]| dx d\pi_0(\tilde{x}) \\ &\leq \int_{\mathbb{R}^d} \int_{\mathbb{R}^d} (4\pi T)^{-d/2} (1 + \varepsilon^{-1})(1 + \|x\|) \exp[-\|x\|^2 / (8T)] \exp[\varepsilon \|\tilde{x}\|^2 / T] dx d\pi_0(\tilde{x}) \\ &\leq 2^{d/2} (1 + \varepsilon^{-1}) \int_{\mathbb{R}^d} (8\pi T)^{-d/2} (1 + \|x\|) \exp[-\|x\|^2 / (8T)] dx \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2 / T] d\pi_0(\tilde{x}) \\ &\leq 2^{d/2} (1 + \varepsilon^{-1}) (1 + 2\sqrt{2}d^{1/2}T^{1/2}) \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2 / T] d\pi_0(\tilde{x}). \end{aligned}$$

In addition, if $T \leq 2/\varepsilon$ then

$$\|\pi_0 \mathbb{P}_{T|0} - \pi_{\infty}\|_{\text{TV}} \leq (\varepsilon/2 + (\varepsilon/2)^{1/2})^{-1} (T^{-1} + T^{-1/2}).$$

因此, 我们得到存在 $C_2 \geq 0$ 使得

$$\|\pi_0 \mathbb{P}_{T|0} - \pi_{\infty}\|_{\text{TV}} \leq C_2 (T^{-1} + T^{-1/2}), \quad (39)$$

其中

$$C_2 = (\varepsilon/2 + (\varepsilon/2)^{1/2})^{-1} + 2^{d/2} (1 + \varepsilon^{-1}) (1 + 2\sqrt{2}d^{1/2}) \int_{\mathbb{R}^d} \exp[\varepsilon \|\tilde{x}\|^2] d\pi_0(\tilde{x}).$$

(c) 回顾 $\mathbb{P}^R$ 与扩散 $(\mathbf{Y}_t)_{t \geq 0}$ 相关联, 使得对于任意 $t \in [0, T]$ 和 $x \in \mathbb{R}^d$

$$d\mathbf{Y}_t = b_1(t, \mathbf{Y}_t)dt + \sqrt{2}\mathbf{B}_t, \quad b_1(t, x) = \alpha x + 2\nabla \log p_{T-t}(x).$$

类似地, 对于任意 $k \in \{1, \dots, N\}$, 我们有 $\mathbb{Q}_k = \mathbb{Q}_{t_k}$, 其中 $\mathbb{Q}$ 与扩散 $(\bar{\mathbf{Y}}_t)_{t \in [0, T]}$ 相关联, 使得对于任意 $(w_t)_{t \in [0, T]} \in C([0, T], \mathbb{R}^d)$, 我们有

$$d\bar{\mathbf{Y}}_t = b_2(t, (\bar{\mathbf{Y}}_s)_{s \in [0, T]})dt + \sqrt{2}\mathbf{B}_t, \\ b_2(t, (w_t)_{t \in [0, T]}) = \sum_{k=0}^{N-1} \mathbb{1}_{[t_k, t_{k+1})}(t) \{2\alpha w_{t_k} + s_\theta(t_k, w_{t_k})\}$$

$k \in \{0, \dots, N\}$, $t_k = \sum_{\ell=0}^{k-1} \gamma_{\ell+1}$ 其中对于任意 $i \in \{1, 2, 3\}$, 存在 $A_i \geq 0$ 和 $\alpha_i \in \mathbb{N}$, 使得对于任意 $x_0 \in \mathbb{R}^d$ $\|\nabla^i \log p_0(x)\| \leq A_i(1 + \|x_0\|^{\alpha_i})$, 与 $\alpha_1 = 1$ 。利用这一结果和定理 16, 我们得到对于任意 $i \in \{1, 2, 3\}$, 存在 $B_i \geq 0$ 和 $\beta_i \in \mathbb{N}$, 且 $\beta_1 = 1$, 使得对于任意 $x_t \in \mathbb{R}^d$ 和 $t \in [0, T]$

$$\|\nabla^i \log p_t(x_t)\| \leq B_i(1 + \|x_t\|^{\beta_i}). \quad (40)$$

此外, 对于任意 $t \in [0, T]$ 和 $x \in \mathbb{R}^d$, 我们有

$$\partial_t p_t(x) = -\operatorname{div}(b p_t)(x) + \Delta p_t(x),$$

与 $b(x) = -\alpha x$ 。因此, 由于 $\log p \in C^\infty((0, T] \times \mathbb{R}^d, \mathbb{R})$, 我们得到对于任意 $t \in (0, T]$ 和 $x_t \in \mathbb{R}^d$

$$\partial_t \log p_t(x_t) = -\operatorname{div}(b \log p_t)(x_t) + \Delta \log p_t(x_t) + \|\nabla \log p_t(x_t)\|^2.$$

最后, 我们得到对于任意 $t \in (0, T]$ 和 $x_t \in \mathbb{R}^d$

$$\partial_t \nabla \log p_t(x_t) = -\nabla \operatorname{div}(b \log p_t)(x_t) + \nabla \Delta \log p_t(x_t) + \nabla \|\nabla \log p_t(x_t)\|^2(x_t).$$

因此, 结合该结果与式 (40), 存在 $\tilde{A} \geq 0$ 和 $\beta \in \mathbb{N}$, 使得对任意 $x_t \in \mathbb{R}^d$ 及成立。因此, 对任意 $t \in (0, T]$, $\|\partial_t \nabla \log p_t(x_t)\| \leq \tilde{A}(1 + \|x_t\|^\beta)$ $t_1, t_2 \in [0, T]$ 和 $x \in \mathbb{R}^d$

$$\|\nabla \log p_{t_2}(x) - \nabla \log p_{t_1}(x)\| \leq \tilde{A}|t_2 - t_1|(1 + \|x\|^\beta). \quad (41)$$

此外, 利用式 (40), 对任意 $t \in [0, T]$ 和 $x_1, x_2 \in \mathbb{R}^d$ 有

$$\begin{aligned} \|\nabla \log p_t(x_1) - \nabla \log p_t(x_2)\| &\leq \int_0^1 \|\nabla^2 \log p_t((1-s)x_1 + sx_2)\| ds \|x_1 - x_2\| \\ &\leq B_2(1 + \int_0^1 \|(1-s)x_1 + sx_2\|^{\beta_2} ds) \|x_1 - x_2\| \\ &\leq B_2(1 + \|x_1\|^{\beta_2} + \|x_2\|^{\beta_2}) \|x_1 - x_2\|. \end{aligned} \quad (42)$$

由于 $s_\theta \in C([0, T] \times \mathbb{R}^d, \mathbb{R}^d)$ 和 $\nabla \log p \in C([0, T] \times \mathbb{R}^d, \mathbb{R}^d)$, 利用引理 19、式 (41)、式 (42) 及柯西-施瓦茨不等式可得

$$\begin{aligned} \|\pi_\infty(\mathbb{P}^R)_{T|0} - \pi_\infty \mathbb{Q}_N\|_{TV}^2 &\leq (1/2) \int_0^T \mathbb{E}[\|b_1(t, \mathbf{Y}_t) - b_2(t, (\mathbf{Y}_t)_{t \in [0, T]})\|^2] dt \\ &\leq 2 \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\nabla \log p_{T-t}(\mathbf{Y}_t) - s_\theta(\mathbf{Y}_{t_k})\|^2] dt \\ &\quad + \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \alpha^2 \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^2] dt \\ &\leq 6 \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\nabla \log p_{T-t}(\mathbf{Y}_t) - \nabla \log p_{T-t}(\mathbf{Y}_{t_k})\|^2] dt \\ &\quad + 6 \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\nabla \log p_{T-t}(\mathbf{Y}_{t_k}) - \nabla \log p_{T-t_k}(\mathbf{Y}_{t_k})\|^2] dt \\ &\quad + 6 \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\nabla \log p_{T-t_k}(\mathbf{Y}_{t_k}) - s_\theta(t_k, \mathbf{Y}_{t_k})\|^2] dt \\ &\quad + \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \alpha^2 \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^2] dt \\ &\leq 18\sqrt{2}B_2^2(1 + 2N_T(4\beta_2))^{1/2} \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^4]^{1/2} dt \\ &\quad + 12\tilde{A}^2(1 + N_T(2\beta)) \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} (t - t_k)^2 dt + 6TM^2 \end{aligned} \quad (43)$$

$$\begin{aligned}
& + \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \alpha^2 \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^2] dt \\
& \leq \{18\sqrt{2}B_2^2(1 + 2N_T(4\beta_2))^{1/2} + \alpha^2\} \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^4]^{1/2} dt \\
& \quad + 4\tilde{A}^2(1 + N_T(2\beta)) \sum_{k=0}^{N-1} (t_{k+1} - t_k)^3 + 6TM^2 \\
& \leq \{18\sqrt{2}B_2^2(1 + 2N_T(4\beta_2))^{1/2} + \alpha^2\} \sum_{k=0}^{N-1} \int_{t_k}^{t_{k+1}} \mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_{t_k}\|^4]^{1/2} dt \\
& \quad + 4\tilde{A}^2(1 + N_T(2\beta))T\bar{\gamma}^2 + 6TM^2,
\end{aligned}$$

其中对任意 $\ell \in \mathbb{N}$, $N_T(\ell) = \sup_{t \in [0, T]} \mathbb{E}[\|\mathbf{Y}_t\|^\ell]$ 。对任意 $t \in [0, T]$, 令 $\mathcal{A}_t : C^2(\mathbb{R}^d) \rightarrow C^2(\mathbb{R}^d, \mathbb{R})$ 为由任意 $t \geq 0$, $\varphi \in C^2(\mathbb{R}^d, \mathbb{R})$ 和 $x \in \mathbb{R}^d$ 给出的生成元

$$\mathcal{A}_t(\varphi)(x) = \langle \alpha x + 2\nabla \log p_{T-t}(x), \nabla \varphi(x) \rangle + \Delta \varphi(x).$$

For any $\ell \in \mathbb{N}$, let $V_\ell(x) = \|x\|^{2\ell}$. Hence, for any $\ell \in \mathbb{N}$, $x \in \mathbb{R}^d$ and $t \in [0, T]$ we have using (40)

$$\mathcal{A}_t(V_\ell)(x) = 2\ell\alpha \|x\|^{2\ell} + 2\ell B_1 \|x\|^{2\ell-1} + 2\ell B_1 \|x\|^{2\ell} + 2\ell(2\ell-1) \|x\|^{2(\ell-1)}.$$

因此, 对任意 $\ell \in \mathbb{N}$ 存在 $\tilde{B}_\ell$, 使得 $x \in \mathbb{R}^d$ 和 $t \in [0, T]$

$$|\mathcal{A}_t(V_\ell)(x)| \leq \tilde{B}_\ell(1 + V_\ell(x)). \quad (44)$$

For any $\ell \in \mathbb{N}$, $(M_{\ell,t})_{t \in [0, T]} = (V_\ell(\mathbf{Y}_t) - V_\ell(\mathbf{Y}_0) - \int_0^t \mathcal{A}_s(V_\ell)(\mathbf{Y}_s) ds)_{t \in [0, T]}$ is a local martingale. For any $\ell \in \mathbb{N}$, there exists $(\tau_{\ell,k})_{k \in \mathbb{N}}$ a sequence of stopping times such that $\lim_{k \rightarrow +\infty} \tau_{\ell,k} = T$ and $(M_{\ell,t \wedge \tau_{\ell,k}})_{t \in [0, T]}$ is a martingale. Using (44), we have for any $t \in [0, T]$, $\ell \in \mathbb{N}$ and $k \in \mathbb{N}$

$$\mathbb{E}[V_\ell(\mathbf{Y}_{t \wedge \tau_{\ell,k}})] \leq \mathbb{E}[V_\ell(\mathbf{Y}_0)] + \tilde{B}_\ell \int_0^t (1 + \mathbb{E}[V_\ell(\mathbf{Y}_{s \wedge \tau_{\ell,k}})]) ds.$$

因此, 利用格朗沃尔引理可得对任意 $\ell \in \mathbb{N}$, $\sup_{k \in \mathbb{N}} \mathbb{E}[V_\ell(\mathbf{Y}_{t \wedge \tau_{\ell,k}})] < +\infty$ 。故对任意 $\ell \in \mathbb{N}$, $((M_{\ell,t \wedge \tau_{\ell,k}})_{t \in [0, T]})_{k \in \mathbb{N}}$ 是一致可积的, 且对任意 $\ell \in \mathbb{N}$, $(M_{\ell,t})_{t \in [0, T]}$ 是鞅。因此得到对任意 $t \in [0, T]$, $\ell \in \mathbb{N}$

$$\mathbb{E}[V_\ell(\mathbf{Y}_t)] \leq \mathbb{E}[V_\ell(\mathbf{Y}_0)] + \tilde{B}_\ell \int_0^t (1 + \mathbb{E}[V_\ell(\mathbf{Y}_s)]) ds.$$

利用格朗沃尔引理可得对任意 $\ell \in \mathbb{N}$ 存在 $\tilde{C}_\ell \geq 0$, 使得

$$N_T(\ell) = \sup_{t \in [0, T]} \mathbb{E}[\|\mathbf{Y}_t\|^{2\ell}] \leq \tilde{C}_\ell \exp[\tilde{B}_\ell T]. \quad (45)$$

对任意 $s, t \in [0, T]$ 有

$$\mathbf{Y}_t = \mathbf{Y}_s + \int_s^t \{\alpha \mathbf{Y}_u + 2\nabla \log p_{T-t}(\mathbf{Y}_u)\} du + \sqrt{2} \int_s^t d\mathbf{B}_u.$$

利用式 (41) 和柯西-施瓦茨不等式, 对于任意 $s, t \in [0, T]$, 我们有

$$\begin{aligned}
\mathbb{E}[\|\mathbf{Y}_t - \mathbf{Y}_s\|^4] & \leq 64(t-s)^3 \int_s^t \{\alpha^4 \mathbb{E}[\|\mathbf{Y}_u\|^4] + 16\mathbb{E}[\|\nabla \log p_{T-t}(\mathbf{Y}_u)\|^4]\} du + 48\sqrt{2}(t-s)^2 \\
& \leq 64(t-s)^3 \int_s^t \{\alpha^4 \mathbb{E}[\|\mathbf{Y}_u\|^4] + 128B_1^4(1 + \mathbb{E}[\|\mathbf{Y}_u\|^4])\} du + 48\sqrt{2}(t-s)^2 \\
& \leq 64(\alpha^4 + 128B_1^4)(1 + N_T(4))(t-s)^4 + 48\sqrt{2}(t-s)^2.
\end{aligned} \quad (46)$$

将式 (45) 和式 (46) 代入式 (43), 我们得到存在 $C_3 \geq 0$ 使得

$$\|\pi_\infty(\mathbb{P}^R)_{T|0} - \pi_\infty Q_N\|_{TV}^2 \leq C_3 \exp[C_3 T](\bar{\gamma} + M^2), \quad (47)$$

若 $\alpha > 0$, 结合式 (38) 和式 (47); 若 $\alpha = 0$, 结合式 (39) 和式 (47), 我们完成证明。□

C.3 通用 SGM 及其与现有工作的联系

在本节中, 我们在附录 C.3.1 中描述一种用于 SGM 的通用算法, 并在附录 C.3.2 中证明公式 (6) 涵盖了 (Song et al., 2021; Ho et al., 2020) 中的公式。

C.3.1 通用 SGM 算法

我们首先提出一种通用算法来计算近似反向动力学，即计算与前向过程相关的反向时间马尔可夫链

$$d\mathbf{X}_t = f_t(\mathbf{X}_t)dt + \sqrt{2}d\mathbf{B}_t, \quad \mathbf{X}_0 \sim p_{\text{data}}. \quad (48)$$

我们使用式 (48) 的欧拉-丸山离散化，即令 $X_0 \sim p_{\text{data}}$ ，且对于任意 $k \in \{0, \dots, N-1\}$

$$X_{k+1} = X_k + \gamma_{k+1}f_k(X_k) + \sqrt{2\gamma_{k+1}}Z_{k+1}.$$

一般而言，与宋和埃尔蒙 (Song and Ermon, 2019)；何等人 (Ho et al., 2020) 不同，我们并不具备 $p(x_k|x_0)$ 为高斯密度的条件。然而，在此情形下，我们得到对于任意 $x \in \mathbb{R}^d$ ，

$$p_{k+1}(x) = (4\pi\gamma_{k+1})^{-d/2} \int_{\mathbb{R}^d} p_k(\tilde{x}) \exp[-\|\mathcal{T}_{k+1}(\tilde{x}) - x\|^2 / (4\gamma_{k+1})] d\tilde{x},$$

其中 $\mathcal{T}_{k+1}(x) = \tilde{x} + \gamma_{k+1}f_k(\tilde{x})$ 。因此，我们得到对于任意 $x \in \mathbb{R}^d$

$$(2\gamma_{k+1}p_{k+1}(x))\nabla \log p_{k+1}(x) = \int_{\mathbb{R}^d} (\mathcal{T}_{k+1}(\tilde{x}) - x)p_k(\tilde{x}) \exp[-\|\mathcal{T}_{k+1}(\tilde{x}) - x\|^2 / (4\gamma_{k+1})] d\tilde{x}.$$

因此，我们得到对于任意 $x \in \mathbb{R}^d$

$$\nabla \log p_{k+1}(x) = \mathbb{E}[\mathcal{T}_{k+1}(X_k) - X_{k+1} | X_{k+1} = x] / (2\gamma_{k+1}) = -(2\gamma_{k+1})^{1/2} \mathbb{E}[Z_{k+1} | X_{k+1} = x]. \quad (49)$$

由该公式我们推导出一个与第 2.1 节类似的回归问题。我们得到算法 2。我们强调本文方法与宋和埃尔蒙 (Song and Ermon) (2019); Ho et al. (2020): 方法之间的若干差异

(a) 如 (49) 式所强调，算法 2 中的回归问题不同于通常的得分生成模型 (SGM) 中所考虑的问题，后者仅限于 $f_k(x) = \alpha x$ 且 $\alpha = 0$ (宋和埃尔蒙 (Ermon, 2019) 或 $\alpha > 0$ (Ho et al., 2020)).

(b) 在当前算法中，我们在采样阶段不使用任何校正步骤 (宋等人, 2021)。注意，校正步骤的使用仅在经典得分生成模型 (SGM) 算法的背景下是合理的，而不适用于第 3.3 节介绍的扩散薛定谔桥 (DSB) 方法。这是因为，与经典得分生成模型不同，在迭代比例拟合 (IPF) 迭代过程中，我们无法获得时间反向密度的边缘分布。

(c) 最后，我们未呈现指数移动平均 (Exponential Moving Average, EMA) 过程 Song 和 Ermon (2020)，该过程是防止网络振荡的关键。与校正步骤不同，该技术可以很容易地纳入算法 2。

更多评论和附加技术在附录 I 中呈现。

C.3.2 与现有工作的联系

在本节中，我们展示通过逆转齐次扩散可以恢复 Song 和 Ermon (2019) 以及 Ho 等人 (2020) 的训练和采样算法。注意 Song 等人 (2021) 识别了与非齐次随机微分方程的联系。我们通过识别两个对应的前向齐次过程 (布朗运动或奥恩斯坦-乌伦贝克过程) 明确刻画了 Song 和 Ermon (2019); Ho 等人 (2020) 方法之间的根本差异。

布朗运动 首先，我们展示通过逆转布朗运动可以恢复 Song 和 Ermon (2019) 的采样过程和损失函数。假设我们有

$$d\mathbf{X}_t = \sqrt{2}d\mathbf{B}_t, \quad \mathbf{X}_0 \sim p_{\text{data}}. \quad (50)$$

在下文中，我们定义 $\{Y_k\}_{k=0}^{N-1}$ 使得 $\{Y_k\}_{k=0}^{N-1}$ 在特定时间序列 $\{t_k\}_{k=0}^{N-1} \in [0, T]^N$ 上近似 $\{\mathbf{X}_{T-t_k}\}_{k=0}^{N-1}$ 。我们回顾 (50) 的时间逆转与以下随机微分方程相关

$$d\mathbf{Y}_t = 2\nabla \log p_{T-t}(\mathbf{Y}_t) dt + \sqrt{2}d\mathbf{B}_t. \quad (51)$$

(51) 的欧拉-丸山离散化对任意 $k \in \{0, \dots, N-1\}$ 给出

$$\tilde{Y}_{k+1} = \tilde{Y}_k + 2\gamma_{k+1}\nabla \log p_{T-t_k}(\tilde{Y}_k) + \sqrt{2\gamma_{k+1}}Z_{k+1}.$$

Algorithm 2 Generalized score-matching

```

1: Inputs:  $(b_k)_{k \in \{0, \dots, N-1\}}$ ,  $N \in \mathbb{N}$  (nb. of iterations),  $M \in \mathbb{N}$  (batch size),  $N_{\text{epochs}}$  (nb. of epochs),  $(\gamma_k)_{k \in \{0, \dots, N-1\}}$  (stepsizes),  $\{s_\theta : \theta \in \Theta\}$  (neural network),  $\text{opt}$  (optimizer),  $p_{\text{prior}}$  (prior distribution),  $\lambda(k)$  (weights)
2: for  $n_{\text{epoch}} = 0, \dots, N_{\text{epoch}} - 1$  do
3:   for  $j \in \{1, \dots, M\}$  do
4:      $X_0^j \sim p_{\text{data}}$ 
5:     for  $k \in \{0, \dots, N-1\}$  do
6:        $X_{k+1}^j = X_k^j + \gamma_{k+1} f_k(X_k^j) + \sqrt{2\gamma_{k+1}} Z_{k+1}^j$ 
7:     end for
8:   end for
9:    $\ell(\theta) = M^{-1} \sum_{j=1}^M \sum_{k=0}^{N-1} \lambda(k) / (2\gamma_{k+1}) \sum_{j=1}^M \|\sqrt{2\gamma_{k+1}} s_\theta(k+1, X_{k+1}^j) + Z_{k+1}^j\|^2$ 
10:   $\theta_{n_{\text{epoch}}+1} = \text{opt}(\ell, \theta_{n_{\text{epoch}}})$ 
11: end for
12:  $X_N \sim p_{\text{prior}}$ 
13: for  $k \in \{N-1, \dots, 0\}$  do
14:    $X_k = X_{k+1} + \gamma_{k+1} \{-f_k(X_{k+1}) + 2s_{\theta_{N_{\text{epoch}}}}(k+1, X_{k+1})\} + \sqrt{2\gamma_{k+1}} Z_{k+1}$ 
15: end for
16: Output:  $X_0$ 

```

其中 $\{\gamma_{k+1}\}_{k=0}^{N-1}$ 是一个步长序列，且对于任意 $k \in \{0, \dots, N\}$, $t_k = \sum_{j=0}^{k-1} \gamma_{j+1}$ 。

$\{\nabla \log p_{T-t_k}\}_{k=0}^{N-1}$ 的闭式解不可得，实际中我们考虑

$$Y_{k+1} = Y_k + 2\gamma_{k+1} s_{\theta^*}(T - t_k, Y_k) + \sqrt{2\gamma_{k+1}} Z_{k+1}, \quad (52)$$

其中对于任意 $k \in \{0, \dots, N-1\}$, $s_{\theta^*}(T - t_k, \cdot)$ 是 $\nabla \log p_{T-t_k}$ 的近似。采样过程 (52) 与 Song 和 Ermon (2019) 的过程类似，只需设定 (采用 Song 和 Ermon 的记号 (2019)) $T \leftarrow 1$ 在 (Song 和 Ermon, 2019, 算法 1) 中 (无校正步)， $\alpha_k/2 \leftarrow \gamma_k$ 和 $\mathbf{s}_\theta(\cdot, \sigma_{k+1}) \leftarrow 2s_{\theta^*}(T - t_k, \cdot)$ 。仍需证明 $2s_{\theta^*}$ 是 (Song 和 Ermon, 2019, 方程 6) 中与 $\mathbf{s}_\theta$ 相同的回归问题的解。首先，注意到对于任意 $t > 0$ 和 $x_t \in \mathbb{R}^d$ 我们有

$$p_t(x_t) = (4\pi t)^{-d/2} \int_{\mathbb{R}^d} p_{\text{data}}(x_0) \exp[-\|x_t - x_0\|^2 / (4t)] dx_0.$$

因此，我们得到对于任意 $t > 0$ 和 $x_t \in \mathbb{R}^d$

$$\nabla \log p_t(x_t) = \int_{\mathbb{R}^d} (x_0 - x_t) / (2t) p_{0|t}(x_0|x_t) dx_0 = \mathbb{E}[\mathbf{X}_0 - \mathbf{X}_t | \mathbf{X}_t = x_t] / (2t).$$

因此，我们有 θ^* 满足以下回归问题

$$\theta^* = \arg \min_{\theta} \sum_{k=0}^{N-1} \lambda(k) \mathbb{E}[\|(\mathbf{X}_0 - \mathbf{X}_{T-t_k}) / (T - t_k) - 2s_\theta(T - t_k, \mathbf{X}_{T-t_k})\|].$$

注意该损失函数与 (Song 和 Ermon, 2019, 方程 6) 中的损失函数类似，只需令 $\sigma_{k+1}^2 \leftarrow 2(T - t_k)$ 和 $L \leftarrow N$ 。因此，两个递归近似定义相同的方案，如果对于任意 $k \in \{0, \dots, N-1\}$, $\sigma_1^2 - \sigma_{k+1}^2 \approx (1/2) \sum_{j=0}^{k-1} \alpha_{j+1}$ 因为 $t_0 = 0$ 蕴含 $T = (1/2)\sigma_1^2$ 。在 Song 和 Ermon (2019) 中，对于任意 $k \in \{0, \dots, N-1\}$, $\sigma_k^2 = \kappa^{N-k} \sigma_N^2$ (回忆 $N = L$) 其中 $\kappa > 1$ 。此外，对于任意 $k \in \{0, \dots, N-1\}$, $\alpha_k = \varepsilon \sigma_k^2 / \sigma_N^2$ 对于某个 $\varepsilon > 0$ 。我们得到

$$\begin{aligned} (1/2) \sum_{j=0}^{k-1} \alpha_{j+1} &= (\varepsilon/2) \kappa^{N-1} \sum_{j=0}^{k-1} \kappa^{-j} \\ &= (\varepsilon/2) (\kappa^{N-1} - \kappa^{N-k-1}) / (1 - \kappa^{-1}) \\ &= \varepsilon / (2(1 - \kappa^{-1}) \sigma_N^2) (\sigma_1^2 - \sigma_{k+1}^2). \end{aligned}$$

因此，两个方案相同，如果 $\varepsilon = 2(1 - \kappa^{-1}) \sigma_N^2$ 。实际中在 Song 和 Ermon (2019) 中作者选择 $N = 10$, $\sigma_N = 10^{-2}$, $\sigma_1 = 1$ (因此 $\kappa = 10^{4/9}$) 和 $\varepsilon = 2 \times 10^{-5}$ 。我们有 $2(1 - \kappa^{-1}) \sigma_N^2 \approx 1.3 \times 10^{-4}$ 与 ε 有一个数量级的差异。

奥恩斯坦-乌伦贝克 其次，我们证明通过逆转奥恩斯坦-乌伦贝克过程可以恢复 Ho 等人 (2020) 的采样过程和损失函数。与之前的分析相反，我们不展示两个递归之间的严格等价性，而是表明我们的算法可以视为 Ho 等人 (2020) 算法的一阶近似。

在本节中，我们考虑以下扩散过程

$$d\mathbf{X}_t = -\alpha\mathbf{X}_t dt + \sqrt{2}d\mathbf{B}_t, \quad \mathbf{X}_0 \sim p_{\text{data}}. \quad (53)$$

In what follows we define $\{Y_k\}_{k=0}^{N-1}$ such that $\{Y_k\}_{k=0}^{N-1}$ approximates $\{\mathbf{X}_{T-t_k}\}_{k=0}^{N-1}$ for a specific sequence of times $\{t_k\}_{k=0}^{N-1} \in [0, T]^N$. We recall that the time-reversal of (53) is associated with the following SDE

$$d\mathbf{Y}_t = \{\alpha\mathbf{Y}_t + 2\nabla \log p_{T-t}(\mathbf{Y}_t)\}dt + \sqrt{2}d\mathbf{B}_t. \quad (54)$$

在下文中，我们固定 $\alpha = 1$ 。对 (54) 式进行欧拉-丸山离散化，对于任意 $k \in \{0, \dots, N-1\}$ ，得到

$$\tilde{Y}_{k+1} = (1 + \gamma_{k+1})\tilde{Y}_k + 2\gamma_{k+1}\nabla \log p_{T-t_k}(\tilde{Y}_k) + \sqrt{2\gamma_{k+1}}Z_{k+1}.$$

其中 $\{\gamma_{k+1}\}_{k=0}^{N-1}$ 是一个步长序列，并且对于任意 $k \in \{0, \dots, N-1\}$, $t_k = \sum_{j=0}^{k-1} \gamma_{j+1} \cdot \Delta$ ， $\{\nabla \log p_{T-t_k}\}_{k=0}^{N-1}$ 的闭式解不可得，在实践中我们考虑

$$Y_{k+1} = (1 + \gamma_{k+1})Y_k + 2\gamma_{k+1}s_{\theta^*}(T - t_k, Y_k)dt + \sqrt{2\gamma_{k+1}}Z_{k+1}. \quad (55)$$

在 (Ho 等人, 2020, 方程 11) 中，对于任意 $k \in \{0, \dots, N-1\}$ ，给出了如下后向递归

$$Y_{k+1} = \alpha_{N-k}^{-1/2}(Y_k - \beta_{N-k}/(1 - \bar{\alpha}_{N-k})^{1/2}\epsilon_{\theta}(Y_k, T - t_k)) + \sigma_{N-k}Z_{k+1}. \quad (56)$$

在 (56) 式中，我们按照 Ho et al. (2020) 中的建议设置 $\sigma_k^2 = \beta_k$ ，其中对于任意 $k \in \{0, \dots, N-1\}$

$$\sigma_{k+1}^2 = \beta_{k+1}, \quad \alpha_{k+1} = 1 - \beta_{k+1}, \quad \bar{\alpha}_{k+1} = \prod_{i=1}^{k+1} \alpha_i.$$

我们考虑 (56) 式关于 $\{\beta_{k+1}\}_{k=0}^{N-1}$ 的一阶展开。对于任意 $k \in \{0, \dots, N-1\}$ ，我们得到如下递归

$$\begin{aligned} Y_{k+1} &= (1 + \beta_{N-k}/2)Y_k - \beta_{N-k}/(1 - \bar{\alpha}_{N-k})^{1/2}\epsilon_{\theta}(Y_k, T - t_k) + \\ &\sqrt{\beta_{N-k}}Z_{k+1}. \end{aligned}$$

最后一个递归在设置 $\beta_{N-k} \leftarrow 2\gamma_{k+1}$ 和 $-\epsilon_{\theta}(\cdot, T - t_k)/(1 - \bar{\alpha}_{N-k})^{1/2} \leftarrow -s_{\theta^*}(T - t_k, \cdot)$ 后等价于 (55) 式。还需证明 s_{θ^*} 是与 (Ho 等人, 2020, 方程 12) 中 $\epsilon_{\theta}/(1 - \bar{\alpha}_{N-k})$ 相同的回归问题的解。首先，注意到对于任意 $t > 0$ 和 $x_t \in \mathbb{R}^d$ ，我们有 $p_t(x_t) = (2\pi\bar{\sigma}_t^2)^{-d/2} \int_{\mathbb{R}^d} p_{\text{data}}(x_0) \exp[-\|x_t - c_t x_0\|^2/(2\bar{\sigma}_t^2)] dx_0$ ，其中

$$c_t^2 = \exp[-2t], \quad \bar{\sigma}_t^2 = 1 - \exp[-2t].$$

因此，对于任意 $t \in [0, T]$ 和 $x_t \in \mathbb{R}^d$ $\int_{\mathbb{R}^d} (c_t x_0 - x_t) p_{\text{data}}(x_0) \exp[-\|x_t - c_t x_0\|^2/(2\bar{\sigma}_t^2)] dx_0$

$$\nabla \log p_t(x_t) = \mathbb{E}[c_t \mathbf{X}_0 - \mathbf{X}_t | \mathbf{X}_t = x_t] / \bar{\sigma}_t^2 = -\mathbb{E}[\mathbf{Z} | \mathbf{X}_t = x_t] / \bar{\sigma}_t, \quad \text{我们得到，其中我们回顾 } \mathbf{X}_t \text{ 与 } c_t \mathbf{X}_0 + \bar{\sigma}_t \mathbf{Z} \text{ 具有相同的分布，其中 } \mathbf{Z} \text{ 是 } d \text{ 维高斯随机变量具有零均值和单位协方差矩阵。}$$

因此，我们有 θ^* 满足以下回归问题

$$\theta^* = \arg \min_{\theta} \sum_{k=0}^{N-1} \lambda(k) \mathbb{E}[\|\mathbf{Z}/\sigma_{T-t_k} + s_{\theta}(T - t_k, \mathbf{X}_{T-t_k})\|].$$

注意，我们有

$$\sum_{i=1}^{N-k} \beta_i = \sum_{i=k}^{N-1} \beta_{N-i} = 2 \sum_{i=k}^{N-1} \gamma_{i+1} = 2(T - t_k).$$

利用这一结果，对于任意 $k \in \{0, \dots, N-1\}$ ，我们有

$$1 - \bar{\alpha}_{N-k} = 1 - \exp[-\sum_{i=1}^{N-k} \log(1 - \beta_i)] \approx 1 - \exp[-\sum_{i=1}^{N-k} \beta_i] \approx \bar{\sigma}_{T-t_k}^2.$$

设 $\tilde{\theta}^*$ 为 (Ho 等人, 2020 年, 方程 12) 的最小化器，我们有

$$\begin{aligned} \tilde{\theta}^* &\approx \arg \min_{\theta} \sum_{k=0}^{N-1} (2\alpha_{N-k}(1 - \alpha_{N-k}))^{-1} \mathbb{E}[\|\mathbf{Z} - \epsilon_{\theta}(\mathbf{X}_{T-t_k}, T - t_k)\|^2] \\ &\approx \arg \min_{\theta} \sum_{k=0}^{N-1} (2\alpha_{N-k})^{-1} \mathbb{E}[\|\mathbf{Z}/(1 - \alpha_{N-k})^{1/2} - \epsilon_{\theta}(\mathbf{X}_{T-t_k}, T - t_k)/(1 - \alpha_{N-k})^{1/2}\|^2] \\ &\approx \arg \min_{\theta} \sum_{k=0}^{N-1} (2\alpha_{N-k})^{-1} \mathbb{E}[\|\mathbf{Z}/\bar{\sigma}_{T-t_k} + s_{\theta}(T - t_k, \mathbf{X}_{T-t_k})\|^2]. \end{aligned}$$

因此，这两个回归问题大致相同（对于 $\{\beta_{k+1}\}_{k=0}^{N-1}$ 的小值

我们设定 $\lambda(k) = (2\alpha_{N-k})^{-1}$ 。

），如果

带势的薛定谔桥与 DSB 递归

在本节中，我们首先在附录 D.1 中证明库尔贝克-莱布勒发散的可加性公式，遵循 Léonard (2014a)。我们在附录 D.2 中回顾使用势的经典 IPF 公式。然后，命题 2 在附录 D.3 中得到证明。最后，我们在附录 D.4 中强调我们的公式与自编码器之间的联系。

D.1 库尔贝克-莱布勒散度的可加公式

本节中，我们遵循莱昂纳德 (Léonard, 2014a) 的证明，证明库尔贝克-莱布勒散度的一个公式，该证明将结果推广到定义在从 $[0, T]$ 的右连续左极限函数空间上的无界测度。我们回顾，波兰空间是一个完备的度量可分空间。

我们从以下概率测度的分解定理开始。

定理 22. 设 $(X, \mathcal{X})$ 和 $(Y, \mathcal{Y})$ 为两个波兰空间。设 $\pi \in \mathcal{P}(X)$ 和 $\varphi : X \rightarrow Y$ 可测。则存在一个马尔可夫核 $K_\varphi^\pi : Y \times \mathcal{X} \rightarrow [0, 1]$ 使得以下成立：

$$(a) \text{ For any } y \in Y, K_\varphi^\pi(y, \varphi^{-1}(\{y\})) = 1.$$

$$(b) \text{ For any } f : X \rightarrow [0, +\infty) \text{ measurable we have } \int_X f(x) d\pi(x) = \int_Y K_\varphi^\pi(y, f) d\pi_\varphi(y),$$

其中 $\pi_\varphi = \varphi_\# \pi$ 。

证明。参见 (德拉谢里与迈耶, 1988, III-70)。

□

K_φ^π 被称为 π w.r.t. φ 的分解，且是唯一的，参见 (Dellacherie 和 Meyer, 1988, III-70)。特别地，对于任意具有分布 π 的 X 值随机变量 X ，我们有 $\mathbb{E}[f(X)|\varphi(X)] = K_\varphi^\pi(\varphi(X), f)$ 。接下来我们证明以下命题，关于无界测度的扩展参见 (Léonard, 2014a, 命题 A.13)。在下文中，对于任意 $\varphi : X \rightarrow \mathbb{R}$ 可测的，我们记 $\pi_\varphi = \varphi_\# \pi$ 。

命题 23. 设 $(X, \mathcal{X})$ 和 $(Y, \mathcal{Y})$ 为两个波兰空间。设 $\pi, \mu \in \mathcal{P}(X)$ 和 $\varphi : X \rightarrow Y$ 可测。假设 $\pi \ll \mu$ 。则以下结论成立：

$$(a) \pi_\varphi \ll \mu_\varphi$$

$$(b) \text{ 存在 } A \in \mathcal{Y} \text{ 且 } \pi_\varphi(A) = 1, \text{ 使得对于任意 } y \in A, K_\varphi^\pi(y, \cdot) \ll K_\varphi^\mu(y, \cdot)。$$

此外，对于任意 $y \in Y, y' \in A$ 和 $x \in X$ ，我们有

$$(d\pi_\varphi/d\mu_\varphi)(y) = K_\varphi^\mu(y, (d\pi/d\mu)), \quad (dK_\varphi^\pi(y', \cdot)/dK_\varphi^\mu(y', \cdot))(x) = (d\pi/d\mu)(x)/(d\pi_\varphi/d\mu_\varphi)(y').$$

最后，存在 $C \in \mathcal{X}$ 且 $\pi(C) = 1$ ，使得对于任意 $x \in C$ ，我们有

$$(d\pi/d\mu)(x) = (d\pi_\varphi/d\mu_\varphi)(\varphi(x))(dK_\varphi^\pi(\varphi(x), \cdot)/dK_\varphi^\mu(\varphi(x), \cdot))(x).$$

证明。设 $f : X \rightarrow [0, +\infty)$ 可测。利用定理 22，我们有

$$\pi_\varphi[f] = \int_X f(\varphi(x)) d\pi(x) = \int_X f(\varphi(x)) (d\pi/d\mu)(x) d\mu(x) = \int_X f(y) K_\varphi^\mu(y, (d\pi/d\mu)) d\mu_\varphi(y),$$

这完成了证明的第一部分。对于证明的第二部分，设 $B = \{y \in Y : (d\pi_\varphi/d\mu_\varphi)(y) = 0\}$ 。我们有

$$0 = \int_Y \mathbb{1}_B(y) (d\pi_\varphi/d\mu_\varphi)(y) d\mu_\varphi(y) = \pi_\varphi(B).$$

因此，存在 $A_1 \in \mathcal{Y}$ 使得 $\pi_\varphi(A_1) = 1$ 且对任意 $y \in A_1, (d\pi_\varphi/d\mu_\varphi)(y) > 0$ 。
 $g : Y \rightarrow [0, +\infty)$ 令。利用定理 22，我们有

$$\int_X g(\varphi(x)) f(x) d\pi(x) = \int_X g(\varphi(x)) f(x) (d\pi/d\mu)(x) d\mu(x) = \int_Y g(y) K_\varphi^\mu(y, f \times (d\pi/d\mu)) d\mu_\varphi(y).$$

类似地，利用定理 22，我们有

$$\int_X g(\varphi(x)) f(x) d\pi(x) = \int_Y g(y) K_\varphi^\pi(y, f) d\pi_\varphi(y) = \int_Y g(y) K_\varphi^\pi(y, f) (d\pi_\varphi/d\mu_\varphi)(y) d\pi_\varphi(y).$$

因此，我们得到存在 $A_2 \in \mathcal{Y}$ 满足 $\mu_\varphi(A_2) = 1$ (从而 $\pi_\varphi(A_2) = 1$) 使得对任意 $y \in A_2$

$$K_\varphi^\pi(y, f)(d\pi_\varphi/d\mu_\varphi)(y) = K_\varphi^\mu(y, f \times (d\pi/d\mu)).$$

令 $A = A_1 \cap A_2$ 并利用对任意 $y \in A$, $(d\pi_\varphi/d\mu_\varphi)(y) > 0$ 的事实，我们得出结论。最后，由于 $\pi_\varphi(A) = 1$ 当且仅当 $\pi(\varphi^{-1}(A)) = 1$ ，对任意 $x \in \varphi^{-1}(A)$ 我们有

$$(d\pi/d\mu)(x) = (d\pi_\varphi/d\mu_\varphi)(\varphi(x))(dK_\varphi^\pi(\varphi(x), \cdot)/dK_\varphi^\mu(\varphi(x), \cdot))(x),$$

这完成了证明。 $\square$

我们现在准备陈述加法公式。

命题 24。 设 $(X, \mathcal{X})$ 和 $(Y, \mathcal{Y})$ 为两个波兰空间，且 $\pi, \mu \in \mathcal{P}(X)$ 满足 $\pi \ll \mu$ 。则对任意 $\varphi: X \rightarrow Y$ 我们有

$$KL(\pi|\mu) = KL(\pi_\varphi|\mu_\varphi) + \int_Y KL(K_\varphi^\pi(y, \cdot)|K_\varphi^\mu(y, \cdot))d\pi_\varphi(y).$$

证明。首先假设 $\int_X |\log((d\pi/d\mu)(x))| d\pi(x) = +\infty$ 然后，利用命题 23 可得 $\int_X |\log((d\pi_\varphi/d\mu_\varphi)(\varphi(x)))| d\pi(x) = +\infty$ or $\int_X |\log((dK_\varphi^\pi(\varphi(x), \cdot)/dK_\varphi^\mu(\varphi(x), \cdot))(x))| d\pi(x) = +\infty$, i.e. either $KL(\pi_\varphi|\mu_\varphi) = +\infty$ or $\int_Y KL(K_\varphi^\pi(y, \cdot)|K_\varphi^\mu(y, \cdot))d\pi_\varphi(y) = +\infty$ using Theorem 22, which concludes the first part of the proof. Second, assume that $\int_X |\log((d\pi/d\mu)(x))| d\pi(x) < +\infty$. Using Pinsker's inequality (Bakry et al., 2014, Equation 5.2.2) we get that $KL(\pi_\varphi|\mu_\varphi) < +\infty$, i.e. $\int_X |\log((d\pi_\varphi/d\mu_\varphi)(\varphi(x)))| d\pi(x) < +\infty$. Hence, we get that $\int_X |\log((dK_\varphi^\pi(\varphi(x), \cdot)/dK_\varphi^\mu(\varphi(x), \cdot))(x))| d\pi(x) < +\infty$. Therefore we have

$$KL(\pi|\mu) = KL(\pi_\varphi|\mu_\varphi) + \int_Y KL(K_\varphi^\pi(y, \cdot)|K_\varphi^\mu(y, \cdot))d\pi_\varphi(y)$$

从而完成证明 $\square$

我们强调，在 $X = \mathbb{R}^d \times \mathbb{R}^d$, $\varphi = \text{proj}_0$ 为对第一个变量的投影且 π, μ 关于勒贝格测度 (Lebesgue measure) 具有密度，分别记为 p 和 q ，使得对任意 $x, y \in \mathbb{R}^d$, $p(x, y) = p_0(x)p_{1|0}(y|x)$ 和 $q(x, y) = q_0(x)q_{1|0}(y|x)$ 成立时，可以避免使用分解理论，命题 24 可直接证明。

D.2 基于势的迭代比例拟合

本节在回顾基于势的迭代比例拟合 (IPF) 通常定义之前，给出一个保证 IPF 序列良定义的条件，该条件贯穿第 3.2 节使用。

命题 25。 假设存在 $\tilde{\pi} \in \mathcal{P}_{N+1}$ 使得 $\tilde{\pi}_0 = p_{\text{data}}$, $\tilde{\pi}_N = p_{\text{prior}}$ 且 $KL(\tilde{\pi}|\pi^0) < +\infty$ 。则 IPF 序列是良定义的。

证明。我们通过递归证明 IPF 序列的存在性。首先，注意到 π^1 是良定义的，因为 $\tilde{\pi} \in \mathcal{P}_{N+1}$ 且 $\tilde{\pi}_N = p_{\text{prior}}$ 且 $KL(\tilde{\pi}|\pi^0) < +\infty$ 。其次，假设序列已良定义至 n 且 $n \in \mathbb{N}$ 。利用 (Csiszár, 1975, 定理 2.2) 可得

$$KL(\tilde{\pi}|\pi^0) = KL(\tilde{\pi}|\pi^n) + \sum_{j=0}^{n-1} KL(\pi^{j+1}|\pi^j).$$

因此 $KL(\tilde{\pi}|\pi^n) < +\infty$ 。利用当 $\tilde{\pi}_0 = p_{\text{data}}$ 为奇数时 n ，以及当 $\tilde{\pi}_N = p_{\text{prior}}$ 为偶数时 n ，我们得到 π^{n+1} 是良定义的，从而完成证明。 $\square$

我们现在引入使用势函数的 IPF。该构造并非新颖，可参见 Bernton 等人 (2019); Chen 等人 (2016, 2021b); Pavon 等人 (2021); Peyré 和 Cuturi (2019) (在连续状态空间中)。在离散情形下，该递归可在以下早期工作中找到：Kruithof (1937); Deming 和 Stephan (1940); Fortet (1940); Sinkhorn 和 Knopp (1967); Kullback (1968); Ruschendorf 等人 (1995)。IPF 由以下递归定义 $\pi^0 = p$ ，如 (1) 式所

$n \geq 0$ 示，且对于

$$\begin{aligned} \pi^{2n+1} &= \arg \min \{ KL(\pi|\pi^{2n}) : \pi \in \mathcal{P}_{N+1}, \pi_N = p_{\text{prior}} \}, \\ \pi^{2n+2} &= \arg \min \{ KL(\pi|\pi^{2n+1}) : \pi \in \mathcal{P}_{N+1}, \pi_0 = p_{\text{data}} \}. \end{aligned}$$

在经典 IPF 表述中，我们在温和假设下得到 π^{2n+1} 关于勒贝格测度具有密度 q^n ，且 π^{2n} 关于勒贝格测度具有密度 p^n ，由以下表达式给出

$$\begin{aligned} q^n(x_{0:N}) &= p_{\text{data}}^n(x_0) \prod_{k=0}^{N-1} p_{k+1|k}^{n+1}(x_{k+1}|x_k), \\ p^{n+1}(x_{0:N}) &= p_{\text{data}}(x_0) \prod_{k=0}^{N-1} p_{k+1|k}^{n+1}(x_{k+1}|x_k), \end{aligned} \quad (57)$$

其中 $(p_{\text{data}}^n(x_0))_{n \in \mathbb{N}}$ 和 $(p_{k+1|k}^n(x_{k+1}|x_k))_{n \in \mathbb{N}}$ 是迭代计算的密度，且 $p_{k+1|k}^0 = p_{k+1|k}$ 。

在生成模型的背景下，推导 (57) 并不实用，因为它没有提供生成模型，即从 p_{prior} 到 p_{data} 的概率转移，而是定义了从 p_{data} 到 p_{prior} 的转移。因此，仅在本节中，我们交换 p_{prior} 和 p_{data} 的角色，并考虑参考密度 $\bar{p}$ ，使得对于任意 $x_{0:N} \in \mathcal{X}$ ，我们有

$$\bar{p}(x_{0:N}) = p_{\text{prior}}(x_0) \prod_{k=0}^{N-1} \bar{p}_{k+1|k}(x_{k+1}|x_k). \quad (58)$$

然后，我们考虑以下递归 $\pi^0 = \bar{p}$ ，如 (58) 式所示，且对于 $n \in \mathbb{N}$

$$\begin{aligned} \pi^{2n+1} &= \arg \min \{ \text{KL}(\pi | \pi^{2n}) : \pi \in \mathcal{P}_{N+1}, \pi_N = p_{\text{data}} \}, \\ \pi^{2n+2} &= \arg \min \{ \text{KL}(\pi | \pi^{2n+1}) : \pi \in \mathcal{P}_{N+1}, \pi_0 = p_{\text{prior}} \}. \end{aligned} \quad (59)$$

再次强调，在此表述中 p_{prior} 和 p_{data} 的角色被交换。使用经典 IPF 表述，我们在温和假设下得到以下表达式

$$\begin{aligned} \bar{q}^n(x_{0:N}) &= p_{\text{prior}}^n(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k), \\ \bar{p}^{n+1}(x_{0:N}) &= p_{\text{prior}}(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k). \end{aligned} \quad (60)$$

在这种情况下，我们得到 π^{2n+1} （近似地）为较大的 $n \in \mathbb{N}$ 值定义了一个生成模型，因为它提供了从 p_{prior} 到（近似地） p_{data} 的转移。在以下命题中，我们给出对应于 (60) 的精确陈述。我们假设 $\bar{p}^0 = \bar{p}$ 。

命题 26. 假设 $\text{KL}(p_{\text{prior}} \otimes p_{\text{data}} | \bar{p}_{0,N}) < +\infty$ 。那么由 (59) 给出的 $(\pi^n)_{n \in \mathbb{N}}$ 是良定义的，并且对于任意 $n \in \mathbb{N}$ ， π^{2n+1} 和 π^{2n+2} 关于勒贝格测度存在密度，分别记为 $\bar{q}^n$ 和 $\bar{p}^{n+1}$ 。此外，对于任意 $n \in \mathbb{N}$ 和 $x_{0:N} \in \mathcal{X}$ ，我们有

$$\begin{aligned} \bar{q}^n(x_{0:N}) &= p_{\text{prior}}^n(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k), \\ \bar{p}^{n+1}(x_{0:N}) &= p_{\text{prior}}(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k), \end{aligned}$$

其中对于任意 $n \in \mathbb{N}$ ，对于任意 $x_{0:N} \in \mathcal{X}$ 和 $k \in \{0, \dots, N-1\}$ ，我们有

$$p_{\text{prior}}^n(x_0) = \psi_0^n(x_0) p_{\text{prior}}(x_0), \quad \bar{p}^{n+1}(x_{k+1}|x_k) = \bar{p}^n(x_{k+1}|x_k) \psi_{k+1}^n(x_{k+1}) / \psi_k^n(x_k),$$

其中

$$\psi_N^n(x_N) = p_{\text{data}}(x_N) / \bar{p}_N^n(x_N), \quad \psi_k^n(x_k) = \int_{\mathbb{R}^d} \psi_{k+1}^n(x_{k+1}) \bar{p}^n(x_{k+1}|x_k) dx_{k+1}.$$

证明。 令 $\tilde{\pi} = (p_{\text{prior}} \otimes p_{\text{data}})^- \bar{p}_{0,N}$ 。利用命题 24，我们得到 $\text{KL}(\tilde{\pi} | \bar{p}) = \text{KL}(p_{\text{prior}} \otimes p_{\text{data}} | \bar{p}_{0,N}) < +\infty$ 。利用命题 25，IPF 序列是良定义的。此外，利用 (Csiszár, 1975, 定理 3.1)，对于任意 $n \in \mathbb{N}$ ，存在 $\psi_N^n : \mathbb{R}^d \rightarrow [0, +\infty)$ 使得对于任意满足 $\tilde{\pi}(A) = 1$ 的 $x_{0:N} \in A$ ，我们有 $\bar{q}^n(x_{0:N}) = \bar{p}^n(x_{0:N}) \psi_N^n(x_N)$ 。由于 $\tilde{\pi}$ 与勒贝格测度等价，我们得到对于任意 $x_{0:N} \in \mathbb{R}^d$

$$\bar{q}^n(x_{0:N}) = \bar{p}^n(x_{0:N}) \psi_N^n(x_N).$$

令 $n \in \mathbb{N}$ 。对于任意 $x_N \in \mathbb{R}^d$ ， $p_{\text{data}}(x_N) = \bar{q}^n(x_N) = \bar{p}_N^n(x_N) \psi_N^n(x_N)$ ，我们有。因此，我们得到对于任意 $N \in \mathbb{N}$ ， $\psi_N^n(x_N) = p_{\text{data}}(x_N) / \bar{p}_N^n(x_N)$ 。
对于任意 $x_{0:N} \in \mathcal{X}$ 和 $\mathbb{R}^d \psi_{k+1}^n(x_{k+1}) \bar{p}^n(x_{k+1}|x_k) dx_{k+1}$ ， $k \in \{0, \dots, N-1\}$ ，令 $\psi_k^n(x_k) = \int$ 。我们得到对于任意 $x_{0:N} \in \mathcal{X}$

$$\bar{q}^n(x_{0:N}) = p_{\text{prior}}(x_0) \psi_0^n(x_0) \prod_{k=0}^{N-1} (\bar{p}^n(x_{k+1}|x_k) \psi_{k+1}^n(x_{k+1}) / \psi_k^n(x_k)).$$

因此，我们得到对于任意 $x_{0:N} \in \mathcal{X}$ ， $\bar{q}^n(x_0) = p_{\text{prior}}^n(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k)$ 。利用命题 24，我们得到对于任意 $x_{0:N} \in \mathcal{X}$ ， $\bar{p}^{n+1}(x_0) = p_{\text{prior}}(x_0) \prod_{k=0}^{N-1} \bar{p}^{n+1}(x_{k+1}|x_k)$ ，从而完成证明。 $\square$

上述表达式不是对称的，IPF 迭代表现为原始前向动态 $\bar{p}$ 的策略精化。在下一个命题中，我们提出 IPF 迭代的另一种对称的潜在形式。

命题 27. 假设 $\text{KL}(p_{\text{prior}} \otimes p_{\text{data}} | q_{0,N}) < +\infty$ 。那么由 (59) 给出的 $(\pi^n)_{n \in \mathbb{N}}$ 是良定义的，并且对于任意 $n \in \mathbb{N}$ ， π^{2n+1} 和 π^{2n+2} 关于勒贝格测度存在密度，分别记为 $\bar{q}^n$ 和 $\bar{p}^{n+1}$ 。此外，对于任意 $n \in \mathbb{N}$ 和 $x_{0:N} \in \mathcal{X}$ ，我们有

$$\begin{aligned}\bar{q}^n(x_{0:N}) &= \varphi_0^n(x_0) \prod_{k=0}^{N-1} \bar{p}(x_{k+1}|x_k) \psi_N^n(x_N), \\ \bar{p}^{n+1}(x_{0:N}) &= \varphi_0^{n+1}(x_0) \prod_{k=0}^{N-1} \bar{p}(x_{k+1}|x_k) \psi_N^n(x_N),\end{aligned}$$

其中对于任意 $n \in \mathbb{N}$ ，对于任意 $x_{0:N} \in \mathcal{X}$ 和 $k \in \{0, \dots, N-1\}$ ，我们有

$$\begin{aligned}\psi_N^n(x_N) &= p_{\text{data}}(x_N) / \varphi_N^n(x_N), \quad \psi_k^n(x_k) = \int_{\mathbb{R}^d} \psi_{k+1}^n(x_{k+1}) \bar{p}(x_{k+1}|x_k) dx_{k+1}, \\ \varphi_0^{n+1}(x_0) &= p_{\text{prior}}(x_0) / \psi_0^n(x_0), \quad \varphi_{k+1}^{n+1}(x_{k+1}) = \int_{\mathbb{R}^d} \varphi_k^{n+1}(x_k) \bar{p}(x_{k+1}|x_k) dx_k,\end{aligned}$$

及 $\varphi_0^0 = p_{\text{prior}}$ 及 $\psi_N^{-1} = 1$ 。

证明。 令 $\tilde{\pi} = (p_{\text{prior}} \otimes p_{\text{data}})q_{|0,N}$ 。利用命题 24，我们得到 $\text{KL}(\tilde{\pi}|q) = \text{KL}(p_{\text{prior}} \otimes p_{\text{data}} | p_{0,N}) < +\infty$ 。利用命题 25，IPF 序列是良定义的。此外，利用 (Csiszár, 1975, 定理 3.1)，对于任意 $n \in \mathbb{N}$ ，存在 $\psi_N^n : \mathbb{R}^d \rightarrow [0, +\infty)$ 使得对于任意满足 $\tilde{\pi}(A) = 1$ 的 $x_{0:N} \in A$ ，我们有

$$\bar{q}^n(x_{0:N}) = \bar{p}^n(x_{0:N}) \tilde{\psi}_N^n(x_N), \quad \bar{p}^{n+1}(x_{0:N}) = \bar{q}^n(x_{0:N}) \tilde{\varphi}_0^n(x_0).$$

由于 $\tilde{\pi}$ 等价于勒贝格测度，我们得到对于任意 $x_{0:N} \in \mathbb{R}^d$

$$\bar{q}^n(x_{0:N}) = \bar{p}^n(x_{0:N}) \tilde{\psi}_N^n(x_N), \quad \bar{p}^{n+1}(x_{0:N}) = \bar{q}^n(x_{0:N}) \tilde{\varphi}_0^n(x_0).$$

For any $n \in \mathbb{N}$, let $\psi_N^n = \psi_N^{n-1} \tilde{\psi}_N^n$ 及 $\varphi_0^{n+1} = \varphi_0^n \tilde{\varphi}_0^n$ 通过递归，我们得到对于任意 $n \in \mathbb{N}$ 且 $x_{0:N} \in \mathcal{X}$

$$\begin{aligned}\bar{q}^n(x_{0:N}) &= \varphi_0^n(x_0) \prod_{k=0}^{N-1} \bar{p}(x_{k+1}|x_k) \psi_N^n(x_N), \\ \bar{p}^{n+1}(x_{0:N}) &= \varphi_0^{n+1}(x_0) \prod_{k=0}^{N-1} \bar{p}(x_{k+1}|x_k) \psi_N^n(x_N).\end{aligned}$$

Let $n \in \mathbb{N}$. For any $x_N \in \mathbb{R}^d$ we have

$$\bar{q}_N^n(x_N) = p_{\text{data}}(x_N) = \bar{p}_N^n(x_N) \tilde{\psi}_N^n(x_N). \quad (61)$$

In addition, for any $k \in \{0, \dots, N-1\}$ 及 $x_{0:N} \in \mathcal{X}$ we define $\varphi_{k+1}^{n+1}(x_{k+1}) = \int_{\mathbb{R}^d} \varphi_k^{n+1}(x_k) \bar{p}(x_{k+1}|x_k) dx_k$. We have for any $x_N \in \mathbb{R}^d$, $\bar{p}_N^n(x_N) = \varphi_N^n(x_N) \psi_N^{n-1}(x_N)$. Combin- 将此结果与 (61) 结合，我们得到对于任意 $x_N \in \mathbb{R}^d$

$$\psi_N^n(x_N) = p_{\text{data}}(x_N) / \varphi_N^n(x_N).$$

类似地，我们得到对于任意 $x_0 \in \mathbb{R}^d$, $\varphi_0^{n+1}(x_0) = p_{\text{prior}}(x_0) / \psi_0^n(x_0)$ ，这完成了证明。□

D.3 命题 2 的证明

设 $\tilde{\pi} = (p_{\text{prior}} \otimes p_{\text{data}})p_{|0,N}$ 。利用命题 24，我们得到 $\text{KL}(\tilde{\pi}|p) = \text{KL}(p_{\text{prior}} \otimes p_{\text{data}} | p_{0,N}) < +\infty$ 。利用命题 25，IPF 序列是良定义的。注意 π^0 关于勒贝格测度具有密度，由 $p > 0$ 给出。设 $n \in \mathbb{N}$ 并假设 $p^n > 0$ 对于任意 $x_{0:N} \in \mathcal{X}$ 由下式给出

$$p^n(x_{0:N}) = p_{\text{data}}(x_0) \prod_{k=0}^{N-1} q^{n-1}(x_{k+1}|x_k). \quad (62)$$

利用命题 24，我们得到对于任意满足 $\pi_N = p_{\text{prior}}$ 的 $\pi \in \mathcal{P}_{N+1}$ ，我们有

$$\text{KL}(\pi | \pi^{2n}) = \text{KL}(p_{\text{prior}} | \pi_0^{2n}) + \int_{\mathbb{R}^d} \text{KL}(\pi_{|N} | \pi_{|N}^{2n}) p_{\text{prior}}(x_N) dx_N.$$

因此，我们有 $\pi^{2n+1} = p_{\text{prior}} \pi_{|N}^{2n}$ 。由于 $p^n > 0$ ，我们得到对于任意 $\pi_{|N}^{2n}$ 满足对于任意 $A \in \mathcal{B}(\mathcal{X})$ 和 $x_N \in \mathbb{R}^d$

$$\pi_{|N}^{2n}(A | x_N) = \int_A p^n(x_{0:N}) / p^n(x_N) dx_{0:N} \delta_{x_N}(A_N).$$

因此， π^{2n+1} 关于勒贝格测度 (Lebesgue measure) 存在密度，记为 q^n ，且对任意 $x_{0:N} \in \mathcal{X}$ by

$$\begin{aligned} q^n(x_{0:N}) &= p^n(x_{0:N})p_{\text{prior}}(x_N)/p^n(x_N) \\ &= p_{\text{prior}}(x_N) \prod_{k=0}^{N-1} p^n(x_{k+1}|x_k)p^n(x_k)/p^n(x_{k+1}) = p_{\text{prior}}(x_N) \prod_{k=0}^{N-1} p^n(x_k|x_{k+1}), \end{aligned}$$

其中我们使用了 (62)。注意 $q^n > 0$ 。类似地，我们得到对任意 $x_{0:N} \in \mathcal{X}$

$$p^{n+1}(x_{0:N}) = p_{\text{data}}(x_0) \prod_{k=0}^{N-1} q^n(x_{k+1}|x_k)。$$

再次注意 $p^{n+1} > 0$ 。我们通过递归得出结论。

D.4 与自编码器的联系

考虑最大似然问题

$$q^* = \arg \max \{ \mathbb{E}_{p_{\text{data}}} [\log q_0(X_0)] : q \in \mathcal{P}_d(\mathcal{X}), q_N = p_{\text{prior}} \},$$

其中 $\mathcal{P}_d(\mathcal{X})$ 是 $\mathcal{X}$ 上概率分布的子集，这些分布关于勒贝格测度存在密度。利用詹森不等式 (Jensen's inequality)，对任意 $q \in \mathcal{P}_d(\mathcal{X})$ 有

$$\begin{aligned} \mathbb{E}_{p_{\text{data}}} [\log q_0(X_0)] &= \int_{\mathbb{R}^d} \log \left(\int_{\mathbb{R}^d} q(x_{0:N}) p(x_{1:N}|x_0) / p(x_{1:N}|x_0) dx_{1:N} \right) p_0(x_0) dx_0 \\ &\geq \int_{\mathcal{X}} \log(q(x_{0:N})/p(x_{1:N}|x_0)) p(x_{0:N}) dx_{0:N} \geq -\text{KL}(p|q) - H(p_0). \end{aligned}$$

该证据下界 (Evidence Lower Bound, ELBO) 与 Ho 等人 (2020) 中识别出的类似。最大化该 ELBO 等价于求解以下问题

$$q^0 = \arg \min \{ \text{KL}(q|p) : q \in \mathcal{P}_d(\mathcal{X}), q_N = p_{\text{prior}} \},$$

这是 IPF 的第一步。因此，后续步骤可以通过最大化与以下最大似然问题相关的 ELBO 获得，对任意 $n \in \mathbb{N}$

$$\begin{aligned} q^* &= \arg \max \{ \mathbb{E}_{p_{\text{data}}} [\log q_0(X_0)] : q \in \mathcal{P}_d(\mathcal{X}), q_N = p_{\text{prior}} \}, \\ p^* &= \arg \max \{ \mathbb{E}_{p_{\text{prior}}} [\log p_N(X_N)] : p \in \mathcal{P}_d(\mathcal{X}), p_0 = p_{\text{data}} \}. \end{aligned}$$

E 替代变分公式

在本节中，我们建立迭代比例拟合与得分匹配技术之间的联系。首先证明

附录 E.1 中的命题 3。随后在附录 E.2 中给出替代变分公式。

E.1 命题 3 的证明

我们仅证明 (12)，因为 (13) 的证明类似。设 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ 。对于任意 $x_{k+1} \in \mathbb{R}^d$ ，有

$$p_{k+1}^n(x_{k+1}) = (4\pi\gamma_{k+1})^{-d/2} \int_{\mathbb{R}^d} p^n(x_k) \exp[-\|F_k^n(x_k) - x_{k+1}\|^2 / (4\gamma_{k+1})] dx_k,$$

其中 $F_k^n(x_k) = x_k + \gamma_{k+1} f_k^n(x_k)$ 。由于 $p_k^n > 0$ 有界，利用控制收敛定理，对于任意 $x_{k+1} \in \mathbb{R}^d$ ，有

$$\nabla \log p_{k+1}^n(x_{k+1}) = \int_{\mathbb{R}^d} (F_k^n(x_k) - x_{k+1}) / (2\gamma_{k+1}) p_{k|k+1}(x_k|x_{k+1}) dx_k.$$

因此，对于任意 $x_{k+1} \in \mathbb{R}^d$ ，我们得到

$$b_{k+1}^n(x_{k+1}) = \int_{\mathbb{R}^d} (F_k^n(x_k) - F_k^n(x_{k+1})) / \gamma_{k+1} p_{k|k+1}(x_k|x_{k+1}) dx_k.$$

这等价于

$$B_{k+1}^n(x_{k+1}) = \mathbb{E}[X_{k+1} + F_k^n(X_k) - F_k^n(X_{k+1}) | X_{k+1} = x_{k+1}],$$

与 $(X_k, X_{k+1}) \sim p_{k,k+1}(x_k, x_{k+1})$ 。因此，我们得到

$$B_{k+1}^n = \arg \min_{B \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|B(X_{k+1}) - (X_{k+1} + F_k^n(X_k) - F_k^n(X_{k+1}))\|^2],$$

这完成了证明。

E.2 变分公式

在命题 3 和第 3.3 节中，我们给出了 B_{k+1}^n 和 F_k^{n+1} 对任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ 的变分公式，其中我们回顾对于任意 $x \in \mathbb{R}^d$ 有

$$B_{k+1}^n(x) = x + \gamma_{k+1} b_{k+1}^n(x), \quad F_k^{n+1} = x + \gamma_{k+1} f_k^{n+1}(x),$$

其中我们有

$$b_{k+1}^n(x) = -f_k^n(x) + 2\nabla \log p_{k+1}^n(x), \quad f_k^{n+1}(x) = -b_{k+1}^n(x) + 2\nabla \log q_k^n(x). \quad (63)$$

在本节其余部分，我们假设对任意 $n \in \mathbb{N}, k \in \{0, \dots, N-1\}$ 和 $x \in \mathbb{R}^d$ 有

$$q_{k|k+1}^n(x_k|x_{k+1}) = (4\pi\gamma_{k+1})^{-d/2} \exp[-\|x_k - B_{k+1}^n(x_{k+1})\|^2/(4\gamma_{k+1})], \\ p_{k+1|k}^{n+1}(x_{k+1}|x_k) = (4\pi\gamma_{k+1})^{-d/2} \exp[-\|x_{k+1} - F_k^{n+1}(x_k)\|^2/(4\gamma_{k+1})].$$

我们回顾在这种情况下，命题 3 确保对任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$

$$B_{k+1}^n = \arg \min_{B \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|B(X_{k+1}) - (X_{k+1} + F_k^n(X_k) - F_k^n(X_{k+1}))\|^2], \\ F_k^{n+1} = \arg \min_{F \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{q_{k,k+1}^n} [\|F(X_k) - (X_k + B_{k+1}^n(X_{k+1}) - B_{k+1}^n(X_k))\|^2].$$

在本节其余部分，我们推导其他变分公式并讨论其实际局限性与优势。

E.2.1 得分匹配公式与网络之和 首先，利用 (63) 式，对任意

$n \in \mathbb{N}, k \in \{0, \dots, N-1\}$ 和 $x \in \mathbb{R}^d$ 我们有

$$b_{k+1}^n(x) = \alpha x + 2 \sum_{j=0}^n \nabla \log p_{k+1}^j(x) - 2 \sum_{j=0}^{n-1} \nabla \log q_k^j(x), \quad (64)$$

$$f_k^n(x) = -\alpha x + 2 \sum_{j=0}^{n-1} \nabla \log q_k^j(x) - 2 \sum_{j=0}^{n-1} \nabla \log p_{k+1}^j(x). \quad (65)$$

在以下命题中，我们推导出对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ ， $\nabla \log p_{k+1}^n$ 与 $\nabla \log q_k^n$ 的变分公式。

命题 28. 对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ ，我们有

$$\nabla \log p_{k+1}^n = \arg \min_{u \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|u(X_{k+1}) - (F_k^n(X_k) - X_{k+1})/(2\gamma_{k+1})\|^2], \quad (66)$$

$$\nabla \log q_k^n = \arg \min_{v \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{q_{k,k+1}^n} [\|v(X_k) - (B_{k+1}^n(X_{k+1}) - X_k)/(2\gamma_{k+1})\|^2]. \quad (67)$$

证明。该证明与命题 3 的证明类似，但为完整性起见在此给出。我们仅证明 (68)，因为 (69) 的证明类似。设 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ 。对于任意 $x_{k+1} \in \mathbb{R}^d$ ，我们有

$$p_{k+1}^n(x_{k+1}) = (4\pi\gamma_{k+1})^{-d/2} \int_{\mathbb{R}^d} p^n(x_k) \exp[-\|F_k^n(x_k) - x_{k+1}\|^2/(4\gamma_{k+1})] dx_k,$$

其中 $F_k^n(x_k) = x_k + \gamma_{k+1} f_k^n(x_k)$ 。由于 $p_k^n > 0$ 有界，利用控制收敛定理，对于任意 $x_{k+1} \in \mathbb{R}^d$ ，有

$$\nabla \log p_{k+1}^n(x_{k+1}) = \int_{\mathbb{R}^d} (F_k^n(x_k) - x_{k+1})/(2\gamma_{k+1}) p_{k|k+1}^n(x_k|x_{k+1}) dx_k.$$

这等价于

$$\nabla \log p_{k+1}^n(x_{k+1}) = \mathbb{E}[(F_k^n(X_k) - X_{k+1})/(2\gamma_{k+1}) | X_{k+1} = x_{k+1}],$$

与 $(X_k, X_{k+1}) \sim p_{k,k+1}(x_k, x_{k+1})$ 。因此，我们得到

$$\nabla \log p_{k+1}^n = \arg \min_{u \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|u(X_{k+1}) - (F_k^n(X_k) - X_{k+1})/(2\gamma_{k+1})\|^2],$$

这完成了证明。 $\square$

注意到 (68) 和 (69) 可以通过指出对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ 来简化

$$X_{k+1}^n = F_k^n(X_k^n) + \sqrt{2\gamma_{k+1}}Z_{k+1}^n, \quad \tilde{X}_k^n = F_k^n(\tilde{X}_{k+1}^n) + \sqrt{2\gamma_{k+1}}\tilde{Z}_{k+1}^n,$$

含 $\{X_k^n\}_{k=0}^N \sim p^n, \{\tilde{X}_k^n\}_{k=0}^N \sim q^n$ 和 $\{(Z_{k+1}^n, \tilde{Z}_{k+1}^n) : n \in \mathbb{N}, k \in \{0, \dots, N-1\}\}$ a family with mean and identity covariance matrix. 由中斯随机变量。利用这一结果，我们得到对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$

$$\nabla \log p_{k+1}^n = \arg \min_{u \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|u(X_{k+1}) - Z_{k+1}^n / \sqrt{2\gamma_{k+1}}\|^2], \quad (68)$$

$$\nabla \log q_k^n = \arg \min_{v \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{q_{k,k+1}^n} [\|v(X_k) - \tilde{Z}_{k+1}^n / \sqrt{2\gamma_{k+1}}\|^2]. \quad (69)$$

在实践中，使用神经网络 $u_{\alpha^n}(k, x) \approx \nabla \log p_k^n(x)$ 和 $v_{\beta^n}(k, x) \approx \nabla \log q_k^n(x)$ 。因此，我们使用以下递归从 q^n 和 p^n 中近似采样，对于任意 $n \in \mathbb{N}$ ：

$$\begin{aligned} \tilde{X}_k^n &= \tilde{\tau}_{k+1} \tilde{X}_{k+1}^n + 2\gamma_{k+1} \left\{ \sum_{j=0}^n u_{\alpha^j}(k+1, \tilde{X}_{k+1}^n) - \sum_{j=0}^{n-1} v_{\beta^j}(k, \tilde{X}_{k+1}^n) \right\} + \sqrt{2\gamma_{k+1}} \tilde{Z}_{k+1}^n, \\ X_{k+1}^n &= \tau_{k+1} X_k^n + 2\gamma_{k+1} \left\{ \sum_{j=0}^n u_{\alpha^j}(k+1, X_k^n) - \sum_{j=0}^n v_{\beta^j}(k, X_k^n) \right\} + \sqrt{2\gamma_{k+1}} Z_{k+1}^n, \end{aligned} \quad (70)$$

其中 $\tilde{\tau}_{k+1} = 1 + \alpha\gamma_{k+1}$, $\tau_{k+1} = 1 - \alpha\gamma_{k+1}$ 及 $X_0^n \sim p_{\text{data}}, \tilde{X}_N^n \sim p_{\text{prior}}$.

E.2.2 漂移匹配公式

在命题 3 中，我们给出了对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ ， B_{k+1}^n 与 F_k^{n+1} 的变分公式。在命题 28 中，我们给出了对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ ， $\nabla \log p_{k+1}^n$ 与 $\nabla \log q_k^n$ 的变分公式。在以下命题中，我们给出漂移 b_{k+1}^n 与 f_k^{n+1} 的变分公式。

命题 29. 对于任意 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ ，我们有

$$b_{k+1}^n = \arg \min_{b \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|b(X_{k+1}) - (F_k^n(X_k) - F_k^n(X_{k+1}))/\gamma_{k+1}\|^2] \quad (71)$$

$$f_k^{n+1} = \arg \min_{f \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{q_{k,k+1}^n} [\|f(X_k) - (B_{k+1}^n(X_{k+1}) - B_{k+1}^n(X_k))/\gamma_{k+1}\|^2] \quad (72)$$

证明。证明过程与命题 3 类似，但为完整性起见在此给出。我们仅证明 (71)，因为 (72) 的证明类似。设 $n \in \mathbb{N}$ 和 $k \in \{0, \dots, N-1\}$ 。对于任意 $x_{k+1} \in \mathbb{R}^d$ ，我们有

$$p_{k+1}^n(x_{k+1}) = (4\pi\gamma_{k+1})^{-d/2} \int_{\mathbb{R}^d} p^n(x_k) \exp[-\|F_k^n(x_k) - x_{k+1}\|^2 / (4\gamma_{k+1})] dx_k,$$

其中 $F_k^n(x_k) = x_k + \gamma_{k+1} f_k^n(x_k)$ 。由于 $p_k^n > 0$ 有界，利用控制收敛定理，对于任意 $x_{k+1} \in \mathbb{R}^d$ ，有

$$\nabla \log p_{k+1}^n(x_{k+1}) = \int_{\mathbb{R}^d} (F_k^n(x_k) - x_{k+1}) / (2\gamma_{k+1}) p_{k|k+1}(x_k | x_{k+1}) dx_k.$$

因此，对于任意 $x_{k+1} \in \mathbb{R}^d$ ，我们得到

$$b_{k+1}^n(x_{k+1}) = \int_{\mathbb{R}^d} (F_k^n(x_k) - F_k^n(x_{k+1})) / \gamma_{k+1} p_{k|k+1}(x_k | x_{k+1}) dx_k.$$

这等价于

$$b_{k+1}^n(x_{k+1}) = \mathbb{E}[(F_k^n(X_k) - F_k^n(X_{k+1})) / \gamma_{k+1} | X_{k+1} = x_{k+1}],$$

与 $(X_k, X_{k+1}) \sim p(x_k, x_{k+1})$ 。因此，我们得到

$$b_{k+1}^n = \arg \min_{b \in L^2(\mathbb{R}^d, \mathbb{R}^d)} \mathbb{E}_{p_{k,k+1}^n} [\|b(X_{k+1}) - (F_k^n(X_k) - F_k^n(X_{k+1})) / \gamma_{k+1}\|^2],$$

这完成了证明。 $\square$

在实践中，使用神经网络 $b_{\beta^n}(k, x) \approx b_k^n(x)$ 和 $f_{\alpha^n}(k, x) \approx f_k^n(x)$ 。因此，我们使用以下递归从 q^n 和 p^n 中近似采样，对于任意 $n \in \mathbb{N}$ ：

$$\begin{aligned} \tilde{X}_k^n &= \tilde{X}_{k+1}^n + \gamma_{k+1} b_{\beta^n}(k+1, \tilde{X}_{k+1}^n) + \sqrt{2\gamma_{k+1}} \tilde{Z}_{k+1}^n, \\ X_{k+1}^n &= X_k^n + \gamma_{k+1} f_{\alpha^n}(k, X_k^n) + \sqrt{2\gamma_{k+1}} Z_{k+1}^n, \end{aligned}$$

含 $X_0^n \sim p_{\text{data}}, \tilde{X}_N^n \sim p_{\text{prior}}$.

E.2.3 讨论

我们识别出与命题 3、命题 28 和命题 29 相关的三个变分公式。在实践中，我们舍弃附录 E.2.1 的方法，因为它需要存储 $2n$ 个神经网络来从 p^n 采样，见 (70)。因此，该算法随着 n 增大需要更多内存，且采样过程需要 $\mathcal{O}(nN)$ 次神经网络前向传播。命题 3 和命题 29 描述的方法产生的采样过程仅需 $\mathcal{O}(N)$ 次神经网络前向传播，并且对于任意 $n \in \mathbb{N}$ 具有固定的内存开销。在实践中，我们观察到命题 3 的方法效果更好。我们推测这种有利行为主要归因于用于近似 B_{k+1}^n 和 F_k^{n+1} 的神经网络架构，这些网络具有残差连接，因此更适合表示 $x \mapsto x + \Phi(x)$ 的函数，其中 Φ 是一个扰动。

F 薛定谔桥与 IPF 的理论研究

在本节中，我们探讨薛定谔桥和 IPF 过程的一些理论性质。命题 4 和命题 5 分别在附录 F.1 和附录 F.2 中证明。

F.1 命题 4 的证明

在本节中，我们证明命题 4。首先，我们在命题 31 中收集了 IPF 的新单调性结果，见附录 F.1.1。然后，我们证明我们的定

量收敛界

定理 36，见附录 F.1.2。

F.1.1 单调性结果

我们考虑静态 IPF 递归： $\pi^0 = \mu \in \mathcal{P}_2$ 以及

$$\begin{aligned}\pi^{2n+1} &= \arg \min \{ \text{KL}(\pi | \pi^{2n}) : \pi \in \mathcal{P}_2, \pi_1 = \nu_1 \}, \\ \pi^{2n+2} &= \arg \min \{ \text{KL}(\pi | \pi^{2n+1}) : \pi \in \mathcal{P}_2, \pi_0 = \nu_0 \},\end{aligned}$$

其中 $\nu_0, \nu_1 \in \mathcal{P}(\mathbb{R}^d)$ 。我们还考虑以下假设。 **B1.** μ 关于 $\mu_0 \otimes \mu_1$ 绝对连续，且 $\text{KL}(\nu_0 \otimes \nu_1 | \mu) < +\infty$ 。此外， ν_i 与 μ_i 等价，对于 $i \in \{0, 1\}$ 。

首先我们建立 **A1** 与 **B1** 之间的联系。

命题 30. **A1** 蕴含 **B1**，其中 $\mu = p_{0,N}$ 。

证明。由于 $p_N > 0$ ，我们得到 p_N 与 p_{prior} 等价。因此 μ_1 与 ν_1 等价，且 $\mu_0 = \nu_0$ 。让我们证明 μ 关于 $\mu_0 \otimes \mu_1$ ，*i.e.* 绝对连续， $p_{0,N}$ 关于 $p_{\text{data}} \otimes p_N$ 绝对连续。由于 $p_N > 0$ ，我们得到 $p_{0,N}$ 关于 $p_{\text{data}} \otimes p_N$ 绝对连续，密度为 $p_{N|0}/p_N$ 。最后我们有

$$\begin{aligned}& \int_{(\mathbb{R}^d)^2} \log(p_{\text{data}}(x_0)p_{\text{prior}}(x_N)/(p_{\text{data}}(x_0)p_{N|0}(x_N|x_0)))p_{\text{data}}(x_0)p_{\text{prior}}(x_N)dx_0dx_N \\ &= \int_{(\mathbb{R}^d)^2} \log(p_{\text{prior}}(x_N)/p_{N|0}(x_N|x_0))p_{\text{data}}(x_0)p_{\text{prior}}(x_N)dx_0dx_N \\ &\leq |H(p_{\text{prior}})| + \int_{\mathbb{R}^d} |\log p_{N|0}(x_N|x_0)|p_{\text{data}}(x_0)p_{\text{prior}}(x_N)dx_0dx_N < +\infty\end{aligned}$$

这完成了证明。 $\square$

在本节中，我们证明以下命题。

命题 31. 假设 **B1** 成立。则 IPF 序列是良定义的，且对于任意 $n \in \mathbb{N}$ ，其中 $n \geq 1$ ，我们有

$$\text{KL}(\pi^{n+1} | \pi^n) \leq \text{KL}(\pi^{n-1} | \pi^n), \quad \text{KL}(\pi^n | \pi^{n+1}) \leq \text{KL}(\pi^n | \pi^{n-1}). \quad (73)$$

此外，以下结果成立： (a) $(\|\pi^{n+1} - \pi^n\|_{\text{TV}})_{n \in \mathbb{N}}$ 和 $(J(\pi^{n+1}, \pi^n))_{n \in \mathbb{N}}$ 是非递增的。

(b) $(\text{KL}(\pi^{2n+1} | \pi^{2n}))_{n \in \mathbb{N}}$ and $(\text{KL}(\pi^{2n+2} | \pi^{2n+1}))_{n \in \mathbb{N}}$ are non-increasing.

(c) $(\text{KL}(\pi_1^{2n+1}|\nu_1))_{n \in \mathbb{N}} \quad (\text{KL}(\pi_0^{2n}|\nu_0))_{n \in \mathbb{N}}$ 并且是非递增的。

(d) $(\|\pi_1^{2n+1} - \nu_1\|_{\text{TV}})_{n \in \mathbb{N}} \quad (\|\pi_0^{2n} - \nu_0\|_{\text{TV}})_{n \in \mathbb{N}}$ 并且是非递增的。

首先，我们证明在 **B1** 条件下，IPF 序列是良定义的，并且与一个势函数序列相关联。

命题 32. 假设 **B1** 成立。则 IPF 序列是良定义的，且存在 $(a_n)_{n \in \mathbb{N}}$ 和 $(b_n)_{n \in \mathbb{N}}$ ，使得对于任意 $n \in \mathbb{N}$, $a_n, b_n : \mathbb{R} \rightarrow (0, +\infty)$ 和任意 $x, y \in \mathbb{R}$

$$\begin{aligned} (\text{d}\pi^{2n+1}/\text{d}(\mu_0 \otimes \mu_1))(x, y) &= a_n(x)h(x, y)b_n(y) \\ (\text{d}\pi^{2n+2}/\text{d}(\mu_0 \otimes \mu_1))(x, y) &= a_{n+1}(x)h(x, y)b_n(y), \end{aligned} \quad (74)$$

并且

$$v_0(x) = a_{n+1}(x) \int_{\mathbb{R}^d} h(x, y)b_n(y)\text{d}\mu_1(y), \quad v_1(y) = b_n(y) \int_{\mathbb{R}^d} h(x, y)a_n(x)\text{d}\mu_0(x), \quad (75)$$

其中 $v_i = \text{d}\nu_i/\text{d}\mu_i \quad i \in \{0, 1\}$ 。证明。首先，我们证明迭代比例拟合序列是良定义的。注意到 π^1 是良定义的，因为 $\text{KL}(\nu_0 \otimes \nu_1|\mu) < +\infty$ 。假设 $\{\pi^\ell\}_{\ell=1}^n$ 是良定义的。利用 (Csiszár, 1975, 定理 2.2)，我们有 $\text{KL}(\nu_0 \otimes \nu_1|\mu) = \text{KL}(\nu_0 \otimes \nu_1|\pi^n) + \sum_{\ell=0}^{n-1} \text{KL}(\pi^{\ell+1}|\pi^\ell)$ 。

特别地， $\text{KL}(\nu_0 \otimes \nu_1|\pi^n) < +\infty$ 和 π^{n+1} 是良定义的。我们通过递归得出结论。利用 (Csiszár, 1975, 定理 3.1) 和 **B1**，存在 $(\tilde{b}_n)_{n \in \mathbb{N}}$ 使得对于任意 $n \in \mathbb{N}$, $\tilde{b}_n : \mathbb{R}^d \rightarrow (0, +\infty)$ 和任意 $x \in \mathbb{R}^d$ 使得 $\tilde{\pi}_1 = \nu_1$ 和 $\text{KL}(\tilde{\pi}|\pi^{2n}) < +\infty$ 。特别地，我们有 $(\nu_0 \otimes \nu_1)(A_n) = 0$ 。由于 ν_i 等价于 μ_i 对于任意 $i \in \{0, 1\}$ ，我们有 $(\mu_0 \otimes \mu_1)(A_n) = 0$ 。类似地，存在 $(\tilde{a}_n)_{n \in \mathbb{N}}$ 使得对于任意 x 和任意具有 $B_n \in \mathcal{B}(\mathbb{R}^d)$ 和 $[0, +\infty)$ $x, y \in A_n$, $(\text{d}\pi^{2n+2}/\text{d}\pi^{2n+1})(x, y) = b_n(y) \quad A \in \mathcal{B}(\mathbb{R}^d)$, $\tilde{\pi}(A_n) = 0$ $(\mu_0 \otimes \mu_1)(B_n) = 0$ 。因此，存在 $(a_n)_{n \in \mathbb{N}}$ 和 $(b_n)_{n \in \mathbb{N}}$ 具有和

$$n \in \mathbb{N}, \tilde{a}_n : \mathbb{R}^d \rightarrow [0, +\infty) \quad x, y \in B_n, (\text{d}\pi^{2n+2}/\text{d}\pi^{2n+1})(x, y) = a_{n+1}(x)$$

$a_n : \mathbb{R} \rightarrow (0, +\infty) \quad b_n : \mathbb{R} \rightarrow [0, +\infty)$ 使得对于任意 $n \in \mathbb{N}$ 及 $x, y \in \mathbb{R}$

$$\begin{aligned} (\text{d}\pi^{2n+1}/\text{d}(\mu_0 \otimes \mu_1))(x, y) &= a_n(x)h(x, y)b_n(y) \\ (\text{d}\pi^{2n+2}/\text{d}(\mu_0 \otimes \mu_1))(x, y) &= a_{n+1}(x)h(x, y)b_n(y), \end{aligned}$$

其中 $h = \text{d}\mu/\text{d}(\mu_0 \otimes \mu_1)$ 和 $a_0 = 1$ 。此外，令 $b_{-1} = 1$ ，我们对于任意 $x, y \in \mathbb{R}^d$ 有

$$(\text{d}\pi^0/\text{d}(\mu_0 \otimes \mu_1))(x, y) = a_0(x)h(x, y)b_{-1}(y).$$

利用 ν_i 关于 μ_i 绝对连续，对于 $i \in \{0, 1\}$ 具有密度 $v_i : \mathbb{R}^d \rightarrow (0, +\infty)$ ，我们得到对于任意 $x, y \in \mathbb{R}^d$ 和 $n \in \mathbb{N}$

$$v_0(x) = a_{n+1}(x) \int_{\mathbb{R}^d} h(x, y)b_n(y)\text{d}\mu_1(y), \quad v_1(y) = b_n(y) \int_{\mathbb{R}^d} h(x, y)a_n(x)\text{d}\mu_0(x).$$

Since $v_0, v_1 > 0$ 对于任意 $n \in \mathbb{N}$, $a_n, b_n > 0$. □

注意，方程组 (75) 对应于迭代求解薛定谔系统，参见 Léonard (2014b) 的综述。此外，(75) 与 Fortet 映射有关 (Léonard, 2019; Fortet, 1940)。

在本节剩余部分，我们详细证明命题 4。我们首先在引理 33 中推导迭代比例拟合的边缘分布与其联合分布之间关于 Kullback-Leibler 散度和全变差范数的恒等式。其次，我们在引理 34 中建立 $(\|\pi^{n+1} - \pi^n\|_{\text{TV}})_{n \in \mathbb{N}}$ 是非递增的。然后，我们在引理 35 中证明 (73)。最后，我们以命题 31 的证明结束。

引理 33. 假设 **B1** 成立。则对任意 $n \in \mathbb{N}$ ，有

$$\|\pi^{2n+1} - \pi^{2n}\|_{\text{TV}} = \|\pi_1^{2n} - \nu_1\|_{\text{TV}}, \quad \|\pi^{2n+2} - \pi^{2n+1}\|_{\text{TV}} = \|\pi_0^{2n+1} - \nu_0\|_{\text{TV}}. \quad (76)$$

此外，有

$$\text{KL}(\pi^{2n}|\pi^{2n+1}) = \text{KL}(\pi_1^{2n}|\nu_1), \quad \text{KL}(\pi^{2n+1}|\pi^{2n+2}) = \text{KL}(\pi_0^{2n+1}|\nu_0). \quad (77)$$

证明。我们将证明分为两部分。首先证明 (76)。其次证明 (77) 成立。

(a) We only show that for any $n \in \mathbb{N}$ we have $\|\pi^{2n+1} - \pi^{2n}\|_{TV} = \|\pi_1^{2n} - \nu_1\|_{TV}$. The proof that for any $n \in \mathbb{N}$, $\|\pi^{2n+2} - \pi^{2n+1}\|_{TV} = \|\pi_0^{2n+1} - \nu_0\|_{TV}$ is similar. Let $n \in \mathbb{N}$. Using (74) and (75) we have

$$\begin{aligned}\|\pi^{2n+1} - \pi^{2n}\|_{TV} &= \int_{(\mathbb{R}^d)^2} |b_n(y) - b_{n-1}(y)| a_n(x) h(x, y) d\mu_0(x) d\mu_1(y) \\ &= \int_{\mathbb{R}^d} |1 - b_{n-1}(x)/b_n(x)| d\nu_1(y).\end{aligned}\quad (78)$$

此外, 对任意 $A \in \mathcal{B}(\mathbb{R}^d)$, 有

$$\pi_1^{2n}(A) = \int_{\mathbb{R}^d \times A} a_n(x) b_{n-1}(y) h(x, y) d\mu_0(x) d\mu_1(y) = \int_A (b_{n-1}/b_n)(y) d\nu_1(y).$$

得到对任意 $y \in \mathbb{R}^d$, $(d\pi_1^{2n}/d\nu_1)(y) = (b_{n-1}/b_n)(y)$. 因此, 利用 (78) 可得

$$\|\pi_1^{2n} - \nu_1\|_{TV} = \int_{\mathbb{R}^d} |1 - a_n(x)/a_{n+1}(x)| d\nu_0(x) = \|\pi^{2n+1} - \pi^{2n}\|_{TV}.$$

(b) We only show that for any $n \in \mathbb{N}$ we have $\text{KL}(\pi^{2n}|\pi^{2n+1}) = \text{KL}(\pi_1^{2n}|\nu_1)$. The proof that for any $n \in \mathbb{N}$, $\text{KL}(\pi^{2n+1}|\pi^{2n+2}) = \text{KL}(\pi_0^{2n+1}|\nu_0)$ is similar. Let $n \in \mathbb{N}$. Using that for any $x, y \in \mathbb{R}^d$, $(d\pi_1^{2n}/d\nu_1)(y) = b_{n-1}(y)/b_n(y)$ and that $(d\pi^{2n+1}/d\pi^{2n})(x, y) = b_n(y)/b_{n-1}(y)$ we have

$$\text{KL}(\pi^{2n}|\pi^{2n+1}) = -\int_{\mathbb{R}^d} \log(b_n(y)/b_{n-1}(y)) d\pi_1^{2n}(y) = \text{KL}(\pi_1^{2n}|\nu_1).$$

证毕。 □

引理 34. 假设 B1 成立。则 $(\|\pi^{n+1} - \pi^n\|_{TV})_{n \in \mathbb{N}}$ 是非递增的。

证明。我们仅证明对于任意 $n \in \mathbb{N}$ with $n \geq 1$, $\|\pi^{2n+1} - \pi^{2n}\|_{TV} \leq \|\pi^{2n} - \pi^{2n-1}\|_{TV}$. The proof that for any $n \in \mathbb{N}$, $\|\pi^{2n+2} - \pi^{2n+1}\|_{TV} \leq \|\pi^{2n+1} - \pi^{2n}\|_{TV}$ is similar. Let $n \in \mathbb{N}$ with $n \geq 1$. 与引理 33 的证明类似, 我们有

$$\|\pi^{2n+1} - \pi^{2n}\|_{TV} = \int_{\mathbb{R}^d} |1 - b_{n-1}(y)/b_n(y)| d\nu_1(y) = \int_{\mathbb{R}^d} |b_n^{-1}(y) - b_{n-1}^{-1}(y)| b_{n-1}(y) d\nu_1(y). \quad (79)$$

此外, 对任意 $y \in \mathbb{R}^d$, 有

$$|b_n^{-1}(y) - b_{n-1}^{-1}(y)| \leq v_1^{-1}(y) \int_{\mathbb{R}^d} h(x, y) |a_{n-1}(x) - a_n(x)| d\mu_0(x).$$

结合该结果与式 (79), 我们得到

$$\begin{aligned}\|\pi^{2n+1} - \pi^{2n}\|_{TV} &\leq \int_{\mathbb{R}^d} |b_n^{-1}(y) - b_{n-1}^{-1}(y)| b_{n-1}(y) d\nu_1(y) \\ &\leq \int_{(\mathbb{R}^d)^2} |a_n(x) - a_{n-1}(x)| h(x, y) b_{n-1}(y) d\mu_0(x) d\mu_1(y) \\ &\leq \int_{\mathbb{R}^d} |1 - a_{n-1}(x)/a_n(x)| d\nu_0(x) \leq \|\pi^{2n} - \pi^{2n-1}\|_{TV},\end{aligned}$$

这完成了证明。 □

引理 35. 假设 B1 成立。则对于任意 $n \in \mathbb{N}$ 且 $n \geq 1$, 我们有

$$\text{KL}(\pi^{n+1}|\pi^n) \leq \text{KL}(\pi^{n-1}|\pi^n), \quad \text{KL}(\pi^n|\pi^{n+1}) \leq \text{KL}(\pi^n|\pi^{n-1}).$$

证明。利用引理 33 和数据处理定理 (Ambrosio 等人, 2008, 引理 9.4.5), 我们得到对于任意 $n \in \mathbb{N}$

$$\text{KL}(\pi^{2n}|\pi^{2n+1}) = \text{KL}(\pi_1^{2n}|\nu_1) \leq \text{KL}(\pi^{2n}|\pi^{2n+1}).$$

类似地, 我们得到对于任意 $n \in \mathbb{N}$, $\text{KL}(\pi^{2n+1}|\pi^{2n+2}) \leq \text{KL}(\pi^{2n+1}|\pi^{2n})$ 。因此, 我们得到对于

any $n \in \mathbb{N}$, $\text{KL}(\pi^n|\pi^{n+1}) \leq \text{KL}(\pi^n|\pi^{n-1})$.

此外, 利用对于任意 $n \in \mathbb{N}$, 其中 $n \geq 1$ 且 $x, y \in \mathbb{R}^d$, 我们有 $\pi_1^{2n+1} = \nu_1$ 以及 $(d\pi^{2n+1}/d\pi^{2n})(x, y) = b_n(y)/b_{n-1}(y)$, 我们得到对于任意 $n \in \mathbb{N}$, 其中 $n \geq 1$

$$\text{KL}(\pi^{2n+1}|\pi^{2n}) = -\int_{\mathbb{R}^d} \log(b_{n-1}(y)/b_n(y)) d\nu_1(y). \quad (80)$$

利用詹森不等式, 对于任意 $n \in \mathbb{N}$, 我们有

$$-\log(b_{n-1}(y)/b_n(y)) \leq -\log\left(\int_{\mathbb{R}^d} h(x, y) a_n(x) d\mu_0(x) / \int_{\mathbb{R}^d} h(x, y) a_{n-1}(x) d\mu_0(x)\right)$$

$$\begin{aligned} &\leq -\log \left(\int_{\mathbb{R}^d} (a_n(x)/a_{n-1}(x)) h(x, y) a_{n-1}(x) d\mu_0(y) / \int_{\mathbb{R}^d} h(x, y) a_{n-1}(x) d\mu_0(x) \right) \\ &\leq -\int_{\mathbb{R}^d} \log(a_n(x)/a_{n-1}(x)) b_{n-1}(y) h(x, y) a_{n-1}(x) / v_1(y) d\mu_0(x). \end{aligned}$$

结合该结果、(80)、富比尼定理以及对于任意 $n \in \mathbb{N}$ ，其中 $n \geq 1$ 且 $x \in \mathbb{R}^d$ ， $(d\pi_0^{2n-1}/d\nu_0)(x) = a_{n-1}(x)/a_n(x)$ ，我们得到对于任意 $n \in \mathbb{N}$ ，其中 $n \geq 1$ ， $\text{KL}(\pi^{2n+1}|\pi^{2n}) \leq \int_{(\mathbb{R}^d)^2} \log(a_{n-1}(x)/a_n(x)) a_{n-1}(x) h(x, y) b_{n-1}(y) d\mu_1(y) d\mu_0(x)$
 $\leq \int_{(\mathbb{R}^d)^2} \log(a_{n-1}(x)/a_n(x)) (a_{n-1}(x)/a_n(x)) d\nu_0(x) \leq \text{KL}(\pi_0^{2n-1}|\nu_0)$ 。利用引理 33（或数据处理定理），我们得到对于任意 $n \in \mathbb{N}$ ，其中 $n \geq 1$ ， $\text{KL}(\pi^{2n+1}|\pi^{2n}) \leq \text{KL}(\pi^{2n-1}|\pi^{2n})$ 。类似地，我们得到对于任意 $n \in \mathbb{N}$ ， $\text{KL}(\pi^{2n+2}|\pi^{2n+1}) \leq \text{KL}(\pi^{2n}|\pi^{2n+1})$ ，从而完成证明。

□

我们现在转向命题 31 的证明

证明。首先，(73) 是引理 35 的直接推论。利用引理 34，我们得到 $(\|\pi^{n+1} - \pi^n\|_{\text{TV}})_{n \in \mathbb{N}}$ 是非递增的。由于对于任意 $\eta_0, \eta_1 \in \mathcal{P}(\mathbb{R}^d)$ ，我们有 $J(\eta_0, \eta_1) = (1/2)\{\text{KL}(\eta_0|\eta_1) + \text{KL}(\eta_1|\eta_0)\}$ ，并且利用 (73)，我们得到 $(J(\pi_{n+1}, \pi_n))_{n \in \mathbb{N}}$ 是非递增的，这证明了命题 31-(a)。命题 31-(b) 是 (73) 的直接推论。命题 31-(c) 是引理 33 和命题 31-(a) 的推论。最后，命题 31-(c) 是引理 33 和 (73) 的推论。

□

Note that we also have that for any $n \in \mathbb{N}$ ， $(\text{KL}(\pi^{2n}|\pi^{2n+1}))_{n \in \mathbb{N}}$ and $(\text{KL}(\pi^{2n+1}|\pi^{2n+2}))_{n \in \mathbb{N}}$ are non-increasing.

F.1.2 定量收敛界

在本节中，我们证明以下定理。

定理 36. 假设条件 **B1** 成立。则迭代比例拟合 (IPF) 序列 $(\pi^n)_{n \in \mathbb{N}}$ 是良定义的，且存在一个概率测度 ν ，使得 $\lim_{n \rightarrow +\infty} \|\pi^n - \nu\|_{\text{TV}} = 0$ 以及以下结论成立：

$$(a) \lim_{n \rightarrow +\infty} n^{1/2} \{\|\pi_0^n - \nu_0\|_{\text{TV}} + \|\pi_1^n - \nu_1\|_{\text{TV}}\} = 0.$$

$$(b) \lim_{n \rightarrow +\infty} n \{\text{KL}(\pi_0^n|\nu_0) + \text{KL}(\pi_1^n|\nu_1)\} = 0.$$

我们从引理 37 开始，它是 (Ruschendorf 等人, 1995, 命题 2.1) 的改编。然后我们陈述并证明引理 38，这是一个来自实分析的经典引理。结合这两个引理以及命题 31 的单调性结果，完成证明。

引理 37. 假设条件 **B1** 成立。则 $(\pi^n)_{n \in \mathbb{N}}$ 是良定义的，并且我们有 $\sum_{n \in \mathbb{N}} \text{KL}(\pi^{n+1}|\pi^n) < +\infty$ 。

证明。利用命题 32，该序列是良定义的。此外，利用 (Csiszár, 1975, 定理 2.2)，对于任意 $n \in \mathbb{N}$ ，我们有

$$\text{KL}(\mu^*|\pi^0) = \text{KL}(\pi^*|\pi^n) + \sum_{k=0}^{n-1} \text{KL}(\pi^{k+1}|\pi^k),$$

这完成了证明。

□

引理 38. 设 $(c_n)_{n \in \mathbb{N}} \in [0, +\infty)^{\mathbb{N}}$ 是一个非增序列，使得 $\sum_{n \in \mathbb{N}} c_n < +\infty$ 。则 $\lim_{n \rightarrow +\infty} c_n n = 0$ 。

证明。设 $\varepsilon > 0$ 和 $n_0 \in \mathbb{N}$ 使得对于任意 $n \geq n_0$ ， $\sum_{k=n}^{+\infty} c_k \leq \varepsilon$ 。设 $n \in \mathbb{N}$ ，其中 $n \geq 2n_0$ 。注意 $n - n_0 \geq n/2 \geq n_0$ 。因此我们有 $\varepsilon \geq (n - n_0)c_n \geq (n/2)c_n$ 。于是，对于任意满足 $n \geq 2n_0$ ， $c_n n \leq 2\varepsilon$ 的 $n \in \mathbb{N}$ ，结论成立。

□

我们现在以定理 36 的证明作结。

证明。利用引理 37 和 Pinsker 不等式 (Bakry 等人, 2014, 方程 5.2.2), 我们有 $\sum_{n \in \mathbb{N}} \|\pi^{n+1} - \pi^n\|_{TV} < +\infty$ 。对于任意 $N \in \mathbb{N}$, 设 $S_N = \sum_{n=0}^N \pi^{n+1} - \pi^n = \pi^{N+1} - \mu$ 。由于赋予 $\|\cdot\|_{TV}$ 的有限符号测度空间是一个 Banach 空间 (Douc 等人, 2019, 定理 D.2.7), 因此 $(S_N)_{N \in \mathbb{N}}$ 收敛。于是存在一个有限符号测度 π^∞ , 使得 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\|_{TV} = 0$ 。 π^∞ 是一个概率测度, 因为对于任意概率测度 $n \in \mathbb{N}$, π^n is a。

In addition, since $(KL(\pi^{2n+1}|\pi^{2n}))_{n \in \mathbb{N}}$ and $(KL(\pi^{2n+2}|\pi^{2n+1}))_{n \in \mathbb{N}}$ are non-increasing by Proposition 31, using Lemma 38, we get that

$$\lim_{n \rightarrow +\infty} n \{KL(\pi_0^n|\nu_0) + KL(\pi_1^n|\nu_1)\} = 0.$$

我们利用平斯克不等式 (Pinsker's Inequality) 得出结论 (Bakry 等人, 2014, 方程 5.2.2)。□

F.2 命题 5 的证明

与附录 F.1 类似, 我们考虑静态 IPF 递归: $\pi^0 = \mu \in \mathcal{P}_2$ 以及

$$\begin{aligned}\pi^{2n+1} &= \arg \min \{KL(\pi|\pi^{2n}) : \pi \in \mathcal{P}_2, \pi_1 = \nu_1\}, \\ \pi^{2n+2} &= \arg \min \{KL(\pi|\pi^{2n+1}) : \pi \in \mathcal{P}_2, \pi_0 = \nu_0\},\end{aligned}$$

其中 $\nu_0, \nu_1 \in \mathcal{P}(\mathbb{R}^d)$ 。我们回顾在此背景下, 如果薛定谔桥 π^* 存在, 则其由下式给出

$$\pi^* = \arg \min \{KL(\pi|\mu) : \pi \in \mathcal{P}_2, \pi_0 = \nu_0, \pi_1 = \nu_1\}.$$

在本节中, 我们证明以下命题, 该命题直接蕴含命题 5。

命题 39。 假设 B1 成立, 并记 $h = d\mu/(d\mu_0 \otimes \mu_1)$ 。假设 $h \in C(\mathbb{R}^d \times \mathbb{R}^d, (0, +\infty])$ 且存在 $\Phi_0, \Phi_1 \in C(\mathbb{R}^d, (0, +\infty))$ 使得对任意 $x, y \in \mathbb{R}^d$ 以及

$$\begin{aligned}h(x, y) &\leq \Phi_0(x)\Phi_1(y), \\ \int_{\mathbb{R}^d \times \mathbb{R}^d} (|\log h(x_0, x_1)| + |\log \Phi_0(x_0)| + |\log \Phi_1(x_1)|) d\mu_0(x_0) d\mu_1(x_1) &< +\infty.\end{aligned}\quad (81)$$

则存在薛定谔桥的解 π^* , 且 IPF 序列满足 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\|_{TV} = 0$ 其中 $\pi^\infty \in \mathcal{P}_2$ 。若 μ 关于 π^∞ 绝对连续, 则 $\pi^\infty = \pi^*$ 。

我们从 (Rüschemdorf 和 Thomsen, 1993, 命题 2) 的一个改编开始。

命题 40。 设 $\mu \in \mathcal{P}_2$, 并假设 μ 关于 $\mu_0 \otimes \mu_1$ 绝对连续。设 $(a_n)_{n \in \mathbb{N}}$ 和 $(b_n)_{n \in \mathbb{N}}$ 使得对任意 $n \in \mathbb{N}$, $a_n : \mathbb{R}^d \rightarrow (0, +\infty)$ 和 $b_n : \mathbb{R}^d \rightarrow (0, +\infty)$ 成立。假设存在 $\Phi : (\mathbb{R}^d)^2 \rightarrow [0, +\infty)$ 和 $A \in \mathcal{B}(\mathbb{R}^d) \otimes \mathcal{B}(\mathbb{R}^d)$ 且 $\mu(A) = 1$ 使得对任意 $(x, y) \in A$ 有 $\lim_{n \rightarrow +\infty} a_n(x)b_n(y) = \Phi(x, y)$ 。那么, 存在及使得对任意 $x, y \in \mathbb{B}$

$$a : \mathbb{R}^d \rightarrow [0, +\infty), b : \mathbb{R}^d \rightarrow [0, +\infty) \quad B \in \mathcal{B}(\mathbb{R}^d) \otimes \mathcal{B}(\mathbb{R}^d) \quad \mu(B) = 1$$

$$\Phi(x, y) = a(x)b(y), \quad \text{or} \quad \Phi(x, y) = 0.$$

证明。设 $\tilde{A} = \{(x, y) \in (\mathbb{R}^d)^2 : \Phi(x, y) = 0\}$ 且 $A_a = \tilde{A} \cap A$ 且 $A_b = \tilde{A}^c \cap A$ 。若 $A_b = \emptyset$, 则证明结束。否则, 设 $(x_0, y_0) \in A_b$ 。设 $C_0, C_1 \in \mathcal{B}(\mathbb{R}^d) \otimes \mathcal{B}(\mathbb{R}^d)$ 由下式给出

$$\begin{aligned}C_0^0 &= \{x \in \mathbb{R}^d : \lim_{n \rightarrow +\infty} a_n^0(x) = a^0(x) \text{ exists and } a^0(x) > 0\}, \\ C_1^0 &= \{y \in \mathbb{R}^d : \lim_n b_n^0(y) = b^0(y) \text{ exists and } b^0(y) > 0\},\end{aligned}\quad (82)$$

其中对任意 $n \in \mathbb{N}$ 和 $x, y \in \mathbb{R}^d$, $a_n^0(x) = a_n(x)/a_n(x_0)$ 和 $b_n^0(y) = b_n(y)/b_n(y_0)$, 这是良定义的, 因为对任意 $n \in \mathbb{N}$, $a_n(x_0) > 0$ 成立。注意

$$\begin{aligned}C_0^1 &= \{x \in \mathbb{R}^d : \lim_n a_n^1(x) = a^1(x) \text{ exists and } a^1(x) > 0\}, \\ x_0 &\in C_0^0 \text{ 且 } y_0 \in C_1^0 \text{。若 } A_b \subset C_0^0 \times C_1^0, \text{ 则证明结束。否则, 设 } \\ (x_1, y_1) &\in A_b \cap (C_0^0 \times C_1^0)^c \text{ 并定义 } \lim\end{aligned}$$

$$C_1^1 = \{y \in \mathbb{R}^d : \lim_n b_n^1(y) = b^1(y) \text{ exists and } b^1(y) > 0\},$$

where for any $n \in \mathbb{N}$ and $x, y \in \mathbb{R}^d$, $a_n^1(x) = a_n(x)/a_n(x_1)$ and $b_n^1(y) = b_n(y)a_n(x_1)$, which is well-defined since for any $n \in \mathbb{N}$, $a_n(x_1) > 0$. Note that $C_0^0 \cap C_0^1 = \emptyset$ and $C_0^0 \cap C_1^1 = \emptyset$. Indeed, if there exists $x \in C_0^0 \cap C_0^1$, then $a^0(x) = \lim_{n \rightarrow +\infty} a_n(x)/a_n(x_0) > 0$ and $a^1(x) = \lim_{n \rightarrow +\infty} a_n(x)/a_n(x_1) > 0$ exists. Therefore $\lim_{n \rightarrow +\infty} a_n(x_1)/a_n(x_0) > 0$ exists and $\lim_{n \rightarrow +\infty} b_n(y_1)a_n(x_0) > 0$ exists. Hence $(x_1, y_1) \in C_0^0 \times C_1^1$ which is absurd. Similarly, if there exists $y \in C_0^0 \cap C_1^1$ then $(x_1, y_1) \in C_0^0 \times C_0^1$ which is absurd. Hence, we consider $T : A_b \rightarrow 2^{(\mathbb{R}^d)^2}$ such that for any $(x, y) \in A_b$, $T(x, y) = C_0^{(x,y)} \times C_1^{(x,y)}$, where $C_0^{(x,y)} \times C_1^{(x,y)}$ is constructed as in (82) replacing (x_0, y_0) by (x, y) .

考虑 $(A_b, \leq)$ 上的一个良序, 这由良序原理 (Enderton, 1977, p. 196). For any $(x, y) \in \mathbb{R}^d$, let $A_b^{(x,y)} = \{(x', y') \in (\mathbb{R}^d)^2 : (x', y') < (x, y)\}$. Using the transfinite recursion theorem (Enderton, 1977, p. 175) there exists $f : A_b \rightarrow \{0, 1\}$ such that for any $(x, y) \in A_b$ if there exists $(x', y') \in (\mathbb{R}^d)^2$ such that $(x', y') < (x, y)$, $f(x', y') = 1$ and $(x, y) \in T(x', y')$ then $f(x, y) = 0$ and $f(x, y) = 1$ otherwise. Let $I = f^{-1}(\{1\})$. Let $(x, y), (x', y') \in I$ with $(x, y) \neq (x', y')$ then for $(x, y) < (x', y')$ for instance. Since $f(x, y) = f(x', y') = 1$ we have that $(C_0^{(x,y)} \times C_1^{(x,y)}) \cap (C_0^{(x',y')} \times C_1^{(x',y')}) = \emptyset$. Let $(x, y) \in A_b$. If $f(x, y) = 1$ then $(x, y) \in C_0^{(x,y)} \times C_1^{(x,y)}$. If $f(x, y) = 0$ then there exists $(x', y') < (x, y)$ such that $(x, y) \in C_0^{(x',y')} \times C_1^{(x',y')}$. Therefore, we get that $\{C^{(x,y)} = (C_0^{(x,y)} \times C_1^{(x,y)}) \cap A_b : (x, y) \in I\}$ is a partition of A_b .

Since $\mu(A_b) \leq 1$, and $\{C^{(x,y)} = (C_0^{(x,y)} \times C_1^{(x,y)}) \cap A_b : (x, y) \in I\}$ is a partition of A_b , we get that $J = \{C^{(x,y)} : (x, y) \in I, \mu_0(C_0^{(x,y)})\mu_1(C_1^{(x,y)}) > 0\}$ is countable. Denote $A_c = \cup_{(x,y) \in J} C^{(x,y)}$. Let us show that $\mu(A_c \cap A_b) = \mu(\cup_{(x,y) \in I \cap J^c} C^{(x,y)}) = 0$. Let $x \in \mathbb{R}^d$ and define $D_x = \{y \in \mathbb{R}^d : (x, y) \in A_b \cap A_c^c\}$. If D_x is not empty, then there exists $(x', y') \in I$ such that $x \in C_0^{(x',y')}$. Then, for any $y \in D_x$, $y \in C_1^{(x',y')}$. Hence, $(x', y') \in I \cap J^c$ by definition of D_x and $\mu_1(D_x) = 0$. We get that

$$\mu(A_b \cap A_c^c) = \int_{\mathbb{R}^d} \left(\int_{D_x} h(x, y) d\mu_1(y) \right) d\mu_0(x) = 0,$$

其中 h 是 μ w.r.t. $\mu_0 \otimes \mu_1$ 的密度。注意, 这是证明中唯一用到 μ 关于 $\mu_0 \otimes \mu_1$ 绝对连续这一条件的地方。对于任意 $(x, y) \in A_c$, 对任意 $n \in \mathbb{N}$ 定义

$$\hat{a}_n(x) = \sum_{(x', y') \in J} \mathbb{1}_{C_0^{(x', y')}}(x) a_n^{(x', y')}(x), \quad \hat{b}_n(y) = \sum_{(x', y') \in J} \mathbb{1}_{C_1^{(x', y')}}(x) b_n^{(x', y')}(y).$$

存在这样的 $\hat{a}, \hat{b} : \mathbb{R}^d \rightarrow [0, +\infty)$ 使得对于任意 $(x, y) \in A_c$, $\lim_{n \rightarrow +\infty} \hat{a}_n(x) \hat{b}_n(y) = \hat{a}(x) \hat{b}(y)$ 。因此, 对于任意 $(x, y) \in A_c$, $\Phi(x, y) = \hat{a}(x) \hat{b}(y)$ 。由于 $A_a \cap A_c = \emptyset$ 和 $\mu(A_c) = \mu(A_b)$, 我们有

$$\mu(A_a) + \mu(A_c) = \mu(A_a) + \mu(A_b) = \mu(A) = 1.$$

我们通过指出对于任意 $(x, y) \in A_a$, $\Phi(x, y) = 0$, 以及对于任意 $(x, y) \in A_c$, 来完成证明。
 $\Phi(x) = \hat{a}(x) \hat{b}(y)$. □

接下来我们证明命题 39。

证明。由于 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\| = 0$ 根据定理 36 和 $KL(\pi^\infty | \mu) < +\infty$, 存在 A , 其中 $\mu(A) = 1$ 和 $\Phi : (\mathbb{R}^d)^2 \rightarrow [0, +\infty)$, 使得在必要时取子列后, 对于任意 $x, y \in A$

$$\lim_{n \rightarrow +\infty} a_n(x) b_n(y) = \Phi(x, y),$$

且 $(d\pi^\infty/d\mu) = \Phi$ 。利用命题 40, 存在 $a, b : \mathbb{R}^d \rightarrow [0, +\infty)$ 和 B , 满足 $\pi^\infty(B) = 1$, 使得对任意 $x, y \in B$, $(d\pi^\infty/d\mu)(x, y) = a(x)b(y)$ 。由于 μ 关于 π^∞ 绝对连续, 可得对任意 $x, y \in \mathbb{R}^d$, $(d\pi^\infty/d(\mu_0 \otimes \mu_1))(x, y) = a(x)b(y)h(x, y)$ 。此外, 薛定谔桥 $\pi^* \in \mathcal{P}((\mathbb{R}^d)^2)$ 存在, 参见 Schrödinger bridge 和 Thomsen, 1993, 定理 3.3 (cf. Rüschendorf and Thomsen, 1993, T there exist $a', b' : \mathbb{R} \rightarrow [0, +\infty)$ and B' with $\mu(B') = 1$ such that for any $x, y \in B'$

$$(d\pi^*/d(\mu_0 \otimes \mu_1))(x, y) = a'(x)b'(y)h(x, y).$$

Let $\mathcal{M}_{+, \times}$ be the space of non-negative product measures over $\mathcal{B}(\mathbb{R}^d) \otimes \mathcal{B}(\mathbb{R}^d)$. Let $\Psi_{\bar{h}} : \mathcal{M}_{+, \times} \rightarrow \mathcal{M}_{+, \times}$ be given for any $\lambda = \lambda_0 \otimes \lambda_1 \in \mathcal{M}_{+, \times}$ by $\Psi_{\bar{h}}(\lambda) = \Psi_{\bar{h}}^\lambda$ where for any $A, B \in \mathcal{B}(\mathbb{R}^d)$

$$\Psi_{\bar{h}}^\lambda(A \times B) = \left(\int_{A \times \mathbb{R}^d} \bar{h}(x, y) d\lambda_0(x) d\lambda_1(y) \right) \left(\int_{\mathbb{R}^d \times B} \bar{h}(x, y) d\lambda_0(x) d\lambda_1(y) \right)$$

where for any $x, y \in \mathbb{R}^d$, $\bar{h}(x, y) = h(x, y) \Phi_0^{-1}(x) \Phi_1^{-1}(y)$. Note that $\bar{h} \in C(\mathbb{R}^d \times \mathbb{R}^d, [0, +\infty))$ and is bounded. Hence, using (Beurling, 1960, Theorem 2) and (81) we get that $\Psi_{\bar{h}}$ is a bijection. Let $\lambda = (a\Phi_0\mu_0, b\Phi_1\mu_1)$ and $\lambda' = (a'\Phi_0\mu_0, b'\Phi_1\mu_1)$. Then, since $\pi_i^* = \pi_i^\infty = \nu_i$ for $i \in \{0, 1\}$ we get that $\Psi_{\bar{h}}(\lambda) = \Psi_{\bar{h}}(\lambda')$. Hence $\lambda = \lambda'$ and $\pi^\infty = \pi^*$ which concludes the proof. $\square$

在命题 42 中，我们推导出命题 39 的一个替代命题。我们从以下引理开始。

引理 41. 设 $\pi^* \in \mathcal{P}_2$ ，其中 $\pi_i^* = \nu_i$ 对 $i \in \{0, 1\}$ 成立。假设 $\text{KL}(\pi^*|\mu) < +\infty$ 且 $L^1(\nu_0) \oplus L^1(\nu_1)$ 在 $L^1(\pi^*)$ 中是闭集。此外，假设存在 $a, b : \mathbb{R}^d \rightarrow [0, +\infty)$ 和 A ，满足 $\pi^*(A) = 1$ ，使得对任意 $(x, y) \in A$ ，

$$(d\pi^*/d\mu)(x, y) = a(x)b(y).$$

则 π^* 是薛定谔桥。

证明。由于 $\text{KL}(\pi^*|\mu) < +\infty$ ，我们有

$$\int_{(\mathbb{R}^d)^2} |\log(a(x)b(y))| d\pi^*(x, y) < +\infty.$$

Using (Kober, 1939, Theorem 1) and that $\pi_i^* = \nu_i$ for $i \in \{0, 1\}$, we get that

$$\int_{\mathbb{R}^d} |\log a(x)| d\nu_0(x) + \int_{\mathbb{R}^d} |\log b(y)| d\nu_1(y) < +\infty. \quad (83)$$

设 $\pi \in \mathcal{P}_2$ 使得对 $i \in \{1, 2\}$ 有 $\pi_i = \nu_i$ 且 $\int_{(\mathbb{R}^d)^2} |\log((d\pi/d\mu)(x, y))| d\pi(x, y) < +\infty$ $\text{KL}(\pi|\mu) < +\infty$ 。利用 (83)，我们有。因此， $(d\pi^*/d\mu) > 0$, π -几乎必然成立。利用这一结果，对任意 $A \in \mathcal{B}(\mathbb{R}^d)$ 有

$$\begin{aligned} \pi[A] &= \int_{\mathbb{R}^d} \mathbb{1}_A(x) (d\pi^*/d\mu)(x) (d\pi^*/d\mu)(x)^{-1} d\pi(x) \\ &= \int_{\mathbb{R}^d} \mathbb{1}_A(x) (d\pi^*/d\mu)(x) (d\pi^*/d\mu)(x)^{-1} (d\pi/d\mu)(x) d\mu(x) \\ &= \int_{\mathbb{R}^d} \mathbb{1}_A(x) (d\pi^*/d\mu)(x)^{-1} (d\pi/d\mu)(x) d\pi^*(x). \end{aligned}$$

因此我们得到 $d\pi/d\pi^* = (d\pi/d\mu)(d\pi^*/d\mu)^{-1}$ 。此外，我们有

$$\text{KL}(\pi^*|\mu) = \int_{\mathbb{R}^d} \log(a(x)) d\nu_0(x) + \int_{\mathbb{R}^d} \log(b(y)) d\nu_1(y) = \int_{(\mathbb{R}^d)^2} \log((d\pi^*/d\mu)(x, y)) d\pi(x, y).$$

我们得到

$$\text{KL}(\pi|\pi^*) = \int_{\mathbb{R}^d} \log((d\pi/d\mu)(d\pi^*/d\mu)(x, y)^{-1}) d\pi(x, y) = \text{KL}(\pi|\mu) - \text{KL}(\pi^*|\mu).$$

因此， $\text{KL}(\pi|\mu) \geq \text{KL}(\pi^*|\mu)$ 当且仅当 $\pi^* = \pi$ 时取等号。所以， π^* 是薛定谔桥。 $\square$

以下命题是命题 39 的另一种表述。

命题 42. 假设 B1 成立。则存在薛定谔桥的解 π^* ，且 IPF 序列 $(\pi^n)_{n \in \mathbb{N}}$ 满足 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\|_{\text{TV}} = 0$ 及 $\pi^\infty \in \mathcal{P}_2$ 。若 $\text{KL}(\pi^\infty|\mu) < +\infty$ 且 $L^1(\nu_0) \oplus L^1(\nu_1)$ 在 $L^1(\pi^\infty)$ 中为闭集，则 $\pi^\infty = \pi^*$ 。

证明。由于 $\lim_{n \rightarrow +\infty} \|\pi^n - \pi^\infty\| = 0$ 根据定理 36 和 $\text{KL}(\pi^\infty|\mu) < +\infty$

，存在 A ，其中 $\mu(A) = 1$ 和 $\Phi : (\mathbb{R}^d)^2 \rightarrow [0, +\infty)$ ，使得在必要时取子列后，对于任意 $x, y \in A$

$$\lim_{n \rightarrow +\infty} a_n(x)b_n(y) = \Phi(x, y),$$

且 $(d\pi^\infty/d\mu) = \Phi$ 。利用命题 40，存在 $a, b : \mathbb{R}^d \rightarrow [0, +\infty)$ 和 B 满足 $\pi^\infty(B) = 1$ ，使得对任意 $x, y \in B$, $(d\pi^\infty/d\mu)(x, y) = a(x)b(y)$ 成立。结合引理 41 即可得出结论。 $\square$

G 几何收敛速率与向真实解的收敛

本节在附录 G.1 中推导高斯情形下的几何收敛速率。特别地，我们给出了仅依赖于参考测度与目标协方差的收敛速率显式上界。在附录 G.2 中，我们证明 DSB（以布朗运动为参考测度）在可获得真实解的高斯情形下收敛到薛定谔桥。在第 4 节中，我们展示了我们的实现在该情形下确实恢复了薛定谔桥。

G.1 几何收敛速率

在以下命题中，我们证明在高斯情形下可获得几何收敛速率，并从该案例研究中获得直观理解。我们设 $N = 1$ 并假设对任意 $x_0, x_N \in \mathbb{R}^d$ 有

$$p(x_0, x_N) \propto \exp[-\|x_0\|^2 + 2\alpha\langle x_0, x_N \rangle - \|x_N\|^2],$$

与 $\alpha \in [0, 1]$ 。在这种情况下，假设存在 $\beta > 0$ ，使得对于任意 $x_0, x_N \in \mathbb{R}^d$ ，目标边缘分布由 $p_{\text{data}}(x_0) \propto \exp[-\beta\|x_0\|^2]$ ， $p_{\text{prior}}(x_N) \propto \exp[-\beta\|x_N\|^2]$ 给出。

命题 43. 设 $\alpha \in (0, 1)$ 和 $\beta > 0$ 。则薛定谔桥 π^* 存在，且存在 $C \geq 0$ （证明中显式给出），使得对于任意 $n \in \mathbb{N}$ ， $\text{KL}(\pi^* | \pi^n) \leq C\kappa^{2n}$ ，其中 $\kappa < 1$ 由 $\kappa = \rho/(1+\rho)$ 和 $\rho = 2\alpha/\beta^2$ 给出。此外， π^* 关于勒贝格测度具有密度，记为 p^* ，对于任意 $x, y \in \mathbb{R}^d$ 由

$$p^*(x, y) = \exp[-\gamma^*\|x\|^2 + 2\alpha\langle x, y \rangle - \gamma^*\|y\|^2] / \int_{\mathbb{R}^d} \exp[-\gamma^*\|x\|^2 + 2\alpha\langle x, y \rangle - \gamma^*\|y\|^2] dx dy,$$
 给出，其中 $\gamma^* = (\beta^2/2)(1 + (1 + 4\alpha^2/\beta^2)^{1/2})$ 。注意，若 $\beta^2 = 1 - \alpha^2$ ，则 $\gamma^* = 1$ 且 $p^* = p$ ，i.e.，IPF 保持 μ 不变。注意，当 κ 接近 0 时，即 $\rho = 2\alpha/\beta^2$ 接近 0 时，IPF 的性能会提升。这种情况发生在 $\alpha \approx 0$ （边缘分布几乎独立）或 $\beta \approx +\infty$ （目标分布接近 δ_0 ），见图 8）时。该行为与极限情形一致：当边缘分布独立或其中一个目标分布为狄拉克质量时，IPF 在两次迭代内收敛。




图 8: κ^2 随 α 和 β 的演化。

此外，注意收敛速度不依赖于维度，而仅依赖于问题的常数。在下文中，我们首先推导该高斯问题的 IPF 序列，并证明 α 控制边缘分布共享的信息量。然后证明命题 43。在本节剩余部分，设 $\mu \in \mathcal{P}_2$ 具有关于勒贝格测度的密度 p ，使得对于任意 $x_0, x_1 \in \mathbb{R}^d$

$$p(x_0, x_1) = \exp[-\|x_0\|^2 + 2\alpha\langle x_0, x_1 \rangle - \|x_1\|^2] / \int_{\mathbb{R}^d} \exp[-\|x_0\|^2 + 2\alpha\langle x_0, x_1 \rangle - \|x_1\|^2] dx_0 dx_1.$$

我们有 μ 是均值为零、协方差矩阵为 Σ 的高斯分布，满足

$$\Sigma = (2(1 - \alpha^2))^{-1} \begin{pmatrix} \text{Id} & \alpha \text{Id} \\ \alpha \text{Id} & \text{Id} \end{pmatrix}.$$

利用舒尔补 (Petersen 等人, 2008, 第 9.1.2 节), 我们有 $\det(\Sigma) = 2^{2d}(1 - \alpha^2)^{-d}$ 。因此, 对于任意 $x_0, x_1 \in \mathbb{R}^d$, 我们得到

$$p(x_0, x_1) = \pi^{-d}(1 - \alpha^2)^{d/2} \exp[-\|x_0\|^2 + 2\alpha\langle x_0, x_1 \rangle - \|x_1\|^2].$$

在下文中, 我们记 $C = \pi^{d/2}(1 - \alpha^2)^{-d/2}$ 。类似地, 我们得到 $\mu_0 = \mu_1$, 且它们关于勒贝格测度具有密度 p_0 , 对于任意 $x \in \mathbb{R}^d$ 由下式给出

$$p_0(x) = \pi^{-d/2}(1 - \alpha^2)^{d/2} \exp[-\|x\|^2(1 - \alpha^2)].$$

在下文中, 我们记 $C_0 = \pi^{d/2}(1 - \alpha^2)^{-d/2}$ 。在这种情况下, 注意 μ 关于勒贝格测度具有密度, $\mu_0 \otimes \mu_1$ 对于任意 $x_0, x_1 \in \mathbb{R}^d$ 由下式给出

$$h(x_0, x_1) = (d\mu/d(\mu_0 \otimes \mu_1))(x_0, x_1) = (1 - \alpha^2)^{-d/2} \exp[-\alpha^2\|x_0\|^2 - 2\alpha\langle x_0, x_1 \rangle - \alpha^2\|x_1\|^2].$$

注意 $p_{\text{prior}} = p_{\text{data}} = q$, 其中对任意 $x \in \mathbb{R}^d$, $q(x)$ 有 $\pi^{-d/2}\beta^{d/2} \exp[-\beta\|x\|^2]$ 。我们有 $\mu_0, \mu_1 \in \mathbb{R}^d$

$$p_{1|0}(x_1|x_0) = p(x_0, x_1)/p_0(x_0) = \pi^{-d/2}(1 - \alpha^2)^{d/2} \exp[-\alpha^2\|x_0\|^2 + 2\alpha\langle x_0, x_1 \rangle - \|x_1\|^2].$$

因此, 我们得到 **A1** 成立, 且 IPF 序列是良定义的, 并根据命题 5 收敛。接下来我们开始证明 α 控制了两个边缘分布 μ_0 和 μ_1 , i.e. 共享的信息量, 即互信息。更精确地, 我们有如下结果。

命题 44. *For any $\alpha \in (0, 1)$ we have $\text{KL}(\mu|\mu_0 \otimes \mu_1) = -(d/2) \log(1 - \alpha^2)$.*

证明。对任意 $x, y \in \mathbb{R}^d$, 我们有

$$(d\mu/(d\mu_0 \otimes d\mu_1))(x, y) = \exp[-\alpha^2\|x\|^2 + 2\alpha\langle x, y \rangle - \alpha^2\|y\|^2](1 - \alpha^2)^{-d/2}.$$

我们有

$$\int_{\mathbb{R}^d \times \mathbb{R}^d} (-\alpha^2\|x\|^2 - \alpha^2\|y\|^2 + 2\alpha\langle x, y \rangle) d\mu(x, y) = 0.$$

Hence, $\text{KL}(\mu|\mu_0 \otimes \mu_1) = -(d/2) \log(1 - \alpha^2)$, which concludes the proof. $\square$

接下来, 我们用 $(\pi^n)_{n \in \mathbb{N}}$ 表示 IPFP 序列, 对任意 $n \in \mathbb{N}$ 定义, 我们有对任意 $x, y \in \mathbb{R}^d$

$$(d\pi^{2n}/d\mu)(x, y) = a_n(x)b_n(y)h(x, y), \quad (d\pi^{2n+1}/d\mu)(x, y) = a_{n+1}(x)b_n(y)h(x, y),$$

其中对于任意 $x, y \in \mathbb{R}^d$

$$a_{n+1}(x) = (d\nu_0/d\mu_0)(x) \left(\int_{\mathbb{R}^d} h(x, y)b_n(y)d\mu_1(y) \right)^{-1},$$

$$b_{n+1}(x) = (d\nu_1/d\mu_1)(y) \left(\int_{\mathbb{R}^d} h(x, y)a_{n+1}(x)d\mu_0(x) \right)^{-1}.$$

现在我们转向命题 43 的证明。

证明。设 $\alpha \in (0, 1)$ 和 $\beta > 1$ 。对任意 $x, y \in \mathbb{R}^d$ 我们有

$$(d\nu_0/d\mu_0)(x) = \exp[(1 - \beta^2 - \alpha^2)\|x\|^2]/C_2, \quad (d\nu_1/d\mu_1)(y) = \exp[(1 - \beta^2 - \alpha^2)\|y\|^2]/C_2,$$

with $C_2 = C_1/C_0$ with $C_1 = \pi^{d/2}\beta^{d/2}$. For any $x \in \mathbb{R}^d$ and $\gamma \geq 0$ we have

$$\begin{aligned} (d\nu_0/d\mu_0)(x) & \left(\int_{\mathbb{R}^d} \exp[-\gamma\|y\|^2] h(x, y) d\mu_1(y) \right)^{-1} \\ &= (C_0 C_2)^{-1} C \exp[(1 - \beta^2 - \alpha^2)\|x\|^2] \left(\int_{\mathbb{R}^d} \exp[-\gamma\|y\|^2 - \|y - \alpha x\|^2] dy \right)^{-1} \\ &= (C_0 C_2)^{-1} C \exp[(1 - \beta^2 - \alpha^2)\|x\|^2] \end{aligned}$$

$$\begin{aligned}
& \times \left(\int_{\mathbb{R}^d} \exp[-(\gamma+1) \|y - \alpha/(\gamma+1)x\|^2 - \alpha^2(1-1/(\gamma+1)) \|x\|^2] dy \right)^{-1} \\
& = (C_0 C_2)^{-1} C \exp[(1-\beta^2 - \alpha^2 + \alpha^2 \gamma/(\gamma+1)) \|x\|^2] \\
& \quad \times \left(\int_{\mathbb{R}^d} \exp[-(\gamma+1) \|y - \alpha/(\gamma+1)x\|^2] dy \right)^{-1} \\
& = (C_0 C_2 \tilde{C}_\gamma)^{-1} C \exp[(1-\beta^2 - \alpha^2/(\gamma+1)) \|x\|^2],
\end{aligned}$$

with $\tilde{C}_\gamma = \pi^{d/2}(1+\gamma)^{-d/2}$. Note that $a_0 = b_0 = 1$. Let $n \in \mathbb{N}$ and assume that for any $y \in \mathbb{R}^d$ $b_n(y) = \exp[-\gamma_{2n} \|y\|^2]/C_{2n}$ with $\gamma_{2n} \geq 0$ and $C_{2n} > 0$ then we have for any $x \in \mathbb{R}^d$

$$a_{n+1}(x) = (C_0 C_2 \tilde{C}_{\gamma_{2n}})^{-1} C C_{2n} \exp[-(1-\beta^2 - \alpha^2/(\gamma_{2n}+1)) \|x\|^2] = \exp[-\gamma_{2n+1} \|x\|^2]/C_{2n+1},$$

with

$$\gamma_{2n+1} = \beta^2 - 1 + \alpha^2/(\gamma_{2n} + 1), \quad (C_0 C_2 \tilde{C}_{\gamma_{2n}})/(C C_{2n}) = C_{2n+1}. \quad (84)$$

类似地，若假设对任意 $x \in \mathbb{R}^d$ $a_{n+1}(x) = \exp[-\gamma_{2n+1} \|x\|^2]/C_{2n+1}$ ，其中 $\gamma_{2n+1} \geq 0$ 且 $C_{2n+1} > 0$ ，则对任意 $y \in \mathbb{R}^d$ 我们有

$$\begin{aligned}
b_{n+1}(y) &= (C_0 C_2 \tilde{C}_{\gamma_{2n+1}})^{-1} (C C_{2n+1}) \exp[-(1-\beta^2 - \alpha^2/(\gamma_{2n+1} + 1)) \|y\|^2] \\
&= \exp[-\gamma_{2n+2} \|y\|^2]/C_{2n+2},
\end{aligned}$$

其中

$$\gamma_{2n+2} = \beta^2 - 1 + \alpha^2/(\gamma_{2n+1} + 1), \quad (C_0 C_2 \tilde{C}_{\gamma_{2n+1}})/(C C_{2n+1}) = C_{2n+2}.$$

结合这一结果、(84) 式并利用递归原理，我们得到对于任意 $n \in \mathbb{N}$

$$a_{n+1}(x) = \exp[-\gamma_{2n+1} \|x\|^2]/C_{2n+1}, \quad b_{n+1}(y) = \exp[-\gamma_{2n+2} \|y\|^2]/C_{2n+2}.$$

递归可扩展至 a_0 和 b_0 ，只需设定 $\gamma_{-1} = \gamma_0 = 0$ 和 $C_{-1} = C_0 = 1$ 。因此，对于任意 $n \in \mathbb{N}$ ，我们有

$$\gamma_{n+1} = \beta^2 - 1 + \alpha^2/(\gamma_n + 1). \quad (85)$$

我们现在研究序列 $(\gamma_n)_{n \in \mathbb{N}}$ 的收敛性。通过递归，我们有对于任意 $k, \ell \in \mathbb{N}$ ，若 $\gamma_k \geq \gamma_\ell$ ，则对于任意 $m \in \mathbb{N}$ 且 m 为偶数时，有 $\gamma_{m+k} \geq \gamma_{m+\ell}$ ；对于任意 $m \in \mathbb{N}$ 且 m 为奇数时，有 $\gamma_{m+k} \leq \gamma_{m+\ell}$ 。我们有 $\gamma_0 = 0$ 以及

$$\gamma_1 = \beta^2 + \alpha^2 - 1, \quad \gamma_2 = \beta^2 - 1 + \alpha^2/(\beta^2 + \alpha^2). \quad (86)$$

我们将证明的其余部分分为三个部分。

(a) First assume that $\beta^2 > 1 - \alpha^2$. Using (86) we have that $\gamma_1 > \gamma_0$ and $\gamma_2 > \gamma_0$. Therefore, we obtain that $(\gamma_{2n})_{n \in \mathbb{N}}$ is non-decreasing, that $(\gamma_{2n+1})_{n \in \mathbb{N}}$ is non-increasing and that for any $n \in \mathbb{N}$, $0 \leq \gamma_{2n} \leq \gamma_{2n+1} \leq \gamma_1$. Therefore, $(\gamma_n)_{n \in \mathbb{N}}$ converges and we denote γ^* its limit. We have $\gamma^* = \beta^2 - 1 + \alpha^2/(\gamma^* + 1)$. Hence, γ^* is a root of $X^2 + (2 - \beta^2)X + 1 - \alpha^2 - \beta^2$. We get that $\gamma^* = \gamma_0^*$ or $\gamma^* = \gamma_1^*$ with

$$\gamma_0^* = \beta^2/2 - 1 - (1/2)(\beta^4 + 4\alpha^2)^{1/2}, \quad \gamma_1^* = \beta^2/2 - 1 + (1/2)(\beta^4 + 4\alpha^2)^{1/2},$$

γ_0^*, γ_1^* 是 β 的非递减函数。我们得到对于任意 $\beta \geq 0$ ，使得 $\beta^2 \geq 1 - \alpha^2$, $\gamma_0^* \leq 0$ 。此外，我们有 γ^* 对于

使得由于 $\gamma^* \geq 0$ 我 $= 0$ $\beta^2 = 1 - \alpha^2$ ，因此对于任意 $\beta \geq 0$ $\beta^2 \geq 1 - \alpha^2$, $\gamma_1^* \geq 0$ 。
们有

$$\gamma^* = -1 + \beta^2/2 + (1/2)(\beta^4 + 4\alpha^2)^{1/2}. \quad (87)$$

对于任意 $n \in \mathbb{N}$, denote $\xi_n = \gamma_n - \gamma^*$ 及 $\tau = \gamma^* + 1$ $\varepsilon > 0$. Since $\lim_{n \rightarrow +\infty} \xi_n = 0$, there
。设存在 $n_0 \in \mathbb{N}$ 使得 $|\xi_n|/\tau \leq \varepsilon$ 。利用 (85)，我们得到对于任意 $n \in \mathbb{N}$

$$|\xi_{n+1}| = \alpha^2 |1/(\gamma_n + 1) - \tau^{-1}| = (\alpha^2/\tau) |1 - (\xi_n/\tau + 1)^{-1}| \leq (\alpha/\tau)^2 |\xi_n|/(1 - \varepsilon).$$

因此，我们得到对于任意 $\varepsilon \in (0, 1)$ ，存在 $C_\varepsilon > 0$ 使得对于任意 $n \in \mathbb{N}$

$$|\xi_n| \leq C_\varepsilon \kappa^n, \quad \kappa = (\alpha/(\tau(1 - \varepsilon)^{1/2}))^2.$$

Note that $\tau > \alpha$ using (87) and $\kappa \in (0, 1)$ if $\varepsilon < 1 - \alpha/\tau$.

For any $n \in \mathbb{N}$ and $x, y \in \mathbb{R}^d$ we have

$$\begin{aligned}\Phi_n(x, y) &= a_{n+1}(x)b_{n+1}(y) = \exp[-\gamma_{2n+1} \|x\|^2 - \gamma_{2n+2} \|y\|^2] / (C_{2n+1}C_{2n+2}) \\ &= \exp[-\gamma_{2n+1} \|x\|^2 - \gamma_{2n+2} \|y\|^2] / (\tilde{C}\tilde{C}_{\gamma_{2n+1}}),\end{aligned}$$

其中 $\tilde{C} = C_0C_2/C$ 。因此我们得到对于任意 $x, y \in \mathbb{R}^d$, $\Phi^*(x, y) = \lim_{n \rightarrow +\infty} \Phi_n(x, y)$ 存在, 并且我们有

$$\Phi^*(x, y) = \exp[-\gamma^* \|x\|^2 - \gamma^* \|y\|^2] / (\tilde{C}\tilde{C}_{\gamma^*}).$$

利用这一结果, 我们得到对于任意 $x, y \in \mathbb{R}^d$

$$\begin{aligned}(\mathrm{d}\pi^{2n}/\mathrm{d}\pi^*)(x, y) &= \exp[-\xi_{2n+1} \|x\|^2 - \xi_{2n+2} \|y\|^2] C_{\gamma^*} / C_{\gamma_{2n+1}} \\ &= \exp[-\xi_{2n+1} \|x\|^2 - \xi_{2n+2} \|y\|^2] \{(1 + \gamma_{2n+1}) / (1 + \gamma^*)\}^{-d/2} \\ &= \exp[-\xi_{2n+1} \|x\|^2 - \xi_{2n+2} \|y\|^2] \{1 + \xi_{2n+1} / (1 + \gamma^*)\}^{-d/2}.\end{aligned}$$

Therefore we have for any $x, y \in \mathbb{R}^d$

$$\begin{aligned}\text{对数}((\mathrm{d}\pi^{2n}/\mathrm{d}\pi^*)(x, y)) &\leq |\xi_{2n+1}| \|x\|^2 + |\xi_{2n+2}| \|y\|^2 + (d/2) |\log(1 + \xi_{2n+1} / (1 + \gamma^*))| \\ &\leq |\xi_{2n+1}| \|x\|^2 + |\xi_{2n+2}| \|y\|^2 + (d/2) |\xi_{2n+1}|.\end{aligned}$$

因此我们得到对于任意 $n \in \mathbb{N}$

$$\mathrm{KL}(\pi^* | \pi^n) \leq (d/2)(\beta^{-2} |\xi_{2n+1}| + \beta^{-2} |\xi_{2n+2}| + |\xi_{2n+1}|).$$

类似的不等式对于 $\mathrm{KL}(\pi^* | \pi^n)$ 成立。因此我们得到对于任意 $\varepsilon \in (0, 1 - \alpha/\tau)$, 存在 $C_\varepsilon \geq 0$ 使得对于任意 $n \in \mathbb{N}$, 我们有

$$\mathrm{KL}(\pi^* | \pi^n) \leq C_\varepsilon \kappa_\varepsilon^{2n},$$

其中

$$\begin{aligned}\kappa_\varepsilon &= \alpha / (\tau(1 - \varepsilon)^{1/2}) = (2\alpha) / ((\beta^2 + (\beta^4 + 4\alpha^2)^{1/2})(1 - \varepsilon)^{1/2}) \\ &\leq \rho / ((1 + (1 + \rho^2)^{1/2})(1 - \varepsilon)^{1/2}).\end{aligned}$$

令 $\varepsilon < 1 - (1 + \rho) / (1 + (1 + \rho^2)^{1/2})$ 。则我们得到 $\kappa_\varepsilon \leq \kappa$, 这完成了证明的第一部分。

(b) If $\beta^2 = 1 - \alpha^2$ 则迭代比例拟合是平稳的, 因为迭代比例拟合保持 μ 不变。

(c) 最后我们假设 $\beta^2 < 1 - \alpha^2$ 。利用 (86) 式可得 $\gamma_1 < \gamma_0$ 且 $\gamma_2 < \gamma_0$, 因为 $\beta^2 < 1 - \alpha^2$ 。因此, 我们得到 $(\gamma_{2n})_{n \in \mathbb{N}}$ 是非递增的, $(\gamma_{2n+1})_{n \in \mathbb{N}}$ 是非递减的, 且对任意 $n \in \mathbb{N}$, $0 \geq \gamma_{2n} \geq \gamma_{2n+1} \geq \gamma_1$ 成立。因此, $(\gamma_n)_{n \in \mathbb{N}}$ 收敛, 我们记其极限为 γ^* 。我们有 $\gamma^* = \beta^2 - 1 + \alpha^2 / (\gamma^* + 1)$ 。因此, γ^* 是 $X^2 + (2 - \beta^2)X + 1 - \alpha^2 - \beta^2$ 的一个根。我们回顾该多项式的两个根由下式给出

$$\gamma_0^* = \beta^2/2 - 1 - (1/2)(\beta^4 + 4\alpha^2)^{1/2}, \quad \gamma_1^* = \beta^2/2 - 1 + (1/2)(\beta^4 + 4\alpha^2)^{1/2}.$$

我们有

$$\begin{aligned}\gamma_1 - \gamma_0^* &= \beta^2 + \alpha^2 - 1 - \beta^2/2 + 1 - (1/2)(\beta^4 + 4\alpha^2)^{1/2} \\ &= (1/2)(\beta^2 + 2\alpha^2 - (\beta^4 + 4\alpha^2)^{1/2}) \geq 0.\end{aligned}$$

由于 $\gamma_3 > \gamma_1$, 我们得到对任意满足 $n \geq 3, \gamma_n \geq \gamma_3 > \gamma_0^*$ 的 $n \in \mathbb{N}$ 成立。因此 $\gamma^* > \gamma_0^*$, 进而 $\gamma^* = \gamma_1^*$ 。证明的其余部分与 $\beta^2 > 1 - \alpha^2$ 的情形类似。

□

G.2 收敛到真实值

本节给出高斯情形下薛定谔桥的解析形式。设 ν_0 为均值 $-a$ (其中 $a \in \mathbb{R}^d$)、协方差矩阵 $\mathbf{I} \in \mathbb{R}^{d \times d}$ 的 d 维高斯分布。类似地, 设 ν_1 为均值 a 、协方差矩阵为单位阵的一维高斯分布。考虑参考分布 π^0 , 使得 $\pi_0^0 = \nu_0$ 且对任意 $x, y \in \mathbb{R}^d$

$(d\pi_{1|0}^0/d\lambda)(x, y) = (2\pi)^{-d/2} \exp[-\|x - y\|^2/2]$, 其中 λ 表示 $\mathbb{R}$ 上的勒贝格测度。注意 $\pi_{1|0}^0$ 可通过运行 d -维布朗运动至时刻 1 得到。考虑如下薛定谔桥问题

$$\pi^* = \arg \min \{ \text{KL}(\pi | \pi^0) : \pi \in \mathcal{P}(\mathbb{R}^{2d}), \pi_0 = \nu_0, \pi_1 = \nu_1 \}. \quad (88)$$

在给出薛定谔桥问题的解析解之前, 先考虑以下代数引理。

引理 45. Let $A \in \mathbb{R}^{d \times d}$ and

$$M = \begin{pmatrix} \mathbf{I} & A \\ A^\top & \mathbf{I} \end{pmatrix}, \quad M^S = \begin{pmatrix} \mathbf{I} & (A + A^\top)/2 \\ (A + A^\top)/2 & \mathbf{I} \end{pmatrix},$$

使得 M 是对称且半正定的。则 $\det(M) \leq \det(M^S)$ 。

证明。令 M 是对称且半正定的, $M^{\text{down}} = \begin{pmatrix} \mathbf{I} & A^\top \\ A & \mathbf{I} \end{pmatrix}$ 可对角化。令 $x, y \in \mathbb{R}^d$ 和 $\theta \geq 0$ 使得 $M^{\text{up}} X = \theta X$ 且 $X = (x, y)$ 。令 $Y = (y, x)$ 。我们有 $M^{\text{down}} Y = \theta Y$ 。因此 M^{down} 是对称、半正定的且 $\det(M^{\text{up}}) = \det(M^{\text{down}})$ 。因此利用 $M \mapsto \log(\det(M))$ 在对称半正定矩阵空间上是凹的, 我们得到 $\det(M^{\text{up}}) \leq \det((M^{\text{up}} + M^{\text{down}})/2) = \det(M^S)$, 证毕。

□

命题 46. (88) 的解存在且 π^* 是一个高斯分布, 均值为 $m \in \mathbb{R}^{2d}$, 协方差矩阵为 Σ , 其中

$$m = (-a, a), \quad \Sigma = \begin{pmatrix} \mathbf{I} & \beta \mathbf{I} \\ \beta \mathbf{I} & \mathbf{I} \end{pmatrix},$$

其中 $\beta = (-1 + \sqrt{5})/2$ 且 $\mathbf{I}$ 是 d 维单位矩阵。

证明。 π^* 存在且为高斯分布这一事实与命题 43. π^* 类似, 其均值为 m , 因为 $\pi_i^* = \nu_i$ 对于 $i \in \{0, 1\}$ 。类似地, 我们有 $\Sigma_{00} = \Sigma_{11} = \mathbf{I}$, 因为 $\pi_i^* = \nu_i$ 对于 $i \in \{0, 1\}$ 。我们有 π^0 关于勒贝格测度存在密度 p^0 , 使得对于任意 $x, y \in \mathbb{R}^d$ 我们有 $p^0(x, y) \propto \exp[-(1/2)\{2\|x\|^2 + \|y\|^2 + 2\langle a, x \rangle - 2\langle x, y \rangle + \|a\|^2\}]$ 。因此 π^0 是一个高斯分布, 均值为 m^0 , 协方差矩阵为 Σ^0 , 其中

$$m^0 = (-a, -a), \quad \Sigma^0 = \begin{pmatrix} \mathbf{I} & \mathbf{I} \\ \mathbf{I} & 2\mathbf{I} \end{pmatrix}.$$

高斯分布 π (均值为 $\tilde{m}$, 协方差矩阵为 $\tilde{\Sigma}$) 与 π^0 (均值为 m^0 , 协方差为 Σ^0) 之间的库尔贝克-莱布勒散度由下式给出

$$\text{KL}(\pi | \pi^0) = (1/2) \{ \log(\det(\Sigma^0)/\det(\tilde{\Sigma})) - d + \text{Tr}((\Sigma^0)^{-1} \tilde{\Sigma}) + (\tilde{m} - m^0)^\top (\Sigma^0)^{-1} (\tilde{m} - m^0) \}.$$

Assume that $\tilde{m} = (-a, a)$ and $\tilde{\Sigma} = \begin{pmatrix} \mathbf{I} & S \\ S^\top & \mathbf{I} \end{pmatrix}$ 使得 $S \in \mathbb{R}^{d \times d}$ 满足 $\tilde{\Sigma}$ 为半正定。

于是我们有

$$\text{KL}(\pi | \pi^0) = (1/2) \{ -\log(\det(\tilde{\Sigma})) - 2 \text{Tr}(S) + C \},$$

where $C \geq 0$ is a constant which does not depend on Σ . In what follows, let $\tilde{\Sigma}' = \begin{pmatrix} \mathbf{I} & (S + S^\top)/2 \\ (S + S^\top)/2 & \mathbf{I} \end{pmatrix}$ and denote π the distribution with mean $\tilde{m}$ and covariance matrix $\tilde{\Sigma}'$. 利用引理 45, 我们有

$$\text{KL}(\pi' | \pi^0) = (1/2) \{ -\log(\det(\tilde{\Sigma}')) - 2 \text{Tr}(S) + C \}$$

$$\leq (1/2)\{-\log(\det(\tilde{\Sigma})) - 2\text{Tr}(S) + C\} = \text{KL}(\pi|\pi^0).$$

因此，可以假设 $S = S^\top$ ，并且由于 S 是实值的， S 是可对角化的。设 $\{\lambda_i\}_{i=1}^d$ 为 S 的特征值。利用舒尔补 (Petersen 等人, 2008, 第 9.1.2 节)，我们有

$$\det(\tilde{\Sigma}) = \det(\mathbf{I} - S^2) = \det(\mathbf{I} - S) \det(\mathbf{I} + S) = \prod_{i=1}^d (1 - \lambda_i^2)。$$

因此，对于任意 $\lambda \in (0, 1)$ ，我们有

$$\text{KL}(\pi|\pi^0) = (1/2) \sum_{i=1}^d f(\beta_i) + C, \quad f(\lambda) = -\log(1 - \lambda^2) - 2\lambda.$$

因此我们得到 $\Sigma_{0,1} = \beta \mathbf{I}$ ，其中

$$\beta = \arg \min_I f, \text{ 且}$$

$I = (-1, 0) \cup (0, 1)$ 。我们有

$$f'(\beta) = 0 \text{ 当且仅当}$$

$\beta = (-1 + \sqrt{5})/2$ 或 $\beta = -(1 + \sqrt{5})/2$ 。利用 $\beta \in I$ 完成证明。 $\square$

H 连续时间薛定谔桥

在本节中，我们在附录 H.1 中证明命题 6，并在附录 H.2 中建立薛定谔桥的势方法与连续时间 DSB 之间的联系。

H.1 命题 6 的证明

我们回顾连续薛定谔问题由下式给出

$$\Pi^* = \arg \min \{ \text{KL}(\Pi|\mathbb{P}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_0 = p_{\text{data}}, \Pi_T = p_{\text{prior}} \}, \quad T = \sum_{k=0}^{N-1} \gamma_{k+1}. \quad (89)$$

在本节中，我们证明命题 6。我们从以下性质开始，该性质可在 (Léonard, 2014b, 命题 2.3, 命题 2.10) 中找到，并建立了动态连续薛定谔桥的基本性质。

命题 47。 (89) 的解存在当且仅当静态薛定谔桥的解存在。此外，如果解存在且 $\mathbb{P}$ 是马尔可夫的，则薛定谔桥是马尔可夫的。

我们现在转向命题 6 的证明。首先我们强调 $(\Pi^n)_{n \in \mathbb{N}}$ 是良定义的，因为其静态对应物 $(\pi_n)_{n \in \mathbb{N}}$ 使用命题 32 是良定义的。我们仅证明对于任何 $n \in \mathbb{N}$ ， $(\Pi^{2n+1})^R$ 是与过程 $(\mathbf{Y}_t^{2n+1})_{t \in [0, T]}$ 相关的路径测度，使得 $\mathbf{Y}_0^{2n+1}$ 具有分布 p_{prior} 并满足

$$d\mathbf{Y}_t^{2n+1} = b_{T-t}^n(\mathbf{X}_t^{2n+1})dt + \sqrt{2}d\mathbf{B}_t.$$

Π^{2n+2} 的证明类似。令 $n \in \mathbb{N}$ 并假设 Π^{2n} 是与过程 $(\mathbf{X}_t^{2n})_{t \in [0, T]}$ 相关的路径测度，使得 $\mathbf{X}_0^{2n}$ 具有分布 p_{data} 并满足

$$d\mathbf{X}_t^{2n} = f_t^n(\mathbf{X}_t^{2n})dt + \sqrt{2}d\mathbf{B}_t.$$

我们有

$$\Pi^{2n+1} = \arg \min \{ \text{KL}(\Pi|\Pi^{2n}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_T = p_{\text{prior}} \}.$$

令 $\phi = \text{proj}_T$ 使得对于任何 $\omega \in \mathcal{C}$ ， $\text{proj}_T(\omega) = \omega_T$ 。使用命题 24 我们得到对于任何 $\Pi \in \mathcal{P}(\mathcal{C})$ 我们有

$$\text{KL}(\Pi|\Pi^{2n}) = \text{KL}(\Pi_T|\Pi_T^{2n}) + \int_{\mathbb{R}^d} \text{KL}(K(x, \cdot)|K^{2n}(x, \cdot))d\Pi_T(x),$$

其中 K 和 K^{2n} 是 Π 和 Π^{2n} 关于 ϕ 的分解。因此，我们得到 $\Pi^{2n+1} = p_{\text{prior}}K^{2n}$ 。由于 $\text{KL}(\Pi^{2n}|\mathbb{Q}) < +\infty$ 和 Π^{2n} 是马尔可夫的，利用 (Cattiaux et al., 2021, Theorem 4.9) 我们得到 $(\Pi^{2n})^R = \Pi_T K^{2n}$ 满足与扩散相关的鞅问题

$$d\mathbf{Y}_t^{2n} = \{-f_{T-t}^n(\mathbf{Y}_t^{2n}) + 2\nabla \log p_{T-t}^n(\mathbf{Y}_t^{2n})\}dt + \sqrt{2}d\mathbf{B}_t. \quad (90)$$

由于 $\Pi^{2n+1} = p_{\text{prior}}K^{2n}$ 我们得到 Π^{2n+1} 也满足与 (90) 相关的鞅问题并且是马尔可夫的，这通过递归完成了证明。

H.2 连续时间中的 IPF 与势函数 首先，我们回顾 IPF $(\Pi^n)_{n \in \mathbb{N}}$ 与 $\Pi^0 = \mathbb{P}$ 关联于 (6) 且对于任意 $n \in \mathbb{N}$

$$\begin{aligned}\Pi^{2n+1} &= \arg \min \{ \text{KL}(\Pi | \Pi^{2n}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_T = p_{\text{prior}} \}, \\ \Pi^{2n+2} &= \arg \min \{ \text{KL}(\Pi | \Pi^{2n+1}) : \Pi \in \mathcal{P}(\mathcal{C}), \Pi_0 = p_{\text{data}} \}.\end{aligned}$$

在本节中，我们在连续时间中建立时间反演方法与势函数方法之间的联系。更精确地，我们在命题 48 中明确了两者之间的恒等式。

命题 48. 假设 **A1** 成立，且存在 $\mathbb{M} \in \mathcal{P}(\mathcal{C})$, $U \in C^1(\mathbb{R}^d, \mathbb{R})$, $C \geq 0$ ，使得对任意 $n \in \mathbb{N}$, $x \in \mathbb{R}^d$ ， $\text{KL}(\Pi^n | \mathbb{M}) < +\infty$, $\langle x, \nabla U(x) \rangle \geq -C(1 + \|x\|^2)$ 与 $\mathbb{M}$ 相关联

$$d\mathbf{X}_t = -\nabla U(\mathbf{X}_t)dt + \sqrt{2}d\mathbf{B}_t,$$

其中 $\mathbf{X}_0$ 按照 (15) 的不变分布进行分布。对于任意 $n \in \mathbb{N}$ ，令 $\{\varphi_t^{n,*}, \varphi_t^{n,\circ}\}_{t=0}^T$ 使得对于任意 $t \in [0, T]$, $\varphi_t^{n,*} : \mathbb{R}^d \rightarrow \mathbb{R}$, $\varphi_t^{n,\circ} : \mathbb{R}^d \rightarrow \mathbb{R}$ ，对于任意 $x_0, x_T \in \mathbb{R}^d$

$$\varphi_T^{*,n}(x_T) = p_{\text{prior}}(x_T)/p_T^n(x_T), \quad \varphi_0^{\circ,n}(x_0) = p_{\text{data}}(x_0)/p_0^{n+1}(x_0),$$

并且对于任意 $t \in (0, T)$ 及 $x_t \in \mathbb{R}^d$

$$\varphi_t^{*,n}(x_t) = \int \varphi_T^{*,n}(x_T) p_{T|t}^n(x_T | x_t) dx_T, \quad \varphi_t^{\circ,n+1}(x) = \int \varphi_0^{\circ,n+1}(x_0) q_{0|t}^n(x_0 | x_t) dx_0.$$

We have for any $n \in \mathbb{N}$, $t \in [0, T]$ and $x_t \in \mathbb{R}^d$

$$q_t^n(x_t) = p_t^n(x_t) \varphi_t^{*,n}(x_t), \quad p_t^{n+1}(x_t) = q_t^n(x_t) \varphi_t^{\circ,n}(x_t). \quad (91)$$

In particular, for any $n \in \mathbb{N}$ we have

$$(a) \ (\Pi^{2n+1})^R \text{ 与 } d \text{ 相关联} \quad \mathbf{Y}_t^{2n+1} = b_{T-t}^n(\mathbf{Y}_t^{2n+1})dt + \sqrt{2}d\mathbf{B}_t \text{ 含 } \mathbf{Y}_0^{2n+1} \sim p_{\text{prior}};$$

$$(b) \ \Pi^{2n+2} \text{ 与 } d \text{ 相关联} \quad \mathbf{X}_t^{2n+2} = f_{T-t}^{n+1}(\mathbf{X}_t^{2n+2})dt + \sqrt{2}d\mathbf{B}_t \quad \mathbf{X}_0^{2n+2} \sim p_{\text{data}};$$

$$f_t^n(x) = f(x) + 2 \sum_{k=1}^n \nabla \log \varphi_t^{*,n}(x), \quad b_t^n(x) = -f(x) + \nabla \log p_t^0(x) + 2 \sum_{k=1}^n \nabla \log \varphi_t^{\circ,n}(x). \quad (92)$$

证明。我们仅证明 (91) 成立。则 (92) 是 (91) 与命题 6 的直接推论。设

$n \in \mathbb{N}$ 。与命题 26 的证明类似，存在 $\varphi_T^{*,n} : \mathbb{R}^d \rightarrow \mathbb{R}_+$ $\{\omega_t\}_{t=0}^T \in \mathcal{C}$ 我们有

$$(d\Pi^{2n+1}/d\Pi^{2n})(\{\omega_t\}_{t=0}^T) = \varphi_T^{*,n}(\omega_T). \quad (93)$$

注意，如命题 6 中所述，对于任意 $s, t \in [0, T]$, $\Pi_{s,t}^{2n+1}$ 关于勒贝格测度具有正密度，记为 $q_{s,t}^n$ ，且 $\Pi_{s,t}^{2n}$ 关于勒贝格测度具有正密度，记为 $p_{s,t}^n$ 。结合此结果与 (93)，我们得到对于任意 $t \in [0, T]$ 和 $x_t, x_T \in \mathbb{R}^d$ ，有

$$q_{t,T}^n(x_t, x_T) = p_{t,T}^n(x_t, x_T) \varphi_T^{*,n}(x_T).$$

对任意 $t \in [0, T]$ 有

$$q_t(x_t) = p_t^n(x_t) \int \varphi_T^{*,n}(x_T) p_{T|t}^n(x_T | x_t) dx_T = p_t^n(x_t) \varphi_t^{*,n}(x_t).$$

对于任意的证明 $n \in \mathbb{N}$, $t \in [0, T]$ 及 $x_t \in \mathbb{R}^d$, $p_t^{n+1}(x_t) = q_t^n(x_t) \varphi_t^{\circ,n}(x_t)$ ，是类似的。□

两种表述之间的联系在 (91) 中明确给出。则 (92) 是 (91) 的直接推论，应与附录 H.1 进行比较。命题 48 的另一种证明利用了 (91) 对联合密度的推广，并利用如下事实：对于任意 $n \in \mathbb{N}$, Π_{n+1} 是 Π_n 的杜布 h -变换（定义见 (Rogers and Williams, 2000, 第 39.1 段)）。注意，半桥的势与密度之间的这种关系并非新发现。特别是，该方程的一个类似版本可在 Bernton et al. (2019) 中找到。在 Finlay et al. (2020) 中，作者在完全薛定谔桥的情形下建立了类似的关系。

H.3 薛定谔桥的似然计算

我们在此给出由薛定谔桥得到的生成模型的似然计算细节。在 (Léonard, 2011, 定理 4.12) 的条件下，我们定义 $(\mathbf{X}_t^*)_{t \in [0, T]}$ 为与 Π^* 相关的扩散，见 (89)，及其时间反演 $(\mathbf{Y}_t^*)_{t \in [0, T]}$ 。存在 $f^*, b^* : [0, T] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 使得 $(\mathbf{X}_t^*)_{t \in [0, T]}$ 和 $(\mathbf{Y}_t^*)_{t \in [0, T]}$ 是下列随机微分方程的弱解

$$d\mathbf{X}_t^* = f_t^*(\mathbf{X}_t^*)dt + \sqrt{2}d\mathbf{B}_t, \quad d\mathbf{Y}_t^* = b_{T-t}^*(\mathbf{Y}_t^*)dt + \sqrt{2}d\mathbf{B}_t.$$

我们假设对于任意 $t \in [0, T]$ ，存在 $p_t^* : \mathbb{R}^d \rightarrow \mathbb{R}_+$ ，使得对于任意 $x \in \mathbb{R}^d$ ， $(d\Pi_t^*/d\lambda)(x) = p_t^*(x)$ 。此外，我们假设 $p^* \in C^\infty([0, T] \times \mathbb{R}^d, \mathbb{R}_+)$ 。在这种情况下，我们有 Π^* 也与过程 $(\tilde{\mathbf{X}}_t^*)_{t \in [0, T]}$ 相关联，该过程与常微分方程相关

$$d\tilde{\mathbf{X}}_t^* = \{f_t^*(\tilde{\mathbf{X}}_t^*) - \nabla \log p_t^*(\tilde{\mathbf{X}}_t^*)\}dt,$$

且 $\tilde{\mathbf{X}}_T^*$ 具有分布 p_{prior} ；参见例如 (Song 等人, 2021, 第 A 节)。由于 $(\mathbf{Y}_t^*)_{t \in [0, T]}$ 是 $(\mathbf{X}_t^*)_{t \in [0, T]}$ 的时间反演，我们有对于任意 $t \in [0, T]$ 和 $x \in \mathbb{R}^d$

$$b_t^*(x) = -f_t^*(x) + 2\nabla \log p_t^*(x).$$

因此，我们得到 $(\tilde{\mathbf{X}}_t^*)_{t \in [0, T]}$ 与常微分方程相关

$$d\tilde{\mathbf{X}}_t^* = \frac{1}{2} \left(f_t^*(\tilde{\mathbf{X}}_t^*) - b_t^*(\tilde{\mathbf{X}}_t^*) \right) dt. \quad (94)$$

利用这一结果，我们可以使用瞬时变量变换公式 (Chen 等人, 2018) 计算模型的对数似然，另见 (Song 等人, 2021, 附录 D.2)

$$\log p_{\text{data}}(\tilde{\mathbf{X}}_0^*) = \log p_{\text{prior}}(\tilde{\mathbf{X}}_T^*) + \frac{1}{2} \int_0^T \text{div}(f_t^* - b_t^*)(\tilde{\mathbf{X}}_t^*) dt. \quad (95)$$

与 Song 等人 (2021) 一样，我们可以使用 Skilling - Hutchinson 迹估计器来计算散度算子 (Skilling, 1989; Hutchinson, 1989)。在实践中，我们离散化 $(\tilde{\mathbf{X}}_t^*)_{t \in [0, T]}$ 的动力学，并使用由算法 1 的最后一次迭代获得的网络 B_{β^n} ，在时间上向后求解常微分方程，同时记住 $\tilde{\mathbf{X}}_T^*$ 具有分布 p_{prior} 。类似地，我们可以定义

$$d\tilde{\mathbf{Y}}_t = \{b_{T-t}^*(\tilde{\mathbf{Y}}_t^*) - \nabla \log p_{T-t}^*(\tilde{\mathbf{Y}}_t^*)\}dt,$$

$\mathbf{Y}_0^*$ 且具有分布 p_{prior} 。与 (94) 类似，我们得到 $(\tilde{\mathbf{Y}}_t^*)_{t \in [0, T]}$ 与常微分方程相关

$$d\tilde{\mathbf{Y}}_t = \frac{1}{2} \left(b_{T-t}^*(\tilde{\mathbf{Y}}_t^*) - f_{T-t}^*(\tilde{\mathbf{Y}}_t^*) \right) dt.$$

与 (96) 类似，我们有

$$\log p_{\text{data}}(\tilde{\mathbf{Y}}_T^*) = \log p_{\text{prior}}(\tilde{\mathbf{Y}}_0^*) + \frac{1}{2} \int_0^T \text{div}(b_{T-t}^* - f_{T-t}^*)(\tilde{\mathbf{Y}}_t^*) dt. \quad (96)$$

在实践中，我们离散化 $(\tilde{\mathbf{Y}}_t^*)_{t \in [0, T]}$ 的动力学，并使用由算法 1 的最后一次迭代获得的网络 $F_{\alpha^n}, B_{\beta^n}$ ，在时间上向前求解常微分方程，同时记住 $\tilde{\mathbf{Y}}_0^*$ 具有分布 p_{prior} 。注意，在这种情况下，我们与 Durkan 和 Song (2021) 相反，在时间上向前求解常微分方程。

I 训练技巧

在本节中，我们基于算法 1，为 DSB 的实现提供一些实用的指导原则。我们强调，与先前的方法 (Song 等人, 2021; Song 和 Ermon, 2020; Ho 等人, 2020; Dhariwal 和 Nichol, 2021) 不同，我们没有对损失函数进行加权，因为我们没有观察到任何改进。设 $I \subset \{0, N-1\} \times \{1, M\}$ 。我们定义广义损失 $\hat{\ell}_{n,I}^b$ 和 $\hat{\ell}_{n,I}^f$ ，由下式给出

$$\hat{\ell}_{n,I}^b(\beta) = M^{-1} \sum_{(k,j) \in I} \|B_\beta(k+1, X_{k+1}^j) - (X_{k+1}^j + F_k^n(X_{k+1}^j) - F_k^n(X_k^j))\|^2, \quad (97)$$

$$\hat{\ell}_{n+1,I}^f(\alpha) = M^{-1} \sum_{(k,j) \in I} \|F_\alpha(k, X_k^j) - (X_k^j + B_{k+1}^n(X_k^j) - B_{k+1}^n(X_{k+1}^j))\|^2. \quad (98)$$

我们首先描述计算这些损失的三种技术，然后介绍进一步提升性能的方法。

技术 1. 模拟轨迹

损失 (97) 和 (98) 可以通过模拟扩散轨迹来计算, 如算法 1 所述。对于每个样本 $j \in \{1, \dots, M\}$, 采样轨迹中的骨架点 $\{X_k^j\}_k$ 是相关的, 因此每个梯度步骤仅使用每个样本的单个均匀采样时间步来计算损失。此外, 在初始 DSB 迭代之后, 模拟扩散轨迹涉及每个扩散步骤中计算量大的神经网络运算。

技术 2. 闭式采样 由于 $f_\alpha^0(x) = -\alpha x$, 在固定 α 的情况下, 第一次 IPF 迭代无需计算完整轨迹, 可以通过从具有适当均值和协方差的高斯分布中采样, 以闭式形式沿轨迹采样点。该技术还提高了第一次 DSB 迭代的计算速度。

技术 3. 缓存轨迹

在初始去噪扩散桥 (DSB) 迭代之后, 无法按照技术 2 进行闭式采样。如技术 1 所述, 模拟完整扩散轨迹既浪费又昂贵。为了获得加速, 我们考虑算法 1 的缓存版本, 即算法 3, 该算法需要存储并重新采样扩散轨迹。重新采样的轨迹随后用于计算损失 (97) 和 (98)。缓存可以按一定频率通过再次模拟扩散来刷新。可以根据可用内存调整缓存大小和刷新频率。这种修改允许显著加速, 因为轨迹无需在每次训练迭代中模拟。

Algorithm 3 Cached Diffusion Schrödinger Bridge

```

1: for  $n \in \{0, \dots, L\}$  do
2:   while not converged do
3:     Sample and store  $\{X_k^j\}_{k,j=0}^{N,M}$  where  $X_0^j \sim p_{\text{data}}$  and
        $X_{k+1}^j = X_k^j + \gamma_{k+1} f_{\alpha^n}(k, X_k^j) + \sqrt{2\gamma_{k+1}} Z_{k+1}^j$ 
4:     while not refreshed do
5:       Sample  $I$  (uniform in  $\{0, N-1\} \times \{1, M\}$ )
6:       Compute  $\hat{\ell}_{n,I}^b(\beta^n)$  using (97)
7:        $\beta^n = \text{Gradient Step}(\hat{\ell}_{n,I}^b(\beta^n))$ 
8:     end while
9:   end while
10:  while not converged do
11:    Sample  $\{X_k^j\}_{k,j=0}^{N,M}$ , where  $X_N^j \sim p_{\text{prior}}$ , and
        $X_k^j = X_{k+1}^j + \gamma_k b_{\beta^n}(k, X_k^j) + \sqrt{2\gamma_k} Z_k^j$ 
12:    while not refreshed do
13:      Sample  $I$  (uniform in  $\{0, N-1\} \times \{1, M\}$ )
14:      Compute  $\hat{\ell}_{n+1,I}^f(\alpha^{n+1})$  using (98)
15:       $\alpha^{n+1} = \text{Gradient Step}(\hat{\ell}_{n+1,I}^f(\alpha^{n+1}))$ 
16:    end while
17:  end while
18: end for
19: Output:  $(\alpha^{L+1}, \beta^L)$ 

```

技术 4. 调整高斯先验均值/方差

迭代比例拟合 (IPF) 的收敛受目标高斯分布的均值和协方差矩阵影响。在附录 J.1 中, 我们研究了这些值的可能选择。在实践中, 我们建议选择高斯先验 p_{prior} 的方差略大于目标数据集的方差, 并选择 p_{prior} 的均值等于目标数据集的均值。这一说明与 (Song 和 Ermon, 2020, 技术 1) 一致。

技术 5。网络精化/微调

在每个 DSB 迭代中从头训练大型网络代价高昂。然而，根据式 (64)-(65)，

$$\begin{aligned} b_{k+1}^n(x) &= b_{k+1}^{n-1}(x) + 2\nabla \log p_{k+1}^n(x) - 2\nabla \log q_k^{n-1}(x), \\ f_k^n(x) &= f_k^{n-1}(x) + 2\nabla \log q_k^{n-1}(x) - 2\nabla \log p_{k+1}^{n-1}(x). \end{aligned}$$

因此，可以在 DBS 迭代 n 时从 $n-1$ 初始化网络，以减少训练时间。在未来的工作中，我们计划通过元学习研究更复杂的温启动方法。

技巧 6。指数移动平均

与 (Song and Ermon, 2020, 技巧 5) 类似，我们发现以速率 0.999 对训练迭代中的网络参数取指数移动平均，可以提升性能。

J 附加实验结果与细节

我们在附录 J.1 中提供了二维设置的更多示例。随后在附录 J.2 中转向更高维的生成建模。最后，我们在附录 J.3 中详细介绍了数据集插值实验。代码可在以下地址获取：
https://github.com/JTT94/diffusion_schrodinger_bridge。

J.1 二维实验

在二维分布的情况下，我们为网络 f_α 和 b_β ，采用简单的架构，见图 9。我们使用附录 E.2.2 中的变分公式，因为我们的网络架构没有残差结构。为了优化网络，我们使用带动量 0.9 和学习率 10^{-4} 的 ADAM 优化器 (Kingma 和 Ba, 2014)。




图 9：二维设置中使用的网络架构。每个 MLP 块是一个多层感知器网络。“位置编码”块应用 Vaswani 等人 (2017) 中描述的正弦变换。MLP 块 (1a) 的形状为 (2, 16, 32)，MLP 块 (1b) 的形状为 (1, 16, 32)，MLP 块的形状为 (64, 128, 128, 2)。参数总数为 26498。

在所有二维实验中，我们固定 $\gamma_k = 10^{-2}$ 并使用批大小 512。 p_{prior} 的均值和方差与 p_{data} 的均值和方差匹配。缓存包含 10^4 个样本，每 10^3 次迭代刷新一次。我们为每个 DSB 步骤训练 10^4 次迭代。所有二维实验均在 Intel(R) Core(TM) i7-10850H CPU @ 2.70GHz CPU 上运行。

在图 10 中，我们展示了额外的二维实验。

我们发现 p_{prior} 的方差对 DSB 的收敛速度有影响，见图 11 的说明。这一观察与 (Song 和 Ermon, 2020, 技术 1) 一致。在实践中，我们建议将方差设置为大于目标数据集的方差，见附录 I 中的技术 4。

最后，由于 DSB 不要求朗之万迭代次数 N 很大，人们可能会质疑为什么不使用 $N = 1$ 来推导前馈生成模型。在实践中，这种 N 的选择由于两个原因而不理想。(a) 首先，由于 p_N 不是 p_{prior} 的良好近似，理论结果如 (Léger, 2020, 推论 1) 表明需要更多的 IPF 迭代。(b) 其次，在我们的实验中，我们观察到为了用 $N = 1$ 获得与 $N = 10$ 相似的结果，即使对于大量的 IPF 迭代，我们也需要大幅增加网络的规模，见图 12。




图 10: 第一行对应 DSB 的第 1 次迭代, 第二行对应 DSB 的第 3 次迭代, 第三行对应 DSB 的第 5 次迭代, 最后一行对应 DSB 的第 20 次迭代。




图 11: p_{prior} 的方差对 DSB 收敛的影响。如果 p_{prior} 具有较小的方差 σ^2 (此处 (a) 和 (b) 中为 $\sigma^2 = 5$) , 则 DSB 收敛较慢。如果 $\sigma^2 \approx \sigma_{\text{data}}^2$, 其中 σ_{data}^2 是 p_{data} 的方差, 则即使迭代次数很少, 我们也能观察到使用 DSB 获得的样本具有更大的多样性。

J.2 生成建模

实现细节 本文采用 Nichol 和 Dhariwal (2021) 提出的简化版 U-net 架构用于 F_α 和 B_β , 出于计算资源考虑, 将通道数设为 64 而非 128。本文尝试了 Song 和 Ermon (2020) 的架构, 但在本框架中观察到更差的结果。尽管使用 Song 等人 (2021) 的校正器方案有所改进, 但该改进与增加 Langevin 方案步数相当。因此, 本文选择完全避免使用此类技术, 因为采样时计算时间增加, 通常会使网络前向传播次数翻倍。

本文选择序列 $\{\gamma_k\}_{k=0}^N$ 在时间反演下保持不变, 即对任意 $k \in \{0, \dots, N\}$, $\gamma_k = \gamma_{N-k}$ 。实际中, 假设 N 为偶数, 令 $\gamma_k = \gamma_0 + (2k/N)(\bar{\gamma} - \gamma_0)$ 对于 $k \in \{0, \dots, N/2\}$, 其中 $\gamma_0 = 10^{-5}$ 且 $\bar{\gamma} = 10^{-1}$ 。序列其余部分由对称性得到。

在 MNIST 数据集 (维度 $d = 28 \times 28 = 784$) 上, 设置批大小为 128, 缓存中样本数为 5×10^4 , 每个 p_{data} 样本从每条轨迹中采样 10 个时间点。最终有效缓存大小为 5×10^5 。缓存每 10^3 次迭代刷新一次, 网络训练 5×10^3 次迭代。同样使用动量 0.9 的 ADAM 优化器, 学习率 10^{-4} 。 p_{prior} 为零均值、单位协方差矩阵的高斯密度。本文展示了不同扩散步数 N 下的结果。

在 CelebA 数据集 (维度 $d = 32 \times 32 \times 3 = 3072$) 上, 设置批大小为 256, 步数 $N = 50$, 缓存中样本数为 250, 每个 p_{data} 样本从每条轨迹中采样 1 个时间点。缓存每 10^2 次迭代刷新一次, 并且




图 12: 低 N 时 DSB 的失败。DSB 第 3 次迭代, $N = 2$ 和 30,000 每个 DSB 迭代的训练步数。算法迭代 5 次后结果显著恶化。

网络训练 5×10^3 次迭代。同样使用动量 0.9 的 ADAM 优化器, 学习率 10^{-4} . p_{prior} 为零均值、单位协方差矩阵的高斯密度。

我们在 MNIST 和 CelebA 上的结果使用 Google Cloud Platform 上最多 4 块 NVIDIA Tesla V100 计算得到。

附加示例 本节展示高维生成建模实验的附加示例。图 13 中我们在潜空间进行插值。更准确地说, 令 X_N^0 和 X_N^1 为来自 p_{prior} 的两个样本。然后针对不同的 $\lambda \in [0, 1]$ 计算 $X_N^\lambda = (1-\lambda)X_N^0 + \lambda X_N^1$ 。对于每个 $\lambda \in [0, 1]$, 关联 X_N^λ , 它对应于使用以 X_N^λ 为最终条件的 DSB 生成模型获得的输出样本。注意, 为获得确定性嵌入, 我们固定采样中使用的高斯随机变量。也可以使用 Song 等人 (2021) 采用的确定性嵌入, 即一个神经常微分方程, 它与扩散过程具有相同的边缘分布, 从而能够精确计算似然, 详见附录 H.3。



图 13: MNIST 潜空间插值。

图 14 中展示 MNIST 的高质量样本。为获得这些高质量样本, 我们采用基线 MNIST 配置, 但将时间步数从 $N = 10$ 改为 $N = 30$ 。此外, 网络训练迭代次数从 5×10^3 增加到 15×10^3 。缓存中的样本数为 $M = 500$ 。图 15 展示了对 CelebA 获得的嵌入进行温度缩放探索。与插值实验类似, 我们固定高斯随机变量, 以获得从潜空间到图像空间的确定性映射。

图 16 中探索 CelebA 嵌入的潜空间。为此, 使用以 p_{prior} 为目标的 Ornstein-Uhlenbeck 过程获取样本。潜空间探索的动画版本见项目主页。



图 14: MNIST 样本: 原始数据集 (左) 与经过 12 次 DSB 迭代后生成的 MNIST 样本 (右)




图 15: 潜空间中的温度缩放。




图 16: 潜空间探索。样本通过使用以 p_{prior} 为目标的奥恩斯坦-乌伦贝格过程生成初始条件, 然后使用由 DSB 给出的生成模型。从左到右: 时间 $t = 0, 1.3, 3.6, 8.6$ 处的样本。

J.3 数据集插值

对于数据集插值任务，我们保持与之前相同的参数和架构，除了在二维示例中朗之万步数增加到 50 步，在 EMNIST/MNIST 插值任务中增加到 30 步。我们还改变了参考动力学，选择使用 DSB 获得的动力学，其中 p_{prior} 是高斯分布。这一选择使我们能够在此设置下加速 DSB 的训练。动画图可在项目网页上查看。

EMNIST/MNIST 为了在手写字母数据集（EMNIST）和手写数字数据集（MNIST）之间进行转换，我们将 EMNIST 缩减为 5 个字母，使其类别数与 MNIST 相同（我们区分大写和小写字母），原始数据集见 Cohen 等人（2017）。



图 17: 使用 $T = 1.5$ (30 扩散步骤的 IPF 第 10 次迭代。从左到右: $t = 0, 0.4, 1.25, 1.5$ 。

二维示例 我们展示了多个经典二维数据集的数据集插值。




图 18: 数据集插值 (DSB 迭代 9)。从左至右: $t = 0, 0.15, 0.30, 0.5$ 。