

Sample from What You See: Visuomotor Policy Learning via Diffusion Bridge with Observation-Embedded Stochastic Differential Equation

Zhaoyang Liu^{1,2} Mokai Pan¹ Zhongyi Wang¹ Kaizhen Zhu¹ Haotao Lu¹ Haipeng Zhang¹ Jingya Wang¹
叶石^{1,2*}

摘要

基于扩散模型的模仿学习通过捕捉多模态动作分布推动了机器人控制的发展。然而，现有方法通常仅将观测作为去噪网络的高层条件，而未将其融入扩散过程本身的随机动力学中。因此，采样被迫从随机噪声开始，削弱了感知与控制之间的耦合，往往导致次优性能。本文提出桥接策略（BridgePolicy），一种生成式视觉运动策略，通过扩散桥接公式将观测直接整合到随机动力学中。通过构建观测信息轨迹，桥接策略使采样能够从丰富且信息量大的先验开始，而非随机噪声，从而显著提升控制的精确率与可靠性。一个关键难点在于，扩散桥通常连接维度匹配的分布，而机器人观测具有异构性，且与动作并非天然对齐。为克服此问题，本文引入语义对齐器以统一视觉与状态输入，并将观测与动作表示对齐，使扩散桥适用于异构机器人数据。在三个基准的 52 个仿真任务和 5 个真实世界任务上的大量实验表明，桥接策略始终优于最先进的生成式策略。代码见 https://jianghcsr.github.io/BridgePolicy_page/。

Diffusion Policy




图 1. 扩散策略与本文桥接策略的比较。桥接策略的观测建模方式使其采样能够从信息量大的先验开始，而非扩散策略中的随机噪声。

1. 引言

模仿学习（Imitation Learning）（Osa 等，2018）是机器人学习（Li 等，2024；Shafiullah 等，2023；Ze 等，2023b；Seo 等，2023；Fu 等，2024）中广泛采用的学习范式，其中机器人在获得一组专家演示后，学习模仿所提供的演示以有效执行任务。近年来，生成模型（Generative Model），如扩散模型（Diffusion Model）（Ho 等，2020；Song 等，2020b；Dhariwal 和 Nichol，2021；Ho 和 Salimans，2022）和流匹配（Flow Matching）（Lipman 等，2024；Liu 等，2022；Albergo 等，2023），因其能够捕捉多模态分布并学习时间依赖性而日益受到重视（Chi 等，2023；Ze 等，2023a；Zhang 等，2025）。这些方法遵循相似的原理：通过由随机或常微分方程（SDE/ODE）定义的前向过程将动作块扰动为随机噪声，然后训练一个以观测为条件的神经网络来逆转该过程，迭代地将噪声转化为可执行动作。

在此范式下，扩散策略（Diffusion Policy）（Chi 等，2023）和

¹ 上海科技大学，上海，中国 ²InstAdapt。通讯作者：叶石 <shiye@shanghaitech.edu.cn>。




图 2. 总体流程。桥接策略（BridgePolicy）通过扩散桥公式将观测显式嵌入扩散随机微分方程轨迹中。观测由机器人状态和点云组成。语义对齐器解决了异构分布桥接和数据形状不匹配的挑战，从而能够有效利用异构观测。在推理过程中，桥接策略从观测中采样，并通过快速采样迭代地将其转化为动作。

三维扩散策略（3D Diffusion Policy, Ze 等人, 2023a），即 DP 和 DP3，采用由随机微分方程（SDE）定义的前向过程，并在视觉输入和机器人状态的条件训练神经网络，以控制去噪过程，从而从随机噪声中采样动作。类似地，流策略（FlowPolicy, Zhang 等人, 2025）采用由常微分方程（ODE）定义的前向和逆向过程，减少了训练和推理过程中的随机性。尽管取得了成功，当前的生成式策略大多将观测视为去噪网络的高层条件信号（Chi 等人, 2023; Ze 等人, 2023a; Zhang 等人, 2025），而非将其整合到前向过程的动态中。这种利用不足迫使采样从无信息的随机噪声开始，削弱了感知与控制之间的耦合，往往导致次优性能。

扩散桥在图像复原和图像转换中已展现出显著的成功（De Bortoli 等人, 2021a; Yue 等人, 2023; Li 等人, 2023; Luo 等人, 2023; Zhou 等人, 2023），它修改了前向过程，使得终点分布自然地与标准扩散中期望的条件分布对齐。如图 1 所示，通过这种数学上精确的建模公式，

在前向过程中建模信息性观测，而非仅仅将观测视为外部条件，逆向过程可以从学习到的观测表示开始，这是一个更具信息量的先验，而非无信息的随机噪声，从而提高了生成动作的精确率。基于这些洞见，本文提出扩散桥也可以作为视觉运动策略学习的更有效框架。具体而言，本文不采用传统的扩散模型，而是将策略学习表述为学习扩散桥的问题，其中观测通过扩散桥框架（Zhu 等人, 2025; Pan 等人, 2025）被显式地建模到扩散随机微分方程轨迹本身中，而非纯粹将其视为条件，逆向过程将能够从观测的更具信息量的先验开始采样动作，而非从无信息的随机高斯噪声开始。这种更深层次的整合使策略能够更有效地利用观测，从而实现更精确和可靠的控制。

然而，将策略学习形式化为扩散桥带来了两个困难。首先，机器人观测与动作本质上是异构的，违反了标准

扩散桥假设，即所连接的端点分布具有相同的维度。其次，观测通常包括本体感受状态、RGB-D 视觉和语言指令，这些并不允许简单地将分布映射到经典桥公式所需的动作空间。因此，统一异构观测的表示并对齐观测与动作的形状，构成了使扩散桥适用于策略学习的关键挑战。我们提出了 BridgePolicy，一种生成式视觉运动策略，它直接从观测信息先验中采样动作，而非从随机噪声中采样。我们构建了一个扩散桥，将观测嵌入到扩散随机微分方程轨迹中，使模型能够充分利用感官输入，而不是仅将其用作外部条件。为了解决模态和形状不匹配问题，我们设计了一个语义对齐器，将观测表示映射到与动作对齐的潜空间中，确保桥的端点兼容。这些模块共同使扩散桥能够利用异构数据源进行策略学习。我们的贡献总结如下：

- 我们提出了 BridgePolicy，一种新颖的生成式视觉运动策略，通过扩散桥公式将观测显式嵌入到扩散随机微分方程轨迹中。这种观测信息随机微分方程轨迹允许采样从有意义的先验开始，而非从随机噪声开始，从而实现更精确和可靠的控制。
- 为了使扩散桥适用于异构机器人数据，我们引入了一个语义对齐器，统一视觉和状态观测，并将其表示与动作空间对齐。这解决了模态和形状不匹配问题，能够有效利用异构观测进行策略学习。
- 在涵盖三个基准的 52 个仿真任务和五个真实世界任务上的大量实验表明，BridgePolicy 始终优于先前的生成策略，达到了最先进的性能。

2. 相关工作

2.1. 机器人学习中的生成模型

扩散模型（Diffusion Model）凭借其在图像生成领域的成功，已成为最先进的生成模型（Song et al., 2020a; Rombach et al., 2022; Lipman et al., 2022）。由于具备多模态与长程建模能力，它们被广泛应用于强化学习（Janner et al., 2022; Ding et al., 2024; 2025）、模仿学习（Wu et al., 2024b; Pearce et al., 2023）以及运动规划（Reuss et al., 2023; Sridhar et al., 2023; Xian & Gkanatsios, 2023; Prasad et al., 2024; Saha et al., 2024）。在机器人领域，DP（Chi et al., 2023）与 DP3（Ze et al., 2024）采用扩散模型

作为生成框架，并在神经网络中以观测为条件，将随机噪声去噪为动作；而基于流的策略（Zhang et al., 2025; Hu et al., 2024）则使用流匹配框架。许多其他工作旨在消除对随机噪声的依赖，直接从观测生成动作。BRIDGER（Chen et al., 2024）首先训练一个粗略策略，然后采用扩散桥来细化动作，其性能在很大程度上取决于粗略策略的质量。另一项同期工作 VITA（Gao et al., 2025）采用两阶段流程。它在联合的潜在图像-动作空间中执行流匹配，可执行动作必须通过解码器恢复。本文通过扩散桥在扩散随机微分方程轨迹中对异构观测进行建模，并直接生成可执行动作。

2.2. 用于生成建模的扩散桥

扩散桥（Diffusion Bridge）能够在两个任意分布之间实现转换，而无需从随机噪声开始扩散过程，这为分布变换提供了一种更具原理性和数学精确性的生成范式。一方面，扩散薛定谔桥（Diffusion Schrödinger Bridge）（Liu 等，2023; Shi 等，2024; De Bortoli 等，2021b; Somnath 等，2023; Chen 等，2021; Deng 等，2024; Wang 等，2025）旨在通过求解两个分布之间的熵正则化最优传输问题来确定一个随机过程。然而，其高计算复杂度，尤其是在高维设置或约束条件下尤为突出，给直接优化带来了显著挑战。其他工作（Zhou 等，2023; Yue 等，2023）将杜布 h 变换引入正向随机微分方程（SDE），在图像复原基准上取得了显著性能。UniDB（Zhu 等，2025）通过基于随机最优控制（SOC）的优化问题重新表述扩散桥，证明杜布 h 变换是 SOC 理论的一个特例，从而统一并推广了现有基于 h 变换的扩散桥方法。在本文中，我们利用扩散桥连接异构分布的能力，具体而言是异构观测分布与专家策略的动作分布，并利用这一机制进行策略学习。

3. 基于扩散桥的策略学习

3.1. 桥接策略

现有策略学习框架（Chi 等人，2023; Ze 等人，2024; Zhang 等人，2025; Hu 等人，2024）旨在学习一个策略 $\pi: \mathcal{O} \rightarrow \mathcal{A}$ ，该策略根据观测 $\mathbf{o} \in \mathcal{O}$ 预测动作 $\mathbf{a} \in \mathcal{A}$ ，其中观测包括作为视觉输入的三维点云和机器人状态，动作被分块为完成任务轨迹的短序列。先前的工作如 DP3（Ze 等人，2024）和 FlowPolicy（Zhang

Algorithm 1 BridgePolicy Training

Input: Actions $\mathbf{a}$, Observations $\mathbf{o} = \{\mathbf{o}_s, \mathbf{o}_{pc}\}$, loss weight α , and gradient descent step size η .

repeat

$\mathbf{z}_s = \text{MLP}_{\phi_1}(\mathbf{o}_s)$, $\mathbf{z}_{pc} = \text{MLP}_{\phi_2}(\mathbf{o}_{pc})$

$\mathbf{z}_{obs} = \text{softmax}(\mathbf{z}_{pc} \cdot \mathbf{z}_s^T / \sqrt{d_s}) \mathbf{z}_s$

$\mathbf{a}_0 = \mathbf{a}$, $\mathbf{a}_T = \mathbf{z}_{obs}$

$t \sim \text{Uniform}(\{1, \dots, T\})$

Compute $\mathcal{L} = \mathcal{L}_{DB} + \alpha \mathcal{L}_{align}$

Update $(\theta, \phi_1, \phi_2) \leftarrow (\theta, \phi_1, \phi_2) - \eta \nabla \mathcal{L}$

until Converged

et al., 2025) 将策略表述为条件生成模型，其中动作在观测条件下由随机噪声生成 $\mathbf{o}$ (Chi et al., 2023; Ze et al., 2024; Zhang et al., 2025)。他们纯粹将信息性观测视为条件信号，以在去噪过程中引导神经网络。

桥接策略的前向过程。 受扩散桥 (Diffusion Bridge) 近期进展的启发 (Zhou 等, 2023; Yue 等, 2023; Zhu 等, 2025)，其中条件可以在前向扩散随机微分方程轨迹中被显式建模，我们直接将观测集成到扩散过程中，以生成更可控且更精确的机器人动作。在此，我们的 BridgePolicy 采用统一的扩散桥框架 (Zhu 等, 2025)，该框架在随机最优控制 (Stochastic Optimal Control, SOC) 理论下构建，作为核心学习范式。为与先前用于视觉运动策略学习的扩散符号保持一致 (Chi 等, 2023)，我们将 $\mathbf{a}_t$ 表示为时间 t 处的插值机器人动作状态。假设动作 $\mathbf{a}$ 与观测 $\mathbf{o}$ 具有相同维度，我们将前向扩散桥过程 (2) 的端点定义如下：

- 初始状态 $\mathbf{a}_0$ ：我们将初始状态设为动作，即 $\mathbf{a}_0 = \mathbf{a}$ 。
- 终端状态 $\mathbf{a}_T$ ：我们将终端状态设为观测，即 $\mathbf{a}_T = \mathbf{o}$ 。这是对标准基于扩散或基于流的策略的关键偏离，在那些策略中 $\mathbf{a}_T \sim \mathcal{N}(0, I)$ 通常是高斯噪声。

根据 UniDB (Zhu 等, 2025)，我们可以将扩散桥的前向过程构建为以下随机最优控制优化问题：

$$\begin{aligned} \min_{\mathbf{u}_{t,\gamma}} \mathbb{E} \left[\int_0^T \frac{1}{2} \|\mathbf{u}_{t,\gamma}\|_2^2 dt + \frac{\gamma}{2} \|\mathbf{a}_T^u - \mathbf{a}_T\|_2^2 \right] \\ \text{s.t. } d\mathbf{a}_t = [\theta_t(\mathbf{a}_T - \mathbf{a}_t) + g_t \mathbf{u}_{t,\gamma}] dt + g_t d\mathbf{w}_t, \mathbf{a}_0^u = \mathbf{a}_0, \end{aligned} \quad (1)$$

Algorithm 2 BridgePolicy Inference

Input: Observations $\mathbf{o} = \{\mathbf{o}_s, \mathbf{o}_{pc}\}$, pre-trained data prediction model $\mathbf{a}_\theta$, and $M + 1$ time steps $\{t_i\}_{i=0}^M$ decreasing from $t_0 = T$ to $t_M = 0$.

$\mathbf{z}_s = \text{MLP}_{\phi_1}(\mathbf{o}_s)$, $\mathbf{z}_{pc} = \text{MLP}_{\phi_2}(\mathbf{o}_{pc})$

Initialize $\mathbf{a}_T = \mathbf{z}_{obs} = \text{softmax}(\mathbf{z}_{pc} \cdot \mathbf{z}_s^T / \sqrt{d_s}) \mathbf{z}_s$

for $i = 1$ **to** M **do**

Sample $\epsilon \sim \mathcal{N}(0, I)$ if $i < M$, else $\epsilon = 0$

$\mathbf{a}_{t_i} \leftarrow \text{Update}(\mathbf{a}_{t_{i-1}}, \mathbf{a}_T, \mathbf{a}_\theta, \epsilon, t_{i-1})$ from (4)

end for

Return Actions $\mathbf{a}$

其中 $\mathbf{a}_0^u$ 和 $\mathbf{a}_T^u$ 是受控端点，以区别于预定义端点， θ_t 和 g_t 是标量值函数，满足关系 $g_t^2 = 2\lambda^2\theta_t$ ，稳态方差水平 λ^2 为给定常数， $\mathbf{w}_t$ 表示维纳过程， $\|\mathbf{u}_{t,\gamma}\|_2^2$ 是轨迹代价， $\frac{\gamma}{2} \|\mathbf{a}_T^u - \mathbf{a}_T\|_2^2$ 是终端代价，其惩罚系数为 γ 。随机最优控制问题 (1) 旨在设计最优控制器 $\mathbf{u}_{t,\gamma}^*$ ，以最小代价驱动动态系统从 $\mathbf{a}_0$ 到 $\mathbf{a}_T$ 。UniDB 解决了问题 (1)，并获得了闭式最优控制前向随机微分方程，将 $\mathbf{a}_0$ 转换为 $\mathbf{a}_T$ ：

$$d\mathbf{a}_t = \left(\theta_t + \frac{g_t^2 e^{-2\bar{\theta}_{t:T}}}{\gamma^{-1} + \bar{\sigma}_{t:T}^2} \right) (\mathbf{a}_T - \mathbf{a}_t) dt + g_t d\mathbf{w}_t, \quad (2)$$

其中 $\bar{\theta}_{s:t} = \int_s^t \theta_z dz$ ， $\bar{\theta}_t = \int_0^t \theta_z dz$ ， $\bar{\sigma}_{s:t}^2 = \lambda^2(1 - e^{-2\bar{\theta}_{s:t}})$ ，且 $\bar{\sigma}_t^2 = \lambda^2(1 - e^{-2\bar{\theta}_t})$ 。通过扩散桥范式，我们成功构建了从动作 $\mathbf{a}_0 = \mathbf{a}$ 到观测 $\mathbf{a}_T = \mathbf{o}$ 的映射。

BridgePolicy 的训练目标。 为了学习这样的桥以逆转过程，我们采用以下重建训练目标来训练一个数据预测神经网络 $\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)$ ，该网络直接将任意 $\mathbf{a}_t$ 映射到干净动作 $\mathbf{a}_0$ ：

$$\mathcal{L}_{DB} = \mathbb{E}_{t,\mathbf{a},\mathbf{a}_T,\mathbf{a}_t} [\|\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t) - \mathbf{a}\|], \quad (3)$$

其中我们遵循 UniDB (Zhu 等人, 2025) 中关于范数顺序的 l_1 范数，并在附录中给出消融实验。因此，BridgePolicy 自然地在随机微分方程轨迹和神经网络中整合了信息性观测 $\mathbf{a}_T = \mathbf{o}$ ，旨在学习一条随机轨迹，将观测 $\mathbf{o}$ 转化为合理的动作 $\mathbf{a}$ 。

BridgePolicy 的采样算法。 在获得最优模型 $\mathbf{a}^*$ 之后，决策模块 $(\mathbf{a}_t, \mathbf{a}_T, t)$ 我们的 BridgePolicy 可以实现为一个从给定观测开始的迭代生成过程。对于专门设计的求解器，UniDB++ (Pan

等人, 2025) 提供了一种免训练的加速算法, 利用数据预测 $\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)$ 直接估计固定且平滑的目标 $\mathbf{a}_0$ 。借助 UniDB++ 中的一些记号 $\rho_t = e^{\bar{\theta}_t}(1 - e^{-2\bar{\theta}_t})$, $\kappa_{t,\gamma} = e^{\bar{\theta}_{t:T}}((\gamma\lambda^2)^{-1} + 1 - e^{-2\bar{\theta}_{t:T}})$, $c_1 = (\gamma\lambda^2)^{-1}e^{2\bar{\theta}_T}$, $c_2 = e^{2\bar{\theta}_T} - 1$, $D = 2c_1c_2/(c_1 + c_2)^3$, $E = c_2^2/(c_1 + c_2)^2$ 和 $F = c_1^2/(c_1 + c_2)^2$, 从时间步 t 到 s 的闭式更新规则形如

$$\begin{aligned} \mathbf{a}_t &= \frac{\kappa_{t,\gamma}\kappa_s\rho_t}{\kappa_{s,\gamma}\kappa_t\rho_s}\mathbf{a}_s + \left(\frac{\kappa_{t,\gamma}}{\kappa_{0,\gamma}} - \frac{\kappa_{t,\gamma}\rho_t\kappa_s}{\kappa_{0,\gamma}\kappa_t\rho_s}\right)\mathbf{a}_\theta(\mathbf{a}_s, \mathbf{a}_T, s) \\ &\quad + \left(1 - \frac{\kappa_{t,\gamma}\kappa_s\rho_t}{\kappa_{s,\gamma}\kappa_t\rho_s} + \frac{\kappa_{t,\gamma}\rho_t\kappa_s}{\kappa_{0,\gamma}\kappa_t\rho_s} - \frac{\kappa_{t,\gamma}}{\kappa_{0,\gamma}}\right)\mathbf{a}_T + \delta_{s:t}^d\epsilon, \\ (\delta_{s:t}^d)^2 &= \frac{\lambda^2\kappa_{t,\gamma}^2\rho_t^2}{\kappa_t^2} \left[E \frac{e^{2\bar{\theta}_s} - e^{2\bar{\theta}_t}}{(e^{2\bar{\theta}_t} - 1)(e^{2\bar{\theta}_s} - 1)} \right. \\ &\quad \left. + D \log \frac{\kappa_{s,\gamma}\rho_t}{\kappa_{t,\gamma}\rho_s} - F \left(\frac{e^{-\bar{\theta}_T - \bar{\theta}_t}}{\kappa_{t,\gamma}} - \frac{e^{-\bar{\theta}_T - \bar{\theta}_s}}{\kappa_{s,\gamma}} \right) \right], \end{aligned} \quad (4)$$

其中 $\epsilon \sim \mathcal{N}(0, I)$ 为高斯噪声。尽管更新规则在 $\mathbf{a}_s$ 、 $\mathbf{a}_T$ 、 $\mathbf{a}_\theta$ 和 ϵ 的系数上看似十分复杂, 实际上这些系数可以显式计算, 且不会带来显著的计算开销, 因为它们具有闭式解, 并且仅依赖于特定的时间步。

3.2. 模态融合与对齐

尽管在统一维度假设下这一概念颇具吸引力, 直接应用扩散桥范式仍然不可行, 因为这种假设在实践中很少成立。该方法仍面临异构分布桥接和数据形状不匹配的挑战, 这阻碍了扩散桥作为策略学习方法的有效运作。为解决这些局限性, 本文提出一种新颖的框架, 通过精心设计的编码与融合流程, 有效桥接异构模态。

机器人状态与点云编码。 本文的编码流程首先将深度图像转换为三维点云, 这一选择出于效率考虑。随后, 使用最远点采样 (Farthest Point Sampling, Qi 等人, 2017) 对点云进行下采样 (仿真中为 512 或 1024 个点; 真实环境中为 2048 个点)。最后, 一个带有层归一化 (LayerNorm) 的轻量级多层感知机 (MLP) 和一个 MLP 状态编码器将点云和机器人状态映射到共享的潜在表示中以供融合, 其公式化表示为:

$$\mathbf{z}_s = \text{MLP}_{\phi_1}(\mathbf{o}_s), \quad \mathbf{z}_{pc} = \text{MLP}_{\phi_2}(\mathbf{o}_{pc}), \quad (5)$$

其中 ϕ_1 和 ϕ_2 为多层感知机网络参数, $\mathbf{o}_s$ 为机器人状态, $\mathbf{o}_{pc}$ 表示点云。

多模态融合。 为使扩散桥能够在异构模态之间有效映射, 本文引入多模态融合模块, 该模块整合了

三维点云与机器人状态融合为统一表示。这使得策略能够在我们的框架内连贯地处理多样化输入。具体而言, 我们采用交叉注意力机制 (Cross-Attention Mechanism) 来融合模态:

$$\mathbf{a}_T := \mathbf{z}_{obs} = \text{softmax}\left(\frac{\mathbf{z}_{pc}\mathbf{z}_s^T}{\sqrt{d_s}}\right)\mathbf{z}_s, \quad (6)$$

其中 $\mathbf{z}_s$ 表示机器人状态的特征向量, d_s 是 $\mathbf{z}_s$ 的维度, $\mathbf{z}_{pc}$ 表示视觉输入的特征向量。此处, $\mathbf{a}_T = \mathbf{z}_{obs}$ 是与动作块形状相同的统一观测特征向量, 代表统一观测表示。

我们认识到扩散桥的终端状态 $\mathbf{a}_T$ 是从学习到的多层感知机 (MLP) 并通过式 (5) 和式 (6) 融合得到的观测表示 $\mathbf{z}_{obs}$, 若编码器映射存在误差, 则可能在生成动作 $\tilde{\mathbf{a}}_0$ 中引入误差。然而, 我们证明生成动作的偏差不会过大, 由此引出以下定理:

定理 3.1. 给定初始值 $\mathbf{a}_T$ 及数据预测网络 $\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)$ 的假设 B.1。假设 $\tilde{\mathbf{a}}_T$ 是 $\mathbf{a}_T$ 的扰动初始值, 且采样过程中的噪声 ϵ 相同, 则有

$$\|\tilde{\mathbf{a}}_0 - \mathbf{a}_0\| \leq C\|\tilde{\mathbf{a}}_T - \mathbf{a}_T\| \quad (7)$$

其中 $C > 0$ 为常数, $\mathbf{a}_0$ 和 $\tilde{\mathbf{a}}_0$ 分别由 $\mathbf{a}_T$ 和 $\tilde{\mathbf{a}}_T$ 通过更新规则式 (4) 生成。

详细证明请参见附录 B。定理 3.1 表明动作输出的误差可由观测多层感知机的误差线性界定。由于 C 难以解析确定, 我们在附录 B 中提供实验结果以经验估计 C 的大小。在我们的实验中, C 的量级很小, 约为 10^{-2} 至 10^{-3} 。因此, 即使观测多层感知机存在拟合误差, 由扩散桥采样算法生成的动作也将被限制在较窄范围内, 避免显著偏差。

模态对齐。 尽管多模态融合在形状上对齐了观测与动作分布, 但仍存在显著的分布差异, 且学习到的观测表示缺乏采样能力。为解决此问题, 我们提出使用对比学习损失来训练对齐器。对比损失对齐观测与动作分布的语义邻近性。具体而言, 我们采用 CLIP 损失 (Radford 等人, 2021) 作为对比学习损失:

$$\begin{aligned} \mathcal{L}_{align} &= \mathcal{L}_{clip}(\mathbf{a}, \mathbf{z}_{obs}) + \mathcal{L}_{clip}(\mathbf{z}_{obs}, \mathbf{a}), \\ \mathcal{L}_{clip}(\mathbf{x}, \mathbf{y}) &= -\frac{1}{n} \sum_{j=1}^n \log \frac{\exp(x_j^\top y_j / \tau)}{\sum_{i=1}^n \exp(x_i^\top y_j / \tau)}, \end{aligned} \quad (8)$$

表 1. 主要仿真结果。基线方法与本文 BridgePolicy 在成功率上的定量比较。我们在 3 个基准上评估 52 项任务，并报告每个基准的平均成功率。对于 MetaWorld，我们根据任务难度进行分组，并报告平均成功率。

Methods\Task	MetaWorld Easy	MetaWorld Medium	MetaWorld Hard	MetaWorld Very Hard	DexArt	Adroit	Average
DP	0.79±0.02	0.31±0.04	0.10±0.03	0.26±0.02	0.45±0.06	0.31±0.03	0.37
DP3	0.87±0.01	0.61±0.03	0.40±0.05	0.51±0.02	0.57±0.06	0.68±0.04	0.60
Simple DP3	0.86±0.02	0.59±0.04	0.38±0.04	0.47±0.03	0.48±0.05	0.68±0.02	0.58
FlowPolicy	0.86±0.02	0.67±0.02	0.59±0.02	0.76±0.02	0.54±0.05	0.70±0.04	0.68
VITA	0.85±0.03	0.58±0.03	0.48±0.03	0.62±0.04	0.55±0.04	0.77±0.03	0.64
BridgePolicy (Ours)	0.91±0.03	0.75±0.03	0.58±0.02	0.79±0.02	0.60±0.05	0.81±0.04	0.74




图 3. 真实机器人对比可视化：DP3、FlowPolicy 与 BridgePolicy 在烤箱开启任务四个关键路径点上的表现。

其中 n 为批大小， τ 为温度参数。整个模型包含扩散桥与模态融合模块，因此总体训练目标将扩散桥损失 (3) 与对齐损失 (8) 相结合：

$$\mathcal{L} = \mathcal{L}_{DB} + \alpha \mathcal{L}_{align}, \quad (9)$$

其中 α 为正权重。我们提供伪代码算法 1 和算法 2，分别描述 BridgePolicy 的训练与推理过程。在训练阶段，观测首先由模态融合模块与对齐器进行融合和重塑，然后根据相应方程计算对齐损失与扩散桥损失。训练完成后，观测被融合为潜向量集，作为采样过程的起点。该潜向量随后通过设计的求解器 (4) 迭代更新，最终生成动作。

4. 实验

4.1. 仿真实验

仿真基准。在仿真任务中，我们在三个基准上评估 BridgePolicy，共涉及 52 项任务，

包括 Adroit (Rajeswaran 等人, 2017)、DexArt (Bao 等人, 2023) 和 MetaWorld (Yu 等人, 2020)。Adroit 和 DexArt 专注于具有不同复杂度的灵巧手操作，而 MetaWorld 提供了跨不同难度级别的广泛机械臂任务。这三个基准上的任务示例如图 5 所示。

专家演示收集。本文在 MetaWorld 中使用脚本策略收集专家数据，并分别采用 VRL3 (Wang 等人, 2022) 和 PPO (Schulman 等人, 2017) 这两种强化学习 (Reinforcement Learning, RL) 算法为 Adroit 和 DexArt 收集专家数据。本文为 Adroit 和 MetaWorld 基准的任务收集了 10 个回合，为 DexArt 基准收集了 100 个回合以训练策略。

基线。为了进行比较，本文选择了最先进的基于 2D 的方法 DP (Chi 等人, 2023)，该方法以 2D 图像作为视觉输入，以及基于 3D 条件扩散或流的方法，包括 DP3 (Ze 等人, 2024)、简单 DP3 (其轻量级版本)、FlowPolicy (Zhang 等人, 2025) 和 VITA (Gao 等人, 2025)，这些方法从随机高斯噪声生成动作，并在神经网络中利用 3D 点云作为视觉条件，作为基线。本文将函数评估次数 (NFE) 设置为 10

表 2. 主要真实世界结果。基线与 BridgePolicy 在真实世界任务上的成功率定量比较。

Method	Oven-Closing	Oven-Opening	Pick Place	Pour	Unplug	Average
Simple DP3	0.8	0.6	0.6	0.6	0.7	0.66
DP3	0.9	0.9	0.7	0.6	0.7	0.76
FlowPolicy	1.0	0.7	0.5	0.1	0.5	0.56
BridgePolicy	1.0	1.0	0.8	0.8	0.9	0.90

表 3. 不同模态融合方法的定量评估结果（成功率）（表中 MetaWorld 记为 MW）。

Task	Modality Fusion Method	
	Concatenation	Cross-Attention
Adroit Pen	0.78	0.81
Adroit Door	0.59	0.665
MW Handle-Pull	0.55	0.63

对于除 FlowPolicy 外的所有基线。根据原始 FlowPolicy 论文中的设置，本文将其 NFE 设置为 1 而不是 10，以避免一致性流匹配（Sabour 等人，2025）多步采样中出现的误差累积问题。有关 NFE 设置的更多细节，请参阅附录 E.2。

评估与实现。继 DP3（Ze 等，2024）和 FlowPolicy（Zhang 等，2025）之后，我们为每个任务运行 3 个随机种子。对于每个随机种子，我们训练模型 3000 个训练轮次，并每 200 个训练轮次在 20 个回合上评估成功率。我们选取每个种子最高的五个成功率，并报告 3 个随机种子的平均成功率。为了公平比较，我们保持模型架构与基线一致，参数量相当，并共享超参数，如学习率、优化器的权重衰减、批大小和训练轮次。对于每个任务，BridgePolicy 在单个 NVIDIA RTX 4090 GPU 上训练。有关 BridgePolicy 和其他基线实现的更多细节，请参阅附录 D。

仿真器中的性能。对于 Adroit 和 DexArt，我们直接报告平均成功率。特别是对于 MetaWorld 任务，进一步分为四个难度级别，并报告每个级别的平均成功率。定量结果报告在表 1 中。我们提出的 BridgePolicy 在所有评估基准上表现出一致的性能，达到了最高的平均成功率。所有基线方法的成功率都显著较低，特别是在更具挑战性的设置中（MetaWorld 中的困难和非常困难），这也展示了我们的方法在具有不同复杂度的任务中的鲁棒性。这些结果验证了 BridgePolicy 在利用扩散桥公式改进仿真环境中策略学习方面的有效性。VITA 的性能介于 DP3 和 FlowPolicy 之间，可能是因为流

表 4. 不同 Adroit 任务在不同损失权重 α 下的定量评估结果（成功率）。

Task	Loss weights α				
	0.0	0.5	1.0	2.0	5.0
Adroit Door	0.79	0.83	0.84	0.84	0.80
DexArt Laptop	0.85	0.86	0.91	0.86	0.89
MW Coffee-Push	0.91	0.99	0.91	0.91	0.92
MW Pick-Place-Wall	0.88	0.93	0.96	0.87	0.83

匹配是在联合图像-动作潜空间中执行的，而可执行动作是通过解码器获得的，这不可避免地会引入泛化误差。有关各个任务详细成功率的说明，请参阅附录 F.5。

4.2. 真实世界实验

实验设置与评估。本文使用弗兰卡·艾米卡熊猫机器人（Franka Emika Panda Robot）在 5 个真实世界任务上评估桥接策略（BridgePolicy）。点云通过 ZED-2i 相机获取。本文在每个任务的 10 个回合上评估策略。实现方式与仿真实验保持一致。本文仅将点云的点数增加到 2048，以更密集地表示真实世界场景。真实世界任务的示例见图 6。真实世界实验环境设置的详细信息见附录 C。

专家演示收集。专家演示通过 GELLO 人类遥操作系统（Wu 等人，2024a）收集，由一名经验丰富的研究生操作。对于每个任务，本文收集 50 个回合来训练策略。类似地，在仿真器中，为了公平比较，提供给所有基线方法和本文桥接策略的专家演示是相同的。真实世界数据收集的详细信息见附录 C。

真实世界任务的定量比较。真实世界任务的成功率见表 2。在使用相同的 50 个回合数据集进行训练的相同约束下，本文的桥接策略在所有任务上取得了最高的成功率，平均为 0.9，凸显了其有效性。同时，流策略（FlowPolicy）在需要位置泛化的任务（如倾倒和拾取放置）上，在真实世界中表现出显著的性能下降。DP3 以 0.78 的成功率位居第二，而简单 DP3 仅达到 0.65 的成功率，可能




图 4. 关于演示次数的消融实验。桥接策略在较少的训练演示下表现出优越性。




图 5. 仿真任务示例。

due to the small number of parameters.

真实世界任务的定性比较。

Three real-world examples of Oven-Opening and Unplug generated by DP3, FlowPolicy, and BridgePolicy are shown in in 图 3 和图 14. 该序列展示了 Franka 完成任务的关键帧。烤箱开启任务包含两个关键阶段：1) 抓住烤箱把手并将其半开；2) 将机械臂移动到半开的门上并向下按压，直至完全打开。在烤箱开启任务中，DP3 未能完成任务，而 FlowPolicy 和 BridgePolicy 成功完成。BridgePolicy 精确完成了两个阶段并完全打开了烤箱，而 FlowPolicy 在第一阶段未能将门半开，而是直接按压把手，导致门未完全打开。我们在图 14 所示的拔插头任务中也观察到类似结果。DP3 和 FlowPolicy 将夹爪伸向目标位置，但未能精确夹住插座，因此未能成功拔出。而 BridgePolicy 成功夹住插头并将其拔出。真实世界实验的视频见补充材料。

4.3. 消融实验

本节分析 BridgePolicy 在不同超参数设置下的性能。更多消融实验见附录 F。

样本效率。 智能体完成任务的成功率在很大程度上取决于专家演示的数量。在此，我们评估专家演示数量如何影响智能体完成任务的成功率。




图 6. 真实世界任务示例。

如图 4 所示，我们为本次消融实验选择了四个任务：MetaWorld Hand-Pull-Side、Pick Place、Stick Pull 和 Adroit Pen 任务。对于所有四个任务，增加专家演示数量通常会提高智能体的成功率。BridgePolicy 在所有评估任务中，在不同演示数量下均表现出最稳定和鲁棒的性能，尤其是在训练样本较少时。更多样本效率消融实验见附录 F 节。

参数敏感性。 本文展示了桥接策略 (BridgePolicy) 关键参数如何影响其性能。具体而言，本文评估了总体训练损失 (9) 中不同权重 α 的影响，结果如表 4 所示。结果表明，在策略学习中使用相对较小的权重可以更好地训练分布对齐器。更多关于超参数的消融实验结果见附录 F。

模态融合。 本文进一步探索了不同的




图 7. 真实机器人对比可视化：DP3、FlowPolicy 和 BridgePolicy 在拾取与放置任务中四个关键五个点的表现。

表 5. 定量评估结果（成功率），用于评估 BridgePolicy 中扩散桥的有效性。

Task	Policy Head		
	Regression	Diffusion	Bridge
Adroit Pen	0.33	0.43	0.58
Adroit Door	0.00	0.68	0.84
DexArt Laptop	0.16	0.86	0.88
DexArt Faucet	0.00	0.37	0.39
MW Basketball	0.00	0.96	1.00
MW Coffee Pull	0.00	0.86	0.97

观测模态融合方式。模态融合在解决策略学习中观测的多模态特性与扩散桥分布映射之间的冲突方面起着关键作用。本文探索了两种模态融合方法——交叉注意力（Cross-Attention）（Lin 等人，2022）和简单拼接——对性能的影响。结果如表 3 所示。当从交叉注意力切换到简单拼接时，在三个评估任务上的性能均持续下降，这证明了使用交叉注意力的有效性。

扩散桥的有效性。本文评估了扩散桥（Diffusion Bridge）公式相较于标准扩散（Diffusion）和回归（Regression）的有效性。本文保持对齐器和模态融合不变，并使用不同的策略头输出动作。结果如表 5 所示。回归未能有效表现，通常崩溃至接近零成功率。标准扩散相较于回归显著提升了性能。扩散桥获得了最高的成功率，表明其公式提供了更好的条件生成过程，并产生更精确的动作。

5. 结论与局限性

本文提出桥接策略（BridgePolicy），一种新颖的生成式策略学习范式，通过扩散桥接公式将观测直接嵌入扩散随机微分方程轨迹中，而非像传统生成式策略那样仅将其视为去噪网络中的高层条件。这种观测信息驱动的随机微分方程使采样能够从丰富且有意义的先验开始，使策略能更有效地利用观测，从而实现更精确、更可靠的控制。桥接策略不仅超越了当前最先进的生成式策略，还将扩散桥接的应用扩展到多模态和异构分布匹配。在仿真和真实世界任务上的大量实验证明了其相对于现有生成式策略的优越性。尽管桥接策略超越了当前最先进的生成式策略，但其采样仍受其随机微分方程公式的限制，这限制了应用可实现一步生成的蒸馏方法的可能性。

致谢

本工作得到了国家自然科学基金（62303319、62406195）、上海市地方高校能力建设计划（23010503100）、上海科技大学人工智能赋能科学计划（SHTAI4S202404）、上海科技大学高性能计算平台、教育部智能感知与人机协同重点实验室（上海科技大学）以及上海市智能视觉与成像工程研究中心的支持。本工作还部分得到了上海飞云科技有限公司提供的计算资源的支持。

影响声明

本文所呈现的工作旨在推动机器学习领域的发展。我们的工作可能带来诸多潜在的社会影响，但在此无需特别强调其中任何一项。

参考文献

- Albergo, M. S., Boffi, N. M., and Vanden-Eijnden, E. Stochastic interpolants: A unifying framework for flows and diffusions. *arXiv preprint arXiv:2303.08797*, 2023.
- Bao, C., Xu, H., Qin, Y., and Wang, X. Dexart: Benchmarking generalizable dexterous manipulation with articulated objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pp. 21190–21200, 2023.
- Chen, K., Lim, E., Lin, K., Chen, Y., and Soh, H. Don’t start from scratch: Behavioral refinement via interpolant-based policy diffusion. *arXiv preprint arXiv:2402.16075*, 2024.
- Chen, T., Liu, G.-H., and Theodorou, E. A. Likelihood training of schrödinger bridge using forward-backward sdes theory. *arXiv preprint arXiv:2110.11291*, 2021.
- Chi, C., Xu, Z., Feng, S., Cousineau, E., Du, Y., Burchfiel, B., Tedrake, R., and Song, S. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, pp. 02783649241273668, 2023.
- De Bortoli, V., Thornton, J., Heng, J., and Doucet, A. Diffusion schrödinger bridge with applications to score-based generative modeling. *Advances in neural information processing systems*, 34:17695–17709, 2021a.
- De Bortoli, V., Thornton, J., Heng, J., and Doucet, A. Diffusion schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34:17695–17709, 2021b.
- Deng, W., Luo, W., Tan, Y., Bilos, M., Chen, Y., Nevmyvaka, Y., and Chen, R. T. Variational schrödinger diffusion models. *arXiv preprint arXiv:2405.04795*, 2024.
- Dhariwal, P. and Nichol, A. Diffusion models beat gans on image synthesis. *Advances in neural information processing systems*, 34:8780–8794, 2021.
- Ding, S., Hu, K., Zhang, Z., Ren, K., Zhang, W., Yu, J., Wang, J., and Shi, Y. Diffusion-based Reinforcement Learning via Q-weighted Variational Policy Optimization. In *Advances in Neural Information Processing Systems*, 2024.
- Ding, S., Hu, K., Zhong, S., Luo, H., Zhang, W., Wang, J., Wang, J., and Shi, Y. Genpo: Generative diffusion models meet on-policy reinforcement learning. *Advances in neural information processing systems*, 2025.
- Fu, Z., Zhao, T. Z., and Finn, C. Mobile aloha: Learning bimanual mobile manipulation with low-cost whole-body teleoperation. *arXiv preprint arXiv:2401.02117*, 2024.
- Gao, D., Zhao, B., Lee, A., Chuang, I., Zhou, H., Wang, H., Zhao, Z., Zhang, J., and Soltani, I. Vita: Vision-to-action flow matching policy. *arXiv preprint arXiv:2507.13231*, 2025.
- Han, M., Wang, L., Xiao, L., Zhang, H., Zhang, C., Xu, X., and Zhu, J. Quickfps: Architecture and algorithm co-design for farthest point sampling in large-scale point clouds. *IEEE Transactions on Computer-Aided Design of Integrated Circuits and Systems*, 2023.
- Ho, J. and Salimans, T. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- Ho, J., Jain, A., and Abbeel, P. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- Hu, X., Liu, Q., Liu, X., and Liu, B. AdafLOW: Imitation learning with variance-adaptive flow-based policies. *Advances in Neural Information Processing Systems*, 37:138836–138858, 2024.
- Janner, M., Du, Y., Tenenbaum, J. B., and Levine, S. Planning with diffusion for flexible behavior synthesis. *arXiv preprint arXiv:2205.09991*, 2022.
- Li, B., Xue, K., Liu, B., and Lai, Y.-K. BbDM: Image-to-image translation with brownian bridge diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern Recognition*, pp. 1952–1961, 2023.
- Li, S., Wang, X., Zuo, R., Sun, K., Cui, L., Ding, J., Liu, P., and Ma, Z. Robust visual imitation learning with inverse dynamics representations. In *Proceedings of the AAAI Conference on Artificial Intelligence*, 2024.
- Lin, H., Cheng, X., Wu, X., and Shen, D. Cat: Cross attention in vision transformer. In *2022 IEEE international conference on multimedia and expo (ICME)*, pp. 1–6. IEEE, 2022.
- Lipman, Y., Chen, R. T., Ben-Hamu, H., Nickel, M., and Le, M. Flow Matching for Generative Modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- Lipman, Y., Havasi, M., Holderrieth, P., Shaul, N., Le, M., Karrer, B., Chen, R. T., Lopez-Paz, D., Ben-Hamu, H., and Gat, I. Flow matching guide and code. *arXiv preprint arXiv:2412.06264*, 2024.

- Liu, G.-H., Vahdat, A., Huang, D.-A., Theodorou, E. A., Nie, W., and Anandkumar, A. I2sb: Image-to-image schrödinger bridge. *arXiv preprint arXiv:2302.05872*, 2023.
- Liu, X., Gong, C., and Liu, Q. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.
- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., and Zhu, J. Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps. *Advances in neural information processing systems*, 35:5775–5787, 2022.
- Lu, C., Zhou, Y., Bao, F., Chen, J., Li, C., and Zhu, J. Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models. *Machine Intelligence Research*, pp. 1–22, 2025.
- Luo, Z., Gustafsson, F. K., Zhao, Z., Sjölund, J., and Schön, T. B. Image restoration with mean-reverting stochastic differential equations. *arXiv preprint arXiv:2301.11699*, 2023.
- Osa, T., Pajarinen, J., Neumann, G., Bagnell, J. A., Abbeel, P., Peters, J., et al. An algorithmic perspective on imitation learning. *Foundations and Trends® in Robotics*, 7 (1-2):1–179, 2018.
- Pan, M., Zhu, K., Ma, Y., Fu, Y., Yu, J., Wang, J., and Shi, Y. Unidb++: Fast sampling of unified diffusion bridge. *arXiv e-prints*, pp. arXiv–2505, 2025.
- Pearce, T., Rashid, T., Kanervisto, A., Bignell, D., Sun, M., Georgescu, R., Macua, S. V., Tan, S. Z., Momennejad, I., Hofmann, K., et al. Imitating human behaviour with diffusion models. *arXiv preprint arXiv:2301.10677*, 2023.
- Prasad, A., Lin, K., Wu, J., Zhou, L., and Bohg, J. Consistency policy: Accelerated visuomotor policies via consistency distillation. *arXiv preprint arXiv:2405.07503*, 2024.
- Qi, C. R., Su, H., Mo, K., and Guibas, L. J. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp. 652–660, 2017.
- Radford, A., Kim, J. W., Hallacy, C., Ramesh, A., Goh, G., Agarwal, S., Sastry, G., Askell, A., Mishkin, P., Clark, J., et al. Learning transferable visual models from natural language supervision. In *International conference on machine learning*, pp. 8748–8763. PmLR, 2021.
- Rajeswaran, A., Kumar, V., Gupta, A., Vezzani, G., Schulman, J., Todorov, E., and Levine, S. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. *arXiv preprint arXiv:1709.10087*, 2017.
- Reuss, M., Li, M., Jia, X., and Lioutikov, R. Goal-conditioned imitation learning using score-based diffusion policies. *arXiv preprint arXiv:2304.02532*, 2023.
- Rombach, R., Blattmann, A., Lorenz, D., Esser, P., and Ommer, B. High-resolution image synthesis with latent diffusion models. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pp. 10684–10695, 2022.
- Sabour, A., Fidler, S., and Kreis, K. Align your flow: Scaling continuous-time flow map distillation. *arXiv preprint arXiv:2506.14603*, 2025.
- Saha, K., Mandadi, V., Reddy, J., Srikanth, A., Agarwal, A., Sen, B., Singh, A., and Krishna, M. Edmp: Ensemble-of-costs-guided diffusion for motion planning. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pp. 10351–10358. IEEE, 2024.
- Schulman, J., Wolski, F., Dhariwal, P., Radford, A., and Klimov, O. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- Seo, M., Han, S., Sim, K., Bang, S. H., Gonzalez, C., Sentis, L., and Zhu, Y. Deep imitation learning for humanoid loco-manipulation through human teleoperation. In *2023 IEEE-RAS 22nd International Conference on Humanoid Robots (Humanoids)*, pp. 1–8. IEEE, 2023.
- Shafiuallah, N. M. M., Rai, A., Etukuru, H., Liu, Y., Misra, I., Chintala, S., and Pinto, L. On bringing robots home. *arXiv preprint arXiv:2311.16098*, 2023.
- Shi, Y., De Bortoli, V., Campbell, A., and Doucet, A. Diffusion schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 36, 2024.
- Somnath, V. R., Pariset, M., Hsieh, Y.-P., Martinez, M. R., Krause, A., and Bunne, C. Aligned diffusion schrödinger bridges. In *Uncertainty in Artificial Intelligence*, pp. 1985–1995. PMLR, 2023.
- Song, J., Meng, C., and Ermon, S. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020a.
- Song, Y., Sohl-Dickstein, J., Kingma, D. P., Kumar, A., Ermon, S., and Poole, B. Score-based Generative Modeling Through Stochastic Differential Equations. *arXiv preprint arXiv:2011.13456*, 2020b.
- Sridhar, K., Dutta, S., Jayaraman, D., Weimer, J., and Lee, I. Memory-consistent neural networks for imitation learning. *arXiv preprint arXiv:2310.06171*, 2023.

- Wang, C., Luo, X., Ross, K., and Li, D. Vrl3: A data-driven framework for visual deep reinforcement learning. *Advances in Neural Information Processing Systems*, 35: 32974–32988, 2022.
- Wang, Y., Yoon, S., Jin, P., Tivnan, M., Song, S., Chen, Z., Hu, R., Zhang, L., Li, Q., Chen, Z., et al. Implicit image-to-image schrödinger bridge for image restoration. *Pattern Recognition*, 165:111627, 2025.
- Wu, P., Shentu, Y., Yi, Z., Lin, X., and Abbeel, P. Gello: A general, low-cost, and intuitive teleoperation framework for robot manipulators. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pp. 12156–12163. IEEE, 2024a.
- Wu, S., Zhu, Y., Huang, Y., Zhu, K., Gu, J., Yu, J., Shi, Y., and Wang, J. AffordDP: Generalizable Diffusion Policy with Transferable Affordance. *arXiv preprint arXiv:2412.03142*, 2024b.
- Xian, Z. and Gkanatsios, N. Chaineddiffuser: Unifying trajectory diffusion and keypose prediction for robotic manipulation. In *Conference on Robot Learning/Proceedings of Machine Learning Research*. Proceedings of Machine Learning Research, 2023.
- Yu, T., Quillen, D., He, Z., Julian, R., Hausman, K., Finn, C., and Levine, S. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pp. 1094–1100. PMLR, 2020.
- Yue, C., Peng, Z., Ma, J., Du, S., Wei, P., and Zhang, D. Image restoration through generalized ornstein-uhlenbeck bridge. *arXiv preprint arXiv:2312.10299*, 2023.
- Ze, Y., Hansen, N., Chen, Y., Jain, M., and Wang, X. Visual reinforcement learning with self-supervised 3d representations. *IEEE Robotics and Automation Letters*, 8(5): 2890–2897, 2023a.
- Ze, Y., Yan, G., Wu, Y.-H., Macaluso, A., Ge, Y., Ye, J., Hansen, N., Li, L. E., and Wang, X. Gnfactor: Multi-task real robot learning with generalizable neural feature fields. In *Conference on robot learning*, pp. 284–301. PMLR, 2023b.
- Ze, Y., Zhang, G., Zhang, K., Hu, C., Wang, M., and Xu, H. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. *arXiv preprint arXiv:2403.03954*, 2024.
- Zhang, Q., Liu, Z., Fan, H., Liu, G., Zeng, B., and Liu, S. Flowpolicy: Enabling fast and robust 3d flow-based policy via consistency flow matching for robot manipulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pp. 14754–14762, 2025.
- Zhou, L., Lou, A., Khanna, S., and Ermon, S. Denoising diffusion bridge models. *arXiv preprint arXiv:2309.16948*, 2023.
- Zhu, K., Pan, M., Ma, Y., Fu, Y., Yu, J., Wang, J., and Shi, Y. UniDB: A Unified Diffusion Bridge Framework via Stochastic Optimal Control. In *Forty-second International Conference on Machine Learning*, 2025.

A. 概述

本文提供补充信息、结果与可视化内容，以完善主论文。本附录结构如下：

- 定理 3.1 的证明及其经验评估；
- 实验设置信息与真实世界数据采集；
- 桥接策略（BridgePolicy）与基线的实现细节；
- 训练与推理细节；
- 补充并扩展的实验结果。

B. 定理 3.1 的证明与实证评估

为证明定理 3.1，我们对数据预测神经网络的利普希茨性质作出如下常见假设 network $\mathbf{a}_\theta$ (Lu et al., 2022; 2025):

假设 B.1. 函数 $\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)$ 关于其参数 $\mathbf{a}_t$ 和 $\mathbf{a}_T$ 是利普希茨连续的，即存在 $L_1, L_2 > 0$ s.t. 使得以下不等式成立：

$$\|\mathbf{a}_\theta(\mathbf{a}'_t, \mathbf{a}''_T, t) - \mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)\| \leq L_1 \|\mathbf{a}'_t - \mathbf{a}_t\| + L_2 \|\mathbf{a}''_T - \mathbf{a}_T\|. \quad (10)$$

定理 3.1. 给定初始值 $\mathbf{a}_T$ 以及数据预测网络 $\mathbf{a}_\theta(\mathbf{a}_t, \mathbf{a}_T, t)$ 上的假设 B.1。假设 $\tilde{\mathbf{a}}_T$ 是从 $\mathbf{a}_T$ 扰动得到的初始值，并且采样过程中的噪声 ϵ 相同，则我们有

$$\|\tilde{\mathbf{a}}_0 - \mathbf{a}_0\| \leq C \|\tilde{\mathbf{a}}_T - \mathbf{a}_T\| \quad (7)$$

其中 $C > 0$ 为常数， $\mathbf{a}_0$ 和 $\tilde{\mathbf{a}}_0$ 分别由 $\mathbf{a}_T$ 和 $\tilde{\mathbf{a}}_T$ 通过更新规则式 (4) 生成。

证明：考虑从时间步 s 到 $t \in [0, s]$ 的两个更新规则：

$$\begin{aligned} \mathbf{a}_t &= c_{1,t:s} \mathbf{a}_s + c_{2,t:s} \mathbf{a}_T + c_{3,t:s} \mathbf{a}_\theta(\mathbf{a}_s, \mathbf{a}_T, s) + \delta_{t:s}^d \epsilon, \\ \tilde{\mathbf{a}}_t &= c_{1,t:s} \tilde{\mathbf{a}}_s + c_{2,t:s} \tilde{\mathbf{a}}_T + c_{3,t:s} \mathbf{a}_\theta(\tilde{\mathbf{a}}_s, \tilde{\mathbf{a}}_T, s) + \delta_{t:s}^d \epsilon, \end{aligned} \quad (11)$$

其中我们简单地将关于 $\mathbf{a}_s, \mathbf{a}_T$ 和 $\mathbf{a}_\theta$ 的三个系数分别记为 $c_{1,t:s}, c_{2,t:s}$ 和 $c_{3,t:s}$ ，噪声为 ϵ 。定义时间 t 处的误差为

$$\mathbf{e}_t \triangleq \|\tilde{\mathbf{a}}_t - \mathbf{a}_t\|. \quad (12)$$

则我们有

$$\begin{aligned} \mathbf{e}_t &= \|\tilde{\mathbf{a}}_t - \mathbf{a}_t\| \\ &= \|c_{1,t:s}(\tilde{\mathbf{a}}_s - \mathbf{a}_s) + c_{2,t:s}(\tilde{\mathbf{a}}_T - \mathbf{a}_T) + c_{3,t:s}[\mathbf{a}_\theta(\tilde{\mathbf{a}}_s, \tilde{\mathbf{a}}_T, s) - \mathbf{a}_\theta(\mathbf{a}_s, \mathbf{a}_T, s)]\| \\ &\stackrel{(i)}{\leq} c_{1,t:s} \|\tilde{\mathbf{a}}_s - \mathbf{a}_s\| + c_{2,t:s} \|\tilde{\mathbf{a}}_T - \mathbf{a}_T\| + c_{3,t:s} \|\mathbf{a}_\theta(\tilde{\mathbf{a}}_s, \tilde{\mathbf{a}}_T, s) - \mathbf{a}_\theta(\mathbf{a}_s, \mathbf{a}_T, s)\| \\ &\stackrel{(ii)}{\leq} c_{1,t:s} \mathbf{e}_s + c_{2,t:s} \mathbf{e}_T + c_{3,t:s} (L_1 \mathbf{e}_s + L_2 \mathbf{e}_T) \\ &= (c_{1,t:s} + c_{3,t:s} L_1) \mathbf{e}_s + (c_{2,t:s} + c_{3,t:s} L_2) \mathbf{e}_T \\ &= C_{1,t:s} \mathbf{e}_s + C_{2,t:s} \mathbf{e}_T, \end{aligned} \quad (13)$$

其中 (i) 由三角不等式得到，(ii) 由式 (10) 得到，并且我们简单地将 $C_{1,t:s} \triangleq c_{1,t:s} + c_{3,t:s} L_1$ 和 $C_{2,t:s} \triangleq c_{2,t:s} + c_{3,t:s} L_2$ 记为。给定 $M+1$ 个时间步 $\{t_i\}_{i=0}^M$ 从 $t_0 = T$ 递减到 $t_M = 0$ ，重复上述论证

(13), 我们有

$$\begin{aligned}
 e_0 &\leq C_{1,t_M:t_{M-1}} e_{t_{M-1}} + C_{2,t_M:t_{M-1}} e_T \\
 &\leq C_{1,t_M:t_{M-1}} C_{1,t_{M-1}:t_{M-2}} e_{t_{M-2}} + (C_{1,t_M:t_{M-1}} C_{2,t_{M-1}:t_{M-2}} + C_{2,t_M:t_{M-1}}) e_T \\
 &\leq \dots \\
 &\leq \prod_{i=1}^M C_{1,t_{M-i+1}:t_{M-i}} e_{t_0} + \sum_{i=1}^M C_{2,t_{M-i+1}:t_{M-i}} \prod_{k=i+1}^M C_{1,t_{M-k+1}:t_{M-k}} e_T \\
 &= \left(\prod_{i=1}^M C_{1,t_{M-i+1}:t_{M-i}} + \sum_{i=1}^M C_{2,t_{M-i+1}:t_{M-i}} \prod_{k=i+1}^M C_{1,t_{M-k+1}:t_{M-k}} \right) e_T.
 \end{aligned} \tag{14}$$

Hence,

$$\begin{aligned}
 e_0 &\leq C e_T \\
 \Leftrightarrow \|\tilde{\mathbf{a}}_0 - \mathbf{a}_0\| &\leq C \|\tilde{\mathbf{a}}_T - \mathbf{a}_T\|,
 \end{aligned} \tag{15}$$

其中 $C \triangleq \prod_{i=1}^M C_{1,t_{M-i+1}:t_{M-i}} + \sum_{i=1}^M C_{2,t_{M-i+1}:t_{M-i}} \prod_{k=i+1}^M C_{1,t_{M-k+1}:t_{M-k}}$ 是一个仅依赖于有限采样步数和假设 B.1 中利普希茨常数的常数, 这完成了证明。 $\square$

常数参数的经验估计 在定理 3.1 中。我们在六 C 个任务上进行实验, 以经验性地

评估 C 的大小。具体来说, 我们对相同的学习观测表示 $\mathbf{a}_T = \mathbf{z}_{obs}$ 添加不同水平的随机扰动, 并通过逆向过程生成动作, 之后计算相应的 C 。这里 $M = 10$ 与仿真实验中的 NFE 一致。对于每个任务, 我们对 1000 次采样试验的结果取平均。




图 8. 定理 3.1 中常数 C 的经验评估。

根据定理 3.1, 对不等式两边取对数后 ($\log \|\tilde{\mathbf{a}}_0 - \mathbf{a}_0\| \leq \log C + \log \|\tilde{\mathbf{a}}_T - \mathbf{a}_T\|$), 相应的误差曲线应位于斜率约为 1 的直线下方。我们的实验结果与定理 3.1 的陈述一致。在图 8 中, 所有拟合直线的斜率大致在 1.09 - 1.23 范围内

且常数 C 落在 10^{-2} 和 10^{-3} 之间，这与我们的公式相符。观测多层感知机引入的误差不会对生成的动作 a_0 产生太大影响。

C. 实验设置与真实世界数据收集细节

C.1. 仿真与真实世界任务示例

仿真与真实世界任务的示例如图 9 所示。




图 9. 仿真与真实世界任务示例。

C.2. 真实世界实验设置

真实世界实验在 Franka 机械臂上进行。我们为其配备了两种夹爪，一种来自 Robotiq，另一种来自 FastUMI。具体场景设置如图 12 所示。FastUMI 夹爪用于完成倒水、开烤箱、关烤箱和抓取放置任务，Robotiq 夹爪用于完成拔插头任务。




图 10. 用于真实世界数据收集的 GELLO 人类遥操作系统。




图 11. 拔插头任务关键帧的点云可视化。

C.3. 数据采集

我们使用 GELLO 人类遥操作系统（Wu 等，2024a）为真实世界实验采集数据。所使用的 GELLO 控制器设备与 GELLO 数据采集系统如图 10 所示。在真实世界数据采集中，我们执行手眼标定。标定过程使我们能够精确确定从相机坐标系到机器人基座坐标系的变换关系。包括三维点云、机器人状态和动作在内的观测数据被记录下来，构成专家演示数据集。我们使用三维点云作为机器人的视觉输入，该点云由 ZED-2i 相机直接获取，这是一款能够生成场景点云的双目相机。相机获取的点云示例如图 11 所示。ZED-2i 相机输出的单个点云包含 252,672 个点。输入到策略（包括 BridgePolicy 和基线）的点云进一步使用最远点采样（FPS）算法下采样至 2048 个点，并通过 fpsample 库（Han 等，2023）完成，以进一步加速以支持实时推理。

D. BridgePolicy 与基线的模型实现

D.1. 去噪网络的实现

遵循 DP3（Ze 等，2024）和 FlowPolicy（Zhang 等，2025）中去噪模型的实现，我们采用 U-Net 架构作为 BridgePolicy 和基线中去噪模型的主干网络。BridgePolicy 和基线中去噪模型的参数数量相同，约为 255M。




图 12. 使用 Robotiq 和 FastUMI 夹爪进行拔插任务的实验设置。

表 6. 使用 10 步和 1 步采样对 FlowPolicy 的评估。

	Flow (1 step)	Flow (10 step)
Adroit Hammer	1.00	0.91
Adroit Door	0.53	0.50
DexArt Faucet	0.38	0.37
DexArt Bucket	0.32	0.26
MetaWorld Hammer	0.98	0.94
MetaWorld Coffee-Pull	0.96	0.89
MetaWorld Soccer	0.33	0.24
Average	0.64	0.59

BridgePolicy 拥有额外的模块，即语义对齐器和模态融合模块，其参数数量不到 1M。

E. BridgePolicy 与基线的训练和推理细节

E.1. 训练

对于诸如视界长度、观测步数和预测动作步数等配置，我们将其设置为公开代码库中的默认设置，BridgePolicy 的相应配置与 DP3 保持一致。对于 BridgePolicy 中对齐器的训练，我们在 50 个训练轮次后冻结其参数。具体而言，我们在表 7 和表 8 中列出了 BridgePolicy 使用的超参数。

E.2. 推理

采样步数。我们将 BridgePolicy 和基线的采样步数设置为 10，但 FlowPolicy 的采样步数根据原始论文（Zhang 等人，2025）设置为 1。我们还进行了额外的实验，以探索增加采样步数时性能会如何变化，结果如表 6 所示。这些结果表明性能会下降，这可能是由于一致性流匹配（Sabour 等人，2025）中的误差累积问题所致。

表 7. BridgePolicy 在实验中的超参数设置（真实世界）。

Hyperparameter	Value
Num epochs	4000
Batch Size	256
Horizon	8
Observation Steps	2
Action Steps	4
Num points	2048
Num train timesteps	100
Num inference steps	10
Learning Rate (LR)	1.0e-4
Aligner weight α	1.0
Weight decay	1.0e-6

表 8. BridgePolicy 在实验中的超参数设置（仿真）。

Hyperparameter	Value
Num epochs	3000
Batch Size	256
Horizon	8
Observation Steps	2
Action Steps	4
Num points	512/1024
Num train timesteps	100
Num inference steps	10
Learning Rate (LR)	1.0e-4
Aligner weight α	1.0
Weight decay	1.0e-6

F. 补充实验结果

此处提供补充实验结果。

F.1. 真实世界任务的补充可视化

图 13、图 14 和图 7 展示了本文桥接策略（BridgePolicy）与基线方法在真实世界任务上的补充可视化结果。

F.2. 关于 α 参数的更多消融结果

表 9 和表 10 展示了关于 α 参数的更多消融结果。对于大多数评估任务，小于 1 的较小 α 更有利于策略训练。

表 9. 消融实验：不同 α 在元世界（MetaWorld）上的成功率

α	MetaWorld			Avg
	coffee-push	hammer	pick-place-wall	
0.0	0.91	0.96	0.88	0.91
0.5	0.99	0.97	0.93	0.96
1.0	0.91	0.99	0.96	0.95
2.0	0.91	0.97	0.87	0.91
5.0	0.92	0.93	0.83	0.89



图 13. 在抓取与放置任务的五个关键点上，DP3、流策略（FlowPolicy）与桥接策略（BridgePolicy）的真实机器人对比可视化。

F.3. Parameter Sensitivity on γ and λ

我们展示了桥接策略（BridgePolicy）的关键参数如何影响其性能。具体而言，我们在统一扩散桥（UniDB）框架（Zhu 等人，2025）中评估了两个超参数（稳态方差水平 λ^2 （超过 255）和惩罚系数 γ ）的组合，结果如表 11 所示。表 11 的结果表明， $\lambda = 50$ 和 $\gamma = 10^7$ 是统一扩散桥框架在策略学习中相对更优的超参数组合。

F.4. 训练目标的消融结果 与 L_1 L_2 范数目标

我们验证了使用不同训练目标训练扩散桥的效果，并报告了桥接策略的成功率。结果如表 12 所示。

F.5. 各任务的成功率

我们在表 13 中列出了每个基准中各个任务的成功率。均值和标准差基于三个随机种子计算。

F.6. 更多样本效率

本节提供了额外的样本效率消融实验结果，如图 15 所示。




图 14. 真实机器人对比可视化：DP3、FlowPolicy 和 BridgePolicy 在拔插头任务四个关键路径点上的表现。BridgePolicy 成功抓取插头，而 DP3 和 FlowPolicy 仅能移动到大致位置。

表 10. 消融实验：不同 α 在 Adroit 和 DexArt 上的成功率。

α	Adroit			Adroit Avg	DexArt				DexArt Avg
	hammer	door	pen		laptop	faucet	toilet	bucket	
0.0	1.00	0.79	0.56	0.78	0.85	0.42	0.74	0.34	0.58
0.5	1.00	0.83	0.51	0.78	0.86	0.41	0.75	0.35	0.59
1.0	1.00	0.84	0.54	0.79	0.91	0.44	0.76	0.30	0.60
2.0	1.00	0.84	0.62	0.82	0.86	0.42	0.76	0.32	0.59
5.0	0.97	0.80	0.57	0.78	0.89	0.43	0.73	0.30	0.58

表 11. 不同稳态方差水平 λ^2 和惩罚系数 γ 下，不同 Adroit 任务的定量评估结果。

Task	Hyperparameters (λ, γ)					
	(30, 10^7)	(50, 10^7)	(70, 10^7)	(30, 10^5)	(50, 10^5)	(70, 10^5)
Adroit Hammer	0.9	1.0	1.0	0.85	1.0	1.0
Adroit Door	0.75	0.85	0.85	0.65	0.85	0.825
Adroit Pen	0.65	0.75	0.65	0.65	0.65	0.6
Avg Success Rate	0.77	0.87	0.83	0.72	0.83	0.81

表 12. 使用 L_1 (MAE) 和 L_2 (MSE) 范数目标进行训练的消融结果。任务训练目标：扩散桥范数 (MAE)

Task	Training Objective of Diffusion Bridge	
	L_1 norm (MAE)	L_2 norm (MSE)
Adroit Pen	0.58	0.56
Adroit Door	0.84	0.83
Adroit hammer	1.00	1.00
Avg	0.81	0.80

表 13. Adroit 和 DexArt 基准上各任务的成功率。

Methods\Tasks	Adroit			DexArt			
	hammer	door	pen	laptop	faucet	toilet	bucket
DP	0.45±0.04	0.35±0.03	0.15±0.03	0.69±0.06	0.23±0.06	0.63±0.06	0.23±0.06
DP3	1.00±0.00	0.65±0.04	0.40±0.04	0.86±0.06	0.36±0.03	0.73±0.05	0.32±0.05
Simple DP3	1.00±0.00	0.59±0.01	0.45±0.02	0.79±0.05	0.26±0.03	0.63±0.05	0.22±0.05
FlowPolicy	1.00±0.00	0.58±0.04	0.53±0.08	0.80±0.04	0.38±0.06	0.70±0.04	0.28±0.04
VITA	0.96±0.01	0.81±0.03	0.55±0.04	0.82±0.04	0.39±0.03	0.72±0.04	0.28±0.04
BridgePolicy	1.00±0.00	0.84±0.05	0.58±0.07	0.88±0.04	0.44±0.05	0.76±0.05	0.32±0.05

表 14. MetaWorld (简单) 基准上各任务的成功率。

Methods\Tasks	MetaWorld (Easy)						
	button-press	button-press-topdown	button-press-topdown-wall	button-press-wall	coffee-button	dial-turn	door-close
DP	0.93±0.01	0.98±0.01	0.96±0.02	0.93±0.02	0.99±0.01	0.63±0.07	1.00±0.00
DP3	1.00±0.00	1.00±0.00	0.99±0.01	0.99±0.01	1.00±0.00	0.66±0.01	1.00±0.00
Simple DP3	1.00±0.00	1.00±0.00	0.98±0.01	0.93±0.01	1.00±0.00	0.59±0.01	0.97±0.00
FlowPolicy	1.00±0.00	0.97±0.02	0.98±0.01	1.00±0.00	1.00±0.00	0.88±0.07	0.90±0.06
VITA	0.99±0.01	1.00±0.00	0.99±0.01	1.00±0.00	1.00±0.00	0.90±0.14	1.00±0.00
BridgePolicy	1.00±0.00	1.00±0.00	0.93±0.01	1.00±0.00	1.00±0.00	0.83±0.01	1.00±0.00

表 15. MetaWorld (简单) 基准上各任务的成功率。

Methods\Tasks	MetaWorld (Easy)						
	door-lock	door-open	lever-pull	drawer-close	reach	window-close	window-open
DP	0.75±0.06	0.98±0.02	0.98±0.02	1.00±0.00	0.93±0.02	0.99±0.01	1.00±0.00
DP3	0.98±0.01	0.86±0.01	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00
Simple DP3	0.98±0.01	0.76±0.06	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00
FlowPolicy	1.00±0.00	0.66±0.06	1.00±0.00	0.75±0.01	1.00±0.00	0.76±0.06	0.73±0.04
VITA	0.90±0.01	0.95±0.01	0.68±0.05	1.00±0.00	0.19±0.00	0.76±0.04	0.73±0.08
BridgePolicy	1.00±0.00	1.00±0.00	0.77±0.01	1.00±0.00	0.36±0.01	1.00±0.00	1.00±0.00

表 16. 元世界 (简单) 基准上各任务的成功率。

Methods\Tasks	MetaWorld (Easy)						
	hand-pull	hand-pull-side	door-unlock	peg-unplug-side	drawer-open	reach-wall	plate-slide-back
DP	0.75±0.06	0.98±0.02	0.98±0.02	1.00±0.00	0.93±0.02	0.99±0.01	1.00±0.00
DP3	0.98±0.01	0.86±0.01	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00
Simple DP3	0.98±0.01	0.76±0.06	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00
FlowPolicy	1.00±0.00	0.66±0.06	1.00±0.00	0.75±0.01	1.00±0.00	0.76±0.06	0.73±0.04
VITA	0.34±0.07	0.54±0.07	0.99±0.01	0.81±0.08	1.00±0.00	0.71±0.05	0.99±0.01
BridgePolicy	1.00±0.00	0.92±0.01	1.00±0.00	0.93±0.03	1.00±0.00	0.80±0.04	1.00±0.00

表 17. 元世界（简单）和元世界（中等）基准上各任务的成功率。

Methods\Tasks	MetaWorld (Easy)			MetaWorld (Medium)			
	plate-slide-back-side	plate-slide	plate-slide-side	basketball	bin-picking	box-close	hammer
DP	0.99±0.00	0.75±0.03	1.00±0.00	0.85±0.04	0.15±0.03	0.30±0.04	0.15±0.04
DP3	1.00±0.00	1.00±0.01	1.00±0.00	0.98±0.01	0.38±0.21	0.42±0.02	0.72±0.03
Simple DP3	0.99±0.00	1.00±0.01	1.00±0.00	0.95±0.03	0.28±0.10	0.38±0.04	0.62±0.06
FlowPolicy	0.65±0.04	1.00±0.00	1.00±0.00	0.66±0.04	0.66±0.10	0.81±0.03	0.98±0.01
VITA	1.00±0.00	0.96±0.02	1.00±0.00	0.90±0.01	0.23±0.01	0.52±0.04	0.90±0.01
BridgePolicy	1.00±0.00	1.00±0.00	1.00±0.00	1.00±0.00	0.45±0.04	0.80±0.06	0.95±0.05

表 18. 元世界（中等）基准上各任务的成功率。

Methods\Tasks	MetaWorld (Medium)						
	peg-insert-side	push-wall	soccer	coffee-pull	coffee-push	sweep	sweep-into
DP	0.34±0.05	0.20±0.02	0.14±0.03	0.34±0.05	0.67±0.03	0.18±0.06	0.10±0.03
DP3	0.67±0.05	0.51±0.06	0.18±0.02	0.85±0.02	0.94±0.02	0.96±0.02	0.17±0.04
Simple DP3	0.48±0.05	0.38±0.06	0.16±0.02	0.92±0.08	0.86±0.04	0.88±0.02	0.09±0.04
FlowPolicy	0.70±0.06	0.63±0.06	0.33±0.04	0.96±0.01	0.61±0.04	0.70±0.03	0.31±0.01
VITA	0.42±0.08	0.51±0.10	0.19±0.03	1.00±0.00	0.63±0.04	0.87±0.03	0.12±0.01
BridgePolicy	0.77±0.04	0.87±0.02	0.31±0.04	0.97±0.01	0.87±0.02	0.97±0.01	0.40±0.02

表 19. 元世界（困难）基准上各任务的成功率。

Methods\Tasks	MetaWorld (Hard)				
	pick-out-of-hole	pick-place	assembly	push	hand-insert
DP	0.00±0.00	0.02±0.01	0.15±0.01	0.28±0.02	0.09±0.01
DP3	0.14±0.06	0.12±0.03	0.99±0.01	0.62±0.02	0.14±0.03
Simple DP3	0.08±0.04	0.12±0.04	0.79±0.01	0.32±0.02	0.12±0.04
FlowPolicy	0.31±0.03	0.63±0.04	1.00±0.00	0.73±0.04	0.26±0.01
VITA	0.23±0.04	0.43±0.07	0.99±0.01	0.65±0.03	0.09±0.01
BridgePolicy	0.28±0.04	0.65±0.01	1.00±0.00	0.74±0.02	0.25±0.04

表 20. 元世界（极难）基准上各任务的成功率。

Methods\Tasks	MetaWorld (Very Hard)				
	stick-push	stick-pull	shelf-place	pick-place-wall	disassemble
DP	0.63±0.02	0.11±0.01	0.11±0.02	0.05±0.01	0.43±0.05
DP3	0.97±0.03	0.27±0.06	0.19±0.07	0.35±0.06	0.75±0.03
Simple DP3	0.97±0.04	0.15±0.06	0.05±0.01	0.28±0.04	0.50±0.02
FlowPolicy	1.00±0.00	0.56±0.02	0.40±0.02	0.95±0.02	0.88±0.02
VITA	0.83±0.05	0.61±0.02	0.16±0.04	0.80±0.06	0.69±0.02
BridgePolicy	1.00±0.00	0.82±0.02	0.25±0.02	0.96±0.04	0.92±0.02




图 15. 额外的样本效率消融结果。