

FLAC: 基于动能正则化桥匹配的最大熵强化学习

Lei Lv^{1,2,3*}, Yunfei Li², Yu Luo³, Fuchun Sun^{3†}, Xiao Ma^{2†}

¹Shanghai Research Institute for Intelligent Autonomous Systems, ²ByteDance Seed, ³Tsinghua University

*The work was accomplished during the author's internship at ByteDance Seed, †Corresponding authors

Abstract

迭代式生成策略，如扩散模型和流匹配，为连续控制提供了卓越的表达能力，但使最大熵强化学习复杂化，因为其动作对数密度无法直接获取。为解决这一问题，本文提出场最小能量（Field Least-Energy）

Actor-Critic (FLAC)

，一种免似然的框架，通过惩罚速度场的动能来调节策略随机性。我们的核心洞见是将策略优化表述为相对于高熵参考过程（例如均匀分布）的广义薛定谔桥（GSB）问题。在这一视角下，最大熵原理自然显现为在优化回报的同时保持接近高熵参考，而无需显式动作密度。在该框架中，动能作为与参考过程偏离的物理基础代理：最小化路径空间能量约束了所诱导的终端动作分布的偏差。基于这一视角，我们推导出一种能量正则化的策略迭代方案，以及一种实用的离线算法，该算法通过拉格朗日对偶机制自动调节动能。实验表明，FLAC 在高维基准上相对于强基线取得了优越或相当的性能，同时避免了显式密度估计。

Date: February 16, 2026

Project Page: <https://pinkmoon-io.github.io/flac.github.io/>

通讯作者: 孙富春, fcsun@tsinghua.edu.cn; 马晓, xiao.ma@bytedance.com

1 引言

迭代式生成策略，包括流匹配和扩散模型 [7, 12, 17]，最近已成为强化学习中的一种强大范式 [24, 38]。与直接输出动作的传统高斯策略 [10] 不同，这些隐式策略通过一个顺序生成过程来定义策略，该过程将简单的基噪声分布传输到复杂的、以状态为条件的动作分布。这种表达能力允许对丰富的多模态行为进行建模 [6]，使这些策略能够在高维控制任务和数据驱动场景中取得卓越性能，而在这些场景中简单的单峰分布表现不足。

然而，将这些迭代式生成策略与最大熵强化学习 [10, 41] 结合并非易事。在强化学习中，最大熵目标通常对于防止过早收敛和通过显式鼓励随机性来维持探索至关重要。然而，最大熵方法通常依赖于

策略对数密度 $\log \pi(a | s)$ 用于量化和调节这种随机性。对于迭代生成器， $\log \pi(a | s)$ 无法直接获取，且通常难以计算，因为动作分布仅通过多步生成过程隐式定义。因此，现有方法诉诸额外的估计机制 [3]，例如训练辅助网络 [40] 或对可处理的分布代理进行正则化 [37]。虽然在某些情况下有效，但这些策略引入了额外的复杂度和计算量，并且常常导致次优的探索。

为解决这一问题，本文提出一种根本性的视角转变：不再显式估计和调节终端熵，而是将熵正则化策略优化表述为广义薛定谔桥（Generalized Schrödinger Bridge, GSB）问题 [18]。薛定谔桥问题（Schrödinger Bridge Problem, SBP）[5, 25, 28] 研究熵正则化传输，通过寻找一个轨迹分布，使其在诱导期望终端行为的同时保持与参考随机过程的接近。在该框架下，最大熵原理不再是外部启发式规则，而是源于终端效用与路径空间上高熵参考之间接近程度的结构化权衡。特别地，本文的推导将诱导的终端动作分布刻画为参考终端边缘分布的重加权；当该参考边缘分布在有界动作域上近似均匀时，该刻画与标准最大熵原理一致。关键的是，本文从理论上证明，在路径空间上控制与参考的偏差也能控制诱导的终端动作分布。此外，对于速度场驱动的迭代生成器，本文证明该路径空间偏差可通过流的动能 [18]（即沿生成轨迹的平方速度/漂移幅度的期望路径积分）来控制，这直接启发了最小动能正则化器。

受此视角启发，本文提出场最小能量演员-评论家（Field Least-Energy Actor-Critic, FLAC），一种在强化学习中实例化该最小动能吉布斯-玻尔兹曼（GSB）正则化的新颖框架。演员被优化以最大化 Q 值，同时最小化该动能，有效平衡奖励最大化与生成随机性的保持。此外，本文引入能量惩罚的自动调节机制，确保策略在训练过程中动态调整其探索水平。

本文在一系列具有挑战性的连续控制基准上评估 FLAC，包括 DMControl [33] 和 HumanoidBench [27]。结果表明，与最先进的基线相比，FLAC 达到具有竞争力或更优的性能。

2 相关工作

迭代生成策略。在离线强化学习和模仿学习中，扩散/流策略作为灵活的行为模型或策略类，从固定数据集中训练，其中模式覆盖是核心问题 [6, 16, 24, 38, 39]。近期工作研究价值/能量引导的训练与采样，其中 Q 值或学习到的能量使生成器偏向高回报动作，同时保持数据支持 [8, 13, 21, 26]。对于在线强化学习，迭代策略已开始与演员-评论家更新及面向效率的设计相结合 [3, 22, 37, 40]。除强化学习基准外，扩散/流策略也被用于机器人学和视觉运动控制中，作为通用动作生成模块，凸显其在结合强表示学习时的实用可扩展性 [6]。

生成策略的熵调节器。最大熵强化学习通过熵或 KL 正则化鼓励探索 [10, 41]。然而，对于由迭代采样器（扩散/流）隐式定义策略的情况，诱导的动作密度可能不可用，使得在求解器预算有限的在线强化学习中，基于密度的正则化代价高昂或脆弱。似然评估可沿 ODE 动力学通过变量替换 [4] 或 SDE 中的路径边缘化 [30] 进行，两者在实践中均非易事。近期方法通过引入针对扩散/流采样器定制的实用熵/探索调节器，将迭代生成策略与离线演员-评论家学习相结合。DIME[3] 优化熵的复杂变分代理目标以控制随机性。Wang 等人 [37] 用多元高斯近似策略熵，并利用其校准探索噪声。Zhang 等人 [40] 训练额外的噪声估计网络，以实现流策略的熵式正则化。

薛定谔桥（Schrödinger Bridges）：路径空间 KL 散度、最优传输与 GSB。薛定谔桥为相对于参考扩散过程、在分布之间最可能的随机演化提供了变分表述，

将熵正则化、随机控制和最优传输联系起来 [14, 15, 36]。确定性极限恢复 Benamou – Brenier 动能最优传输 [2, 23]，这也推动了传输学习方法 [17, 20]。在随机方面，基于学习的 SB 求解器以及扩散-SB 连接已被开发用于拟合随机传输 [25, 28, 35]。广义薛定谔桥进一步将硬终端约束松弛为软终端势，产生与决策制定场景对齐的单端目标，其中目标由效用或奖励指定 [18]。

3 预备知识

3.1 熵正则化强化学习

我们考虑由元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, p, r, \gamma)$ 定义的马尔可夫决策过程 (MDP) [1]，具有连续状态空间 $\mathcal{S} \in \mathbb{R}^{d_s}$ 和动作空间 $\mathcal{A} \in \mathbb{R}^{d_a}$ 。转移动力学为 $p(s' | s, a)$ ，奖励函数为 $r(s, a)$ ， $\gamma \in [0, 1)$ 为折扣因子。目标是学习一个策略 $\pi(a | s)$ ，最大化期望回报 [31]。

在连续控制中，为防止过早收敛并鼓励探索，目标通常增加熵项（最大熵强化学习）：

$$J_{\text{MaxEnt}}(\pi) = \mathbb{E}_{\pi} \left[\sum_{t=0}^{\infty} \gamma^t (r(s_t, a_t) + \alpha \mathcal{H}(\pi(\cdot | s_t))) \right], \quad (1)$$

其中 $\mathcal{H}(\pi) = -\mathbb{E}_{a \sim \pi} [\log \pi(a | s)]$ ，最大化 $\mathcal{H}(\pi)$ 等价于最小化 $D_{\text{KL}}(\pi(\cdot | s) \| \text{均匀分布}(\mathcal{A}))$ 。值得注意的是，最大熵强化学习 (MaxEnt RL) 产生如下形式的玻尔兹曼最优策略 $\pi^*(a | s) \propto \exp(Q(s, a)/\alpha)$ ，这与将在我们的吉布斯采样玻尔兹曼 (GSB) 公式中重现的指数倾斜闭式结构相呼应。

3.2 迭代生成策略

与直接输出动作样本的显式策略（如高斯分布）不同，迭代生成式策略通过传输过程隐式地定义分布 $\pi(a | s)$ 。设 $\tau \in [0, 1]$ 表示连续生成时间。动作生成被建模为状态条件随机微分方程 (SDE) [19, 30] 的解：

$$dX_{\tau} = u(s, \tau, X_{\tau})d\tau + \sigma dW_{\tau}, \quad X_0 \sim \mu_0, \quad (2)$$

其中 $X_{\tau} \in \mathbb{R}^{d_a}$ 为潜状态， X_0 采样自简单先验 μ_0 （通常为 $\mathcal{N}(0, I)$ 或均匀分布）， $a := X_1$ 为已实现动作。漂移项 $u_{\theta} : \mathcal{S} \times [0, 1] \times \mathbb{R}^{d_a} \rightarrow \mathbb{R}^{d_a}$ 为可学习向量场（速度场）， W_{τ} 为标准维纳过程。

式 (2) 的一个关键性质是，终端状态的边际密度 $\pi(X_1 | s)$ 无法直接获取。评估 $\log \pi(a | s)$ 需要求解瞬时变量变化公式或对所有可能路径进行边际化，这在线训练过程中计算代价高昂且数值不稳定。因此，有必要采用一种无似然的方法来调节随机性。

3.3 薛定谔 Schrödinger 桥问题

薛定谔桥 (Schrödinger Bridge, SB) 问题 [5] 旨在给定参考过程下，寻找两个概率分布之间最可能的随机演化。形式上，设 $\Omega = C([0, 1], \mathbb{R}^d)$ 为路径空间，设 $X_{\tau} : \Omega \rightarrow \mathbb{R}^d$ 为由 $X_{\tau}(\omega) = \omega(\tau)$ 定义的标准坐标过程，其中 $\omega \in \Omega$ 。我们将时刻 τ 的边际分布记为

$$\mathbb{P}_{\tau} := (X_{\tau})_{\#} \mathbb{P}.$$

给定一个参考 $\mathbb{P}^{\text{ref}}$ （通常为不受控的布朗运动）[15] 和两个边缘分布 μ_0, μ_1 ，薛定谔桥问题寻求一个测度 $\mathbb{P}^*$ ，该测度在满足边缘分布匹配约束的前提下，最小化相对于参考测度的发散度量 $\mathcal{D}$ ：

$$\min_{\mathbb{P}} \mathcal{D}(\mathbb{P} \| \mathbb{P}^{\text{ref}}) \quad \text{s.t.} \quad \mathbb{P}_0 = \mu_0, \mathbb{P}_1 = \mu_1. \quad (3)$$

具体而言，对于随机微分方程， $\mathcal{D}$ 是 KL 散度；对于常微分方程，它与 Wasserstein-2 距离 [32] 相关联。该公式通常被称为“数据到数据”桥，在生成建模中常用于连接噪声与数据。近期工作 [18] 将其推广至广义薛定谔桥，其中硬性终端约束 $\mathbb{P}_1 = \mu_1$ 被松弛为软性势能或泛函约束。这一推广对于第 4 节中的公式至关重要，其中目标由奖励而非样本定义。

3.4 动能与路径约束

为了在无法获取终端对数密度的情况下调节策略，我们将视角从动作空间提升至路径空间。我们将生成过程的动能定义为漂移场所做的期望物理功：

$$\mathcal{E}(s) := \mathbb{E} \left[\int_0^1 \frac{1}{2} \|u_\theta(s, \tau, X_\tau)\|^2 d\tau \right]. \quad (4)$$

该量作为相对于参考测度 $\mathbb{P}^{\text{ref}}$ （基础噪声过程）的发散在随机和确定性两种情形下的统一代理。

随机情形 ($\sigma > 0$): 路径发散与能量 [34] 成正比。如附录 A.1 所推导：

$$D_{\text{KL}}(\mathbb{P}^\theta \| \mathbb{P}^{\text{ref}}) = \frac{1}{\sigma^2} \mathcal{E}(s). \quad (5)$$

此处， $\mathbb{P}^\theta$ 和 $\mathbb{P}^{\text{ref}}$ 分别表示策略路径测度和参考路径测度（两者均以 $X_0 \sim \mu_0$ 初始化），它们在 $\tau = 1$ 处的终端边缘分布为 $\pi_\theta(\cdot | s)$ 和 μ_1^{ref} 。关键的是，我们建立了路径测度之间的发散严格上界于 $\pi(\cdot | s)$ 与参考终端边缘分布 μ_1^{ref} 之间的发散：

$$D_{\text{KL}}(\pi_\theta \| \mu_1^{\text{ref}}) \leq D_{\text{KL}}(\mathbb{P}^\theta \| \mathbb{P}^{\text{ref}}) = \frac{1}{\sigma^2} \mathcal{E}(s). \quad (6)$$

我们在附录 A.3 中给出了该不等式的证明。这一理论结果对于我们的框架至关重要，因为它保证了最小化动能是强制终端动作分布约束的充分条件。

确定性机制 ($\sigma \rightarrow 0$): 在常微分方程情形下，动能与最优传输代价 [2, 23] 相关。详见附录 A.2:

$$\mathcal{W}_2^2(\mu_0, \pi_\theta) \leq 2\mathcal{E}(s). \quad (7)$$

在确定性（常微分方程）情形下，参考动力学保持 $X_\tau = X_0$ ，因此 $\mu_1^{\text{ref}} = \mu_0$ 。注意，虽然常微分方程流是确定性的，但随机性来源于 X_0 。最小化动能作为一种几何正则化器，严格限制了与该先验的偏差（以 Wasserstein-2 距离度量）。当 μ_0 在有界动作域上均匀分布时，这遵循与最大熵强化学习相似的原理，即不鼓励过度集中的动作分布，并鼓励在动作域上具有广泛支撑的随机策略，尽管如附录 A.2 所讨论的，在确定性极限下它并不提供严格的熵保证。

因此，最小化动能始终强制与先验保持接近，这被解释为熵接近（在随机微分方程中）或几何接近（在常微分方程中）。因此，最小化该路径能量足以限制终端动作分布的发散。

4 强化学习作为广义薛定谔 Schrödinger 桥问题

在本节中，我们正式推导 FLAC。我们首先将策略优化问题重新表述为不仅仅是最大化回报，而是作为一个广义薛定谔桥 (GSB) 问题。这一视角将生成动力学和探索目标统一到一个单一、连贯的物理传输公式中。

广义薛定谔 Schrödinger 桥公式 标准强化学习将策略视为条件分布。在这里，我们将其视为受控随机过程。遵循 Liu 等人 [18] 的公式，我们将目标定义为在轨迹空间上寻找一个路径测度 $\mathbb{P}$ ，该测度最小化一个复合目标：相对于高熵参考过程的发散代价，以及反映任务奖励的终端势代价。令 $\mathbb{P}^{\text{ref}}$ 表示从高熵先验（实例化为均匀分布）出发的固定参考路径测度（例如，布朗运动）。我们公式化单端广义薛定谔桥

μ_0
problem as

$$\min_{\mathbb{P}} \mathcal{J}_{\text{GSB}}(\mathbb{P}) := \alpha \underbrace{\mathcal{D}(\mathbb{P} \parallel \mathbb{P}^{\text{ref}})}_{\text{Divergence Cost}} + \underbrace{\mathbb{E}_{X_1 \sim \mathbb{P}} [\mathcal{G}(X_1)]}_{\text{Terminal Potential}} \quad \text{s.t.} \quad \mathbb{P}_0 = \mu_0. \quad (8)$$

该优化受特定边界条件约束，使其区别于经典运输问题。首先，过程锚定于固定起点，约束为从参考先验 μ_0 初始化。其次，不同于标准薛定谔桥（Schrödinger Bridge）对终端边缘分布施加硬约束（即强制 X_1 匹配数据分布），本文的公式是单端的（或“自由端”）：终端分布 $\mathbb{P}_1$ 可自由演化，仅由软势 $\mathcal{G}(X_1)$ 正则化。

本文分析该公式的理论性质。式 (8) 中的优化问题对终端边缘分布存在闭式解。

命题 1（最优 GSB 解）。最小化式 (8) 的最优路径测度 $\mathbb{P}^*$ 诱导出如下形式的终端边缘分布 $p(X_1)$ ：

$$p^*(X_1) \propto \mu_1^{\text{ref}}(X_1) \cdot \exp\left(-\frac{\mathcal{G}(X_1)}{\alpha}\right), \quad (9)$$

where $\mu_1(X_1)$ 是参考过程在 $\tau = 1$ 处的边缘分布。

证明见附录 A.4。 □

命题 1 揭示了最优终端边缘分布的指数倾斜闭式形式。当在边界动作域上近似均匀时，解退化为

$$p(X_1) \propto \exp(-\mathcal{G}(X_1)/\alpha) \cdot \mu_1^{\text{ref}}.$$

为将该一般形式与强化学习联系起来，本文引入状态条件终端势 $\mathcal{G}_s(X_1)$ ，使得诱导的终端边缘分布定义动作 $a := X_1$ 上的策略 $\pi(\cdot | s)$ 。特别地，本文将使用类似评论家的、价值信息势（对高价值动作赋予更低势）实例化 $\mathcal{G}_s(\cdot)$ ，从而产生类似 SAC[10] 的玻尔兹曼风格策略族：

$$\pi(a | s) \propto \mu_1^{\text{ref}} \cdot \exp\left(-\frac{\mathcal{G}_s(a)}{\alpha}\right).$$

4.2 能量正则化策略优化

虽然命题 1 刻画了最优均衡，但在高维连续空间中直接从非归一化玻尔兹曼分布采样是难以处理的。因此，我们通过参数化生成过程并将抽象的广义薛定谔桥组件实例化为可处理的强化学习目标，直接求解变分问题（式 8）。

推导 FLAC 目标。首先，利用第 3.4 节建立的联系，我们将抽象发散项替换为速度场的期望动能：

$$\mathcal{D}(\mathbb{P}^\theta \parallel \mathbb{P}^{\text{ref}}) \propto \mathbb{E} \left[\int_0^1 \frac{1}{2} \|u_\theta\|^2 d\tau \right].$$




图 1 动能正则化鼓励探索。二维多目标景观上的玩具示例。（上）无约束：高速场压过内在噪声，迫使策略坍缩为单一确定性模式。（下）FLAC：通过惩罚动能，策略被约束以保持随机性。该低能量场成功恢复了完整的多模态分布。

其次，为与演员-评论家框架对齐，我们将终端势能实例化为在状态 s 采取动作 $a := X_1$ 后的负（期望）折扣回报：

$$\mathcal{G}_s(X_1) := -R(s, X_1) = -\mathbb{E} \left[\sum_{t=0}^T \gamma^t r(s_t, a_t) \right].$$

将这些项代入式 8，我们得到所提方法——场最小能量演员-评论家（FLAC）的训练目标：

$$\min_{\theta} J_{\text{FLAC}}(\theta) = \mathbb{E}_{\mathbb{P}^{\theta}} \left[\underbrace{\alpha \int_0^1 \frac{1}{2} \|u_{\theta}(s, \tau, X_{\tau})\|^2 d\tau}_{\text{Minimize Kinetic}} \underbrace{-R(s, X_1)}_{\text{Maximize Return}} \right], \quad \text{s.t. } X_0 \sim \mu_0. \quad (10)$$

此处，期望是对当前策略生成的轨迹取的。“最小动能”一词反映了我们方法的物理直觉：动能项充当动态正则化器。由于参考过程（布朗运动）具有零漂移（零动能），最小化能量迫使策略遵循参考过程的内在随机性，仅在必要时施加努力以转向高价值区域。

为了证明这种正则化的有效性，我们可视化了在二维多目标玩具环境中学习到的向量场的演变过程（图 1）。在朴素流（Naive Flow）的情况下（顶部），策略在没有正则化的情况下最大化奖励。正如在学习过程中所观察到的，它学习到一个激进的、高速的场（由长红色箭头描绘），该场迅速集中概率质量。这种高动能完全压倒了噪声，导致动作分布遭受严重的模式崩塌，只捕获一个单一目标。相比之下，FLAC（底部）惩罚动能。所产生的场施加最小的控制努力，由微妙的、低幅度的场向量表示。在训练结束时，FLAC 成功地保持了足够的随机性以覆盖所有 8 个最优模式，验证了我们的假设，即限制动能可以防止多样化解路径的过早消除。

5 场最小能量演员-评论家

在 GSB 公式的基础上，我们提出了场最小能量演员-评论家（FLAC），它优化一个速度场，以最小的动能将先验噪声传输到高奖励区域。本节详细介绍了实用的算法，推导了一个严格的能量正则化策略迭代方案及其自动能量调节的实现。

5.1 能量正则化策略迭代

我们将动能惩罚直接纳入贝尔曼算子中。这使我们能够将标准策略迭代的保证扩展到我们的设置中。类似于 SAC，它推导了一个带有熵正则化项的软贝尔曼备份，我们通过将动作生成过程的动能成本纳入备份中，推导出一个能量正则化的贝尔曼算子。

策略评估。对于固定策略 π ，我们定义能量正则化的贝尔曼评估算子 $\mathcal{T}^\pi$ 作用于 $Q : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ 为

$$(\mathcal{T}^\pi Q)(s, a) := r(s, a) + \gamma \mathbb{E}[Q(s', a') - \alpha \mathcal{E}_\pi(s')], \quad (11)$$

其中 $\mathcal{E}_\pi(s')$ 表示采样 $a' \sim \pi(\cdot | s')$ 所需的期望动能。

命题 2（策略评估的收敛性）。假设奖励有界且能量项有限。算子 $\mathcal{T}^\pi$ 在 L 范数下是压缩映射。因此，迭代更新 $Q_{k+1} = \mathcal{T}^\pi Q_k$ 收敛到唯一的正则化值函数 Q^π 。

（证明见附录 A.5）

策略改进。给定值函数 Q^π ，我们更新策略以最大化正则化目标。这相当于找到一个策略，在最大化期望 Q 值的同时最小化其生成能量：

$$\pi \leftarrow \arg \max_{\pi} \mathbb{E}_{s \sim \mathcal{D}} [\mathbb{E}_{a \sim \pi(\cdot | s)} [Q^\pi(s, a)] - \alpha \mathcal{E}_\pi(s)]. \quad (12)$$

命题 3（单调改进）。该更新规则保证了广义目标的单调改进，即

$$J_{\text{GSB}}(\pi_{\text{new}}) \geq J_{\text{GSB}}(\pi).$$

这推动策略趋向于平衡奖励最大化和熵探索的最优传输计划。

（证明见附录 A.6）

5.2 实用实现

我们将上述框架实例化为一个实用的异策略演员-评论家算法。我们参数化向量场 $u_\theta(s, \tau, X_\tau)$ （演员）和状态-动作值函数 $Q_\psi(s, a)$ （评论家）。

评论家更新。评论家通过最小化由式（11）导出的贝尔曼残差进行训练。为估计目标值，我们使用数值求解器从状态 s' 处的当前策略中采样下一动作 a' ，并同时计算其离散化动能 $\mathcal{E}_\theta(s')$ 。目标值 y 构造如下：

$$y = r + \gamma \left(\min_{i=1,2} Q_{\bar{\psi}_i}(s', a') - \alpha \hat{\mathcal{E}}_\theta(s') \right), \quad (13)$$

其中 $Q_{\bar{\psi}_i}$ 为目标评论家网络。评论家参数 ψ 通过最小化贝尔曼残差进行更新 Error.

演员更新。演员更新 θ 以最大化改进目标。由于动作 a_θ 通过可微求解器生成，我们可以将评论家的梯度沿整个生成轨迹反向传播（路径导数）。演员损失为：

$$J_\pi(\theta) = \mathbb{E}_{s \sim \mathcal{B}} \left[\alpha \hat{\mathcal{E}}_\theta(s) - Q_\psi(s, a) \right], \quad (14)$$

其中 $a \sim \pi_\theta(\cdot|s)$ 。最小化该损失促使速度场寻找能够产生高价值动作且保持低动能的轨迹。

5.3 自动能量调节

选择固定的正则化系数 α 具有挑战性，因为动能的大小在不同任务和训练阶段差异显著。固定的 α 可能导致过度探索或过早收敛到确定性行为。

为解决这一问题，我们将能量调节表述为约束优化问题。不再手动调节惩罚权重，而是指定目标能量预算 E_{tgt} ，表示生成过程中期望的随机性水平。目标是在平均动能保持低于该阈值的约束下最大化期望回报：

$$\max_{\pi} \mathbb{E}_{s \sim \mathcal{D}, a \sim \pi} [Q^\pi(s, a)] \quad \text{s.t.} \quad \mathbb{E}_{s \sim \mathcal{D}} [\hat{\mathcal{E}}_\pi(s)] \leq E_{\text{tgt}}. \quad (15)$$

我们通过拉格朗日对偶方法求解该约束问题。针对可学习乘子 $\alpha \geq 0$ 构造拉格朗日函数：

$$\min_{\alpha \geq 0} \max_{\pi} \mathcal{L}(\pi, \alpha) = \mathbb{E} \left[Q^\pi(s, a) - \alpha (\hat{\mathcal{E}}_\pi(s) - E_{\text{tgt}}) \right]. \quad (16)$$

策略的优化 π （演员更新）对应于关于 π 最大化 $\mathcal{L}$ ，这恢复了公式（14）中的能量正则化目标。对于乘子 α ，我们最小化对偶目标：

$$J(\alpha) = \mathbb{E}_{s \sim \mathcal{D}} \left[\alpha \cdot (E_{\text{tgt}} - \hat{\mathcal{E}}_\pi(s)) \right]. \quad (17)$$

在实践中，为确保正性，我们将乘子参数化为 $\alpha = \exp(\log \alpha)$ ，并通过梯度下降更新对数乘子 $\log \alpha$ ：

$$\log \alpha \leftarrow \log \alpha - \beta \cdot \mathbb{E}_{s \sim \mathcal{B}} \left[E_{\text{tgt}} - \text{stopgrad}(\hat{\mathcal{E}}_\theta(s)) \right]. \quad (18)$$

其中 β 是学习率。

该机制充当策略随机性的动态调节器。当策略变得过于确定性时， α 增大，迫使生成过程更紧密地遵循高熵先验。相反，当策略足够随机时， α 减小，允许智能体追求激进的、高回报的轨迹。

6 实验

为全面评估 FLAC 的有效性和通用性，我们在来自 DMControl[33] 和 HumanoidBench[27] 的多种具有挑战性的任务上进行了实验。这些基准涵盖了高维运动和仿人机器人（Unitree H1）控制任务。我们的评估旨在回答以下关键问题：

- 问题 1：在高维连续控制任务上，FLAC 在样本效率和渐近性能方面与最先进的基于模型和无模型的基线相比如何？
- 问题 2：所提出的动能正则化是否有效调节了策略随机性并提升了性能？

- 问题三：FLAC 对其关键超参数（特别是目标能量预算）的敏感度如何？自动拉格朗日调节机制是否优于固定正则化方案？

本文将 FLAC 与两类强基线进行比较：

- **无模型强化学习：**本文涵盖确定性策略（TD7 [9]）、标准高斯策略（SAC [10]）以及近期基于扩散或流的策略（DIME [3]、SAC-FLOW [40] 和 FlowRL [22]）。
- **基于模型的强化学习：**本文纳入 TD-MPC2 [11]，该算法在不同基准上均属领先的基于模型方法，用于标定渐近性能极限。需注意，基于模型的方法与无模型方法在基本假设和环境动态获取方式上存在差异，因此二者不宜直接比较；TD-MPC2 仅作为渐近性能的参考。

6.1 主要结果




图 2 主要结果。本文在两个具有挑战性的基准上给出性能比较。完整结果请参见附录 D。所有无模型算法均以 5 个随机种子评估，基于模型的算法（TD-MPC2）使用 3 个种子。DIME 引入交叉 Q 学习 [29] 以提升性能，而 FLAC 不依赖这些增强手段。

跨环境性能。图 2 展示了在多种连续控制任务上的对比学习曲线。我们观察到，FLAC 始终能够达到或超越强大的无模型基线。这种鲁棒性延伸至高维状态空间，特别是在 DMC Dog 领域（ $s \in \mathbb{R}^{223}, a \in \mathbb{R}^{38}$ ）以及接触丰富的 HumanoidBench Unitree H1 任务中。此外，与基于模型的基准 TD-MPC2 [11] 相比，FLAC 在无模型框架内达到了可比的渐近回报，无需世界模型学习或在线规划。

与其他基于扩散或流的策略的比较。与先前基于扩散和基于流的策略相比，FLAC 相对于强大的基线（如 DIME [3] 和 SAC-Flow [40]）展现出更优或可比的渐近性能。FLAC 在训练和评估过程中每个动作使用 $N = 2$ 次函数评估（NFE）即可达到这些结果。相比之下，这些基线通常需要更多的离散化步骤来近似策略，其中 DIME 使用 $N = 16$ 次，SAC-Flow 使用 $N = 4$ 次。此外，DIME 还受益于交叉 Q 学习 [29] 作为额外的性能增强，而 FLAC 不依赖此技术。

6.2 消融研究

为严格验证 FLAC 的鲁棒性和内部机制，我们进行了两组消融研究。

对目标能量预算的敏感性。我们首先研究 FLAC 对目标能量预算 E_{tgt} 的敏感性。如附录 E 所示，在各向同性动作生成先验下，预期动能




图 3 消融研究。 (a) 在 **h1-walk** 任务上对目标能量预算 E_{tgt} 的敏感性。**FLAC** 在广泛的预算范围内保持高性能，表明其鲁棒性。 (b) 在 **h1-run** (左) 和 **h1-walk** (右) 上自动拉格朗日调谐的有效性。训练过程中 $\log \alpha$ 的演变显示出“先降后升”的模式，表明 **FLAC** 自动放宽约束以促进早期学习，随后收紧约束以强制探索。

大致与动作维度线性相关，这促使采用维度归一化参数化 $E_{tgt} = C \cdot \dim(\mathcal{A})$ 。我们在广泛的系数范围 $C \in \{0, 0.1, 0.5, 2.5\}$ 内评估性能。

如图 3a 所示，FLAC 表现出鲁棒性，在广泛的能量预算范围内保持高性能。当预算紧张时 ($C \in \{0, 0.1\}$)，观察到显著的性能下降。具体而言， $C = 0$ 的极限情况对应于动能预算趋于零。在此状态下，调节机制严格抑制学习到的速度场，迫使策略完全随机。由此产生的性能不佳在理论上是预期的，并在经验上验证了动能约束的有效性，确认该机制有效地控制了与先验的偏差。除了这一极端状态外， E_{tgt} 的确切值并不关键，从而简化了超参数调谐。

自动调谐的有效性与动态。

为了理解 FLAC 的自动调谐，我们将其与固定正则化方案进行比较。图 3b 证实，自适应方法始终优于静态设置，后者通常因先验限制过强或正则化不足导致的不稳定而表现不佳。 $\log \alpha$ 的演变进一步揭示了一种明显的“先降后升”模式：最初放宽约束以促进激进的价值最大化，随后收紧约束以迫使策略在几何上更接近先验，从而防止模式崩塌。

此外，可学习乘子 $\log \alpha$ 的演化（如图 3b 所示）揭示了 FLAC 的内在机制。我们观察到一个明显的趋势： $\log \alpha$ 先下降后上升。在早期阶段，惩罚减小；这种放松使智能体能够优先通过到达高奖励区域来实现价值最大化。然而，在后期阶段， $\log \alpha$ 增大，从而收紧动能约束。通过迫使生成流保持较低能量，该机制将策略在几何上拉近到高熵先验。因此，这一过程在策略收敛时主动增强探索，有效防止过早的模式崩塌。这种动态行为有力地验证了我们的假设：动能正则化作为一种主动的、状态感知的调节器，自动引导智能体从激进学习过渡到熵约束收敛。

7 结论

本文提出了场最小能量演员-评论家 (FLAC)，建立了一个将强化学习映射到广义薛定谔桥框架的统一视角。我们从理论上证明了最大熵原理自然地从小化动能中产生，动能作为可计算的几何代理，用于约束与参考过程的散度，而无需显式密度估计。实验上，FLAC 在强基线对比中表现出极具竞争力的性能。然而，与标准最大熵方法类似，我们当前的框架对所有动作维度施加各向同性正则化。这将对不同执行器一视同仁，未来工作将致力于开发各向异性或状态依赖的能量约束，以更好地适应不同控制通道需要不同程度随机性的任务。

参考文献

- [1] Richard Bellman. A markovian decision process. *Journal of mathematics and mechanics*, pages 679–684, 1957.
- [2] Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the monge-kantorovich mass transfer problem. *Numerische Mathematik*, 84(3):375–393, 2000.
- [3] Onur Celik, Zechu Li, Denis Blessing, Ge Li, Daniel Palenicek, Jan Peters, Georgia Chalvatzaki, and Gerhard Neumann. Dime: Diffusion-based maximum entropy reinforcement learning. *arXiv preprint arXiv:2502.02316*, 2025.
- [4] Ricky TQ Chen, Yulia Rubanova, Jesse Bettencourt, and David K Duvenaud. Neural ordinary differential equations. *Advances in neural information processing systems*, 31, 2018.
- [5] Raphaël Chetrite, Paolo Muratore-Ginanneschi, and Kay Schwieger. E. schrödinger’s 1931 paper “on the reversal of the laws of nature”[“über die umkehrung der naturgesetze”, *sitzungsberichte der preussischen akademie der wissenschaften, physikalisch-mathematische klasse*, 8 n9 144–153]. *The European Physical Journal H*, 46(1):28, 2021.
- [6] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, page 02783649241273668, 2023.
- [7] Prafulla Dhariwal and Alexander Nichol. Diffusion models beat gans on image synthesis. *Advances in neural information processing systems*, 34:8780–8794, 2021.
- [8] Shutong Ding, Ke Hu, Zhenhao Zhang, Kan Ren, Weinan Zhang, Jingyi Yu, Jingya Wang, and Ye Shi. Diffusion-based reinforcement learning via q-weighted variational policy optimization. *arXiv preprint arXiv:2405.16173*, 2024.
- [9] Scott Fujimoto, Wei-Di Chang, Edward Smith, Shixiang Shane Gu, Doina Precup, and David Meger. For sale: State-action representation learning for deep reinforcement learning. *Advances in neural information processing systems*, 36:61573–61624, 2023.
- [10] Tuomas Haarnoja, Aurick Zhou, Pieter Abbeel, and Sergey Levine. Soft actor-critic: Off-policy maximum entropy deep reinforcement learning with a stochastic actor. In *International conference on machine learning*, pages 1861–1870. Pmlr, 2018.
- [11] Nicklas Hansen, Hao Su, and Xiaolong Wang. Td-mpc2: Scalable, robust world models for continuous control. *arXiv preprint arXiv:2310.16828*, 2023.
- [12] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. *Advances in neural information processing systems*, 33:6840–6851, 2020.
- [13] Vineet Jain, Tara Akhoun-Sadegh, and Siamak Ravanbakhsh. Sampling from energy-based policies using diffusion. *arXiv preprint arXiv:2410.01312*, 2024.
- [14] Christian Léonard. From the schrödinger problem to the monge–kantorovich problem. *Journal of Functional Analysis*, 262(4):1879–1920, 2012.
- [15] Christian Léonard. A survey of the schrödinger problem and some of its connections with optimal transport. *arXiv preprint arXiv:1308.0215*, 2013.
- [16] Sergey Levine, Aviral Kumar, George Tucker, and Justin Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020.
- [17] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [18] Guan-Horng Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos A. Theodorou, and Ricky T. Q. Chen. Generalized schrödinger bridge matching, 2024. URL <https://arxiv.org/abs/2310.02233>.
- [19] Jie Liu, Gongye Liu, Jiajun Liang, Yangguang Li, Jiaheng Liu, Xintao Wang, Pengfei Wan, Di Zhang, and Wanli Ouyang. Flow-grpo: Training flow matching models via online rl. *arXiv preprint arXiv:2505.05470*, 2025.
- [20] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.

- [21] Cheng Lu, Huayu Chen, Jianfei Chen, Hang Su, Chongxuan Li, and Jun Zhu. Contrastive energy prediction for exact energy-guided diffusion sampling in offline reinforcement learning. In International Conference on Machine Learning, pages 22825–22855. PMLR, 2023.
- [22] Lei Lv, Yunfei Li, Yu Luo, Fuchun Sun, Tao Kong, Jiafeng Xu, and Xiao Ma. Flow-based policy for online reinforcement learning. arXiv preprint arXiv:2506.12811, 2025.
- [23] Toshio Mikami. Monge’s problem with a quadratic cost by the zero-noise limit of h-path processes. Probability theory and related fields, 129(2):245–260, 2004.
- [24] Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning. arXiv preprint arXiv:2502.02538, 2025.
- [25] Michele Pavon, Giulio Trigila, and Esteban G Tabak. The data-driven schrödinger bridge. Communications on Pure and Applied Mathematics, 74(7):1545–1573, 2021.
- [26] Michael Psenka, Alejandro Escontrela, Pieter Abbeel, and Yi Ma. Learning a diffusion model policy from rewards via q-score matching. arXiv preprint arXiv:2312.11752, 2023.
- [27] Carmelo Sferazza, Dun-Ming Huang, Xingyu Lin, Youngwoon Lee, and Pieter Abbeel. Humanoidbench: Simulated humanoid benchmark for whole-body locomotion and manipulation. arXiv preprint arXiv:2403.10506, 2024.
- [28] Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion schrödinger bridge matching. Advances in Neural Information Processing Systems, 36:62183–62223, 2023.
- [29] Riley Simmons-Edler, Ben Eisner, Eric Mitchell, Sebastian Seung, and Daniel Lee. Q-learning for continuous actions with cross-entropy guided policies. arXiv preprint arXiv:1903.10605, 2019.
- [30] Yang Song, Jascha Sohl-Dickstein, Diederik P Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. arXiv preprint arXiv:2011.13456, 2020.
- [31] Richard S Sutton, Andrew G Barto, et al. Reinforcement learning: An introduction, volume 1. MIT press Cambridge, 1998.
- [32] Kirill Tamogashev and Nikolay Malkin. Data-to-energy stochastic dynamics. arXiv preprint arXiv:2509.26364, 2025.
- [33] Yuval Tassa, Yotam Doron, Alistair Muldal, Tom Erez, Yazhe Li, Diego de Las Casas, David Budden, Abbas Abdolmaleki, Josh Merel, Andrew Lefrancq, et al. Deepmind control suite. arXiv preprint arXiv:1801.00690, 2018.
- [34] Belinda Tzen and Maxim Raginsky. Theoretical guarantees for sampling and inference in generative models with latent diffusions. In Conference on Learning Theory, pages 3084–3114. PMLR, 2019.
- [35] Francisco Vargas, Pierre Thodoroff, Austen Lamacraft, and Neil Lawrence. Solving schrödinger bridges via maximum likelihood. Entropy, 23(9):1134, 2021.
- [36] Cédric Villani. Optimal Transport: Old and New, volume 338 of Grundlehren der mathematischen Wissenschaften. Springer Berlin Heidelberg, Berlin, Heidelberg, 2009. ISBN 978-3-540-71050-9. doi: 10.1007/978-3-540-71050-9. URL <https://link.springer.com/book/10.1007/978-3-540-71050-9>.
- [37] Yinuo Wang, Likun Wang, Yuxuan Jiang, Wenjun Zou, Tong Liu, Xujie Song, Wenxuan Wang, Liming Xiao, Jiang Wu, Jingliang Duan, et al. Diffusion actor-critic with entropy regulator. Advances in Neural Information Processing Systems, 37:54183–54204, 2024.
- [38] Zhendong Wang, Jonathan J Hunt, and Mingyuan Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. arXiv preprint arXiv:2208.06193, 2022.
- [39] Long Yang, Zhixiong Huang, Fenghao Lei, Yucun Zhong, Yiming Yang, Cong Fang, Shiting Wen, Binbin Zhou, and Zhouchen Lin. Policy representation via diffusion probability model for reinforcement learning. arXiv preprint arXiv:2305.13122, 2023.
- [40] Yixian Zhang, Shu’ang Yu, Tonghe Zhang, Mo Guang, Haojia Hui, Kaiwen Long, Yu Wang, Chao Yu, and Wenbo Ding. Sac flow: Sample-efficient reinforcement learning of flow-based policies via velocity-reparameterized sequential modeling. arXiv preprint arXiv:2509.25756, 2025.
- [41] Brian D Ziebart. Modeling purposeful adaptive behavior with the principle of maximum causal entropy. Carnegie Mellon University, 2010.

附录

A 正文中的证明 记号。在本附录中，我们用 $D(\|\cdot\|)$ 表示通用距离。我们分别在随机和确定性情形下分析动能。

$$\mathcal{E}(u) = \mathbb{E}[\int_0^1 \frac{1}{2} \|u_\tau\|^2 d\tau]$$

技术假设。为确保理论结果的适定性，我们在全文中做出以下标准假设：1. 漂移正则性：向量场 $u_\theta(s, \tau, x)$ 关于 x 是利普希茨连续的，并且适应于滤波。它满足诺维科夫条件 $\mathbb{E}[\exp(\frac{1}{2\sigma^2} \int_0^1 \|u\|^2 d\tau)] < \infty$ ，从而保证吉尔萨诺夫变换的有效性。

2. 有界性：动作空间 $\mathcal{A}$ 是有界的（例如， $[-1, 1]^d$ ），且奖励函数 $r(s, a)$ 是有界的。参考先验 μ_0 在 $\mathcal{A}$ 上是均匀的。3. 绝对连续性：策略分布 $\pi(\cdot|s)$ 相对于参考先验 μ_0 (i.e., $\pi \ll \mu_0$) 是绝对连续的，从而确保 KL 散度是良定义的。

A.1 随机机制：能量作为 KL 散度

我们推导出 SDE 的 KL 散度与动能之间的等价性 ($\sigma > 0$)。

设定。令 $\mathbb{P}_s^{\text{ref}}$ 为由 $dX_\tau = \sigma dW_\tau$ 诱导的参考路径测度。令 $\mathbb{P}_s^\theta$ 为由 $dX_\tau = u_\theta d\tau + \sigma dW_\tau$ 诱导的策略路径测度。两者共享初始分布 $X_0 \sim \mu_0$ 。

推导。定义 $\beta_\tau := \frac{1}{\sigma}$ 。根据 $u_\theta(s, \tau, X_\tau)$ 吉尔萨诺夫定理，对数 Radon-Nikodym 导数为：

$$\log \frac{d\mathbb{P}_s^\theta}{d\mathbb{P}_s^{\text{ref}}} = \int_0^1 \beta_\tau^\top dW_\tau - \frac{1}{2} \int_0^1 \|\beta_\tau\|^2 d\tau. \quad (19)$$

在测度 $\mathbb{P}_s^\theta$ 下，其中，we can rewrite $dW_\tau = d\widetilde{W}_\tau + \beta_\tau d\tau$
 W_τ 是标准布朗运动。

将其代回：

$$\log \frac{d\mathbb{P}_s^\theta}{d\mathbb{P}_s^{\text{ref}}} = \int_0^1 \beta_\tau^\top d\widetilde{W}_\tau + \frac{1}{2} \int_0^1 \|\beta_\tau\|^2 d\tau. \quad (20)$$

取期望 $\mathbb{E}_{\mathbb{P}_s^\theta}$ ，随机积分（鞅）项消失：

$$D_{\text{KL}}(\mathbb{P}_s^\theta \| \mathbb{P}_s^{\text{ref}}) = \mathbb{E}_{\mathbb{P}_s^\theta} \left[\frac{1}{2} \int_0^1 \|\beta_\tau\|^2 d\tau \right] = \frac{1}{\sigma^2} \mathcal{E}(u). \quad (21)$$

□

A.2 确定性机制：能量作为 Wasserstein-2 距离

我们证明，在常微分方程极限 ($\sigma \rightarrow 0$) 下，动能约束了沃瑟斯坦-2 距离。

设定。考虑描述概率密度 ρ_τ 演化的连续性方程，该方程由向量场 u_τ 驱动：

$$\partial_\tau \rho_\tau + \nabla \cdot (\rho_\tau u_\tau) = 0. \quad (22)$$

贝纳穆-布勒尼耶公式 [2] 指出，两个分布 μ_0 与 μ_1 之间的平方沃瑟斯坦-2 距离，是在所有将 μ_0 传输到 μ_1 的有效速度场中动能的下确界：

$$\mathcal{W}_2^2(\mu_0, \mu_1) = \inf_{(v, \rho)} \left\{ \int_0^1 \int_{\mathbb{R}^d} \|v(x, \tau)\|^2 \rho(x, \tau) dx d\tau \right\}, \quad (23)$$

受连续性方程和边界条件 $\rho_0 = \mu_0, \rho_1 = \mu_1$ 的约束。

与 FLAC 的联系。我们学习到的策略 u_θ 生成一个特定的流，将 μ_0 传输到终端分布 $\pi_\theta = \rho_1$ 。根据定义，我们特定流 $\mathcal{E}(u_\theta)$ 的能量是所有可能传输方案集合中的一个候选方案。因此，它作为最优传输成本的一个上界：

$$\mathcal{W}_2^2(\mu_0, \pi_\theta) \leq 2\mathcal{E}(u_\theta). \quad (24)$$

因此，最小化 $\mathcal{E}(u_\theta)$ 即最小化先验分布 μ_0 与策略 π_θ 之间几何距离的上界。此外，当 μ_0 为均匀分布时，该目标与最大熵目标相关，后者推动策略接近均匀分布。

注（常微分方程极限与熵）。在确定性（常微分方程）极限下，控制与均匀先验在 $\mathcal{W}_2$ 中的偏差是一种几何邻近约束，通常并不意味着较大的终端（微分）熵。

然而，在连续控制强化学习中，最大熵正则化的实际作用通常是通过维持广泛支撑的随机动作采样和持续探索，来防止策略过早集中和过早承诺次优模式（即较差的局部最优）。

从这个角度看，这种能量/ $\mathcal{W}_2$ 正则化提供了一个有用的替代方案：它惩罚激进的、大规模的传输（高控制代价），这在经验上抑制了概率质量的快速集中，并促进了对有界动作域的覆盖。

此外，将 $\mathcal{W}_2$ 邻近性与分布扩散解耦的理论构造通常依赖于极端的局部体积压缩，并且往往与诱导流的高度非均匀雅可比矩阵相关。在实践中，在我们的策略参数化和训练动态下，这类行为不太可能出现：使用一阶方法训练的神经网络表现出对更平滑、低复杂度解的经验性偏置（通常称为谱偏置），并且在我们的能量正则化下，所学习到的传输倾向于保持相对规则。因此，在确定性情形下，我们将能量/ $\mathcal{W}_2$ 约束视为一种几何归纳偏置，它在经验上缓解了全局坍塌并鼓励广泛支撑的动作采样，而不是作为一个严格的信息论界限。

□

A.3 终端熵控制的证明

我们证明最小化路径散度可以控制终端分布。

设 $\Pi(X_{0:1}) = X_1$ 为到终端状态的投影。设 $\pi_\theta = \mathbb{P}^{\mu_\theta}$

$$\circ \Pi^{-1} \text{ 及 } \mu_1^{\text{ref}} = \mathbb{P}_s^{\text{ref}} \circ \Pi^{-1}.$$

根据 f-散度（包括 KL 散度）的数据处理不等式（DPI）：

$$D_{\text{KL}}(\pi_\theta \|\mu_1^{\text{ref}}) \leq D_{\text{KL}}(\mathbb{P}_s^\theta \|\mathbb{P}_s^{\text{ref}}). \quad (25)$$

将此与附录 A.1 的结果结合，我们得到：

$$D_{\text{KL}}(\pi_\theta \|\mu_1^{\text{ref}}) \leq \frac{1}{\sigma^2} \mathcal{E}(s). \quad (26)$$

因此，最小化动能会迫使终端策略 π_θ 保持接近高熵先验 μ_1^{ref} 。此外，当 μ_1^{ref} 为均匀分布时，该目标与最大熵目标相关。

□

A.4 命题 1 的证明（最优广义薛定谔桥解）

命题重述。 最小化单端广义薛定谔桥目标（式 8）的唯一最优路径测度 $\mathbb{P}^*$ 诱导出如下形式的终端边缘分布 $p^*(X_1)$ ：

$$p^*(X_1) \propto p_{\text{ref}}(X_1) \cdot \exp\left(-\frac{\mathcal{G}(X_1)}{\alpha}\right).$$

证明。广义薛定谔桥问题可视为路径测度空间上的静态变分问题。目标函数为：

$$\mathcal{J}(\mathbb{P}) = \alpha \mathcal{D}(\mathbb{P} \|\mathbb{P}^{\text{ref}}) + \mathbb{E}_{\mathbb{P}}[\mathcal{G}(X_1)]. \quad (27)$$

回顾 KL 散度的定义为

$$\mathcal{D}(\mathbb{P} \|\mathbb{Q}) = \int \log\left(\frac{d\mathbb{P}}{d\mathbb{Q}}\right) d\mathbb{P}.$$

将其代入目标函数：

$$\mathcal{J}(\mathbb{P}) = \alpha \int \log\left(\frac{d\mathbb{P}}{d\mathbb{P}^{\text{ref}}}\right) d\mathbb{P} + \int \mathcal{G}(X_1) d\mathbb{P} \quad (28)$$

$$= \alpha \int \left[\log\left(\frac{d\mathbb{P}}{d\mathbb{P}^{\text{ref}}}\right) + \frac{\mathcal{G}(X_1)}{\alpha} \right] d\mathbb{P}. \quad (29)$$

注意 $\frac{\mathcal{G}(X_1)}{\alpha} = \log \exp\left(\frac{\mathcal{G}(X_1)}{\alpha}\right)$, thus:

$$\mathcal{J}(\mathbb{P}) = \alpha \int \log\left(\frac{d\mathbb{P}}{d\mathbb{P}^{\text{ref}}} \cdot \exp\left(\frac{\mathcal{G}(X_1)}{\alpha}\right)\right) d\mathbb{P}. \quad (30)$$

定义一个未归一化的辅助测度 $\tilde{\mathbb{Q}}$ ，使得

$$d\tilde{\mathbb{Q}} = \exp\left(-\frac{\mathcal{G}(X_1)}{\alpha}\right) d\mathbb{P}^{\text{ref}}.$$

则对数内部的项变为 $\frac{d\mathbb{P}}{d\tilde{\mathbb{Q}}}$ 。当 $\mathbb{P}$ 与归一化版本匹配时，目标函数达到最小。

$\tilde{\mathbb{Q}}$ 的版本。因此，最优测度 $\mathbb{P}^*$ 满足：

$$\frac{d\mathbb{P}^*}{d\mathbb{P}^{\text{ref}}}(\omega) \propto \exp\left(-\frac{\mathcal{G}(X_1(\omega))}{\alpha}\right). \quad (31)$$

在 $\tau = 1$ 处对该路径测度进行边缘化，得到终端分布：

$$p^*(X_1) = \frac{d\mathbb{P}_1^*}{dx}(x) \propto p_{\text{ref}}(X_1) \exp\left(-\frac{\mathcal{G}(X_1)}{\alpha}\right). \quad (32)$$

证明完毕。

□

A.5 命题 2 的证明

Fix a policy π .

贝尔曼算子。回顾能量正则化的贝尔曼评估算子：

$$(\mathcal{T}^\pi Q)(s, a) := r(s, a) + \gamma \mathbb{E}_{\substack{s' \sim p(\cdot | s, a) \\ a' \sim \pi(\cdot | s')}} [Q(s', a') - \alpha \mathcal{E}_\pi(s')]. \quad (33)$$

此处 $\mathcal{E}_\pi(s')$ 表示采样 $a' \sim \pi(\cdot | s')$ 所需的期望动能。

收缩于 $\|\cdot\|_\infty$. 对于任意两个有界函数 Q_1, Q_2 及任意 (s, a) , 有

$$|(\mathcal{T}^\pi Q_1)(s, a) - (\mathcal{T}^\pi Q_2)(s, a)| = \gamma |\mathbb{E}_{s', a'} [Q_1(s', a') - Q_2(s', a')]| \quad (34)$$

$$\leq \gamma \mathbb{E}_{s', a'} [|Q_1(s', a') - Q_2(s', a')|] \quad (35)$$

$$\leq \gamma \|Q_1 - Q_2\|_\infty, \quad (36)$$

其中期望分别对 $s' \sim p(\cdot | s, a)$ 和 $a' \sim \pi(\cdot | s')$ 取。

对 (s, a) 取上确界可得

$$\|\mathcal{T}^\pi Q_1 - \mathcal{T}^\pi Q_2\|_\infty \leq \gamma \|Q_1 - Q_2\|_\infty.$$

Thus $\mathcal{T}^\pi$ is a γ -contraction.

不动点的存在性与唯一性。根据不动点定理, $\mathcal{T}^\pi$ 具有唯一的不动点 Q^π 。

与正则化回报的对应关系。展开不动点方程 $Q^\pi = \mathcal{T}^\pi Q^\pi$ 可得

$$Q^\pi(s, a) = \mathbb{E} \left[r(s_0, a_0) + \gamma (Q^\pi(s_1, a_1) - \alpha \mathcal{E}_\pi(s_1)) \mid s_0 = s, a_0 = a \right] \quad (37)$$

$$= \mathbb{E} \left[\sum_{t \geq 0} \gamma^t r(s_t, a_t) - \alpha \sum_{t \geq 1} \gamma^t \mathcal{E}_\pi(s_t) \mid s_0 = s, a_0 = a \right], \quad (38)$$

其中 $s_{t+1} \sim p(\cdot | s_t, a_t)$ 及 $a_{t+1} \sim \pi(\cdot | s_{t+1})$.

□

A.6 命题 3 的证明

固定策略 π , 令 Q^π 为式 (11) (i.e., $Q^\pi = \mathcal{T}^\pi Q^\pi$.) 中定义的 $\mathcal{T}^\pi$ 的唯一不动点。

策略改进条件。假设更新后的策略 π_{new} 对所有状态 s 满足：

$$\mathbb{E}_{a \sim \pi_{\text{new}}(\cdot | s)} [Q^\pi(s, a)] - \alpha \mathcal{E}_{\pi_{\text{new}}}(s) \geq \mathbb{E}_{a \sim \pi(\cdot | s)} [Q^\pi(s, a)] - \alpha \mathcal{E}_\pi(s). \quad (39)$$

证明贝尔曼备份的一步改进。考虑贝尔曼评估算子 $\mathcal{T}^\pi$ 和 $\mathcal{T}^{\pi_{\text{new}}}$ 。

对任意 (s, a) ,

$$(\mathcal{T}^{\pi_{\text{new}}} Q^\pi)(s, a) = r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a)} \mathbb{E}_{a' \sim \pi_{\text{new}}(\cdot | s')} [Q^\pi(s', a') - \alpha \mathcal{E}_{\pi_{\text{new}}}(s')]. \quad (40)$$

Applying (39) at state s' yields

$$\mathbb{E}_{a' \sim \pi_{\text{new}}(\cdot | s')} [Q^\pi(s', a')] - \alpha \mathcal{E}_{\pi_{\text{new}}}(s') \geq \mathbb{E}_{a' \sim \pi(\cdot | s')} [Q^\pi(s', a')] - \alpha \mathcal{E}_\pi(s').$$

对 $s' \sim p(\cdot | s, a)$ 取期望并代回, 得到

$$(\mathcal{T}^{\pi_{\text{new}}} Q^\pi)(s, a) \geq r(s, a) + \gamma \mathbb{E}_{s' \sim p(\cdot | s, a)} \mathbb{E}_{a' \sim \pi(\cdot | s')} [Q^\pi(s', a') - \alpha \mathcal{E}_\pi(s')] \quad (41)$$

$$= (\mathcal{T}^\pi Q^\pi)(s, a). \quad (42)$$

由于 Q^π 是 $\mathcal{T}^\pi$ 的不动点, 有 $(\mathcal{T}^\pi Q^\pi)(s, a) = Q^\pi(s, a)$; 因此

$$(\mathcal{T}^{\pi_{\text{new}}} Q^\pi)(s, a) \geq Q^\pi(s, a), \quad \forall (s, a). \quad (43)$$

单调收敛到不动点。算子 $\mathcal{T}^{\pi_{\text{new}}}$ 是单调的：若 $Q_1 \leq Q_2$ 逐点成立，则 $\mathcal{T}^{\pi_{\text{new}}} Q_1 \leq \mathcal{T}^{\pi_{\text{new}}} Q_2$ （奖励项和能量项不依赖于 Q ，且期望保持序关系）。

Apply $\mathcal{T}^{\pi_{\text{new}}}$ iteratively to (43):

$$Q^\pi \leq \mathcal{T}^{\pi_{\text{new}}} Q^\pi \leq (\mathcal{T}^{\pi_{\text{new}}})^2 Q^\pi \leq \dots$$

根据命题 2, $\mathcal{T}^{\pi_{\text{new}}}$ is a γ -压缩；因此该序列在 $\|\cdot\|_\infty$ 中收敛到其唯一不动点 $Q^{\pi_{\text{new}}}$ 。取极限得到 $Q^{\pi_{\text{new}}}(s, a) \geq Q^\pi(s, a)$, $\forall (s, a)$, , 这证明了单调改进。

□

表 1 超参数

	Hyperparameter	Value
Hyperparameters	Optimizer	Adam
	Critic learning rate	3×10^{-4}
	Actor learning rate	3×10^{-4}
	Discount factor	0.99
	Batch Size	256
	Replay buffer size	1×10^6
	Target energy	$0.5 \cdot \dim(A)$
	NFE steps N	2
	Solver	Midpoint Euler
Value network	Network hidden dim	512
	Network hidden layers	3
	Network activation function	gelu
Policy network	Network hidden dim	512
	Network hidden layers	2
	Network activation function	elu

B 基线

在我们的实验中，我们使用原始代码库和官方结果实现了 SAC、TD7、DIME、SAC-FLOW 和 TD-MPC2。

- SAC [10], 我们使用了开源的 PyTorch 实现, 可在 <https://github.com/pranz24/pytorch-soft-actor-critic> 获取。
- TD7 [9] 通过其官方代码库集成到我们的实验中, 可在 <https://github.com/sfujim/TD7> 访问。
- TD-MPC2 [11] 采用了来自 <https://github.com/nicklashansen/tdmpc2> 的官方实现, 并使用了他们的官方结果。
- SAC-FLOW [40] 采用了来自 <https://github.com/Elessar123/SAC-FLOW.git> 的官方实现。
- DIME [3] 采用其官方实现, 来自 <https://github.com/ALRhub/DIME.git> 并使用其官方结果。
- FlowRL [22] 采用其官方实现, 来自 <https://github.com/bytedance/FlowRL>

C 环境细节

我们在 DMControl [33] 和 HumanoidBench [27] 上验证算法，包括最具挑战性的高维和 Unitree H1 人形机器人控制任务。在 DMControl 上，我们专注于最具挑战性的任务（狗和人形领域）。在 HumanoidBench 上，我们专注于不需要灵巧手的任务。

Task	State dim	Action dim
Humanoid Stand	67	24
Humanoid Run	67	24
Humanoid Walk	67	24
Dog Run	223	38
Dog Trot	223	38
Dog Stand	223	38
Dog Walk	223	38

表 2 DMControl 的任务维度。

Task	Observation dim	Action dim
H1 Crawl	51	19
H1 Hurdle	51	19
H1 Maze	51	19
H1 Pole	51	19
H1 Reach	57	19
H1 Run	51	19
H1 Sit Hard	64	19
H1 Sit Simple	51	19
H1 Slide	51	19
H1 Stair	51	19
H1 Stand	51	19
H1 Walk	51	19

表 3 HumanoidBench 的任务维度。

D 玩具示例设置

我们考虑一个二维多目标赌博机问题，以说明最小作用量正则化的效果。动作空间为 $\mathcal{A} = \mathbb{R}^2$ ，8 个目标位置均匀分布在一个半径为 4 的圆上：

$$g_k = \left(4 \cos \left(\frac{2\pi k}{8} \right), 4 \sin \left(\frac{2\pi k}{8} \right) \right), \quad k = 0, 1, \dots, 7. \quad (44)$$

奖励函数是所有目标上的最大高斯凸起：

$$r(a) = \max_k \exp \left(-\frac{\|a - g_k\|^2}{2} \right). \quad (45)$$

两种策略均使用具有基础分布 $\nu = \mathcal{N}(0, I)$ 和 $K = 24$ 个欧拉步骤的两层多层感知机漂移场。在没有正则化的情况下，朴素流崩塌到单一模式（覆盖率为 1/8），同时其动能爆炸式增长。流形作用量约束通过双重上升保持能量有界，并发现所有 8 个目标（覆盖率为 8/8），表明最小作用量正则化防止了模式崩塌。




图 4 任务域可视化。

E 目标动能估计

在我们的自适应动能预算机制中，对目标动能 E_{tgt} 的启发式调整直接受到软演员-评论家（Soft Actor-Critic, SAC）中目标熵启发式的启发。在 SAC 中，目标熵通常设置为 $\mathcal{H}_{\text{target}} = -\dim(\mathcal{A})$ ，以防止策略崩塌为确定性点质量。类似地，流形作用量约束需要一个参考值来调节控制努力与随机性之间的权衡。然而，由于我们在能量域而非熵域中操作，我们基于最优传输的物理原理推导出一个几何启发式。

在此，我们基于穿越动作空间所需的传输成本，推导出一个设置 E_{tgt} 的实用经验法则。

E.1 几何推导

考虑一个标准的连续控制场景，其中动作空间有界并归一化到 $\mathcal{A} = [-1, 1]^d$ 。生成式策略将潜在状态 X_τ 从基础分布 $X_0 \sim \mathcal{N}(0, I)$ （以原点为中心）演化到终端动作 X_1 。

单位位移代价。假设策略需要从先验均值（例如 $x = 0$ ）出发，生成可行空间边界处的动作（例如 $x = 1$ ）。根据最小作用量原理，最节能的轨迹是匀速路径（测地线）：

$$u(\tau) = v, \quad \text{where } v = \frac{\Delta x}{\Delta \tau} = \frac{1 - 0}{1} = 1.$$

该特定“单位”轨迹所消耗的动能为：

$$\mathcal{E}_{\text{unit}} = \int_0^1 \frac{1}{2} \|u(\tau)\|^2 d\tau = \int_0^1 \frac{1}{2} (1)^2 d\tau = 0.5.$$

这意味着，要将概率质量确定性地从动作空间中心移动到边界，系统每个维度至少需要消耗 0.5 单位的能量。

维度缩放。由于总动能对独立维度是可加的（因为平方范数 $\|u\|^2 = \sum_i u_i^2$ ），在所有 d 个维度上到达边界所需的总能量为 $0.5 \times d$ 。

E.2 能量预算公式

基于上述推导，我们将目标能量预算表示为动作维度的线性函数：

$$E_{\text{tgt}} = C \cdot \dim(\mathcal{A}), \quad (46)$$

其中 C 是能量因子，表示每个维度允许的平均动能。

与 SAC 的比较。在实验中，我们发现设置 $C \in [0.5, 2.5]$ 在所有任务上均能获得鲁棒性能，并且设置 $C=0.5$ 无需针对每个任务进行超参数调优。这为 SAC 的熵启发式提供了一种几何对应。

通过自动调节实现鲁棒性。关键在于，由于拉格朗日乘子 α 的自动调节机制， C 的具体选择并不十分敏感。自适应 α 动态调整惩罚权重，以平衡能量约束与奖励信号。因此，即使 C 并非最优，算法也能调整 α 以找到稳定平衡，使得 FLAC 远不如需要固定正则化权重的方法那样脆弱。

F 更多实验结果

F.1 对 NFE 的敏感性

在所有实验中，我们将函数评估次数（NFE）设为 2。经验表明，增加 NFE 确实有助于加速训练初期的收敛。然而，如图 5 所示，它对最终性能影响甚微。这表明，虽然更高的 NFE 可以促进更快的初始学习，但策略的最终有效性并不强烈依赖于该超参数。我们推测，这一现象源于动能正则化使学习到的生成动态偏向低能量轨迹，这些轨迹往往更短，且更接近从先验到动作的直线传输。这一效应也在玩具示例（图 1）中观察到，其中能量正则化产生了更直、更短的传输路径。




图 5 对 NFE 的敏感性。增加 NFE 可加速早期收敛，但对最终性能影响甚微。

这一发现支持了对于 FLAC 而言：使用较小且固定的 NFE 进行高效训练，同时不牺牲最终结果的质量。

F.2 效率

除了样本效率之外，我们还分析了算法在整体计算效率方面的表现，如图 6 所示。

图 6。具体而言，我们针对 DMC-hard 基准中的七个具有挑战性的任务，与 DIME 进行了对比研究。在这些实验中，横轴表示实际运行时间。尽管我们的实现基于 PyTorch（并使用 torch.compile 进行加速），但由于我们的方法对 NFE 超参数具有鲁棒性，我们的方法仍然比 DIME 更高效（DIME 在 NFE=2 处未能有效学习，其实现基于 JAX）。这表明，尽管底层框架存在差异，我们的方法仍实现了更优的计算效率。




图 6 与 DIME 的计算效率比较

F.3 综合结果

我们分别在 Fig. 8 和 Fig. 7 中报告了 DMC-Hard 和 HumanoidBench 上的完整结果。在 HumanoidBench 上，FLAC 在大多数任务上与所有基线方法持平或更优，仅在少数任务上不及一个强大的基于模型的基线；在 DMC-Hard 上，FLAC 在所有任务上与所有基线方法持平或更优。




图 7 Humanoid Bench 上的完整结果。




图 8 DMC-Hard 上的完整结果。