

一步流策略：面向快速视觉运动策略的自蒸馏方法

Shaolong Li

CSE Department, University of Michigan
shaolonl@umich.edu

Lichao Sun[†]

Lehigh University
lis221@lehigh.edu

Yongchao Chen[†]

College of AI, Tsinghua University
yongchaochen12@gmail.com

摘要

生成式流模型与扩散模型能够提供高精度机器人策略所需的连续、多模态动作分布。然而，它们对迭代采样的依赖会引入严重的推理延迟，降低控制频率，并在时间敏感的操控任务中损害性能。为解决这一问题，本文提出一步流策略（One-Step Flow Policy, OFP），一种无需预训练教师模型、从零开始的自蒸馏框架，用于高保真、单步动作生成。OFP 统一了自洽性损失，以强化跨时间间隔的一致传输，并引入自引导正则化，使预测向高密度专家模式锐化。此外，热启动机制利用时间动作相关性来最小化生成传输距离。在 56 个多样化的仿真操控任务上的评估表明，一步 OFP 达到了最先进的结果，优于 100 步扩散和流策略，同时将动作生成加速超过 $100\times$ 。我们进一步将 OFP 集成到 RoboTwin 2.0 上的 $\pi_{0.5}$ 模型中，其中一步 OFP 超越了原始的 10 步策略。这些结果确立了 OFP 作为一种实用、可扩展的解决方案，用于高精度和低延迟的机器人控制。

1 引言

视觉-语言-动作（Vision-Language-Action, VLA）模型在机器人操作 [1–4]、自动驾驶 [5, 6] 和长时程任务执行 [7–9] 方面进展迅速。在这种高维控制环境中，流模型和扩散模型已成为参数化条件策略的主导范式 [10–12, 4]。与离散分词相比，这些生成模型具有两个显著优势：它们能够自然地表示人类演示中固有的多模态动作分布，并且输出连续控制信号。这种连续输出对于高精度操控任务至关重要，因为细微的动作粒度决定了任务的成败。

尽管有这些优势，当前范式仍面临严重的推理延迟瓶颈。从流模型或扩散策略中采样通常需要迭代求解常微分方程（ODE）或随机微分方程（SDE），将样本从噪声先验传输到目标动作分布。这一过程需要数十到数百次通过大型神经网络的前向传播才能生成单个动作 [13, 14]。在高速抓取或动态交互等时间敏感的机器人应用中，这种延迟是难以接受的。动作生成延迟直接降低控制频率并加剧累积误差，经常导致任务失败。随着视觉-语言-动作（VLA）架构在规模和复杂度上的增长，一个核心挑战随之出现：

[†]通讯作者。

我们如何加速生成式策略，使其在几步甚至一步内输出高保真动作，同时不牺牲控制精度？

图像和视频生成领域的大量工作研究了如何加速流模型和扩散模型的采样 [15–18]，旨在以最少的函数评估次数（NFE）生成高保真输出。我们专注于基于流的模型，因为它们在工业界被广泛部署 [19, 10, 11]。扩散模型可视为流框架的一个特例，使得加速技术可以在不同参数化之间迁移。一种常见方法是采用高阶数值求解器来减少步数 [20, 21]。然而，在极端的少步情况下，离散化误差变得难以控制，严重降低生成质量。




图 1：在 56 个任务上取平均。在 NFE=1 处评估，OFP 优于所有其他单步基线，并且与 DP3 和 FM 策略相比，生成加速超过 $100 \times$ (NFE=100)。

另一类工作使用蒸馏 [22]，通常通过训练学生模型将预训练教师模型的轨迹压缩到更少的步骤中。主要有两个家族：一致性蒸馏（CD）[15, 16] 和分数蒸馏（SD）[18, 23, 24]。CD 强制自洽性约束，使轨迹上的点映射到同一端点，从而实现一步生成。SD 则将教师分数视为可微先验来优化生成器。最近，MeanFlow [17, 25] 尝试通过建模平均速度场实现一步生成，但在训练中引入了雅可比-向量积（JVP），显著增加了内存成本并使优化不稳定。

先前的工作直接将视觉加速思想应用于机器人策略学习以降低推理延迟，但他们对控制任务的影响尚未得到充分分析。因此，现有方法往往难以同时实现低延迟和高动作精度。一致性策略（Consistency Policy, CP）[26] 遵循一致性蒸馏范式。然而，由于其轨迹匹配目标 [27] 的模式覆盖特性，该策略倾向于对多模态动作分布进行平均。虽然这有助于少步推理，但由此产生的一步动作往往缺乏精确操作所需的锐度。相比之下，一步扩散策略（One-Step Diffusion Policy, OneDP）[28] 采用分数蒸馏方法。这些目标通常是模式寻求的 [29, 30]，导致策略坍缩到单一的高概率模式。虽然这能产生高质量的一步样本，但极大地降低了多样性。由于其设计，类似 OneDP 的方法仅支持单步推理，无法通过增加计算时间来换取更高的控制精度。

受这些观察的启发，本文提出了一步流策略（One-Step Flow Policy, OFP），它结合了两个方向的优势，无需辅助网络或预训练教师。OFP 是一个从零开始的自蒸馏框架，统一了两种互补信号：自洽性，强制传输动力学的跨时间一致性；以及自引导，注入分布级校正，将一步预测锐化到高密度专家行为。这种组合实现了高保真的一步推理，且无性能下降。此外，本文引入了一种热启动动作重用机制，为一步生成提供强先验，同时提高时间平滑性和控制精度。

本文的贡献总结如下：

- 本文提出了一种统一的基于流策略的自蒸馏方法，在不依赖教师模型的情况下解决了推理速度与动作精度之间的权衡。
- 本文将热启动动作初始化策略重新用作一种高效、无需训练的机制，以减少少步推理中的传输距离。
- 本文在涵盖 Adroit [31]、DexArt [32] 和 MetaWorld [33] 的 56 个模拟任务上取得了最先进的成功率。1-NFE 的 OFP 优于 100-NFE 的扩散和流基线，实现了超过 $100\times$ 的加速。
- 我们通过将 OFP 集成到 $\pi_{0.5}$ 模型 [11] 中来验证其可扩展性。在 RoboTwin 2.0 [34] 上，我们的 1 步集成超越了基线 10 步策略，证明了其在大容量系统和复杂语义下的鲁棒性。

2 预备知识

2.1 流匹配

设数据空间为 $\mathbb{R}^d$ 。我们旨在学习一个时间依赖的速度场 $\mathbf{v}_\theta: [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，该速度场定义了一个常微分方程（ODE）。由该 ODE 诱导的流 $\{\xi(t)\}_{t \in [0, 1]}$ 将基础分布 p_0 传输到目标数据分布 p_1 ：

$$\frac{d}{dt}\xi(t) = \mathbf{v}_\theta(\xi(t), t), \quad \xi(0) \sim p_0. \quad (1)$$

考虑一个概率路径 $\{p_t\}_{t \in [0, 1]}$ ，它在边界条件 p_0 和 p_1 之间插值。如果 $\mathbf{v}_\theta$ 与生成该路径的向量场相匹配，则解 $\xi(1)$ 将遵循目标分布 p_1 。流匹配通过回归目标速度场来训练 $\mathbf{v}_\theta$ 。然而，边缘速度场通常是不可解的。

为了使训练可行，条件流匹配（CFM）[14] 引入了条件概率路径。给定数据样本 $x_1 \sim p_1$ 和噪声 $\epsilon \sim p_0$ ，我们定义条件路径 $\mathbf{z}_t = a(t)x_1 + b(t)\epsilon$ ， $t \in [0, 1]$ ，其中 $a(0) = 0$ ， $b(0) = 1$ 和 $a(1) = 1$ ， $b(1) = 0$ 。时间导数为： $\dot{\mathbf{z}}_t(x_1, \epsilon) = a'(t)x_1 + b'(t)\epsilon$ 。边缘速度场对应于期望： $\bar{\mathbf{v}}(x, t) = \mathbb{E}[\dot{\mathbf{z}}_t(x_1, \epsilon) \mid \mathbf{z}_t = x]$ 。CFM 通过直接回归条件路径的导数来学习 $\mathbf{v}_\theta$ ：

$$\mathcal{L}_{\text{CFM}}(\theta) = \mathbb{E}_{t, x_1, \epsilon} \|\mathbf{v}_\theta(\mathbf{z}_t, t) - \dot{\mathbf{z}}_t(x_1, \epsilon)\|_2^2. \quad (2)$$

最小化式 (2) 得到的最优解与回归不可解的边缘速度场 $\bar{\mathbf{v}}(x, t)$ 相同。

采样涉及使用学习到的场 $\mathbf{v}_\theta$ 从 $\mathbf{z}_0 \sim p_0$ 开始积分式 (1)。实际上，这需要时间离散化（例如欧拉或 RK4 求解器），导致多次网络前向传播。这种迭代过程是主要的推理瓶颈。由于重叠轨迹的平均导致边缘速度场具有高曲率，标准求解器在低 NFE 情况下会产生较大的截断误差，导致样本质量较差。

2.2 基于流的生成式策略

本文考虑视觉运动模仿学习设定。设 $\mathcal{D} = \{(o^{(i)}, a^{(i)})\}_{i=1}^N$ 表示专家演示数据集。观测 $o \in \mathcal{O}$ 可包含本体感知、多视角 RGB 图像、点云及语言指令。动作 $a \in \mathbb{R}^{d_a H}$ 表示时域长度为 H 的轨迹块，通常参数化为末端执行器 SE(3) 位姿或关节角度。目标是学习条件生成式策略 $\pi_\theta(a \mid o)$ ，使其采样得到的动作与专家分布一致。

本文将第 2.1 节框架扩展至条件设定，定义观测条件下的速度场 $\mathbf{v}_\theta(x, t \mid o)$ 。部署时，策略通过从噪声先验 $\mathbf{z}_0 \sim p_0$ 积分条件常微分方程至终态 $\mathbf{z}_1$ 来生成动作 $\hat{a}$ 。推理成本随函数评估次数线性增长。

训练阶段，本文采用最优传输（Optimal Transport, OT）[35, 36] 公式构造噪声与数据之间的直线条件路径： $\mathbf{z}_t = (1-t)\epsilon + ta$ ， $\epsilon \sim p_0$ 。其导数为常数： $\dot{\mathbf{z}}_t = a - \epsilon$ 。本文通过以下回归目标训练条件速度场：

$$\mathcal{L}_{\text{policy}}(\theta) = \mathbb{E}_{(o, a) \sim \mathcal{D}} \mathbb{E}_{t \sim p_T, \epsilon \sim p_0} \|\mathbf{v}_\theta(\mathbf{z}_t, t \mid o) - (a - \epsilon)\|_2^2. \quad (3)$$

此处 p_T 为在 $t \in [0, 1]$ 上选取的采样分布。

3 单步流策略

本节提出单步流策略（One-Step Flow Policy, OFP），一种面向快速高精度视觉运动控制的从零开始自蒸馏框架。第 3.1 节详述自治性训练，该训练学习区间平均速度场以强化轨迹间的时间一致性。第 3.2 节提出自引导正则化，该机制显式地将单步动作预测锐化至高密度专家模式。第 3.3 节引入利用连续动作块时间相关性的热启动机制，以提供强初始化先验。




图 2：单步流策略的自蒸馏。 (a) 自洽性训练：模型通过匹配嵌套子区间上的预测来学习区间平均速度场，从而强化沿边缘流轨迹的时间一致性。(b) 自引导训练：通过对模型自身预测施加无分类器引导，本文提取分布级校正信号。该正则化将单步预测推离无条件先验，并将生成动作锐化至专家数据的高密度模式。

3.1 自洽性训练

为消除推理过程中对迭代常微分方程（ODE）积分的依赖，本文学习区间平均速度场，而非标准流匹配（Flow Matching）中使用的瞬时速度 [14, 35]。具体而言，本文对 $\mathbf{u}_\theta(\mathbf{z}_t, t, r | o)$ 进行参数化，其中 $0 \leq t \leq r \leq 1$ ，表示从 t 到 r 轨迹上的平均速度。为简洁起见，在上下文清晰时省略条件 o 。

给定 $\mathbf{u}$ ，任意区间的更新规则定义为： $\mathbf{z}_r = \mathbf{z}_t + (r - t)\mathbf{u}(\mathbf{z}_t, t, r)$ 。当 $r \rightarrow t^+$ ， $\mathbf{u}(\mathbf{z}_t, t, r)$ 退化为瞬时速度，在对角线上保持与流匹配的理论一致性。

给定数据-噪声对 $((o, a), \epsilon) \sim \mathcal{D} \times p_0$ ，采样两个时间 $(t, r) \sim p_{T,R}$ ，满足 $t < r$ ，并抽取中间时间 $m \in [t, r]$ 。利用最优传输（OT）直线插值，得到 $\mathbf{z}_m = (1 - m)\epsilon + ma$ 。模型的指数移动平均（EMA）副本，记为 $\mathbf{u}_{\theta^-}$ ，作为教师预测轨迹终点 $\hat{\mathbf{z}}_r = \mathbf{z}_m + (r - m)\mathbf{u}_{\theta^-}(\mathbf{z}_m, m, r)$ 。根据区间 $[t, r]$ 上平均速度的定义，定义训练目标：

$$\mathbf{u}_{\text{target}} = \frac{\hat{\mathbf{z}}_r - \mathbf{z}_t}{r - t}. \quad (4)$$

本文通过最小化自洽性损失来训练 $\mathbf{u}_\theta$ ：

$$\mathcal{L}_{\text{self-consistency}}(\theta) = \mathbb{E}_{(o, a) \sim \mathcal{D}} \mathbb{E}_{(t, r, m) \sim p_{T, R, M}} \mathbb{E}_{\epsilon \sim p_0} \left\| \mathbf{u}_\theta(\mathbf{z}_t, t, r | o) - \mathbf{u}_{\text{target}} \right\|_2^2. \quad (5)$$

该目标函数充当自蒸馏机制，其中教师是缓慢演化的 EMA 副本 θ^- 。

时间收缩调度。 本文从随训练进行逐渐收缩至 t 的范围内采样 m ：

$$m \sim \mathcal{U}[t, t + (r - t)\rho(s)]. \quad (6)$$

此处， $\rho(s)$ 是训练步数 s 的单调递减函数。在训练初期， $(\rho(s) \approx 1)$ ， m 在整个区间 $[t, r]$ 内采样。这使得目标 $\mathbf{u}_{\text{target}}$ 能够更多地依赖插值状态 $\mathbf{z}_m$ ，而非未经训练的教师模型 $\mathbf{u}_{\theta^-}$ 。这有效减少了由未经训练的教师模型引起的自举误差。随着训练的进行（ $\rho(s) \rightarrow 0$ ），采样范围收缩，使得 $m \rightarrow t$ 。这将目标转变为沿真实轨迹强制严格的局部自洽性。

命题 1. 在区间速度场连续可微且关于状态全局利普希茨连续的假设下，当收缩因子 $\rho(s) \rightarrow 0$ 且指数移动平均教师模型 $\mathbf{u}_\theta$ 准确时， $\mathbf{u}_{\text{target}}$ 成为真实平均速度 $\mathbf{u}(\mathbf{z}_t, t, r)$ 的一致监督信号，且最小化 $\mathcal{L}$ 自洽性满足 $\mathbf{u}_\theta \approx \mathbf{u}$ 。

详细推导见附录 A.1。命题 1 表明，时间收缩调度提供了一种平滑的课程：从稳定初始化过渡到细化轨迹精度。

与 MeanFlow 的比较。 关键在于，构建目标 $\mathbf{u}_{\text{target}}$ 避免了 MeanFlow 所需的昂贵的雅可比向量积 (JVP) 计算 [17, 25]。MeanFlow 依赖于微分目标，这显著增加了内存开销和实际训练时间。相比之下，本文的方法仅依赖前向传播。我们在附录 A.2 中提供了正式证明，表明当区间 $(m - t) \rightarrow 0$ 时，本文的自洽性目标收敛于 MeanFlow 目标中导数项的有限差分近似。

边界锚定。 为了约束解空间并确保策略保持在专家数据分布中，本文引入边界锚定损失。该项对瞬时速度施加标准的流匹配监督：

$$\mathcal{L}_{\text{flow}}(\theta) = \mathbb{E}_{(o,a) \sim \mathcal{D}} \mathbb{E}_{t \sim \mathcal{U}[0,1], \epsilon \sim p_0} \left\| \mathbf{u}_\theta(\mathbf{z}_t, t, t \mid o) - (a - \epsilon) \right\|_2^2. \quad (7)$$

该锚定项确保 OFP 保留高质量多步生成的能力。

自洽性目标函数充当轨迹匹配机制。该公式在少步机制（例如 2 至 4 步）下展现出强大的性能，并保持了动作分布的多样性。然而，我们发现仅靠自洽性在单步机制下往往无法为复杂操作提供足够的精确率。为解决这一局限性，我们在第 3.2 节引入自引导正则化。

3.2 自引导正则化

虽然自洽性（第 3.1 节）约束了跨时间间隔的轨迹一致性，但它并未明确强制单步预测与专家分布的高密度模式对齐。

为施加分布层面的约束，我们引入基于分数的正则化器。分数函数 $\nabla_x \log p(x)$ 指向更高密度区域。我们将其用作引导信号，以将生成的动作引导至专家数据流形。

单步采样与再噪声化。 设 $\epsilon_0, \epsilon_1 \sim \mathcal{N}(0, I)$ 为独立噪声，且 $(o, a) \sim \mathcal{D}$ 。对于时间 $t \in [0, 1]$ ，定义线性混合 $\mathbf{z}_t = (1 - t)\epsilon_0 + ta$ 。策略通过单次区间跳跃生成单步预测： $\hat{a} \triangleq \hat{\mathbf{z}}_1 = \mathbf{z}_t + (1 - t)\mathbf{u}_\theta(\mathbf{z}_t, t, 1 \mid o)$ 。为了比较策略的边际分布与专家分布，我们在新时间 $t' \sim \mathcal{U}[0, 1]$ 对 $\hat{a}$ 进行再噪声化： $\tilde{\mathbf{z}}_{t'} = (1 - t')\epsilon_1 + t'\hat{a}$ 。

设 $\pi_\theta(\cdot \mid \tilde{\mathbf{z}}_{t'} \mid o)$ 表示以 o 为条件的 $\tilde{\mathbf{z}}_{t'}$ 的策略诱导边际分布，并设 $\pi_\star(\cdot \mid \tilde{\mathbf{z}}_{t'} \mid o)$ 表示相应的专家分布。我们的目标是最小化 $\pi_\theta(\cdot \mid o)$ 与 $\pi_\star(\cdot \mid o)$ 之间的反向库尔贝克-莱布勒 (KL) 发散：

$$D_{\text{KL}}(\pi_\theta(\tilde{\mathbf{z}}_{t'} \mid o) \parallel \pi_\star(\tilde{\mathbf{z}}_{t'} \mid o)) = \mathbb{E}_{\tilde{\mathbf{z}}_{t'} \sim \pi_\theta(\cdot \mid o)} [\log \pi_\theta(\tilde{\mathbf{z}}_{t'} \mid o) - \log \pi_\star(\tilde{\mathbf{z}}_{t'} \mid o)]. \quad (8)$$

方程 (8) 关于 θ 的梯度可以写为分数差项：

$$\begin{aligned} & \nabla_\theta D_{\text{KL}}(\pi_\theta \parallel \pi_\star) \\ &= \mathbb{E} \left[\left(\nabla_{\tilde{\mathbf{z}}_{t'}} \log \pi_\theta(\tilde{\mathbf{z}}_{t'} \mid o) - \nabla_{\tilde{\mathbf{z}}_{t'}} \log \pi_\star(\tilde{\mathbf{z}}_{t'} \mid o) \right) \frac{\partial \tilde{\mathbf{z}}_{t'}}{\partial \theta} \right] \\ &= \mathbb{E} \left[\left(s_\theta(\tilde{\mathbf{z}}_{t'} \mid o) - s_\star(\tilde{\mathbf{z}}_{t'} \mid o) \right) \frac{\partial \tilde{\mathbf{z}}_{t'}}{\partial \theta} \right], \end{aligned} \quad (9)$$

其中 $s(\cdot) = \nabla_{\tilde{\mathbf{z}}_{t'}} \log p(\cdot)$ 表示得分函数。

通过无分类器引导 (Classifier-Free Guidance, CFG) 实现自引导。 为增强条件信号，本文引入无分类器引导 (CFG) [37]。给定引导尺度 $\alpha \geq 1$ 和空条件 ϕ ，经 CFG 调整的专家得分为

defined as: $s_{\star}^{\text{CFG}}(\tilde{\mathbf{z}} \mid o) = s_{\star}(\tilde{\mathbf{z}} \mid o) + (\alpha - 1)(s_{\star}(\tilde{\mathbf{z}} \mid o) - s_{\star}(\tilde{\mathbf{z}} \mid \phi))$. 将该形式代入式 (9) 揭示了其分解为两个分量:

$$s_{\theta}(\tilde{\mathbf{z}}_{t'} \mid o) - s_{\star}^{\text{CFG}}(\tilde{\mathbf{z}}_{t'} \mid o) = \underbrace{(\alpha - 1)(s_{\star}(\tilde{\mathbf{z}}_{t'} \mid \phi) - s_{\star}(\tilde{\mathbf{z}}_{t'} \mid o))}_{\text{CFG Augmentation}} + \underbrace{(s_{\theta}(\tilde{\mathbf{z}}_{t'} \mid o) - s_{\star}(\tilde{\mathbf{z}}_{t'} \mid o))}_{\text{Distribution Matching}}. \quad (10)$$

近期对 DMD 式训练的分析 [38, 39] 表明, CFG 增强 (CFG-Augmentation, CA) 项是样本质量的主要驱动因素。受此启发, 本文仅使用 CA 项作为引导信号。直观上, CA 项引导模型趋向条件分布。与依赖预训练教师计算 $s_{\star}$ 的先前工作 [40, 28] 不同, 本文利用指数移动平均 (EMA) 教师 $\mathbf{u}_{\theta-}$ 估计得分, 从而获得自引导训练信号。

对于最优传输 (OT) 概率路径 $\tilde{\mathbf{z}}_t = (1 - t)\epsilon + t\mathbf{a}$, 时间 t 处的边际得分与瞬时速度之间存在解析关系:

$$s(\tilde{\mathbf{z}}_t \mid o) = \frac{t\mathbf{u}(\tilde{\mathbf{z}}_t, t, t \mid o) - \tilde{\mathbf{z}}_t}{1 - t}. \quad (11)$$

随后构建自引导目标:

$$\mathbf{s}_{\text{target}} = \text{sg} \left[\mathbf{u}_{\theta}(\mathbf{z}_t, t, 1 \mid o) - (\mathbf{u}_{\theta-}(\tilde{\mathbf{z}}_{t'}, t', t' \mid \phi) - \mathbf{u}_{\theta-}(\tilde{\mathbf{z}}_{t'}, t', t' \mid o)) \right], \quad (12)$$

其中 $\text{sg}[\cdot]$ 表示停止梯度算子。

本文将自引导损失定义为一步预测与引导目标之间的平方误差:

$$\mathcal{L}_{\text{self-guidance}}(\theta) = \mathbb{E}_{(o, a) \sim \mathcal{D}} \mathbb{E}_{t, t' \sim \mathcal{U}[0, 1], \epsilon \sim p_0} \left[\left\| \mathbf{u}_{\theta}(\mathbf{z}_t, t, 1 \mid o) - \mathbf{s}_{\text{target}} \right\|^2 \right]. \quad (13)$$

最小化式 (13) 可得到 $\mathbf{u}_{\theta}$ 的梯度, 使更新方向与 CA 项对齐 (证明见附录 A.3), 从而有效地将生成过程推离无条件模式。由于引导信号由模型自身产生, 该目标也可视为一种自蒸馏形式。

自引导项需要无条件分支。本文通过条件随机失活实现: 训练时, 以概率 p_{drop} 将观测 o 随机替换为空标记 ϕ , 使单一网络能够同时捕捉条件动态与无条件动态。

统一目标。 本文将流锚定损失 (式 (7))、自洽性损失 (式 (5)) 与自引导损失 (式 (13)) 合并为统一训练目标:

$$\mathcal{L}_{\text{self-distill}}(\theta) = \mathcal{L}_{\text{flow}}(\theta) + \lambda_c \mathcal{L}_{\text{self-consistency}}(\theta) + \lambda_g \mathcal{L}_{\text{self-guidance}}(\theta). \quad (14)$$

实验表明, 加入自引导可显著提升一步输出的精确率。这些信号的组合使 OFP 在少步与一步生成中均达到最先进的性能。完整训练流程见算法 1。

推理。 OFP 支持灵活的采样策略。为实现最小延迟, 我们通过与噪声进行单次全局跳跃生成一步动作预测 $\hat{\mathbf{a}}$: $\hat{\mathbf{a}} = \epsilon + \mathbf{u}_{\theta}(\epsilon, 0, 1 \mid o), \epsilon \sim \mathcal{N}(0, I)$. 或者, 为达到更高精确率, 模型可通过链式区间预测作为多步求解器运行。给定时间离散化方案 $0 = \tau_0 < \tau_1 < \dots < \tau_K = 1$, 我们通过查询每个子区间上的平均速度递归更新状态 $[\tau_k, \tau_{k+1}]$: 这允许策略以增加推理 $\tilde{\mathbf{z}}_{\tau_{k+1}} = \tilde{\mathbf{z}}_{\tau_k} + (\tau_{k+1} - \tau_k)\mathbf{u}_{\theta}(\tilde{\mathbf{z}}_{\tau_k}, \tau_k, \tau_{k+1} \mid o)$. 时间来换取更精细的控制。




图 3: 用于一步推理的热启动动作先验。先前生成的动作块中未执行的后缀被移位并用末端动作填充, 形成完整长度的时序先验。通过从更接近目标数据流形的位置开始, 而非从纯高斯噪声开始, 该初始化减少了所需的传输距离。

3.3 Warm-Start for One-Step Inference

热启动在动作分块生成策略中被广泛使用 [41, 42], 以提升滚动时域执行中的平滑性和执行效率。在此, 我们重新利用热启动来减轻单步推理的生成负担。通过利用连续块之间的高时序相关性, 我们构建了一个强先验, 降低了到达目标动作分布所需的传输成本。

In a receding-horizon control loop with execution horizon $h < H$, the robot executes the first h actions. The unexecuted suffix

represents a valid plan for the current step, $a_{\text{left}} = [a_{h+1}, \dots, a_H] \in \mathbb{R}^{d_a(H-h)}$. We construct a full-length warm-start prior a_{warm} by shifting the unexecuted suffix and padding the terminal action:

$$a_{\text{warm}} = [a_{h+1}, \dots, a_H, \underbrace{a_H, \dots, a_H}_{h \text{ times}}] \in \mathbb{R}^{d_a H}. \quad (15)$$

热启动生成。 我们不是从无信息的高斯噪声中采样, 而是从热启动先验的加噪投影初始化生成器。我们选择噪声水平 $t_w \in (0, 1]$ 并采样 $\epsilon \sim \mathcal{N}(0, I)$ 来构造初始状态: $\mathbf{z}_{t_w} = (1 - t_w)\epsilon + t_w a_{\text{warm}}$. 然后策略可以通过单次区间更新生成下一个动作块 $\hat{a}$: $\hat{a} = \mathbf{z}_{t_w} + (1 - t_w)\mathbf{u}_\theta(\mathbf{z}_{t_w}, t_w, 1 \mid o)$. 该公式在结构上与第 3.2 节中使用的重加噪形式一致, 使得推理时初始化与训练时引导构造保持一致。我们在

图 3 中说明了该热启动先验的构造, 其在滚动时域控制问题中的应用。

使用 a_{warm} 初始化显著减少了流在单步中必须跨越的传输距离。通过从更接近数据流形的位置开始, 策略在不增加额外训练或计算开销的情况下, 实现了更高的精确率和更好的时序平滑性。

4 实验

为评估 OFP 的有效性, 我们在 4 个操作基准上进行了广泛的仿真实验: Adroit [31]、DexArt [32]、MetaWorld [33] 和 RoboTwin 2.0 [34]。我们的

表 1：基于 2D 图像的操作性能。结果在 3 个随机种子上取平均。每列中的最佳性能以粗体突出显示。

Method	NFE	Door	Hammer	Pen	Bucket	Faucet	Laptop	Toilet	Average
DP	100	51.7±4.0	100.0±0.0	67.7±1.2	34.7±4.7	38.7±1.5	80.3±2.9	76.0±1.7	64.2±2.3
DP	10	44.7±1.5	100.0±0.0	66.7±1.5	32.7±4.0	35.0±2.6	81.0±2.6	66.0±3.6	60.9±2.3
FM Policy	100	63.7±2.1	100.0±0.0	69.7±2.1	31.7±1.2	40.7±2.3	84.7±2.5	79.7±1.5	67.2±1.7
FM Policy	10	61.3±3.2	97.3±3.1	64.7±3.8	27.7±2.3	32.7±3.8	87.0±1.7	77.3±1.5	64.0±2.8
CP	1	46.3±3.5	100.0±0.0	58.7±5.7	30.7±2.5	33.3±0.6	79.0±2.6	69.7±3.1	59.7±2.6
OneDP	1	53.3±5.1	100.0±0.0	64.7±1.5	32.7±1.2	40.0±1.7	76.3±2.9	76.3±2.3	63.3±2.1
MP1	1	49.3±6.0	96.3±3.5	57.3±4.9	31.7±6.7	33.0±7.5	83.7±1.5	72.3±4.6	60.5±5.0
OFP (Ours)	1	68.3±3.1	100.0±0.0	69.3±1.5	33.3±2.5	41.0±1.7	85.7±3.5	80.7±2.5	68.3±2.1

表 2：基于 3D 点云的操作性能。我们在 56 个具有挑战性的任务上使用 3 个随机种子评估性能。

Method	NFE	Adroit (3)	DexArt (4)	MetaWorld Easy (28)	MetaWorld Medium (11)	MetaWorld Hard (5)	MetaWorld Very Hard (5)	Average
DP3	100	79.0±0.6	63.7±0.6	82.8±8.0	46.5±3.8	38.3±9.6	41.0±0.6	66.4±5.7
DP3	10	76.0±3.3	61.5±0.9	80.8±2.1	46.2±1.4	36.3±8.2	45.3±5.7	65.2±2.8
FM Policy	100	83.3±0.7	61.7±4.2	68.9±5.7	42.3±3.8	43.6±3.4	47.7±4.5	59.8±4.6
FM Policy	10	80.3±1.8	60.5±4.5	66.7±7.7	41.3±7.4	40.3±7.2	46.7±7.6	57.9±7.0
CP	1	76.3±4.6	60.7±3.4	68.3±1.8	32.1±4.3	28.7±5.2	36.0±2.3	54.7±2.9
OneDP	1	77.3±1.8	62.5±4.1	77.7±0.5	39.6±9.2	38.7±4.4	41.7±1.6	62.4±3.0
MP1	1	82.0±2.1	61.0±2.0	70.5±6.1	37.9±5.9	34.3±9.5	32.3±5.5	57.4±5.8
OFP (Ours)	1	85.0±4.5	64.3±2.5	87.9±4.6	52.4±5.7	43.3±2.4	49.2±0.7	71.6±4.1

评估回答三个核心问题：1) OFP 能否在仅需单次网络评估的情况下，达到或超过标准多步扩散和流策略的性能？2) OFP 在稳定性、准确率和扩展能力方面与现有单步加速方法相比如何？3) OFP 能否有效扩展到现代 VLA 架构而不出现性能崩溃？

4.1 实验设置

我们将评估分为基于 2D 图像和基于 3D 点云的控制设置。对于 2D 评估，我们在 Adroit [31] 的 3 个任务和 DexArt [32] 的 4 个任务上进行测试。对于 3D 评估，我们在这 7 个任务以及 MetaWorld [33] 的 49 个任务上进行测试。Adroit 和 DexArt 评估单任务学习，而 MetaWorld 评估大规模多任务学习。遵循先前工作 [43]，我们将 49 个 MetaWorld 任务分为 4 个经验难度级别：简单、中等、困难和非常困难。

基线。我们将 OFP 与五个强大的生成式策略基线进行对比：扩散策略（DP）[41] 和流匹配策略（FM Policy）[44] 作为多步控制；一致性策略（CP）[26] 和一步扩散策略（OneDP）[28] 代表蒸馏方法；以及 MP1 [45] 适配 MeanFlow [17]。对于 3D 设置，我们利用 DP3 [46]，并使用相同的点编码器适配流匹配策略。CP 和 OneDP 从预训练的 DP3 教师模型蒸馏而来，而 OFP 和 MP1 则从头训练。所有评估共享相同设置，并在 3 个随机种子上取平均（报告为均值 ± 标准差）。详细的实验设置和评估度量见附录 B 和 C。

4.2 实验结果

二维图像条件评估。表 1 报告了二维任务上的结果。OFP 在所有单步方法中取得了最高的平均成功率。它还超越了强大的多步基线。在 NFE = 1 时，OFP 达到 68.3%，高于 NFE = 100 时的 DP（64.2%）和 NFE = 100 时的 FM 策略（67.2%）。这表明所提出的自蒸馏目标不仅降低了延迟，还显著提升了最终动作质量。在训练过程中，MP1 表现出高方差和频繁的损失尖峰。这与其目标中 JVP 操作引入的额外数值敏感性一致。OFP 通过训练区间平均目标避免了 JVP，从而实现了更稳定的优化和更好的控制准确率。

三维点云条件评估。表 2 展示了三维场景下更为显著的提升。OFP 在绝大多数任务中取得了最高的成功率。在 NFE = 1 条件下，其性能优于 DP3

表 3: 少步与一步生成对比。 OFP 支持灵活采样，在一步时保持高性能，并在更多生成步骤下可靠提升准确率。

Method	NFE	Bucket	Faucet	Laptop	Toilet	Average
OneDP	1	32.7±5.8	44.7±3.1	89.3±3.8	83.3±3.8	62.5±4.1
CP	1	29.3±3.5	44.3±3.8	86.7±2.5	82.3±3.8	60.7±3.4
	4	38.3±4.2	43.7±1.2	90.0±3.5	84.7±2.9	64.2±2.9
OFP	1	39.3±0.6	45.7±3.8	91.7±3.2	81.3±3.2	64.5±2.7
	4	42.7±2.1	47.0±1.0	92.3±4.2	83.0±1.7	66.2±2.2

在 $NFE = 100$ 时平均提升 8%，且在 $NFE = 100$ 时超过 3D FM Policy 19.7%。这一优势在 MetaWorld 多任务设置中尤为明显，OFP 同时提升了平均性能和跨难度级别的鲁棒性。这些结果支持了自引导正则化的作用，该正则化使动作分布更加尖锐，并减少了标准流目标中常见的过度平滑现象。

图 1 展示了所有 56 个任务中推理时间与成功率之间的权衡。OFP 在保持单步低延迟机制的同时，达到了最佳平均成功率。在墙钟时间方面，OFP 每个动作块需要 17.58 毫秒，相比之下，DP3 在 $NFE = 100$ 时需要 3225.67 毫秒，3D FM Policy 在 $NFE = 100$ 时需要 1865.72 毫秒。这分别对应约 183× 倍和 106× 倍的加速。OFP 比 OneDP 和 MP1 稍慢，因为热启动增加了少量计算，但准确率的提升足以证明这一成本是合理的。

延迟与准确率权衡。 OneDP 类方法的一个基本局限性是它们仅支持单步推理。相比之下，CP 等轨迹匹配方法支持多步生成，但通常单步预测精度较低。OFP 结合了两者的优势。如表 3 所示，在多个任务上，OneDP 在 $NFE = 1$ 时强于 CP。然而，一旦允许更多步骤，CP 的性能会提升。OFP 在 $NFE = 1$ 时保持强劲，并在 $NFE = 4$ 时进一步提升，这表明同一模型既能提供低延迟的单步控制，又能在计算预算稍大时获得更高的准确率。

消融研究。 为分离核心组件的贡献，我们进行了针对性的消融研究。具体而言，我们在固定训练条件下独立消融每个模块，以评估其对单步和少步成功率的影响。结果表明，自洽性训练对于可靠的少步推理是必要的，而自引导正则化则驱动了单步场景下的性能提升。经验表明，自洽性与自引导训练相互补充。此外，热启动机制作为一种无需训练的推理先验，能够在任意步数下持续提升生成质量。统一这些机制使得 OFP 能够在单步和少步控制中均实现高准确率。我们在附录 D 中报告了这些消融实验的详细结果。

数据效率与扩展性。 我们研究了在 DexArt Faucet 任务上性能随数据可用性的扩展情况（图 4）。在数据极为有限的情况下，仅使用 20 个演示时，MP1 的性能急剧下降。相比之下，OFP 保持了鲁棒的成功率，表明自引导正则化在低数据场景下提供了更强的学习信号。随着演示数量的增加，OFP 从 32.7% 稳步提升至 51.0%。MP1 起初有所改善，但在 100 个演示后出现下降。

4.3 与 VLA 模型的集成

现代 VLA 系统通常需要大规模过参数化模型，并基于丰富的多模态语义来条件化动作生成。然而，基于自举的方法在模型容量增大时可能遭遇秩坍塌 [47, 48]。为验证 OFP 在此场景下是否仍然有效，




图 4: 数据扩展行为。 OFP 从稀疏数据（20 个演示）中提取了更高的效用，并随着数据增加持续平稳扩展，避免了 MP1 在 150 个演示时出现的性能下降。




图 5: 在 RoboTwin 2.0 上迁移至 $\pi_{0.5}$ 。所有加速方法均在 NFE=1 下评估, $\pi_{0.5}$ 基线在 NFE=10 下运行。OFP 在四个任务上取得了最佳平均成功率, 表明 OFP 即使对于具有更丰富多模态输入的大规模 VLA 模型仍然有效。



图 6: RoboTwin 2.0 任务可视化。评估采用领域随机化以测试视觉变化下的鲁棒性。

为验证该场景, 我们将其集成到 $\pi_{0.5}$ 模型中, 并在 RoboTwin 2.0 中进行评估。图 6 可视化了我们 $\pi_{0.5}$ 集成研究中使用的 4 个 RoboTwin 2.0 任务。我们在领域随机化 (杂乱/干扰物、背景纹理、光照和桌面高度) 下评估 OFP。我们与三种代表性的从零开始加速方法进行了比较: 一致性流匹配 (CFM) [49]、捷径模型 [47] 和改进平均流 (iMF) [25]。

图 5 显示, OFP 达到了最佳平均成功率, 在四项任务中达到 94.7%。更重要的是, OFP 在 NFE = 1 时超越了原始 $\pi_{0.5}$ 策略在 NFE = 10 时的表现。这一结果表明, OFP 在语义更丰富的大规模 VLA 设置中并未失效。相反, 它在保持单步生成优势的同时, 仍提升了控制质量。这证实了 OFP 并不局限于狭窄的策略类别。当骨干网络更大、条件信息更丰富、任务语义更复杂时, 自蒸馏设计依然有效。

5 相关工作

5.1 面向机器人控制的生成式策略

扩散模型 (Diffusion Model) 与机器人技术的结合最初通过“规划即生成”范式出现 [42, 50]。随后, 研究重心转向视觉运动模仿: 扩散策略 (Diffusion Policy) [41] 将条件策略参数化为对动作块进行迭代去噪的过程, 从而建立了稳健的基线。该方法在建模多模态分布方面表现出色, 并保证了训练稳定性, 但其推理延迟较高, 且随去噪步数线性增长。后续研究聚焦于更强的条件表示 [51, 46] 和更具结构性的生成方式 [52]。与此同时, 流匹配 (Flow Matching) 策略 [53 – 56, 44, 57] 利用基于常微分方程的速度场公式。基于流的范式正逐渐与现代视觉-语言-动作 (VLA) 架构 [4, 10, 58, 11, 12, 19] 融合。

5.2 蒸馏与加速

生成策略的少步加速主要遵循两条路径。

一致性蒸馏 基于一致性模型 (Consistency Model) [15], 一致性策略 (Consistency Policy) [26] 和 ManiCM [59] 等方法将预训练的扩散教师模型蒸馏为学生模型。然而, 在高度多模态的动作分布下, 它们更可能表现出平均化现象, 导致单步动作精确率不足。

分数蒸馏 受分布匹配蒸馏 (Distribution Matching Distillation, DMD) [18] 的启发, 一步扩散策略 (One-Step Diffusion Policy) [28] 和 SDM 策略 (SDM Policy) [40] 等方法利用基于分数的梯度来优化一步生成器。虽然这种方法能产生更清晰、偏向模式寻求的样本, 适合精度要求高的任务, 但它通常会牺牲分布多样性, 并且严重依赖预训练的教师模型。

本文的方法在从零开始的自蒸馏框架内统一了这两种范式, 无需外部教师即可实现高保真的少步和单步生成。详细版本见附录 E。

6 结论与局限性

本文提出 OFP, 一种自蒸馏框架, 可将基于流的视觉运动策略加速至一步推理机制, 同时保持较高的控制精度。通过统一自洽性和自引导训练, OFP 相对于多步基线实现了超过 $100\times$ 倍的加速, 在多种操作基准上取得了最先进的成功率, 并能有效迁移到更大的视觉-语言-动作 (VLA) 骨干网络, 如 $\pi_{0.5}$ 。尽管 OFP 在多种任务中表现出稳健的性能, 但目前的评估均在仿真环境中进行。下一步直接工作是在实体机器人系统上评估 OFP。OFP 与系统级加速技术正交。未来工作可将 OFP 与模型量化和结构化剪枝无缝集成, 以进一步降低推理延迟。

参考文献

- [1] Chi-Lam Cheang, Guangzeng Chen, Ya Jing, Tao Kong, Hang Li, Yifeng Li, Yuxiao Liu, Hongtao Wu, Jiafeng Xu, Yichu Yang, et al. Gr-2: A generative video-language-action model with web-scale knowledge for robot manipulation. *arXiv preprint arXiv:2410.06158*, 2024.
- [2] Koffivi Fidèle Gbagbe, Miguel Altamirano Cabrera, Ali Alabbas, Oussama Alyunes, Artem Lykov, and Dzmitry Tsetserukou. Bi-vla: Vision-language-action model-based system for bimanual robotic dexterous manipulations. In *2024 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, pages 2864–2869. IEEE, 2024.
- [3] Cunxin Fan, Xiaosong Jia, Yihang Sun, Yixiao Wang, Jianglan Wei, Ziyang Gong, Xiangyu Zhao, Masayoshi Tomizuka, Xue Yang, Junchi Yan, et al. Interleave-vla: Enhancing robot manipulation with interleaved image-text instructions. *arXiv preprint arXiv:2505.02152*, 2025.
- [4] Songming Liu, Lingxuan Wu, Bangguo Li, Hengkai Tan, Huayu Chen, Zhengyi Wang, Ke Xu, Hang Su, and Jun Zhu. Rdt-1b: a diffusion foundation model for bimanual manipulation. *arXiv preprint arXiv:2410.07864*, 2024.
- [5] Zewei Zhou, Tianhui Cai, Seth Z Zhao, Yun Zhang, Zhiyu Huang, Bolei Zhou, and Jiaqi Ma. Autovla: A vision-language-action model for end-to-end autonomous driving with adaptive reasoning and reinforcement fine-tuning. *arXiv preprint arXiv:2506.13757*, 2025.
- [6] Zhenlong Yuan, Chengxuan Qian, Jing Tang, Rui Chen, Zijian Song, Lei Sun, Xiangxiang Chu, Yujun Cai, Dapeng Zhang, and Shuo Li. Autodrive-r²: Incentivizing reasoning and self-reflection capacity for vla model in autonomous driving. *arXiv preprint arXiv:2509.01944*, 2025.
- [7] Fanqi Lin, Ruiqian Nai, Yingdong Hu, Jiacheng You, Junming Zhao, and Yang Gao. Onet-wovla: A unified vision-language-action model with adaptive reasoning. *arXiv preprint arXiv:2505.11917*, 2025.

- [8] Ruijie Zheng, Yongyuan Liang, Shuaiyi Huang, Jianfeng Gao, Hal Daumé III, Andrey Kolobov, Furong Huang, and Jianwei Yang. Tracevla: Visual trace prompting enhances spatial-temporal awareness for generalist robotic policies. *arXiv preprint arXiv:2412.10345*, 2024.
- [9] Anurag Ajay, Seungwook Han, Yilun Du, Shuang Li, Abhi Gupta, Tommi Jaakkola, Josh Tenenbaum, Leslie Kaelbling, Akash Srivastava, and Pulkit Agrawal. Compositional foundation models for hierarchical planning. *Advances in Neural Information Processing Systems*, 36: 22304–22325, 2023.
- [10] Kevin Black, Noah Brown, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, Lachy Groom, Karol Hausman, Brian Ichter, et al. π_0 : A vision-language-action flow model for general robot control. *arXiv preprint arXiv:2410.24164*, 2024.
- [11] Physical Intelligence, Kevin Black, Noah Brown, James Darpinian, Karan Dhabalia, Danny Driess, Adnan Esmail, Michael Equi, Chelsea Finn, Niccolo Fusai, et al. $\pi_{0.5}^*$: a vision-language-action model with open-world generalization. *arXiv preprint arXiv:2504.16054*, 2025.
- [12] Physical Intelligence, Ali Amin, Raichelle Aniceto, Ashwin Balakrishna, Kevin Black, Ken Conley, Grace Connors, James Darpinian, Karan Dhabalia, Jared DiCarlo, et al. $\pi_{0.6}^*$: a vla that learns from experience. *arXiv preprint arXiv:2511.14759*, 2025.
- [13] Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. *arXiv preprint arXiv:2010.02502*, 2020.
- [14] Yaron Lipman, Ricky TQ Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022.
- [15] Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. 2023.
- [16] Dongjun Kim, Chieh-Hsin Lai, Wei-Hsiang Liao, Naoki Murata, Yuhta Takida, Toshimitsu Uesaka, Yutong He, Yuki Mitsufuji, and Stefano Ermon. Consistency trajectory models: Learning probability flow ode trajectory of diffusion. *arXiv preprint arXiv:2310.02279*, 2023.
- [17] Zhengyang Geng, Mingyang Deng, Xingjian Bai, J Zico Kolter, and Kaiming He. Mean flows for one-step generative modeling. *arXiv preprint arXiv:2505.13447*, 2025.
- [18] Tianwei Yin, Michaël Gharbi, Richard Zhang, Eli Shechtman, Fredo Durand, William T Freeman, and Taesung Park. One-step diffusion with distribution matching distillation. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 6613–6623, 2024.
- [19] Johan Bjorck, Fernando Castañeda, Nikita Cherniadev, Xingye Da, Runyu Ding, Linxi Fan, Yu Fang, Dieter Fox, Fengyuan Hu, Spencer Huang, et al. Gr00t n1: An open foundation model for generalist humanoid robots. *arXiv preprint arXiv:2503.14734*, 2025.
- [20] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. Dpm-solver: A fast ode solver for diffusion probabilistic model sampling in around 10 steps. *Advances in neural information processing systems*, 35:5775–5787, 2022.
- [21] Cheng Lu, Yuhao Zhou, Fan Bao, Jianfei Chen, Chongxuan Li, and Jun Zhu. Dpm-solver++: Fast solver for guided sampling of diffusion probabilistic models. *Machine Intelligence Research*, pages 1–22, 2025.
- [22] Tim Salimans and Jonathan Ho. Progressive distillation for fast sampling of diffusion models. *arXiv preprint arXiv:2202.00512*, 2022.
- [23] Tianwei Yin, Michaël Gharbi, Taesung Park, Richard Zhang, Eli Shechtman, Fredo Durand, and Bill Freeman. Improved distribution matching distillation for fast image synthesis. *Advances in neural information processing systems*, 37:47455–47487, 2024.
- [24] Artem Lukoianov, Haitz Sáez de Ocáriz Borde, Kristjan Greenewald, Vitor Guizilini, Timur Bagautdinov, Vincent Sitzmann, and Justin M Solomon. Score distillation via reparametrized ddim. *Advances in Neural Information Processing Systems*, 37:26011–26044, 2024.

- [25] Zhengyang Geng, Yiyang Lu, Zongze Wu, Eli Shechtman, J Zico Kolter, and Kaiming He. Improved mean flows: On the challenges of fastforward generative models. *arXiv preprint arXiv:2512.02012*, 2025.
- [26] Aaditya Prasad, Kevin Lin, Jimmy Wu, Linqi Zhou, and Jeannette Bohg. Consistency policy: Accelerated visuomotor policies via consistency distillation. *arXiv preprint arXiv:2405.07503*, 2024.
- [27] Yilun Xu, Weili Nie, and Arash Vahdat. One-step diffusion models with f -divergence distribution matching. *arXiv preprint arXiv:2502.15681*, 2025.
- [28] Zhendong Wang, Zhaoshuo Li, Ajay Mandlekar, Zhenjia Xu, Jiaojiao Fan, Yashraj Narang, Linxi Fan, Yuke Zhu, Yogesh Balaji, Mingyuan Zhou, et al. One-step diffusion policy: Fast visuomotor policies via diffusion distillation. *arXiv preprint arXiv:2410.21257*, 2024.
- [29] Yanzuo Lu, Yuxi Ren, Xin Xia, Shanchuan Lin, Xing Wang, Xuefeng Xiao, Andy J Ma, Xiaohua Xie, and Jian-Huang Lai. Adversarial distribution matching for diffusion distillation towards efficient image and video synthesis. In *Proceedings of the IEEE/CVF International Conference on Computer Vision*, pages 16818–16829, 2025.
- [30] Peihao Wang, Dejia Xu, Zhiwen Fan, Dilin Wang, Sreyas Mohan, Forrest Iandola, Rakesh Ranjan, Yilei Li, Qiang Liu, Zhangyang Wang, et al. Taming mode collapse in score distillation for text-to-3d generation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 9037–9047, 2024.
- [31] Vikash Kumar. *Manipulators and Manipulation in high dimensional spaces*. PhD thesis, 2016.
- [32] Chen Bao, Helin Xu, Yuzhe Qin, and Xiaolong Wang. Dexart: Benchmarking generalizable dexterous manipulation with articulated objects. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 21190–21200, 2023.
- [33] Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pages 1094–1100. PMLR, 2020.
- [34] Tianxing Chen, Zhanxin Chen, Baijun Chen, Zijian Cai, Yibin Liu, Zixuan Li, Qiwei Liang, Xianliang Lin, Yiheng Ge, Zhenyu Gu, et al. Robotwin 2.0: A scalable data generator and benchmark with strong domain randomization for robust bimanual robotic manipulation. *arXiv preprint arXiv:2506.18088*, 2025.
- [35] Qiang Liu. Rectified flow: A marginal preserving approach to optimal transport. *arXiv preprint arXiv:2209.14577*, 2022.
- [36] Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.
- [37] Jonathan Ho and Tim Salimans. Classifier-free diffusion guidance. *arXiv preprint arXiv:2207.12598*, 2022.
- [38] Dongyang Liu, Peng Gao, David Liu, Ruoyi Du, Zhen Li, Qilong Wu, Xin Jin, Sihan Cao, Shifeng Zhang, Hongsheng Li, et al. Decoupled dmd: Cfg augmentation as the spear, distribution matching as the shield. *arXiv preprint arXiv:2511.22677*, 2025.
- [39] Xin Yu, Xiaojuan Qi, Zhengqi Li, Kai Zhang, Richard Zhang, Zhe Lin, Eli Shechtman, Tianyu Wang, and Yotam Nitzan. Self-evaluation unlocks any-step text-to-image generation. *arXiv preprint arXiv:2512.22374*, 2025.
- [40] Bofang Jia, Pengxiang Ding, Can Cui, Mingyang Sun, Pengfang Qian, Siteng Huang, Zhaoxin Fan, and Donglin Wang. Score and distribution matching policy: Advanced accelerated visuomotor policies via matched distillation. *arXiv preprint arXiv:2412.09265*, 2024.
- [41] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025.

- [42] Michael Janner, Yilun Du, Joshua B Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. *arXiv preprint arXiv:2205.09991*, 2022.
- [43] Younggyo Seo, Danijar Hafner, Hao Liu, Fangchen Liu, Stephen James, Kimin Lee, and Pieter Abbeel. Masked world models for visual control. In *Conference on Robot Learning*, pages 1332–1344. PMLR, 2023.
- [44] Fan Zhang and Michael Gienger. Affordance-based robot manipulation with flow matching. *arXiv preprint arXiv:2409.01083*, 2024.
- [45] Juyi Sheng, Ziyi Wang, Peiming Li, and Mengyuan Liu. Mp1: Meanflow tames policy learning in 1-step for robotic manipulation. *arXiv preprint arXiv:2507.10543*, 2025.
- [46] Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations. *arXiv preprint arXiv:2403.03954*, 2024.
- [47] Kevin Frans, Danijar Hafner, Sergey Levine, and Pieter Abbeel. One step diffusion via shortcut models. *arXiv preprint arXiv:2410.12557*, 2024.
- [48] Aviral Kumar, Rishabh Agarwal, Dibya Ghosh, and Sergey Levine. Implicit underparameterization inhibits data-efficient deep reinforcement learning. *arXiv preprint arXiv:2010.14498*, 2020.
- [49] Ling Yang, Zixiang Zhang, Zhilong Zhang, Xingchao Liu, Minkai Xu, Wentao Zhang, Chenlin Meng, Stefano Ermon, and Bin Cui. Consistency flow matching: Defining straight flows with velocity consistency. *arXiv preprint arXiv:2407.02398*, 2024.
- [50] Anurag Ajay, Yilun Du, Abhi Gupta, Joshua Tenenbaum, Tommi Jaakkola, and Pulkit Agrawal. Is conditional generative modeling all you need for decision-making? *arXiv preprint arXiv:2211.15657*, 2022.
- [51] Xiang Li, Varun Belagali, Jinghuan Shang, and Michael S Ryoo. Crossway diffusion: Improving diffusion-based visuomotor policy via self-supervised learning. In *2024 IEEE International Conference on Robotics and Automation (ICRA)*, pages 16841–16849. IEEE, 2024.
- [52] Xiao Ma, Sumit Patidar, Iain Haughton, and Stephen James. Hierarchical diffusion policy for kinematics-aware multi-task robotic manipulation. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 18081–18090, 2024.
- [53] Xixi Hu, Qiang Liu, Xingchao Liu, and Bo Liu. Adaflow: Imitation learning with variance-adaptive flow-based policies. *Advances in Neural Information Processing Systems*, 37:138836–138858, 2024.
- [54] Niklas Funk, Julien Urain, Joao Carvalho, Vignesh Prasad, Georgia Chalvatzaki, and Jan Peters. Actionflow: Equivariant, accurate, and efficient policies with spatially symmetric flow matching. *arXiv preprint arXiv:2409.04576*, 2024.
- [55] Qinglun Zhang, Zhen Liu, Haoqiang Fan, Guanghui Liu, Bing Zeng, and Shuaicheng Liu. Flowpolicy: Enabling fast and robust 3d flow-based policy via consistency flow matching for robot manipulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 14754–14762, 2025.
- [56] Max Braun, Noémie Jaquier, Leonel Roza, and Tamim Asfour. Riemannian flow matching policy for robot motion learning. In *2024 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, pages 5144–5151. IEEE, 2024.
- [57] Eugenio Chisari, Nick Heppert, Max Argus, Tim Welschhold, Thomas Brox, and Abhinav Valada. Learning robotic manipulation policies from point clouds with conditional flow matching. *arXiv preprint arXiv:2409.07343*, 2024.
- [58] Lucy Xiaoyang Shi, Brian Ichter, Michael Equi, Liyiming Ke, Karl Pertsch, Quan Vuong, James Tanner, Anna Walling, Haohuan Wang, Niccolo Fusai, et al. Hi robot: Open-ended instruction following with hierarchical vision-language-action models. *arXiv preprint arXiv:2502.19417*, 2025.

- [59] Guanxing Lu, Zifeng Gao, Tianxing Chen, Wenxun Dai, Ziwei Wang, Wenbo Ding, and Yansong Tang. Manicm: Real-time 3d diffusion policy via consistency model for robotic manipulation. *arXiv preprint arXiv:2406.01586*, 2024.
- [60] William Peebles and Saining Xie. Scalable diffusion models with transformers. In *Proceedings of the IEEE/CVF international conference on computer vision*, pages 4195–4205, 2023.
- [61] Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3d diffuser actor: Policy diffusion with 3d scene representations. *arXiv preprint arXiv:2402.10885*, 2024.
- [62] Zhou Xian, Nikolaos Gkanatsios, Theophile Gervet, Tsung-Wei Ke, and Katerina Fragkiadaki. Chaineddiffuser: Unifying trajectory diffusion and keypose prediction for robotic manipulation. In *7th Annual Conference on Robot Learning*, 2023.
- [63] Zibin Dong, Jianye Hao, Yifu Yuan, Fei Ni, Yitian Wang, Pengyi Li, and Yan Zheng. Diffuserlite: Towards real-time diffusion planning. *Advances in Neural Information Processing Systems*, 37: 122556–122583, 2024.
- [64] Quentin Rouxel, Andrea Ferrari, Serena Ivaldi, and Jean-Baptiste Mouret. Flow matching imitation learning for multi-support manipulation. In *2024 IEEE-RAS 23rd International Conference on Humanoid Robots (Humanoids)*, pages 528–535. IEEE, 2024.
- [65] Yuhui Chen, Haoran Li, and Dongbin Zhao. Boosting continuous control with consistency policy. *arXiv preprint arXiv:2310.06343*, 2023.
- [66] Sigmund H Høeg, Yilun Du, and Olav Egeland. Streaming diffusion policy: Fast policy synthesis with variable noise diffusion models. *arXiv preprint arXiv:2406.04806*, 2024.

A 理论支撑与证明

A.1 自治性训练

我们现在为命题 1 提供形式化推导。目标是证明自治性损失中的目标

$$\mathbf{u}_{\text{target}} = \frac{\hat{\mathbf{z}}_r - \mathbf{z}_t}{r - t}, \quad \hat{\mathbf{z}}_r = \mathbf{z}_m + (r - m)\mathbf{u}_{\theta^-}(\mathbf{z}_m, m, r \mid o),$$

是真实区间速度场 $\mathbf{u}(\mathbf{z}_t, t, r \mid o)$ 的一致监督信号。

真实区间速度的定义。 设 $\{\mathbf{z}_\tau\}_{\tau \in [0, 1]}$ 表示与固定对 (o, a, ϵ) 相关的真实条件传输轨迹。对于任意 $0 \leq t < r \leq 1$ ，定义区间平均速度场

$$\mathbf{u}(\mathbf{z}_t, t, r \mid o) \triangleq \frac{\mathbf{z}_r - \mathbf{z}_t}{r - t}. \quad (16)$$

By definition, it satisfies

$$\mathbf{z}_r = \mathbf{z}_t + (r - t)\mathbf{u}(\mathbf{z}_t, t, r \mid o).$$

同样，对于同一轨迹上的任意中间时间 $m \in [t, r]$ ，

$$\mathbf{z}_r = \mathbf{z}_m + (r - m)\mathbf{u}(\mathbf{z}_m, m, r \mid o).$$

假设。我们在以下假设下工作。

(A1) 真实区间速度场 $\mathbf{u}(\mathbf{x}, t, r \mid o)$ 在定义域上关于连续可微
 $(\mathbf{x}, t, r) \quad \{(\mathbf{x}, t, r) : 0 \leq t \leq r \leq 1\}.$

(A2) $\mathbf{u}$ 在状态上全局利普希茨连续：存在 $L_x > 0$ ，使得对所有 $\mathbf{x}, \mathbf{y}$ ，

$$\|\mathbf{u}(\mathbf{x}, t, r \mid o) - \mathbf{u}(\mathbf{y}, t, r \mid o)\| \leq L_x \|\mathbf{x} - \mathbf{y}\|.$$

(A3) EMA 教师模型是准确的。具体地，定义

$$\varepsilon_{\text{ema}}(s) \triangleq \sup_{o, \mathbf{x}, t, r} \|\mathbf{u}_{\theta^-}(\mathbf{x}, t, r \mid o) - \mathbf{u}(\mathbf{x}, t, r \mid o)\|,$$

并假设随着训练进行 $\varepsilon_{\text{ema}}(s) \rightarrow 0$ 。

(A4) 中间时间 m 采样自

$$m \sim \mathcal{U}[t, t + (r - t)\rho(s)],$$

其中 $\rho(s) \rightarrow 0$ 作为训练步 $s \rightarrow \infty$ 。

目标的代数分解。从 $\mathbf{u}_{\text{target}}$ 的定义出发，

$$\mathbf{u}_{\text{target}} = \frac{\mathbf{z}_m - \mathbf{z}_t}{r - t} + \frac{r - m}{r - t} \mathbf{u}_{\theta^-}(\mathbf{z}_m, m, r \mid o).$$

另一方面，利用从 m 到 r 的精确区间更新，

$$\mathbf{z}_r - \mathbf{z}_t = (\mathbf{z}_m - \mathbf{z}_t) + (r - m)\mathbf{u}(\mathbf{z}_m, m, r \mid o).$$

两边同时除以 $(r - t)$ 可得

$$\mathbf{u}(\mathbf{z}_t, t, r \mid o) = \frac{\mathbf{z}_m - \mathbf{z}_t}{r - t} + \frac{r - m}{r - t} \mathbf{u}(\mathbf{z}_m, m, r \mid o).$$

将两个表达式相减可得

$$\mathbf{u}_{\text{target}} - \mathbf{u}(\mathbf{z}_t, t, r \mid o) = \frac{r - m}{r - t} \left(\mathbf{u}_{\theta^-}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}(\mathbf{z}_m, m, r \mid o) \right). \quad (17)$$

目标的逐点一致性。

Since $m \in [t, r]$, 我们有 $0 \leq (r - m)/(r - t) \leq 1$. 因此, 由式 (17) 可得,

$$\|\mathbf{u}_{\text{target}} - \mathbf{u}(\mathbf{z}_t, t, r \mid o)\| \leq \|\mathbf{u}_{\theta^*}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}(\mathbf{z}_m, m, r \mid o)\| \leq \varepsilon_{\text{ema}}(s).$$

Hence,

$$\mathbf{u}_{\text{target}} \xrightarrow{s \rightarrow \infty} \mathbf{u}(\mathbf{z}_t, t, r \mid o) \quad \text{uniformly on the training domain.} \quad (18)$$

这证明了只要指数移动平均教师模型是准确的, 教师生成的目标就是一个一致的监督信号。

时间收缩调度表的作用。 由于 $m \in [t, t + (r - t)\rho(s)]$, 我们有 $0 \leq m - t \leq (r - t)\rho(s)$. 因为真实轨迹是连续可微的, 所以存在一个常数 $C_z > 0$ 使得 $\|\mathbf{z}_m - \mathbf{z}_t\| \leq C_z|m - t| \leq C_z(r - t)\rho(s)$. 利用 (t, r) 中的连续可微性和状态上的利普希茨连续性, 存在一个常数 $C_u > 0$ 使得

$$\|\mathbf{u}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}(\mathbf{z}_t, t, r \mid o)\| \leq C_u(\|\mathbf{z}_m - \mathbf{z}_t\| + |m - t|) \leq C'_u(r - t)\rho(s),$$

for some constant $C'_u > 0$.

因此, 当 $\rho(s) \rightarrow 0$ 时, 教师查询点 $(\mathbf{z}_m, m, r)$ 趋近于 $(\mathbf{z}_t, t, r)$, 且 $\mathbf{u}(\mathbf{z}_m, m, r \mid o) \rightarrow \mathbf{u}(\mathbf{z}_t, t, r \mid o)$. 这表明收缩调度逐渐将目标从粗略的长区间自助信号转变为以学生输入 $(\mathbf{z}_t, t, r)$ 为中心的局部自洽性信号。

总体回归目标的收敛性。 令 $X \triangleq (\mathbf{z}_t, t, r, o)$, $Y \triangleq \mathbf{u}_{\text{target}}$. 将目标写为 $Y = \mathbf{u}(X) + \boldsymbol{\eta}$, $\boldsymbol{\eta} \triangleq \mathbf{u}_{\text{target}} - \mathbf{u}(X)$. 根据式 (17), $\|\boldsymbol{\eta}\| \leq \varepsilon_{\text{ema}}(s)$, 因此

$$\mathbb{E}\|\boldsymbol{\eta}\|^2 \leq \varepsilon_{\text{ema}}(s)^2 \rightarrow 0.$$

考虑总体自洽性损失

$$\mathcal{L}(\theta) = \mathbb{E}[\|\mathbf{u}_{\theta}(X) - Y\|^2].$$

自洽性 令 θ^* 为该目标的任意全局极小值点。由于 $\mathbf{u}$ 是一个有效的比较对象,

$$\mathcal{L}_{\text{self-consistency}}(\theta^*) \leq \mathcal{L}_{\text{self-consistency}}(\mathbf{u}) = \mathbb{E}\|\boldsymbol{\eta}\|^2.$$

Expanding the loss at θ^* gives

$$\mathcal{L}_{\text{自洽性}}(\theta^*) = \mathbb{E}\|\mathbf{u}_{\theta^*}(X) - \mathbf{u}(X)\|^2 + 2\mathbb{E}[\langle \mathbf{u}_{\theta^*}(X) - \mathbf{u}(X), \boldsymbol{\eta} \rangle] + \mathbb{E}\|\boldsymbol{\eta}\|^2.$$

结合上述两个表达式并应用柯西-施瓦茨不等式,

$$\mathbb{E}\|\mathbf{u}_{\theta^*}(X) - \mathbf{u}(X)\|^2 \leq 2\left(\mathbb{E}\|\mathbf{u}_{\theta^*}(X) - \mathbf{u}(X)\|^2\right)^{1/2}\left(\mathbb{E}\|\boldsymbol{\eta}\|^2\right)^{1/2}.$$

Therefore,

$$\left(\mathbb{E}\|\mathbf{u}_{\theta^*}(X) - \mathbf{u}(X)\|^2\right)^{1/2} \leq 2\left(\mathbb{E}\|\boldsymbol{\eta}\|^2\right)^{1/2},$$

which implies

$$\mathbb{E}\|\mathbf{u}_{\theta^*}(X) - \mathbf{u}(X)\|^2 \leq 4\mathbb{E}\|\boldsymbol{\eta}\|^2 \xrightarrow{s \rightarrow \infty} 0. \quad (19)$$

Hence,

$$\mathbf{u}_{\theta^*} \rightarrow \mathbf{u} \quad \text{in } L^2. \quad (20)$$

结论。 方程 (17) 至 (20) 证明了命题 1 中的论断: 当指数移动平均教师模型准确且收缩因子满足 $\rho(s) \rightarrow 0$ 时, 目标 $\mathbf{u}_{\text{target}}$ 是真实区间速度场 $\mathbf{u}(\mathbf{z}_t, t, r \mid o)$ 的一致监督信号, 最小化自洽性损失可恢复 $\mathbf{u}_{\theta} \approx \mathbf{u}$ 。

A.2 与平均流的关系

本节表明，本文的一致性目标与平均流（MeanFlow）[17] 中使用的微分项存在一阶联系。特别地，当子区间长度 $(m - t) \rightarrow 0$ 时，本文的目标诱导出平均流恒等式中出现的全导数的有限差分近似。与平均流通过雅可比向量积（JVP）计算该导数不同，本文的构造仅使用指数移动平均教师模型的前向评估。平均流显式推导了平均速度恒等式，然后在训练期间将其全导数展开为雅可比向量积项。

设定。固定条件样本 (o, a) 和噪声 ϵ 。沿直线最优传输条件路径， $\mathbf{z}_\tau = (1 - \tau)\epsilon + \tau a$, $\tau \in [0, 1]$ ，瞬时速度恒定： $\dot{\mathbf{z}}_\tau = a - \epsilon \triangleq \mathbf{v}$ 。定义真实区间平均速度场为

$$\mathbf{u}(\mathbf{z}_t, t, r | o) \triangleq \frac{\mathbf{z}_r - \mathbf{z}_t}{r - t}, \quad 0 \leq t < r \leq 1.$$

平均流恒等式。从

$$(r - t) \mathbf{u}(\mathbf{z}_t, t, r | o) = \mathbf{z}_r - \mathbf{z}_t,$$

沿轨迹对 t 求导，同时保持 r 固定。由于 $\frac{d}{dt}$ ，乘积法则给出

$$\frac{d}{dt} \mathbf{z}_t = \mathbf{v},$$

$$-\mathbf{u}(\mathbf{z}_t, t, r | o) + (r - t) \frac{d}{dt} \mathbf{u}(\mathbf{z}_t, t, r | o) = -\mathbf{v}.$$

整理得

$$\mathbf{u}(\mathbf{z}_t, t, r | o) = \mathbf{v} + (r - t) \frac{d}{dt} \mathbf{u}(\mathbf{z}_t, t, r | o). \quad (21)$$

Equivalently,

$$\frac{d}{dt} \mathbf{u}(\mathbf{z}_t, t, r | o) = \frac{\mathbf{u}(\mathbf{z}_t, t, r | o) - \mathbf{v}}{r - t}. \quad (22)$$

这正是平均流（MeanFlow）所使用的微分关系。在平均流中，全导数进一步展开为时间偏导项加上状态雅可比项，然后通过雅可比向量积（JVP）实现。

使用精确教师的一致性目标。为了分析，首先用精确场替换指数移动平均（EMA）教师。则一致性目标变为

$$\mathbf{u}_{\text{target}}^* = \frac{\mathbf{z}_m + (r - m) \mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{z}_t}{r - t}, \quad t < m < r.$$

由于最优传输（OT）路径是线性的， $\mathbf{z}_m - \mathbf{z}_t = (m - t) \mathbf{v}$ 。将其代入目标得到

$$\mathbf{u}_{\text{target}}^* = \frac{m - t}{r - t} \mathbf{v} + \frac{r - m}{r - t} \mathbf{u}(\mathbf{z}_m, m, r | o).$$

两边同时减去 $\mathbf{u}(\mathbf{z}_m, m, r | o)$ ：

$$\mathbf{u}_{\text{target}}^* - \mathbf{u}(\mathbf{z}_m, m, r | o) = \frac{m - t}{r - t} (\mathbf{v} - \mathbf{u}(\mathbf{z}_m, m, r | o)).$$

Hence,

$$\frac{\mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{u}_{\text{target}}^*}{m - t} = \frac{\mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{v}}{r - t}. \quad (23)$$

在时间 m 处应用平均流导数恒等式，

$$\frac{d}{dm} \mathbf{u}(\mathbf{z}_m, m, r | o) = \frac{\mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{v}}{r - m},$$

可将 (23) 式右端改写为

$$\frac{\mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{v}}{r - t} = \frac{r - m}{r - t} \frac{d}{dm} \mathbf{u}(\mathbf{z}_m, m, r | o).$$

Therefore,

$$\frac{\mathbf{u}(\mathbf{z}_m, m, r | o) - \mathbf{u}_{\text{target}}^*}{m - t} = \frac{r - m}{r - t} \frac{d}{dm} \mathbf{u}(\mathbf{z}_m, m, r | o). \quad (24)$$

取极限 $m \rightarrow t^+$. 假设 $\mathbf{u}$ 连续可微。在 (24) 中取极限 $m \rightarrow t^+$ yields

$$\lim_{m \rightarrow t^+} \frac{\mathbf{u}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}_{\text{target}}^*}{m - t} = \frac{d}{dt} \mathbf{u}(\mathbf{z}_t, t, r \mid o). \quad (25)$$

因此，精确一致性目标与后一时间点场值之间的差异 $(\mathbf{z}_m, m, r)$ ，在除以小区间长度 $(m - t)$ 后，是平均流导数项的有限差分近似。

包含指数移动平均 (EMA) 教师模型。 现在回到实用目标

$$\mathbf{u}_{\text{target}} = \frac{\mathbf{z}_m + (r - m)\mathbf{u}_{\theta-}(\mathbf{z}_m, m, r \mid o) - \mathbf{z}_t}{r - t}.$$

Let

$$\delta_m \triangleq \mathbf{u}_{\theta-}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}(\mathbf{z}_m, m, r \mid o).$$

则

$$\mathbf{u}_{\text{target}} = \mathbf{u}_{\text{target}}^* + \frac{r - m}{r - t} \delta_m.$$

因此，

$$\frac{\mathbf{u}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}_{\text{target}}}{m - t} = \frac{\mathbf{u}(\mathbf{z}_m, m, r \mid o) - \mathbf{u}_{\text{target}}^*}{m - t} - \frac{r - m}{r - t} \frac{\delta_m}{m - t}.$$

如果 EMA 教师模型准确且其近似误差满足

因为此时第二项消失，且 (25) 在 $\|\delta_m\| = o(m - t)$ 时 $m \rightarrow t^+$ ，仍然成立。因此，在小区间极限下，我们的一致性目标恢复了与平均流通过 JVP 计算的相同一阶微分信号，但它仅使用前向教师评估来实现。

结论。 方程 (25) 展示了精确关系：当 $(m - t) \rightarrow 0$ 时，本文的一致性目标诱导出对平均流恒等式中全导数项的有限差分近似。因此，本文方法可视为平均流微分目标的前向离散化。这解释了为何两种形式在局部极限下等价，而本文的实现避免了平均流训练中使用的显式雅可比向量积。平均流的训练目标基于平均速度恒等式构建，并通过雅可比向量积计算导数项。

A.3 自引导与条件增强项的梯度对齐

本节证明最小化自引导损失产生的梯度下降方向与条件增强 (CA) 项对齐。该结果形式化了自引导目标作为分数蒸馏方法中条件增强机制的自蒸馏版本的论断。

符号说明。 为简洁起见，定义单步预测器

$$\mathbf{f}_\theta \triangleq \mathbf{u}_\theta(\mathbf{z}_t, t, 1 \mid o), \quad \hat{\mathbf{a}} = \mathbf{z}_t + (1 - t)\mathbf{f}_\theta.$$

重新加噪的样本为 $\tilde{\mathbf{z}}_{t'} = (1 - t')\epsilon_1 + t'\hat{\mathbf{a}}, t' \sim \mathcal{U}[0, 1]$. Let

$$\mathbf{u}_{\text{cond}}^- \triangleq \mathbf{u}_{\theta-}(\tilde{\mathbf{z}}_{t'}, t', t' \mid o), \quad \mathbf{u}_{\text{uncond}}^- \triangleq \mathbf{u}_{\theta-}(\tilde{\mathbf{z}}_{t'}, t', t' \mid \phi).$$

则自引导中使用的目标为

$$\mathbf{s}_{\text{target}} = \text{sg} \left[\mathbf{f}_\theta - \left(\mathbf{u}_{\text{uncond}}^- - \mathbf{u}_{\text{cond}}^- \right) \right],$$

其中 $\text{sg}[\cdot]$ 表示停止梯度。

将损失改写为残差形式。自引导损失为

$$\mathcal{L}_{\text{self 引导}}(\theta) = \mathbb{E} \left[\|\mathbf{f}_\theta - \mathbf{s}_{\text{target}}\|_2^2 \right].$$

定义

$$\Delta_{\text{CA}} \triangleq \mathbf{u}_{\text{uncond}}^- - \mathbf{u}_{\text{cond}}^-.$$

由于 $\text{sg}[\cdot]$ 在反向传播中冻结其参数，前向残差为

$$\mathbf{f}_\theta - \mathbf{s}_{\text{target}} = \mathbf{f}_\theta - \text{sg}[\mathbf{f}_\theta - \Delta_{\text{CA}}].$$

数值上，该残差等于 Δ_{CA} ，而其梯度仅流经第一个 $\mathbf{f}_\theta$ 。因此，

$$\mathcal{L}_{\text{self 引导}}(\theta) = \mathbb{E} \left[\|\mathbf{f}_\theta - \text{sg}[\mathbf{f}_\theta - \Delta_{\text{CA}}]\|_2^2 \right].$$

计算自引导损失的梯度。

设

$$J_\theta(\mathbf{z}_t, t, o) \triangleq \frac{\partial \mathbf{f}_\theta}{\partial \theta}$$

表示单步预测器关于模型参数的雅可比矩阵。由于停止梯度分支不贡献导数，链式法则给出

$$\nabla_\theta \mathcal{L}_{\text{self-guidance}} = 2 \mathbb{E} [J_\theta(\mathbf{z}_t, t, o)^\top \Delta_{\text{CA}}]. \quad (26)$$

因此，由该损失诱导的梯度下降更新为

$$-\nabla_\theta \mathcal{L}_{\text{self-guidance}} = -2 \mathbb{E} [J_\theta(\mathbf{z}_t, t, o)^\top \Delta_{\text{CA}}]. \quad (27)$$

这已经表明更新方向直接由基于指数移动平均的条件-无条件差距驱动。

用相同的变量表示无分类器引导增强（CFG Augmentation, CA）项。 在最优传输路径 $\tilde{\mathbf{z}}_{t'} = (1-t')\epsilon + t'\mathbf{a}$ 下，边际得分与瞬时速度满足

$$\mathbf{s}(\tilde{\mathbf{z}}_{t'} | c) = \frac{t' \mathbf{u}(\tilde{\mathbf{z}}_{t'}, t', t' | c) - \tilde{\mathbf{z}}_{t'}}{1 - t'},$$

for condition $c \in \{o, \phi\}$. Therefore,

$$\mathbf{s}(\tilde{\mathbf{z}}_{t'} | \phi) - \mathbf{s}(\tilde{\mathbf{z}}_{t'} | o) = \frac{t'}{1 - t'} \left(\mathbf{u}(\tilde{\mathbf{z}}_{t'}, t', t' | \phi) - \mathbf{u}(\tilde{\mathbf{z}}_{t'}, t', t' | o) \right).$$

利用指数移动平均教师模型估计得分，定义教师侧无分类器引导增强向量

$$\mathbf{g}_{\text{CA}} \triangleq \mathbf{s}_{\text{uncond}}^- - \mathbf{s}_{\text{cond}}^- = \frac{t'}{1 - t'} \Delta_{\text{CA}}, \quad (28)$$

其中 $\mathbf{s}_{\text{cond}}^- \triangleq \mathbf{s}_{\theta^-}(\tilde{\mathbf{z}}_{t'} | o)$, $\mathbf{s}_{\text{uncond}}^- \triangleq \mathbf{s}_{\theta^-}(\tilde{\mathbf{z}}_{t'} | \phi)$. Thus,

$$\Delta_{\text{CA}} = \frac{1 - t'}{t'} \mathbf{g}_{\text{CA}}. \quad (29)$$

与得分蒸馏中的无分类器引导增强梯度进行比较。 在反向 KL 风格的分馏蒸馏目标中，实用的基于 CFG 的梯度包含一个如下形式的 CA 项

$$\nabla_\theta \mathcal{J}_{\text{CA}} = \mathbb{E} \left[\mathbf{g}_{\text{CA}}^\top \frac{\partial \tilde{\mathbf{z}}_{t'}}{\partial \theta} \right].$$

Since $\tilde{\mathbf{z}}_{t'} = (1 - t')\epsilon_1 + t'\hat{\mathbf{a}}$, $\hat{\mathbf{a}} = \mathbf{z}_t + (1 - t)\mathbf{f}_\theta$, 我们有

$$\frac{\partial \tilde{\mathbf{z}}_{t'}}{\partial \theta} = t'(1 - t) J_\theta(\mathbf{z}_t, t, o).$$

将其与 (29) 式一同代入，得到

$$\begin{aligned}\nabla_{\theta} \mathcal{J}_{\text{CA}} &= t'(1-t) \mathbb{E}[J_{\theta}(\mathbf{z}_t, t, o)^{\top} \mathbf{g}_{\text{CA}}] \\ &= t'(1-t) \mathbb{E}\left[J_{\theta}(\mathbf{z}_t, t, o)^{\top} \frac{t'}{1-t'} \Delta_{\text{CA}}\right] \\ &= \frac{t'^2(1-t)}{1-t'} \mathbb{E}[J_{\theta}(\mathbf{z}_t, t, o)^{\top} \Delta_{\text{CA}}].\end{aligned}\quad (30)$$

比较 (26) 与 (30)，我们得到

$$\nabla_{\theta} \mathcal{J}_{\text{CA}} = \frac{t'^2(1-t)}{2(1-t')} \nabla_{\theta} \mathcal{L}_{\text{self-guidance}}. \quad (31)$$

因此，只要 $t \in [0, 1)$ 且，这两个梯度就由一个严格正的标量成比例。等价地，它们的梯度 $t' \in (0, 1)$ 下降方向相同：

$$-\nabla_{\theta} \mathcal{L}_{\text{self-guidance}} \parallel -\nabla_{\theta} \mathcal{J}_{\text{CA}}. \quad (32)$$

解释。方程 (32) 证明，最小化自引导损失所施加的一阶更新方向与 CA 项相同，仅相差一个正的缩放因子。由于

$$\Delta_{\text{CA}} = \mathbf{u}_{\text{uncond}}^{-} - \mathbf{u}_{\text{cond}}^{-},$$

下降更新将条件一步预测器推离无条件分支，并推向 CFG 所偏好的条件特定方向。

结论。自引导损失产生的参数梯度形式为

$$\nabla_{\theta} \mathcal{L}_{\text{self-guidance}} = 2 \mathbb{E}[J_{\theta}^{\top} \Delta_{\text{CA}}],$$

而分数蒸馏中的交叉注意力项给出

$$\nabla_{\theta} \mathcal{J}_{\text{CA}} \propto \mathbb{E}[J_{\theta}^{\top} \Delta_{\text{CA}}].$$

因此，两者在正标量因子意义下等价。这证明了自引导损失以自蒸馏、可前向训练的形式实现了交叉注意力效应。

B 策略实现细节

我们详细描述了在 Adroit [31]、DexArt [32]、MetaWorld [33] 和 RoboTwin 2.0 [34] 基准上评估目标流策略的观测流程、网络架构和优化超参数。

B.1 观测输入

二维设置。基于图像的控制依赖于两帧历史的 84x84 RGB 观测、低维本体感受状态（例如，Adroit Hammer 为 24 维，DexArt Faucet 为 32 维）以及 8 步动作块目标。滚动时域控制执行前 4 个动作。视觉特征使用 ResNet-18 主干网络提取，并与策略端到端联合训练。输入经过标准归一化和数据增强（随机裁剪、旋转、颜色抖动）。编码后的视觉和状态特征被拼接为流模型的全局条件向量。

三维设置。点云控制同样采用两步观测历史与八步动作时域。输入规模从 512 个点（Adroit、MetaWorld）到 1024 个场景点加 96 个想象机器人点（DexArt）不等。我们使用 DP3 编码器 [46] 处理三维观测，该编码器采用基于 PointNet 的提取器和多层感知机状态编码器。得到的 128 维点云特征与 64 维状态特征拼接后，为 Transformer 策略生成一个简短的调节序列。

$\pi_{0.5} + \text{OFP}$ 集成。该设置使用三个 224×224 的 RGB 视图、一个 32 维机器人状态以及一个经 PaliGemma 分词的语言提示。图像被缩放至 $[-1, 1]$ ，并通过随机裁剪、缩放、旋转和颜色抖动进行增强。状态和动作被填充以匹配模型维度。

B.2 模型架构

主干网络。 OFP 采用扩散 Transformer (DiT) [60] 来预测区间平均速度场，条件包括当前动作、起始时间、目标区间和观测嵌入。二维和三维变体均使用 12 层 Transformer、8 个注意力头以及 768 的隐藏维度。时间步和目标区间嵌入（各 128 维）被拼接并投影。观测通过交叉注意力进行整合，线性头输出最终动作。

扩散基线。 DP 与蒸馏基线 (CP、OneDP) 采用通道宽度为 $[256, 512, 1024]$ 的 U-Net 去噪器。DP3 使用更宽的通道 $[512, 1024, 2048]$ 。所有蒸馏基线均保留其各自的教师架构。

$\pi_{0.5}$ +OFP 架构。该集成采用双专家 PaliGemma 架构：一个 2B 参数的视觉-语言前缀专家（包含 SigLIP 编码器）和一个 300M 参数的动作专家。

前缀专家将多视角相机和语言提示融合为共享令牌序列。动作专家（深度 18，宽度 1024，8 个头）将噪声动作令牌映射为流更新。时间和间隔条件通过自适应 RMS 归一化施加。

B.3 训练细节

OFP 训练。 本文使用 AdamW（学习率 $1e-4$ ， $\beta_1=0.95$ ， $\beta_2=0.999$ ，权重衰减 $1e-6$ ）优化 OFP，采用余弦调度和 500 个预热步骤。EMA 教师使用指数衰减 0.75（最大 0.9999）。训练在单个 NVIDIA A100 GPU 上进行 3000 个训练轮次，批大小为 64。训练目标将 80% 权重分配给边界流匹配，20% 分配给自洽性。自洽性间隔从 logit-normal 分布中采样，时间收缩调度遵循多项式衰减。对于 3D 任务，启用自引导，权重为 0.05，空条件随机失活为 10%。推理期间，热启动初始化为

应用于 $t_w = 0.15$ ， $z_{t_w} = (1 - t_w)\epsilon + t_w a_{\text{warm}}$ 。

$\pi_{0.5}$ +OFP 训练。遵循 OpenPI [10] 配置，本文使用 AdamW 优化器，全局梯度裁剪为 1.0，余弦调度峰值学习率为 $2.5e-5$ 。模型从基础 $\pi_{0.5}$ 检查点微调 3000 步，使用 4 个 NVIDIA A100 GPU。

C 仿真实验




图 7：仿真操作基准的可视化。这些多样化的环境严格测试了 OFP 在不同机器人配置、几何约束和视觉条件下的能力。

C.1 Benchmarks

我们在四个不同的仿真环境中进行评估，如图 7 所示。

Adroit。 Adroit [31] 是一个基于高自由度拟人手构建的灵巧操作基准。它包括打开带门锁的门、钉钉子、重新定向笔等任务。这些任务需要精确的手指协调和准确的接触丰富控制。

DexArt。 DexArt [32] 是一个用于关节物体灵巧操作的基准。它专注于转动水龙头、打开笔记本电脑盖、提起水桶和打开马桶盖等操作问题。与刚体任务相比，关节物体引入了额外的运动约束和更强的几何变化。

MetaWorld。元世界 (MetaWorld) [33] 是一个大规模模拟操作套件, 专为多任务和元学习而设计。它包含一系列广泛的桌面操作问题, 具有多样化的任务语义。我们采用 49 个任务的多任务设置, 并将这些任务分为四个经验难度级别: 简单、中等、困难和极难。单一策略在所有 49 个任务上联合训练。

机器双胞胎 2.0 (RoboTwin 2.0)。机器双胞胎 2.0 (RoboTwin 2.0) [34] 是一个双臂操作基准, 用于稳健的双臂控制。机器双胞胎 2.0 的一个关键特性是强大的领域随机化, 包括杂乱干扰物、背景纹理、光照条件和桌面高度变化。我们使用机器双胞胎 2.0 来评估 OFP 能否集成到大型视觉语言动作模型中, 并在语义丰富且视觉变化多样的双臂任务下保持稳定。

C.2 实验方案

灵巧手 (Adroit) 和灵巧艺术 (DexArt)。对于这两个基准, 我们训练所有方法 3000 个训练轮次。对于灵巧手, 每个任务使用 10 个演示; 对于灵巧艺术, 每个任务使用 100 个演示。在训练过程中, 每 50 个训练轮次评估 20 个 rollout 回合。遵循 DP3 [46] 协议, 最终成功率定义为训练过程中观察到的前 5 个 rollout 成功率的平均值。

MetaWorld。对于 49 个任务的多任务设置, 我们训练所有方法 1000 个训练轮次。每个任务使用 10 个演示, 每 200 个训练轮次评估 20 个回合。我们将最终成功率定义为训练窗口内前 3 个 rollout 成功率的平均值。

机器双胞胎 2.0 (RoboTwin 2.0)。对于 $\pi_{0.5}$ 集成研究, 我们使用每个任务 100 个演示对模型进行 3k 训练步的微调。训练后, 我们在 100 个随机化测试试验上评估每个策略。

C.3 完整结果

详细的 3D 结果报告于表 4。OFP 相较于单步基线持续提升, 并且即使与强大的多步策略相比仍具有竞争力。这些结果表明, OFP 在保持一步生成的速度优势的同时, 在控制问题上维持了高动作质量。

完整的 $\pi_{0.5}$ 集成结果展示于表 5。OFP 在所有 4 个 RoboTwin 2.0 任务上均达到最佳性能, 并取得最高的平均成功率。更重要的是, 在 $NFE = 1$ 下, OFP 在每个任务上都优于原始 $\pi_{0.5}$ 策略在 $NFE = 10$ 下的表现。这表明所提出的自蒸馏设计在插入大型 VLA 骨干网络并处于强领域随机化条件下后仍然有效。

D 消融实验

为严格评估核心设计机制的各自贡献并理解其对超参数变化的敏感性, 本文呈现一项全面的消融实验。所有评估均在 3D 点云设置下, 跨 Adroit 和 DexArt 基准的 7 个仿真任务上进行。策略训练使用每个 Adroit 任务 10 个演示和每个 DexArt 任务 100 个演示, 批大小为 64, 训练 3000 个轮次。

D.1 组件分析

本文首先剖析自洽性训练 (SCT)、自引导正则化 (SGR) 以及热启动初始化先验的各自作用。对比结果详见表 6。

数据清晰地揭示了仅依赖纯轨迹匹配蒸馏的根本局限性。当仅使用 SCT 训练时, 策略学习到稳健的时间一致性, 在 $NFE=4$ 下达到 72.3% 的强劲平均成功率。然而, 其一步生成能力显著滞后, 仅达到 68.7%。这一性能差距的产生是因为一致性训练对齐了流轨迹的端点, 但难以强制与目标数据分布的高密度模式精确对齐。因此, 一步预测往往对多个有效模式进行平均, 缺乏精确操作所需的锐度。

整合 SGR 有效中和了这一局限性。通过利用无分类器引导作为显式校正信号, SGR 将单步预测推离无条件噪声

表 4: Adroit、DexArt 和 MetaWorld 上的详细 3D 仿真结果。结果在 3 个随机种子上取平均，并以均值 $\pm$ 标准差的形式报告。每列中的最佳结果以粗体突出显示。

Method	NFE	Adroit			DexArt			
		Hammer	Door	Pen	Laptop	Faucet	Bucket	Toilet
DP3	100	100$\pm$0	70 $\pm$ 1	67 $\pm$ 1	94$\pm$1	44 $\pm$ 1	34 $\pm$ 1	82 $\pm$ 1
DP3	10	98 $\pm$ 2	66 $\pm$ 4	64 $\pm$ 4	91 $\pm$ 1	43 $\pm$ 1	35 $\pm$ 1	77 $\pm$ 1
FM Policy	100	100$\pm$0	76 $\pm$ 1	74 $\pm$ 1	92 $\pm$ 5	39 $\pm$ 4	32 $\pm$ 3	83$\pm$4
FM Policy	10	100$\pm$0	72 $\pm$ 3	69 $\pm$ 3	92 $\pm$ 3	37 $\pm$ 5	34 $\pm$ 5	80 $\pm$ 7
CP	1	98 $\pm$ 3	67 $\pm$ 5	65 $\pm$ 5	87 $\pm$ 3	44 $\pm$ 4	29 $\pm$ 4	82 $\pm$ 4
OneDP	1	99 $\pm$ 1	67 $\pm$ 2	65 $\pm$ 2	89 $\pm$ 4	45 $\pm$ 3	33 $\pm$ 6	83$\pm$4
MP1	1	100$\pm$0	74 $\pm$ 3	72 $\pm$ 3	88 $\pm$ 5	42 $\pm$ 1	33 $\pm$ 0	82 $\pm$ 2
OFP	1	100$\pm$0	79$\pm$7	76$\pm$7	92 $\pm$ 3	46$\pm$4	39$\pm$0	81 $\pm$ 3

Method	NFE	MetaWorld Easy					
		Button Press	Button Press Topdown	Button Press Topdown Wall	Button Press Wall	Coffee Button	Dial Turn
DP3	100	78 $\pm$ 10	100$\pm$0	98 $\pm$ 2	82 $\pm$ 8	81 $\pm$ 13	79 $\pm$ 14
DP3	10	75 $\pm$ 7	100$\pm$0	96 $\pm$ 3	83 $\pm$ 6	81 $\pm$ 5	70 $\pm$ 4
FM Policy	100	50 $\pm$ 14	100$\pm$0	100$\pm$0	53 $\pm$ 2	76 $\pm$ 3	68 $\pm$ 11
FM Policy	10	46 $\pm$ 12	100$\pm$0	100$\pm$0	47 $\pm$ 11	73 $\pm$ 7	60 $\pm$ 9
CP	1	60 $\pm$ 4	100$\pm$0	94 $\pm$ 3	62 $\pm$ 7	66 $\pm$ 4	54 $\pm$ 8
OneDP	1	74 $\pm$ 5	100$\pm$0	100$\pm$0	76 $\pm$ 8	81 $\pm$ 5	66 $\pm$ 5
MP1	1	61 $\pm$ 3	100$\pm$0	100$\pm$0	62 $\pm$ 9	67 $\pm$ 3	53 $\pm$ 13
OFP	1	86$\pm$7	100$\pm$0	100$\pm$0	87$\pm$8	92$\pm$6	89$\pm$4

Method	NFE	MetaWorld Easy					
		Door Close	Door Lock	Door Open	Door Unlock	Drawer Close	Drawer Open
DP3	100	100$\pm$0	49 $\pm$ 20	100$\pm$0	100$\pm$0	73 $\pm$ 15	100$\pm$0
DP3	10	100$\pm$0	38 $\pm$ 9	100$\pm$0	100$\pm$0	76 $\pm$ 6	100$\pm$0
FM Policy	100	100$\pm$0	23 $\pm$ 13	100$\pm$0	100$\pm$0	45 $\pm$ 11	100$\pm$0
FM Policy	10	100$\pm$0	31 $\pm$ 18	100$\pm$0	100$\pm$0	41 $\pm$ 15	100$\pm$0
CP	1	100$\pm$0	25 $\pm$ 2	100$\pm$0	90 $\pm$ 5	54 $\pm$ 6	100$\pm$0
OneDP	1	100$\pm$0	29 $\pm$ 1	100$\pm$0	100$\pm$0	69 $\pm$ 6	100$\pm$0
MP1	1	100$\pm$0	21 $\pm$ 17	100$\pm$0	100$\pm$0	56 $\pm$ 5	100$\pm$0
OFP	1	100$\pm$0	61$\pm$12	100$\pm$0	100$\pm$0	81$\pm$13	100$\pm$0

Method	NFE	MetaWorld Easy					
		Faucet Close	Faucet Open	Handle Press	Handle Pull	Handle Press Side	Handle Pull Side
DP3	100	100$\pm$0	80 $\pm$ 15	100$\pm$0	47 $\pm$ 21	54 $\pm$ 7	84$\pm$12
DP3	10	100$\pm$0	75 $\pm$ 11	100$\pm$0	42 $\pm$ 6	57 $\pm$ 5	80 $\pm$ 6
FM Policy	100	100$\pm$0	77 $\pm$ 9	100$\pm$0	30 $\pm$ 9	55 $\pm$ 12	36 $\pm$ 9
FM Policy	10	100$\pm$0	72 $\pm$ 10	100$\pm$0	30 $\pm$ 11	51 $\pm$ 10	35 $\pm$ 19
CP	1	100$\pm$0	64 $\pm$ 5	100$\pm$0	21 $\pm$ 4	45 $\pm$ 5	48 $\pm$ 6
OneDP	1	100$\pm$0	79 $\pm$ 4	100$\pm$0	33 $\pm$ 5	50 $\pm$ 8	70 $\pm$ 4
MP1	1	100$\pm$0	65 $\pm$ 5	100$\pm$0	34 $\pm$ 9	45 $\pm$ 13	59 $\pm$ 16
OFP	1	100$\pm$0	88$\pm$7	100$\pm$0	63$\pm$13	91$\pm$6	69 $\pm$ 10

方法	NFE	MetaWorld 简单 杠杆板板滑板滑板滑板伸手拉滑回回侧侧					
DP3	100	78$\pm$14	43 $\pm$ 21	90 $\pm$ 13	100$\pm$0	87 $\pm$ 9	77$\pm$11
DP3	10	66 $\pm$ 3	39 $\pm$ 10	99$\pm$0	100$\pm$0	87 $\pm$ 5	69 $\pm$ 5
FM Policy	100	37 $\pm$ 6	24 $\pm$ 10	69 $\pm$ 9	100$\pm$0	60 $\pm$ 10	49 $\pm$ 11
FM Policy	10	32 $\pm$ 17	24 $\pm$ 7	63 $\pm$ 18	100$\pm$0	58 $\pm$ 14	45 $\pm$ 9
CP	1	43 $\pm$ 6	19 $\pm$ 2	79 $\pm$ 4	96 $\pm$ 4	73 $\pm$ 7	40 $\pm$ 1
OneDP	1	58 $\pm$ 3	27 $\pm$ 5	95 $\pm$ 1	100$\pm$0	89 $\pm$ 6	54 $\pm$ 3
MP1	1	46 $\pm$ 14	28 $\pm$ 15	77 $\pm$ 8	100$\pm$0	73 $\pm$ 5	43 $\pm$ 13
OFP	1	74 $\pm$ 12	57$\pm$20	94$\pm$5	100$\pm$0	94$\pm$3	71 $\pm$ 13

表 4: (续) Adroit、DexArt 和 MetaWorld 上的详细 3D 仿真结果。

Method	NFE	MetaWorld Easy				MetaWorld Medium	
		Reach Wall	Window Close	Window Open	Peg Unplug Side	Basket ball	Bin Picking
DP3	100	62±14	100±0	87±7	90±11	100±0	19±3
DP3	10	57±2	100±0	81±10	91±3	100±0	17±5
FM Policy	100	24±8	100±0	84±7	67±15	100±0	17±6
FM Policy	10	20±11	100±0	77±16	62±14	100±0	16±9
CP	1	30±7	100±0	69±4	79±8	73±9	7±3
OneDP	1	44±5	100±0	85±6	95±1	100±0	13±5
MP1	1	35±10	100±0	69±13	78±8	78±11	14±6
OFP	1	72±8	100±0	94±3	96±2	100±0	29±11

Method	NFE	MetaWorld Medium						
		Box Close	Coffee Pull	Coffee Push	Hammer	Peg Insert Side	Push Wall	Soccer
DP3	100	21±3	43±11	58±5	69±7	53±2	51±7	16±7
DP3	10	20±1	43±3	55±2	70±3	55±3	53±6	13±2
FM Policy	100	18±3	56±7	45±6	63±1	46±5	39±10	11±4
FM Policy	10	14±6	53±11	47±6	61±9	47±10	36±13	12±5
CP	1	6±2	37±6	39±5	54±6	39±3	37±8	6±1
OneDP	1	12±6	41±12	42±12	57±15	43±11	44±19	14±7
MP1	1	13±4	43±5	45±5	60±6	45±10	43±7	9±3
OFP	1	27±6	57±10	59±5	73±3	59±7	57±5	20±7

Method	NFE	MetaWorld Medium		MetaWorld Hard				
		Sweep	Sweep Into	Assembly	Hand Insert	Pick Out of Hole	Pick Place	Push
DP3	100	68±10	15±4	73±10	21±11	22±13	26±10	50±6
DP3	10	66±7	17±3	72±7	18±4	20±10	25±14	47±11
FM Policy	100	58±7	12±8	75±7	22±1	26±5	46±10	49±5
FM Policy	10	57±9	12±6	69±6	19±7	26±4	41±14	47±10
CP	1	50±8	6±2	63±9	11±6	14±8	22±7	35±7
OneDP	1	54±11	16±8	72±4	17±9	19±2	38±9	48±5
MP1	1	56±15	11±4	63±6	17±10	19±11	28±13	45±8
OFP	1	70±7	24±12	74±5	22±2	23±2	42±1	55±6

方法	NFE	MetaWorld 极难					Average
		Shelf Place	Disassemble	Stick Pull	Stick Push	Pick Place Wall	
DP3	100	22±5	45±4	24±1	74±8	40±3	66.4±5.7
DP3	10	21±9	52±7	28±8	80±7	47±8	65.2±2.8
FM Policy	100	26±6	54±2	36±5	82±8	41±5	59.8±4.6
FM Policy	10	25±9	52±6	36±4	79±14	42±7	57.9±7.0
CP	1	12±2	42±4	21±1	69±10	36±6	54.7±2.9
OneDP	1	16±5	48±6	26±6	76±8	43±5	62.4±3.0
MP1	1	8±3	38±7	18±4	64±9	33±7	57.4±5.8
OFP	1	23±2	56±2	34±5	83±6	50±7	71.6±4.1

表 5: RoboTwin 2.0 上的详细 $\pi_{0.5}$ 集成结果。所有方法均在 100 次随机测试试验上评估。

Method	NFE	Adjust Bottle	Beat Block Hammer	Handover Mic	Place Empty Cup
$\pi_{0.5}$	10	96.0 $\pm$ 4.0	88.3 $\pm$ 3.8	90.7 $\pm$ 1.2	91.0 $\pm$ 3.0
CFM	1	85.3 $\pm$ 3.1	82.0 $\pm$ 3.6	74.3 $\pm$ 1.2	74.7 $\pm$ 2.9
Shortcut	1	89.3 $\pm$ 2.3	78.0 $\pm$ 3.6	75.0 $\pm$ 3.0	81.3 $\pm$ 2.5
iMF	1	92.7 $\pm$ 2.3	84.3 $\pm$ 2.5	82.7 $\pm$ 2.9	87.0 $\pm$ 3.5
OFP	1	99.0$\pm$1.0	91.7$\pm$2.5	94.3$\pm$3.8	93.7$\pm$1.5

表 6: OFP 的组件分析。SCT: 自洽性训练。SGR: 自引导正则化。

Method	NFE	Door	Hammer	Pen	Bucket	Faucet	Laptop	Toilet	Average
SCT	1	72 $\pm$ 3	100$\pm$0	68 $\pm$ 5	33 $\pm$ 3	42 $\pm$ 1	89 $\pm$ 1	77 $\pm$ 1	68.7
	4	82 $\pm$ 1	100$\pm$0	72 $\pm$ 2	36 $\pm$ 2	44 $\pm$ 3	90 $\pm$ 0	82 $\pm$ 1	72.3
SCT+SGR	1	77 $\pm$ 4	100$\pm$0	73 $\pm$ 3	37 $\pm$ 1	44 $\pm$ 0	90 $\pm$ 1	79 $\pm$ 2	71.4
	4	82 $\pm$ 3	100$\pm$0	73 $\pm$ 1	39 $\pm$ 3	43 $\pm$ 1	90 $\pm$ 2	81 $\pm$ 0	72.6
OFP	1	79 $\pm$ 7	100$\pm$0	76 $\pm$ 7	39 $\pm$ 0	46 $\pm$ 4	92$\pm$3	81 $\pm$ 3	73.3
	4	86$\pm$2	100$\pm$0	79$\pm$1	43$\pm$2	47$\pm$1	92$\pm$4	83$\pm$1	75.7

并直接驱动它们朝向专家模式。这种有针对性的正则化将单步成功率提升至 71.4%，提高了近 3 个百分点。此外，锐化单步预测为多步集成提供了更准确的局部目标，将 NFE=4 性能推至 72.6%。这表明 SCT 与 SGR 高度互补：SCT 平滑了跨时间的流轨迹，而 SGR 确保最终预测精确落在数据流形上。

在推理阶段引入无需训练的 Warm-Start 机制带来了显著的额外增益，将 NFE=1 处的成功率提升至 73.3%，NFE=4 处提升至 75.7%。通过从时间上偏移的未执行动作构建初始化先验，Warm-Start 本质上使起始状态更接近目标分布。这减少了生成模型在单步中必须穿越的传输距离，可靠地增强了控制平滑度和精确度。

D.2 超参数分析

为优化系统效率和稳定性，我们探索超参数的选择与设计。

子批次分配。为减轻计算开销，OFP 实施子批次训练策略。我们分配批次的一部分 p_{sc} 用于计算自洽性损失（ $r \neq t$ ）。剩余 $1 - p_{sc}$ 部分用于标准流匹配（ $r = t$ ）。从该子集中，分配比例 p_{sg} 用于计算 SGR 损失。表 7a 表明最优配置为 $p_{sc} = 0.2$ 和 $p_{sg} = 0.1$ 。将过多数据分配给一致性或引导会削弱基础流匹配目标，而保持较小且有针对性的比例可在不破坏基线的稳定性的情况下提供最优正则化。

时间采样分布。生成质量对一致性训练中区间时间的采样分布较为敏感。策略网络以当前时间 t 和相对区间 dt 作为条件，并以 $r = t + dt$ 处的区间为目标。如表 7b 所示，从贝塔分布中采样 t 并从对数正态分布中采样 dt 可获得最高的成功率（73.3%）。

引导权重。系数 λ_{sg} 调节自引导正则项相对于总目标的强度。表 7c 表明，保守权重 $\lambda_{sg} = 0.05$ 为最优。施加过于激进的引导信号（例如 0.5）会过度正则化生成过程，迫使模型陷入模式崩塌，并将性能显著降低至 68.7%。

热启动噪声比率。热启动通过以特定比例的高斯噪声破坏先前动作块中未执行的序列来初始化生成器，该比例由起始时间

表 7：超参数分析。所有结果均反映 Adroit 和 DexArt 中 7 项任务的平均成功率。

(a) **Sub-batch training ratios.** Impact of data fraction allocation (p_{sc}, p_{sg}).

p_{sc}	p_{sg}	SR (%)
20%	10%	73.3
20%	20%	72.2
50%	10%	71.7
50%	20%	71.4

(b) **Time samplers.** Performance under various interval sampling distributions for t and dt .

t sampler	dt sampler	SR (%)
Uniform(0, 1)	Uniform(0, 1)	69.9
Uniform(0, 1)	LogNorm(-0.2, 1)	71.7
Uniform(0, 1)	LogNorm(-0.4, 1)	72.3
Beta(1, 1.5)	LogNorm(-0.2, 1)	73.3
Beta(1, 1.5)	LogNorm(-0.4, 1)	72.2

(c) **Guidance scale.** The effect of the SGR loss regularizer weight λ_{sg} .

λ_{sg}	SR (%)
0.5	68.7
0.1	70.4
0.05	73.3
0.01	72.1

(d) **Warm-start noise.** Modifying the initialization noise ratio via t_w .

t_w	SR (%)
0.75	69.5
0.5	72.3
0.25	72.1
0.15	73.3
0.0	71.4

参数 t_w 控制。当 $t_w \rightarrow 0$ 时，初始化趋近于纯噪声。表 7d 确定 $t_w = 0.15$ 可获得最佳性能。当 t_w 过小时，推理实际上退化为标准的零样本生成，丢弃了强大的时间先验。相反，赋予较大的 t_w （例如 0.75）会严重抑制必要的生成随机性。这种对过去预测的僵化依赖限制了系统纠正累积误差或适应即时动作空间中大幅变化的能力。

E 相关工作

E.1 机器人控制的生成式策略

扩散模型最初通过规划即生成范式进入机器人领域。Diffuser [42] 和 Decision Diffuser [50] 等工作将长时程行为概念化为通过逐步去噪生成的轨迹样本，用条件生成取代传统动态规划。随后，研究重点转向直接参数化视觉运动策略。Diffusion Policy [41] 将动作序列生成建模为条件去噪过程，显著提升了多模态动作分布的表达能力和整体训练稳定性。然而，其部署需要迭代多步采样，导致推理延迟随步数线性增长。后续研究沿两个主要方向展开。第一个方向侧重于增强空间表示和结构偏差以改进精细操作，采用交叉注意力（Crossway Diffusion [51]）、三维点云条件化（DP3 [46]、3D Diffuser Actor [61]）和关键姿态预测（ChainedDiffuser [62]）等方法。第二个方向通过探索高吞吐量范式（DiffuserLite [63]）来解决闭环控制的严格延迟约束。

与此同时，基于流匹配的策略学习获得了显著关注。连续流匹配（CFM）已成功与可供性表示 [44] 和多接触全身控制 [64] 相结合。ActionFlow [54] 等工作将 SE(3) 等变结构注入速度场以改善空间泛化，而 AdaFlow [53] 设计了自适应步长求解器以平衡速度与多样性。在此框架内，出现了面向少步推理的结构化方法。例如，FlowPolicy [55] 通过一致性流匹配追求单步生成，MP1 [45] 则采用 MeanFlow 的区间平均速度，在单步（1-NFE）内生成以三维点云为条件的动作。

随着生成式策略扩展为大规模视觉-语言-动作（VLA）模型，迭代采样的计算成本成为严重瓶颈。RDT-1B [4] 等架构将扩散 Transformer 扩展到十亿参数以用于双臂操作，而 π 系列（包括 π_0 [10]，

$\pi_{0.5}$ [11] 和 $\pi_{0.6}$ [12] 将流匹配确立为高度可扩展的动作生成头，用于开放世界任务。随着模型容量和语义复杂度的增加，在不降低控制精度的情况下将生成压缩到单步，是实际部署的关键要求。

E.2 蒸馏与加速

在视觉生成中，少步加速存在两种主流范式。一致性模型（Consistency Models）[15] 将概率路径上的点映射到单一原点，建立了一致性蒸馏路线。另一种是分布匹配蒸馏（Distribution Matching Distillation, DMD）[23]，它利用分数差异通过反向 KL 梯度使学生模型与教师模型的分布对齐。最近，MeanFlow [17] 通过建模有限区间平均速度实现了从零开始的 1-NFE 训练；然而，实现其目标需要复杂的高阶雅可比向量积（Jacobian-Vector Products, JVPs），这会破坏训练稳定性并消耗大量内存。

这些加速概念已迅速转移到机器人领域。一致性范式被应用于强化学习（CPQL [65]）和视觉运动控制（一致性策略 [26]，ManiCM [59]）。由于一致性蒸馏迫使中间状态收敛到共享终点，其优化目标本质上是模式覆盖的。虽然这实现了少步推理，但经常导致策略在多模态动作分布上取平均，产生平滑、不精确的动作，在精细操作任务中失败。

相反，单步扩散策略（One-Step Diffusion Policy, OneDP）[28] 和 SDM 策略 [40] 等方法将 DMD 风格的分布匹配应用于机器人领域。这种方法本质上是模式寻求的，产生更清晰、更高质量的单步样本。然而，它严重限制了动作多样性。此外，它严重依赖大型预训练教师模型和辅助分数网络，这增加了训练开销，并在分布偏移期间造成泛化瓶颈。

除了蒸馏之外，流式扩散策略（Streaming Diffusion Policy）[66] 等工作利用滚动时域控制的时间相关性，重用中间状态以减少所需的去噪步骤并保持高控制频率。

总结。 现有少步加速方法迫使在一致性模型的模式覆盖稳定性与分数蒸馏的模式寻求精确率之间进行权衡。OFP 在统一的、从零开始的自蒸馏目标中结合了两种信号。通过这样做，它消除了外部教师的计算开销和 JVP 算子的不稳定性。结合重用跨块先验的热启动机制，OFP 提供了一种高度稳定的单步推理解决方案，具备复杂机器人控制所需的精确率。