

广义薛定谔桥下在线策略强化学习的路径空间镜像下降

Yuehu Gong¹ Zeyuan Wang² Yulin Chen² Shutong Ding³ Qingyuan Zhou⁴ Yanwei Fu^{1,5}

¹School of Data Science, Fudan University

²Laboratory for Big Data and Decision, National University of Defense Technology

³ShanghaiTech University

⁴College of Computer Science and Artificial Intelligence, Fudan University

⁵Shanghai Innovation Institute

摘要

经典在线策略算法，如近端策略优化（PPO）和镜像下降策略优化，通过可处理的动作似然提供稳定的近端策略更新，但通常采用简单的高斯策略，其在复杂连续控制任务中的表达能力可能受限。基于扩散和流模型的生成式策略提供了更具表达力的动作分布，但它们自然定义了多步去噪路径上的分布，其终端动作密度往往难以处理，从而与基于似然的在线策略近端更新产生不匹配。为解决这一不匹配问题，本文提出 **GSB-MDPO**（广义薛定谔桥镜像下降策略优化），将在线生成式策略优化形式化为状态条件生成路径上的广义薛定谔桥问题，并通过镜像下降策略优化实例化所得的路径测度更新。关键洞见在于，GSB 路径空间 KL 散度在 MDPO 中扮演近端项的角色，同时上界终端动作 KL 散度，从而无需显式终端动作似然评估即可直接控制执行的动作分布。在 Playground 和 Gym-MuJoCo 上的 14 个连续控制任务实验证明了 **GSB-MDPO** 的经验有效性，并支持路径空间正则化作为多步生成式策略的原则性近端更新。

1 引言

在线策略强化学习因其高度可并行化的轨迹收集 [29, 31] 而在连续控制中被广泛使用。诸如 TRPO 和 PPO 等方法通过信任域、似然比或 KL 正则化 [39, 41, 44] 约束策略更新来稳定这些更新。然而，大多数实现依赖于计算高效但受限的策略类，如对角高斯分布，当有效控制需要多模态动作分布时，这可能限制性能。近年来，基于扩散 [18, 42] 或流模型 [15, 23] 的生成式策略提供了更具表达力的替代方案。生成式策略在规划 [19]、模仿学习 [6]、离线强化学习 [34, 49, 50] 和在线控制 [17, 20] 中已展现出潜力。

与具有可处理动作密度的高斯策略不同，生成式策略将动作生成为多步去噪或传输过程的终点。由此产生的终端动作似然通常难以处理或评估成本高昂 [5, 16, 52, 54]，这使得基于似然比或动作空间 KL 正则化的标准同策略更新难以应用。近期工作试图通过恢复或近似标准近端更新中使用的似然比项，使同策略优化与生成式策略兼容。DPPO 将策略梯度更新适配到扩散策略 [24, 38]，GenPO 引入可逆扩散策略以恢复精确动作

似然 [9], 而 FPO 从条件流匹配目标构造代理策略比率 [30]。

这些方法使同策略生成式强化学习日益实用, 但留下了一个更根本的问题: 当终端动作似然难以处理时, 生成式策略的近端正则化应施加于何处?

合适的正则化器应易于处理, 同时仍能控制所执行动作的分布。终端动作密度往往不满足这一要求, 而完整生成路径提供了一个易于处理的替代方案。具体而言, 生成式策略在其去噪轨迹上诱导出一个路径测度, 路径测度之间的 KL 散度上界于其终端动作边缘分布之间的 KL 散度。因此, 将当前路径测度向旧路径测度正则化, 可以在不显式评估终端动作似然的情况下控制所执行的策略。这种路径空间视角与广义薛定谔桥公式一致, 后者相对于参考过程优化随机路径测度 [22, 25]。

由此引出 GSB-MDPO, 一个用于同策略生成式强化学习的路径空间镜像下降框架。在每次迭代中, GSB-MDPO 提升终端动作的旧策略优势, 同时通过路径空间 KL 将当前生成路径测度向旧路径测度正则化。优势项和前向路径 KL 项均可通过重要性采样从旧策略采样路径中估计, 因此策略更新无需从当前策略额外采样。对于具有共享扩散系数的随机生成器, 相同的路径 KL 通过标准 SDE 路径 KL 恒等式进一步简化为漂移均方误差正则化器。

总体而言, 本文的贡献总结如下:

- **GSB-MDPO: 生成式策略的路径空间镜像下降。**本文提出 GSB-MDPO, 一种镜像下降策略优化框架, 在广义薛定谔桥视角下, 将邻近更新从终端动作分布提升到条件生成路径测度。
- **通过路径 KL 上界实现终端动作控制。**本文证明完整生成路径测度之间的 KL 散度是终端动作分布之间 KL 散度的上界。这使得 GSB-MDPO 能够通过可处理的路径空间正则化器约束实际执行的动作分布, 而无需显式评估终端动作似然。
- **在连续控制基准上的实证验证。**本文在 Playground 和 Gym-MuJoCo 上评估 GSB-MDPO, 并与代表性的高斯和生成式在线策略基线进行比较, 包括 PPO、DPPO、FPO 和 GenPO。关于路径正则化、参考混合、比率稳定化和确定性评估的消融实验进一步支持了路径空间正则化的作用。

2 相关工作

2.1 用于在线强化学习的生成式策略

近期研究已开始将表达性扩散与流策略整合到显式在线策略强化学习中。DPPO 对扩散策略应用策略梯度微调, 并将去噪过程视为策略优化过程的一部分 [38]。GenPO 使用虚拟动作使扩散策略可逆且似然可处理, 以用于 PPO 风格的更新 [9–11, 21]。CPPPO 对条件高斯去噪转移应用近端更新, 避免了完整的去噪似然, 但在单峰设置中收益较少 [24]。FPO 则通过使用条件流匹配损失为流策略构建替代优势加权比率, 从而避免精确似然计算 [30]。ReinFlow 将可学习噪声注入流匹配策略, 使流成为具有可处理似然的离散时间马尔可夫过程, 用于在线强化学习微调 [52], 而 Flow-GRPO 在 GRPO 设置中研究流匹配模型的在线策略梯度训练 [26]。FlowRL 进一步通过模块化 JAX 框架和分类法, 在 Gym、DMC 和 IsaacLab 基准上系统化扩散/流策略强化学习领域 [13]。

GSB-MDPO 在目标和实现上均与这些方法不同。我们不是像 GenPO 和 ReinFlow 那样修改生成过程以恢复精确的终端动作似然, 也不是像 FPO 那样用流匹配替代似然比, 而是将更新直接表述为路径测度上的镜像下降。优势项和前向路径 KL 项均通过重要性采样在旧策略 rollout 路径上进行评估。这产生了一个

受广义薛定谔桥视角启发的在线策略路径空间更新，同时保留了 PPO 风格训练的数据重用结构。

2.2 其他生成式强化学习范式

大量研究探讨了非在策略设定下的生成式策略。在模仿学习与规划中，扩散模型已被用于从示范和离线数据生成轨迹或动作序列 [6, 19]。在离线强化学习中，扩散 Q 学习 (Diffusion-QL) 引入扩散策略作为表达力强的策略类，并以 Q 学习目标进行正则化 [50]。后续工作提升了扩散策略在离线强化学习目标下的效率或兼容性，包括隐式扩散 Q 学习 (IDQL) [17]、能量扩散策略 (EDP) [20] 以及基于流的 Q 学习 [12, 32, 34]。这些方法凸显了生成式策略的表示优势，但它们从固定数据集中学习，而非从新鲜的在策略采样轨迹中学习。

生成式策略也已在在线与离策略演员-评论家设定中得到探索。Q 分数匹配 (QSM) 利用 Q 分数匹配以价值梯度引导扩散策略 [36]，而 Q 值加权变分策略优化 (QVPO) 为基于扩散的在线强化学习推导出 Q 加权变分策略优化目标 [8]。扩散演员-评论家熵正则化 (DACER) 将扩散策略扩展至带熵正则化的在线演员-评论家学习 [47]，DACERv2 通过加入 Q 梯度场监督与时间加权提升扩散效率，以更少的扩散步骤实现强劲性能 [48]。扩散最大熵 (DIME) 通过边际熵下界为扩散策略推导最大熵目标 [4]。相关的基于流的方法，如软演员-评论家流 (SAC Flow) [53]，通过速度重参数化使熵最大化变得可处理。流演员-评论家 (FLAC) 进一步将最大熵生成式强化学习与广义薛定谔桥及动能正则化联系起来 [27]。这些工作与本文互补：它们主要研究离线、离策略或最大熵演员-评论家范式，而广义薛定谔桥镜像下降策略优化 (GSB-MDPO) 专注于在旧策略生成路径上的在策略镜像下降。

3 预备知识

3.1 在策略镜像下降策略优化

本文考虑一个折扣马尔可夫决策过程 $\mathcal{M} = (S, \mathcal{A}, p, r, \rho_0, \gamma)$ 。随机策略 $\pi_\theta(a | s)$ 被优化以最大化

$$J(\pi_\theta) = \mathbb{E}_{\pi_\theta} \left[\sum_{h=0}^{\infty} \gamma^h r(s_h, a_h) \right], \quad (1)$$

其中 h 索引环境交互时间。对于策略 π ，令

$$A^\pi(s, a) = Q^\pi(s, a) - V^\pi(s) \quad (2)$$

为优势函数。在第 k 次迭代中，在策略方法从旧策略 π_k 收集轨迹并估计 $A_k(s, a) \approx A^{\pi_k}(s, a)$ ，通常使用广义优势估计 [40]。令 d_k 表示由 π_k 诱导的状态访问分布。

镜像下降策略优化将策略改进表述为反复求解围绕旧策略 [14, 44] 的正则化局部更新。在其理想的动作空间形式中，更新为

$$\pi_{k+1} = \arg \max_{\pi} \mathbb{E}_{s \sim d_k} \left[\mathbb{E}_{a \sim \pi(\cdot | s)} [A_k(s, a)] - \alpha D_{\text{KL}}(\pi(\cdot | s) \| \pi_k(\cdot | s)) \right], \quad (3)$$

其中 $\alpha > 0$ 控制与旧策略的接近程度。对于固定的 s ，精确的非参数优化器是指数倾斜

$$\pi^*(a | s) = \frac{1}{Z(s)} \pi_k(a | s) \exp \left(\frac{A_k(s, a)}{\alpha} \right), \quad (4)$$

其中 $Z(s)$ 为归一化常数。在参数化策略类中，MDPO 通过梯度更新近似优化该 KL 正则化目标，既保留了镜像下降原理，又避免了精确的信任域求解 [44]。GSB-MDPO 将这一动作空间更新从终端动作分布提升到由多步生成策略诱导的完整条件路径测度。

3.2 路径空间策略的广义薛定谔桥

迭代生成策略通过随机传输过程而非单步动作密度来定义动作分布 [18, 23, 42]。令 $t \in [0, 1]$ 表示生成时间。我们通过以下随机微分方程对动作生成进行建模

$$da_t = f_\theta(a_t, t, s) dt + \sigma_t dW_t, \quad a_0 \sim \mu_{\text{init}}, \quad (5)$$

其中 f_θ 是学习到的漂移或速度场， σ_t 是预设的噪声尺度， W_t 是标准维纳过程。初始变量 a_0 从简单先验 μ_{init} 中采样，终端变量 a_1 是在环境中执行的动作。因此，生成策略在从先验端点到动作端点的轨迹上诱导出一个路径测度。

广义薛定谔桥（GSB）将随机生成表述为相对于参考过程 [3, 22, 25, 35] 的效用正则化路径测度优化。对于路径空间策略优化，GSB 目标可以写为

$$P^* = \arg \max_{P: P_0 = \mu_{\text{init}}} \{ \mathbb{E}_{\tau \sim P} [U(a_1)] - \alpha D_{\text{KL}}(P \| P_{\text{ref}}) \}, \quad (6)$$

其中 P_{ref} 是参考路径测度， $P_0 = \mu_{\text{init}}$ 固定简单先验端点， $U(a_1)$ 对终端动作分布进行软塑造，而不是将其规定为硬边际约束。对于在线策略生成强化学习，参考过程是旧路径策略， U 是所执行动作的旧策略优势。

在实现中，连续过程在网格上离散化

$$0 = t_0 < t_1 < \dots < t_N = 1, \quad (7)$$

采用 $a^{(n)} \approx a_{t_n}$ 。一个简单的欧拉转移为

$$a^{(n+1)} = a^{(n)} + (t_{n+1} - t_n) f_\theta(a^{(n)}, t_n, s) + \sigma_{t_n} \sqrt{t_{n+1} - t_n} \epsilon_n, \quad \epsilon_n \sim \mathcal{N}(0, I). \quad (8)$$

对于离散路径

$$\tau := a^{(0:N)} = (a^{(0)}, a^{(1)}, \dots, a^{(N)}), \quad (9)$$

该策略诱导出路径密度

$$P_\theta(a^{(0:N)} | s) = \mu_{\text{init}}(a^{(0)}) \prod_{n=0}^{N-1} p_\theta(a^{(n+1)} | a^{(n)}, s). \quad (10)$$

这种广义薛定谔桥视角促使第 4 节提出广义薛定谔桥-镜像下降策略优化：镜像下降从终端动作分布提升到生成路径测度。

4 方法

广义薛定谔桥-镜像下降策略优化的核心思想是将生成策略不仅视为终端动作分布，而且视为整个随机生成过程上的条件路径测度。这种路径空间视角使我们能够直接在生成轨迹上定义近端策略改进，同时通过重要性采样重用旧策略的采样路径。我们的公式建立在镜像下降策略优化 [14, 44] 和将随机生成视为路径空间优化的广义薛定谔桥视角 [22, 25] 之上。

4.1 广义薛定谔桥-镜像下降策略优化：路径空间中的镜像下降

设 $P_\theta(\tau | s)$ 表示由生成策略诱导的路径测度，其中 $\tau = a^{(0:N)}$ ， $a^{(0)} \sim \mu_{\text{init}}$ 是先验样本， $a^{(N)}$ 是在环境中执行的终端动作。如第 3.2 节所述，终端动作分布是边缘分布

$$\pi_\theta(a^{(N)} | s) = \int P_\theta(a^{(0:N)} | s) da^{(0:N-1)}. \quad (11)$$

因此，对于仅依赖于已执行动作的任何优势，

$$\mathbb{E}_{a^{(N)} \sim \pi_\theta(\cdot | s)} [A(s, a^{(N)})] = \mathbb{E}_{\tau \sim P_\theta(\cdot | s)} [A(s, a^{(N)})]. \quad (12)$$

设 $P_k := P_{\theta_k}$ 为用于收集轨迹的旧路径策略，设 $A_k(s, a^{(N)})$ 为旧策略优势估计。GSB-MDPO 在路径测度上执行镜像下降：

$$P_{k+1} = \arg \max_P \mathbb{E}_{s \sim d_k} \left[\mathbb{E}_{\tau \sim P(\cdot | s)} [A_k(s, a^{(N)})] - \alpha D_{\text{KL}}(P(\cdot | s) \| P_k(\cdot | s)) \right], \quad (13)$$

其中 d_k 是旧状态分布， $\alpha > 0$ 控制镜像下降步长。奖励改进项作用于终止动作，而近端正则化项作用于完整生成路径。

命题 1 (路径 KL 控制终止 KL)。设 F 和 Q 为 $\tau = a^{(0:N)}$ 上的路径测度，其终止边缘分布分别为 π_F 和 π_Q (定义于 $a^{(N)}$)。则

$$D_{\text{KL}}(P \| Q) \geq D_{\text{KL}}(\pi_P \| \pi_Q) \quad (14)$$

证明见附录 A.1。这是 KL 链式法则，等价于数据处理不等式 [7] 的一个实例。相关的辅助变量界出现在变分推断和生成建模中 [1, 2, 28, 37, 46]，并且最近已被用于扩散策略熵界 [4]。此处，相同的结构表明路径空间正则化同时控制终止边缘分布和条件生成动态。

命题 2 (期望旧优势改进)。设 s 求解式 (13)。则

$$\mathbb{E}_{s \sim d_k, \tau \sim P_{k+1}(\cdot | s)} [A_k(s, a^{(N)})] \geq \mathbb{E}_{s \sim d_k, \tau \sim P_k(\cdot | s)} [A_k(s, a^{(N)})]. \quad (15)$$

证明见附录 A.2。该结果表明，精确的路径空间镜像下降更新在固定旧状态分布下，相对于旧路径策略，提升了期望的旧策略优势。

命题 3 (最优 GSB-MDPO 路径测度)。对于固定的 s ，式 (13) 的解满足

$$P^*(\tau | s) \propto P_k(\tau | s) \exp\left(\frac{A_k(s, a^{(N)})}{\alpha}\right). \quad (16)$$

由于 A_k 仅依赖于终止动作，这意味着

$$\pi^*(a^{(N)} | s) \propto \pi_k(a^{(N)} | s) \exp\left(\frac{A_k(s, a^{(N)})}{\alpha}\right), \quad (17)$$

$$P^*(a^{(0:N-1)} | a^{(N)}, s) = P_k(a^{(0:N-1)} | a^{(N)}, s). \quad (18)$$

该指数倾斜解的示意可视化见附录 C.1。

证明见附录 A.3。命题 3 表明，精确更新提高了高优势终止动作的概率，同时保留了给定终止动作下的旧条件路径结构。这类似于动作空间 KL 正则化策略改进 [14, 44]，但将其应用于路径测度而非单步动作密度。

4.2 重要性采样路径 KL 目标

式 (13) 中的精确目标涉及在 P_θ 下的期望，而在策略回放中收集的样本来自 P_k 。对于存储的路径 τ ，定义精确路径比率

$$r_\theta(s, \tau) = \frac{P_\theta(\tau | s)}{P_k(\tau | s)} = \prod_{n=0}^{N-1} \frac{p_\theta(a^{(n+1)} | a^{(n)}, s)}{p_k(a^{(n+1)} | a^{(n)}, s)}. \quad (19)$$

对于任意路径级函数 F ，

$$\mathbb{E}_{\tau \sim P_\theta(\cdot | s)} [F(s, \tau)] = \mathbb{E}_{\tau \sim P_k(\cdot | s)} [r_\theta(s, \tau) F(s, \tau)]. \quad (20)$$

取 $F(s, \tau) = A_k(s, a^{(N)})$ 即得重要性采样的优势项。

路径 KL 散度在第 3.2 节的随机微分方程视角下也具备漂移均方误差形式。对于共享相同初始先验 μ_{init} 和扩散系数 σ_t 的两个策略，其漂移分别为 f_θ 和 f_k ，吉尔萨诺夫定理给出 [33]

$$D_{\text{KL}}(P_\theta \| P_k) = \mathbb{E}_{\tau \sim P_\theta} \left[\int_0^1 \frac{\|f_\theta(a_t, t, s) - f_k(a_t, t, s)\|_2^2}{2\sigma_t^2} dt \right], \quad (21)$$

在上下文清晰时省略对 s 的条件化。离散化后，路径 KL 漂移代价为

$$C_{\text{path}}(\theta, \theta_k; s, \tau) = \sum_{n=0}^{N-1} \frac{\Delta t_n}{2\sigma(t_n)^2} \|f_\theta(a^{(n)}, t_n, s) - f_k(a^{(n)}, t_n, s)\|_2^2, \quad \Delta t_n = t_{n+1} - t_n. \quad (22)$$

因此，均方误差形式的漂移差异并非临时惩罚项，而是共享扩散系数的随机生成器在离散化后的路径 KL 形式。利用式 (20)，实用目标将该代价纳入有效优势：

$$\mathcal{L}_{\text{MDPO}}(\theta) = -\mathbb{E}_{s \sim d_k, \tau \sim P_k} \left[r_\theta(s, \tau) (A_k(s, a^{(N)}) - \lambda C_{\text{path}}(\theta, \theta_k; s, \tau)) \right]. \quad (23)$$

这与在线策略镜像下降目标一致，因为优势项和路径 KL 代价均在当前路径测度下评估，再通过重要性采样改写为旧策略路径上的形式。然而，精确路径比是逐步似然比的乘积，当当前生成器远离旧生成器时可能具有高方差。为此，本文实现采用第 4.4 节所述的稳定路径比估计器。

4.3 熵保持参考正则化

在某些环境中，将路径策略不仅向旧策略正则化，还向一个简单参考过程正则化是有益的。设 $P_{\text{ref}}(\cdot | s)$ 表示参考路径测度，例如零漂移加噪过程。本文考虑

$$\max_P \mathbb{E}_{s \sim d_k} \left[\mathbb{E}_{\tau \sim P(\cdot | s)} [A_k(s, a^{(N)})] - \alpha D_{\text{KL}}(P(\cdot | s) \| P_k(\cdot | s)) - \beta D_{\text{KL}}(P(\cdot | s) \| P_{\text{ref}}(\cdot | s)) \right]. \quad (24)$$

两个 KL 项合并为朝向的单一 KL 散度

$$P_\eta(\tau | s) = \frac{1}{Z_\eta(s)} P_k(\tau | s)^{1-\eta} P_{\text{ref}}(\tau | s)^\eta, \quad \eta = \frac{\beta}{\alpha + \beta}, \quad (25)$$

因为

$$\alpha D_{\text{KL}}(P \| P_k) + \beta D_{\text{KL}}(P \| P_{\text{ref}}) = (\alpha + \beta) D_{\text{KL}}(P \| P_\eta) - (\alpha + \beta) \log Z_\eta(s). \quad (26)$$

参考过程正则化在薛定谔桥 (Schrödinger Bridge) 公式中很常见 [22, 25]，并且最近出现在最大熵生成式强化学习 [4, 27] 中。

在漂移空间中，配平方得到混合锚点

$$f_\eta = (1 - \eta) f_k + \eta f_{\text{ref}}. \quad (27)$$

在我们的实现中， f_{ref} 是零漂移，因此每条路径的成本变为

$$C_\eta(\theta, \theta_k; s, \tau) = \sum_{n=0}^{N-1} \frac{\Delta t_n}{2\sigma(t_n)^2} \|f_\theta(a^{(n)}, t_n, s) - f_\eta(a^{(n)}, t_n, s)\|_2^2, \quad \Delta t_n = t_{n+1} - t_n. \quad (28)$$

当参考正则化被禁用时， $\eta = 0$ 和 $C_\eta = C_{\text{path}}$ 。

4.4 步骤级和路径级比率裁剪

理论目标使用精确的路径比率 $r_\theta(s, \tau)$ 。在实践中，路径比率是生成步骤似然比的乘积，因此数值误差可能沿生成路径累积。对于每个生成步骤，令

$$\Delta \ell_n = \log p_\theta(a^{(n+1)} | a^{(n)}, s) - \log p_k(a^{(n+1)} | a^{(n)}, s), \quad n = 0, \dots, N-1.$$

我们使用裁剪后的路径比率

$$\tilde{r}_\theta(s, \tau) = \exp \left[\text{裁剪} \left(\sum_{n=0}^{N-1} \text{clip}(\Delta \ell_n, -c_{\text{step}}, c_{\text{step}}), -c_{\text{path}}, c_{\text{path}} \right) \right]. \quad (29)$$

实现的策略损失为

$$\hat{\mathcal{L}}_{\text{MDPO}}(\theta) = -\mathbb{E}_{s \sim d_k, \tau \sim P_k} \left[\tilde{r}_\theta(s, \tau) (A_k(s, a^{(N)}) - \lambda C_\eta(\theta, \theta_k; s, \tau)) \right]. \quad (30)$$

Algorithm 1 GSB-MDPO

Require: Actor θ , critic ϕ , coefficients λ, η , clipping thresholds $c_{\text{step}}, c_{\text{path}}$

```
1: for each on-policy iteration  $k = 0, 1, 2, \dots$  do
2:   Set old actor  $\theta_k \leftarrow \theta$ 
3:   Collect rollouts with  $P_k = P_{\theta_k}$  and store paths, old log-likelihoods, and old drifts
4:   Compute advantages and value targets
5:   for each minibatch do
6:     Recompute current log-likelihoods and drifts on stored paths
7:     Compute path cost  $C_\eta$  using Eq. (28)
8:     Compute clipped path ratio  $\tilde{r}_\theta$  using Eq. (29)
9:     Update actor with Eq. (30)
10:    Update critic  $\phi$  by minimizing  $\mathcal{L}_V(\phi) = \mathbb{E}_{s \sim \mathcal{D}_k} \left[ \left( V_\phi(s) - \hat{V}_k(s) \right)^2 \right]$ 
11:   end for
12: end for
```

在形成策略目标中使用的比率之前，对累积路径对数比率应用步级和路径级裁剪操作。这是累积路径似然比率的数值稳定机制，而非 PPO 风格的裁剪替代目标：PPO 裁剪的是终止动作比率，而 GSB-MDPO 裁剪的是逐步生成对数比率及其累积路径对数比率，以在小批量优化期间控制路径比率方差。当似然比率被裁剪时，通过该比率的梯度被抑制，但漂移成本 $C_\eta(\theta, \theta_k; s, \tau)$ 仍通过式 (30) 中的有效优势项贡献梯度。因此，裁剪在不移除路径 KL 漂移正则化信号的情况下稳定了重要性权重。

算法 1 总结了实现过程。所有策略更新均复用从旧策略采样的路径；在优化过程中，我们仅在存储的回放路径上重新计算当前路径似然和漂移值。

5 实验

我们在两个连续控制基准套件上评估 GSB-MDPO：(i) 来自 FPO 基准 [30] 的八个 Playground 任务，该基准构建于 MuJoCo Playground[51] 之上；以及 (ii) 在我们基于 FlowRL 的在线策略流程 [13] 中实现的六个 Gym-MuJoCo 任务，使用 Gymnasium 接口和 MuJoCo 物理引擎 [43, 45]。我们比较了五种方法：高斯 PPO[41]、DPPO[38]、FPO[30]、GenPO[9] 和 GSB-MDPO。在每个基准内，每种方法在所有任务上使用一个固定的超参数配置，不进行任务特定调优，除了 Humanoid-v5 上因内存相关的 GenPO 批量大小调整（见附录 B）。对于 Gym-MuJoCo，所有方法在相同的六个任务上训练 4000 万次环境交互。主要基准曲线报告五个种子的均值，阴影区域显示一个标准差。消融曲线报告两个种子的均值，阴影区域显示最小-最大包络。实现细节和超参数见附录 B。

5.1 Playground 上的主要结果

图 1 报告了游乐场套件上的结果。GSB-MDPO 在八个任务中获得了具有竞争力或更高的回报，在接球入杯、手指旋转、手指旋转容易和手指旋转困难任务上提升明显。在猎豹奔跑和两个到达任务上，多种方法达到了可比的最终回报，而 GSB-MDPO 仍处于领先方法之列。

这些结果表明，收益不仅仅源于使用多步生成策略。与 DPPO、FPO 和 GenPO 相比，GSB-MDPO 对完整生成路径进行正则化，为在线策略训练提供了更直接的近端更新。

5.2 Gym-MuJoCo 上的主要结果

图 2 报告了 Gym-MuJoCo 上的结果。GSB-MDPO 在六个运动任务上表现强劲，在更高维度的环境中尤其有效，例如 Ant-v5 和 Humanoid-




图 1: 游乐场结果。曲线显示五个种子上的均值 $\pm$ 一个标准差。




图 2: Gym-MuJoCo 结果。面板 (A) – (F) 显示六个任务的学习曲线，五个种子上的均值 $\pm$ 一个标准差。面板 (G) 报告了 HalfCheetah-v5 上的代表性训练时间和 GPU 内存。

v5，其中状态和动作空间都更大。它在 Swimmer-v5 和 Walker2d-v5 上也获得了强劲的最终性能，并在 Hopper-v5 上保持竞争力。在 HalfCheetah-v5 上，GenPO 取得了最高回报，而 GSB-MDPO 在所有 Gym-MuJoCo 任务使用的相同基准级超参数配置下仍保持竞争力，反映了在异构环境中使用一个固定配置的权衡。

面板 (G) 显示，GSB-MDPO 并未引入过高的训练开销。在 HalfCheetahv5 上，其训练时间接近 PPO/FPO/DPPO，且显著低于 GenPO，而内存使用与其他基于路径的生成基线相当。因此，Gym-MuJoCo 结果支持路径空间镜像下降作为在线策略生成策略在独立 FlowRL 训练栈上的有效且实用的优化原则。

5.3 进一步分析

图 3 在 HalfCheetah-v5 上评估了 GSB-MDPO 的四个组成部分。所有变体均在相同的基准级配置下训练，仅改变被测试的组件。对于 KL 和 Log-ratio 裁剪消融，我们与 GSB-MDPO 的 $\eta = 0$ 版本进行比较，以隔离路径-KL 系数与参考混合的影响。

路径-KL 正则化 (图 3A)。路径-KL 系数提供了路径空间镜像下降更新所需的近端约束。将该系数设为零会显著降低最终性能，表明漂移空间惩罚是优化目标的重要组成部分，而非辅助稳定器。

参考混合 (图 3B)。正的参考混合系数相比 $\eta = 0$ 变体提升了性能。这表明参考混合充当了类似熵的正则化器，有助于维持生成路径分布的随机性，并防止策略过早集中。

确定性 ODE 评估 (图 3C)。该结果支持在评估时使用确定性路径：策略在随机生成路径下训练，而评估时通过遵循学习到的确定性漂移来消除采样噪声。

对数比裁剪 (图 3D)。步级和路径级对数比裁剪提高了重要性采样路径比优化的稳定性。若不进行裁剪，累积的生成步数似然比会导致更新可靠性降低。




图 3: HalfCheetah-v5 上的消融实验。曲线表示两个随机种子下的均值及最小 - 最大包络。

对生成步数的敏感性。本文进一步研究了 GSB-MDPO 对生成步数的敏感性。图 4 报告了在 HalfCheetah-v5 上使用 4、8、16 和 32 个流步骤的结果。所有变体均训练 40M 环境交互次数，并在两个随机种子上取平均。

结果表明，在该任务上 GSB-MDPO 对生成步数的具体取值并不高度敏感。四种设置在训练结束时均达到相似的最终性能。使用更多步数可以略微平滑后期阶段的改进，而较少的步数（如 4 或 8）仍具有竞争力，有时在训练早期学习更快。这表明路径空间 MDPO 目标与较短和中等长度的生成路径均兼容，并且减少生成步数可能是在采样成本与性能之间进行权衡的实用方法。




图 4: GSB-MDPO 在 HalfCheetah-v5 上生成步数的消融实验。实线表示两个随机种子下的均值，阴影区域表示种子间的最小 - 最大包络。

6 结论与局限性

GSB-MDPO 将广义薛定谔桥建模与镜像下降策略优化相结合，为多步生成策略推导出路径空间近端更新。该方法不依赖通常难以处理的终端动作密度，而是对条件生成路径测度进行正则化。由此得到的路径 KL 散度控制了终端动作 KL 散度，可从在线策略数据中估计，并在共享扩散系数下退化为漂移均方误差惩罚。尽管优化的是多步生成路径，GSB-MDPO 通过避免额外的当前策略采样，实现了与 PPO 相当的效率。在 Playground 和 Gym-MuJoCo 上的实验及消融研究支持了路径空间正则化对在线策略生成式强化学习的有效性。

尽管性能强劲，GSB-MDPO 目前使用跨动作维度共享的固定标量噪声调度。虽然在归一化连续控制基准上有效，但这种设计对于需要状态依赖随机性的异构执行器可能并非最优，这一局限性在相关基于桥的最大熵方法中也有提及 [27]。未来工作应探索自适应噪声调度和更少步数的路径空间更新，以适用于更广泛的控制领域。

参考文献

- [1] Felix V. Agakov and David Barber. An auxiliary variational method. In *International Conference on Neural Information Processing (ICONIP)*, pages 561–566. Springer, 2004.
- [2] Oleg Arenz, Gerhard Neumann, and Mingjun Zhong. Efficient gradient-free variational inference using policy search. In *International Conference on Machine Learning (ICML)*, pages 234–243, 2018.
- [3] Jean-David Benamou and Yann Brenier. A computational fluid mechanics solution to the monge-kantorovich mass transfer problem. *Numerische Mathematik*, 84:375–393, 2000.
- [4] Onur Celik, Zechu Li, Denis Blessing, Ge Li, Daniel Palenicek, Jan Peters, Georgia Chalvatzaki, and Gerhard Neumann. DIME: Diffusion-based maximum entropy reinforcement learning. In *International Conference on Machine Learning (ICML)*, pages 6958–6977, 2025.
- [5] Ricky T. Q. Chen, Yulia Rubanova, Jesse Bettencourt, and David Duvenaud. Neural ordinary differential equations. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [6] Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 2025.
- [7] Thomas M. Cover. *Elements of Information Theory*. John Wiley & Sons, 1999.
- [8] Shutong Ding, Ke Hu, Zhenhao Zhang, Kan Ren, Weinan Zhang, Jingyi Yu, Jingya Wang, and Ye Shi. Diffusion-based reinforcement learning via q-weighted variational policy optimization. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [9] Shutong Ding, Ke Hu, Shan Zhong, Haoyang Luo, Weinan Zhang, Jingya Wang, Jun Wang, and Ye Shi. Genpo: Generative diffusion models meet on-policy reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [10] Laurent Dinh, David Krueger, and Yoshua Bengio. Nice: Non-linear independent components estimation. In *International Conference on Learning Representations Workshop (ICLR Workshop)*, 2015.
- [11] Laurent Dinh, Jascha Sohl-Dickstein, and Samy Bengio. Density estimation using real NVP. In *International Conference on Learning Representations (ICLR)*, 2017.
- [12] Nicolas Espinosa-Dice, Yiyi Zhang, Yiding Chen, Bradley Guo, Owen Oertell, Gokul Swamy, Kianté Brantley, and Wen Sun. Scaling offline rl via efficient and expressive shortcut models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [13] Chenxiao Gao, Edward Chen, Tianyi Chen, and Bo Dai. FlowRL: A taxonomy and modular framework for reinforcement learning with diffusion policies. *arXiv preprint arXiv:2603.27450*, 2026.
- [14] Matthieu Geist, Bruno Scherrer, and Olivier Pietquin. A theory of regularized markov decision processes. In *International Conference on Machine Learning (ICML)*, 2019.
- [15] Zhengyang Geng, Mingyang Deng, Xingjian Bai, J. Zico Kolter, and Kaiming He. Mean flows for one-step generative modeling. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025. Oral.
- [16] Will Grathwohl, Ricky T. Q. Chen, Jesse Bettencourt, Ilya Sutskever, and David Duvenaud. FFLORD: Free-form continuous dynamics for scalable reversible generative models. In *International Conference on Learning Representations (ICLR)*, 2019.
- [17] Philippe Hansen-Estruch, Ilya Kostrikov, Michael Janner, Jakub Grudzien Kuba, and Sergey Levine. IDQL: Implicit q-learning as an actor-critic method with diffusion policies. *arXiv preprint arXiv:2304.10573*, 2023.
- [18] Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2020.

- [19] Michael Janner, Yilun Du, Joshua B. Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning (ICML)*, pages 9902–9915, 2022.
- [20] Bingyi Kang, Xiao Ma, Chao Du, Tianyu Pang, and Shuicheng Yan. Efficient diffusion policies for offline reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2023.
- [21] Diederik P. Kingma and Prafulla Dhariwal. Glow: Generative flow with invertible 1x1 convolutions. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2018.
- [22] Christian Léonard. A survey of the schrödinger problem and some of its connections with optimal transport. *Discrete and Continuous Dynamical Systems*, 34(4):1533–1574, 2014.
- [23] Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations (ICLR)*, 2023.
- [24] Ben Liu, Shunpeng Yang, and Hua Chen. Diffusion policy through conditional proximal policy optimization. *arXiv preprint arXiv:2603.04790*, 2026.
- [25] Guan-Horng Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos A. Theodorou, and Ricky T. Q. Chen. Generalized schrödinger bridge matching. In *International Conference on Learning Representations (ICLR)*, 2024.
- [26] Jie Liu, Gongye Liu, Jiajun Liang, Yangguang Li, Jiaheng Liu, Xintao Wang, Pengfei Wan, Di Zhang, and Wanli Ouyang. Flow-GRPO: Training flow matching models via online rl. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.
- [27] Lei Lv, Yunfei Li, Yu Luo, Fuchun Sun, and Xiao Ma. FLAC: Maximum entropy rl via kinetic energy regularized bridge matching. *arXiv preprint arXiv:2602.12829*, 2026.
- [28] Lars Maaløe, Casper Kaae Sønderby, Søren Kaae Sønderby, and Ole Winther. Auxiliary deep generative models. In *International Conference on Machine Learning (ICML)*, pages 1445–1453, 2016.
- [29] Viktor Makoviychuk, Lukasz Wawrzyniak, Yunrong Guo, Michelle Lu, Kier Storey, Miles Macklin, David Hoeller, Nikita Rudin, Arthur Allshire, Ankur Handa, et al. Isaac gym: High performance gpu-based physics simulation for robot learning. *arXiv preprint arXiv:2108.10470*, 2021.
- [30] David McAllister, Songwei Ge, Brent Yi, Chung Min Kim, Ethan Weber, Hongsuk Choi, Haiwen Feng, and Angjoo Kanazawa. Flow matching policy gradients. In *International Conference on Learning Representations (ICLR)*, 2026.
- [31] Volodymyr Mnih, Adria Puigdomenech Badia, Mehdi Mirza, Alex Graves, Timothy Lillicrap, Tim Harley, David Silver, and Koray Kavukcuoglu. Asynchronous methods for deep reinforcement learning. In *International conference on machine learning (ICML)*, 2016.
- [32] Zhancun Mu. Deflow: Decoupling manifold modeling and value maximization for offline policy extraction. *arXiv preprint arXiv:2601.10471*, 2026.
- [33] Bernt Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. Springer, 6 edition, 2003.
- [34] Seohong Park, Qiyang Li, and Sergey Levine. Flow q-learning. In *International Conference on Machine Learning (ICML)*, pages 48104–48127, 2025.
- [35] Michele Pavon, Giulio Trigila, and Esteban G. Tabak. The data-driven schrödinger bridge. *Communications on Pure and Applied Mathematics*, 74(7):1545–1573, 2021.
- [36] Michael Psenka, Alejandro Escontrela, Pieter Abbeel, and Yi Ma. Learning a diffusion model policy from rewards via q-score matching. In *International Conference on Machine Learning (ICML)*, pages 41163–41182, 2024.

- [37] Rajesh Ranganath, Dustin Tran, and David M. Blei. Hierarchical variational models. In *International Conference on Machine Learning (ICML)*, pages 324–333, 2016.
- [38] Allen Z. Ren, Justin Lidard, Lars L. Ankile, Anthony Simeonov, Pulkit Agrawal, Anirudha Majumdar, Benjamin Burchfiel, Hongkai Dai, and Max Simchowitz. Diffusion policy policy optimization. In *International Conference on Learning Representations (ICLR)*, 2025.
- [39] John Schulman, Sergey Levine, Pieter Abbeel, Michael Jordan, and Philipp Moritz. Trust region policy optimization. In *International Conference on Machine Learning (ICML)*, pages 1889–1897, 2015.
- [40] John Schulman, Philipp Moritz, Sergey Levine, Michael Jordan, and Pieter Abbeel. High-dimensional continuous control using generalized advantage estimation. In *International Conference on Learning Representations (ICLR)*, 2016.
- [41] John Schulman, Filip Wolski, Prafulla Dhariwal, Alec Radford, and Oleg Klimov. Proximal policy optimization algorithms. *arXiv preprint arXiv:1707.06347*, 2017.
- [42] Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations (ICLR)*, 2021.
- [43] Emanuel Todorov, Tom Erez, and Yuval Tassa. Mujoco: A physics engine for model-based control. In *2012 IEEE/RSJ international conference on intelligent robots and systems*, pages 5026–5033. IEEE, 2012.
- [44] Manan Tomar, Lior Shani, Yonathan Efroni, and Mohammad Ghavamzadeh. Mirror descent policy optimization. In *International Conference on Learning Representations (ICLR)*, 2022.
- [45] Mark Towers, Ariel Kwiatkowski, Jordan Terry, John U Balis, Gianluca De Cola, Tristan Deleu, Manuel Goulão, Andreas Kallinteris, Markus Krimmel, Arjun KG, et al. Gymnasium: A standard interface for reinforcement learning environments. *arXiv preprint arXiv:2407.17032*, 2024.
- [46] Dustin Tran, David M. Blei, and Edoardo M. Airolidi. Copula variational inference. In *Advances in Neural Information Processing Systems (NeurIPS)*, volume 28, pages 3564–3572, 2015.
- [47] Yinuo Wang, Likun Wang, Yuxuan Jiang, Wenjun Zou, Tong Liu, Xujie Song, Wenxuan Wang, Liming Xiao, Jiang Wu, Jingliang Duan, and Shengbo Eben Li. Diffusion actor-critic with entropy regulator. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2024.
- [48] Yinuo Wang, Likun Wang, Mining Tan, Wenjun Zou, Xujie Song, Wenxuan Wang, Tong Liu, Guojian Zhan, Tianze Zhu, Shiqi Liu, Zeyu He, Feihong Zhang, Jingliang Duan, and Shengbo Eben Li. Enhanced DACER algorithm with high diffusion efficiency. *arXiv preprint arXiv:2505.23426*, 2025.
- [49] Zeyuan Wang, Da Li, Yulin Chen, Ye Shi, Liang Bai, Tianyuan Yu, and Yanwei Fu. One-step generative policies with q-learning: A reformulation of meanflow. In *Proceedings of the AAAI Conference on Artificial Intelligence (AAAI)*, 2026.
- [50] Zhendong Wang, Jonathan J. Hunt, and Mingyuan Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. In *International Conference on Learning Representations (ICLR)*, 2023.
- [51] Kevin Zakka, Baruch Tabanpour, Qiayuan Liao, Mustafa Haiderbhai, Samuel Holt, Jing Yuan Luo, Arthur Allshire, Erik Frey, Koushil Sreenath, Lueder A Kahrs, et al. Mujoco playground. *arXiv preprint arXiv:2502.08844*, 2025.
- [52] Tonghe Zhang, Chao Yu, Sichang Su, and Yu Wang. ReinFlow: Fine-tuning flow matching policy with online reinforcement learning. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2025.

- [53] Yixian Zhang, Shu'ang Yu, Tonghe Zhang, Mo Guang, Haojia Hui, Kaiwen Long, Yu Wang, Chao Yu, and Wenbo Ding. Sac flow: Sample-efficient reinforcement learning of flow-based policies via velocity-reparameterized sequential modeling. *International Conference on Learning Representations (ICLR)*, 2026.
- [54] Yixian Zhang, Shu'ang Yu, Tonghe Zhang, Guang Mo, Haojia Hui, Kaiwen Long, Yu Wang, Chao Yu, and Wenbo Ding. SAC flow: Sample-efficient reinforcement learning of flow-based policies via velocity-reparameterized sequential modeling. In *International Conference on Learning Representations (ICLR)*, 2026.

A 证明

A.1 路径 KL 分解的证明

设 P 和 Q 为 $\tau = a^{(0:N)}$ 上的路径测度。按终端动作对两个测度进行分解, 得到

$$P(a^{(0:N)}) = \pi_P(a^{(N)})P(a^{(0:N-1)} | a^{(N)}), \quad (31)$$

$$Q(a^{(0:N)}) = \pi_Q(a^{(N)})Q(a^{(0:N-1)} | a^{(N)}). \quad (32)$$

则

$$D_{\text{KL}}(P||Q) = \mathbb{E}_{\tau \sim P} \left[\log \frac{P(a^{(0:N)})}{Q(a^{(0:N)})} \right] \quad (33)$$

$$= \mathbb{E}_{\tau \sim P} \left[\log \frac{\pi_P(a^{(N)})}{\pi_Q(a^{(N)})} + \log \frac{P(a^{(0:N-1)} | a^{(N)})}{Q(a^{(0:N-1)} | a^{(N)})} \right] \quad (34)$$

$$= D_{\text{KL}}(\pi_P||\pi_Q) + \mathbb{E}_{a^{(N)} \sim \pi_P} \left[D_{\text{KL}} \left(P(a^{(0:N-1)} | a^{(N)}) || Q(a^{(0:N-1)} | a^{(N)}) \right) \right] \quad (35)$$

$$\geq D_{\text{KL}}(\pi_P||\pi_Q). \quad (36)$$

A.2 期望旧优势改进的证明

For fixed s , define

$$\mathcal{J}_s(P) = \mathbb{E}_{\tau \sim P(\cdot | s)} [A_k(s, a^{(N)})] - \alpha D_{\text{KL}}(P(\cdot | s) || P_k(\cdot | s)). \quad (37)$$

由于 P_{k+1} 最大化 $\mathcal{J}_s$ 且 P_k 是可行的,

$$\mathbb{E}_{\tau \sim P_{k+1}} [A_k(s, a^{(N)})] - \alpha D_{\text{KL}}(P_{k+1} || P_k) = \mathcal{J}_s(P_{k+1}) \quad (38)$$

$$\geq \mathcal{J}_s(P_k) \quad (39)$$

$$= \mathbb{E}_{\tau \sim P_k} [A_k(s, a^{(N)})]. \quad (40)$$

因此,

$$\mathbb{E}_{\tau \sim P_{k+1}} [A_k(s, a^{(N)})] \geq \mathbb{E}_{\tau \sim P_k} [A_k(s, a^{(N)})] + \alpha D_{\text{KL}}(P_{k+1} || P_k) \quad (41)$$

$$\geq \mathbb{E}_{\tau \sim P_k} [A_k(s, a^{(N)})]. \quad (42)$$

对 $s \sim d_k$ 取期望得到状态平均结果。

A.3 最优 GSB-MDPO 路径测度的证明

固定 s 并记 $\tau = a^{(0:N)}$ 。逐状态优化问题为

$$\max_P \int P(\tau) A_k(s, a^{(N)}) d\tau - \alpha \int P(\tau) \log \frac{P(\tau)}{P_k(\tau)} d\tau, \quad (43)$$

$$\text{s.t.} \quad \int P(\tau) d\tau = 1. \quad (44)$$

引入拉格朗日乘子 λ 得到

$$\mathcal{L}(P, \lambda) = \int P(\tau) A_k(s, a^{(N)}) d\tau - \alpha \int P(\tau) \log \frac{P(\tau)}{P_k(\tau)} d\tau \quad (45)$$

$$+ \lambda \left(\int P(\tau) d\tau - 1 \right). \quad (46)$$

一阶条件及其重排形式为

$$\frac{\delta \mathcal{L}}{\delta P(\tau)} = A_k(s, a^{(N)}) - \alpha \left(\log \frac{P^*(\tau)}{P_k(\tau)} + 1 \right) + \lambda = 0, \quad (47)$$

$$\log \frac{P^*(\tau)}{P_k(\tau)} = \frac{A_k(s, a^{(N)})}{\alpha} + \frac{\lambda}{\alpha} - 1. \quad (48)$$

将常数 $\exp(\lambda/\alpha - 1)$ 吸收到归一化因子中得到

$$P^*(\tau | s) = \frac{1}{Z(s)} P_k(\tau | s) \exp \left(\frac{A_k(s, a^{(N)})}{\alpha} \right), \quad (49)$$

$$Z(s) = \int P_k(\tau | s) \exp \left(\frac{A_k(s, a^{(N)})}{\alpha} \right) d\tau. \quad (50)$$

等价地,

$$Z(s) = \mathbb{E}_{\tau \sim P_k(\cdot | s)} \left[\exp \left(\frac{A_k(s, a^{(N)})}{\alpha} \right) \right]. \quad (51)$$

由于倾斜仅取决于终端动作 $a^{(N)}$, 联合优化器分解为

$$P^*(a^{(0:N)} | s) = \frac{1}{Z(s)} \pi_k(a^{(N)} | s) P_k(a^{(0:N-1)} | a^{(N)}, s) \exp \left(\frac{A_k(s, a^{(N)})}{\alpha} \right), \quad (52)$$

$$\pi^*(a^{(N)} | s) = \int P^*(a^{(0:N)} | s) da^{(0:N-1)} \quad (53)$$

$$= \frac{1}{Z(s)} \pi_k(a^{(N)} | s) \exp \left(\frac{A_k(s, a^{(N)})}{\alpha} \right), \quad (54)$$

$$P^*(a^{(0:N-1)} | a^{(N)}, s) = \frac{P^*(a^{(0:N)} | s)}{\pi^*(a^{(N)} | s)} \quad (55)$$

$$= P_k(a^{(0:N-1)} | a^{(N)}, s). \quad (56)$$

A.4 重要性采样恒等式

对于任意路径级函数 $F(s, \tau)$,

$$\mathbb{E}_{\tau \sim P_\theta(\cdot | s)} [F(s, \tau)] = \int P_\theta(\tau | s) F(s, \tau) d\tau \quad (57)$$

$$= \int P_k(\tau | s) \frac{P_\theta(\tau | s)}{P_k(\tau | s)} F(s, \tau) d\tau \quad (58)$$

$$= \mathbb{E}_{\tau \sim P_k(\cdot | s)} [r_\theta(s, \tau) F(s, \tau)], \quad (59)$$

这恢复了式 (20)。取 $F(s, \tau) = A_k(s, a^{(N)})$ 得到重要性采样的优势项。类似地,

$$D_{\text{KL}}(P_\theta(\cdot | s) \| P_k(\cdot | s)) = \int P_\theta(\tau | s) \log \frac{P_\theta(\tau | s)}{P_k(\tau | s)} d\tau \quad (60)$$

$$= \int P_k(\tau | s) \frac{P_\theta(\tau | s)}{P_k(\tau | s)} \log \frac{P_\theta(\tau | s)}{P_k(\tau | s)} d\tau \quad (61)$$

$$= \mathbb{E}_{\tau \sim P_k(\cdot | s)} [r_\theta(s, \tau) \log r_\theta(s, \tau)]. \quad (62)$$

A.5 路径 KL 散度作为漂移均方误差

考虑由具有相同初始先验 μ_{init} 和相同扩散系数的随机微分方程诱导的两个路径测度 P_θ 和 P_k :

$$da_t = f_\theta(a_t, t, s) dt + \sigma_t dW_t, \quad a_0 \sim \mu_{\text{init}}, \quad (63)$$

$$da_t = f_k(a_t, t, s) dt + \sigma_t dW_t, \quad a_0 \sim \mu_{\text{init}}. \quad (64)$$

在吉尔萨诺夫定理的标准绝对连续性假设下,

$$D_{\text{KL}}(P_\theta(\cdot | s) \| P_k(\cdot | s)) = \mathbb{E}_{\tau \sim P_\theta(\cdot | s)} \left[\int_0^1 \frac{\|f_\theta(a_t, t, s) - f_k(a_t, t, s)\|_2^2}{2\sigma_t^2} dt \right]. \quad (65)$$

由于两个路径测度共享相同的初始先验，因此不出现初始 KL 散度项。在网格 $0 = t_0 < \dots < t_N = 1$ 上的一阶离散化给出

$$\int_0^1 \frac{\|f_\theta(a_t, t, s) - f_k(a_t, t, s)\|_2^2}{2\sigma_t^2} dt \approx \sum_{n=0}^{N-1} \frac{\Delta t_n}{2\sigma(t_n)^2} \|f_\theta(a^{(n)}, t_n, s) - f_k(a^{(n)}, t_n, s)\|_2^2 \quad (66)$$

$$= C_{\text{path}}(\theta, \theta_k; s, \tau), \quad (67)$$

其中 $\Delta t_n = t_{n+1} - t_n > 0$ 。由此得到式 (22) 中的漂移-均方误差路径正则化项。

A.6 复合 KL 散度与混合锚点漂移惩罚

对于固定的 s ，将所有路径测度写为给定 s 的条件测度。令

$$\eta = \frac{\beta}{\alpha + \beta}, \quad (68)$$

$$P_\eta(\tau | s) = \frac{1}{Z_\eta(s)} P_k(\tau | s)^{1-\eta} P_{\text{ref}}(\tau | s)^\eta. \quad (69)$$

Then

$$\log P_\eta(\tau | s) = (1 - \eta) \log P_k(\tau | s) + \eta \log P_{\text{ref}}(\tau | s) - \log Z_\eta(s). \quad (70)$$

Therefore,

$$\alpha D_{\text{KL}}(P(\cdot | s) \| P_k(\cdot | s)) + \beta D_{\text{KL}}(P(\cdot | s) \| P_{\text{ref}}(\cdot | s)) \quad (71)$$

$$= (\alpha + \beta) \mathbb{E}_{\tau \sim P(\cdot | s)} [\log P(\tau | s) - (1 - \eta) \log P_k(\tau | s) - \eta \log P_{\text{ref}}(\tau | s)] \quad (72)$$

$$= (\alpha + \beta) \mathbb{E}_{\tau \sim P(\cdot | s)} \left[\log \frac{P(\tau | s)}{P_\eta(\tau | s)} \right] - (\alpha + \beta) \log Z_\eta(s) \quad (73)$$

$$= (\alpha + \beta) D_{\text{KL}}(P(\cdot | s) \| P_\eta(\cdot | s)) - (\alpha + \beta) \log Z_\eta(s). \quad (74)$$

对于固定的 s ， $Z_\eta(s)$ ，其独立于被优化的条件路径测度 $P(\cdot | s)$ 。由于镜像下降更新对固定的旧策略状态分布 d_k 取外层期望，归一化因子为固定 d_k 目标贡献了一个与策略无关的常数。

对于固定的路径样本和共享扩散系数，逐点加权漂移差异满足

$$\alpha \|f_\theta - f_k\|_2^2 + \beta \|f_\theta - f_{\text{ref}}\|_2^2 \quad (75)$$

$$= (\alpha + \beta) \left\| f_\theta - \frac{\alpha f_k + \beta f_{\text{ref}}}{\alpha + \beta} \right\|_2^2 + \frac{\alpha \beta}{\alpha + \beta} \|f_k - f_{\text{ref}}\|_2^2. \quad (76)$$

由此

$$f_\eta = (1 - \eta) f_k + \eta f_{\text{ref}}, \quad (77)$$

第一项给出混合锚点漂移惩罚。当漂移损失在固定采样路径上评估时，式 (76) 中的残差项不依赖于被优化的漂移 f_θ ，可在实用代理目标中省略。将所得漂移差异在 $0 = t_0 < \dots < t_N = 1$ 上离散化即得式 (28)。

B 实现细节

B.1 硬件配置

所有实验均在一台配备两个 AMD EPYC 7763 64 核处理器的服务器上运行。每个插槽包含 64 个物理核心，每个核心具有 2 个硬件线程，最多可提供 256 个逻辑 CPU。最大 CPU 频率约为 3.53 GHz。系统具有双节点 NUMA 拓扑结构，CPU 分布在两个插槽上。

对于 GPU 加速，我们使用了 8 个 NVIDIA A800 80GB PCIe GPU，每个 GPU 具有 80 GB 显存。GPU 使用 NVIDIA 驱动程序版本 570.211.01 和 CUDA 12.8 运行。实验期间禁用了多实例 GPU (MIG)。该机器配备 2.0 TiB 系统内存，运行 Ubuntu 24.04.3 LTS，Linux 内核版本为 6.8.0。

B.2 代码库与实验框架

我们的实验基于两个公开代码库实现。对于 Playground 实验，我们使用官方 FPO 仓库，其 playground/ 实现为 MuJoCo Playground 和 Brax 提供了基于 JAX 的训练流程 [30]。FPO 代码库已在同一 Playground 训练接口中支持 PPO、FPO 和 DPPO；DPPO 作为 FPO 训练脚本的一种模式实现。我们使用原始的 Playground 实现和超参数结构复现了这三个基线。此外，我们通过从 FlowRL 适配相应的 GenPO 实现逻辑，在同一 FPO Playground 流程中实现了 GenPO。我们的 GSB-MDPO 智能体被添加到同一流程中，因此所有 Playground 比较共享相同的环境接口、轨迹收集过程、训练循环和评估协议。

对于健身房的穆乔科 (Gym-MuJoCo) 实验，我们基于流强化学习 (FlowRL) 进行构建，这是一个模块化的 JAX 框架，用于具有扩散和流策略的强化学习 [13]。流强化学习提供了近端策略优化 (PPO)、去噪近端策略优化 (DPPO)、流策略优化 (FPO) 和生成策略优化 (GenPO) 的实现，以及用于扩散/流策略强化学习的标准化基础设施。原始的流强化学习代码库包括在线策略的艾萨克实验室 (IsaacLab) 启动脚本和离线策略的健身房-穆乔科启动脚本。由于我们的健身房-穆乔科比较是在线策略的，我们按照流强化学习的训练接口实现了一个额外的在线策略健身房-穆乔科启动器。我们还在这个基于流强化学习的健身房-穆乔科流程中实现了广义状态相关马尔可夫决策过程策略优化 (GSB-MDPO)。由于流策略优化游乐场 (FPO Playground) 与流强化学习/健身房-穆乔科之间的接口差异，游乐场和健身房-穆乔科的广义状态相关马尔可夫决策过程策略优化实现是分开维护的，但它们共享相同的核心算法逻辑：旧策略路径轨迹存储、当前路径似然重新计算、重要性采样的马尔可夫决策过程策略优化损失以及路径 KL 散度漂移正则化。

对于健身房-穆乔科，我们使用流强化学习中的艾萨克实验室在线策略配置作为网络架构和算法超参数的起点，因为健身房-穆乔科的运动任务在结构上与相应的艾萨克实验室运动任务相似。这包括策略和价值网络架构、优化器设置、轨迹/更新设置以及适用的生成策略参数。主要的系统性差异在于环境交互的总次数：流强化学习的艾萨克实验室设置使用 1 亿个环境步骤，并采用大规模并行的图形处理器 (GPU) 仿真，而我们的健身房-穆乔科实验使用 4000 万个步骤，因为健身房-穆乔科不支持相同规模的图形处理器并行环境交互。

B.3 超参数

对于每个基准，我们在所有任务中为每种方法使用单一的基准级超参数配置，而不进行任务特定的调整。该协议旨在使比较依赖于算法设计，而不是每个环境的超参数搜索。在健身房-穆乔科基准中，广义状态相关马尔可夫决策过程策略优化对策略/流优化器使用余弦学习率调度，从报告的初始学习率衰减到训练结束时的零。

游乐场。表 1 总结了游乐场实验中使用的超参数。近端策略优化、流策略优化和去噪近端策略优化的配置遵循流策略优化游乐场的设置 [30]；去噪近端策略优化通过流策略优化训练流程的去噪马尔可夫决策过程模式实现。生成策略优化和广义状态相关马尔可夫决策过程策略优化在相同的游乐场训练接口中实现，以进行公平比较。

健身房-穆乔科 (Gym-MuJoCo)。表 2 总结了健身房-穆乔科实验所用的超参数。对于每种方法，我们在全部六个健身房-穆乔科任务中使用单一超参数配置，不进行任务特定调优。健身房-穆乔科配置改编自流强化学习 (FlowRL) 风格的在线策略伊萨克实验室 (IsaacLab) 配置，并为我们的实验额外实现了在线策略健身房-穆乔科启动器。

表 1: 游乐场实验的超参数。每种方法在所有游乐场任务中使用单一配置。

Hyperparameter	PPO	DPPO	FPO	GenPO	GSB-MDPO
<i>Benchmark and rollout setup</i>					
Total environment steps	60M	60M	60M	60M	60M
Number of environments	2048	2048	2048	2048	2048
Episode length	1000	1000	1000	1000	1000
Number of evaluations	10	10	10	10	10
Unroll length	30	30	30	30	30
Batch size	1024	1024	1024	1024	1024
Number of minibatches	32	32	32	32	32
Updates per batch	16	16	16	16	16
Discount factor γ	0.995 [†]	0.995 [†]	0.995 [†]	0.995 [†]	0.995 [†]
GAE λ	0.95	0.95	0.95	0.95	0.95
Reward scaling	10.0	10.0	10.0	10.0	10.0
Normalize observations	Yes	Yes	Yes	Yes	Yes
Normalize advantages	Yes	Yes	Yes	Yes	Yes
Optimizer	Adam	Adam	Adam	Adam	Adam
<i>Actor configuration</i>					
Actor network	MLP, 4×32	MLP, 4×32	MLP, 4×32	MLP, 3×64	MLP, 4×32
Actor learning rate	3×10^{-4}	3×10^{-4}	3×10^{-4}	3×10^{-4}	1×10^{-3}
Entropy coefficient	0	0	0	0	0
PPO clip ϵ	0.1	0.2	0.05	0.2	–
<i>Critic configuration</i>					
Critic network	MLP, 5×256	MLP, 5×256	MLP, 5×256	MLP, 5×256	MLP, 5×256
Critic learning rate	3×10^{-4}	3×10^{-4}	3×10^{-4}	3×10^{-4}	1×10^{-3}
Value loss coefficient	0.25	0.25	0.25	1.0	0.1
<i>Generative-policy configuration</i>					
Generation steps	–	10	10	5	8
Time embedding dimension	–	8	8	32	8
Policy output scale	–	0.25	0.25	–	0.25
Sigma schedule	–	Constant	–	–	Exp.
$\sigma_{\max} / \sigma_{\min}$	–	0.05 / 0.05	–	–	3.0 / 1.0
<i>FPO-specific configuration</i>					
Samples per action	–	–	8	–	–
<i>GenPO-specific configuration</i>					
Flow mix parameter	–	–	–	0.9	–
Compress coefficient	–	–	–	0.01	–
<i>GSB-MDPO-specific configuration</i>					
Step log-ratio clip	–	–	–	–	0.1
Path log-ratio clip	–	–	–	–	0.3
KL penalty coefficient	–	–	–	–	0.8
Reference mix η	–	–	–	–	0.0

[†] 遵循快速策略优化 (FPO) 游乐场设置, $\gamma = 0.995$ 用于大多数任务; 接球入杯 (BallInCup) 和手指旋转 (FingerSpin) 使用 $\gamma = 0.95$ 。

表 2: 健身房-穆乔科实验的超参数。每种方法在所有健身房-穆乔科任务中使用单一配置。

Hyperparameter	PPO	DPPO	FPO	GenPO	GSB-MDPO
<i>Benchmark and rollout setup</i>					
Total environment steps	40M	40M	40M	40M	40M
Evaluation interval	1M	1M	1M	1M	1M
Evaluation episodes	10	10	10	10	10
Number of environments	1024	1024	1024	1024	1024
Rollout length	24	24	24	24	24
Batch size	6144	6144	6144	6144 [‡]	6144
Number of minibatches	4	4	4	4 [‡]	4
Training epochs	4	4	4	4	4
Discount factor γ	0.99	0.99	0.99	0.99	0.99
GAE λ	0.95	0.95	0.95	0.95	0.95
Reward scaling	1.0	1.0	1.0	1.0	1.0
Normalize observations	Yes	Yes	Yes	Yes	Yes
Normalize advantages	Yes	Yes	Yes	Yes	Yes
Gradient clip norm	1.0	1.0	1.0	1.0	1.0
<i>Actor configuration</i>					
Actor network	MLP, 3×256	MLP, 3×256	MLP, 3×256	MLP, 3×256	MLP, 3×256
Actor activation	ELU	SiLU	SiLU	SiLU	SiLU
Actor learning rate	1×10^{-4}	1×10^{-3}	1×10^{-4}	1×10^{-3}	7.5×10^{-4}
PPO clip ϵ	0.2	0.2	0.05	0.2	–
Entropy coefficient	0	–	–	0.0	–
<i>Critic configuration</i>					
Critic network	MLP, 3×256	MLP, 3×256	MLP, 3×256	MLP, 3×256	MLP, 3×256
Critic activation	ELU	ELU	ELU	ELU	ELU
Critic learning rate	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}	1×10^{-3}
<i>Generative-policy configuration</i>					
Generation steps	–	10	10	16	16
Flow / diffusion hidden dims	–	3×256	3×256	3×256	3×256
Time embedding dimension	–	32	16	16	16
Flow / diffusion output scale	–	–	0.25	0.25	0.25
Noise schedule	–	Cosine DDPM	–	–	Linear
Min log-prob std.	–	0.1	–	–	–
$\sigma_{\max} / \sigma_{\min}$	–	–	–	–	3.0 / 0.3
<i>FPO-specific configuration</i>					
Monte Carlo samples	–	–	8	–	–
Additive noise	–	–	0.1	–	–
<i>GenPO-specific configuration</i>					
Flow mix parameter	–	–	–	0.9	–
Compress coefficient	–	–	–	0.01	–
<i>GSB-MDPO-specific configuration</i>					
Step log-ratio clip	–	–	–	–	0.1
Path log-ratio clip	–	–	–	–	0.4
KL penalty coefficient	–	–	–	–	0.08
Reference mix η	–	–	–	–	0.02

[‡] 仅针对人形机器人-v5 (Humanoid-v5) 上的生成式策略优化 (GenPO), 由于图形处理器 (GPU) 内存限制, 我们使用批大小 4096 和 6 个小批量。所有其他生成式策略优化健身房-穆乔科任务使用默认批大小 6144 和 4 个小批量。

C 附加实验结果

C.1 最优路径空间更新的玩具分析

我们引入一个受控的二维玩具示例，以可视化命题 3 中的闭式优化器。旧策略 p_{old} 是终端动作 (x_1, x_2) 上的四模态高斯混合分布。我们定义象限偏好 $A(x)$ ，并构造指数倾斜目标

$$p^*(x) \propto p_{\text{old}}(x) \exp\left(\frac{A(x)}{\beta}\right), \quad (78)$$

该目标是由最优路径空间镜像下降更新所隐含的终端边。偏好赋予第三象限最大的权重，而其他象限的权重较小，因此最优更新应增加第三象限的概率质量，同时保留从旧策略继承的局部模态结构。




图 5: 最优 GSB-MDPO 更新的玩具可视化。左: 具有四个近似平衡模态的旧策略 p_{old} 。中: 象限偏好权重 $\exp(A/\beta)$ 。右: 目标指数倾斜边 p^* 与学习到的分布 p_θ 。学习到的策略与理论倾斜目标高度吻合，在偏好象限中增加质量，同时保留旧策略的模态结构。

图 5 证实了命题 3 所预测的行为。指数倾斜根据终端偏好改变模态的相对质量，同时在理想解中保持条件路径结构不变。在学习到的分布中，象限质量与目标分布高度吻合，象限质量 ℓ_1 误差为 0.100。这表明 GSB-MDPO 实现了预期的镜像下降更新：它并非简单地坍塌到最高奖励模态，而是根据优势诱导的指数倾斜对旧生成策略进行重新加权。

C.2 步骤对数比裁剪分析

为了更好地理解步骤级裁剪的作用，我们记录训练期间步骤对数比超过裁剪阈值的轨迹样本比例。图 6 报告了在 HalfCheetah-v5 上完整 GSB-MDPO 基线的这一诊断指标，取两个随机种子的平均值。

裁剪比例在训练初期迅速上升，随后在大部分优化过程中稳定在约 0.2。这一行为表明，步骤级裁剪既不是极少触发的边缘情况，也不是完全主导学习的机制。相反，它作为重要性采样路径比估计器的持续稳定器，尤其是在当前策略偏离旧策略的时期。

该诊断还有助于阐明裁剪在 GSB-MDPO 中的作用。路径 KL 漂移正则化项是镜像下降目标本身的一部分，而步进对数比率裁剪是一种实现手段，用于控制累积路径似然比的方差。图 6 中观察到的适中且稳定的裁剪频率表明，该机制在实践中足够频繁地发挥作用，同时仍使大多数步进似然比处于未裁剪范围内。




图 6: 在 HalfCheetah-v5 上 GSB-MDPO 训练期间, 步进对数比率被裁剪的轨迹样本比例。结果在两个随机种子上取平均, 阴影区域表示种子间的变异性。

C.3 计算效率

我们在表 3 中报告了 HalfCheetah-v5 上的代表性计算成本。所有方法均使用种子 0 进行 5M 环境交互, 硬件配置与附录 B.1 相同。报告的墙钟时间是端到端训练时间, GPU 内存从训练期间的进程树中测量。该实验旨在进行轻量级效率比较, 而非全面的基准剖析研究。

表 3: HalfCheetah-v5 上 5M 环境交互的代表性计算成本。墙钟时间为端到端训练时间。GPU 内存从训练进程树中测量。

方法	墙钟时间	相对时间	峰值 GPU 内存	平均 GPU 内存
PPO	6.24 min	1.00×	0.60 GB	0.59 GB
FPO	6.96 min	1.12×	1.00 GB	0.97 GB
DPPO	8.67 min	1.39×	2.50 GB	2.38 GB
GenPO	28.73 min	4.61×	64.98 GB	64.13 GB
GSB-MDPO	7.39 min	1.19×	2.59 GB	2.51 GB

与高斯 PPO 相比, GSB-MDPO 由于存储去噪路径以及在策略更新期间重新计算当前路径似然和漂移而增加了适度的开销。然而, 在此代表性设置中, 其端到端运行时间仍接近 FPO 且低于 DPPO。其 GPU 内存占用与 DPPO 相当, 且显著低于 GenPO, 后者在此 HalfCheetah-v5 运行中实现所需内存要大得多。这些结果表明, 相对于其他多步生成式策略基线, 路径空间目标可以以实用的开销实现。