

## 用于少步视觉导航的整流薛定谔桥匹配

Wuyang Luan, Junhui Li, Weiguang Zhao, Wenjian Zhang, Tieru Wu<sup>†</sup>, and Rui Ma<sup>†</sup>

**摘要**——从单目图像流进行视觉导航，要求智能体将高维视觉观测转换为连续、长时域的动作轨迹。基于扩散模型和薛定谔桥（Schrödinger Bridge）的生成策略能够忠实建模多模态动作分布，但由于高方差随机传输，它们需要数十个积分步骤。本文提出整流薛定谔桥匹配（Rectified Schrödinger Bridge Matching, RSBM），这是一种视觉条件轨迹生成框架，利用标准薛定谔桥（ $\varepsilon=1$ ）与确定性最优传输（ $\varepsilon\rightarrow 0$ ）之间共享的速度场结构，该结构由单一熵正则化参数  $\varepsilon$  控制。本文证明两个理论结果：（1）条件速度场在整个  $\varepsilon$  谱上保持相同的函数形式，因此一个网络参数化即可适用于所有正则化强度；（2）减小  $\varepsilon$  会线性降低条件速度方差，从而提高粗步长常微分方程积分的稳定性。RSBM 锚定于一个缩短传输距离的学习条件先验，仅需 3 个积分步骤即可实现超过 94% 的余弦相似度和 92% 的成功率，无需蒸馏或多阶段训练，显著缩小了高保真生成策略与实时多媒体系统之间的差距。

**索引词**——视觉导航，单目图像流，视觉轨迹生成，薛定谔桥，流匹配，扩散模型，少步推理，最优传输。

## 1. 引言

V 视觉导航是智能多媒体系统中一个基本的感知与决策问题。智能体必须解读流式视觉观测，随时间保持场景语义，并将其转化为可靠的动作轨迹。近期由去噪扩散概率模型（Denoising Diffusion Probabilistic Models, DDPMs）驱动的生成式策略在该场景下展现出相较于确定性回归的明显优势，因为它们能够忠实表征视觉模糊条件下未来动作的多模态特性。当同一观测存在多个有效延续时，确定性回归器会跨模态取平均并产生不可行的轨迹，而基于扩散的策略则保持不同模态并生成物理上合理的规划。尽管具备这些表征优势，在实时多媒体系统中部署基于扩散的策略

在推理延迟方面提出了一个关键的实用挑战。标准扩散模型和薛定谔桥（Schrödinger Bridges, SB）构建从噪声到数据的高方差布朗传输路径，需要数十次迭代去噪步骤才能准确恢复轨迹。对于视觉驱动的导航，轨迹预测必须在严格的响应预算下基于连续视觉感知运行，这种计算开销是难以承受的。现有的加速策略，包括跳步调度、知识蒸馏和渐进式训练，可以减少函数评估次数，但通常会牺牲轨迹保真度或需要昂贵的多阶段流程。另一条研究路线解决初始化问题。与从无信息的各向同性高斯噪声开始不同，先验条件方法（如 NaviBridger）将生成过程锚定到学习到的运动先验上，从而缩短有效传输距离并改善收敛性。然而，即使有良好的先验，底层布朗桥在传输区间内部仍表现出高路径曲率和高方差，限制了在极低步数下可达到的质量。为了同时应对这两个挑战，我们提出了整流薛定谔桥匹配（Rectified Schrödinger Bridge Matching, RSBM）。我们的核心洞见是，具有  $\varepsilon=1$  的标准 SB 和条件流匹配（Conditional Flow Matching）中具有  $\varepsilon\rightarrow 0$  的线性插值器是同一熵正则化谱的两个端点。通过在桥核中引入  $\varepsilon\in(0,1]$ ，RSBM 在最大熵随机传输和确定性最优传输之间提供了连续插值。我们证明了条件速度场在整个  $\varepsilon$  族中保持相同的函数形式（定理 1），并且减小  $\varepsilon$  会线性降低速度方差（命题 1）。结合缩短传输距离的学习条件先验，这些特性使 RSBM 能够在仅 3 个 ODE 步骤内生成高保真轨迹，同时保留多模态行为。总之，我们的主要贡献如下：

- **连续的 SB - FM 插值：**我们证明， $\varepsilon$  参数化的桥核构成了从最大熵薛定谔桥到确定性最优传输的连续谱，并证明条件速度场在该谱上具有结构不变性（定理 1），从而支持共享网络参数化。

- **具有理论保证的方差缩减：**我们证明  $\varepsilon$  整流线性地降低条件速度方差（命题 1），并在第四节中给出基于薛定谔桥理论的完整推导。

<sup>†</sup> 通讯作者（电子邮箱：wutr@jlu.edu.cn; ruim@jlu.edu.cn）。

栾文宇、吴天瑞和马锐就职于吉林大学人工智能学院，

中国长春，邮编 130012（电子邮箱：luanwy25@mails.jlu.edu.cn）。

李俊辉就职于重庆大学计算机学院，

中国重庆，邮编 400044（电子邮箱：junhui@stu.cqu.edu.cn）。

赵伟光就职于利物浦大学计算机科学系，

英国利物浦，邮编 L69 3BX（电子邮箱：weiguang.zhao@liverpool.ac.uk）。

张伟文任职于长春格恩西科技有限公司，位于长春，

中国（电子邮箱：zhangwenjian@genycc.cn）。




图 1. 两条玩具轨迹（星形巡逻和 8 字形环路）上的去噪过程。在  $t=T$  时，所有方法都从无结构点云开始（DDPM/FM 为高斯噪声；NaviBridger/RSBM 为学习先验）。到  $k=2$ （NFE=3）时，只有 RSBM 与真值接近，而基线方法需要  $k \geq 10$  才能收敛。在  $k=30$ （NFE=59）时，所有方法均已收敛，证实了表 III 中的定量趋势。

- **单阶段少步性能：** RSBM 在  $k=3$  处实现了比 NaviBridger 低  $6.3\times$  的均方误差，并以  $3.8\times$  更少的函数评估次数达到了其  $k=10$  准确率，且无需像 [1]、[2] 中那样进行蒸馏或多阶段训练。

## II. 相关工作

**视觉导航的生成式策略。** 视觉导航已从经典模块化流水线 [3]、[4] 以及基于强化学习 [5]、[6] 或行为克隆 [7]、[8] 的端到端方法，演进为生成式策略。基础模型如 ViNT[9] 展现出强大的样本效率，而高斯泼溅（Gaussian Splatting）[10]、[11] 等三维表示则改善了空间锚定。然而，确定性规划器在多模态环境中面临困难，因为对多个不同有效模式取平均会产生不可行的规划 [12]、[13]。基于分数的扩散模型和流匹配模型 [14]–[18] 通过捕捉多模态动作分布来解决这一问题；NoMaD[19] 是最早将扩散应用于导航的方法之一。一个关键局限仍然存在：从各向同性高斯噪声 [20]、[21] 初始化需要较长的逆向过程，限制了实时部署。扩散桥与流匹配。扩散桥 [22] 通过杜布  $h$  变换 [24] 推广了端点条件过程 [23]，并扩展至离散时间 [25] 和连续时间形式 [26]。最近的薛定谔桥匹配方法 [27]、[28] 无需迭代仿真即可学习桥；轻量最优薛定谔桥匹配 [29] 和对抗薛定谔桥匹配 [30] 进一步提升了训练效率。在导航中，NaviBridger[31] 从学习到的运动先验初始化扩散桥，NaviD[32] 利用深度约束，FlowNav[33] 将条件流匹配与深度先验结合，StepNav[34] 在线构建几何感知先验。然而，标准桥形式在时间边界附近表现出病态动力学，在少步机制中引入截断误差 [35]、[36]。本文方法通过单个  $\varepsilon$  参数显式约束桥方差来解决这一问题，从而产生更稳定的传输动力学。路径拉直与加速采样。修正流（Rectified Flow）[2] 通过迭代回流拉直常微分方程轨迹：

一致性模型（Consistency Models）[1] 将预训练扩散模型蒸馏为少步生成器。两者都需要多阶段训练。RSBM 通过从信息先验进行显式方差控制，在单阶段实现路径拉直，并在中间  $\varepsilon$  保留多模态覆盖。

## III. 方法

如图 2 所示，本文框架由三个紧密耦合的组件构成。双流视觉编码器  $f_\phi$  将流式观测与目标图像压缩为上下文向量  $\mathbf{c}$ （第 III-A 节）。学习到的变分先验网络  $g_\psi$  随后将  $\mathbf{c}$  映射为粗略动作初始化  $\mathbf{a}_T$ （第 III-A 节）。最后，条件速度网络  $\mathbf{v}_\theta$  驱动  $\varepsilon$  校正薛定谔桥，在最少 3 个常微分方程步骤内逐步将  $\mathbf{a}_T$  细化为输出轨迹  $\mathbf{a}_0$ （第 III-B 至 III-D 节）。

### A. 视觉导航问题表述

本文将视觉导航表述为条件生成建模问题。在每个决策步骤，智能体接收单目 RGB 图像的流式观测序列  $\mathcal{O} = \{I_{t-C}, \dots, I_t\}$  和目标图像  $I_g$ ，并必须生成动作轨迹  $\mathbf{a}_0 \in \mathbb{R}^{H \times 2}$ ，该轨迹表示局部坐标系中  $H$  个未来航点。感知编码器将视觉输入映射为紧凑的上下文向量：

$$\mathbf{c} = f_\phi(\mathcal{O}, I_g) \in \mathbb{R}^d \quad (1)$$

本文不从无信息的高斯噪声生成  $\mathbf{a}_0$ （该方案通常需要大量去噪步骤），而是将生成过程锚定于信息丰富的条件先验。学习到的变分先验网络生成结构化初始化  $\mathbf{a}_T$ ，粗略捕捉导航意图：

$$\mathbf{a}_T = g_\psi(\mathbf{z}, \mathbf{c}), \quad \mathbf{z} \sim q_\psi(\mathbf{z} | \mathbf{c}, \mathbf{a}_0) \text{ (train)} / \mathcal{N}(\mathbf{0}, \mathbf{I}) \text{ (test)} \quad (2)$$

该先验  $\mathbf{a}_T$  作为扩散桥的终端边界条件 ( $t=T$ ：模型仅需学习从粗略先验到精确真值轨迹的残差细化，从而显著缩短有效传输距离。




图 2. RSBM 框架概览。左：双流 EfficientNet-B0 视觉编码器  $f_\phi$ （第 III-A 节）提取观测与目标特征，通过位置编码和自注意力融合为上下文向量  $c \in \mathbb{R}^{256}$ 。中：学习到的变分先验网络  $g_\psi$ （第 III-A 节）生成粗略动作先验  $a_T$ 。右：带 FiLM 条件化的条件 U-Net—速度网络  $v_\theta$ （第 III-C 节）通过  $\epsilon$  校正薛定谔桥（第 III-B 至 III-D 节）迭代细化  $a_T$  为输出轨迹  $a_0$ 。三个轨迹快照展示了逐步细化过程：从分散的先验航点（绿色），经过部分收敛的中间状态（橙色），到最终高保真轨迹（红色），与真值（灰色虚线）紧密匹配。

B.  $\epsilon$ -修正的条件桥核函数 标准扩散桥模型在  $a_0$  与  $a_T$  之间构建布朗桥，其方差为  $\sigma_t^2 = t^2(1 - t^2/\sigma_{\max}^2)$ 。这些高方差的随机路径使中间状态相互纠缠，并需要大量积分步骤才能准确恢复。为修正此问题，本文引入一个结构正则化参数  $\epsilon \in (0, 1]$ ，以显式控制路径几何。本文修正桥的前向转移核函数为：

$$q_\epsilon(a_t | a_0, a_T) = \mathcal{N}(\mu_t, \sigma_{\epsilon,t}^2 \mathbf{I}) \quad (3)$$

其中均值在数据与先验之间无缝插值：

$$\mu_t = s_t a_T + (1 - s_t) a_0, \quad s_t = \frac{t^2}{\sigma_{\max}^2} \quad (4)$$

且方差按  $\epsilon$  缩放，以强制轨迹平直：

$$\sigma_{\epsilon,t}^2 = \epsilon \cdot t^2(1 - s_t) \quad (5)$$

**边界条件。** 对于任意  $\epsilon \in (0, 1]$ ，有  $\sigma_{\epsilon,0}^2 = 0$ （精确数据恢复  $\sigma_{\max} = 0$  复）和  $\sigma^2$ （精确先验匹配），确保桥正确固定两个端点。几何解释。设置  $\epsilon = 1$  可恢复标准布朗桥。当  $\epsilon \rightarrow 0$  时，核函数坍缩为  $\delta(a_t - \mu_t)$ ，即蒙日-坎塔罗维奇最优传输的确定性位移插值。中间值在随机多样性与路径平直性之间平滑权衡。该公式基于熵正则化最优传输；由随机最优控制原理的完整推导见第四节。

### C. 条件速度场与流匹配目标

为实现可扩展训练，本文推导修正桥的条件速度场，并构建一个免模拟的流匹配目标。利用重参数化  $a_t = \mu_t + \sigma_{\epsilon,t} \epsilon$ ，其中  $\epsilon \sim \mathcal{N}(0, \mathbf{I})$ ，目标速度为：

$$\mathbf{v}_t^*(a_t | a_0, a_T) = \frac{d\mu_t}{dt} + \frac{d \log \sigma_{\epsilon,t}}{dt} (a_t - \mu_t) \quad (6)$$

Computing the key derivatives (complete algebra in Section IV-F):

$$\frac{d\mu_t}{dt} = \frac{2t}{\sigma_{\max}^2} (a_T - a_0) \quad (7)$$

$$\frac{d \log \sigma_{\epsilon,t}}{dt} = \frac{1 - 2s_t}{t(1 - s_t)} \quad (8)$$

**定理 1**（速度结构不变性）。对于  $\epsilon$ -整流桥族  $\{q_\epsilon\}_{\epsilon \in (0,1]}$ （式 3），标准差的对数导数满足  $d \log \sigma_{\epsilon,t}/dt = (1 - 2s_t)/[t(1 - s_t)]$ ，该导数与  $\epsilon$  无关。因此，条件速度  $\mathbf{v}_t^*$ （式 6）的函数形式在整个  $\epsilon$ -谱上保持不变：单一速度网络参数化对所有  $\epsilon \in (0, 1]$  均有效。证明：由于  $\sigma_{\epsilon,t} = \sqrt{\epsilon} t \sqrt{1 - s_t}$ ，导数为  $d \sigma_{\epsilon,t}/dt = \sqrt{\epsilon} (1 - 2s_t)/\sqrt{1 - s_t}$ 。其比值为  $d \sigma_{\epsilon,t}/dt$ ，其中  $\sqrt{\epsilon}$  恰好抵消。完整推导见第 IV-F 节。

$$\sigma_{\epsilon,t} = \frac{1 - 2s_t}{t(1 - s_t)}, \quad \square$$

定理 1 表明，SB（ $\epsilon = 1$ ）与 FM（ $\epsilon \rightarrow 0$ ）具有相同的条件速度泛函形式： $\mathbf{v}_t^*(a_t)$ （式 6）。控制决策采样时保持速度场的结构不变。在实际中， $\epsilon$  充当

空间支撑收缩器，当  $\varepsilon < 1$  时产生一个更低方差的学习问题（命题 1）。我们参数化一个神经速度网络  $\mathbf{v}_\theta$ ，实现为条件 U-Net 1D，并通过 FiLM 对  $\mathbf{c}$  进行条件化，并通过无仿真的条件流匹配损失进行训练：

$$\mathcal{L}_{\text{RSBM}} = \mathbb{E}_{t, \mathbf{a}_0, \mathbf{a}_T, \epsilon} \left[ \|\mathbf{v}_\theta(\mathbf{a}_t, t, \mathbf{c}) - \mathbf{v}_t^*\|^2 \right] \quad (9)$$

关键的是， $\mathbf{v}$  预测直接参数化了常微分方程速度场，避免了  $x_0$  预测方法所需的分数到漂移的转换。我们通过实验证明，这在  $k = 3$  处将误差降低了 35.6%；详见第 V-E 节。

## D. 少步常微分方程推理与误差分析

在推理阶段，通过求解从  $\mathbf{a}_T$  到  $\mathbf{a}_0$  的概率流常微分方程（Probability Flow ODE）生成动作轨迹：

$$d\mathbf{a}_t = \mathbf{v}_\theta(\mathbf{a}_t, t, \mathbf{c}) dt \quad (10)$$

使用二阶休恩求解器在卡拉斯时间步上时间表  $\{t_0 > t_1 > \dots > t_k = 0\}$ ：

$$\begin{aligned} \mathbf{d}_1 &= \mathbf{v}_\theta(\mathbf{a}_{t_i}, t_i, \mathbf{c}), \quad \tilde{\mathbf{a}}_{t_{i+1}} = \mathbf{a}_{t_i} + \mathbf{d}_1(t_{i+1} - t_i) \\ \mathbf{d}_2 &= \mathbf{v}_\theta(\tilde{\mathbf{a}}_{t_{i+1}}, t_{i+1}, \mathbf{c}), \quad \mathbf{a}_{t_{i+1}} = \mathbf{a}_{t_i} + \frac{1}{2}(\mathbf{d}_1 + \mathbf{d}_2)(t_{i+1} - t_i) \end{aligned} \quad (11)$$

$$(12)$$

每一步需要两次函数评估；一步的最终评估被复用为下一步的首次评估（FSAL），因此对于  $k$  步，NFE 为  $2k - 1$ 。为什么  $\varepsilon < 1$  能实现更少的步数？本文通过以下结果对此进行形式化。

**命题 1**（速度方差缩减）。对于修正桥核函数  $q_\varepsilon$ （式 3），目标速度场的条件方差满足：

$$\text{Var}[\mathbf{v}_t^* | \mathbf{a}_0, \mathbf{a}_T] = \varepsilon \cdot \frac{(1 - 2s_t)^2}{1 - s_t} \cdot \mathbf{I}_D \quad (13)$$

其中  $D = 2H$  表示展平后的轨迹维度。特别地，线性减小  $\varepsilon$  可降低速度场在训练分布上的随机波动。

证明。由式 (6)， $\mathbf{v}_t^*$  的随机分量为， $\frac{d \log \sigma_{\varepsilon, t}}{dt} \cdot \sigma_{\varepsilon, t} \boldsymbol{\epsilon}$  其中  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 。每个分量 variance is  $\left( \frac{d \log \sigma_{\varepsilon, t}}{dt} \right)^2 \cdot \sigma_{\varepsilon, t}^2$ 。Substituting Eqs. (5) and (8):  $\frac{(1-2s_t)^2}{t^2(1-s_t)^2} \cdot \varepsilon t^2(1-s_t) = \varepsilon \cdot \frac{(1-2s_t)^2}{1-s_t}$ 。□

命题 1 具有两个实用启示。首先，较低的速度方差意味着训练目标在桥支撑上的变化较小，使网络在相同容量下能够达到更好的逼近质量。其次，在实践中，较小的

$\varepsilon$  使轨迹更接近插值

$\mu_t$ ，产生曲率较低的路径，这些路径更容易用有限步求解器进行积分。第 IV-H 节给出了相应的采样误差分解及其与

$\varepsilon$  的直接联系。

## 四、理论分析

本节推导了连接随机最优控制、薛定谔桥（Schrödinger Bridge）与本文  $\varepsilon$  校正公式的理论基础。

## A. 生成建模作为随机最优控制

本文将轨迹生成建模为随机最优控制（Stochastic Optimal Control）问题。目标是寻找最优控制  $u_t$ ，将基础分布引导至结构化先验，同时最小化路径代价：

$$\min_u \mathbb{E}_{X \sim p^u} \left[ \int_0^1 \frac{1}{2} \|u_t(X_t)\|^2 dt + g(X_1) \right] \quad (14)$$

$$\text{s.t. } dX_t = (f_t(X_t) + \sigma_t u_t(X_t)) dt + \sigma_t dW_t \quad (15)$$

其中  $X_0 \sim p_{\text{data}}$ 。根据哈密顿-雅可比-贝尔曼方程，最优控制满足  $u_t^*(x) = -\sigma_t \nabla V_t(x)$ ，其中  $V_t$  为值函数。在无记忆松弛下，终端代价简化为  $g(x) = \log(p_{\text{base}}^1(x)/p_{\text{prior}}(x))$ ，从而将随机最优控制与熵正则化传输联系起来。

## B. 与薛定谔桥的对偶性

薛定谔桥框架将该随机最优控制问题重新表述为熵正则化最优传输。在薛定谔桥最优性下，动力学由耦合的薛定谔势  $\phi_t$  和  $\hat{\phi}_t$  控制，并通过霍普夫-科尔变换  $\phi_t(x) = \exp(-V_t(x))$  与随机最优控制统一。所得条件桥分布为高斯分布：

$$q(X_t | X_0, X_1) = \mathcal{N}((1-s_t)X_0 + s_tX_1, t^2(1-s_t)\mathbf{I}) \quad (16)$$

其中  $s_t = t^2/\sigma_{\text{max}}^2$ 。方差  $t^2(1-s_t)$  控制随机传输的扩散性：它在两端点处消失（精确钉扎），在中点处达到峰值，此时传输最为弥散。这启发了本文的  $\varepsilon$  校正方法，直接对该方差进行缩放。

## C. 与 $\varepsilon$ 校正核函数的联系

基于第 IV-B 节推导的桥核，我们的  $\varepsilon$  校正将方差  $t^2(1-s_t)$  替换为：

$$\sigma_{\varepsilon, t}^2 = \varepsilon \cdot t^2(1-s_t), \quad \varepsilon \in (0, 1] \quad (17)$$

这调节了薛定谔桥 [37] 的熵正则化强度。具体而言，具有熵代价  $\gamma \text{KL}(p \| p_{\text{ref}})$  的薛定谔桥问题产生由  $\gamma$  索引的解族；我们的  $\varepsilon$  所起的作用类似于  $\gamma/\gamma_0$ ，其中  $\gamma_0$  是参考正则化。这两个极端之间进行插值：

- $\varepsilon = 1$ ：标准布朗桥（最大熵，完全随机传输）。
- $\varepsilon \rightarrow 0$ ：确定性位移插值  $\mu_t$ （最小熵，蒙日最优传输映射）。

通过选择  $\varepsilon \in (0, 1)$ ，我们保留了桥结构和边界条件，同时将概率质量集中在连接  $\mathbf{a}_0$  和  $\mathbf{a}_T$  的测地线附近。这为在生成多样性与路径平直性之间进行权衡提供了一种原则性机制。

1) *Formal KL Divergence Connection:* We now rigorize the entropic regularization interpretation. Consider the Schrödinger Bridge problem with regularization strength  $\gamma > 0$ :

$$\min_{p \in \mathcal{P}(\Omega)} \int c(\omega) dp(\omega) + \gamma \text{KL}(p \| p_{\text{ref}}) \quad (18)$$

where  $c(\omega) = \frac{1}{2} \int_0^T \|u_t\|^2 dt$  is the kinetic energy cost,  $p_{\text{ref}}$  is the Brownian Bridge reference, and  $\Omega$  is the path space. The solution satisfies  $p^* \propto p_{\text{ref}} \cdot \exp(-c/\gamma)$ , with conditional kernel:

$$p^*(\mathbf{a}_t | \mathbf{a}_0, \mathbf{a}_T) = \mathcal{N}\left(\boldsymbol{\mu}_t, \frac{\gamma}{\gamma_0} t^2(1-s_t) \mathbf{I}\right) \quad (19)$$

where  $\gamma_0$  is the reference regularization yielding unit bridge variance. Identifying  $\varepsilon = \gamma/\gamma_0$ , we obtain  $\sigma_{\varepsilon,t}^2 = \varepsilon \cdot t^2(1-s_t)$ , recovering Eq. (17). The KL cost between the  $\varepsilon$ -rectified and standard bridges admits a closed form:

$$\begin{aligned} \text{KL}(q_\varepsilon(\mathbf{a}_t | \mathbf{a}_0, \mathbf{a}_T) \| q_1(\mathbf{a}_t | \mathbf{a}_0, \mathbf{a}_T)) \\ = \frac{D}{2} (\varepsilon - 1 - \log \varepsilon) \end{aligned} \quad (20)$$

其中  $D$  是动作空间维度。对于  $\varepsilon \neq 1$ ，该值严格非负，并随着  $\varepsilon \rightarrow 0$  而单调增加，量化了校正的信息代价。对于我们的默认  $\varepsilon = 0.5$ ，其中  $D = 16$ （8 个路径点  $\times$  2 个维度）， $\text{KL} = 8 \times (0.5 - 1 - \log 0.5) = 1.55$  纳特，这是一个适中的代价，它显著降低了传输曲率，同时保留了足够的多模态生成随机性。边界条件  $\sigma_{\varepsilon,0}^2 = \sigma_{\varepsilon,\sigma_{\text{max}}}^2 = 0$  对任意  $\varepsilon > 0$  均成立，确保端点精确固定（见 III-B 节）。

## D. 概率流常微分方程推导

保持边缘分布的概率流常微分方程 [38] 用确定性流替代随机动力学。对于我们的  $\varepsilon$  校正桥，代入条件得分  $\nabla_{\mathbf{a}_t} \log p(\mathbf{a}_t | \mathbf{a}_0, \mathbf{a}_T) = -(\mathbf{a}_t - \boldsymbol{\mu}_t)/\sigma_{\varepsilon,t}^2$  即可得到式 (6) 中的速度场。由于  $d \log \sigma_{\varepsilon,t}/dt$  与  $\varepsilon$  无关（第 IV-F 节），相同的函数形式适用于所有  $\varepsilon$ ；仅训练输入分布发生变化。推理通过 Heun 方法以  $k$  步（函数评估次数  $= 2k-1$ ）进行反向积分。

*E. v 预测：* 信噪比分析 速度场  $\mathbf{v}_t^*$  允许三种重参数化。 $\varepsilon$ -预测预测噪声  $\hat{\varepsilon}$ ；在  $t \approx 0$  附近，小误差会被放大。 $x_0$  预测预测  $\hat{\mathbf{a}}_0$ ；在  $t \approx \sigma_{\text{max}}$  附近，信噪比较低。 $v$  预测（本文方法）直接预测速度，自然地平衡漂移项和随机项：

$$\text{SNR}_v(t) = \frac{\|d\boldsymbol{\mu}_t/dt\|^2}{\varepsilon(1-2s_t)^2/(1-s_t)} \quad (21)$$

该比值在  $t \in (0, \sigma_{\text{max}})$  范围内表现良好，避免了两种替代方案的边界奇异性，并直接最小化常微分方程积分误差。

## Algorithm 1: RSBM Training

**Input:** Dataset  $\mathcal{D}$ ,  $\sigma_{\text{max}}$ ,  $\varepsilon$ , learning rate  $\eta$

**repeat**

1. Sample  $(\mathcal{O}, I_g, \mathbf{a}_0) \sim \mathcal{D}$ ;  $\mathbf{c} = f_\phi(\mathcal{O}, I_g)$
2.  $\mathbf{a}_T = g_\psi(\mathbf{c}, \mathbf{z})$ ,  $\mathbf{z} \sim q_\psi(\mathbf{z} | \mathbf{c}, \mathbf{a}_0)$ ;  $t \sim \mathcal{U}(\sigma_{\text{min}}, \sigma_{\text{max}})$
3.  $s_t = t^2/\sigma_{\text{max}}^2$ ;  $\boldsymbol{\mu}_t = (1-s_t)\mathbf{a}_0 + s_t\mathbf{a}_T$
4.  $\mathbf{a}_t = \boldsymbol{\mu}_t + \sqrt{\varepsilon} t \sqrt{1-s_t} \boldsymbol{\epsilon}$ ,  $\boldsymbol{\epsilon} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
5.  $\mathbf{v}_t^* = \frac{2t}{\sigma_{\text{max}}^2}(\mathbf{a}_T - \mathbf{a}_0) + \frac{1-2s_t}{t(1-s_t)}(\mathbf{a}_t - \boldsymbol{\mu}_t)$
6.  $(\phi, \psi, \theta) \leftarrow (\phi, \psi, \theta) - \eta \nabla[\|\mathbf{v}_\theta(\mathbf{a}_t, t, \mathbf{c}) - \mathbf{v}_t^*\|^2 + \mathcal{L}_{\text{prior}}]$

**until** converged

## Algorithm 2: RSBM Inference

**Input:**  $\mathcal{O}$ ,  $I_g$ , networks  $(f_\phi, g_\psi, \mathbf{v}_\theta)$ , steps  $k$

1.  $\mathbf{c} = f_\phi(\mathcal{O}, I_g)$ ;  $\mathbf{a}_{t_0} = g_\psi(\mathbf{c}, \mathbf{z})$ ,  $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
2. **for**  $i = 0, \dots, k-1$ : Heun step with  $\mathbf{v}_\theta$
- $\mathbf{d}_1 = \mathbf{v}_\theta(\mathbf{a}_{t_i}, t_i, \mathbf{c})$ ;  $\tilde{\mathbf{a}} = \mathbf{a}_{t_i} - \Delta t \cdot \mathbf{d}_1$
- $\mathbf{d}_2 = \mathbf{v}_\theta(\tilde{\mathbf{a}}, t_{i+1}, \mathbf{c})$ ;  $\mathbf{a}_{t_{i+1}} = \mathbf{a}_{t_i} - \frac{\Delta t}{2}(\mathbf{d}_1 + \mathbf{d}_2)$
3. **return**  $\hat{\mathbf{a}}_0 = \mathbf{a}_{t_k}$  (NFE =  $2k-1$ )

## F. 完整速度场推导

四步推导（均值导数、标准差导数、带  $\varepsilon$  抵消的对数导数以及最终速度组装）在补充材料（第 II-A 节）中给出。关键结果是  $d \log \sigma_{\varepsilon,t}/dt =$ ，其中  $\frac{\varepsilon}{1-2s_t}/[t(1-s_t)]$  变性。

## G. 命题 1 的讨论

方差  $V(s_t) = \varepsilon \cdot (1-2s_t)^2/(1-s_t)$

在  $s_t = 1/2$  处消失，并在  $s_t \rightarrow 0$  附近受  $\varepsilon$  约束。将  $\varepsilon$  减小到 0.5 可使该方差均匀减半，从而 (i) 降低回归难度，(ii) 使常微分方程对有限步求解器更平滑。这解释了为何标准薛定谔桥与正则化薛定谔桥匹配之间的均方误差差距在低  $k$  时最为显著。

## H. 采样误差分析

对于  $k$  步 Heun 求解器，2-沃瑟斯坦距离满足  $W_2(\hat{p}_0, p_0) \leq C_1 T \delta + C_2 L_\theta T^3/k^2$  [39]，其中  $\delta^2 = \mathbb{E}\|\mathbf{v}_\theta - \mathbf{v}^*\|^2$ 。根据命题 1，降低  $\varepsilon$  可减小目标方差，从而同时减小  $\delta$  和离散化误差，这与图 3 一致。

## 一、训练与推理算法

### 五、实验

#### A. 实验设置

**数据集。** 我们在五个公开导航数据集（HuRoN、Recon、SACSoN、SCAND、GoStanford；~ 共 60k 条轨迹）[9]、[19] 上进行评估，另加一个基于 Gazebo 的自定义室内环境（500/100 个回合）和室外 CitySim 环境（400/80 个回合）。智能体接收  $96 \times 96$  RGB 图像并预测 8 步航点。 $\varepsilon = 0.5$  在自定义室内环境上选定，并在所有环境中固定不变。

**基线与度量。** 我们将所提方法与 ViNT（单样本）、NoMaD（ $k=20$ ）、DDPM（ $k=50$ ）、CFM（ $k=10$ ）[39] 以及 NaviBridger（ $k=10$ ）[31] 进行对比，评估指标包括均方误差  $\downarrow$ 、余弦相似度  $\uparrow$ 、终点距离误差  $\downarrow$ ，



**表一 综合比较。**每种方法均以其默认  $k$  及  $k=3$  展示，揭示零样本步数缩减下的性能退化。灰色行  $k=3$  VARIANTS。**RSBM** 同时以  $k=3$  AND  $k=10$  展示，以证明其早期饱和。粗体：每列最佳总体结果。

| Method             | $k$      | NFE      | Custom Indoor |              |             |             |           | CitySim (Outdoor) |              |             |             |           |
|--------------------|----------|----------|---------------|--------------|-------------|-------------|-----------|-------------------|--------------|-------------|-------------|-----------|
|                    |          |          | MSE↓          | CosSim↑      | FDE↓        | Col.%↓      | Suc.%↑    | MSE↓              | CosSim↑      | FDE↓        | Col.%↓      | Suc.%↑    |
| ViNT [9] (1-shot)  | 1        | 1        | 6.50          | 0.720        | 2.85        | 1.58        | 28        | 8.20              | 0.650        | 4.50        | 0.41        | 38        |
| NoMaD [19]         | 20       | 20       | 3.60          | 0.820        | 1.95        | 1.32        | 32        | 5.80              | 0.740        | 3.20        | 0.34        | 52        |
| NoMaD [19]         | 3        | 6        | 8.40          | 0.610        | 3.75        | 2.25        | 18        | 10.50             | 0.540        | 5.20        | 0.55        | 22        |
| DDPM [20]          | 50       | 50       | 3.80          | 0.820        | 2.05        | 0.98        | 64        | 5.50              | 0.750        | 3.10        | 0.35        | 50        |
| DDPM [20]          | 3        | 6        | 14.80         | 0.320        | 6.10        | 3.60        | 6         | 16.20             | 0.280        | 7.80        | 0.72        | 4         |
| FM [39]            | 10       | 10       | 2.80          | 0.910        | 1.45        | 0.52        | 82        | 4.20              | 0.850        | 2.20        | 0.32        | 58        |
| FM [39]            | 3        | 3        | 5.90          | 0.710        | 2.90        | 1.15        | 45        | 7.80              | 0.650        | 3.80        | 0.48        | 34        |
| NaviBridger [31]   | 10       | 19       | <b>1.82</b>   | 0.942        | 0.82        | 0.41        | 88        | <b>2.50</b>       | 0.920        | 1.15        | 0.30        | 64        |
| NaviBridger [31]   | 3        | 5        | 12.00         | 0.710        | 4.20        | 2.80        | 35        | 13.50             | 0.660        | 5.60        | 0.65        | 28        |
| <b>RSBM (Ours)</b> | <b>3</b> | <b>5</b> | <b>1.90</b>   | <b>0.945</b> | <b>0.80</b> | <b>0.38</b> | <b>92</b> | <b>2.55</b>       | <b>0.925</b> | <b>1.10</b> | <b>0.28</b> | <b>68</b> |
| RSBM (Ours)        | 10       | 19       | <b>1.72</b>   | 0.949        | 0.75        | 0.35        | 93        | <b>2.40</b>       | 0.930        | 1.05        | 0.26        | 70        |

列百分比 ↓，成功率 ↑。所有基于桥接的方法共享相同的先验  $\mathbf{a}_T$ 。

**协议。**所有方法使用相同的数据划分、硬件 (RTX 4090) 和 3 个随机种子。每个基线均在默认  $k$  和  $k=3$  (零样本步数缩减, 无重训练) 下评估。

## B. 主要结果

表一比较了所有方法在默认  $k$  和  $k=3$  下的表现。RSBM 在  $k=3$  (NFE=5) 时匹配或超越基线在完整预算下的表现；

$k=10$  仅带来边际增益 (MSE 1.90  $\rightarrow$  1.72)，证实了早期饱和。RSBM 以比 NaviBridger ( $k=10$ ) 少  $3.8\times$  的 NFE 实现了 92% 的成功率和 0.945 的 CosSim。在零样本缩减下，NaviBridger 的 CosSim 从 0.942 降至 0.710；DDPM 降至 0.320。图 4 可视化了质量-成本帕累托前沿。RSBM 在  $k=3$  (NFE=5) 时实现了 0.945 的 CosSim 和 92% 的成功率，比 NaviBridger 在  $k=10$  时少用  $3.8\times$  次评估。DDPM 和 NaviBridger 在预算约束下急剧退化，与命题 1 一致。

## C. 消融： $\varepsilon$ 正则化

**图 3 剖析**  $\varepsilon$ 。  $\varepsilon=1.0$  恢复了具有高曲率路径的标准薛定谔桥；非常小的  $\varepsilon$  会导致过度正则化。  $\varepsilon=0.5$  在多模态覆盖与少步保真度之间取得平衡。解耦先验与桥贡献。表七报告了五种配置，隔离了学习先验和  $\varepsilon$  校正的影响。学习先验减少了传输距离，将均方误差从 12.0 降低到 5.8 ( $2.1\times$ ，而  $\varepsilon$  校正拉直了常微分方程路径，进一步将均方误差从 5.8 降低到 1.9 ( $3.1\times$ 。这些增益是乘性的：单独任一组件都无法接近完整系统。此外，从高斯噪声进行的  $\varepsilon$  校正已经实现了  $2.9\times$  的降低




图 3.  $\varepsilon=0.5$  (红色) 的效果提供了稳定的低  $k$  性能。

均方误差低于标准薛定谔桥 (4.2 vs. 12.0)，证实了桥校正独立于先验质量做出贡献。

## D. 跨真实世界数据集的鲁棒性

为了验证在自定义室内数据集中观察到的优势具有泛化性，表二在 [9]、[19] 的标准开环离线协议下，分解了五个不同真实世界数据集上的动作均方误差和余弦相似度。在  $k=3$  处，RSBM 在所有五个数据集上与 NaviBridger 在  $k=10$  处保持竞争力：NaviBridger 的平均均方误差为 4.42，余弦相似度为 0.672，而 RSBM 获得 1.19 和 0.934。差距在 GoStanford (一个长距离室外数据集) 和 SACSoN (具有动态障碍物) 上最为明显，这与命题 1 的方差缩减机制一致。




图 4. 质量 - 成本帕累托前沿。每个标记代表一种方法在给定采样预算下的表现 ( $k$ )。 (a) 余弦相似度与函数评估次数; (b) 成功率与函数评估次数。RSBM 在  $k=3$  (函数评估次数 = 5) 处位于有利的前沿区域, 以显著更少的评估次数提供了强大的质量。

表 2 逐数据集泛化。动作均方误差  $\downarrow$  AND CosSim  $\uparrow$  跨五个不同真实世界数据集。RSBM ( $k=3$ ) 始终匹配或超过 NAVIBRIDGER ( $k=10$ ); N AVIBRIDGER ( $k=3$ ) 在所有领域显著退化。粗体: 每列最佳 AMONG  $k=3$  METHODS。

| Method           | $k$      | Action MSE $\downarrow$ |             |             |             |             |             | CosSim $\uparrow$ |              |              |              |              |              |
|------------------|----------|-------------------------|-------------|-------------|-------------|-------------|-------------|-------------------|--------------|--------------|--------------|--------------|--------------|
|                  |          | HuRoN                   | Recon       | SACSoN      | SCAND       | GoStan.     | Avg         | HuRoN             | Recon        | SACSoN       | SCAND        | GoStan.      | Avg          |
| DDPM [20]        | 10       | 1.38                    | 1.19        | 1.74        | 0.72        | 4.12        | 1.83        | 0.880             | 0.900        | 0.860        | 0.920        | 0.780        | 0.868        |
| DDPM [20]        | 3        | 8.50                    | 6.20        | 9.80        | 4.60        | 15.30       | 8.88        | 0.350             | 0.420        | 0.280        | 0.480        | 0.210        | 0.348        |
| FM [39]          | 10       | 1.10                    | 0.97        | 1.55        | 0.65        | 3.65        | 1.58        | 0.910             | 0.920        | 0.885        | 0.935        | 0.820        | 0.894        |
| FM [39]          | 3        | 3.20                    | 2.60        | 4.10        | 1.80        | 7.50        | 3.84        | 0.720             | 0.740        | 0.670        | 0.790        | 0.560        | 0.696        |
| NaviBridger [31] | 10       | 0.27                    | 0.88        | 1.43        | 0.59        | 3.22        | 1.28        | 0.955             | 0.935        | 0.920        | 0.960        | 0.875        | 0.929        |
| NaviBridger [31] | 3        | 2.80                    | 3.45        | 5.20        | 2.15        | 8.50        | 4.42        | 0.750             | 0.690        | 0.620        | 0.780        | 0.520        | 0.672        |
| <b>RSBM</b>      | <b>3</b> | <b>0.25</b>             | <b>0.82</b> | <b>1.35</b> | <b>0.48</b> | <b>3.05</b> | <b>1.19</b> | <b>0.958</b>      | <b>0.940</b> | <b>0.925</b> | <b>0.965</b> | <b>0.880</b> | <b>0.934</b> |
| RSBM             | 10       | 0.24                    | 0.80        | 1.32        | 0.47        | 2.95        | 1.16        | 0.960             | 0.942        | 0.928        | 0.968        | 0.885        | 0.937        |

## E. 消融: 预测目标

表三在相同的 RSBM 桥 ( $\varepsilon=0.5$ , 自定义室内) 下比较了三种预测目标。  $v$ -预测直接参数化 ODE 速度场, 避免了  $\epsilon$ -预测的分数到漂移转换以及  $x_0$ -预测的端点估计偏差。

$k=3$ ,  $v$ -预测的 MSE 比  $x_0$ -预测低 **35.6%**, 比  $\epsilon$ -预测低 **45.7%**。在  $k=10$  处差距缩小, 到  $k=50$  时三种目标收敛 (MSE 1.67 对 1.72 对 1.74), 证实  $v$ -预测的优势集中在少步机制中。

## F. 定性结果

图 5 可视化了  $k=3$  处八个具有挑战性场景中的轨迹。基线在前几个转弯处发生碰撞 ( $\times$  标记), 而 RSBM 产生平滑、无碰撞的轨迹, 紧密跟踪地面真值, 与命题 1 的方差缩减一致。

表 3 预测目标消融 (RSBM,  $\varepsilon=0.5$ , C 自定义室内)。粗体: 每列最佳。

| Target                            | $k=3$ (NFE=5)    |                   |                  | $k=10$ (NFE=19)  |                   |                  |
|-----------------------------------|------------------|-------------------|------------------|------------------|-------------------|------------------|
|                                   | MSE $\downarrow$ | CosSim $\uparrow$ | FDE $\downarrow$ | MSE $\downarrow$ | CosSim $\uparrow$ | FDE $\downarrow$ |
| $\epsilon$ -pred                  | 3.50             | 0.895             | 1.42             | 1.95             | 0.940             | 0.88             |
| $x_0$ -pred                       | 2.95             | 0.920             | 1.15             | 1.80             | 0.946             | 0.84             |
| <b><math>v</math>-pred (Ours)</b> | <b>1.90</b>      | <b>0.945</b>      | <b>0.80</b>      | <b>1.72</b>      | <b>0.949</b>      | <b>0.78</b>      |

轨迹紧密跟踪地面真值, 与命题 1 的方差缩减一致。

## G. 实现细节

1) 网络架构: 视觉编码器使用 EfficientNet-B0 和 4 层变换器 (上下文维度


Trajectory Prediction: Qualitative Comparison ( $k=3$ , NFE = 5 for all diffusion methods)

图 5. 八个挑战性场景下的定性轨迹比较 ( $2 \times 4$  网格,  $k=3$ , NFE = 5). 第一行: 四个室内/结构化环境。第二行: 四个大规模环境。基线方法早期即发生碰撞 (×); 淡色虚线表示无效的幽灵延续。RSBM (绿色) 保持无碰撞并紧密跟踪真值 (灰色虚线)。

$d=256$ )。先验网络  $g_\psi$  是一个三层多层感知机条件变分自编码器 (隐藏层 256, 潜在变量 32)。速度网络是一个条件一维 U-Net, 通道数为 [64, 128, 256], 并使用 FiLM 条件调制。桥参数:  $\sigma_{\max} = 10.0$ ,  $\sigma_{\min} = 0.002$ ,  $\varepsilon = 0.5$ , 采用 Heun 求解器与 Karras 调度 ( $\rho = 7$ ), 默认  $k=3$ 。训练使用 AdamW (学习率  $= 10^{-4}$ , 批量大小 256, 训练 30 轮次)。完整的超参数表见补充材料。

2) 仿真环境: 定制室内场景。基于 Gazebo 的环境, 包含 10 个互联房间 ( $20 \times 15$  m), 狭窄门口及家具障碍物。CitySim (室外

门)。一个包含建筑物和街道级障碍物的城市环境, 距离范围为 15 至 30 米。两者均使用配备单目 RGB ( $96 \times 96$ ) 的 TurtleBot3。地面真值路径采用 A\* 搜索与高斯平滑。

**关于生成建模。**即便在仿真环境中, 条件动作分布  $p(a_0 | \mathcal{O}, I_g)$  也是多模态的, 因为视觉上相似的观测允许多种有效延续。确定性回归器对各模态取平均, 产生不可行的轨迹 [12]、[13]。表 I 证实了这一点: 视觉导航变换器 (ViNT, 确定性) 仅达到 0.720 的余弦相似度和 28% 的成功率。

3) 统计变异性: 表四报告了在自定义室内数据集上 3 个随机种子的均值  $\pm$  标准差。RSBM 在  $k=3$  处所有度量 (MSE  $1.90 \pm 0.06$ 、CosSim  $0.945 \pm 0.002$ 、成功率  $92 \pm 2\%$ ) 上表现出最低方差。相比之下, NaviBridger 在  $k=3$  处表现出高度不稳定性 ( $12.00 \pm 0.45$  MSE,  $35 \pm 4\%$  成功率), 证明在少步约束下未修正的桥接脆弱性。即使在其默认预算 ( $k=10$ ), 下, NaviBridger 的方差仍高于 RSBM 在  $k=3$  处的方差,

表四 MEAN  $\pm$  3 个随机种子的标准差 (自定义室内)。粗体: 每列最佳。

| Method                         | $k$      | MSE $\downarrow$                  | CosSim $\uparrow$                   | Suc.% $\uparrow$             |
|--------------------------------|----------|-----------------------------------|-------------------------------------|------------------------------|
| ViNT (1-shot)                  | 1        | $6.50 \pm 0.15$                   | $0.720 \pm 0.005$                   | $28 \pm 2$                   |
| NoMaD                          | 20       | $3.60 \pm 0.12$                   | $0.820 \pm 0.004$                   | $32 \pm 3$                   |
| DDPM                           | 50       | $3.80 \pm 0.14$                   | $0.820 \pm 0.005$                   | $64 \pm 3$                   |
| FM                             | 10       | $2.80 \pm 0.10$                   | $0.910 \pm 0.003$                   | $82 \pm 2$                   |
| NaviBridger ( $k=10$ )         | 10       | $1.82 \pm 0.08$                   | $0.942 \pm 0.003$                   | $88 \pm 2$                   |
| NaviBridger ( $k=3$ )          | 3        | $12.00 \pm 0.45$                  | $0.710 \pm 0.015$                   | $35 \pm 4$                   |
| <b>RSBM (<math>k=3</math>)</b> | <b>3</b> | <b><math>1.90 \pm 0.06</math></b> | <b><math>0.945 \pm 0.002</math></b> | <b><math>92 \pm 2</math></b> |
| RSBM ( $k=10$ )                | 10       | $1.72 \pm 0.05$                   | $0.949 \pm 0.002$                   | $93 \pm 1$                   |

证实  $\varepsilon$ -修正稳定了预测的均值和离散度。4) 各数据集多度量结果: 5) ODE 求解器消融: 表六隔离了求解器阶数与桥接修正的影响。在相同 NFE = 5 下, Heun ( $k=3$ ) 在 MSE 上比 Euler ( $k=5$ ) 优 7.3%, 成功率高出 6 个百分点, 证实了二阶修正的益处。值得注意的是, 即使是一阶 Euler 配合 RSBM 在  $k=5$  (NFE=5, MSE=2.05) 处也已超过所有非桥接基线在其完整预算下的表现 (FM  $k=10$ : MSE=2.80; DDPM  $k=50$ : MSE=3.80), 表明性能提升主要源于修正后的桥接几何。6) 先验初始化消融: 一个自然的问题是, 多少性能可归因于学习到的先验  $g_\psi$ , 多少归因于  $\varepsilon$ -修正桥接本身。表七解耦了



表五 各数据集比较 ( $k=3$  除非注明)。粗体: 最佳。

| Method       | $k$      | HuRoN        | Recon        | SACSoN       | SCAND        | GoStan.      | Avg          |
|--------------|----------|--------------|--------------|--------------|--------------|--------------|--------------|
| Action MSE ↓ |          |              |              |              |              |              |              |
| DDPM         | 3        | 8.50         | 6.20         | 9.80         | 4.60         | 15.30        | 8.88         |
| FM           | 3        | 3.20         | 2.60         | 4.10         | 1.80         | 7.50         | 3.84         |
| NaviBridger  | 10       | 0.27         | 0.88         | 1.43         | 0.59         | 3.22         | 1.28         |
| NaviBridger  | 3        | 2.80         | 3.45         | 5.20         | 2.15         | 8.50         | 4.42         |
| <b>RSBM</b>  | <b>3</b> | <b>0.25</b>  | <b>0.82</b>  | <b>1.35</b>  | <b>0.48</b>  | <b>3.05</b>  | <b>1.19</b>  |
| CosSim ↑     |          |              |              |              |              |              |              |
| DDPM         | 3        | 0.350        | 0.420        | 0.280        | 0.480        | 0.210        | 0.348        |
| FM           | 3        | 0.720        | 0.740        | 0.670        | 0.790        | 0.560        | 0.696        |
| NaviBridger  | 10       | 0.955        | 0.935        | 0.920        | 0.960        | 0.875        | 0.929        |
| NaviBridger  | 3        | 0.750        | 0.690        | 0.620        | 0.780        | 0.520        | 0.672        |
| <b>RSBM</b>  | <b>3</b> | <b>0.958</b> | <b>0.940</b> | <b>0.925</b> | <b>0.965</b> | <b>0.880</b> | <b>0.934</b> |

表六 求解器消融 (RSBM,  $\varepsilon=0.5$ , C 自定义室内)。粗体: 每COLUMN最佳。

| Solver      | $k$ | NFE | MSE↓        | CosSim↑      | FDE↓        | Suc.%↑    |
|-------------|-----|-----|-------------|--------------|-------------|-----------|
| Euler (1st) | 3   | 3   | 2.45        | 0.928        | 1.15        | 82        |
| Euler       | 5   | 5   | 2.05        | 0.938        | 0.95        | 86        |
| Euler       | 10  | 10  | 1.80        | 0.947        | 0.82        | 90        |
| Heun (2nd)  | 3   | 5   | <b>1.90</b> | <b>0.945</b> | <b>0.80</b> | <b>92</b> |
| Heun        | 5   | 9   | 1.78        | 0.948        | 0.76        | 93        |
| Heun        | 10  | 19  | 1.72        | 0.949        | 0.74        | 93        |

表七 先验初始化消融 (自定义室内,  $k=3$ )。

| Configuration                          | MSE↓        | CosSim↑      | FDE↓        | Suc.%↑    |
|----------------------------------------|-------------|--------------|-------------|-----------|
| Prior $g_\psi$ only (no bridge)        | 5.80        | 0.780        | 2.60        | 45        |
| Gauss. + RSBM ( $\varepsilon=0.5$ )    | 4.20        | 0.860        | 1.95        | 62        |
| Gauss. + Std. SB ( $\varepsilon=1.0$ ) | 12.00       | 0.710        | 4.20        | 35        |
| Prior + Std. SB ( $\varepsilon=1.0$ )  | 5.50        | 0.810        | 2.35        | 52        |
| Prior + RSBM ( $\varepsilon=0.5$ )     | <b>1.90</b> | <b>0.945</b> | <b>0.80</b> | <b>92</b> |

这些贡献在自定义室内数据集上。第 1 行显示仅先验网络  $g_\psi$  (无桥接细化)。第 2 行将学习到的先验替换为各向同性高斯噪声  $\mathbf{a}_T \sim \mathcal{N}(\mathbf{0}, \sigma_{\max}^2 \mathbf{I})$ , 同时保留 RSBM 桥接。第 3 行是完整系统。得出四个关键观察: (i) 仅先验不足, MSE=5.80 和 45% 成功率, 而完整系统为 MSE=1.90 和 92%。(ii) 标准 SB 配合  $\varepsilon=1$  在低  $k$  下按设计失败, 因为 3 步不足以让高方差路径收敛。(iii) RSBM 即使从高斯噪声开始也有效, 达到 MSE=4.20, 而标准 SB 为 MSE=12.00, 提升  $2.9\times$ 。(iv) 先验和修正桥接互补且协同。7) 推理成本分析: 可变推理成本完全由 NFE 决定; 视觉编码和先验生成是固定开销。  $3.8\times$  NFE 减少 (19 $\rightarrow$ 5) 直接转化为  $3.8\times$  的墙钟时间加速。

在英伟达 Jetson Orin 平台上, RSBM 每周期耗时  $\sim 50$  毫秒 (4 赫兹控制频率), 而 DDPM 需要  $\sim 350$  毫秒, 无法满足实时控制要求。

## 六、讨论

**为何  $\varepsilon$ -修正有效?** RSBM 的成功可从三个互补视角理解。几何上, 减小  $\varepsilon$  使桥分布集中于确定性插值  $\mu_t$  附近, 产生曲率更低的常微分方程路径, 便于有限步求解器积分。统计上, 命题 1 表明条件速度方差随  $\varepsilon$  线性缩放, 直接降低了神经网络的回归难度。信息论上, 公式 20 中的 KL 代价量化了修正的代价: 在  $\varepsilon=0.5$  且  $D=16$  时, 代价仅为 1.55 纳特, 这一适度的信息惩罚在  $k=3$  处带来了  $6.3\times$  的均方误差降低。

### 与修正流和一致性模型的联系

**模型。**修正流 [2] 通过迭代回流拉直常微分方程轨迹, 每个阶段都需要重新生成数据。一致性模型 [1] 将预训练教师模型蒸馏为少步学生模型。RSBM 通过桥几何本身在单一训练阶段实现拉直; 我们的实验表明, 对于  $k \geq 3$  而言, 回流并非必要。

### 学习先验的作用

表七显示, 先验与  $\varepsilon$ -修正的贡献是相乘的。二者结合实现了比高斯+标准 SB 低  $1.9$  ( $6.3\times$  的均方误差, 证实了任一单独组件都无法接近完整系统。这一分解表明, 未来对先验或桥的改进都将产生复合增益。

**关于多媒体相关性。**视觉导航需要在实时约束下, 根据流式视觉输入合成结构化的轨迹输出。这一设定与现代多媒体系统的核心挑战相同, 其中迭代生成模型必须在输出多样性与推理效率之间取得平衡。  $\varepsilon$  校正机制和条件先验范式可直接迁移到任何基于扩散的多媒体流程中。

### Limitations

三项局限性界定了本文结果的范围。(1) 评估协议。在五个公开数据集上, 评估遵循先前工作 [9]、[19] 的标准开环协议: 从单一观测预测轨迹, 并与真值航点进行比较。只有两个模拟环境提供了闭环成功率和碰撞度量, 且两者仅包含静态障碍物。(2) 先验依赖性。学习到的变分自编码器先验在每个数据集上与桥接网络联合训练, 不支持对未见环境的零样本迁移。在新领域部署 RSBM 需要使用目标领域演示进行微调; 开发通用的、环境无关的先验仍然是一个开放问题。(3)  $\varepsilon$  选择。我们在所有实验中固定  $\varepsilon=0.5$ , 基于 Custom Indoor 上的网格搜索。第 V-C 节显示性能稳定,  $\varepsilon \in [0.3, 0.7]$ , 但选择的跨领域鲁棒性尚未得到充分验证; 自适应调度策略将提高适用性。

未来方向包括自适应  $\varepsilon$  调度、将 RSBM 扩展到三维场景表示 [10] 以及更高

维动作空间、在物理机器人平台上进行闭环验证，以及将校正机制应用于更广泛的跨模态多媒体生成任务。

## VII. 结论

本文提出了整流薛定谔桥匹配 (Rectified Schrödinger Bridge Matching) 框架，通过单一熵正则化参数  $\varepsilon$  统一了薛定谔桥与条件流匹配。我们证明了条件速度场在整个  $\varepsilon$  谱上具有结构不变性 (定理 1)，且  $\varepsilon$ -整流线性降低速度方差 (命题 1)，从而在仅 3 步常微分方程中实现高保真轨迹生成。在五个公开数据集和两个模拟环境中，RSBM 在  $k=3$  处达到 94.5% 的余弦相似度和 92% 的成功率，且函数评估次数比 NaviBridger 少  $3.8\times$ ，无需蒸馏或多阶段训练。未来工作包括自适应  $\varepsilon$  调度以及将整流机制扩展到更广泛的多媒体生成任务。

## 参考文献

- [1] Y. Song, P. Dhariwal, M. Chen, and I. Sutskever, "Consistency models," in *International Conference on Machine Learning*. PMLR, 2023, pp. 32 211–32 252.
- [2] X. Liu, C. Gong, and Q. Liu, "Flow straight and fast: Learning to generate and transfer data with rectified flow," in *International Conference on Learning Representations*, 2023.
- [3] A. Chalkatzaras, I. Pratikakis, and A. A. Amanatiadis, "A survey on map-based localization techniques for autonomous vehicles," *IEEE Transactions on intelligent vehicles*, vol. 8, no. 2, pp. 1574–1596, 2022.
- [4] L. Yang, J. Qi, D. Song, J. Xiao, J. Han, and Y. Xia, "Survey of robot 3d path planning algorithms," *Journal of Control Science and Engineering*, vol. 2016, no. 1, p. 7426913, 2016.
- [5] F. Zeng, C. Wang, and S. S. Ge, "A survey on visual navigation for artificial agents with deep reinforcement learning," *Ieee Access*, vol. 8, pp. 135 426–135 442, 2020.
- [6] J. Kulhánek, E. Derner, and R. Babuška, "Visual navigation in real-world indoor environments using end-to-end deep reinforcement learning," *IEEE Robotics and Automation Letters*, vol. 6, no. 3, pp. 4345–4352, 2021.
- [7] K. Chen, J. P. De Vicente, G. Sepulveda, F. Xia, A. Soto, M. Vázquez, and S. Savarese, "A behavioral approach to visual navigation with graph localization networks," *arXiv preprint arXiv:1903.00445*, 2019.
- [8] T. Manderson, J. C. G. Higuera, S. Wapnick, J.-F. Tremblay, F. Shkurti, D. Meger, and G. Dudek, "Vision-based goal-conditioned policies for underwater navigation in the presence of obstacles," *arXiv preprint arXiv:2006.16235*, 2020.
- [9] D. Shah, A. Sridhar, N. Dashora, K. Stachowicz, K. Black, N. Hirose, and S. Levine, "Vint: A foundation model for visual navigation," *arXiv preprint arXiv:2306.14846*, 2023.
- [10] W. Guo, X. Xu, H. Yin, Z. Wang, J. Feng, J. Zhou, and J. Lu, "Igl-nav: Incremental 3d gaussian localization for image-goal navigation," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2025, pp. 6808–6817.
- [11] X. Lei, M. Wang, W. Zhou, and H. Li, "Gaussnav: Gaussian splatting for visual navigation," *IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 5, pp. 4108–4121, 2025.
- [12] P. Florence, C. Lynch, A. Zeng, O. A. Ramirez, A. Wahid, L. Downs, A. Wong, J. Lee, I. Mordatch, and J. Tompson, "Implicit behavioral cloning," in *Conference on robot learning*. PMLR, 2022, pp. 158–168.
- [13] N. M. Shafiullah, Z. Cui, A. A. Altanzaya, and L. Pinto, "Behavior transformers: Cloning  $k$  modes with one stone," *Advances in neural information processing systems*, vol. 35, pp. 22 955–22 968, 2022.
- [14] J. Carvalho, A. T. Le, M. Baierl, D. Koert, and J. Peters, "Motion planning diffusion: Learning and planning of robot motions with diffusion models," in *2023 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2023, pp. 1916–1923.
- [15] T.-W. Ke, N. Gkanatsios, and K. Fragkiadaki, "3d diffuser actor: Policy diffusion with 3d scene representations," *arXiv preprint arXiv:2402.10885*, 2024.
- [16] Z. Zhu, H. Zhao, H. He, Y. Zhong, S. Zhang, H. Guo, T. Chen, and W. Zhang, "Diffusion models for reinforcement learning: A survey," *arXiv preprint arXiv:2311.01223*, 2023.
- [17] A. Ajay, Y. Du, A. Gupta, J. Tenenbaum, T. Jaakkola, and P. Agrawal, "Is conditional generative modeling all you need for decision-making?" *arXiv preprint arXiv:2211.15657*, 2022.
- [18] M. Janner, Y. Du, J. B. Tenenbaum, and S. Levine, "Planning with diffusion for flexible behavior synthesis," *arXiv preprint arXiv:2205.09991*, 2022.
- [19] A. Sridhar, D. Shah, C. Glossop, and S. Levine, "Nomad: Goal masked diffusion policies for navigation and exploration," in *2024 IEEE International Conference on Robotics and Automation (ICRA)*. IEEE, 2024, pp. 63–70.
- [20] J. Ho, A. Jain, and P. Abbeel, "Denoising diffusion probabilistic models," *Advances in neural information processing systems*, vol. 33, pp. 6840–6851, 2020.
- [21] J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli, "Deep unsupervised learning using nonequilibrium thermodynamics," in *International Conference on Machine Learning*, 2015, pp. 2256–2265.
- [22] V. R. Somnath, M. Pariset, Y.-P. Hsieh, M. R. Martinez, A. Krause, and C. Bunne, "Aligned diffusion Schrödinger bridges," in *Uncertainty in Artificial Intelligence*. PMLR, 2023, pp. 1985–1995.
- [23] J. Heng, V. De Bortoli, A. Doucet, and J. Thornton, "Simulating diffusion bridges with score matching," *Biometrika*, vol. 112, no. 4, p. asaf048, 2025.
- [24] X. Liu, L. Wu, M. Ye, and Q. Liu, "Let us build bridges: Understanding and extending diffusion generative models," *arXiv preprint arXiv:2208.14699*, 2022.
- [25] B. Li, K. Xue, B. Liu, and Y.-K. Lai, "Bbmd: Image-to-image translation with brownian bridge diffusion models," in *Proceedings of the IEEE/CVF conference on computer vision and pattern Recognition*, 2023, pp. 1952–1961.
- [26] L. Zhou, A. Lou, S. Khanna, and S. Ermon, "Denoising diffusion bridge models," *arXiv preprint arXiv:2309.16948*, 2023.
- [27] Y. Shi, V. De Bortoli, A. Campbell, and A. Doucet, "Diffusion Schrödinger bridge matching," in *Advances in Neural Information Processing Systems*, vol. 36, 2023.
- [28] G.-H. Liu, Y. Lipman, M. Nickel, B. Karrer, E. A. Theodorou, and R. T. Q. Chen, "Generalized Schrödinger bridge matching," in *International Conference on Learning Representations*, 2024.
- [29] N. Gushchin, S. Kholkin, E. Burnaev, and A. Korotin, "Light and optimal Schrödinger bridge matching," *arXiv preprint arXiv:2402.03207*, 2024.
- [30] N. Gushchin, D. Selikhanovych, and A. Korotin, "Adversarial Schrödinger bridge matching," *arXiv preprint arXiv:2405.06474*, 2024.
- [31] H. Ren, Y. Zeng, Z. Bi, Z. Wan, J. Huang, and H. Cheng, "Prior does matter: Visual navigation via denoising diffusion bridge models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2025, pp. 12 100–12 110.
- [32] J. Zhang, K. Wang, R. Xu, G. Zhou, Y. Hong, X. Fang, Q. Wu, Z. Zhang, and H. Wang, "Navid: Video-based vlm plans the next step for vision-and-language navigation," *arXiv preprint arXiv:2402.15852*, 2024.
- [33] S. Gode, A. Nayak, D. N. Oliveira, M. Krawez, C. Schmid, and W. Burgard, "Flownav: Combining flow matching and depth priors for efficient navigation," in *2025 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*. IEEE, 2025, pp. 17 762–17 768.
- [34] X. Luo, A. Wu, H. Han, X. Wan, W. Zhang, L. Shu, and R. Wang, "Stepnav: Structured trajectory priors for efficient and multimodal visual navigation," *arXiv preprint arXiv:2602.02590*, 2026.
- [35] A. Tong, N. Malkin, K. Fatras, L. Atanackovic, Y. Zhang, G. Hugué, G. Wolf, and Y. Bengio, "Simulation-free Schrödinger bridges via score and flow matching," *arXiv preprint arXiv:2307.03672*, 2023.
- [36] Q. Zhu and W. Lin, "Switched flow matching: Eliminating singularities via switching odes," *arXiv preprint arXiv:2405.11605*, 2024.
- [37] Y. Chen, T. Georgiou, and M. Pavon, "Entropic and displacement interpolation: a computational approach using the Hilbert metric," *SIAM Journal on Applied Mathematics*, vol. 76, no. 6, pp. 2375–2396, 2016.
- [38] Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole, "Score-based generative modeling through stochastic differential equations," *arXiv preprint arXiv:2011.13456*, 2020.
- [39] Y. Lipman, R. T. Chen, H. Ben-Hamu, M. Nickel, and M. Le, "Flow matching for generative modeling," in *International Conference on Learning Representations*, 2023.