

将流映射策略与最优 Q 引导对齐

Christos Ziakas^{1*} Alessandra Russo¹ Avishek Joey Bose^{1,2}

¹Imperial College London ²Mila

摘要

基于表达力强的模型类（如扩散和流匹配）的生成式策略非常适合具有高度多模态动作分布的复杂控制问题。然而，其表达力是以显著的推理成本为代价的：生成每个动作通常需要模拟生成过程的许多步骤，从而在顺序决策的展开过程中累积延迟。我们引入了流映射策略，这是一类新颖的生成式策略，旨在通过学习在现有基于流的策略的生成动态中采取任意大小的跳跃（包括一步跳跃）来实现快速动作生成。我们将流映射策略实例化用于离线到在线强化学习（RL），并将在在线适应形式化为一个信任域优化问题，该问题在保持接近离线策略的同时提升评论家的 Q 值。我们从理论上推导出 FLOW MAP Q -GUIDANCE (FMQ)，这是一个有原则的闭式学习目标，在评论家引导的信任域约束下，对于适应离线流映射策略是最优的。我们进一步引入了 Q -GUIDED BEAM SEARCH (QGBS)，这是一种随机流映射采样器，它将重新加噪与束搜索相结合，以实现推理时的迭代细化。在来自 OGBench 和 RoboMimic 的 12 个具有挑战性的机器人操作和运动任务中，FMQ 在离线到在线强化学习中达到了最先进的性能，在平均成功率上以 21.3% 的相对改进超越了之前的一步策略 MVP。

1 引言

离线强化学习（Offline Reinforcement Learning, RL）的最大前景在于，能够以可扩展的数据驱动方式引导出有效策略，而无需昂贵的环境交互 [Levine 等人, 2020]。这种扩展理念是现代数据驱动强化学习 [Kumar, 2019, Fu 等人, 2020] 的核心，它利用不断增长的多样化离线数据集 [Collaboration 等人, 2023]，如今已在从对话 [Jaques 等人, 2019] 到机器人导航 [Kahn 等人, 2018] 等高影响力应用中驱动策略学习。事实上，在此类复杂控制问题中模仿专家行为策略的高度多模态动作分布，需要使用超越受限单峰高斯执行器（Gaussian Actor）的表达性策略类 [Zhu 等人, 2023, Wang 等人, 2022]。

基于动态质量传输的生成式策略，如扩散模型（Diffusion Model）[Sohl-Dickstein 等人, 2015; Song 等人, 2020] 和流匹配（Flow Matching）[Liu 等人, 2022; Lipman 等人, 2022; Albergo 等人, 2023]，为高斯策略提供了一种引人注目的替代方案，因为它们学习将简单的基础分布映射为丰富的状态条件动作分布 [Chi 等人, 2025]。生成式策略在表达性上的提升使其特别适用于离线及离线到在线强化学习 [Fujimoto 和 Gu, 2021; Tarasov 等人, 2023]，其中策略必须首先从静态数据集中建模多样化行为，然后通过交互进行改进。然而，表达性生成式策略的代价是推理时计算成本高昂的仿真。更准确地说，生成动作需要

* 通讯作者：c.ziakas24@imperial.ac.uk




图 1: (左) FMQ: 单步流映射策略将噪声 a_0 传输至动作 a_1 ; 随后, 信赖域投影将动作 a_1 位移至 a_1^* , 以最大化 Q 值。 (右): QGBS ($M=1, B=2$): 重加噪将 a_1^* 破坏为 B 个中间状态 $a_{t'}$, 流映射策略随后对这些状态去噪以生成 B 个候选动作; 候选动作通过最优信赖域位移进行更新以最大化 Q_ϕ , 并选择具有最高 M 值的动作。

从噪声到动作的动力学数值积分, 并在每个环境步骤中执行 [Yang 等人, 2023]——这阻碍了在在线和现实世界环境中的部署 [Zhan 等人, 2024, 2025]。

解决生成式策略的推理延迟问题对于从生成式策略中提取最大效用至关重要, 近期已有若干工作尝试学习一步离线策略 [Park 等人, 2025, Zhan 等人, 2026]。然而, 在离线到在线强化学习的背景下, 一步生成仍然不足, 因为策略必须超越离线行为先验进行改进。此外, 当前的一步生成式策略通常依赖于基于启发式的生成-选择过程, 例如最佳 N 采样, 以使动作偏向高批评家 Q 值。关键的是, 这种启发式方法通过每次决策需要多次策略和批评家评估, 抵消了一步策略的计算优势, 同时对于任何有限的 N , 不能保证在批评家下采样的动作的最优局部改进。

当前工作。在这项工作中, 我们引入了流映射策略, 这是一类新颖的生成式策略, 学习与扩散和流匹配策略的概率流常微分方程相关的唯一双时间跳跃算子。至关重要的是, 流映射策略推广了现有的用于离线到在线强化学习的一步策略, 例如平均速度策略 [詹等人, 2026年], 同时引入了新的学习目标, 产生了流映射策略的拉格朗日、欧拉和渐进变体。与先前工作形成鲜明对比的是, 对于一步流映射策略的原则性在线适应, 我们制定了一个信任区域优化问题, 并推导出一种解析最优的闭式方法, 使动作分布与 Q 值引导对齐。这产生了我们的贡献 FLOW MAP Q -GUIDANCE (FMQ), 它构建了一个新颖的自举学习目标——如图 1 所示——作为批评家的投影动作梯度, 并消除了对蒸馏网络或最佳 N 启发式的需要。

此外, 本文在评估阶段引入了一种互补的推理时搜索程序, 即 Q 引导的束搜索 (QGBS), 该程序通过将候选样本重新加噪至中间状态, 结合 Q 引导的束搜索在信任域内进行随机采样。重要的是, QGBS 能够在高 Q 值动作周围产生多样化的细化结果, 而无需昂贵的常微分方程仿真或在线适应过程中的额外学习。本文的核心贡献总结如下: 1. 流映射策略。本文提出流映射策略, 作为学习一步策略的框架, 该策略充当基于流的生成式行动者的两时间跳跃算子。

2. 算法。本文提出流映射最优引导 (FMQ), 其利用最优引导 (定理 3.2) 高效适配流映射 Q 执行体。此外, 本文进一步提出引导束随机搜索 (QGBS), 这是一种随机推理时精化算法, 融合了流映射重噪、束选择与信赖域 Q 引导。3. 最先进的性能: 在来自 OGBench 和 RoboMimic 的 12 项操作与运动任务中, FMQ 相较于先前最先进的离线到在线基线, 平均相对性能提升 21.3%, 同时在线适应阶段的平均效率提升 $\approx 2.77\times$ 。

2 背景与预备知识

离线到在线强化学习。我们考虑一个马尔可夫决策过程 (MDP) [萨顿与巴托, 1998年], 由元组 $\mathcal{M} = (\mathcal{S}, \mathcal{A}, r, P, \gamma)$ 定义, 其中 $\mathcal{S} \subseteq \mathbb{R}^n, \mathcal{A} \subseteq \mathbb{R}^d$ 表示连续状态-动作空间, $r(s, a)$ 表示奖励函数, $P(s'|s, a)$ 表示转移概率分布, $\gamma \in [0, 1)$

折扣因子。强化学习的目标是训练一个策略 $\pi(a|s)$ ，以最大化期望累积折扣回报 $J(\pi) = \mathbb{E}_\pi[\sum_{\tau=0}^{\infty} \gamma^\tau r(s^\tau, a^\tau)]$ ，其中 τ 表示时间步。离线到在线强化学习是一个两阶段学习框架，包括离线预训练和随后的在线微调。在离线预训练阶段，行为先验策略在静态数据集 $\mathcal{D} = \{(s, a, r, s')\}$ 上进行训练，提供一个初始化。随后，在在线微调阶段，策略直接与环境交互。一种流行的方法是演员-评论家方法，它使用一个演员 $\pi(a|s)$ 和一个评论家 $Q_\theta(s, a)$ ，评论家近似在策略 π : $Q^\pi(s, a) = \mathbb{E}_{\pi, P}$ 下的期望折扣回报 $[\sum_{i=0}^{\infty} \gamma^i r(s^i, a^i) \mid s^0 = s, a^0 = a]$ 。

流匹配策略。一个以状态 s 为条件的生成式策略 $a_1 \sim \pi_1(\cdot|s)$ ，可以被表述为一个传输计划，它将一个易于采样的参考测度 $p_0(a_0) \in \mathcal{P}(\mathbb{R}^d)$ 推前到期望的（最优）目标动作测度 $p_1(a_1) := p_{\text{target}}^*(a^*) \in \mathcal{P}(\mathbb{R}^d)$ 。下标表示时间概念，其中过程在时间 $t=0$ ，i.e. $a_0 \sim p_0$ 从先验演化一个（伪）动作，到在时间 $a_1 \sim p_1(a_1)$ 遵循目标分布 $t=1$ 的动作。我们强调，与传输动力学相关的时间 t 区别于与马尔可夫决策过程相关的 τ 。形式上，流策略是一个以状态 $s, \psi_t(\cdot|s) : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 为条件的单参数微分同胚，它是以下常微分方程的解：

$$\frac{d}{dt} \psi_t(a_t | s) = v_t(\psi_t(a_t | s)), \quad \psi_0(a_0) = a_0, \quad (1)$$

具有初始条件 $\psi_0(a_0) = a_0$ 。此外， $v_t : [0, 1] \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 是一个随时间变化的（瞬时）速度场。实际上，生成策略问题的核心在于学习一个策略，该策略将基础测度前推如下 $\pi_1(\cdot|s) := p_1 = [\psi_1(\cdot|s)] \# (p_0)$ 。我们强调 ψ_1 产生确定性动作，而 $\pi_1(\cdot|s)$ 是由流策略在 $t=1$ 处诱导的动作分布。为了构建流策略，我们可以将其与条件概率路径 $p_t(\cdot|z) : [0, 1] \times \mathcal{P}(\mathbb{R}^d) \rightarrow \mathcal{P}(\mathbb{R}^d)$ 相关联，该路径是概率空间中两个分布 p_0 和 p_1 之间的时间索引插值。在其最简单的形式中，条件变量可以取端点 $z := (a_0, a_1)$ ，并且可以采用粒子级插值，即端点的凸组合，即 $a_t = (1-t)a_0 + ta_1$ 。我们称 ψ_t 生成 p_t ，如果它通过遵循方程 (1) 中的常微分方程将 p_0 前推到 p_1 。为了学习流策略，更容易对已知的目标条件速度 $v_t^*(a_t|z, s)$ 场进行回归，该场生成 p_t 。在获得这样的 v_t^* 后，可以使用条件流匹配损失 [Tong 等人, 2023; Albergo 等人, 2023; Liu 等人, 2022; Lipman 等人, 2022; Peluchetti, 2023] 进行学习，这是一个简单的无仿真回归目标：

$$\mathcal{L}_{\text{CFM}} = \mathbb{E}_{t, q(z), p_t(a_t|z, s)} \|v_t(a_t | s) - v_t^*(a_t | z, s)\|_2^2 = \mathbb{E}_{t, q(z), p_t(a_t|z, s)} \|v_t(a_t | s) - (a_1 - a_0)\|_2^2,$$

其中 $q(z)$ 是状态上的耦合——例如独立耦合 $q(z) = p_0(a_0)p_1(a_1)$ ——在最后一个等式中，我们将 $v^*(a_t | z, s) = a_1 - a_0$ 替换为其解析线性速度目标速度。

3 FLOW MAP Q -GUIDANCE

生成式策略在内时间轴上运行，即常微分方程仿真时间，这与马尔可夫决策过程的演化不同。因此，对于轨迹 s^τ 上的每个状态，必须通过流策略常微分方程（式 (1)）的数值仿真生成相应的动作 a_1^τ ——这需要大量策略网络的函数评估。接下来，我们通过学习流映射来解决这一计算低效问题，流映射通过沿常微分方程轨迹进行大步长跳跃，大幅加速仿真。本节其余部分安排如下：在 § 3.1 中，我们引入流映射策略，并在 § 3.2 中将其应用于离线强化学习。在 § 3.3 中，我们基于评论家的 Q 函数，利用信赖域严格设计了一种高效的在线自适应更新方法。最后，在 § 3.4 中，我们引入随机采样方法，在推理时细化生成的动作。

3.1 流映射策略

对于使用流匹配策略的高保真动作生成，模拟式 (1) 中参数化速度场的无穷小动力学仍然至关重要。本文不直接求解常微分方程，而是参数化并学习与流匹配策略相关的唯一双时间算子。

定义 3.1（流映射策略）。设 $\overline{X}_{r,t} : [0, 1]^2 \times \mathcal{S} \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ 为一个流映射，它在任意 $(r, t) \in [0, 1]$ 之间演化动作动态，并以马尔可夫决策过程状态 $s \in \mathcal{S}$ 为条件进行控制

根据方程 (1)，并满足跳跃条件 $X_{r,t}(a_r|s) = a_t$ 。流映射策略即为该映射在时刻 $t=1$ 处诱导的分布，其中 $\pi(a|s) = [X_{r,1}] \# p_r(a_r|s)$ 。

为了参数化诱导该策略的底层流映射，我们利用两个时间点 r, t 之间的平均动作速度 $u_{r,t} : [0, 1]^2 \times \mathcal{S} \times \mathbb{R}^d \rightarrow \mathbb{R}^d$ ，并满足条件 $r \leq t$ ：

$$X_{r,t}(a_r|s) = a_r + (t-r)u_{r,t}(a_r|s), \quad u_{r,t}(a_r|s) = \frac{1}{t-r} \int_r^t v_\tau(a_\tau|s) d\tau. \quad (2)$$

本文指出，利用公式 (2)，我们沿常微分方程轨迹进行大小为 $t-r$ 的跳跃。此外，在边界 $r=0$ 和 $t=1$ 处评估该流映射，可得到单步策略 $X_{0,1}$ 。本文还强调，瞬时速度对应于流匹配策略，可通过取时间极限恢复，从而得到切线条件： $\lim_{r \rightarrow t} \partial_t X_{r,t}(a_r|s) = u_{t,t}(a_t|s) := v_t(a_t|s)$ 。因此，这允许沿时间对角线 $r=t$ 提供监督信号，相当于经典流匹配。

$$\mathcal{L}_{\text{Diag}} = \mathbb{E}_{t,q(z),p_t(a_t|z,s)} \|u_{t,t}(a_t|s) - (a_1 - a_0)\|_2^2. \quad (3)$$

为了在非对角 $r < t$ 上训练底层流映射，我们遵循标准做法，强制实施一致性规则，这些规则源自满足流映射跳跃条件以及常微分方程的半群性质 [博菲等人, 2025年]。这导致了物理信息神经网络风格的 ℓ_2 -回归目标，通过强制流映射在非对角时间 $r < t$ 上的拉格朗日、欧拉和渐进条件，并结合停止梯度 sg，将近似常微分方程速度场蒸馏到 $X_{r,t}$ 中：

1. 拉格朗日策略蒸馏

$$\mathcal{L}_{\text{LPD}} = \int_0^1 \int_0^t \mathbb{E}_{p_r(a_r|z,s)} \left[|\partial_t X_{r,t}(a_r|s) - \text{sg}(u_{t,t}(X_{r,t}(a_r|s)))|^2 \right] dr dt, \quad (4)$$

2. 欧拉策略蒸馏

$$\mathcal{L}_{\text{EPD}} = \int_0^1 \int_0^t \mathbb{E}_{p_r(a_r|z,s)} \left[|\partial_r X_{r,t}(a_r|s) + \text{sg}(\nabla X_{r,t}(a_r|s) u_{r,r}(a_r|s))|^2 \right] dr dt, \quad (5)$$

3. 渐进式策略蒸馏。

$$\mathcal{L}_{\text{PPD}} = \int_0^1 \int_0^t \mathbb{E}_{p_r(a_r|z,s)} \left[|X_{w,t}(X_{r,w}(a_r|s)) - \text{sg}(X_{r,t}(a_r|s))|^2 \right] dr dt d\gamma, \quad (6)$$

where $w = (1-\gamma)r + \gamma t$ with $\gamma \in [0, 1]$.

与平均流策略的关系。关键的是，与先前工作形成对比，将策略学习等同于流映射解锁了基于流映射的学习目标的全部手段——其中平均流策略 [Geng 等人, 2025, Nguyen 和 Yoo, 2026, Zhan 等人, 2026] 是欧拉策略的一个具体实例。特别地，平均流策略可以作为上述公式 (5) 中概述的欧拉策略蒸馏目标的一个具体实例推导出来（见 § A.2），而瞬时速度约束是切线条件的应用，并且就是公式 (3) 中的对角损失。

3.2 基于流映射策略的离线强化学习

我们现在在演员-评论家框架内部署流映射策略用于离线到在线强化学习。我们首先在现有离线数据集 $\mathcal{D} = \{(s, a_1, r, s')\}$ 上预训练一个高效的流映射演员，以及一个评论家 Q 网络。我们将演员参数化为 $u_{r,t}(a_r|s)$ ，覆盖所有时间对 $(r, t) \in [0, 1]^2$ ，并使用 § 3.1 中的策略自蒸馏目标进行训练： $\mathcal{L}_{\text{actor}}^{\text{off}} = \mathcal{L}_{\text{Diag}} + \lambda \mathcal{L}_{\text{SD}}$ ，其中 $\mathcal{L}_{\text{SD}}$ 对应于任何策略自蒸馏损失， λ 是控制非对角训练强度的超参数。为了最大化动作生成效率，我们可以简单地调用流映射策略 $a_1 = X_{0,1}^{\text{off}}(a_0|s)$ ，并通过将先验噪声动作 a_0 直接传输到干净动作 a_1 一步生成动作：

$$a_1 = a_0 + u_{0,1}^{\text{off}}(a_0|s), \quad a_0 \sim \mathcal{N}(0, I). \quad (7)$$

我们通过带 EMA 目标 Q_{ϕ_j} 的裁剪双重 Q 学习来训练评论家 [Fujimoto 等人, 2018]：

$$\mathcal{L}_{\text{critic}}(\phi_j) = \mathbb{E}_{(s, a_1, r, s') \sim \mathcal{D}} \left[(Q_{\phi_j}(s, a_1) - y)^2 \right], \quad y = r + \gamma \min_{j=1,2} Q_{\phi_j}(s', X_{0,1}^{\text{off}}(a'_0|s')). \quad (8)$$

3.3 基于高效信任域的在线自适应

过渡到在线阶段引入了在训练生成策略时识别要模仿的最优动作的挑战：在没有精心整理的数据集的连续动作空间中，求解 $\arg \max_a Q(s, a)$ 作为学习目标是难以处理的。一种常见策略是“ N 中最佳”启发式方法，该方法从策略中抽取 N 个动作，并选择具有最高 Q 值的动作 [Zhan 等人, 2026]。然而，这种朴素策略带来了一个不小的缺点，即需要大量采样动作 N ，这至少需要 N 次流映射演员的一步仿真和 Q 函数评估。我们接下来开发一种更有原则的方法，通过构建信任域来找到最优动作。考虑一个流映射策略 $\pi^{\text{off}}(\cdot|s)$ ，在线自适应的自然问题是：

问：什么是使评论家 Q 函数最大化的最优扰动 Δ （针对 $a_1 \sim \pi^{\text{off}}$ ）？为回答这一问题，本文假设存在一个可行的最优动作 $a_1^* = a_1 + \Delta^*$ ，即通过扰动 Δ 可从流映射策略到达。为防止偏离 $a_1 \sim \pi^{\text{off}}(\cdot|s)$ 无界，本文在评论家当前 Q 值周围设置半径为 η 的信任域约束 Δ_{within} 。由此得到以下最大化评论家 Q 函数的非线性优化问题：

$$\arg \max_{\Delta} \mathbb{E}_{r \sim \mathcal{U}[0,1]} [Q_{\phi}(s, X_{0,r}^{\text{off}}(a_0 | s) + \Delta)] \quad \text{s.t.} \quad \|\Delta\|_2 \leq \eta \quad (9)$$

在 Δ -perturbation 被给定为平均速度网络 $u_{r,1}(a_r|s)$ 的情况下，在动作空间中约束扰动 $\|\Delta\|_2 \leq \eta$ 等价于对 $\|u_{r,1}(a_r|s) - u_{r,1}^{\text{off}}(a_r|s)\|_2$ 进行有界限制。由于评论家 Q 函数是非线性的，该优化问题难以求得闭式解。因此，本文考虑最优性的一阶近似，旨在为任意参考 $u_{r,1}^{\text{ref}}(a_r|s)$ 寻找最优目标位移。有趣的是，在这些设定下，最优目标位移的解析表达式具有闭式形式。

定理 3.2. 考虑一个流映射策略 $\pi^{\text{ref}}(\cdot|s)$ ，其底层流映射为 $X_{r,1}^{\text{ref}}$ ，生成动作 $a_1 = a_r + (1-r)u_{r,1}^{\text{ref}}(a_r|s)$ 。在信任域约束 $\|u_{r,1} - u_{r,1}^{\text{ref}}\|_2 \leq \eta$ 下，使 Q_{ϕ} 在 a_1 附近的一阶展开最大化的最优平均速度 $u_{r,1}^*$ 为：

$$u_{r,1}^*(a_r | s) = u_{r,1}^{\text{ref}}(a_r | s) + \eta \frac{\nabla_a Q_{\phi}(s, a_1)}{\|\nabla_a Q_{\phi}(s, a_1)\|_2}. \quad (10)$$

证明概要。为在 Q_{ϕ} 上最大化 $u_{r,1}$ ，我们将流映射参数化代入围绕 a_1 的一阶泰勒展开，从而将问题简化为在 $\langle \nabla_a Q_{\phi}(s, a_1), u_{r,1} - u_{r,1}^{\text{ref}} \rangle$ 的约束下最大化 $\|u_{r,1} - u_{r,1}^{\text{ref}}\|_2 \leq \eta$ 。求解相应的 KKT 条件即可得到最优闭式解。完整证明见 § A.1。 $\square$

定理 3.2 对任意参考流图策略均成立。令 $\pi^{\text{ref}} = \pi^{\text{off}}$ ，即锚定于离线流图速度 $u_{r,1}(a_r|s)$ ，可得如下最优平均速度：

$$u_{r,1}^*(a_r|s) = u_{r,1}^{\text{off}}(a_r|s) + \eta \frac{\nabla_a Q_{\phi}(s, a_1)}{\|\nabla_a Q_{\phi}(s, a_1)\|_2}. \quad (11)$$

公式 (11) 的解析形式使我们能够构建一个用于高效在线自适应的学习目标，我们称之为流 MAP Q 引导 (FMQ)。具体而言，我们利用噪声 $a_0 \sim \mathcal{N}(0, I)$ 和来自重放缓冲区 $a_{\text{data}} \sim \mathcal{D}$ 的动作来构造插值 $a_r = (1-r)a_0 + r a_{\text{data}}$ 。这使得随后能够将 $u_{r,1}(a_r|s)$ 回归到以下最优自举信任区域目标：

$$\mathcal{L}_{\text{FMQ}}(\theta) = \mathbb{E}_{r, a_0, a_{\text{data}}} \left[\left\| u_{r,1}^{\theta}(a_r) - \text{sg} \left(u_{r,1}^{\text{off}}(a_r) + \eta \frac{\nabla_a Q_{\phi}(s, a_1)}{\|\nabla_a Q_{\phi}(s, a_1)\|_2 + \kappa_1} \right) \right\|_2^2 \right], \quad (12)$$

其中 $\text{sg}(\cdot)$ 为停止梯度算子， $\kappa_1 > 0$ 为算法 1 中所述的稳定性常数。

不确定性感知的自适应信任区域 固定半径 η 无论批评家置信度如何都施加相同的步长。我们现在制定一个由廉价启发式驱动的自适应逐样本 η 半径，该启发式通过捕捉批评家集成中的认知不确定性来驱动。给定一个双 define $\delta_{\text{critic}}(s, a) = \frac{1}{\sqrt{2}} |Q_{\phi_1}(s, a) - Q_{\phi_2}(s, a)|$ 批评家集成，我们捕捉批评家之间的绝对差异 Q -values 这使我们能够设计一个批量归一化的逐样本有效信任区域，

$$\eta_{\text{eff}}(s, a) = \frac{1}{1 + \beta \tilde{\delta}_{\text{critic}}(s, a)}, \quad \tilde{\delta}_{\text{critic}}(s, a) = \frac{\delta_{\text{critic}}(s, a)}{\frac{1}{B} \sum_{i=1}^B \delta_{\text{critic}}(s_i, a_i) + \kappa_2}, \quad (13)$$

其中 $\kappa_2 > 0$ 是一个小常数， β 是一个超参数。通过构造， $\eta_{\text{eff}} \in (0, 1]$ 随幅度 $\delta_{\text{critic}}(s, a)$ 单调衰减：较小的差异 δ_{critic} 导致更大的步长，而相反较大的差异 δ_{critic} 导致优先考虑离线流映射执行器。

3.4 Q 推理时 引导搜索

流映射策略诱导了一个映射，该映射传输噪声动作边缘分布 $[X_{r,t}] \# p_r = p_t$ 对于所有 $r, t \in [0, 1]$ 。该映射从根本上无法捕捉同时最大化批评家 Q 值的端点上的条件后验。因此， a_0 的初始采样可能对等式 (9) 中优化问题的解产生不成比例的影响。我们没有训练一个单独的随机流映射来进行奖励对齐 [Potapchik et al., 2026, Holderrieth et al., 2026]，而是选择了一种纯推理时搜索策略。具体来说，我们接下来为流映射执行器构建一个随机采样器，该采样器也利用了批评家 Q 值的信任区域。

基于信噪比的随机采样 为了设计随机采样器，我们利用基于信噪比 (SNR) 的重新加噪策略。具体而言，给定在线后的一步流映射执行器

自适应 $a_1 = X_{0,1}^{\text{adapt}}(a_0|s)$ ，我们可以通过审慎地选择一个新的时间来进行重新加噪，因此，我 $t' < 1$ 。To do 们通过选择 $t' = \text{信噪比} / (1 + \text{信噪比}) \in (0, 1)$ 来设计重新加噪插值：

$$a_{t'} = t' \cdot a_1 + (1 - t') \cdot \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, I), \quad (14)$$

流映射的第二次应用随后将该中间状态传输回时间 $t = 1$, i.e., $\tilde{a}_1 = X_{t',1}^{\text{adapt}}(a_{t'} | s)$ 。关键的是，每次抽取 ε 都会产生不同的动作 $\tilde{a}_1$ ——这是来自流映射的随机样本，可以对其重新应用信赖域更新。因此，该方法在推理过程中定义了一种迭代细化程序：(1) 我们使用公式 (14) 将当前动作 a_1 破坏为 t' ，从而获得多样化的动作和噪声中间状态 $a_{t'}$ ，然后 (2) 对每个新样本重新应用最优信赖域 Q 值投影，得到 $\tilde{a}_1$ 。噪声水平 t' 控制探索与利用之间的平衡：较小的 t' （低信噪比）使 $a_{t'}$ 更接近纯噪声，允许流映射探索较远的模式。相反，较大的 t' （高信噪比）保留了当前动作 a_1 的大部分，将更新限制在更局部的细化范围内。

Q 引导的束搜索。我们现在概述一种推理时搜索策略，该策略将随机采样器与束搜索相结合。这种新算法仅在推理时部署一次——即通过搜索实现推理时扩展——因此不会影响在线更新的训练速度。我们在算法 2 中给出了完整的算法描述。我们将这一新的最终推理过程实例化为 Q 引导束搜索 (QGBS)，它在探索与利用之间取得平衡。具体而言，QGBS 在 M 个粒子上运行，这些粒子沿着已经在线适应的流映射策略轨迹在 K 步内逐步细化。总之，该算法迭代地执行以下两个步骤：1. 探索：QGBS 的第一步构成探索阶段，将候选的 N 个动作多样化，生成一批 B 个中间状态，进而产生总共 $\bigcup_{i=1}^{N \cdot B} X_{t',1}^{\text{adapt}}(a'_i|s)$ 动作。2. 利用：第二步使用评论家 $Q_\phi(s, \tilde{a}_1)$ ，选择最有前景的 M 个粒子，然后在进入下一个束之前，将这些粒子用于信赖域更新（公式 (11)）。

经过 K 步后，该过程返回 $\arg \max_i Q_\phi(s, a_i)$ 。当 $K=0$ 时，该方法简化为最佳 M Q 引导（定理 3.2 的单次应用，无迭代）。

4 实验

我们研究了流匹配强化学习 (FMQ) 在 12 项机器人操作与运动任务中的应用，这些任务来自 OGBench [Park 等人, 2024] 和 Robomimic [Mandlekar 等人, 2021] 基准中的 7 个环境，难度各异。操作任务包括来自 Robomimic 的两项（罐子、方块）和来自 OGBench 的六项（立方体双转三/四、立方体三转三/四、场景四/五）。运动任务在四项 OGBench 任务（人形迷宫中等三/四、蚂蚁迷宫通用四/五）上进行评估。在离线预训练期间，我们为 Robomimic 使用多人类演示数据集，为 OGBench 使用默认的噪声专家数据集（游戏风格和导航）。此外，我们利用单任务 OGBench 变体进行离线到在线强化学习。人形和蚂蚁迷宫任务使用稀疏奖励，其余任务使用密集奖励。为清晰起见，我们在 § H 中报告完整的训练配置和实验设置。

基线。我们将流匹配强化学习 (FMQ) 与两个主要基线进行比较：(1) 质量批评 (QC) [李等人, 2025 年] 训练一个具有 10 个积分步骤的多步流匹配策略。(2) 作为第二个基线，我们报告最先进的




图 2: 6 个环境上的训练曲线。在 1M 离线步骤后接 1M 在线步骤的过程中，每 100K 步的平均成功率，基于 5 个随机种子。阴影区域表示 95% 置信区间。

方法最有价值策略 (MVP) [詹等人, 2026], 该方法训练一个具有初始速度约束的平均流策略。对于最有价值策略 (MVP), 我们区分 MVP* 为直接取自原始论文的结果, 该结果仅在本文考虑的 6/12 环境中可用, 以及我们的复现 MVP, 使我们能够研究所有考虑的环境。所有基线共享相同的模型架构, 并遵循相同的截断双重 Q 学习算法 [藤本等人, 2018]。在推理时, 质量批评 (QC)、最有价值策略 (MVP) 和我们的方法流匹配强化学习 (FMQ) 均通过 32 次最佳采样选择动作, 选择具有最高 Q 值的动作。

评估协议。我们遵循 Park 等人提出的标准离线到在线协议 [2024]: 使用提供的数据集进行 100 万梯度步的离线预训练, 随后进行 100 万步的在线微调并与环境交互。在线阶段, 新收集的转移样本被追加到回放缓冲区中。为了监控训练过程, 我们每 10 万步在 50 个随机初始状态的回合上评估策略。最后, 我们在每个环境的 50 个未见测试回合上评估最后一个检查点, 计算 5 个随机种子上的平均成功率, 并报告四分位均值 (IQM) 以及 95% 分层自助置信区间 [Agarwal 等人, 2021]。

4.1 主要结果

我们在表 1 中报告了主要定量结果, 并观察到 FMQ 取得了最高的 IQM 分数 (0.91; [0.89, 0.93]), 比 MVP 高出 21.3% (0.75; [0.73, 0.77]), 比 QC 高出 5.8% (0.86; [0.84, 0.87])。在具有挑战性的环境中, 改进最为显著: 在 cube-trl-t4 上, FMQ 达到 0.88, 而 QC 为 0.37, MVP 为 0.32; 在 amaze-gnt-t4 上, FMQ 达到 0.80, 而 QC 和 MVP 分别为 0.64 和 0.42。我们还注意到, QC 平均表现优于 MVP (0.76 vs. 0.68), 但这是以推理时模拟流而非一步生成所带来的 $10\times$ 计算开销为代价的。尽管如此, 我们发现 FMQ 仅使用单步生成就在 10/12 个环境中优于 QC。这些结果表明, 与 best-of- N 相比, 在 FMQ 中利用最优 Q 引导具有明显优势。

推理扩展。为评估我们的补充贡献 Q 引导束搜索 (QGBS), 该算法可作为随机采样器应用于任何流映射策略, 包括基线方法 MVP。我们引入两种额外配置: MVP + QGBS 和 FMQ + QGBS。具体而言, 我们在推理时用随机采样算法替换 best-of- N 采样, 该算法与束搜索 ($K = 1, B = 4, M = 4$) 相结合, 并在 § 3.4 中概述。总体而言, 应用 QGBS 后, 我们观察到 IQM 相对提升了 8.0% (从 0.75 提升至 0.81)




图 3: 在成功目标 (ξ) 下, FMQ 相比 MVP 的收敛加速情况, 附 95% 置信区间。

表 1: 成功率 (5 个随机种子、50 个回合的均值 $\pm$ 标准差)。每行最佳值加粗, 次佳值加下划线。聚合性能以 IQM 分数及 95% 置信区间衡量。

Environment	QC	MVP*	MVP	MVP + QGBS (Ours)	FMQ (Ours)	FMQ + QGBS (Ours)
can	0.88 $\pm$ 0.06	0.92 $\pm$ 0.07	0.83 $\pm$ 0.07	0.87 $\pm$ 0.07	0.96 $\pm$ 0.04	0.97 $\pm$ 0.03
square	0.89 $\pm$ 0.04	0.93 $\pm$ 0.01	0.82 $\pm$ 0.04	0.83 $\pm$ 0.05	0.94 $\pm$ 0.02	0.95 $\pm$ 0.04
cube-dbl-t3	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00
cube-dbl-t4	0.92 $\pm$ 0.05	0.95 $\pm$ 0.04	0.98 $\pm$ 0.02	0.98 $\pm$ 0.02	0.98 $\pm$ 0.02	1.00 $\pm$ 0.00
cube-trl-t3	0.83 $\pm$ 0.08	0.71 $\pm$ 0.06	0.64 $\pm$ 0.12	0.78 $\pm$ 0.12	0.78 $\pm$ 0.10	0.84 $\pm$ 0.04
cube-trl-t4	0.37 $\pm$ 0.26	0.52 $\pm$ 0.11	0.32 $\pm$ 0.07	0.37 $\pm$ 0.09	0.88 $\pm$ 0.07	0.87 $\pm$ 0.05
scene-t4	0.99 $\pm$ 0.01	—	0.92 $\pm$ 0.02	0.98 $\pm$ 0.02	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01
scene-t5	0.96 $\pm$ 0.02	—	0.90 $\pm$ 0.06	0.95 $\pm$ 0.05	0.98 $\pm$ 0.02	1.00 $\pm$ 0.00
hmaze-med-t3	0.65 $\pm$ 0.11	—	0.47 $\pm$ 0.10	0.53 $\pm$ 0.03	0.69 $\pm$ 0.04	0.58 $\pm$ 0.07
hmaze-med-t4	0.04 $\pm$ 0.03	—	0.00 $\pm$ 0.00	0.02 $\pm$ 0.02	0.06 $\pm$ 0.03	0.06 $\pm$ 0.03
amaze-gnt-t4	0.64 $\pm$ 0.12	—	0.42 $\pm$ 0.06	0.43 $\pm$ 0.04	0.80 $\pm$ 0.06	0.77 $\pm$ 0.03
amaze-gnt-t5	0.91 $\pm$ 0.05	—	0.82 $\pm$ 0.08	0.90 $\pm$ 0.06	0.92 $\pm$ 0.04	0.92 $\pm$ 0.05
IQM SR [95% CI] 0.86 [0.84, 0.87] — 0.75 [0.73, 0.77] 0.81 [0.78, 0.83] 0.91 [0.89, 0.93] 0.93 [0.91, 0.94]						

对于 MVP, 相对提升幅度为 2.2 % (从 0.91 到 0.93) 对于 FMQ。然而, 对于少数运动任务 (hmaze-med-t3 和 amaze-gnt-t4), QGBS 使性能分别下降了 15.9 % 和 3.8 %。总体而言, 我们发现将我们提出的训练和推理算法 FMQ + QGBS 相结合可获得最佳性能, 达到最高的 IQM 为 0.93; [0.91, 0.94], 其置信区间与所有基线 (包括 QC (0.86; [0.84, 0.87]) 和 MVP (0.75; [0.73, 0.77]))。这些结果凸显了通过随机采样和束搜索在推理阶段增加计算预算对性能的影响。

4.2 样本效率分析

接下来, 我们研究使用 Q 引导训练流映射策略所带来的样本效率提升。在图 2 中, 我们绘制了 6 个环境中所有方法在线适应阶段的训练曲线 (完整结果见图 17)。我们发现, 尽管 MVP 和 FMQ 均从相同的离线检查点开始, 但在线微调期间 FMQ 始终比 MVP 收敛更快。为量化这一优势, 我们定义 ξ 为 MVP 和 FMQ 在每个种子和环境下可达到的最高成功率。在表 4 中, 我们测量加速比 T : 首次达到 {75%, 85%, 95%, 100%} 的 ξ 所需步数。加速比 $T_{\text{MVP}}/T_{\text{FMQ}}$ 在 5 个种子上取平均, 量化了 FMQ 收敛到 ξ 各分数点的速度倍数。在线阶段 (1M – 2M), FMQ 平均比 MVP 快 $2.77\times$ 达到 MVP 可达到的最高成功率, 在 hmaze-med-t3 上最高可达 $6.14\times$ 。这些结果进一步证实, Q 梯度对齐提供了比 N 选优更强的学习信号, 从而在每个环境步骤中实现更快的策略改进。

4.3 消融研究

表 2: QGBS 效率消融。

	$K \setminus \{B, M\}$	NFE	IQM
推理时束搜索。利用 QGBS 的计算成本为每次动作选择 $NFE = M(1 + KB)$, 其中 M 为初始候选数量, K 为重噪声化步数, B 为每个候选的补全次数。本文指出, 最优 N 采样对应于 $K=0$ 和 $M=N$ 。在表 2 中, 本文展示了最优配置 ($K=1, B=4, M=4$) 仅用 20 次函数评估即达到峰值 IQM 0.93 ——比最优 32 采样少 37.5 %——这表明通过重噪声化使候选多样化比考虑更多候选更高效。将 K 增加到 1 以上并不能提升性能, 这表明仅需适度增加推理成本即可达到最优性能。	0 {1, 32}	32	0.91 [0.89, 0.93]
	1 {4, 4}	20	0.93 [0.91, 0.94]
	1 {2, 8}	24	0.93 [0.91, 0.95]
	1 {1, 16}	32	0.92 [0.90, 0.93]
	1 {4, 16}	80	0.92 [0.90, 0.93]
	2 {4, 4}	36	0.91 [0.90, 0.93]
到 1 以上并不能提升性能, 这表明仅需适度增加推理成本即可达到最优性能。	2 {1, 16}	48	0.90 [0.89, 0.92]
	2 {4, 16}	144	0.90 [0.89, 0.91]

信赖域收敛性分析 我们评估了式 (12) 中信赖域的影响。具体而言, 我们测量在线策略相对于冻结离线策略的距离 $\|u_{r,1}^{\text{on}} - u_{r,1}^{\text{off}}\|_2$ 。在线训练开始时, 在线和离线速度场重合, 距离为 0。随着在线训练开始, 学习主动驱动 $u_{r,1}^{\text{on}}$ 朝向

$$u^{\text{off}} \text{——如图中所示。} \quad + \eta \nabla_a Q_\phi(s, a_1) / \|\nabla_a Q_\phi(s, a_1)\|_2 \quad 4\text{——}$$

并稳定在 η_{eff} 附近。因此, 流映射

策略融入了归一化的 Q 梯度方向, 同时安全地约束在信赖域半径内 (参见图 18 了解所有环境)。




图 4: 在 3 个环境上在线训练的收敛情况。在线和离线流映射策略之间的距离（蓝色）收敛到自适应半径 η_{eff} （红色），因为策略融入了 Q 引导。

流映射策略变体。接下来，我们消融离线流映射策略变体及其对性能的影响。在表 3 中，ESD 和 LSD 达到相同的 IQM 0.79，而 PSD 略低，为 0.77。然而，ESD 表现出最窄的 95% 自助置信区间 $[0.77, 0.81]$ ，表明它在各环境中最为一致。因此，我们采用 ESD 作为展示结果的默认公式。

5 相关工作

生成式策略 扩散模型和流匹配已成为表达性策略表示 [Chi 等人, 2023, Pearce 等人, 2023]。对于策略学习，先前的方法通过加权行为克隆 [Lu 等人, 2023, Kang 等人, 2023]、重参数化策略梯度 [Wang 等人, 2023, Ding 和 Jin, 2023, Zhang 等人, 2024] 以及拒绝采样 [Chen 等人, 2024, Hansen-Estruch 等人, 2023, He 等人, 2024] 来训练扩散和流匹配模型。虽然有效，但重参数化梯度需要昂贵的通过时间的反向传播（BPTT）。为了解决流匹配多步模型的延迟问题，FQL [Park 等人, 2025] 将多步流蒸馏到一个单独的一步学生网络中，而 QC [Li 等人, 2025] 对动作序列进行分组。MVP [Zhan 等人, 2026] 原生实现了一步生成，但使用“生成-选择”启发式方法来寻找模仿目标。相比之下，我们将一步流映射策略形式化，并利用 FMQ 实现更高效的在线适应。

离线到在线强化学习。离线到在线强化学习通过从静态数据集初始化来加速在线学习 [莱文等人, 2020]。然而，离线强化学习必须应对分布外动作的 Q 值高估问题，可通过发散惩罚 [藤本等人, 2019, 吴等人, 2019, 奈尔和达拉尔, 2020, 王等人, 2023]、悲观价值估计 [库马尔等人, 2020, 于等人, 2020, 安等人, 2021] 或样本内最大化 [科斯特里科夫等人, 2022, 加格等人, 2023] 来解决。在过渡到在线阶段时，分布偏移可能导致行为先验的灾难性遗忘 [李等人, 2022, 宋等人, 2023, 中本等人, 2023]。最近最先进的流匹配方法依赖行为正则化 [帕克等人, 2025] 或最佳 N 选择 [李等人, 2025, 詹等人, 2026] 来稳定适应过程。相比之下，本文将在线微调形式化为一个带有 FMQ 的信任域问题。

表 3: 自蒸馏损失消融。环境 ESD PSD LSD

Environment	ESD	PSD	LSD
cube-trl-t3	0.79 $\pm$ 0.06	0.74 $\pm$ 0.13	0.84 $\pm$ 0.09
cube-trl-t4	0.90 $\pm$ 0.05	0.87 $\pm$ 0.09	0.88 $\pm$ 0.06
hmaze-med-t3	0.64 $\pm$ 0.02	0.48 $\pm$ 0.29	0.62 $\pm$ 0.09
hmaze-med-t4	0.03 $\pm$ 0.03	0.04 $\pm$ 0.04	0.06 $\pm$ 0.00
amaze-gnt-t4	0.82 $\pm$ 0.02	0.86 $\pm$ 0.04	0.78 $\pm$ 0.06
amaze-gnt-t5	0.92 $\pm$ 0.01	0.87 $\pm$ 0.05	0.91 $\pm$ 0.03
IQ	0.79 [0.77, 0.81]	0.77 [0.70, 0.81]	0.79 [0.75, 0.82]

6 结论

本文弥合了表达性生成策略与离线到在线强化学习的低延迟需求之间的差距。本文将一步流映射策略的在线适应形式化为信任域优化问题，得到 FLOW MAP Q -GUIDANCE (FMQ)：一种闭式、局部最优的 Q 引导更新，在改进线性化评论家的同时保持锚定于离线行为先验。本文进一步引入 QGBS，一种基于随机重噪和束搜索的推理时细化过程，可改进任何流映射策略。在 OGBench 和 RoboMimic 的 12 个连续控制任务中，FMQ 建立了最先进的性能，在 IQM 成功率上以 21.3% 的相对优势超越了之前领先的一步策略 MVP。虽然 FMQ 享有高效的线性化评论家近似，但其有效性依赖于评论家准确性和局部线性。将流映射适应扩展到曲率感知更新、更强的不确定性估计以及在物理机器人平台上的部署，是未来工作有前景的方向。

致谢

我们感谢 Jorge de Freitas 对早期草稿的有益评论，以及 Luca Eyring 关于重噪的深刻讨论。这项工作得到了 UKRI (EP/Y037111/1) 的支持，作为 ProSafe 项目（欧盟地平线 2020，MSCA，资助号 101119358）的一部分。

参考文献

- R. Agarwal, M. Schwarzer, P. S. Castro, A. C. Courville, and M. Bellemare. Deep reinforcement learning at the edge of the statistical precipice. *Advances in neural information processing systems*, 34:29304–29320, 2021. (Cited on page 7)
- M. S. Albergo, N. M. Boffi, and E. Vanden-Eijnden. Stochastic interpolants: A unifying framework for flows and diffusions, 2023. URL <https://arxiv.org/abs/2303.08797>. (Cited on pages 1 and 3)
- G. An, S. Moon, J.-H. Kim, and H. O. Song. Uncertainty-based offline reinforcement learning with diversified q-ensemble. *Advances in neural information processing systems*, 34:7436–7447, 2021. (Cited on page 9)
- N. M. Boffi, M. S. Albergo, and E. Vanden-Eijnden. How to build a consistency model: Learning flow maps via self-distillation, 2025. URL <https://arxiv.org/abs/2505.18825>. (Cited on page 4)
- T. Chen, Z. Wang, and M. Zhou. Diffusion policies creating a trust region for offline reinforcement learning. *Advances in Neural Information Processing Systems*, 37:50098–50125, 2024. (Cited on page 9)
- C. Chi, S. Feng, Y. Du, Z. Xu, E. Cousineau, B. Burchfiel, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. In *Robotics: Science and Systems*, 2023. (Cited on page 9)
- C. Chi, Z. Xu, S. Feng, E. Cousineau, Y. Du, B. Burchfiel, R. Tedrake, and S. Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025. (Cited on page 1)
- O.-E. Collaboration, A. O’Neill, A. Rehman, A. Gupta, A. Maddukuri, A. Gupta, A. Padalkar, A. Lee, A. Pooley, A. Gupta, et al. Open x-embodiment: Robotic learning datasets and rt-x models. *arXiv preprint arXiv:2310.08864*, 1(2), 2023. (Cited on page 1)
- Z. Ding and C. Jin. Consistency models as a rich and efficient policy class for reinforcement learning. *arXiv preprint arXiv:2309.16984*, 2023. (Cited on page 9)
- J. Fu, A. Kumar, O. Nachum, G. Tucker, and S. Levine. D4rl: Datasets for deep data-driven reinforcement learning. *arXiv preprint arXiv:2004.07219*, 2020. (Cited on page 1)
- S. Fujimoto and S. S. Gu. A minimalist approach to offline reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 34, pages 20132–20145, 2021. (Cited on page 1)
- S. Fujimoto, H. van Hoof, and D. Meger. Addressing function approximation error in actor-critic methods. In *International Conference on Machine Learning*, 2018. URL <https://api.semanticscholar.org/CorpusID:3544558>. (Cited on pages 4, 7, and 22)
- S. Fujimoto, D. Meger, and D. Precup. Off-policy deep reinforcement learning without exploration. In *International Conference on Machine Learning*, pages 2052–2062. PMLR, 2019. (Cited on page 9)
- D. Garg, J. Hejna, M. Geist, and S. Ermon. Extreme q-learning: Maxent rl without entropy. In *International Conference on Learning Representations*, 2023. (Cited on page 9)
- Z. Geng, M. Deng, X. Bai, J. Z. Kolter, and K. He. Mean flows for one-step generative modeling, 2025. URL <https://arxiv.org/abs/2505.13447>. (Cited on page 4)
- P. Hansen-Estruch, I. Kostrikov, M. Janner, J. G. Kuba, and S. Levine. Idql: Implicit q-learning as an actor-critic method with diffusion policies. *arXiv preprint arXiv:2304.10573*, 2023. (Cited on page 9)

- L. He, L. Shen, and X. Wang. Alignql: Policy alignment in implicit q-learning through constrained optimization. *arXiv preprint arXiv:2405.18187*, 2024. (Cited on page 9)
- P. Holderrieth, D. Chen, L. Eyring, I. Shah, G. Anantharaman, Y. He, Z. Akata, T. Jaakkola, N. M. Boffi, and M. Simchowitz. Diamond maps: Efficient reward alignment via stochastic flow maps. *arXiv preprint arXiv:2602.05993*, 2026. (Cited on page 6)
- N. Jaques, A. Ghandeharioun, J. H. Shen, C. Ferguson, A. Lapedriza, N. Jones, S. Gu, and R. Picard. Way off-policy batch deep reinforcement learning of implicit human preferences in dialog. *arXiv preprint arXiv:1907.00456*, 2019. (Cited on page 1)
- G. Kahn, A. Villaflor, P. Abbeel, and S. Levine. Composable action-conditioned predictors: Flexible off-policy learning for robot navigation. In *Conference on robot learning*, pages 806–816. PMLR, 2018. (Cited on page 1)
- B. Kang, X. Ma, C. Du, T. Pang, and S. Yan. Efficient diffusion policies for offline reinforcement learning. *Advances in Neural Information Processing Systems*, 36:67195–67212, 2023. (Cited on page 9)
- I. Kostrikov, A. Nair, and S. Levine. Offline reinforcement learning with implicit q-learning. In *International Conference on Learning Representations*, 2022. (Cited on page 9)
- A. Kumar. Data-driven deep reinforcement learning. *Berkeley Artificial Intelligence Research (BAIR), Tech. Rep.*, 2019. (Cited on page 1)
- A. Kumar, A. Zhou, G. Tucker, and S. Levine. Conservative q-learning for offline reinforcement learning. In *Advances in Neural Information Processing Systems*, volume 33, pages 1179–1191, 2020. (Cited on page 9)
- J. Lee, C. Paduraru, D. J. Mankowitz, N. Heess, D. Precup, K.-E. Kim, and A. Guez. Offline-to-online reinforcement learning via balanced replay and pessimistic q-ensemble. In *Conference on Robot Learning*, pages 1602–1612. PMLR, 2022. (Cited on page 9)
- S. Levine, A. Kumar, G. Tucker, and J. Fu. Offline reinforcement learning: Tutorial, review, and perspectives on open problems. *arXiv preprint arXiv:2005.01643*, 2020. (Cited on pages 1 and 9)
- Q. Li, Z. Zhou, and S. Levine. Reinforcement learning with action chunking. *arXiv preprint arXiv:2507.07969*, 2025. (Cited on pages 6, 9, and 22)
- Y. Lipman, R. T. Chen, H. Ben-Hamu, M. Nickel, and M. Le. Flow matching for generative modeling. *arXiv preprint arXiv:2210.02747*, 2022. (Cited on pages 1 and 3)
- X. Liu, C. Gong, and Q. Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022. (Cited on pages 1 and 3)
- C. Lu, Y. Hu, et al. Contrastive energy prediction for exact energy-guided diffusion sampling in offline reinforcement learning. In *International Conference on Machine Learning*. PMLR, 2023. (Cited on page 9)
- A. Mandlekar, D. Xu, J. Wong, S. Nasiriany, C. Wang, R. Kulkarni, L. Fei-Fei, S. Savarese, Y. Zhu, and R. Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. *arXiv preprint arXiv:2108.03298*, 2021. (Cited on page 6)
- A. Nair and M. r. l. w. o. d. Dalal. Accelerating online reinforcement learning with offline datasets. *arXiv preprint arXiv:2006.09359*, 2020. (Cited on page 9)
- M. Nakamoto, Y. Zhai, A. Singh, M. Radin, A. Kumar, C. Finn, and S. Levine. Cal-ql: Calibrated offline rl pre-training for efficient online fine-tuning. In *Advances in Neural Information Processing Systems*, volume 36, 2023. (Cited on page 9)
- T. X. Nguyen and C. D. Yoo. One-step flow q-learning: Addressing the diffusion policy bottleneck in offline reinforcement learning. In *The Fourteenth International Conference on Learning Representations*, 2026. (Cited on page 4)

- S. Park, K. Frans, B. Eysenbach, and S. Levine. Ogbench: Benchmarking offline goal-conditioned rl. *arXiv preprint arXiv:2410.20092*, 2024. (Cited on pages 6 and 7)
- S. Park, Q. Li, and S. Levine. Flow q-learning. In *International Conference on Machine Learning (ICML)*, 2025. (Cited on pages 2 and 9)
- T. Pearce, T. Rashid, A. Kanervisto, D. Bignell, M. Sun, R. Georgescu, S. V. Macua, S. Z. Tan, I. Momennejad, K. Hofmann, and S. Devlin. Imitating human behaviour with diffusion models. *ArXiv*, abs/2301.10677, 2023. URL <https://api.semanticscholar.org/CorpusID:256231177>. (Cited on page 9)
- S. Peluchetti. Non-denoising forward-time diffusions. *arXiv preprint arXiv:2312.14589*, 2023. (Cited on page 3)
- P. Potapchik, A. Saravanan, A. Mammadov, A. Prat, M. S. Albergo, and Y. W. Teh. Meta flow maps enable scalable reward alignment. *arXiv preprint arXiv:2601.14430*, 2026. (Cited on page 6)
- J. Sohl-Dickstein, E. Weiss, N. Maheswaranathan, and S. Ganguli. Deep unsupervised learning using nonequilibrium thermodynamics. In *International conference on machine learning*, pages 2256–2265. pmlr, 2015. (Cited on page 1)
- Y. Song, J. Sohl-Dickstein, D. P. Kingma, A. Kumar, S. Ermon, and B. Poole. Score-based generative modeling through stochastic differential equations. *arXiv preprint arXiv:2011.13456*, 2020. (Cited on page 1)
- Y. Song, Y. Zhou, A. Sekhari, J. A. Bagnell, A. Krishnamurthy, and W. Sun. Hybrid rl: Using both offline and online data can make rl efficient. In *International Conference on Learning Representations*, 2023. (Cited on page 9)
- R. S. Sutton and A. G. Barto. *Reinforcement learning: An introduction*, volume 1. MIT press Cambridge, 1998. (Cited on page 2)
- D. Tarasov, V. Kurenkov, A. Nikulin, and S. Kolesnikov. Revisiting the minimalist approach to offline reinforcement learning. *Advances in Neural Information Processing Systems*, 36:11592–11620, 2023. (Cited on page 1)
- A. Tong, K. Fatras, N. Malkin, G. Huguette, Y. Zhang, J. Rector-Brooks, G. Wolf, and Y. Bengio. Improving and generalizing flow-based generative models with minibatch optimal transport. *arXiv preprint arXiv:2302.00482*, 2023. (Cited on page 3)
- Z. Wang, J. J. Hunt, and M. Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. *arXiv preprint arXiv:2208.06193*, 2022. (Cited on page 1)
- Z. Wang, J. J. Hunt, and M. Zhou. Diffusion policies as an expressive policy class for offline reinforcement learning. In *International Conference on Learning Representations*, 2023. (Cited on page 9)
- Y. Wu, G. Tucker, and O. Nachum. Behavior regularized offline reinforcement learning. *arXiv preprint arXiv:1911.11361*, 2019. (Cited on page 9)
- L. Yang, Z. Huang, F. Lei, Y. Zhong, Y. Yang, C. Fang, S. Wen, B. Zhou, and Z. Lin. Policy representation via diffusion probability model for reinforcement learning. *arXiv preprint arXiv:2305.13122*, 2023. (Cited on page 2)
- T. Yu, G. Thomas, L. Yu, S. Ermon, J. Zou, S. Levine, C. Finn, and T. Ma. Mopo: Model-based offline policy optimization. In *Advances in Neural Information Processing Systems*, volume 33, pages 14129–14142, 2020. (Cited on page 9)
- G. Zhan, Y. Jiang, S. E. Li, Y. Lyu, X. Zhang, and Y. Yin. A transformation-aggregation framework for state representation of autonomous driving systems. *IEEE Transactions on Intelligent Transportation Systems*, 25(7):7311–7322, 2024. (Cited on page 2)
- G. Zhan, X. An, Y. Jiang, J. Duan, H. Zhao, and S. E. Li. Physics informed neural pose estimation for real-time shape reconstruction of soft continuum robots. *IEEE Robotics and Automation Letters*, 2025. (Cited on page 2)

- G. Zhan, L. Tao, P. Wang, Y. Wang, Y. Li, Y. Chen, H. Li, M. Tomizuka, and S. E. Li. Mean flow policy with instantaneous velocity constraint for one-step action generation. *arXiv preprint arXiv:2602.13810*, 2026. (Cited on pages [2](#), [4](#), [5](#), [7](#), [9](#), [15](#), and [23](#))
- R. Zhang, Z. Luo, J. Sjölund, T. B. Schön, and P. Mattsson. Entropy-regularized diffusion policy with q-ensembles for offline reinforcement learning. *Advances in neural information processing systems*, 37:98871–98897, 2024. (Cited on page [9](#))
- Z. Zhu, H. Zhao, H. He, Y. Zhong, S. Zhang, H. Guo, T. Chen, and W. Zhang. Diffusion models for reinforcement learning: A survey. *arXiv preprint arXiv:2311.01223*, 2023. (Cited on page [1](#))

A 理论细节

A.1 Proofs

定理 3.2. 考虑一个流映射策略 $\pi^{ref}(\cdot|s)$ ，其底层流映射为 $X_{r,1}^{ref}$ ，生成动作 $a_1 = a_r + (1-r)u_{r,1}^{ref}(a_r|s)$ 。在信任域约束 $\|u_{r,1} - u_{r,1}^{ref}\|_2 \leq \eta$ 下，使 Q_ϕ 在 a_1 附近的一阶展开最大化的最优平均速度 $u_{r,1}^*$ 为：

$$u_{r,1}^*(a_r|s) = u_{r,1}^{ref}(a_r|s) + \eta \frac{\nabla_a Q_\phi(s, a_1)}{\|\nabla_a Q_\phi(s, a_1)\|_2}. \quad (10)$$

证明。我们寻求生成动作的最优平均速度 $u_{r,1}(a_r|s)$

$$\bar{a}_1 = a_r + (1-r)u_{r,1}(a_r|s). \quad (15)$$

令 $u_{r,1}(a_r|s)$ 表示候选平均速度，生成动作 $\bar{a}_1 = a_r + (1-r)u_{r,1}(a_r|s)$ 。我们对参考动作 a_1 处的 Q 函数进行一阶泰勒展开：

$$Q_\phi(s, \bar{a}_1) \approx Q_\phi(s, a_1) + \langle \nabla_a Q_\phi(s, a_1), \bar{a}_1 - a_1 \rangle \quad (16)$$

代入流映射参数化后，起始状态 a_r 被消去，得到平均速度向量之差：

$$\bar{a}_1 - a_1 = (a_r + (1-r)u_{r,1}(a_r|s)) - (a_r + (1-r)u_{r,1}^{ref}(a_r|s)) = (1-r)(u_{r,1}(a_r|s) - u_{r,1}^{ref}(a_r|s)) \quad (17)$$

由于 $Q_\phi(s, a_1)$ 关于 $u_{r,1}(a_r|s)$ 为常数，在平均速度的信任域约束下最大化线性近似可表述为：

$$\begin{aligned} \min_{u_{r,1}} \quad & f_0(u_{r,1}(a_r|s)) = -\langle \nabla_a Q_\phi(s, a_1), u_{r,1}(a_r|s) - u_{r,1}^{ref}(a_r|s) \rangle \\ \text{subject to} \quad & f_1(u_{r,1}(a_r|s)) = \frac{1}{2}\|u_{r,1}(a_r|s) - u_{r,1}^{ref}(a_r|s)\|_2^2 - \frac{1}{2}\eta^2 \leq 0 \end{aligned} \quad (18)$$

因为 $\eta > 0$ ，可行集内部非空，满足斯莱特约束规范。因此强对偶性成立，且 KKT 条件为充分必要条件。拉格朗日函数为：

$$\begin{aligned} \mathcal{L}(u_{r,1}, \lambda) = & -\langle \nabla_a Q_\phi(s, a_1), u_{r,1}(a_r|s) - u_{r,1}^{ref}(a_r|s) \rangle \\ & + \lambda \left(\frac{1}{2}\|u_{r,1}(a_r|s) - u_{r,1}^{ref}(a_r|s)\|_2^2 - \frac{1}{2}\eta^2 \right) \end{aligned} \quad (19)$$

令 $u_{r,1}^*(a_r|s)$ 和 λ^* 分别为原始最优解和对偶最优解。KKT 条件为：

$$f_1(u_{r,1}^*(a_r|s)) \leq 0 \quad (\text{Primal feasibility}) \quad (20)$$

$$\lambda^* \geq 0 \quad (\text{Dual feasibility}) \quad (21)$$

$$\lambda^* f_1(u_{r,1}^*(a_r|s)) = 0 \quad (\text{Complementary slackness}) \quad (22)$$

$$-\nabla_a Q_\phi(s, a_1) + \lambda^*(u_{r,1}^*(a_r|s) - u_{r,1}^{ref}(a_r|s)) = 0 \quad (\text{Stationarity}) \quad (23)$$

假设 $\nabla_a Q_\phi(s, a_1) \neq 0$ ，平稳性方程 23 要求 $\lambda^* > 0$ 。互补松弛方程 22 则迫使该约束为活跃约束：

$$\|u_{r,1}^*(a_r|s) - u_{r,1}^{ref}(a_r|s)\|_2 = \eta \quad (24)$$

对平稳性条件取范数可得 $\lambda^* \eta = \|\nabla_a Q_\phi(s, a_1)\|_2$ ，so $\lambda^* = \|\nabla_a Q_\phi(s, a_1)\|_2 / \eta$ 。将 λ^* 代回平稳性条件，得到：

$$u_{r,1}^*(a_r|s) = u_{r,1}^{ref}(a_r|s) + \eta \frac{\nabla_a Q_\phi(s, a_1)}{\|\nabla_a Q_\phi(s, a_1)\|_2} \quad (25)$$

□

A.2 欧拉策略与平均流策略的等价性

在本节中，本文阐明了平均流策略 [詹等人, 2026年] 与公式 (5) 中的欧拉策略之间的等价性。本文首先陈述平均流策略及其关于参数 θ 的损失梯度。

$$\begin{aligned}\mathcal{L}_{\text{MF}} &= \mathbb{E} \left[\left| u_{r,t}^\theta(a_r | s) - \text{sg} \left(u_{r,t}^\theta(a_r | s) + (t-r) \frac{d}{dr} u_{r,t}^\theta(a_r | s) \right) \right|^2 \right] \\ \nabla_\theta \mathcal{L}_{\text{MF}} &= 2\mathbb{E} \left[\nabla_\theta u_{r,t}^\theta(a_r | s)^T \left(u_{r,t}^\theta(a_r | s) - \text{sg} \left(u_{r,t}^\theta(a_r | s) + (t-r) \frac{d}{dr} u_{r,t}^\theta(a_r | s) \right) \right) \right],\end{aligned}\quad (26)$$

其中期望是对 $(r, t, p_r(a_r | z, s))$ 取的。现在回顾欧拉目标，采用流映射策略参数化 $X_{r,t}(a_r | s) = a_r + (t-r)u_{r,t}^\theta(a_r | s)$ ，并以显式参数 θ 表示平均速度：

$$\mathcal{L}_{\text{EPD}}(\theta) = \mathbb{E} \left[\left| \partial_r X_{r,t}(a_r | s) + \text{sg}(\nabla X_{r,t}(a_r | s) u_{r,r}^\theta(a_r | s)) \right|^2 \right], \quad (27)$$

考察平方范数内的各项，并移除停止梯度算子 sg 。计算关于起始时间 r 的偏导数：

$$\partial_r X_{r,t}(a_r | s) = -u_{r,t}^\theta(a_r | s) + (t-r)\partial_r u_{r,t}^\theta(a_r | s). \quad (28)$$

将其代回欧拉目标，得到：

$$\mathcal{L} = \mathbb{E} \left[\left| \underbrace{-u_{r,t}^\theta(a_r | s)}_{T_1} + \underbrace{(t-r)\partial_r u_{r,t}^\theta(a_r | s) + \nabla X_{r,t}(a_r | s) u_{r,r}^\theta(a_r | s)}_{T_2} \right|^2 \right]. \quad (29)$$

对 T_2 施加停止梯度并取参数梯度，将其代回欧拉目标，得到：

$$\nabla_\theta \mathcal{L}(\theta) = 2\mathbb{E} \left[u_{r,t}^\theta(a_r | s) - \nabla_\theta u_{r,t}^\theta(a_r | s) \cdot (u_{r,t}^\theta(a_r | s) + \text{sg}(T_2)) \right]. \quad (30)$$

现在展开 T_2 中的空间梯度项，即 $\nabla X_{r,t}(a_r | s) u_{r,r}^\theta(a_r | s)$ ：

$$\nabla X_{r,t}(a_r | s) u_{r,r}^\theta(a_r | s) = u_{r,r}^\theta(a_r | s) + (t-r)\nabla u_{r,t}^\theta(a_r | s) u_{r,r}^\theta(a_r | s). \quad (31)$$

现在通过引入切线条件，并用真实瞬时速度 v^* 替换 $u_{r,r}^\theta$ ，我们可以展开 T_2 得到

$$T_2 = (t-r)\partial_r u_{r,t}^\theta(a_r | s) + v_r^*(a_r | s) + (t-r)\nabla u_{r,t}^\theta(a_r | s) v_r^*(a_r | s).$$

重新整理各项并将 $(t-r)$ 项分组，我们注意到全导数 d/dr 恰好对应于 T_2 。我们现在利用并简洁地重写方程 (30)：

$$\nabla_\theta \mathcal{L}(\theta) = 2\mathbb{E} \left[\nabla_\theta u_{r,t}^\theta(a_r | s)^T \left(u_{r,t}^\theta(a_r | s) - \text{sg} \left(u_{r,t}^\theta(a_r | s) + (t-r) \frac{d}{dr} u_{r,t}^\theta(a_r | s) \right) \right) \right].$$

该损失梯度与平均流策略的损失梯度一致，主要区别在于使用了真实速度 v_r^* ，而非网络预测 $u_{r,r}^\theta$ 。此外，瞬时速度约束等价于公式 (3) 的对角损失。这表明平均流策略 [詹等人, 2026年] 并非独立的范式，而是更广泛的欧拉策略蒸馏框架的一个具体实例。

B 成功轨迹

我们可视化训练后的 FMQ 策略在所有 12 个评估环境中的成功轨迹。每张图展示单个完成任务目标回合中均匀间隔的帧。



图 5: 罐子 (Robomimic)。从桌上拿起罐子并将其放入箱中。



图 6: 方形螺母 (Robomimic)。拿起方形螺母并将其套到销钉上。



图 7: 双立方体任务 3 (OGBench)。将 2 个立方体重排至目标位置。




图 8: 双立方体任务 4 (OGBench)。交换 2 个立方体的位置。



图 9: 三立方体任务 3 (OGBench)。将 3 个立方体拆垛并分别放置到不同的目标位置。




图 10: 三立方体任务 4 (OGBench)。将 3 个立方体循环置换到新位置。




图 11: 场景任务 4 (OGBench)。解锁抽屉按钮，打开抽屉，并将立方体放入其中。




图 12: 场景任务 5 (OGBench)。将立方体放入抽屉并打开窗户。



图 13: 人形迷宫-中等-任务 3 (OGBench)。在中等迷宫中导航人形机器人到达目标。



图 14: 人形迷宫-中等-任务 4 (OGBench)。在中等迷宫中导航人形机器人到达远处目标。




图 15: antmaze-giant-task4 (OGBench)。在巨型迷宫中导航蚂蚁到达目标。




图 16: antmaze-giant-task5 (OGBench)。在巨型迷宫中导航蚂蚁到达附近目标。

C 算法

Algorithm 1 FLOW MAP Q -GUIDANCE (FMQ)

Require: Offline policy $u_{r,1}^{\text{off}}$, online policy $u_{r,1}^{\theta}$, critics Q_{ϕ_1}, Q_{ϕ_2} , buffer $\mathcal{D}$

- 1: **for** each environment step **do**
 - 2: $a_1 \leftarrow a_0 + u_{0,1}^{\theta}(a_0|s), a_0 \sim \mathcal{N}(0, I)$
 - 3: $\mathcal{D} \leftarrow \mathcal{D} \cup \{(s, a_1, r, s')\}$
 - 4: Sample batch from $\mathcal{D}$; update critics via Eq. 8
 - 5: $r \sim \mathcal{U}[0, 1]; a_0 \sim \mathcal{N}(0, I); a_r \leftarrow (1-r)a_0 + r a_{\text{data}}$
 - 6: $a_1 \leftarrow a_r + (1-r) u_{r,1}^{\text{off}}(a_r|s)$
 - 7: $g \leftarrow \nabla_a Q_{\phi_1}(s, a_1) / (\|\nabla_a Q_{\phi_1}(s, a_1)\|_2 + \kappa_1)$
 - 8: $\eta_{\text{eff}} \leftarrow \eta / (1 + \beta \tilde{\delta}_{\text{critic}})$ ▷ Eq. 13
 - 9: $\theta \leftarrow \theta - \alpha \nabla_{\theta} \|u_{r,1}^{\theta}(a_r|s) - \text{sg}(u_{r,1}^{\text{off}}(a_r|s) + \eta_{\text{eff}} g)\|^2$
 - 10: **end for**
-

Algorithm 2 Q -GUIDED BEAM SEARCH (QGBS)

Require: Flow map $X_{r,1}^{\theta}$, critic Q_{ϕ} , state s , beam M , steps K , branches B , SNR ρ , step size η

- 1: $t' \leftarrow \rho / (1 + \rho)$
 - 2: Sample $\{a_0^m\}_{m=1}^M \sim \mathcal{N}(0, I); a_1^m \leftarrow a_0^m + u_{0,1}^{\theta}(a_0^m|s)$ for all m
 - 3: **for** $k = 1, \dots, K$ **do**
 - 4: **for** $m = 1, \dots, M$ and $b = 1, \dots, B$ **do**
 - 5: $\varepsilon^{mb} \sim \mathcal{N}(0, I)$
 - 6: $\hat{a}_1^{mb} \leftarrow X_{t',1}^{\theta}(t' a_1^m + (1-t') \varepsilon^{mb} | s)$ ▷ Re-noise & complete
 - 7: **end for**
 - 8: $\{a_1^m\}_{m=1}^M \leftarrow \text{Top-}M(\{\hat{a}_1^{mb}\}_{m,b}; Q_{\phi}(s, \hat{a}_1^{mb}))$ ▷ Select best M of $M \cdot B$
 - 9: $a_1^m \leftarrow a_1^m + \eta \nabla_a Q_{\phi}(s, a_1^m) / \|\nabla_a Q_{\phi}(s, a_1^m)\|_2$ for all m ▷ Thm. 3.2
 - 10: **end for**
 - 11: **return** $a_1^{\arg \max_m Q_{\phi}(s, a_1^m)}$
-




图 17: 所有环境中 QC、MVP 和 FMQ 的离线到在线学习曲线。所有方法先执行 1M 离线步骤，再执行 1M 在线步骤。阴影区域表示 5 个种子上的 95% 置信区间。

D 训练曲线

图 17 将图 2 扩展到全部 12 个环境。在较简单的操作任务 (can、square、cube-dbl) 上，所有方法都收敛到接近完美的成功率，但 FMQ 更早达到该水平。在较难的任务上优势更加明显：在 cube-trl-t4 上，FMQ 达到 0.88，而 MVP 停滞在 0.32；在 amaze-gnt-t4 上，FMQ 达到 0.80，而 MVP 为 0.42。对于运动任务 (hmaze、amaze)，在稀疏奖励下 Q 梯度信号特别有益，此时从 N 中选择最佳提供的学习信号较弱。

E 信赖域收敛

图 18 将图 4 的收敛分析扩展到全部 12 个环境。我们跟踪在线训练期间在线流映射策略与冻结离线流映射策略之间的动作位移 $\|u_{r,1}^{\text{on}} - u_{r,1}^{\text{off}}\|_2$ 。在微调开始时 (1M 步)，两个策略重合，位移接近零。随着训练进行，方程 (12) 中的信赖域损失驱动 $u_{r,1}^{\text{on}}$ 趋向 $u_{r,1}^{\text{off}} + \eta_{\text{eff}} \hat{g}$ ，导致位移单调增长，直到稳定在 η_{eff} 附近。橙色曲线 (右轴) 显示隐含的 Q 不确定性 $\tilde{\sigma}_Q = (\eta_{\text{eff}}^{-1} - 1)/\beta$ ，随着评论家




图 18: FMQ ($\beta=0.3$) 在所有 12 个环境中的信赖域收敛情况。蓝色: 动作位移 $\|u_{r,1}^{\text{on}} - u_{r,1}^{\text{off}}\|_2$ 。红色虚线: 自适应信赖域半径 η_{eff} 。橙色点线 (右轴): 隐含的 Q 值不确定性 $\tilde{\sigma}_Q = (\eta_{\text{eff}}^{-1} - 1)/\beta$ 。

变得更加自信——自动收紧信赖域，并证实自适应机制防止了在低置信区域中的过度调整。




图 19: 在线阶段 (1M – 2M 步) 中 FMQ 相对于 MVP 的收敛加速 (T_{MVP}/T_{FMQ})。每个点代表一个环境；黑色菱形表示带 95% 置信区间的均值。虚线标记相等的收敛速度 ($1\times$)。

表 4: FMQ 相对于 MVP 的加速 (T_{MVP}/T_{FMQ})，衡量达到收敛目标某一比例 ξ 所需的时间 (每个种子, 5 个种子取平均)。左: 完整训练 (0 – 2M)。右: 仅在线阶段 (1M – 2M)。数值 > 1 表示 FMQ 更快。

Environment	Full (0-2M)				Online (1M-2M)			
	75%	85%	95%	100%	75%	85%	95%	100%
can	1.04	1.18	1.39	1.48	4.40	5.80	4.56	3.21
square	1.33	1.34	1.37	1.40	2.69	2.28	2.30	2.40
cube-double-task3	1.00	1.00	1.05	1.27	1.00	1.60	2.50	2.60
cube-double-task4	1.32	1.30	1.31	1.21	3.38	2.64	2.33	1.64
cube-triple-task3	1.23	1.24	1.27	1.21	2.00	1.77	1.76	1.57
cube-triple-task4	1.36	1.40	1.45	1.45	2.41	2.50	2.63	2.63
scene-task4	1.00	1.00	1.09	1.16	1.20	1.20	1.86	2.12
scene-task5	1.13	1.22	1.36	1.32	3.20	4.40	4.33	2.54
hmaze-med-task3	1.41	1.55	1.63	1.63	6.17	6.33	6.14	6.14
amaze-giant-task4	1.54	1.56	1.52	1.59	4.56	4.67	3.91	4.27
amaze-giant-task5	1.02	1.07	1.21	1.14	1.20	1.50	1.88	1.37
Average	1.22	1.26	1.33	1.35	2.93	3.15	3.11	2.77
95% CI	[1.10, 1.33]	[1.14, 1.37]	[1.23, 1.43]	[1.25, 1.45]	[1.97, 3.89]	[2.08, 4.23]	[2.27, 3.95]	[1.95, 3.59]

F 加速分析

图 19 可视化了在线阶段 (1M – 2M) 中 FMQ 相对于 MVP 的逐环境收敛加速，补充了第 4.2 节的讨论。对于共享收敛目标的每个阈值 $\xi \in 75\%, 85\%, 95\%, 100\%$ ，我们绘制比率 T_{MVP}/T_{FMQ} 。FMQ 在每个环境、每个阈值下均快于 MVP (所有点均高于 $1\times$)，平均加速为 $2.8 - 3.2\times$ 。包含完整训练和仅在线阶段的逐环境详细分解见表 4。

表 5: FMQ 上的 QGBS。信噪比 = 1.5, $\eta = 0.3$ 。列按 K 分组; 子列 $\{B, M\}$. 成功率 (均值 $\pm$ 标准差, 5 个种子, 50 个回合)。每行最佳值以粗体显示。

Environment	$K = 0$	$K = 1$				$K = 2$	
	$\{1, 32\}$	$\{1, 16\}$	$\{2, 8\}$	$\{4, 4\}$	$\{4, 16\}$	$\{1, 16\}$	$\{4, 4\}$
can	0.96 $\pm$ 0.04	0.97 $\pm$ 0.02	0.96 $\pm$ 0.04	0.97 $\pm$ 0.03	0.94 $\pm$ 0.04	0.95 $\pm$ 0.03	0.98 $\pm$ 0.03
square	0.94 $\pm$ 0.02	0.94 $\pm$ 0.03	0.96 $\pm$ 0.04	0.95 $\pm$ 0.04	0.96 $\pm$ 0.02	0.94 $\pm$ 0.04	0.94 $\pm$ 0.03
cdp3	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00
cdp4	0.98 $\pm$ 0.02	0.99 $\pm$ 0.03	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00	0.98 $\pm$ 0.02	0.99 $\pm$ 0.03	0.99 $\pm$ 0.01
ctrp3	0.78 $\pm$ 0.10	0.82 $\pm$ 0.10	0.78 $\pm$ 0.06	0.84 $\pm$ 0.04	0.83 $\pm$ 0.07	0.84 $\pm$ 0.08	0.82 $\pm$ 0.08
ctrp4	0.88 $\pm$ 0.07	0.84 $\pm$ 0.06	0.88 $\pm$ 0.06	0.87 $\pm$ 0.05	0.82 $\pm$ 0.09	0.82 $\pm$ 0.04	0.84 $\pm$ 0.06
sc4	1.00 $\pm$ 0.00	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00
sc5	0.98 $\pm$ 0.02	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00	0.99 $\pm$ 0.01	1.00 $\pm$ 0.00	0.98 $\pm$ 0.02
hm3	0.69 $\pm$ 0.04	0.70 $\pm$ 0.07	0.63 $\pm$ 0.04	0.58 $\pm$ 0.07	0.72 $\pm$ 0.11	0.68 $\pm$ 0.10	0.70 $\pm$ 0.07
hm4	0.06 $\pm$ 0.03	0.07 $\pm$ 0.04	0.10 $\pm$ 0.04	0.06 $\pm$ 0.03	0.11 $\pm$ 0.04	0.10 $\pm$ 0.05	0.10 $\pm$ 0.03
ag4	0.80 $\pm$ 0.06	0.78 $\pm$ 0.06	0.86 $\pm$ 0.10	0.77 $\pm$ 0.03	0.82 $\pm$ 0.04	0.75 $\pm$ 0.05	0.79 $\pm$ 0.03
ag5	0.92 $\pm$ 0.04	0.92 $\pm$ 0.04	0.90 $\pm$ 0.05	0.92 $\pm$ 0.05	0.90 $\pm$ 0.09	0.89 $\pm$ 0.03	0.90 $\pm$ 0.02
IQM	0.91 [0.89, 0.93]	0.92 [0.90, 0.93]	0.93 [0.91, 0.95]	0.93 [0.91, 0.94]	0.92 [0.90, 0.93]	0.90 [0.89, 0.92]	0.91 [0.90, 0.93]

G 推理时束搜索

表 5 提供了 QGBS 应用于训练后的 FMQ 检查点的完整逐环境分解, 扩展了表 2 中报告的聚合 IQM 结果。NFE = $M(1 + KB)$, 其中 M 是初始候选数量, K 是重噪步骤数, B 是每个候选的完成次数; $K=0$ 简化为标准的 M 择优。逐环境结果证实, 重噪带来的增益 ($K=1$) 在任务领域间保持一致——操作、多目标重排和运动——在更难的迷宫任务上改进最为显著 (hm3: 0.59 $\rightarrow$ 0.72, hm4: 0.07 $\rightarrow$ 0.11).

表 6: 所有方法共享的超参数。

Parameter	Value
Optimizer	Adam
Learning rate	3×10^{-4}
Batch size	256
Discount (γ)	0.99
Target update (τ)	5×10^{-3}
UTD ratio	1
Offline / online steps	1M / 1M
Replay buffer	2M
Policy network	MLP, 4×512 , GELU
Critic network	MLP, 4×512 , GELU, LayerNorm
Critic ensemble	2 (double Q, mean agg.)
Fourier embedding	64 dim per time axis
Chunking horizon (H)	5
Eval interval / episodes	100K / 50

H 实现细节

所有方法共享相同的网络架构、评论家算法和训练流程, 以确保受控比较。策略被参数化为时间条件速度场 u_θ : 一个具有 512 个隐藏单元和 GELU 激活函数的 4 层 MLP。标量流时间在与观测和噪声动作拼接之前, 被提升为 64 维正弦傅里叶嵌入。评论家遵循截断双 Q 学习框架 [藤本等人, 2018 年]: 由两个具有相同 MLP 架构 (带 LayerNorm) 的 Q 网络组成的集成, 使用 Polyak 平均目标网络 ($\tau=0.005$) 针对共享贝尔曼目标进行训练。所有方法使用动作分块 ($H=5$), 一个包含 2M 转移的重放缓冲区, 并进行 1M 离线步骤后接 1M 在线步骤的训练, UTD 比率为 1, 使用 Adam ($\text{lr}=3 \times 10^{-4}$) 和批大小 256。完整的共享超参数见表 6。

质量控制 (QC) [Li 等, 2025] 使用直线插值目标训练标准条件流匹配 (CFM) 速度场 $v_\theta(a_t, t | s)$ 。在推理时, 常微分方程 (ODE) 从 $t=0$ 积分到 $t=1$, 采用 10 步欧拉法, 产生

表 7: 推理过程。NFE = 每个动作的网络前向评估。

Method	Action selection	Steps	N	NFE
QC	Best-of- N (Euler)	10	32	320
MVP	Best-of- N (flow map)	1	32	32
MVP + QGBS (ours)	QGBS	K	M	$K \cdot M$
FMQ (ours)	Best-of- N (flow map)	1	32	32
FMQ + QGBS (ours)	QGBS	K	M	$K \cdot M$

32 个候选动作，由评价器打分（最佳- N ，总计 320 次函数评估）。多步预测（MVP）[Zhan 等，2026] 用单步流映射（ $K=1$ ）替代多步欧拉积分，该映射直接预测 $[r, t]$ 上的平均速度 $u_{r,t}(a_r | s)$ 。网络输入为 $[s, \mathbf{x}_r, \text{傅里叶}(r), \text{傅里叶}(t), \text{傅里叶}(t_c), \mathbf{a}_c]$ ，其中 $(t_c, \mathbf{a}_c)$ 构成随机动作生成的条件轴。训练采用渐进式课程：先进行 5K 步的对角线条件流匹配（ $r=t$ ），然后在 50K 步内将区间 $[r, t]$ 退火至全范围，并在 10K 步后引入条件轴，使用 $P(t_c=0)=0.5$ 。推理时，单次前向传播生成每个候选动作，并应用最佳-32 选择（32 次函数评估）。流匹配 Q 学习（FMQ）与 MVP 共享相同的离线预训练。在线阶段，它切换到第 3.3 节描述的信任域 Q 梯度目标：离线流映射被冻结作为参考 $u_{r,1}^{\text{off}}$ ，Q 梯度进行 ℓ_2 归一化，信任域半径 η_{eff} 通过 Q 集成不一致性（ $\beta=0.3$, cf. eq. (13)）对每个样本自适应调整。推理时，FMQ 使用与 MVP 相同的最佳-32 流映射选择（32 次函数评估）。Q 引导束搜索（QGBS）在推理时应用第 3.4 节的 Q 引导束搜索，无需额外训练。从训练好的流映射开始，通过基于信噪比（SNR）的重新加噪使动作多样化，并在 K 个束步骤中使用 M 个候选动作进行细化，每次迭代应用信任域投影。引导强度由 λ 控制，动作通过直通估计器进行裁剪。成本：每个动作 $M(1 + KB)$ 次函数评估。推理过程和计算成本总结在表 7 中。所有训练实验均在 NVIDIA A100-SXM4-80GB GPU 上运行。完整的训练运行每个种子大约需要 4 小时。推理时的引导评估在 NVIDIA RTX 6000 Ada Generation GPU（48 GB 显存）上进行。