

PRISM: 薛定谔桥模型的原则性参考识别

Forouzan Fallah, Yezhou Yang
Arizona State University

摘要

薛定谔桥模型通过遵循参考过程的条件桥，从退化观测中恢复干净信号，然而该参考通常是启发式选择的，典型为具有手工调整时间表的白噪声。本文提出 PRISM，一种桥参考设计理论。我们刻画了在逐模式时间表下保持精确可解性的时变高斯参考：正是那些瞬时协方差可交换的参考。随后我们证明了一个不可见性原理：在精确漂移和无限求解器步数下，每个可容许参考都能恢复真实后验。因此，参考的选择仅在有限计算资源下才重要。对于固定步数预算，我们以闭式形式推导出有限步目标，并证明每个最优噪声谱正比于 P_k ，传感器所破坏信息的谱，且具有与模式无关的常数 $x^*(T) = (2 \ln T)^{-1/2}(1 + o(1))$ 。分析表明，噪声颜色与时间调度可互换，且正则化可证明地将最优参考推向白噪声。高斯设置下的实验证实了预测的排序和闭式损失下界。在 FFHQ 上，失真-感知权衡和谱局部落化得以迁移，但白噪声优于匹配参考；一项改变训练机制的预注册研究否定了岭白化作为解释。一项 2×2 机制研究随后将这种反转追溯到真实图像的非高斯逐模式统计。PRISM 将参考设计从超参数搜索转变为高斯机制下的计算，并精确定位了真实图像使其失效之处。


1 引言

薛定谔桥模型 (Schrödinger Bridge Models) [31, 9, 38] 学习沿参考过程的条件桥在两个分布之间传输样本。该参考过程决定了训练期间使用的中间状态，包括噪声如何在空间频率上分布。然而，它通常由人工选择，最常见的是带有启发式标量调度的白噪声。这种做法将参考过程视为次要的实现细节。图 1 表明并非如此：在每个求解器预算下，都存在一个内部最优噪声水平，其位置遵循一条简单且可预测的规则。扩散调度曾经经过人工调整，直到调度理论 [24, 28] 使其设计变得有原则。近期工作已通过实验表明，注入噪声的频谱在单端点生成扩散 [11, 22, 3, 10] 中很重要。然而，该设置中没有测量算子来识别首选频谱。因此，颜色是通过搜索而非推导来选择的，且没有理论描述其何时应重要。本文为桥参考过程发展了类似的理论，我们称之为 PRISM（薛定谔桥模型的原则性参考识别），并发现答案比单一最优公式更为微妙：参考过程在理想极限下无关紧要，而其最优有限资源设计取决于求解器步数或模型误差。

我们的分析在一个可解的线性高斯退化模型中进行，其中观测为 $x_1 = h_k x_0 + n$ ，按空间频率 k ，具有传递函数 h_k 、噪声谱 N_k 和信号



(a) reference scale $x = v/P \rightarrow$



(b) 在每个 T 处存在内部最优值 (c) 该常数及其规律

图 1：参考噪声存在一个合适的量，且其大小是可预测的。 (a) 每一行是一个求解器采样预算 T ；每一列显示注入的参考噪声水平，作为相对于传感器破坏信息的尺度 x 。噪声过少（左）无法恢复缺失细节；噪声过多（右）则模糊重建结果。(b) 重建误差作为 x 的函数，每个 T 对应一条曲线。每条曲线都有一个最小值，表明中间噪声水平表现最佳。(c) 最小值的位置遵循公式 (7)，在每个测试预算下均与实测最优值匹配。

先验 S_k 。核心量是维纳残差谱

$$P_k = S_k N_k / (h_k^2 S_k + N_k), \quad (1)$$

它衡量观测 x_1 后剩余的后验不确定性：在传感器观测良好的地方， $P_k \approx N_k \approx 0$ ；在传感器盲区， $P_k \approx S_k$ 。因此， P_k 是被破坏信息的频谱，可直接从已知退化模型计算得出。

贡献。

1. 可解性定理（第 3.1 节）。我们刻画了允许 I^2 SB 型闭式桥并解耦为独立标量模态的时变算子值参考：其瞬时协方差必须两两交换，等价于可同时对角化。我们还给出了分块混叠、线性漂移和希尔伯特空间扩展。

2. 不可见性原理（第 3.2 节）。在精确漂移和 $T \rightarrow \infty$ 步下，对于每个参考方差 $v > 0$ ，终端分布等于真实后验，并坍缩为 $v = 0$ 处的点质量。只有当某些资源（求解器步数或模型准确率）受限时，参考才起作用。

3. 有限步理论（第 3.3 节）。我们以闭式形式推导了 T 步终端分布。逐模态 KL 散度仅通过 $x = v/P$ 依赖于 (v, P) ，因此每个优化器都是成比例的， $v_k = x^* P_k$ 。在均匀网格上， $x^*(T) = (2 \ln T)^{-1/2} (1 + o(1))$ 且最优 KL 散度为 $\frac{\ln T}{2T^2} (1 + o(1))$ 。第二个变量替换，即 z 恒等式，使颜色和调度可交换：在逐模态调度下，离散化误差与颜色无关，且最优调度唯一，具有 $4P/T$ 下限。在聚类网格上，颜色目标函数有多个局部极小值，因此两者不能独立设计。

4. 模型误差与学习（第 3.4 节）。我们将分析扩展到漂移的任意（增益，偏差）扰动。给定 z 调度和误差分布，采样与颜色无关，且对于任何尺度等变学习器，逐模态学习与颜色无关；颜色仅在尺度对称性被破坏时起作用。共享岭正则化在确定方向上破坏了它，给出次比例定律 $v_k = x^*(nP_k) \cdot P_k$ ：较少的数据使最优参考白化，该参考介于白噪声和 P_k 之间。

5. 实验与被反驳的预测（第 4 节）。数值实验和训练后的预测器证实了预测的排序和闭式损失下限，并直接测量了岭白化。在 FFHQ [25] 上，以 64×64 步和已知退化，失真-感知权衡和预测的频谱局部化得以迁移，但白色仍然是更好的感知参考。一项预先注册的双机制研究（第 4.4 节）反驳了岭白化作为解释，而 2×2 机制研究（第 4.5 节）表明反演跟踪数据而非架构，暗示了理论理想化掉的非高斯逐模态统计量。

2 相关工作

薛定谔桥与桥匹配。扩散薛定谔桥（Diffusion Schrödinger Bridge, DSB）利用基于分数的扩散近似迭代比例拟合 [9]；DSBM 和迭代马尔可夫拟合则交替进行桥匹配与马尔可夫投影 [38, 35]，而迭代比例马尔可夫拟合统一了这两类方法 [26, 16]。另一条研究路线追求简化、非迭代或可证明轻量的求解器 [39, 14, 35]、任务相关的状态代价以及半监督耦合 [30, 20]。这些方法改进了基于给定参考的估计器。本文则探讨应使用何种参考。

用于恢复和逆问题的桥模型。[31] 利用解析布朗桥后验来映射成对的退化图像与干净图像，而 [48] 在具有 VE/VP 变体的一般参考扩散上构建 DDBM。后续工作改进了更快且非马尔可夫的采样 [42, 47]、少步或一步蒸馏 [17, 15]、预训练先验 [40]、均值回归与随机控制公式 [49]、残差或能量缩短轨迹 [41, 19]，以及针对曝光偏差和失真的正则化 [45]。这些方法主要修改漂移项或时间范围；扩散协方差保持各向同性，其标量尺度通过调参选择。

结构化参考与退化感知的前向过程。高斯薛定谔桥具有闭式解 [5]，而更丰富的参考动力学——如多元奥恩斯坦-乌伦贝克过程、拓扑感知的热扩散、解析线性二次桥——近期也得到研究 [46, 44, 6]。在这些工作中，参考或其诱导的代价是预先固定的；本文将其视为未知。

频谱整形与有色噪声。最接近的研究方向关注注入噪声的频谱。前向过程的傅里叶空间分析 [11] 促使设计使所有频率以匹配速率退化的调度。实证研究报告了蓝噪声、低频主导噪声、频谱各向异性的前向噪声、频谱引导或逐实例调度以及采样时的频带重分配带来的增益 [21, 22, 37, 3, 10, 8]。这些工作表明噪声颜色是一个重要的设计选择，但通过搜索或端到端拟合来确定。这产生了数据集特定的规则，却未解释为何应偏好某一频谱或颜色何时应无影响。本文在桥设置中同时给出这两个结果：最优频谱是被破坏信息的频谱 P_k ，且其影响在精确漂移、调度自适应的极限下可证明地消失。

调度设计、步数预算与失真-感知。变分扩散模型（Variational Diffusion Models）与 EDM 将调度与加权选择确立为重要的设计变量 [28, 24]。随后

研究探讨了基于 ELBO 的重新加权、对数信噪比重要性采样以及对常见调度的修正 [27, 29, 33]。这些方法优化固定单端点过程的时间调度，并在给定 NFE 预算下进行经验评估。我们的有限步目标具有闭式解，因此其最优性是通过证明而非测量得到的。此外， z 恒等式表明，所报告的颜色效应必须检验是否存在调度混杂。最后，失真 - 感知权衡是经典问题 [4, 13]，在桥恢复中仍然重要 [45, 12]。在我们的模型中，其二倍代价作为定理成立，而参考文献则追踪整条曲线。

3 PRISM: 参考设计理论

3.1 哪些参考是精确可解的？

设 B 为 $\mathbb{R}^d$ 中的标准布朗运动，且 $dX_t = L(t) dB_t$ 满足 $Q(t) := L(t)L(t)^\top$ 。图像到图像薛定谔桥 (I^2SB) 方法 [31, 43] 需要两个闭式对象：用于训练状态采样的固定边缘 $X_t | (X_0, X_1)$ ，以及用于祖先采样的反向子桥核 $X_s | (X_t, X_0)$ 。对于任意确定性协方差调度 $Q(\cdot)$ ，两者均为具有显式矩阵公式的多元高斯分布（引理 1-2，附录 6.2）。然而，实用的 I^2SB 需要精确分解为独立的标量模式，每个模式具有各自的空间频率噪声调度。以下结果刻画了这一条件。

定理 1（交换参考可解性）。假设 $Q(t)$ 是实对称且几乎处处半正定的 $t \in [0, 1]$ 。则以下命题等价：

1. 两两交换性：对于所有 s, t ，在公共零测集之外有 $Q(s)Q(t) = Q(t)Q(s)$ 。
2. 固定模态基： $Q(t) = U \text{diag}(q_1(t), \dots, q_d(t))U^\top$ ，具有时间无关的正交 U 。
3. 在坐标 $Y = U^\top X$ 中，参考过程为 独立时间变换标量布朗运动的乘积：

$$dY_{k,t} = \sqrt{q_k(t)} dB_{k,t}。$$

在这些条件下，当 $a_k(t) := \int_0^t q_k, v_k := a_k(1)$ ，且 $\rho_k(t) := a_k(t)/v_k$ ，钉扎桥

在模态上精确分解：

$$\begin{aligned} Y_{k,t} | (y_{k,0}, y_{k,1}) &\sim \mathcal{N}(\mu_{k,t}, \sigma_{k,t}^2), \\ \mu_{k,t} &= (1 - \rho_k(t))y_{k,0} + \rho_k(t)y_{k,1}, \\ \sigma_{k,t}^2 &= v_k \rho_k(t)(1 - \rho_k(t)), \end{aligned} \tag{2}$$

且对于 $0 < s < t \leq 1$ ，反向核为模态高斯分布，
 $\rho_k(s)/\rho_k(t) = a_k(s)(1 - \rho_k(s,t))$ ，均值系数为 $r_k(s,t) =$ ，方差为

推论 1（调度参数化）。定理 1 中的族按模态精确参数化，由总方差 $v_k > 0$ （称为颜色）和绝对连续非递减调度 $\rho_k : [0, 1] \rightarrow [0, 1]$ （满足 $\rho_k(0) = 0$ 和 $\rho_k(1) = 1$ ，称为分配）通过 $q_k(t) = v_k \dot{\rho}_k(t)$ 给出。

三个扩展在实践中很重要，均在附录 6.2 中证明。

(i) 静态颜色：形式为 $Q(t) = \beta(t)\Sigma$ 的引用，在先前固定颜色工作中使用，构成严格子族，其中所有模式共享一个 ρ ；白色 I^2SB 对应于 $\Sigma = cI$ 。

(ii) 混叠块：如果每个 $Q(t)$ 在一个固定正交分解下是块对角的，则桥解耦为独立的有限维块，且块内无需交换性。

这正确地模拟了下采样，其中每个频率与其折叠频率耦合。

(iii) 交换线性漂移：同时可对角化的 $F(t)$ 和 $Q(t)$ 在修改的高斯公式下保持精确的模态可处理性，涵盖均值回归引用；在迹条件下存在希尔伯特空间版本。

3.2 可解模型与不可见性原理

定理 1 将算子问题分离为标量模式，因此我们按模式工作并省略索引 k 。对于每个空间频率，退化模型为

$$x_0 \sim \mathcal{N}(0, S), \quad x_1 = h x_0 + n, \quad n \sim \mathcal{N}(0, N). \tag{3}$$

后验为 $x_0 \mid x_1 \sim \mathcal{N}(Wx_1, P)$ ，其中 $W = Sh/(h^2S + N)$ 是维纳增益，
 $P = SN/(h^2S + N) > 0$ 是残差方差。对于 颜色 $v \geq 0$ 和桥水平 $\rho \in [0, 1]$ ，参考桥为

$$x_\rho = (1 - \rho)x_0 + \rho x_1 + \sqrt{v\rho(1 - \rho)}\xi.$$

设 $0 = \rho_0 < \dots < \rho_T = 1$ 为离散化网格。插件均值祖先采样器——标准 I^2 SB 配合贝叶斯最优网络——从 x_1 开始。在每一层，它计算 $\hat{x}_0 = \mathbb{E}[x_0 \mid x_{\rho_i}, x_1]$ 并应用定理 1 中的反向核，将 x_0

替换为 $\hat{x}_0$ ，并且
Define $\varphi(\rho) := (1 - \rho)P + v\rho$

$$K(\rho) = \frac{P}{\varphi(\rho)}, \quad M(\rho) = \frac{v\rho P}{\varphi(\rho)}, \quad \Sigma(\rho) = (1 - \rho)\varphi(\rho). \quad (4)$$

此处 $K(\rho)$ 为条件增益， $M(\rho) = \text{Var}(x_0 \mid x_\rho, x_1)$ 为条件方差， $\Sigma(\rho) = \text{Var}(x_\rho \mid x_1)$ 。给定 x_1 ，每个采样器状态保持高斯分布： $x_{\rho_i} \mid x_1 \sim \mathcal{N}(c_i x_1, V_i)$ ，其中 c_i 和 V_i 遵循显式仿射递推（附录 6.3）。

定理 2（参考的不可见性）。(a) 固定 $v > 0$ 及任意网格，其亏缺和在引理 6（附录 6.3）中随 $T \rightarrow \infty$ 趋于零，包括均匀网格和幂网格 $\rho_i = (i/T)^a$ 且 $a \geq 1$ 。则终端分布收敛于真实后验： $\mathcal{N}(c_0 x_1, V_0) \rightarrow \mathcal{N}(Wx_1, P)$ 。更精确地， $D_0/P \rightarrow 0$ 在均匀网格上以速率 $O(\log T/T)$ 收敛，在幂网格上以速率 $O(1/T)$ 收敛且 $a > 1$ 。由于终端均值是精确的， $\text{KL} = D_0^2/4P^2(1 + o(1))$ ；因此， $\text{KL} = O((\log T/T)^2)$ 在均匀网格上， $\text{KL} = O(1/T^2)$ 在幂网格上且 $a > 1$ 。极限分布独立于 $v > 0$ 和容许调度；参考在无限步极限中变得不可见。(b) 在边界 $v = 0$ 处，终端分布为 $\delta(Wx_1)$ ，对每个有限 T 均成立：采样器不连续地坍塌为维纳回归，且与后验的 KL 散度为无穷大。

证明（附录 6.3）基于三个精确性质。首先，均值在每个有限 T 处是精确的：对每个网格， T ，且 $v \geq 0$ ， $c_i = (1 - \rho_i)W + \rho_i$ 。将 x_0 替换为其后验均值仅移除其条件随机性，因此有限步误差仅影响方差。

其次，收缩精确地望远镜式缩减：步长系数为 $A_i = \varphi(\rho_{i-1})/\varphi(\rho_i)$ ，因此步长系数的乘积简化为 φ 的精确比值。第三，方差亏缺 $D_i := \Sigma(\rho_i) - V_i$ 满足一个带有非负源项的线性递推，从而得到：

推论 2（系统性欠离散）。假设 $v > 0$ 。则 $V_i < \Sigma(\rho_i)$ 对每个 $i < T$ 成立；特别地， $V_0 < P$ 对每个有限 T 成立。插件均值采样器只有一种失效模式：它产生的方差过小。

定理 2 是核心的否定性结果。任何有意义的参考设计目标都必须为有限资源分配代价：求解器步数（§ 3.3）或模型精度与数据（§ 3.4）。没有这样的代价，目标将变得退化；例如，训练目标的积分贝叶斯风险在坍塌边界

$$v = 0 \text{ 处达到最小（附录 6.3）}。$$

3.3 步数：精确有限步理论

精确目标与优化器形式

利用望远镜乘积展开方差赤字递归，得到闭式赤字（引理 6，附录 6.3）：

$$D_0(v, P; \text{grid}) = vP^3 \sum_{i=1}^T \frac{(\Delta\rho_i)^2}{\rho_i \varphi(\rho_i) \varphi(\rho_{i-1})^2}, \quad (5)$$

$$u = 1 - D_0/P, \quad \text{KL} = 1/2(u - 1 - \ln u).$$

这是精确的 T 步目标。参考设计在颜色 $\{v_k\}$ 上最小化 $\sum_k \text{KL}_k$ ，并可选地针对每模式调度（推论 1）。

定理 3（尺度对称性与比例性）。固定任意共享网格。每模式 KL 仅通过无量纲比率 $x = v/P$ 依赖于 (v, P) ：模式无关剖面 Φ 满足 $\text{KL}(v, P; \text{网格}) = \Phi(v/P)$ 。由于 $\Phi(x) \rightarrow \infty$ as $x \rightarrow 0$ 或 $x \rightarrow \infty$ ，内部优化器存 $\sum_k \text{KL}_k = \sum_k \Phi(v_k/P_k)$ 。在。目标也分离： $\sum$

因此：(i) 在每个局部优化器处， $v_k = x_k P_k$ ，其中每个 x_k 是同一模式无关剖面 Φ 的局部极小值

(ii) 在每个全局优化器处， $x_k \in$ 对每个 k 取 Φ 的极小值。

(iii) 每当 Φ 的极小值唯一时，每个全局优化器与后验谱成比例，

$$v_k^* = x^*(\text{grid}, T) P_k, \quad k = 1, \dots, d, \quad (6)$$

具有一个模式无关的 x^* 对每个 T 。若极小值不唯一，如在某些非均匀网格上（命题 2），模式可能选择不同的局部极小值，产生非比例的局部最优。

这种比例关系源于精确的代数对称性，而非渐近论证。在逐模式高斯问题中， F 是唯一的尺度， v/F 是唯一的无量纲参数； T 仅控制常数。

命题 1（比例常数）。在均匀网格上，每个极小值点都满足

$$x^*(T) = (2 \ln T)^{-1/2} (1 + o(1)), \quad (7)$$

且最优值满足 $\text{KL}(x^*) = \frac{\ln T}{2T^2}$ 。证明（附录 6.4）建立了在窗口 $x \in [x_0/3, 3x_0]$ 上的一致展开 $T D_0/P = x \ln T + 1 + o(1)$ ，其中 $x_0 = (2 \ln T)^{-1/2}$ ，同时给出了排除窗口外极小值点的全局下界。带有精确导数的数值证书独立地证实了该展开；有限 T 余项在 $T = 10^3 - 10^5$ 范围内稳定在 1.15 附近。

实际上，对于现实的步数， $x^* \approx 0.2 - 0.6$ ：最优参考注入被破坏信息谱的适度部分，且该部分仅以 $(\ln T)^{-1/2}$ 的速度缩小。

命题 2（唯一性依赖于网格）。在 $T = 2$ 处， Φ 是严格单峰的。在均匀网格上，唯一性对 $2 \leq T \leq 120$ 已证明，对 $T \leq 200$ 和 $T \in \{500, 1000, 5000\}$ 已数值验证（附录 6.4）；将证明推广到一般 T 仍是一个未解决的问题。

在一般网格上，唯一性不成立。一个解析的双簇构造表明，在 $T = 3$ 时，网格对每个 $C \geq 100$ 至少产生 Φ 的两个局部极小值（附录 6.4）。当 $C \rightarrow \infty$ 时，轮廓分裂为两个单峰 $T = 2$ 轮廓，每个簇一个，尺度分别为 $x \asymp 1$ 和 $x \asymp C$ 。在 $T = 48$ 。双簇网格有七个局部极小值：每个步长簇偏好其自身的噪声尺度。

该反例警示：在非均匀网格上，调度设计与颜色设计无法解耦。

命题 3（预算弯曲指数）。固定 $P_1, \dots, P_d$ 及总噪声预算 V 。On uniform grids, as $T \rightarrow \infty$, every global optimizer of $\sum_k \text{KL}_k$ subject to $\sum_k v_k = V$ satisfies

$$v_k^* = \frac{P_k^2}{\sum_j P_j^2} V \left(1 + O\left(\frac{1}{\ln T}\right) \right), \quad k = 1, \dots, d. \quad (8)$$

固定预算使每个模式处于 Φ 的递增分支上，自由最优值 $x^*(T)P_k$ 随 $T \rightarrow \infty$ 消失，但预算保持不变。因此最优指数从 P_k 弯曲至 P_k^2 。等预算比较在经验颜色扫描中常见，却悄然改变了优化问题并使最优值更陡峭。我们在第 4 节中报告两种约定，因为它们回答不同的问题。

z 恒等式：颜色与调度可互换

关键结构出现在变量变换 $z(\rho) := v\rho/\varphi(\rho) = M(\rho)/P$ 下，即归一化条件最小均方误差水平，其中 $z_0 = 0$ 且 $z_T = 1$ 。

定理 4（精确 z 恒等式与调度理论）。对于每种颜色 $v > 0$ 及每个网格，

$$D_0 = P \sum_{i=1}^T (z_i - z_{i-1})^2 / z_i. \quad (9)$$

因此：(a) 无色性。对于每个 $v > 0$ ，映射 $\rho \mapsto z(\rho)$ 是 $[0, 1]$ 的双射。因此，在逐模式调度自适应下，每种颜色在每个有限 T 上都达到相同的 z 网格集合，从而获得相同的调度优化亏损，离散化误差不会偏向任何颜色。

(b) 唯一最优调度。目标函数 $F(z) = \sum_{i=1}^T (\Delta z_i)^2 / z_i$ 是联合凸的，由二次比线性项之和构成，其在固定网格上的极小值点是唯一的。

(c) 显式前向递推。当 $a_i = z_{i-1}/z_i$ 时，一阶条件变为 $2a_{i+1} = 1 + a_i^2$ ， $a_1 = 0$ ，给出显式前向递推 ($a_2 = \frac{1}{2}$, $a_3 = \frac{5}{8}$, $a_4 = \frac{89}{128}$, ...)，无需打靶法。

(d) 下界与连续极限。最优亏损满足 $D_0^* = \frac{4P}{T}$ ，给出逐模式 KL 下界 $\sim 4/T^2$ 。精确优化器以显式 $(1 + O(\log^2 T/T))$ ，速率收敛到连续调度 $z = s^2$ ；在原变量中， $Ps^2/(Ps^2 + v(1-s^2))$ ，条件 MMSE 是求解器时间的二

$$z_i^* = (i/T)^2 \exp(O(\ln(i+1)/(i+1))) \text{ 次函数: } M(\rho^*(s)) = Ps^2. \quad \rho^*(s) =$$

定理 4 重新构建了设计空间：参考仅通过其 z 调度影响离散化，而逐模式颜色仅仅是一种重新参数化。由此产生两个实际后果。在共享调度下，如现有实现中那样，定理 3 确定了颜色最优值。在频率自适应调度下，离散化完全无色；任何颜色效应必然来自学习漂移或有限数据。

3.4 模型误差：颜色真正所在之处

在可解模型中，精确漂移是仿射的。因此，任何学习到的仿射漂移在每个层级上相差两个量：相对增益误差 η_i 和加性偏差 β_i 。由于一切都在 x_1 条件下， β_i 可能依赖于它；这吸收了漂移 x_1 系数中的误差。这种双通道分解在模型内是穷尽的，且两个通道都保持仿射-高斯结构，使得以下所有终端定律都是精确的。

命题 4 (增益误差无法使采样器产生偏差)。在任意增益误差 $\{\eta_i\}$ 下，终端条件均值仍精确为 $W x_1$ 。增益误差仅作用于方差通道；只有偏差会移动均值。

定理 5 (扰动采样器的精确 z 缩减)。在固定的 z 网格上工作，每层误差分布为 $(\eta(z), \beta(z))$ 。扰动收缩为 $\hat{A}_i = A_i(1 + \eta_i \frac{\Delta z_i}{z_i})$ 。在第 i 层注入的偏差以权重 Δz_i 到达输出，当 $\eta \equiv 0$ 时，该权重恰好为 $\Delta z_i/z_i$ 。因此，终端均值误差为

$$m_0 = \sum_{i=1}^T \beta_i \frac{\Delta z_i}{z_i} \prod_{m < i} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right), \quad (10)$$

且终端方差具有闭式形式

$$V_0 = P \sum_{j=1}^T z_{j-1} \frac{\Delta z_j}{z_j} \times \prod_{m < j} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right)^2, \quad (11)$$

其 $\eta \equiv 0$ 情形恢复 $V_0/P = 1 - \sum_i (\Delta z_i)^2 / z_i$ 。每个因子仅依赖于 z 网格和误差分布。因此，采样器的终端分布对于每种颜色 $v > 0$ 都是相同的：给定 z 调度，采样在任意漂移误差下保持颜色无关。终端 KL 散度为

$$u = V_0/P, \quad \text{KL} = 1/2 (u + m_0^2/P - 1 - \ln u). \quad (12)$$

命题 5 (学习问题在每个模态下也是颜色无关的)。在第 z 层，给定 x_1 时 (x_0, x_t) 的每模态联合分布仅由 z 决定（至多相差一个尺度因子）：相关性 $^2(x_0, \text{偏差} | x_1) = 1 - z$ 精确成立。因此，任何尺度等变学习器在每个 z 层都具有颜色无关的相对误差分布；例如，从 n 对进行零截距 OLS 在归一化设计 $\sum_i X_i^2 = n\tau^2$ 上具有 $\text{Var}(\hat{K}/K - 1) = z/(n(1-z))$ （随机设计将 n 替换为 $n-2$ ）。结合定理 5，在给定 z 调度的情况下，颜色在每模态标量模型中端到端不可见。




图 2：精确有限步预测。(a) 不可见性（定理 2）。(b) 终端 KL 散度速率，均匀网格与幂网格对比。(c,d) 常数（命题 1）：测量 $x^*(T)$ 与 $(2 \ln T)^{-1/2}$ 及其比值。(e) 参考多模态性（命题 2）：在聚类 $T=48$ 调度上 Φ 的七个局部极小值，以 50 位精度验证。

因此，颜色仅通过每模态标量模型无法看到的机制起作用：(a) 非尺度等变学习，以及 (b) 跨模态耦合。机制 (a) 存在于每个训练网络中（权重衰减、岭惩罚、有限初始化尺度），其最小模型已经以确定的方向破坏了比例性：

命题 6（岭回归使最优参考白化）。共享岭惩罚 λ 诱导相对收缩 $\eta_k(z) = -\lambda/(\lambda + n \Sigma_k(z))$ （相同约定），这是一个有量纲的偏差，破坏了保护 $v \propto P$ 的尺度对称性。精确链优化产生急剧下降的 $x^*(nP)$ ：在 $T=100$ 和 $\lambda=1$ 处，它从 $nP=10$ 时的 11.92 下降到 $nP \rightarrow \infty$ 时的 0.363。因此，弱观测频率需要不成比例地更多的参考噪声。该规律呈次比例弯曲， $v_k^* = x^*(nP_k)P_k$ ，so 正则化使最优参考白化；纯 $v \propto F$ 仅在等变、无限数据极限下恢复。

由此机制可进一步得到两个结果（证明见附录 6.5）。失真-感知权衡：后验均值估计器的均方误差恰为 P ，与参考无关，而采样输出的均方误差为 $= P + V_0 \in [P, 2P)$ ；因此，后验采样的经典 2 倍代价作为定理出现，参考追踪整条权衡曲线。有原则的欠离散

更正：由于采样器的主要失效模式是欠离散（推论 2），有意的增益膨胀是一种校准修正，其精确条件为：选择 $\eta(z)$ 使得 (11) 中的重加权达到 P ，这是温度与扰动启发式方法的闭式对应。定理 5 还为真实网络提供了一种测量协议：沿路径探测训练漂移的雅可比矩阵以估计 $\hat{\eta}(z)$ ，然后通过 (11) 预测采样器的终端方差，无需重新训练，仅需一次前向分析。我们在第 4 节中使用该协议。

4 实验

4.1 精确数值评估

第 3.2 至 3.4 节的确定性仿射递归将有限步效应与采样和训练误差分离；每个量均以闭式形式计算，并交叉校验至机器精度（附录 7.3）。

图 2 验证了各项预测。对于 $P=v=4$ ，终端方差在 $T=10^5$ 处达到 3.9995，而 $v=0$ 坍塌（定理 2）。实测最优值遵循 $(2 \ln T)^{-1/2}$ 定律，比值从 $T=5$ 处的 1.29 降至 $T=10^5$ 处的 1.017（命题 1），且聚类网格展现出预测的多模态性（命题 2）。在双模态问题中，匹配分配在每个测试的 T 处均使 KL 散度最小；在 $T=200$ 处，贝叶斯风险顶点的 KL 散度高出 $294\times$ （附录 7.3 表 13）。优化后的 z 调度消除了参考颜色依赖性，达到数值精度（定理 4(a)），且预算最优值向预测的 P^2 分配移动（命题 3）。

4.2 学习得到的高斯模型

我们在 64–256 个独立模式上训练逐模式预测器，使用 $S_k \sim k^{-2}$ 、高斯调制传递函数和平坦观测噪声，在总预算相等（3 个种子，公共随机数）的情况下比较白化、匹配（ $v \propto P$ ）、反匹配（ $v \propto 1/P$ ）和先验着色（ $v \propto S$ ）参考。学习到的模型达到理论下限并重现其排序（图 3）。经过 12k 步后，相对于闭式贝叶斯下限的中位相对超额为 0.18%，远在预注册的 5% 门限之内。在 NFE 50 时，总 KL 从 0.19 ± 0.03 （匹配）到 4.3 ± 0.3 （先验着色）变化，




图 3：学习到的高斯模型。(a) 收敛损失相对于闭式贝叶斯下限的相对超额，针对 $\rho \in [0.1, 0.95]$ ：中位数 0.18%，对照预注册的 5% 门限。(b) 按参考的 NFE 与 KL 关系（3 个种子，均值 $\pm$ 标准差；虚线为精确漂移下限）。

白化和反匹配介于两者之间——在学习到的漂移下，精确漂移排序成立。在 NFE 200 时，增益误差（命题 4）主导离散化误差：匹配和白化在种子变异内重叠，而着色参考变得不稳定（附录 7.4）。

在模型准确的区域，测得的最优尺度与理论一致：0.575 vs. 0.577 在 $T=10$ 处，0.402 vs. 0.404 在 $T=50$ 处。在 $T=200$ 处，它比精确漂移值高 8%，这是命题 6 所预测的有限数据正则化方向；岭回归扫描、雅可比探针（预测终端方差的中位 0.6% 相对误差，无需重新训练）以及逐模式调度零假设见附录 7.4。

表 1：NFE 50 下的 FFHQ 恢复（原始方案； $\sigma_{\text{blur}}=2.0, \sigma_n=0.05$ ）。FID 来自 50k 样本；白化和匹配使用三个种子（均值 $\pm$ 标准差），其他使用一个种子，因此粗体差距 <0.1 在种子噪声范围内。

reference	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	FID $\downarrow$
white	25.01	0.836	0.0337	7.87$\pm$0.06
matched $v \propto P$	24.98	0.836	0.0344	8.45 $\pm$ 0.13
matched, equal budget	24.97	0.836	0.0370	9.12
anti-matched	25.75	0.854	0.0426	14.14
fixed color ($\alpha=1$)	25.04	0.837	0.0338	7.93
fixed color ($\alpha=2$)	25.21	0.840	0.0354	8.46




图 4：原始方案下的 FFHQ（公共随机数；匹配和白化为 3 个种子的均值 $\pm$ std）。(a) PSNR 和 (b) FID 随 NFE 变化：反匹配在每个 NFE 下获得最佳失真和最差感知——附录 6.5 的失真-感知权衡。(c) NFE 50 下径向误差谱，对照精确漂移预测 $2P(r) - D_0(r)$ （虚线）；参考差异集中在 MTF 截止频率附近（SSIM、LPIPS、误差比视图、训练指纹：附录 7.5）。

4.3 已知退化下的 FFHQ

我们在 64×64 下训练 FFHQ 上的桥模型，使用已知高斯模糊和平坦观测噪声；因此 P_k 和匹配参考由理论固定而非调优。所有参考共享一个训练方案、一个求解器和公共评估随机性（附录 7.5）。

两项预测完全吻合。首先，失真 - 感知权衡：在每个函数评估次数（NFE）下，反匹配均取得最佳峰值信噪比（PSNR）和结构相似性指数（SSIM），以及最差的感知相似度（LPIPS）和弗雷歇 inception 距离（FID）（表 1，图 4），正如理论对在传感器盲区抑制方差的参考所预测的那样：后验均值锐化，而采样细节丢失（附录 6.5）。其次，预测的频谱局部化：参考相关的误差差异集中在调制传递函数（MTF）截止频率附近，即 $P(k)$ 过渡处（图 4(c)）。

细粒度的匹配优先排序并不吻合。在测试的 NFE 范围内，白噪声和固定 $\alpha=1$ 参考获得的 FID 和 LPIPS 均低于匹配参考（表 1）。在定理 4 的 z 最优时间表上重新评估每个训练好的网络，对所有参考的改善幅度相近，且白噪声与匹配之间的差距几乎不变（ $0.58 \rightarrow 0.53$ ；附录 7.5），因此共同的离散化误差不能解释该差距。根据定理 5，剩余的是学习漂移：要么是尺度非等变学习（命题 6），要么是跨模式耦合。接下来的两项研究将它们分开。

表 2：在收敛配方法下（随机失活 0，批量 512，30 万步；固定预算下 $v \propto P_k^\theta$ ）的 FFHQ 结果。 FID 来自 5 万样本；端点表示 5 个种子上的均值 $\pm$ 标准差， θ 为一个种子。

reference	FID@10 $\downarrow$	FID@50 $\downarrow$	LPIPS@50 $\downarrow$
white ($\theta=0$)	9.62 $\pm$ 0.06	3.53 $\pm$ 0.02	0.0323
$\theta=0.25$	9.42	3.58	0.0326
$\theta=0.5$	9.75	3.78	0.0332
$\theta=0.75$	10.77	4.15	0.0343
matched ($\theta=1$)	12.05 $\pm$ 0.15	4.71 $\pm$ 0.09	0.0355

4.4 训练机制与参考指数

岭白化（命题 6）预测改进的优化应将最优参考移向 $v \propto P_k$ 。我们通过预先注册的干预和扫描 $v \propto P_k^\theta$, $\theta \in \{0, \frac{1}{4}, \frac{1}{2}, \frac{3}{4}, 1\}$ ，进行检验。收敛配方在绝对意义上同时改善了匹配和白噪声，但在相同的 5 万评估集上增大了匹配与白噪声之间的 FID 差距：在 NFE 10 时差距从 1.36 增至 2.43，在 NFE 50 时从 0.58 增至 1.18。因此端点预测被否定。

更强的模糊（ $\sigma_{\text{blur}}=4.0$ ）扩大了差距，在相同实验协议下于 CelebA [32] 上的重复实验再现了白噪声优先排序和失真 - 感知权衡（附录 7.7）。扫描揭示了预算依赖性。在低 NFE 下，轻度频谱着色是有益的： $\theta=0.25$ 在 NFE ≤ 20 时取得了观察到的最低 FID（表 2）。然而，随着预算增加，最优值移向白噪声，在 NFE ≥ 50 时所有报告的指标上表现最佳。因此，实验支持少步机制中的部分 P_k 着色。它们未解决每模式理论的实际失败是源于傅里叶模式间的依赖、非高斯每模式边缘分布，还是两者兼有。

4.5 机制研究：数据与耦合

非高斯性，而非模式耦合，解释了这种反转。 我们的 2×2 研究将模型耦合与数据统计分离开来。只要保留真实的 FFHQ 统计特性，即使耦合不可能发生，白噪声优于匹配参考的反转现象依然存在。在具有相同频谱但无高阶跨模式结构的高斯语料库上，匹配参考重新获得了低 NFE 优势：在 NFE 5 时 FID 从 19.3 改善到 13.5，在 NFE 10 时从 7.9 改善到 5.3。在 NFE 50 时，两种参考几乎持平。耦合探针显示，在 FFHQ 训练的 U-Net 中存在显著的离对角傅里叶响应，在高斯训练的模型中大约少十倍，在逐模式模型中数值为零。反转跟随数据而非耦合：在耦合数值为零的逐模式模型中反转依然存在，而当具有耦合能力的 U-Net 在高斯数据上训练时反转消失。因此，FFHQ 训练网络中的耦合是非高斯图像统计的征兆，而非操作原因；在真实图像上失效的是逐模式高斯性假设，而不仅仅是解耦假设。NFE 50 时的接近持平与定理 2 的精确漂移不可见极限一致，在该极限下参考差距随着步数预算增加而消失。该定理并不保证对于学习的非高斯模型成立，因为漂移误差不一定随 NFE 消失；事实上，在 § 4.2 中，有色参考在 NFE 200 时不稳定。

5 结论

我们为薛定谔桥模型开发了参考设计理论。在精确漂移和无限步数下，参考是不可见的；在有限预算下，每个最优解都与被破坏的信息谱 P_k 成比例，颜色和调度完全可交换。在真实图像上，这种排序发生反转，受控研究将反转追溯到非高斯逐模式统计。由此产生的配方依赖于预算：在少步数阶段使用温和的 P_k 着色，否则使用白噪声，两种情况均采用 z 最优调度。因此，将理论扩展到高斯条件模式之外是未来工作的主要方向。

6 附录

6.1 概述

除了表 4 中收集的六个教科书事实外，每个论证都在此从第一性原理证明。第 6.2 – 6.5 节按主要文本中结果出现的顺序给出证明。第 7 节提供实验协议和额外结果。

表 3 收集了符号。以下各处均采用三个约定。

1. 以观测为条件。关于采样器的所有陈述均以 x_1 为条件。除非另有说明，期望、方差和 KL 散度均以 x_1 为条件。2. 逐模式约简。在定理 1 之后，我们在对角化基中工作，并且只要陈述涉及单一模式，就省略模式索引 k 。仅当模式通过预算（附录 6.4）或共享学习器（附录 6.5）耦合时，对 k 的求和才重新出现。3. 网格。网格为 $0 = \rho_0 < \rho_1 < \dots < \rho_T = 1$ ，且 i 从 T （观测端）向下运行至 0（干净端），这是采样器行进的方向。

表 4 列出了我们使用的六个教科书事实，并附有全文引用时使用的标签 (S1) – (S6)。柯西-施瓦茨不等式（定理 6(ii)）和中值定理（定理 2(a)）仅以其基本形式使用，未列入表中。

6.2 第 3.1 节（可处理性）的证明

一般高斯桥

我们首先证明，每个确定性矩阵值协方差在多元层面上都给出一个可处理的桥。然后，定理 1 精确地确定了这种可处理性何时分离为标量模式。

引理 1（精确固定边缘）。对于每个 $t \in (0, 1)$ ，

$$X_t \mid (X_0=x_0, X_1=x_1) \sim \mathcal{N}(\mu_t, \Gamma_t), \quad (13)$$

其中

$$\mu_t := x_0 + A(t)V^{-1}(x_1 - x_0), \quad (14)$$

$$\Gamma_t := A(t) - A(t)V^{-1}A(t). \quad (15)$$

证明。在 $X_0 = x_0$ 条件下。则

$$X_t = x_0 + \int_0^t L dB, \quad X_1 = x_0 + \int_0^1 L dB, \quad (16)$$

so $\text{Var}(X_t \mid X_0) = A(t)$ 与 $\text{Var}(X_1 \mid X_0) = V$ 。布朗增量的独立性 $\text{Cov}(X_t, X_1 \mid X_0) = A(t)$ 给出。对联合高斯对应用高斯条件化 (S1) (X_t, X_1) proves the claim. $\square$

引理 2（精确反向子桥核函数）。对于 $0 < s < t \leq 1$ 且 $A(t) \succ 0$ ，

$$X_s \mid (X_t=x_t, X_0=x_0) \sim \mathcal{N}(\mu_{s|t}, \Gamma_{s|t}), \quad (17)$$

其中

$$\mu_{s|t} := x_0 + A(s)A(t)^{-1}(x_t - x_0), \quad (18)$$

$$\Gamma_{s|t} := A(s) - A(s)A(t)^{-1}A(s), \quad (19)$$

并且进一步 $\mathcal{L}(X_s \mid X_t, X_0, X_1) = \mathcal{L}(X_s \mid X_t, X_0)$ 。

证明。在 X_0 条件下。对 (X_s, X_t) 是联合高斯的，具有 $\text{Var}(X_s \mid X_0) = A(s)$ ， $\text{Var}(X_t \mid X_0) = A(t)$ 与 $\text{Cov}(X_s, X_t \mid X_0) = A(s)$ ，因此高斯条件化 (S1) 给出所述核函数。最后的等式是双侧马尔可夫性质 (S3)：在 X_t 条件下，过去与未来端点独立。

表 3：符号。故意重载标记为 $\dagger$ ；它们不会出现在同一论证中。

<i>Signals, spectra, modes</i>	
x_0, x_1	clean signal; observation
X_t	bridge state, $t \in [0, 1]$
U, k	orthogonal diagonalizer; mode index
S_k, h_k, N_k	prior power, transfer function, observation noise
P_k	posterior variance of mode k given x_1
W	posterior-mean (Wiener) operator, $\mathbb{E}[x_0 x_1] = Wx_1$
v_k	reference variance of mode k — the <i>color</i>
V	total budget $\sum_k v_k$ (App 6.4) $\dagger$
<i>Reference process</i>	
$Q(t)$	instantaneous increment covariance
$A(t)$	$\int_0^t Q$; $V = A(1)$ $\dagger$
q_k, a_k	modal versions of Q, A ; $v_k = a_k(1)$
$\rho_k(t)$	schedule $a_k(t)/v_k$, increasing from 0 to 1
$\beta(t)$	rate of a static-color reference (Cor. 3)
<i>Grids and coordinates</i>	
T	number of sampler steps (NFE)
$\rho_i, \Delta\rho_i$	grid level; $\rho_i - \rho_{i-1}$
r_i	ρ_{i-1}/ρ_i
x	v/P , the only dimensionless color parameter
$\varphi(\rho)$	$(1 - \rho)P + v\rho = P\psi(\rho)$
$\psi(\rho)$	$1 + (x - 1)\rho$; $b := 1 - x$
$M(\rho)$	conditional MMSE at level ρ
$z(\rho)$	$v\rho/\varphi(\rho) \in [0, 1]$, the solver coordinate
$z_i, \Delta z_i$	$z(\rho_i)$; $z_i - z_{i-1}$
a_i, ε_i	z_{i-1}/z_i ; $1 - a_i$ (App 6.4)
s	continuum solver time, $z = z(s)$
<i>Sampler, deficit, objective</i>	
$a(\xi)$	frontier launch point, root of $\ln \frac{1}{a} - (1 - a) = \xi$ (Theorem 6)
x_{ρ_i}	sampler state at level ρ_i , conditional on x_1
ξ, ξ_i	standard Gaussian noise (bridge; sampler step i) $\dagger$
$K(\rho)$	regression gain of the plug-in drift
A_i, B_i, q_i	affine-recursion coefficients $\dagger$
c_i, V_i	mean and variance coefficients of the plug-in chain $\dagger$
$\Sigma(\rho)$	variance of the exact ancestral chain
D_i, D_0	variance deficit $\Sigma(\rho_i) - V_i$; its terminal value
$H(x)$	D_0/P
$F(z)$	$\sum_i (\Delta z_i)^2 / z_i$; equals H under $z = z(\rho)$
$\Phi(x)$	terminal KL, $\frac{1}{2}(u - 1 - \ln u)$ with $u = 1 - H$
$\mathcal{H}_T$	harmonic number $\sum_{i \leq T} 1/i$
χ_T	$(2 \ln T)^{-1/2}$, the target point
$\mathcal{W}_T$	localization window $[\chi_T/3, 3\chi_T]$
η_i, β_i	relative gain error; additive bias at step i
Ξ, ξ	gain-error susceptibility; its budget $\dagger$
λ	ridge penalty (App 6.5); Lagrange multiplier (App 6.4)

表 4：标准事实，无需证明即可使用。这些是附录 6.2 – 6.5 中唯一的外部成分。

	Fact	Used in
(S1)	<i>Gaussian conditioning.</i> If (X, Y) is jointly Gaussian with $\text{Cov}(X, Y) = C$ and $\text{Var}(Y) = \Sigma_Y \succ 0$, then $X Y=y \sim \mathcal{N}(\mathbb{E}X + C\Sigma_Y^{-1}(y - \mathbb{E}Y), \text{Var}(X) - C\Sigma_Y^{-1}C^\top)$. If Σ_Y is singular the same formula holds on $\text{ran } \Sigma_Y$ with the Moore–Penrose pseudoinverse in place of Σ_Y^{-1} [1, Theorem 2.5.1].	Lemmas 1–2, Cor. 5
(S2)	<i>Simultaneous diagonalization.</i> A family of real symmetric matrices is simultaneously orthogonally diagonalizable if and only if its members commute pairwise [18, Ch. 4.5].	Theorem 1, step (1) $\Rightarrow$ (2)
(S3)	<i>Linear SDEs; two-sided Markov property.</i> A linear SDE with deterministic coefficients is solved by variation of constants and has Gaussian marginals with deterministic covariance; and for a Markov process, conditionally on X_t the past $\sigma(X_s : s \leq t)$ is independent of the future $\sigma(X_u : u \geq t)$ [23, 34].	Lemma 2, Cor. 5, Lemma 5
(S4)	<i>Riemann-sum error via total variation.</i> For f of bounded variation on $[c, d]$ and any partition, the sum of the oscillations of f over the subintervals is at most $\text{TV}_{[c,d]}(f)$; for f monotone on each of two subintervals, $\text{TV}(f)$ is bounded by the sum of its endpoint values [36, Ch. 6].	Lemmas 8, 12
(S5)	<i>Descartes’ rule of signs.</i> The number of positive real roots of a nonzero real polynomial, counted with multiplicity, is at most the number of sign changes in its coefficient sequence, and differs from it by an even number; see [2, Ch. 2] for its use in exact certificates.	the exact integer uniqueness certificates for $2 \leq T \leq 120$, App 6.4
(S6)	<i>Gaussian KL.</i> For $p = \mathcal{N}(\mu_1, \sigma_1^2)$ and $q = \mathcal{N}(\mu_2, \sigma_2^2)$, $\text{KL}(p \ q) = \frac{1}{2}(u - 1 - \ln u) + \frac{(\mu_1 - \mu_2)^2}{2\sigma_2^2}$ with $u = \sigma_1^2/\sigma_2^2$ [7, Ch. 8].	Theorem 2, Prop. 1, Theorem 5, and the definition of Φ throughout App 6.4

若 $A(t)$ 是奇异的，则核 $A(t)$ 中的方向在时间 t 之前未累积噪声，并保持确定性地等于 x_0 。在值域 $A(t)$ 上应用核函数，或等价地将 $A(t)^{-1}$ 替换为伪逆。在模态设置中，这是具有 $a_k(t) = 0$ 的模态的约定。在采样器的网格上，仅 $\rho_0 = 0$ 是退化的，且在那里不采取反向步骤。□

定理 1 的证明

证明。 **(1) $\Rightarrow$ (2).** 每个 $Q(t)$ 是实对称的，因此可正交对角化。 $\{Q(t) : t \notin N\}$ 的线性张成是对称矩阵的一个有限维子空间，因此该族中有限多个成员 $Q(t_1), \dots, Q(t_m)$ 张成它。由 (1) 可知这些矩阵两两交换，而有限个实对称矩阵的交换族可同时正交对角化 (S2)：先对角化一个矩阵，观察到其他每个矩阵都保持其特征子空间，然后对限制递归进行。所得的 U 对角化 $Q(t_1), \dots, Q(t_m)$ ，从而对角化它们张成空间中的每个矩阵，进而对角化 N 之外的每个 $Q(t)$ 。在零测集上重新定义 Q 不改变随机微分方程的分布。最后 $Q \succeq 0$ 迫使所有对角元素非负。**(2) $\Rightarrow$ (3).** 在坐标 $Y = U^\top X$ 下，增量协方差为 $U^\top Q(t)U dt = \text{diag}(q_k(t)) dt$ ，因此可以选择确定性的对角平方根。这些坐标在所有时刻都是联合高斯的，且互协方差为零，因此是独立的标量高斯过程，每个都是在时钟 $a_k(t)$ 下的布朗运动。**(3) $\Rightarrow$ (1).** 固定基下的独立标量模式在该基下具有对角的瞬时协方差，因此所有 $Q(t)$ 共享对角化矩阵 U ；对角矩阵可交换。

固定公式。将对角化 $A(t) = U \text{diag}(a_k(t))U^\top$ 和 $V = U \text{diag}(v_k)U^\top$ 代入引理 1。在模式 k 下，均值为

$$y_{k,0} + \frac{a_k(t)}{v_k}(y_{k,1} - y_{k,0}) = (1 - \rho_k)y_{k,0} + \rho_k y_{k,1}, \quad (20)$$

方差为

$$a_k(t) - \frac{a_k(t)^2}{v_k} = v_k \rho_k(1 - \rho_k). \quad (21)$$

条件协方差是对角的，因此模式保持独立。代入引理 2 得到反向均值系数 $a_k(s)/a_k(t) = r_k(s, t)$ 和方差 $a_k(s)(1 - r_k(s, t))$ 。□

推论 1 的证明

证明。绝对连续性给出 $a_k(t) = \int_0^t q_k = v_k \rho_k(t)$ 。 q_k 的非负性等价于 ρ_k 的单调性，端点条件给出 $a_k(0) = 0$ 和 $a_k(1) = v_k$ 。反之，定义 $\rho_k := a_k/v_k$ 。□

四个结论仅在此处陈述。

推论 3 (静态颜色是严格子族)。假设 $Q(t) = \beta(t)\Sigma$ 满足 $\Sigma = U \text{diag}(v_k)U^\top$ 和 $\int_0^1 \beta = 1$ 。则定理 1 适用于共享调度 $\rho_k \equiv \rho(t) = \int_0^t \beta$ 和模式相关总量 v_k 。白色 I^2 SB 是特例 $\Sigma = cI$ 。因此固定颜色允许不同的 v_k ，但迫使每个模式使用相同的 ρ 。

推论 4 (混叠分块)。假设 $d = E_1 \oplus \dots \oplus E_m$ 是固定正交分解，且每个 $Q(t)$ 关于它都是块对角的。则引理 1–2 将桥分解为独立的有限维块，即使块内矩阵不可交换；每个块使用 $A(t)$ 和 V 中的矩阵公式。这是下采样混叠的正确处理方式：一个频率及其折叠形成一个耦合块，小的矩阵值块调度取代标量调度。

证明。令 Π_j 为到 E_j 上的正交投影。由于每个 $Q(t)$ 是块对角的， $A(t) = \int_0^t Q$ 和 $V = A(1)$ 也是。写出 $X_t^{(j)} := \Pi_j X_t$ ，对于 $j \neq l$ ，增量满足

$$\text{Cov}(X_t^{(j)} - X_s^{(j)}, X_t^{(l)} - X_s^{(l)}) = \Pi_j(A(t) - A(s))\Pi_l^\top = 0, \quad (22)$$

因此联合高斯块过程 $(X^{(j)})_j$ 相互独立。从而固定边际和反向核按块分解，矩阵公式逐块应用于 $A^{(j)}(t) := \Pi_j A(t)\Pi_j^\top$ 和 $V^{(j)} := \Pi_j V \Pi_j^\top$ 。未使用块内的交换性。□

推论 5 (同时对角化线性漂移和扩散)。考虑 $dX_t = F(t)X_t dt + L(t)dB_t$ ，并假设单个正交 U 同时对角化两个系数， $U^\top F(t)U = \text{diag}(f_k(t))$ 和 $U^\top Q(t)U = \text{diag}(q_k(t))$ a.e. Put

$$g_k(t, s) := \exp \int_s^t f_k, \quad \sigma_k^2(t) := \int_0^t g_k(t, u)^2 q_k(u) du. \quad (23)$$

则参考过程和所有固定桥精确分解为标量模式，其中

$$\begin{aligned} \mathbb{E}[Y_{k,t} \mid y_{k,0}, y_{k,1}] &= g_k(t, 0) y_{k,0} \\ &\quad + \frac{\sigma_k^2(t) g_k(1, t)}{\sigma_k^2(1)} (y_{k,1} - g_k(1, 0) y_{k,0}), \end{aligned} \quad (24)$$

$$\begin{aligned} \text{Var}(Y_{k,t} \mid y_{k,0}, y_{k,1}) &= \sigma_k^2(t) \\ &\quad - \frac{\sigma_k^2(t)^2 g_k(1, t)^2}{\sigma_k^2(1)}, \end{aligned} \quad (25)$$

且对于 $0 < s < t$ ，反向核函数的均值为

$$g_k(s, 0) y_{k,0} + \frac{\sigma_k^2(s) g_k(t, s)}{\sigma_k^2(t)} (y_{k,t} - g_k(t, 0) y_{k,0}) \quad (26)$$

方差为 $\sigma_k^2(s) - \sigma_k^2(s)^2 g_k(t, s)^2 / \sigma_k^2(t)$ 。

证明。常数变易法 (S3) 给出 $Y_{k,t} = g_k(t, 0)y_{k,0} + \int_0^t g_k(t, u)\sqrt{q_k(u)} dB_{k,u}$, whence

$$\text{Var}(Y_{k,t} | y_{k,0}) = \sigma_k^2(t), \quad (27)$$

$$\text{Cov}(Y_{k,t}, Y_{k,1} | y_{k,0}) = \sigma_k^2(t) g_k(1, t), \quad (28)$$

$$\text{Cov}(Y_{k,s}, Y_{k,t} | y_{k,0}) = \sigma_k^2(s) g_k(t, s). \quad (29)$$

高斯条件化 (S1) 给出所述公式, 且各模态间的独立性由共同对角化得出。□

注 1 (希尔伯特空间)。假设 $\mathbb{H}$ 是可分的, 协方差算子与 $Q(t)e_k = q_k(t)e_k$ 共享一组标准正交特征基, 且 $\sum_k v_k < \infty$ (迹类)。则参考过程为取值于 $\mathbb{H}$ 的高斯过程, 定理 1 可逐坐标应用, 高斯级数在 $L^2(\Omega; \mathbb{H})$ 中收敛。对于柱状噪声, 模态恒等式在更大的分布空间中仍保持形式意义。对于离散图像, 有限维定理已足够。复傅里叶系数可通过酉/埃尔米特形式处理, 或将共轭对分组为二维实块 (推论 4)。

6.3 第 3.2 节 (不可见性) 的证明

作为仿射递归的采样器

写出 $\bar{c}_i := (1 - \rho_i)W + \rho_i$ 。从层级 ρ_i 到 ρ_{i-1} 的插件步骤为

$$\hat{x}_0 = Wx_1 + K(\rho_i)(x_{\rho_i} - \bar{c}_i x_1), \quad (30)$$

$$x_{\rho_{i-1}} = \hat{x}_0 + r_i(x_{\rho_i} - \hat{x}_0) + \sqrt{q_i}\xi_i, \quad (31)$$

以 $r_i = \rho_{i-1}/\rho_i$ 和 $q_i = v\rho_{i-1}(1 - r_i)$ 。每个操作在 (x, x_1) 中是仿射的, 并添加独立的高斯噪声。在 x_1 条件下, 状态因此恰好为 $\mathcal{N}(c_i x_1, V_i)$, 其中

$$A_i = r_i + (1 - r_i)K(\rho_i), \quad (32)$$

$$B_i = (1 - r_i)(W - K(\rho_i)\bar{c}_i), \quad (33)$$

$$c_{i-1} = A_i c_i + B_i, \quad c_T = 1, \quad (34)$$

$$V_{i-1} = A_i^2 V_i + q_i, \quad V_T = 0. \quad (35)$$

引理 3 (对于所有 i , 在任意网格、任意 $T \geq 1$ 和任意 $v \geq 0$ 下, 每个 T , $c_i = (1 - \rho_i)W + \rho_i$ 处的均值精确性。特别地, $c_0 = W$ 精确成立。)

证明。反向归纳。基础情形: $c_T = 1 = (1 - \rho_T)W + \rho_T$ 。步骤: 将 $c_i = \bar{c}_i$ 代入 (34)。包含 $K(\rho_i) - \bar{c}_i$ 的两项精确抵消, 留下

$$\begin{aligned} c_{i-1} &= r_i \bar{c}_i + (1 - r_i)W \\ &= W(1 - r_i \rho_i) + r_i \rho_i \\ &= (1 - \rho_{i-1})W + \rho_{i-1}, \end{aligned} \quad (36)$$

其中我们使用了 $r_i \rho_i = \rho_{i-1}$ 。□

引理 4 (Exact telescoping). $A_i = \varphi(\rho_{i-1})/\varphi(\rho_i)$, and hence

$$\prod_{m=j+1}^i A_m = \frac{\varphi(\rho_j)}{\varphi(\rho_i)}, \quad \prod_{m=1}^i A_m = \frac{P}{\varphi(\rho_i)}. \quad (37)$$

证明。根据 (32), $[r_i \varphi(\rho_i) + (1 - r_i)P]/\varphi(\rho_i)$, 且分子可裂项相消:

$$\begin{aligned} A_i &= \frac{r_i \varphi(\rho_i) + (1 - r_i)P}{\varphi(\rho_i)} = r_i[(1 - \rho_i)P + v\rho_i] + (1 - r_i)P \\ &= P(1 - r_i \rho_i) + v r_i \rho_i \\ &= P(1 - \rho_{i-1}) + v \rho_{i-1} \\ &= \varphi(\rho_{i-1}). \end{aligned} \quad (38)$$

□

引理 5（单步恒等式与亏量递推）。设
之间的差距。则

$D_i := \Sigma(\rho_i) - V_i$ 为精确祖先链与插件链

$$D_{i-1} = A_i^2 D_i + (1 - r_i)^2 M(\rho_i), \quad D_T = 0. \quad (39)$$

每一项均非负，且当 $v > 0$ 时源项严格为正；由此证明推论 2。

证明。由双侧马尔可夫性质（S3），精确祖先链在每一层都重现真实条件律。该链抽取 $x_0 \sim \mathcal{N}(\cdot, M(\rho_i))$ 而非用条件均值替换变量，因此其方差满足

$$\Sigma(\rho_{i-1}) = A_i^2 \Sigma(\rho_i) + (1 - r_i)^2 M(\rho_i) + q_i. \quad (40)$$

插件链满足省略中间项的同一递推，即（35）。相减得到（39）。 D_0 的非负性由 $D_T = 0$ 向后归纳立得。□

引理 6（亏量的闭式表达）。对任意网格及任意 $T \geq 1$ ，

$$D_0 = vP^3 \sum_{i=1}^T \frac{(\Delta \rho_i)^2}{\rho_i \varphi(\rho_i) \varphi(\rho_{i-1})^2}. \quad (41)$$

对均匀网格上的 $P = v$ ，此式简化为 $D_0 = (P/T)\mathcal{H}_T$ ，其中 $\mathcal{H}_T$ 为第 T 个调和数。

证明。展开（39）式从 $D_T = 0$ 开始，并利用（37）式处理累积的收缩，同时结合一步恒等式

$$(1 - r_i)^2 M(\rho_i) = \frac{vP(\Delta \rho_i)^2}{\rho_i \varphi(\rho_i)}. \quad (42)$$

每个存留项获得因子 $(P/\varphi(\rho_{i-1}))^2$ ，从而在分母中产生所述的 $\varphi(\rho_{i-1})^2$ 以及整体的 P^3 。当 $P = v$ 时，我们有 $\varphi \equiv P$ ，因此求和式坍塌为 $\sum_i (\Delta \rho_i)^2 / \rho_i = (1/T) \sum_{i \leq T} 1/i$ 。□

定理 2 的证明

证明。（a） $v > 0$ 。令 $\varphi_{\min} = \min(P, v) > 0$, $\varphi_{\max} = \max(P, v)$ 并设

$$\Theta_T := \sum_{i=1}^T \frac{(\Delta \rho_i)^2}{\rho_i} \quad (43)$$

为（41）式的纯几何部分。由于在 $[0, 1]$ 上 $\varphi_{\min} \leq \varphi(\rho) \leq \varphi_{\max}$ ，

$$\frac{vP^3}{\varphi_{\max}^3} \Theta_T \leq D_0 \leq \frac{vP^3}{\varphi_{\min}^3} \Theta_T. \quad (44)$$

因此只需证明 $\Theta_T \rightarrow 0$ 。

Uniform grid. $\Theta_T = (1/T)\mathcal{H}_T = (\log T)/T + O(1/T)$ 。

电网 $\rho_i = (i/T)^a$, $a > 1$ 。中值定理给出 $\Delta \rho_i \leq a i^{a-1}/T^a$ ，因此

$$\frac{(\Delta \rho_i)^2}{\rho_i} \leq \frac{a^2 i^{a-2}}{T^a}. \quad (45)$$

求和项并非一致地具有 T^{-2} 阶： $i = 1$ 项为 T^{-a} 。现在 $u \mapsto u^{a-2}$ 在 $[1, \infty)$ 上单调（当 $1 < a \leq 2$ 时非增，当 $a \geq 2$ 时非减），因此逐项将求和与积分比较——在非增情形下单独加上第一项——可得

$$\begin{aligned} \sum_{i=1}^T i^{a-2} &\leq 1 + \int_1^{T+1} u^{a-2} du \\ &\leq \left(1 + \frac{2^{a-1}}{a-1}\right) T^{a-1}, \end{aligned} \quad (46)$$

其中我们使用了 $(T+1)^{a-1} \leq (2T)^{a-1}$ 和 $1 \leq T^{a-1}$ 。因此

$$\Theta_T \leq a^2 \left(1 + \frac{2^{a-1}}{a-1}\right) \frac{1}{T} = O(1/T). \quad (47)$$

在两种情况下 $D_0 \rightarrow 0$ 由 (44), so $V_0 \rightarrow P$ 。引理 3 表明均值已经精确, 因此终端律收敛到 $\mathcal{N}(Wx_1, P)$ 。由 (S6) 终端 KL 为

$$\frac{1}{2} \left(\frac{V_0}{P} - 1 - \log \frac{V_0}{P} \right) = \frac{D_0^2}{4P^2} + O((D_0/P)^3), \quad (48)$$

且极限律既不依赖于 v 也不依赖于调度。 **(b)** $v = 0$ 。所有 $q_i = 0$, so $V_i \equiv 0$ 且终端律是 $c_0 x_1 = Wx_1$ 处的点质量; 引理 3 仍然有效。从 $\rho = 1$ 开始的第一步直接由 $\hat{x}_0 = Wx_1$ 定义, 因为缩放偏差恒为零。因此 $\text{KL}(\delta(Wx_1) \parallel \mathcal{N}(Wx_1, P)) = +\infty$ 。从 v to t 到极限律的映射在 $v > 0$ 上为常数, 并在 $v = 0$ 处跳跃。 $\square$

为什么无资源目标会退化

积分贝叶斯风险目标

$$J = \sum_k \int w(t) \text{MMSE}_k(t) dt \quad (49)$$

在每个 v_k 上是凹的且递增的。在预算下, 匹配点确实满足拉格朗日条件——但它是最大值; 最小值位于顶点分配处。一个显式反例是 $\rho = 0.5, P = (1, 4)$ 且预算为 5: 匹配值为 2.5, 而顶点分配给出 0.833。

最小化目标贝叶斯风险会奖励一个对 x_0 具有最大信息量的桥接状态, 并且在没有资源约束的情况下最优解是 $v = 0$ 。该选择使插值成为确定性的, 将方法简化为一次性维纳回归, 并破坏了分布正确性, 因为终端方差趋于 0。一个最优解位于 $v = 0$ 边界上的目标不适合用于桥接, 因为桥接的目的是分布性的。

6.4 第 3.3 节证明 (有限步)

定理 3 的证明

证明。步骤 1 (尺度对称性)。将 $\varphi(\rho) = P\psi(\rho)$ 写为 $\psi(\rho) = 1 + (x-1)\rho$ 与 $x = v/P$ 。在 (41) 中, 因子 P^3 抵消了由 φ 项贡献的三个 F 因子, 剩余因子为 $v = xP$ 。因此 x 在无量纲表达式中保留, 而 F 归一化 D_0 : $\frac{D_0}{P}$

$$P = xG(x), \quad G(x) = \sum_i \frac{(\Delta\rho_i)^2}{\rho_i \psi(\rho_i) \psi(\rho_{i-1})^2}. \quad (50)$$

因此 $\text{KL} = \Phi(x)$ 仅通过 x 依赖于参考, 其余仅依赖于网格。结构上, F 是逐模式高斯问题中唯一的尺度, 而 v/F 是其唯一的无量纲参数。

步骤 2 (每个优化器的形式)。由步骤 1, $\sum_k \text{KL}_k = \sum_k \Phi(v_k/P_k)$ 在每个模式中具有相同的函数

Φ , 因此目标函数是可分离的。在任何局部极小值处, 每个坐标 $x_k = v_k/P_k$ 必须是 Φ 的局部极小值, 但不同坐标可能选择不同的局部极小值, 因此不强制要求共同的模式无关 x 。在任何全局极小值处 $x_k \in \arg \min \Phi$ 对于每个 k 。如果 $\arg \min \Phi$ 是单元素集 $\{x^*\}$, 则 $v_k^* = x^* P_k$ 对于每个模式, 其中 x^* 与模式无关。如果 Φ 有多个局部极小值——根据命题 2, 这在一般网格上确实会发生——那么将不同模式分配到不同的谷值会产生总和的真正非比例局部优化器。

步骤 3 (障碍, 因此内部最优)。当 $x \rightarrow 0$ 时, $xG(x)$ 的观测端项 ($i=T$) 趋于 1: 采样器在没有参考噪声的情况下无法产生后验方差, 与定理 2(b) 完全一致。因此 $u \rightarrow 0$ 且 $\Phi \rightarrow \infty$ 。当 $x \rightarrow \infty$ 时, $xG(x)$ 的干净端项 ($i=1$) 趋于 1: 进入最终贝叶斯步骤的过量噪声无法被完全去除, 因此再次 $\Phi \rightarrow \infty$ 。由于 Φ 在 $(0, \infty)$ 上连续, 它达到内部最小值。两个障碍在图 5 的左面板中可见。 $\square$

命题 1 的证明：常数 $x^*(T)$

本小节采用两项约定。首先，命题 1 陈述中的窗口中心 x_0 在此处为量 $\chi_T = (2 \ln T)^{-1/2}$ ；符号 x_0 保留给干净信号。其次，极小化元指 Φ 在 $(0, \infty)$ 上的全局极小化元；命题 1 在此意义下证明。

本小节中网格是均匀的， $\rho_i = i/T$ ，且我们记

$$H(x) := \frac{D_0}{P} = \frac{x \mathcal{S}(x)}{T}, \quad (51)$$

$$\mathcal{S}(x) := \frac{1}{T} \sum_{i=1}^T \frac{1}{\rho_i \psi_i \psi_{i-1}^2}, \quad (52)$$

$$\psi_i := \psi(i/T) = 1 - b \frac{i}{T}, \quad b := 1 - x. \quad (53)$$

We also set

$$f(\rho) := \frac{1}{\rho \psi(\rho)^3}, \quad \mathcal{S}^\circ(x) := \frac{1}{T} \sum_{i=1}^T f(\rho_i), \quad (54)$$

$$h(x) := x \ln T + \frac{1}{2x}, \quad \chi_T := (2 \ln T)^{-1/2}, \quad (55)$$

且 $\mathcal{W}_T := [\chi_T/3, 3\chi_T]$ 。比较函数 h 在 $(0, \infty)$ 上严格凸，具有唯一极小化元 χ_T ，最小值 $h(\chi_T) = \sqrt{2 \ln T}$ 且 $h''(x) = x^{-3}$ 。最后， $\Phi(x) = \frac{1}{2}(u - 1 - \ln u)$ 且 $u = 1 - H(x) \in (0, 1)$ 关于 u , so 严格递减，极小化 Φ 等价于极小化 H 。我们始终使用缩放量 TH 。

证明分四步比较 TH 与 h ：替换平移网格因子（引理 7），将求和替换为积分（引理 8），以闭式形式计算该积分（引理 9），并合并（引理 10）。引理 11 随后将极小化元限制在 $\mathcal{W}_T$ 内，其中比较是一致的。




图 5： $TH(x)$ 的景观，以及极小化元为何被局部化。左：定理 3 第 3 步的两个障碍——两端处的 $\Phi \rightarrow \infty$ ——每个 T 均标出精确极小化元。右：在 $T = 10^4$ 处，精确 TH 与引理 10 的比较函数 $h(x) = x \ln T + \frac{1}{2x}$ 相对照；加性间隙为 $1 + o(1)$ ，阴影带为引理 11 的窗口 $\mathcal{W}_T = [\chi_T/3, 3\chi_T]$ ，且 x^* 已几乎达到 $\chi_T = (2 \ln T)^{-1/2}$ 。由 (41) 式计算；无仿真。

引理 7（网格平移替换）。 对于 $0 < x < 1$ 和 $T \geq 2$,

$$\left(1 + \frac{1}{Tx}\right)^{-2} \mathcal{S}^\circ(x) \leq \mathcal{S}(x) \leq \mathcal{S}^\circ(x). \quad (56)$$

Proof. $\psi_{i-1} = \psi_i + b/T$ 其中 $0 < b < 1$ ，且 $\psi_i \geq \psi_T = x$, so $\psi_i \leq \psi_{i-1} \leq \psi_i(1 + \frac{1}{Tx})$. Square 并逐项求逆。□

Lemma 8 (Riemann comparison). For $0 < x \leq \frac{3}{4}$ 和 $T \geq 8$,

$$\left| \mathcal{S}^\circ(x) - 1 - \int_{1/T}^1 f(\rho) d\rho \right| \leq 1 + \frac{12}{T} + \frac{1}{Tx^3}. \quad (57)$$

证明。对数导数 $(\ln f)'(\rho) = -1/\rho + 3b/\psi(\rho)$ 仅在 $\rho^* = 1/(4b) \leq 1$, 处为零, 利用 $b \geq \frac{1}{4}$ 。因此 f 在 $(0, \rho^*)$ 上严格递减, 在 $[\rho^*, 1]$ 上严格递增。

Separate the initial term first. For $T \geq 8$,

$$\frac{1}{T}f(1/T) = \psi(1/T)^{-3} \in [1, 1 + \frac{6}{T}], \quad (58)$$

because $\psi(1/T) \geq 1 - 1/T$ $(1 - u)^{-3} \leq 1 + 6u$ on $[0, \frac{1}{8}]$. For each remaining interval, $|\frac{1}{T}f(\rho_i) - \int_{\rho_{i-1}}^{\rho_i} f| \leq \frac{1}{T}$ 且 $\frac{1}{T}$ 振荡 $[\rho_{i-1}, \rho_i]$ f , 由 (S4) 可知这些振荡之和至多为 $\text{TV}(f)$ 。因为 f 先减后增, $\text{TV}(f) \leq f(1/T) + f(1)$ 。因此

$$\begin{aligned} \left| \sum_{i=2}^T \frac{1}{T}f(\rho_i) - \int_{1/T}^1 f \right| &\leq \frac{1}{T}(f(1/T) + f(1)) \\ &\leq \psi(1/T)^{-3} + \frac{1}{Tx^3} \\ &\leq 1 + \frac{6}{T} + \frac{1}{Tx^3}. \end{aligned} \quad (59)$$

结合两个展示式即可得证。 $\square$

引理 9 (闭形式积分)。对于 $0 < x < 1$ 和 $T \geq 3$,

$$x \int_{1/T}^1 f(\rho) d\rho = x \ln T + \frac{1}{2x} + 1 + x \ln \frac{1}{x} - \frac{3x}{2} + \theta, \quad (60)$$

含 $|\theta| \leq 6x/T$ 。

证明。在 $(1 - u)(1 + u + u^2) = 1 - u^3$ 中通分, 利用 $u = 1 - b\rho$ 得到部分分式恒等式

$$\frac{1}{\rho\psi^3} = \frac{1}{\rho} + \frac{b}{\psi} + \frac{b}{\psi^2} + \frac{b}{\psi^3}, \quad (61)$$

其原函数为

$$F(\rho) = \ln \frac{\rho}{\psi(\rho)} + \frac{1}{\psi(\rho)} + \frac{1}{2\psi(\rho)^2}, \quad F' = f. \quad (62)$$

Hence $\int_{1/T}^1 f = F(1) - F(1/T)$ with $F(1) = \ln \frac{1}{x} + \frac{1}{x} + \frac{1}{2x^2}$. Also $\psi(1/T) = 1 - b/T \in [1 - \frac{1}{T}, 1]$, so

$$\begin{aligned} F(1/T) &= -\ln T - \ln \psi(1/T) + \frac{1}{\psi(1/T)} + \frac{1}{2\psi(1/T)^2} \\ &= -\ln T + \frac{3}{2} + O\left(\frac{1}{T}\right). \end{aligned} \quad (63)$$

对于 $T \geq 3$, 该余项的绝对值至多为 $6/T$ 。乘以 x 即完成证明。(在 $T = 2$ 处, 常数 6 勉强不满足 $x \rightarrow 0$; 这无碍, 因为引理 10 仅用于较大的 T , 而命题 2 精确处理 $T = 2$ 。) $\square$

引理 10 (窗口上的一致展开)。设

$$\delta_T := \sup_{x \in \mathcal{W}_T} |TH(x) - h(x) - 1|。则;$$

$\delta_T \rightarrow 0$ 显式地

$$\delta_T = O\left(\chi_T \ln \frac{1}{\chi_T} + \frac{\ln T}{T}\right). \quad (64)$$

证明。取 T 足够大, 使得 $3\chi_T \leq \frac{3}{4}$, 从而引理 7-9 在 $\mathcal{W}_T$ 上均适用。将三者串联起来 lemmas,

$$\begin{aligned} TH(x) &= x\mathcal{S}(x) = x\mathcal{S}^\circ(x) + E_1 \\ &= x + x \int_{1/T}^1 f + xE_2 + E_1 \\ &= h(x) + 1 + r(T, x), \end{aligned} \quad (65)$$

其中余项收集了六项,

$$r(T, x) := x + x \ln \frac{1}{x} - \frac{3x}{2} + \theta + xE_2 + E_1. \quad (66)$$

Here $|E_1| \leq \frac{2}{T^x} \cdot xS^\circ = \frac{2S^\circ}{T}$ by Lemma 7, $|E_2| \leq 1 + \frac{12}{T} + \frac{1}{Tx^3}$ by Lemma 8, and $|\theta| \leq \frac{6x}{T}$ by Lemma 9.

We check each contribution uniformly on $\mathcal{W}_T$. First $x \leq 3\chi_T \rightarrow 0$ and $x \ln \frac{1}{x} \leq 3\chi_T \ln \frac{3}{\chi_T} \rightarrow 0$. Next $x \cdot \frac{1}{Tx^3} = \frac{1}{Tx^2} \leq \frac{18 \ln T}{T} \rightarrow 0$. Finally Lemmas 8–9 together with $\frac{1}{2x^2} \leq 9 \ln T$ give $S^\circ = O(\ln T)$ on the window, so $\frac{2S^\circ}{T} = O(\frac{\ln T}{T}) \rightarrow 0$. Every contribution to r therefore vanishes uniformly on $\mathcal{W}_T$. $\square$

引理 11 (窗口外无最小值点)。 存在 T_0 , 使得对于每个 $T \geq T_0$, H 在 $(0, \infty)$ 上的每个全局最小值点都位于 $\mathcal{W}_T = [\chi_T/3, 3\chi_T]$ 内。

证明。由引理 10, $\min_{x \in \mathcal{W}_T} TH(x) \leq \Lambda_T$, 其中

$$\Lambda_T := \sqrt{2 \ln T} + 1 + \delta_T. \quad (67)$$

我们证明对于所有大的 T , 在 $\mathcal{W}_T$ 外有 $TH(x) > \Lambda_T$ 。

Two lower bounds. 对于 $0 < x \leq 1$, 仅保留含有 $i > T/2$ 的项。由于 $\rho_i \leq 1$, 且 $\psi_i \leq \psi_{i-1}$, ψ^{-3} 在那里是递增的,

$$\begin{aligned} TH(x) &\geq x \sum_{i > T/2} \frac{1/T}{\psi_{i-1}^3} \geq x \int_{1/2}^{1-1/T} \frac{d\rho}{\psi(\rho)^3} \\ &= \frac{x}{2b} \left[\frac{1}{\psi(1 - \frac{1}{T})^2} - \frac{1}{\psi(\frac{1}{2})^2} \right] \\ &\geq \frac{x}{2} \left[\frac{1}{(x + \frac{1}{T})^2} - 4 \right], \end{aligned} \quad (68)$$

where we used $b \leq 1$, $\psi(1 - \frac{1}{T}) \leq \frac{b}{2}$ 单独地 $\frac{b}{2}$ 对于 $\frac{1}{T}$ 和 $\psi(\frac{1}{2}) \geq \frac{1}{2}$ $0 < x \leq 1$, 该项单独给出 $i = T$

$$TH(x) \geq \frac{1}{T(x + \frac{1}{T})^2}. \quad (69)$$

六个区域。表 5 列出了它们; 空区域可以忽略。区域 (i) 使用 (69), 其中 $x + \frac{1}{T} \leq \frac{2}{T}$ 。区域 (ii) – (iii) 使用 (68), 分别对应 $x + T^{-1} \leq 2x$ 和 $x + T^{-1} \leq x(1 + T^{-1/2})$ 。区域 (iv) 在 $[0, 1]$, so $TH \geq x \sum_i 1/i \geq x \ln T$ 上使用 $\psi \leq 1$ 。区域 (v) 对于 $i \leq T/(2x)$ 使用 $\psi_{i-1} \leq \psi_i \leq \frac{3}{2}$, 得到 $TH \geq \frac{8}{81} x \ln \frac{T}{2x}$, 因此对于 $T \geq 64$ 有 $\frac{8}{81} \ln T$ 。区域 (vi) 使用 $i = 1$ 项, $TH \geq x/\psi(1/T) \geq Tx/(T+x)$ 。

在 T 的最低阶 $o(1)$ 项, in region (iii) the leading coefficient is $\frac{3}{2}\sqrt{2} > \sqrt{2}$, in region (iv) it is $\frac{3}{\sqrt{2}} > \sqrt{2}$, 且在其余区域中 T , T 或 $\ln T$ 的增长速度快于 $\sqrt{\ln T}$ 。因此, 一旦 T 足够大, 全局极小点就不会位于 $\mathcal{W}_T$ 之外。 $\square$

表 5: 引理 11 的六个区域。 每一行给出了 TH 的一个下界, 该下界由证明中提到的工具获得, 并且已经超过了在窗口内达到的基准 $\Lambda_T = \sqrt{2 \ln T}(1 + o(1))$ 。只有区域 (iii) 和 (iv) 由常数决定, 且在这两种情况下常数均为 $\frac{3}{2}\sqrt{2}$ 。

	region	lower bound on TH
(i)	$x \leq T^{-1}$	$T/4$
(ii)	$T^{-1} \leq x \leq T^{-1/2}$	$\sqrt{T}/8 - 2$
(iii)	$T^{-1/2} \leq x \leq \chi_T/3$	$\frac{3}{2}\sqrt{2 \ln T}(1 - 2T^{-1/2}) - 1$
(iv)	$3\chi_T \leq x \leq 1$	$\frac{3}{\sqrt{2}}\sqrt{\ln T}$
(v)	$1 \leq x \leq \sqrt{T}$	$\frac{8}{81} \ln T$
(vi)	$x \geq \sqrt{T}$	$\sqrt{T}/2$

命题 1 的证明。定理 3 保证存在全局极小点 x^* , 并且对于 $T \geq T_0$, 引理 11 将其置于 $\mathcal{W}_T$ 中。在 $\mathcal{W}_T$ 上我们有 $h'' \geq (3\chi_T)^{-3}$, 因此二次下界

$$h(x) \geq h(\chi_T) + \frac{(x - \chi_T)^2}{54\chi_T^3}. \quad (70)$$

引理 10 同时给出 $TH(x^*) \leq TH(\chi_T) \leq h(\chi_T) + 1 + \delta_T$ 和 $TH(x^*) \geq h(x^*) + 1 - \delta_T$ 。
。相减得到，

$$\frac{(x^* - \chi_T)^2}{54\chi_T^3} \leq 2\delta_T \implies \left| \frac{x^*}{\chi_T} - 1 \right| \leq \sqrt{108\delta_T\chi_T} \longrightarrow 0. \quad (71)$$

因此 $x^*(T) = (2\ln T)^{-1/2}(1 + o(1))$ ，即所证结论。

For the optimal value, $H(x^*) = \frac{1}{T}(\sqrt{2\ln T} + 1 + O(\delta_T))$ ，并展开 $\Phi = \frac{1}{2}(u - 1 - \ln u)$ at $u = 1 - H$ 如 (48) 式所示，得到

$$\Phi(x^*) = \frac{H(x^*)^2}{4}(1 + O(H(x^*))) = \frac{\ln T}{2T^2}\left(1 + O\left(\frac{1}{\sqrt{\ln T}}\right)\right). \quad (72)$$

□

数值证书

注 2 (数值证书)。 一个独立的证书，使用精确导数且不使用有限差分，从三个方面支持有限 T 展开。(i) 在 $\mathcal{W}_T, \sup |TH(x) - h(x)|$ 上稳定于 1.146 附近，对于 $T = 10^3 - 10^5$ ，与引理 10 的极限常数 $\frac{1}{2}$ 以及缓慢衰减值 $\frac{1}{2x}$ 一致。导数证书 $\sup |h'(x)| \ln T$ 随和 $\frac{1}{2x}$ 衰减，与 $\frac{1}{2x}$ 一致。(ii) 一致。导数证书 $\sup |h'(x)| \ln T$ 随和 $\frac{1}{2x}$ 衰减，与 $\frac{1}{2x}$ 一致。完整扫描，图 6 绘制了该结果。 χ_T : 0.211

注 3。 我们最初的渐近假设为 $x^* \asymp (2/(T \ln T))^{1/3}$ ，它在对数主体与离散端点项之间取得平衡。精确数值计算果断地否定了它：比值在 $T = 5 - 10^5$ 范围内从 1.1 漂移到 17.6。重新审视连续积分后，发现了引理 9 所严格证明的项。这一经历正是 $\frac{1}{2x}$ 。本文中每个数值认证声明背后协议的原因：先推导预测，再与精确离散目标核对。

表 6：常数 $x^*(T)$ 与命题 1 的对照。 通过 (41) 式在均匀网格上对 Φ 进行精确最小化。比值以已证明的速率 $O(\delta_T^{1/2} \chi_T^{1/2})$ 缓慢趋近于 1； $T \leq 50$ 行是附录 7.4 中引用的值。

T	$x^*(T)$	$\chi_T = (2\ln T)^{-1/2}$	ratio
5	0.721	0.557	1.294
10	0.577	0.466	1.239
50	0.404	0.357	1.130
200	0.332	0.307	1.081
217	0.329	0.305	1.079
10^3	0.283	0.269	1.050
10^4	0.240	0.233	1.028
10^5	0.212	0.208	1.017

Uniqueness (Proposition 2)

Reduction. Since $\Phi(x) = \frac{1}{2}(u - 1 - \ln u)$ 关于 $u \in (0, 1)$ 严格递减，最小化 Φ 等价于最小化 $H(\tilde{x}) = D_0/P$ 。令 $\omega_i := (1 - \rho_i)/\rho_i$ 。则在求解器坐标中的颜色路径为

$$z_i(x) = \frac{x}{x + \omega_i}, \quad H(x) = F(z(x)), \quad (73)$$

其中 F 如式 (83) 所示。因此， x^* 的唯一性问题归结为单参数曲线 $x \mapsto z(x)$ 如何与凸函数 F 相交。

$T = 2$ ：已证明。此处 $H(x) = z_1(x) + (1 - z_1(x))^2$ 。映射 z_1 严格递增到 $(0, 1)$ 上，且 $J(z) := z + (1 - z)^2$ 严格凸，因此 H 严格单峰， x^* 唯一。




图 6: $x^*(T)$ 遵循 $(2 \ln T)^{-1/2}$. 左图: 相对于命题 1 定律的精确优化器。右图: 它们的比值, 从 1.29 在 $T=5$ 处下降到 1.017 在 $T=10^5$ 处。逼近速度缓慢, 因为已证明的误差为 $O(\sqrt{\delta_T \chi_T})$, 而非 $O(1/T)$ 。

均匀网格: 已证明适用于 $2 \leq T \leq 120$. 对于每个整数 $2 \leq T \leq 120$, 我们推导出一个显式多项式 $P_T \in \mathbb{Z}[x]$, 其正根恰好是 H 的临界点。 P_T 的非零系数序列恰好有一次符号变化, 因此根据笛卡尔符号法则 (S5), P_T 至多有一个正根 [2, 第 2.2.1 节]。结合定理 3 第 3 步的内部存在性论证 (两端障碍 $\Phi \rightarrow \infty$), 这证明了对于每个 $2 \leq T \leq 120$, H 具有唯一的临界点, 从而具有唯一的最小值。

在该认证范围之外, 容差鲁棒的数值扫描发现对于每个 $T = 2, \dots, 200$ 和 $T \in \{500, 1000, 5000\}$ 恰好有一个局部最小值。一般的解析证明仍然悬而未决。它要么归结为猜想: 对于每个 T , 相关系数序列有一次符号变化; 要么归结为在每个临界点验证 $\text{Var}_p(z) < 1/12$, 其中 $1/12$ 是连续统中的极限值。

一般网格: 通过显式构造证明为假。 非唯一性已经出现在 $T = 3$ on a 双簇网格上。取 $\rho = (-1, \frac{1}{1+C}, \frac{1}{x+C}, 1)$, 等价于 $\omega = (C, 1, 0)$ 。则 $z_1 =$ 和 $z_2 = \frac{x}{x+1}$, $z_3 = 1$

$$H(x) = z_1 + \frac{(z_2 - z_1)^2}{z_2} + (1 - z_2)^2. \quad (74)$$

表 7 在五个点上评估了式 (74), 并表明值 $\frac{3}{4}$ 被穿过四次, 对于每个 $C \geq 1$ 。因此 Φ 至少有两个局部极小值, 一个在 $(\frac{1}{1+C}, \frac{1}{x+C})$ 中, 另一个在 $(\frac{1}{x+C}, \sqrt{C})$ 中, $\sqrt{C}$ 是 Φ 的根, $\sqrt{C}$ 是 Φ 的根。

$x, H(x) \rightarrow J(\frac{x}{x+1})$ 对于固定的 J , 严格单峰的 $T=2$ 轮廓如上; 对于 $x = Cw$ 且 fixed, $H \rightarrow J(\frac{w}{w+1})$ w 。因此每个聚类产生一个 $T=2$ 谷, 极小值在 $x \approx 1$ 和 $x \approx C$ 附近趋近于 $\frac{3}{4}$, 且谷被聚类尺度比所分隔。

表 7: 强制产生两个谷的五次评估 (式 (74), 任意 $C \geq 100$; 表中读作 $C = 100$), 其中 $u := \frac{1}{1+C}$ 且 $\bar{u} := \frac{1}{1+\frac{1}{C}} \leq \frac{1}{11}$ 。每个外部界限保留式 (74) 中的一项; 两个内部恒等式为精确替换。所有五次评估也已在精确有理算术中验证。

point	value or bound	vs. $\frac{3}{4}$
$x = \frac{1}{10}$	$H \geq (1 - z_2)^2 = \frac{100}{121}$	$> \frac{3}{4}$
$x = 1$	$H = \frac{3}{4} - u + 2u^2$	$< \frac{3}{4}$
$x = \sqrt{C}$	$H \geq z_1 + (z_2 - z_1)^2 = 1 - 3\bar{u} + 4\bar{u}^2$	$> \frac{3}{4}$
$x = C$	$H = \frac{3 - 6u + 8u^2 - 4u^3}{4(1 - u)}$	$< \frac{3}{4}$
$x = 10C$	$H \geq z_1 = \frac{10}{11}$	$> \frac{3}{4}$

内部恒等式通过直接替换得到，利用 $z_1(1) = u, z_2(1) = \frac{1}{2}, z_1(C) = \frac{1}{2}$ and $z_2(C) = 1 - u$. For the middle lower bound we drop $(1 - z_2)^2 \geq 0$ and use $z_2 \leq 1$; moreover $\bar{u} \leq \frac{1}{11}$ lies below $\frac{3-\sqrt{5}}{8}$, the smaller root of $4\bar{u}^2 - 3\bar{u} + \frac{1}{4}$.

严重性。聚类可以推高计数。在 $T=48$ 处的一个双聚类网格，节点集中在 10^{-7} 附近和 1 附近，产生 H 的七个局部极小值，每个均在 50 位精度算术中确认。对理论的影响是定理 3 中的条件陈述：每个局部优化器按模式比例对应于 Φ 的某个局部极小值，且公共形式 $v_k^* = x^* P_k$ 对全局优化器成立当且仅当 $\arg \min \Phi$ 是单元素集。

在这种类型的双簇网格上，一个具有 $P = (1, 4)$ 的双模态实例存在一个真正的局部最优解，其模态占据不同的谷，且 v_2/v_1 的阶为 10^6 ，而非比例比值 4；每个方向上的扰动都证实了局部最优性。

预算弯曲 (命题 3)

相关的渐近机制保持预算 V 固定，而 $T \rightarrow \infty$ ；这也是实验所检验的机制。证明使用了引理 7-9 以及一个同类的导数引理。在整个过程中， $x_k := v_k/P_k$ 和 $\bar{x}_k := VP_k/\sum_j P_j^2$ ；该假设蕴含 $\bar{x}_{\max} \leq \frac{3}{4}$ 。

引理 12 (扩展窗口上的展开与导数)。固定 $X \geq 1$ 。在均匀网格上，一致地对于 $x \in [T^{-1/4}, X]$,

$$TH(x) = x \ln T + \frac{1}{2x} + O(1), \quad (75)$$

$$TH'(x) = \ln T - \frac{1}{2x^2} + O\left(\frac{1}{x}\right), \quad (76)$$

其中常数仅依赖于 X 。

证明。三个引理的推广。限制 $x \leq \frac{3}{4}$ 仅通过引理 8 中 f 的先减后增形状进入。对于 $b < \frac{1}{4}$ (包括 $b \leq 0$)，可以验证 $(\ln f)' = -1/\rho + 3b/\psi < 0$ 在整个 $(0, 1]$, so f 上是单调的，并且全变差界只会改善。引理 9 的原函数对每个 $b \neq 0$ 都成立，而 $x = 1$ 是平凡情形 $\psi \equiv 1$ 。So。引理 7-9 从 $(0, \frac{3}{4}]$ 推广到 $(0, X]$ 。

值。如 (65) 中那样进行链式处理，并注意到 $x \ln \frac{1}{x} = O(1)$ 且 $\frac{1}{T x^3} \leq T^{-1/4}$ 且在窗口上给出 (75)。

导数。由 $TH = xS(x)$ 可得 $TH' = S + xS'$ ，且 (75) 给出 $S = \ln T + \frac{1}{2x} + O(\frac{1}{x})$ 。对 (52) 逐项 $\frac{1}{2x^2} + O(\frac{1}{x})$ 。微分，结合 $\partial_x \psi(\rho) = \rho$ ，

$$-S'(x) = \frac{1}{T} \sum_{i=1}^T \left[\frac{1}{\psi_i^2 \psi_{i-1}^2} + \frac{2\rho_{i-1}/\rho_i}{\psi_i \psi_{i-1}^3} \right], \quad (77)$$

这是被积函数 ψ^{-4} 的一对黎曼型求和，关于 ρ 单调，直至引理 7 的网格平移及因子

$\rho_{i-1}/\rho_i = 1 - \frac{1}{i}$, whose deviation contributes at most $\frac{2 \ln T}{T x^4} = O(\frac{1}{x})$ on the window. Since

$$\int_0^1 \psi^{-4} d\rho = \frac{x^{-3} - 1}{3b} = \frac{x^{-3}}{3} + O(x^{-2}) \quad (78)$$

且全变差黎曼误差为 $O(x^{-4}/T) = O(\frac{1}{x})$ 在该处，我们得到 $-S' = x^{-3} + O(x^{-2})$ 因此 $TH' = \ln T + \frac{1}{2x^2} - \frac{1}{x^2} + O(\frac{1}{x})$ ，即 (76)。□

命题 3 的证明。由于 $\Phi \rightarrow \infty$ 在 0 处且 Φ 连续，全局最优解存在于内部并满足拉格朗日条件 $1_{P_k} \Phi'(x_k) = \lambda$ 对每个 k 成立，其中 $\Phi'(x) = \frac{1}{2} \frac{H}{1-H} H'(x)$ 。

In particular $\text{sign } \Phi' = \text{sign } H'$ and $\Phi = \frac{H^2}{4}(1 + O(H))$ 。

步骤 1 (价值基准)。可行点 $\bar{v}_k = \bar{x}_k P_k$ 的目标值为

$$\Phi_T^{\text{bm}} := \sum_k \Phi(\bar{x}_k) = \frac{\ln^2 T}{4T^2} \left(\sum_k \bar{x}_k^2 \right) (1 + o(1)) \quad (79)$$

由引理 12。任何最优解至少达到该值，因此每个坐标满足 $\Phi(x_k) \leq \Phi_T^{\text{bm}} = O(\ln^2 T/T^2)$ 。

Step 2 (localization). First exclude $x_k \leq T^{-1/4}$: there (68) gives $TH \geq \frac{1}{2x}(1 - 2T^{-1/2}) - 2x \geq \frac{T^{1/4}}{3}$, so $\Phi(x_k) \geq \frac{H^2}{4} \gg \Phi_T^{\text{bm}}$. Next exclude $x_k \geq x_{\text{hi}}$ for a large fixed constant x_{hi} depending only on $\sum_j \bar{x}_j^2$, using the regional bounds of Table 5: $TH \geq x \ln T$ on $[T^{-1/4}, 1]$, $TH \geq \frac{8}{27}x \ln \frac{T}{2x}$ on $[1, \sqrt{T}]$, and $TH \geq \frac{\sqrt{T}}{2}$ beyond.

现在 $\lambda > 0$ 。如果 $\lambda \leq 0$ 则 $H'(x_k) \leq 0$ 对每个 k , so on $[T^{-1/4}, x_{\text{hi}}]$ 成立，引理 12 将迫使 $x_k \leq (2 \ln T)^{-1/2}(1 + o(1))$ ，从而 $\sum_k v_k \leq (2 \ln T)^{-1/2}(1 + o(1)) \sum_k P_k < V$ 对大的 T 成立，与预算矛盾。因此 $\lambda > 0$ ，每个坐标有 $H'(x_k) > 0$ ，且 $x_k \geq (2 \ln T)^{-1/2}(1 - o(1))$ 。

最后所有坐标都由一个固定常数下界。预算迫使某个 $x_{k_0} \geq V/\sum_j P_j =: x_{\text{lo}} > 0$ ，然后引理 12 给出某个 $x_{k_0} \leq c \frac{\ln^2 T}{T^2}$ 。

ε 小且固定。则 $\Phi'(x_k) = \lambda P_k \geq c' \frac{\ln^2 T}{T^2}$ would require

$$\left(x_k \ln T + \frac{1}{2x_k}\right) \left(\ln T - \frac{1}{2x_k^2}\right) \geq c'' \ln^2 T, \quad (80)$$

并且对于 $x_k \leq \varepsilon$ ，第一个因子只能通过 $\frac{1}{2x_k} \gtrsim \ln T$ 达到 $c'' \ln T$ ，这使得第二个因子为负——矛盾。因此每个 $x_k \in [c', x_{\text{hi}}]$ ，一个固定的紧区间。

步骤 3 (平稳性给出规律)。 在该紧集上，引理 12 一致地给出

$$\begin{aligned} \Phi'(x) &= \frac{1}{2} H(x) H'(x) (1 + O(H)) \\ &= \frac{x \ln^2 T}{2T^2} \left(1 + O\left(\frac{1}{\ln T}\right)\right), \end{aligned} \quad (81)$$

so $\frac{1}{P_k} \Phi'(x_k) = \lambda$ becomes $x_k = \kappa P_k (1 + O(1/\ln T))$ 具有公共常数 $\kappa = 2\lambda T^2/\ln^2 T$ 。预算方程 $\sum_k x_k P_k = \kappa \sum_k P_k^2 (1 + O(1/\ln T))$ 确定 κ ，因此

$$v_k^* = x_k P_k = \frac{P_k^2}{\sum_j P_j^2} V (1 + O(1/\ln T)), \quad (82)$$

即 (8)。假设 $V P_{\max}/\sum_j P_j^2 \leq 4$ 确保极限配 $P_j^2 \leq$ 置停留在常数一致的窗口内。

□

表 8: 预算最优趋向于 P^2 规律。 两种模式， $P = (1, 4)$ ，预算 $V = 5$ ，均匀网格；精确最小化 $\sum_k \Phi_k$ 。极限为 $P_1^2 V / \sum_j P_j^2 = \frac{5}{17} = 0.294$ ，以已证明的速率 $O(1/\ln T)$ 逼近。注意等预算协议与自由噪声优化回答不同问题并具有不同指数；两者都应报告。

T	5	10	50	200	10^3	2×10^4
v_1^*	0.773	0.634	0.460	0.391	0.347	0.306

定理 4 的证明

证明。（恒等式。）令 $z(\rho) = v\rho/\varphi(\rho)$ 。通过 $\varphi = v\rho/z$ 和 $1 - z =$ 代入 (41) 式， $(1 - \rho)P/\varphi$ 将表达式化简为

$$D_0 = P F(z), \quad F(z) := \sum_{i=1}^T \frac{(\Delta z_i)^2}{z_i}, \quad (83)$$

其中 $z_0 = 0$ 和 $z_T = 1$ ；两行化简的符号残差为 0。方程 (83) 重述了 (9) 式。下面反复使用的两个恒等式为

$$M(\rho) = P z(\rho), \quad \frac{\Delta z_i}{z_i} = \frac{P \Delta \rho_i}{\rho_i \varphi(\rho_{i-1})}, \quad (84)$$

两者均可由 $K(\rho) = P/\varphi(\rho)$ 直接得到。

(a) 可达集合的色盲性。 对于每个 $v > 0$ ，映射 $\rho \mapsto z$ 是 $[0, 1]$ 上的连续严格递增双射（图 7 左图）。因此，可达的 z -网格——以及由此得到的调度优化亏量——在每个有限 T 处对所有颜色均相同。

(b) 最优网格的唯一性。 F 是二次除以线性项之和，因此是联合凸的。若存在两个极小值点，则 F 在连接它们的线段上将是仿射的，这迫使每个比值 z_{i-1}/z_i 沿该线段保持恒定。结合固定端点，这些比值唯一确定网格，因此极小值点唯一。

(c) 闭式最优网格。 令 $a_i := z_{i-1}/z_i$ 。内部坐标下 F 的平稳性给出

$$2a_{i+1} = 1 + a_i^2, \quad a_1 = \frac{z_0}{z_1} = 0, \quad (85)$$

一个显式的前向递推，由此 $z_i = \prod_{j>i} a_j$ 。表 9 列出了初值及相应的最优代价。对 $T = 2, 3, 4$ ，暴力最小化与 10^{-14} 一致。在 $T = 2$ 处，精确最优值为 $z_1 = \frac{1}{2}$ ，且 $F^* = \frac{3}{4}$ ，而连续统调度 $z = s^2$ 给出 13 16：连续统调度在有限 T 下并非精确最优。 16

(d) 最优值的渐近性。 令 $\varepsilon_i := 1 - a_i$ 。两个精确改写开启论证。首先 $\Delta z_i = z_i(1 - a_i)$ ，因此最优值为

$$F^* = \sum_{i=1}^T z_i \varepsilon_i^2. \quad (86)$$

其次，(85) 式精确变为

$$\varepsilon_{i+1} = \varepsilon_i \left(1 - \frac{\varepsilon_i}{2}\right), \quad \varepsilon_1 = 1, \quad (87)$$

一个纯二次递推，不含三次项。它表明 $\varepsilon_i \in (0, 1]$ 且该序列递减，so

$$\begin{aligned} \frac{1}{\varepsilon_{i+1}} &= \frac{1}{\varepsilon_i} + \frac{1}{2} \cdot \frac{1}{1 - \varepsilon_i/2} \\ &= \frac{1}{\varepsilon_i} + \frac{1}{2} + \frac{\varepsilon_i}{4} + O(\varepsilon_i^2). \end{aligned} \quad (88)$$

递推的精确渐近性。在 (88) 式中去掉正修正项，得到 $1/\varepsilon_i \geq (i+1)/2$, i.e. $\varepsilon_i \leq 2/(i+1)$ 。将该上界代回，得到 $\sum_{j<i} \varepsilon_j/4 = \frac{1}{2} \ln i + O(1)$ 和 $\sum_{j<i} \varepsilon_j^2 = O(1)$ ，

因此，带显式常数的双向归纳给出

$$\frac{1}{\varepsilon_i} = \frac{i}{2} + \frac{1}{2} \ln i + O(1), \quad (89)$$

$$\varepsilon_i = \frac{2}{i} \left(1 + O\left(\frac{\ln(i+1)}{i+1}\right)\right). \quad (90)$$

Modal positions. Since $z_i = \prod_{j>i} a_j$,

$$\begin{aligned} \ln z_i &= \sum_{j>i} \ln(1 - \varepsilon_j) \\ &= -\sum_{j>i} \varepsilon_j + O\left(\sum_{j>i} \varepsilon_j^2\right) \\ &= -2 \ln \frac{T}{i} + O\left(\frac{\ln(i+1)}{i+1}\right), \end{aligned} \quad (91)$$

using $\sum_{j>i} 2/j = 2 \ln(T/i) + O(1/i)$ 以及两个修正和 $\sum_{j>i} \varepsilon_j^2$ 的事实 $\sum_{j>i} 1/j^2$ 均为 $O(\ln(i+1)/(i+1))$. Hence

$$z_i^* = (i/T)^2 e^{O(\ln(i+1)/(i+1))}. \quad (92)$$

这是严格的收敛性陈述及其速率：精确优化器趋近于连续时间调度 $z = s^2$ 。等价地，极限调度为

$$\rho^*(s) = \frac{Ps^2}{Ps^2 + v(1 - s^2)}, \quad (93)$$

在此条件下，由式 (84) 得 $M(\rho^*(s)) = Ps^2$ ：条件最小均方误差是求解器时间的二次函数。

The floor. Combining (90) and (92) term by term,

$$z_i \varepsilon_i^2 = \frac{4}{T^2} \left(1 + O\left(\frac{\ln(i+2)}{i+1}\right) \right), \quad (94)$$

$$\begin{aligned} F^* &= \frac{4}{T} + O\left(\frac{1}{T^2} \sum_{i=1}^T \frac{\ln(i+2)}{i+1}\right) \\ &= \frac{4}{T} \left(1 + O\left(\frac{\log^2 T}{T}\right) \right), \end{aligned} \quad (95)$$

so $D_0^* = 4P/T (1 + O(\log^2 T/T))$ 。 $\log^2$ 因子来自 $\sum_i (\ln i)/i$ ；提高速率需要各项修正之间相互抵消，但未发现此类抵消。表 9 最后一列支持所证明的规律。

最后，对于均匀 s 网格在 $z = s^2$ 下，(83) 的被加项符号简化为 $P(s_i^2 - s_{i-1}^2)^2/s_i^2$ ，其中颜色 v 完全消失——逐项证实了 (a)。

表 9：定理 4(c) 的最优 z 调度。左：前向递推 (85) 得到的前几个比值 $a_i = z_{i-1}/z_i$ ，以精确有理数表示。右：最优代价，小 T 时精确，并与下界 $F^* = 4/T$ of part(d) 比较。趋近于 1 的速率为已证明的 $1 + O(\log^2 T/T)$ 。

i	a_i	T	F^*	$F^*T/4$
1	0	2	3/4	0.375
2	1/2	3	39/64	0.457
3	5/8	4	16929/32768	0.517
4	89/128	10	0.2778	0.694
5	24305/32768	200	0.01931	0.966
6	0.7751...	10^4	3.996×10^{-4}	0.999




图 7：求解器坐标 z 吸收颜色。左图： $\rho \mapsto z = v\rho/\varphi(\rho)$ 对应 $x = v/P$ 的五个取值。每个都是 $[0, 1]$ 的双射，因此每个 z -网格在每种颜色下都可达——这正是定理 4a。中图：来自递推式 (85) 的精确优化器 z_i^* 与 $T = 64$ 处的连续律 $(i/T)^2$ 对比，说明了 $F^* = 4P/T$ 的 (d) 部分。 (92)。右图： $F^*T/4 \rightarrow 1$ ，即 (d) 部分的取整 D_0^* 。

多目标调度前沿

离散化最优调度具有增益误差敏感性

$$\Xi := \sum_i \frac{\Delta z_i}{z_i} (1 - z_i) = 2 \ln T + O(1), \quad (96)$$

该敏感性呈对数发散；数值上 $\Xi = 2 \ln T - 3.05$ 在 $T = 10^4$ 处。因此两个目标相互冲突：离散化倾向于在 $z = 0$ 附近采用许多小步长，而鲁棒性倾向于短对数路径。在模型误差下，参考设计变为多目标 z -调度问题——在敏感性预算约束下最小化 $\sum_i (\Delta z_i)^2 / z_i$ 。该约束涉及比率 z_{i-1}/z_i ，它们不是联合凸的，因此精确有限 T 前沿的凸性不能由 F 的凸性推出。然而在连续情形下，前沿有闭式解。

定理 6 (连续敏感性 - 离散化前沿)。考虑递增

C^1 调度，满

$z: [0, 1] \rightarrow (0, 1]$ 足 $z(0^+) = z_1$ 和 $z(1) = 1$ 。

(i) 敏感性与路径无关。

$$\Xi^{\text{cont}} = \int_0^1 \frac{\dot{z}}{z} (1 - z) ds = \int_{z_1}^1 \frac{1 - z}{z} dz = \ln \frac{1}{z_1} - (1 - z_1). \quad (97)$$

这仅取决于发射点 z_1 。因此，预算 $\Xi^{\text{cont}} \leq \xi$ 只施加 $z_1 \geq a(\xi)$ ，而没有进一步的路径约束，其中 $a(\xi) \in (0, 1)$ 是 $\ln \frac{1}{1-a} = \xi$ 的唯一根。

(二) 平方律，已推导。代入 $w = \sqrt{z}$ 将离散化泛函转化为狄利克雷能量，

$$\int_0^1 \frac{\dot{z}^2}{z} ds = 4 \int_0^1 \dot{w}^2 ds, \quad (98)$$

端点固定在 $w(0) = \sqrt{a}$ 和 $w(1) = 1$ 。柯西-施瓦茨给出唯一极小化子 $w(s) = \sqrt{a} + (1 - \sqrt{a})s$ ，即在 a 处发射的自由平方律路径：

$$z(s) = (\sqrt{a} + (1 - \sqrt{a})s)^2, \quad E(\xi) = 4(1 - \sqrt{a(\xi)})^2. \quad (99)$$

(iii) Closed-form, C^1 frontier. Differentiating the constraint,

$$\frac{da}{d\xi} = -\frac{a}{1-a}, \quad (100)$$

$$\frac{d^2a}{d\xi^2} = \frac{a}{(1-a)^3} > 0, \quad (101)$$

$$\frac{dE}{d\xi} = \frac{4\sqrt{a}}{1+\sqrt{a}} > 0. \quad (102)$$

两个导数在 $\xi: a$ 中严格单调，随着 ξ 增加而减小，而 $\sqrt{a}/(1+\sqrt{a})$ 随 a 增加而增加。因此，每个分支都具有单一符号的曲率。发射点 $a(\xi)$ 是 C^1 ，严格递减且严格凸；平滑路径能量 $E(\xi)$ 是 C^1 ，严格递增且严格凹，并随着 $\xi \rightarrow \infty$ 趋近于自由值 4。

在有限 T 处，发射点 z_1 恰好是第一步对赤字的 $O(1)$ 贡献，因为它在 (83) 中的项是 $(z_1 - 0)^2 / z_1 = z_1$ 。因此，沿包络族的总赤字为

$$a(\xi) + \frac{1}{T} E(\xi) (1 + o(1)), \quad (103)$$

其主导阶前沿是凸的、递减的，并且具有闭式形式；凹 E 分支仅贡献 $O(1/T)$ 修正。

敏感性约束在 $\xi \approx 2 \ln T$ 附近变得不活跃，前沿在定理 4d 的自由最优处趋于平坦。(i) 中的连续恒等式是主要的概念性陈述，并取代了离散界 $\Xi \leq \ln(1/z_1)$ ；离散界作为有限 T 比较仍然有用，它们之间的差异 $1 - z_1$ 恰好是第一步的敏感性贡献。

6.5 第 3.4 节证明 (模型误差与学习)

误差模型的完整性

在可解模型中，精确漂移为仿射形式， $\hat{x}_0 = Wx_1 + K_i(x - \bar{c}_i x_1)$ 。任何学习得到的仿射漂移与精确漂移的差异仅可能有两种：相对增益误差 η_i ，即对状态偏差敏感度的错误缩放；以及加性偏差 β_i 。由于分析以 x_1 为条件，偏差可能依赖于 x_1 ；因此，漂移中 x_1 系数的误差——例如使用 $\hat{W} \neq W$ ——被吸收到 β_i 中。因此，在该模型内，双通道分解是完备的。两个通道均保持仿射-高斯结构，故终端分布仍为精确。

命题 4 的证明

证明。扰动步骤给出

$$c' = [r + (1-r)K(1+\eta)]c + (1-r)[W - K(1+\eta)\bar{c}]. \quad (104)$$

代入归纳值 $c = \bar{c}_i$ ，两项 $K(1+\eta)\bar{c}$ 在 η 中完全抵消，剩下 $c' = r\bar{c}_i + (1-r)W = \bar{c}_{i-1}$ 。因此，围绕正确中心对偏差的错误缩放不会使均值产生偏差；只有加性偏差才能移动均值。 $\square$

定理 5 的证明

证明。在 z 坐标系中工作。三个直接计算给出精确的步进量，这些量在匹配的 z 网格上与颜色无关。未扰动的收缩是 $w(z) := z + x(1-z)$ ，值的比值，与引理 4 一致，关键恒等式为 (84) 式的后半部分，

$$\frac{(1-r_i)K_i}{A_i} = \frac{\Delta z_i}{z_i}, \quad (105)$$

该结果精确且不依赖于 $x = v/P$ 。因此，增益扰动后的收缩为

$$\hat{A}_i = A_i \left(1 + \eta_i \frac{\Delta z_i}{z_i}\right). \quad (106)$$

偏差在第 i 步以 $(1-r_i)\beta_i$ 的形式进入，并在传递至输出的过程中被下游收缩 $\hat{A}_{i-1} \cdots \hat{A}_1$ 所乘，因此其权重为

$$(1-r_i) \prod_{m < i} \hat{A}_m = \frac{\Delta z_i}{z_i} \prod_{m < i} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right), \quad (107)$$

where we used $\prod_{m < i} A_m = P/\varphi(\rho_{i-1})$ 由引理 4 得到的 $\prod_{m < i} A_m = P/\varphi(\rho_{i-1})$ 与 (105) 中的 $(1-r_i)P/\varphi(\rho_{i-1}) = (1-r_i)K_i/A_i = \frac{\Delta z_i}{z_i}$ 相结合。当 $\eta \equiv 0$ 时，权重简化为 $\frac{\Delta z_i}{z_i}$ 。因此一般而言，

$$m_0 = \sum_i \beta_i \frac{\Delta z_i}{z_i} \prod_{m < i} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right), \quad (108)$$

即 (10)。利用相同因子展开方差递归 (35)，得到

$$\frac{V_0}{P} = \sum_j z_{j-1} \frac{\Delta z_j}{z_j} \prod_{m < j} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right)^2, \quad (109)$$

即 (11)。在特殊情形 $\eta \equiv 0$ 下，该式变为

$$\frac{V_0}{P} = \sum_j z_{j-1} \frac{\Delta z_j}{z_j} = 1 - \sum_j \frac{(\Delta z_j)^2}{z_j}, \quad (110)$$

using $z_{j-1} = z_j - \Delta z_j$ 和 $\sum_j \Delta z_j = 1$ ，这恢复了 (83)。

(108) - (109) 中的每个因子仅依赖于 z 网格和误差分布。因此，终端规律对于每个 $v > 0$ 都是相同 $u = V_0/P$ by (S6). 的，且对于均值误差，终端 KL 散度为 $\frac{1}{2}(u + m_0^2/P - 1 - \ln u)$ ，其中 $\square$

注 4 (数值验证)。对于同时扰动 $\eta(z) = 0.2z + 0.1 \sin 3z$ 和平滑偏差剖面 $\beta(z)$ ，两种闭式解在 V_0 和 m_0 中与精确递归一致至 $\leq 3 \times 10^{-16}$ 。在匹配的 z 网格上，它们在 $x \in [0.01, 100]$ 范围内也一致到 12 位数字。

命题 5 的证明

Proof. At level z the conditional correlation satisfies

$$\text{corr}^2(x_0, \text{deviation} \mid x_1) = 1 - z \quad (111)$$

表 11：岭白化扫描。 $T = 100$ 和 $\lambda = 1$ 的最优尺度 $x^*(nP)$ 。较小的有效样本量 nF 产生更平坦的最优谱。

nP	10	30	100	300	10^3	10^4	∞
$x^*(nP)$	11.92	3.95	1.58	0.89	0.58	0.39	0.363

精确地，符号残差为 0。在尺度范围内，给定 x_1 时 (x_0, x_t) 的逐模联合律仅依赖于 z ，因此任何尺度等变学习器在每个 z 层级上都具有无颜色的相对误差律。对于在归一化设计 Σ 上由 n 对进行的零截距最小二乘 $\sum_i X_i^2 = n\tau$ ，

$$\text{Var}(\hat{K}/K - 1) = \frac{M}{n\Sigma K^2} = \frac{z}{n(1-z)}, \quad (112)$$

这再次是无颜色的；在随机设计下， n 被替换为 $n-2$ 。结合定理 5，一旦 z 调度固定，逐模颜色在端到端过程中完全不可见。□

注 5（相关误差校准）。恒定的相对增益误差沿 z 路径累积为

$$\exp\left(\pm 2\eta \sum_i \frac{\Delta z_i}{z_i}\right). \quad (113)$$

在固定的 ρ 网格上，颜色改变了该路径的形状，测得的优化点移动很大（表 10）。根据定理 5，这种依赖性必须解读为 z 调度效应，而非颜色本身的效应。

表 10：固定 ρ 网格上的恒定增益误差 $\pm\eta$ 使表观最优值移动了数个数量级——这是由诱导 z 调度产生的工件，见备注 5。

η	0	0.02	0.05	0.2
x^*	0.34	5.4	16.4	78.8

岭白化（命题 6）

共享岭惩罚 λ 通过相对偏差收缩估计增益

$$\eta_k(z) = -\frac{\lambda}{\lambda + n\Sigma_k(z)}. \quad (114)$$

由于 Σ_k 具有量纲，该惩罚打破了定理 3 的尺度对称性。使用 $T=100$ 和 $\lambda=1$ 进行精确链优化得到表 11 中的扫描结果，该结果随有效样本量 nP 显著下降。

对于 $P = (1, 4)$ 和 $n = 100$ ，最优值满足

$$\frac{v_2^*}{v_1^*} = 4 \cdot \frac{x^*(400)}{x^*(100)} = 1.99, \quad (115)$$

相对于比例值 4：弱观测频率需要不成比例地增加参考噪声以抵消收缩，且正则化最优值明显更平坦。在共享常数 λ 下，模态保持可分离，因为机制是逐模态尺度敏感性。真正共享的网络引入真实的跨模态耦合；最简单的此类模型在各模态间绑定一个增益，其精确代价等于逐模态最优增益的曲率加权离散度。完全非线性的共享网络情形仍待解决。

数据依赖的最优值。使用精确矩递归且不采用蒙特卡洛方法，首阶统计贡献等于 $1/n$ 乘以离散化泛函；在 $x = 0.3$ 和 $x = 2.0$ 处，测量值/预测值为 0.971 和 0.979。因此平均效应不会移动最小值点。该偏移反而由方差之方差的惩罚引起，这产生了轻微的下降趋势

$$x^* = 0.323 (n=\infty) \rightarrow 0.305 (n=300) \rightarrow 0.272 (n=100). \quad (116)$$

失真 - 感知与欠离散校正

推论 6 (失真 - 感知权衡, 推导)。后验均值估计器 Wx_1 对每个 T 的条件均方误差恰好为 F ，与参考无关；这是均值精确性 (引理 3) 唯一使其不变的量。采样输出具有正确的均值，且在给定 x_1 的条件下与真实 x_0 条件独立，因此其条件均方误差为

$$\text{MSE} = P + V_0 \in [P, 2P), \quad (117)$$

该误差仅通过 V_0 依赖于参考。折叠采样器在 $V_0 = 0$ 处将其最小化，此时它实际上是后验均值估计器；在分布完美 $V_0 = F$ 处，均方误差等于 $2P$ 。因此，后验采样的经典因子 2 (3 dB) 代价作为定理成立，且参考描绘了整个权衡曲线。

推论 7 (有原则的欠离散校正)。由推论 2，插件采样器唯一的失效模式是欠离散，因此有意的增益膨胀可作为校准校正：根据 (109)，选择

$\eta(z)$ 使得

$$\sum_j z_{j-1} \frac{\Delta z_j}{z_j} \prod_{m < j} \left(1 + \eta_m \frac{\Delta z_m}{z_m}\right)^2 = 1. \quad (118)$$

每一项都带有自身的部分乘积；不存在单一的全局因子乘以 $\eta \equiv 0$ 方差。一种方便的单参数解保持 η 恒定并求解所得的标量方程，从而给出温度与扰动启发式方法的精确公式对应。

注意，仅检查期望方差的目标可以被任何增加方差的误差所满足。合适的目标是在误差实现上取 $\mathbb{E}[\text{KL}]$ 。

7 实验方案与补充结果

7.1 I^2 SB 超分辨率中的参考颜色

我们从激发该理论的问题开始：参考颜色对完整的预训练恢复模型是否重要？从标准的 $I^2\text{SB } 4\times$ 超分辨率检查点出发，我们在相同的优化设置下，针对每个参考分别微调一个模型，共进行 5 万步，仅改变参考噪声的颜色——白色、低通 ($1/f^2$) 和高通 (f^2)。所有三个参考具有相同的尺度 ε 和相同的总像素方差，这消除了无关的混淆因素；只有方差在不同频率上的分配不同。由于 $4\times$ 下采样会破坏高空间频率，高通参考正是将噪声集中在被破坏的信息上的参考——即 $v_k \propto P_k$ 的定性方向。

表 12: $4\times$ 使用重着色参考的超分辨率。在保留对齐图像对上的峰值信噪比/结构相似性 (PSNR/SSIM)，NFE 为 20；数据、计算量和总参考方差均相同。“最佳”选取最佳验证检查点；“最终”为 50k 步时的结果。

reference	best		final	
	PSNR↑	SSIM↑	PSNR↑	SSIM↑
high-pass (f^2)	29.13	0.714	27.66	0.647
white	27.64	0.579	26.82	0.554
low-pass ($1/f^2$)	26.36	0.476	21.35	0.207

表 12 展示了由信息破坏图景所预测的排序：在两个度量上，无论是最佳检查点还是训练结束时，高通 $>$ 均优于白噪声 $>$ ，白噪声优于低通。尽管基础模型是用白噪声预训练的，高通参考在最佳检查点处的峰值信噪比高出 1.5 分贝，结构相似性指数高出 0.14。低通参考更为显著：其最佳检查点即为第一个检查点，继续微调则单调破坏，损失 5.0 dB by 50 千步。一个将噪声集中在观测已保留频率上的参考，不仅学习缓慢，而且会稳步抹除预训练模型的重建能力。

本实验仅改变噪声的颜色，在单一尺度 ε 和单一步数预算下进行。它证实了理论预测的大致方向——噪声应位于观测被破坏之处

信息——但它并未检验预测的量 $x^*(T)$ ，这需要扫描尺度（图 1 在精确设定下完成了这一检验）。即便在这些极限内，效果依然显著：在真实的预训练恢复模型上，参考谱是一阶设计选择，而非实现细节。

7.2 协议

精确数值（第一阶段）

每个量均以三种方式计算——闭式亏量 (41)、望远镜式 V_0 以及精确仿射递归 (34) - (35)——并在每次运行前交叉核对至机器精度。固定回归锚点为 $D_0 = 1.171587$ ，位于 $P = v = 4$ 和 $T = 10$ 处。

图 2(a) 在均匀网格和幂网格上使用 $P = v = 4$ ，并采用 T up to 10^5 。图 2(c) 通过在 22 个对数间隔的 $T \in [5, 10^5]$ 上对 Φ 进行黄金分割最小化来定位 $x^*(T)$ 。图 2(e) 在 $T=48$ 处使用双簇网格：每个候选最小值都用 50 位 mpmath 算术中的精确导数重新验证。表 13 使用精确递归，预算为 $\sum_k v_k = 5$ ，线性调度和顶点 $\epsilon = 10^{-2}$ 。 z 调度计算使用前向递推 (85)。所有第一阶段实验都是确定性的，不使用随机种子，在笔记本电脑上几分钟内运行。

高斯设置（第二阶段）

合成设置具有 64 个模式（在次级扫描中最多 256 个），先验 $S_k = k^{-2}$ ，高斯 MTF $h_k = \exp(-(k/k_c)^2)$ ，其中 $k_c = 16$ ，以及平坦噪声 $N_k = 10^{-3}$ ； P_k 被精确计算并随每次运行保存。匹配参考是 $v_k = x^*(T)P_k$ ，其中 x^* 来自表 6；白色、反匹配 ($\propto 1/P_k$) 和先验着色 ($\propto S_k$) 参考被重新缩放到匹配的总预算。

预测器是 64 个独立的每模式 MLP（使用 bmm 批处理），每个接收 $(x_t, x_1, 32 \text{ 维正弦 } t)$ ，具有 3 个 SiLU 隐藏层和标量输出 $\hat{x}_0$ 。训练：Adam 10^{-3} ，批量 2048 - 4096，12k - 20k 步，EMA

0.999，连续 $t \sim U(0, 1)$ ，通过 $\sqrt{S_k}$ 进行每模式 I/O 归一化（一种良性的每模式重新缩放），种子 $\{0, 1, 2\}$ ，跨参考使用公共随机数。

终端 KL 估计如下：以 x_1 为条件，每个模式的终端定律通过在 10^5 个样本的公共随机数批次上进行回归来拟合。然后以闭式形式评估拟合高斯与 $\mathcal{N}(Wx_1, P)$ 之间的 KL 散度；经验 KL 下限约为 10^{-5} 。岭白化和常数扫描实验使用每个 (k, t) 区间的闭式岭/OLS 学习器，具有 32 个区间和精确的确定性链传播，因此零采样噪声。雅可比探针通过训练指纹网络上 $\partial \hat{x}_0 / \partial x_t$ 的有限差分来估计 $\hat{\eta}(z)$ ，并应用 (109)。

FFHQ 64×64 (Phase 3)

FFHQ 被中心裁剪并调整大小为 64×64，使用 Lanczos 插值；前 60k 图像用于训练，用于拟合 $[-1, 1]$ 。 $S(k)$ 和 FID 统计，接下来的 10k 用于评估；像素位于

退化在 DFT 域中定义，因此 $P(k)$ 是解析的： $x_1 = k_{\text{blur}} * x_0 + n$ 具有高斯模糊 $\sigma_{\text{blur}} = 2.0$ 像素，传递函数 $h(k) = \exp(-2\pi^2 \sigma_{\text{blur}}^2 |f|^2)$ ，以及噪声 $\sigma_n = 0.05$ ，i.e. $N = 2.5 \times 10^{-3}$ 。没有抽取，因此没有混叠块，所以这里不需要推论 4。 $S(k)$ 通过径向平均训练分割功率谱一次性拟合，并与 $P(k)$ 、 $W(k)$ 、 $h(k)$ 和 $x^*(T)$ 一起保存在一个包中。匹配参考使用 $x^*(T_{\text{ref}}=50) = 0.404$ ；所有预算匹配的颜色具有相同的每像素噪声方差，因此“相同噪声水平，不同频谱”是字面意思。

每次运行训练一个 I^2 SB 风格的 ADM U-Net（基础宽度 128，每个分辨率 (1, 2, 2, 2)，2 个残差块，在 16^2 和 8^2 ；39.6 M 参数处使用注意力），通过将 x_1 与 x_t (6 个输入通道拼接进行条件化，外加一个标准的 t 嵌入)。

原始配方： $\hat{x}_0$ 均方误差，在均匀时间表上使用 $\rho \sim U(0, 1)$ ；Adam 10^{-4} ，批大小 128，150k 步，指数移动平均 0.9999，随机失活 0.1，水平翻转，bf16 自动混合精度。匹配和白噪声使用种子 $\{0, 1, 2\}$ ；反、 $\alpha=1$ ， $\alpha=2$ 和等预算匹配使用种子 0——共 10 次运行，每次在现代 GPU 上耗时 4 - 7 小时。

评估使用祖先插件均值采样器，在 NFE 为 5、10、20、50 和 100 的均匀子网格上进行，固定生成器种子和分块，因此跨参考的比较使用字节相同的公共随机数。我们报告 1k 张留出图像上的 PSNR/SSIM/LPIPS，以及针对 FFHQ-64 统计量的 FID；径向平均误差谱包含精确漂移叠加 $2P(k) - D_0(k)$ 。每 5k 步，在 256 张固定图像上对 EMA 网络进行探测，使用 16 点 t 网格，记录相对于贝叶斯下限的每（径向频带， t ）指纹。

收敛配方与 θ 族

收敛配方与原始配方相同，除了随机失活为 0、批大小 512 和 300k 步——梯度样本数量为原来的八倍。 θ 族是将 $v(k) \propto P(k)^\theta$ 重新缩放到固定总预算 A ，其中 $\theta \in \{0, \frac{1}{4}, \frac{1}{2}, \frac{3}{4}, 1\}$ ；端点与该预算下的白噪声和匹配参考一致（已对照保存的捆绑包验证至 10^{-6} ，因此无需单独运行端点）。运行：匹配和白噪声使用种子 $\{0, \dots, 4\}$ ； $\theta \in \{0.25, 0.5, 0.75\}$ ，种子 0；匹配和白噪声在 $\sigma_{\text{blur}} = 4.0$ 处使用种子 0（单独捆绑包）。

FID 协议。第 4.4 节中的每个 FID 使用 50k 个样本，由 10k 评估集的 5 次重复池化而成，每次重复使用新的采样器驱动噪声；存储每次重复的 10k FID，并且原始配方运行在任何比较之前已按相同协议重新评估。

时间表消融。每个训练好的网络也在定理 4(c) 的 z 最优网格上进行评估，无需重新训练。

第 7.6 节的预测 P1 – P4 在第一次收敛配方运行开始之前已写下。

7.3 精确数值评估

数值验证。所有确定性递归自检均达到机器精度。对于隐身实验（图 2a），当 $P = v = 4$ 时，终端方差在 $T = 10^5$ 处达到 $V_0 = 3.9995$ ，而奇异情形 $v = 0$ 崩溃，符合定理 2(b) 的要求。对于缩放实验（图 2c），测得的优化点包括 $x^*(217) = 0.329$ 和 $x^*(10^5) = 0.212$ ，比值 $x^*(T)/(2 \ln T)^{-1/2}$ 从 $T = 5$ 处的 1.29 降至 $T = 10^5$ 处的 1.017；表 6 给出了完整扫描结果。对于聚类 $T = 48$ 调度（图 2e），在 50 位精度算术中验证了七个局部极小值。

表 13：双模态设置下的有限步 KL 散度。总 KL $\sum_k \text{KL}_k$ 对于 $P = (1, 4)$ ，总预算 5 及线性调度。匹配分配在每个测试步数下均为最优。顶点分配使用 $v_2 = \epsilon$ 与 $\epsilon = 10^{-2}$ ，是附录 6.3 中退化贝叶斯风险目标所选择的分配。

allocation	$T=5$	$T=10$	$T=20$	$T=50$	$T=200$
matched (1, 4)	0.1534	0.0537	0.0184	0.0043	0.0004
uniform (2.5, 2.5)	0.1901	0.0710	0.0263	0.0068	0.0008
anti (4, 1)	0.2682	0.1012	0.0382	0.0104	0.0013
vertex (5- ϵ , ϵ)	1.8491	1.3075	0.8995	0.4869	0.1174

表 13 显示，匹配分配在每个测试的 T 处均使 KL 散度最小；在 $T = 200$ 处，顶点分配的 KL 散度大 $294\times$ 。

调度与预算效应。对于 z -调度递归， $F^*T/4$ 在 $T = 2, 10, 200$ 和 10^4 处等于 0.375, 0.694, 0.966 和 0.999（表 9），趋近于定理 4d 的 $4P/T$ 下界。调度优化后，赤字对参考颜色的不变性达到 10^{-12} ，符合定理 4a 的要求。预算优化点向命题 3 预测的 P^2 分配弯曲： v_1^* 从 $T = 5$ 处的 0.773 移动到 $T = 10^3$ 处的 0.347 和 $T = 2 \times 10^4$ 处的 0.306，趋近顶点值 $5/17 \approx 0.294$ （表 8）。

7.4 受控高斯实验

测试的预测。我们检验以下内容：（i）收敛损失是否与贝叶斯下限 $P\phi/(\phi + P)$ 匹配，且 $\phi = v\rho/(1 - \rho)$ ；（ii）预测的有限 NFE 参考排序是否出现；（iii）最优尺度

是否遵循理论常数，并在等预算约束下向 P^2 弯曲；(iv) 有限数据和权重衰减是否使最优值向白化方向平坦化；以及 (v) 基于一个已训练网络的雅可比矩阵估计是否能在不重新训练的情况下预测终端方差。

损失指纹与 NFE 依赖性。经过 12k 训练步后，在模式-时间对的 64×32 网格上，超出贝叶斯下限的相对中位数超额为 0.18%，低于预设的 5% 门槛。对于每个 NFE（最高 50），KL 排序均匹配 $< \text{白化} < \text{反匹配} < \text{先验着色}$ ；在 NFE 50 时，三个种子上的总 KL 为 $0.19 \pm 0.03, 0.21 \pm 0.03, 0.44 \pm 0.04$ 和 4.3 ± 0.3 。

在 NFE 200 时，增益误差主导离散化误差：学习曲线比其精确漂移下限高出一到两个数量级，先验着色参考变得不稳定 ($\text{KL } 10^4 - 10^5$)，匹配和白化在 0.60 ± 0.16 和 0.54 ± 0.15 处统计上不可区分。因此，该区域不保留精确漂移下预测的有限步排序——正如定理 5 所预期。

最优尺度与岭白化。实测最优常数为 0.575（在 $T = 10$ 处）和 0.402（在 $T = 50$ 处），而表 6 中的理论值为 0.577 和 0.404。在 $T = 200$ 处，实测最优值为 0.360，比精确漂移值 0.332 高出 8%——这正是命题 6 针对有限数据正则化所预测的方向。在 $T = 100$ 和 $\lambda = 1$ 处的精确链岭扫描中（相对偏差 (114)），最优尺度 $x^*(nP)$ 随着有效样本量的减小而单调增长——从 0.363（在 $nP = \infty$ 处）经 0.58（在 $nP = 10^3$ 处）到 11.92（在 $nP = 10$ 处）——即较小的有效样本量产生更平坦的最优谱。对于 $P = (1, 4)$ 和 $n = 100$ ，岭调整后的最优值给出 $v_2^*/v_1^* = 1.99$ ，而在精确比例下为 4：正则化最优值明显更平坦。

雅可比矩阵与调度探针。训练指纹网络的雅可比分析以 0.6% 的中位相对误差预测终端方差，且无需重新训练，验证了第 3.4 节的测量协议。逐模式调度自适应将参考色差缩小至理论下限，一旦消除调度误差，便支持定理 4a 的色盲预测。

7.5 FFHQ：评估细节与次要结果

数据与度量。所有 FFHQ 运行在参考选择上使用公共随机数。PSNR、SSIM 和 LPIPS 在相同的 1,000 张留出图像上计算。在原始配方实验中，FID 由 5 万次恢复对 6 万张干净训练图像的 Inception 统计量计算；收敛配方实验使用 5 万次恢复（第 7.6 节）。匹配参考由已知高斯 MTF 和平坦观测噪声谱计算；并非通过验证性能选择。

预算约定。表 1 的大多数行使用总预算 $A = \sum_k x^* P(k)$ 。“匹配，等预算”行改用最优白预算 B 。在 NFE 50 时，等预算匹配模型的 FID 为 9.12，而匹配模型在其自由预算下为 8.45——这正是命题 3 预测的预算效应。我们报告两种约定，因为它们回答不同的问题。更平坦的经验最优也并非 NFE 50 特有：在 NFE 100 时，白模型达到 FID 6.07，而匹配模型为 6.64，超出观察到的种子变异。

调度重新评估。每个训练模型均使用定理 4 的 z 最优调度重新评估，无需重新训练。优化后的调度以相似幅度改善每个参考，且保持排序不变（在 NFE 50 时：白 7.87 $\rightarrow$ 7.10，匹配 8.45 $\rightarrow$ 7.62，反匹配 14.1 $\rightarrow$ 13.0）；白-匹配 FID 差距仅从 0.58 变为 0.53。因此，它消除了共享的离散化分量，但并未解释颜色相关的差距。

7.6 训练方案与参考指数

FID 测量。对于每个收敛方案运行，使用新的采样器噪声生成五组独立的 10k 修复图像，并将其初始特征合并为 50k 估计；每组中位数扩展为 ± 0.04 ，最大值为 ± 0.08 。为了与原始

10k 协议直接比较，也报告了每组 10k 的 FID。合并不会改变结论：在 NFE 50 时，匹配-白色差距在 10k 基础上为 1.169，合并后为 1.177。

预先指定的预测记录。在训练之前，我们记录了四个方向性预测：P1. 更好的优化应缩小匹配-白色 FID 和 LPIPS 差距，特别是在 NFE 5-10 时，并可能逆转其符号。P2. θ 家族应具有内部感知最优值，其最小化 θ 在收敛方案下应增加。P3. 在每个测试方案中，反匹配在感知度量上应保持显著更差。P4. 将模糊增加到 $\sigma_{\text{blur}} = 4.0$ 应增加匹配-白色效应的幅度，无论方向如何。

这些预测涉及最优值移动的方向；它们并不假设匹配必须成为最佳。




图 8：两种训练方案下的参考指数。 FID（左）和 LPIPS（右）相对于颜色指数 $\theta (v \propto P_k^\theta)$ ，固定预算）；星号标记每个 NFE 的 argmin。顶部：收敛方案 — $\theta=0.25$ 仅在 NFE ≤ 20 时最佳，白色在 NFE ≥ 50 时最佳。底部：原始方案（仅端点； α 套件不在 P_k^θ 家族中）。更好的优化扩大了而不是缩小了白色-匹配 FID 差距。

命题一与命题二。收敛后的配方在绝对指标上改善了两种端点参考：在函数评估次数为 50 时，白色参考的弗雷歇初始距离从 7.87 降至 4.34，匹配参考从 8.45 降至 5.50。

然而命题一被否定。匹配与白色参考之间的差距在函数评估次数为 5 时从 1.78 扩大至 2.09，在函数评估次数为 10 时从 1.36 扩大至 2.43，在函数评估次数为 50 时从 0.58 扩大至 1.18 ——在函数评估次数为 50 时，基于种子扩散 ± 0.09 （匹配）和 ± 0.02 （白色）的合并估计，差距约为 27 个标准误。学习感知图像块相似度差距在函数评估次数为 10 时从 0.0028 扩大至 0.0055，在函数评估次数为 50 时从 0.0007 扩大至 0.0032。

命题二仅在函数评估次数较小时获得有限支持：在函数评估次数为 ≤ 20 时，弗雷歇初始距离在 $\theta = 0.25$ 处达到最小（图 8），在函数评估次数为 5 时其值为 14.87，而白色参考为 15.27 ± 0.07 。对于函数评估次数为 ≥ 50 ，弗雷歇初始距离回到白色参考最优，且学习感知图像块相似度在函数评估次数为 ≥ 10 时选择白色参考。对最小化配方的直接跨配方比较

θ 不可识别，因为原始配方未包含内部 θ 值；可识别的端点差距与预测方向相反。

命题三与命题四。 命题三在原始方案下两种调度网格均得到支持：在函数评估次数为 50 时，反匹配参考在均匀调度下弗雷歇初始距离为 14.1，在 z 最优调度下为 13.0，两种情况下均为感知参考最差。反匹配参考未在收敛配方下重新训练，因此命题三未在该条件下评估。

命题四在幅度上得到支持，方向有利于白色参考：在 $\sigma_{\text{blur}} = 4.0$ 处，函数评估次数为 50 时白色与匹配参考的弗雷歇初始距离差距为 2.80 (6.45，对比 9.25；每个参考一个种子，合并 50k 弗雷歇初始距离)，而在 $\sigma_{\text{blur}} = 2.0$ 处相同基础上为 1.18。对应的学习感知图像块相似度差距为 0.0066 和 0.0032。

收敛性审计与范围。 损失指纹（图 9）表明，收敛配方减少但未消除低频优化误差：在最低径向频带中，匹配条件下中位相对超出贝叶斯下限从 150k 步时的 $1.37\times$ 降至 300k 步时的 $1.05\times$ ，白化条件下从 $0.73\times$ 降至 $0.60\times$ ，而中频和高频频带仍处于下限。根据预设标准，收敛配方优化效果更好，但尚未达到精确漂移状态。

由于 300k 步时低频指纹误差仍然存在，岭白化定律在真正收敛状态下仍未得到检验。 $\theta = 0.25$ 处的小 NFE 最优值表明，有限的 P_k 着色可能有所帮助。




图 9：收敛性审计（收敛配方）。300k 步时各（径向频带， t ）训练损失相对于贝叶斯下限。低频超出量相对于原始配方有所缩小但仍存在；中频和高频处于下限。

表 14：收敛配方下 NFE 50 的 FFHQ（随机失活 0，批大小 512，300k 步；其他设置同表 1）。FID 使用 50k 合并样本。白化和匹配报告五个种子的均值 $\pm$ std；内部 θ 值使用一个种子。

reference	PSNR $\uparrow$	SSIM $\uparrow$	LPIPS $\downarrow$	FID $\downarrow$
white ($\theta=0$)	24.81 $\pm$ 0.01	0.828	0.0323	3.53 $\pm$ 0.02
$\theta=0.25$	24.73	0.826	0.0326	3.58
$\theta=0.5$	24.67	0.824	0.0332	3.78
$\theta=0.75$	24.67	0.823	0.0343	4.15
matched ($\theta=1$)	24.73 $\pm$ 0.01	0.825	0.0355	4.71 $\pm$ 0.09

7.7 数据集复现：CelebA

协议。 为检验白化优先顺序是否特定于 FFHQ，我们在 CelebA 上以 64×64 复现收敛配方，采用相同的退化（ $\sigma_{\text{blur}} = 2.0, \sigma_n = 0.05$ ），其中 $S(k)$ 和束在 CelebA 训练划分上重新拟合；白化、匹配、 $\theta=0.25$ 和反匹配各用一个种子训练。表 15 报告了每个评估 NFE 下的 FID、PSNR 和 LPIPS。

表 15: CelebA 复现（收敛配方，每个参考一个种子；FID 使用 5 万池化样本）。每列最佳在每个块内加粗。白色在每个 NFE 下具有最佳 FID，反匹配在每个 NFE 下具有最佳 PSNR（SSIM 与 PSNR 一致）；反匹配在每个 NFE 下具有最差 LPIPS 和 FID。

NFE	5	10	20	50	100
FID↓					
white	10.97	6.99	4.46	2.73	2.13
$\theta=0.25$	11.03	7.21	4.75	2.98	2.34
matched	12.72	8.88	6.04	3.85	2.99
anti-matched	16.12	11.97	8.77	5.88	4.44
PSNR↑					
white	26.64	26.28	25.95	25.60	25.42
$\theta=0.25$	26.50	26.17	25.83	25.53	25.39
matched	26.39	26.13	25.85	25.54	25.33
anti-matched	27.27	27.10	26.89	26.56	26.28
LPIPS↓					
white	0.0371	0.0330	0.0306	0.0295	0.0295
$\theta=0.25$	0.0365	0.0329	0.0312	0.0298	0.0296
matched	0.0428	0.0388	0.0355	0.0326	0.0326
anti-matched	0.0510	0.0463	0.0416	0.0362	0.0335

结果。两项 FFHQ 发现均得到复现（表 15）。推论 6 的失真-感知分裂在每个 NFE 下均成立：反匹配始终具有最佳 PSNR/SSIM 和最差 LPIPS/FID。白色优先的 FID 排序在每个 NFE 下也成立，且在 NFE 50 时匹配-白色差距 1.12 与 FFHQ 相当。在 CelebA 上，白色在 NFE 5 时已具有最佳 FID，因此图 8 的小 NFE 内部最优似乎依赖于数据集。

参考文献

- [1] T.W. Anderson. *An Introduction to Multivariate Statistical Analysis*. Wiley Series in Probability and Statistics. Wiley, 2003.
- [2] Saugata Basu, Richard Pollack, and Marie-Françoise Roy. *Algorithms in real algebraic geometry*. Springer, 2006.
- [3] Roi Benita, Miki Elad, and Joseph Keshet. Spectral analysis of diffusion models with application to schedule design. *Advances in Neural Information Processing Systems*, 38:2073–2127, 2026.
- [4] Yochai Blau and Tomer Michaeli. The perception-distortion tradeoff. In *Proceedings of the IEEE conference on computer vision and pattern recognition*, pages 6228–6237, 2018.
- [5] Charlotte Bunne, Ya-Ping Hsieh, Marco Cuturi, and Andreas Krause. The schrödinger bridge between gaussian measures has a closed form. In *International Conference on Artificial Intelligence and Statistics*, pages 5802–5833. PMLR, 2023.
- [6] Michael Chertkov. Analytic bridge diffusions for controlled path generation. *arXiv preprint arXiv:2605.02961*, 2026.
- [7] T.M. Cover and J.A. Thomas. *Elements of Information Theory*. Wiley, 2012.
- [8] Hadar Davidson, Noam Issachar, and Sagie Benaim. Colored noise diffusion sampling. *arXiv preprint arXiv:2605.30332*, 2026.
- [9] Valentin De Bortoli, James Thornton, Jeremy Heng, and Arnaud Doucet. Diffusion Schrödinger bridge with applications to score-based generative modeling. *Advances in Neural Information Processing Systems*, 34:17695–17709, 2021.
- [10] Carlos Esteves and Ameesh Makadia. Spectrally-guided diffusion noise schedules. In *Forty-third International Conference on Machine Learning*, 2026.

- [11] Fabian Falck, Teodora Pandeava, Kiarash Zahirnia, Rachel Lawrence, Richard Turner, Edward Meeds, Javier Zazo, and Sushrut Karmalkar. A fourier space perspective on diffusion models. *arXiv preprint arXiv:2505.11278*, 2025.
- [12] Forouzan Fallah, Wenwen Li, Chia-Yu Hsu, Hyunho Lee, and Yezhou Yang. Rareflow: Physics-aware flow-matching for cross-sensor super-resolution of rare-earth features. *arXiv preprint arXiv:2510.23816*, 2025.
- [13] Dror Freirich, Tomer Michaeli, and Ron Meir. A theory of the distortion-perception tradeoff in wasserstein space. *Advances in Neural Information Processing Systems*, 34:25661–25672, 2021.
- [14] Nikita Gushchin, Sergei Kholkin, Evgeny Burnaev, and Alexander Korotin. Light and optimal schrödinger bridge matching. In *Forty-first International Conference on Machine Learning*, 2024.
- [15] Nikita Gushchin, David Li, Daniil Selikhanovych, Evgeny Burnaev, Dmitry Baranchuk, and Alexander Korotin. Inverse bridge matching distillation. *arXiv preprint arXiv:2502.01362*, 2025.
- [16] Nikita Gushchin, Daniil Selikhanovych, Sergei Kholkin, Evgeny Burnaev, and Alexander Korotin. Adversarial schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 37:89612–89651, 2024.
- [17] Guande He, Kaiwen Zheng, Jianfei Chen, Fan Bao, and Jun Zhu. Consistency diffusion bridge models. *Advances in Neural Information Processing Systems*, 37:23516–23548, 2024.
- [18] R.A. Horn and C.R. Johnson. *Matrix Analysis*. Cambridge University Press, 2012.
- [19] Jinhui Hou, Zhiyu Zhu, and Junhui Hou. Energy-oriented diffusion bridge for image restoration with foundational diffusion models. *arXiv preprint arXiv:2604.10983*, 2026.
- [20] Samuel Howard, Peter Potapchik, and George Deligiannidis. Schrödinger bridge matching for tree-structured costs and entropic wasserstein barycentres. *Advances in Neural Information Processing Systems*, 38:130112–130149, 2026.
- [21] Xingchang Huang, Corentin Salaun, Cristina Vasconcelos, Christian Theobalt, Cengiz Oztireli, and Gurprit Singh. Blue noise for diffusion models. In *ACM SIGGRAPH 2024 conference papers*, pages 1–11, 2024.
- [22] Thomas Jiralerspong, Berton Earnshaw, Jason Hartford, Yoshua Bengio, and Luca Scimeca. Shaping inductive bias in diffusion models through frequency-based noise control. *arXiv preprint arXiv:2502.10236*, 2025.
- [23] I. Karatzas and S. Shreve. *Brownian Motion and Stochastic Calculus*. Number v. 113 in Brownian Motion and Stochastic Calculus. Springer New York, 1991.
- [24] Tero Karras, Miika Aittala, Timo Aila, and Samuli Laine. Elucidating the design space of diffusion-based generative models. *Advances in neural information processing systems*, 35:26565–26577, 2022.
- [25] Tero Karras, Samuli Laine, and Timo Aila. A style-based generator architecture for generative adversarial networks. In *Proceedings of the IEEE/CVF conference on computer vision and pattern recognition*, pages 4401–4410, 2019.
- [26] Sergei Kholkin, Grigoriy Ksenofontov, David Li, Nikita Kornilov, Nikita Gushchin, Alexandra Suvorikova, Alexey Kroshnin, Evgeny Burnaev, and Alexander Korotin. Diffusion & adversarial schrödinger bridges via iterative proportional markovian fitting. *arXiv preprint arXiv:2410.02601*, 2024.
- [27] Diederik Kingma and Ruiqi Gao. Understanding diffusion objectives as the elbo with simple data augmentation. *Advances in Neural Information Processing Systems*, 36:65484–65516, 2023.

- [28] Diederik Kingma, Tim Salimans, Ben Poole, and Jonathan Ho. Variational diffusion models. *Advances in neural information processing systems*, 34:21696–21707, 2021.
- [29] Shanchuan Lin, Bingchen Liu, Jiashi Li, and Xiao Yang. Common diffusion noise schedules and sample steps are flawed. In *Proceedings of the IEEE/CVF winter conference on applications of computer vision*, pages 5404–5411, 2024.
- [30] Guan-Horng Liu, Yaron Lipman, Maximilian Nickel, Brian Karrer, Evangelos Theodorou, and Ricky T. Q. Chen. Generalized schrödinger bridge matching. In *The Twelfth International Conference on Learning Representations*, 2024.
- [31] Guan-Horng Liu, Arash Vahdat, De-An Huang, Evangelos A. Theodorou, Weili Nie, and Anima Anandkumar. I2SB: Image-to-image Schrödinger bridge. *arXiv preprint arXiv:2302.05872*, 2023.
- [32] Ziwei Liu, Ping Luo, Xiaogang Wang, and Xiaoou Tang. Deep learning face attributes in the wild. In *Proceedings of the IEEE international conference on computer vision*, pages 3730–3738, 2015.
- [33] Shuntaro Okada, Ryota Yoshihashi, Hirokatsu Kataoka, Tomohiro Tanaka, et al. Constant rate scheduling: Constant-rate distributional change for efficient training and sampling in diffusion models. *arXiv preprint arXiv:2411.12188*, 2024.
- [34] B. Øksendal. *Stochastic Differential Equations: An Introduction with Applications*. Universitext. Springer Berlin Heidelberg, 2010.
- [35] Stefano Peluchetti. Diffusion bridge mixture transports, schrödinger bridge problems and generative modeling. *Journal of Machine Learning Research*, 24(374):1–51, 2023.
- [36] W. Rudin. *Principles of Mathematical Analysis*. International series in pure and applied mathematics. McGraw-Hill, 1976.
- [37] Luca Scimeca, Thomas Jiralerspong, Berton Earnshaw, Jason Hartford, and Yoshua Bengio. Learning what matters: Steering diffusion via spectrally anisotropic forward noise. *arXiv preprint arXiv:2510.09660*, 2025.
- [38] Yuyang Shi, Valentin De Bortoli, Andrew Campbell, and Arnaud Doucet. Diffusion Schrödinger bridge matching. *Advances in Neural Information Processing Systems*, 36:62183–62223, 2023.
- [39] Zhicong Tang, Tiankai Hang, Shuyang Gu, Dong Chen, and Baining Guo. Simplified diffusion schrödinger bridge. *arXiv preprint arXiv:2403.14623*, 2024.
- [40] Hanting Wang, Tao Jin, Wang Lin, Shulei Wang, Hai Huang, Shengpeng Ji, and Zhou Zhao. Irbridge: Solving image restoration bridge with pre-trained generative diffusion models. *arXiv preprint arXiv:2505.24406*, 2025.
- [41] Hebaixu Wang, Jing Zhang, Haoyang Chen, Haonan Guo, Di Wang, Jiayi Ma, and Bo Du. Residual diffusion bridge model for image restoration. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 8375–8386, 2026.
- [42] Yuang Wang, Siyeop Yoon, Pengfei Jin, Matthew Tivnan, Zhenhong Chen, Rui Hu, Li Zhang, Zhiqiang Chen, Quanzheng Li, and Dufan Wu. Implicit image-to-image schrödinger bridge for ct super-resolution and denoising. *arXiv preprint arXiv:2403.06069*, 2, 2024.
- [43] Yuang Wang, Siyeop Yoon, Pengfei Jin, Matthew Tivnan, Sifan Song, Zhenhong Chen, Rui Hu, Li Zhang, Quanzheng Li, Zhiqiang Chen, and Dufan Wu. Implicit image-to-image schrödinger bridge for image restoration. *Pattern Recognition*, 165:111627, 2025.
- [44] Kacper Wyrwal, Ismail Ilkan Ceylan, and Alexander Tong. Topological flow matching. In *The Fourteenth International Conference on Learning Representations*, 2026.
- [45] Qing Yao, Lijian Gao, Qirong Mao, and Ming Dong. Regularized schrödinger bridge: Alleviating distortion and exposure bias in solving inverse problems. *arXiv preprint arXiv:2511.11686*, 2025.

- [46] Stephen Zhang and Michael Stumpf. Learning non-equilibrium diffusions with schrödinger bridges: from exactly solvable to simulation-free. *Advances in Neural Information Processing Systems*, 38:119861–119898, 2026.
- [47] Kaiwen Zheng, Guande He, Jianfei Chen, Fan Bao, and Jun Zhu. Diffusion bridge implicit models. In *International Conference on Learning Representations*, volume 2025, pages 81857–81884, 2025.
- [48] Linqi Zhou, Aaron Lou, Samar Khanna, and Stefano Ermon. Denoising diffusion bridge models. In *International Conference on Learning Representations*, volume 2024, pages 8160–8171, 2024.
- [49] Kaizhen Zhu, Mokai Pan, Yuexin Ma, Yanwei Fu, Jingyi Yu, Jingya Wang, and Ye Shi. Unidb: A unified diffusion bridge framework via stochastic optimal control. *arXiv preprint arXiv:2502.05749*, 2025.