

统一条件-动作建模实现精确单步动作生成

Xinyu Zhou^{1,*}, Zikun Cai^{1,*}, Kuangji Zuo¹, Gen Li¹, Boyu Ma¹, Yanshuo Lu¹, Yutong Song¹, Mingqi Yuan², Jiayu Chen^{2,†}, Jianfei Yang^{1,†}

¹MARS Lab, Nanyang Technological University, ²The University of Hong Kong

*Equal Contribution, †Corresponding Authors

机器人操作要求策略兼具准确性与高效性，因为机器人控制必须在严格的延迟约束下响应不断变化的观测。近期扩散策略与流策略展现出前景，但它们通常将条件视为辅助信号，而非与动作轨迹联合演化。我们发现，通过一种简单而有效的统一条件-动作建模设计，可有效缓解这一局限性。该设计在共享令牌空间中表示条件与动作，使紧凑模型在提升推理速度与准确性的同时实现高性能。因此，本文提出统一条件-动作流（UCA-Flow）框架，用于精确的单步动作生成。该方法将观测条件、时间步条件、区间条件与动作令牌统一为单一序列，并利用统一条件-动作变换器（Unified Condition-Action Transformer）进行联合条件-动作表示学习。由此，条件表示根据当前生成阶段动态重构，突出与动作细化最相关的信息。此外，本文引入改进的双通道监督方案，对 u 与 v 进行更强优化，以强化统一条件-动作建模。UCA-Flow 相较于最强基线平均成功率提升 9.3 个百分点，同时相较于 DP3 与 Simple DP3 分别实现 $45.6\times$ 与 $33.4\times$ 倍加速，并比单步 FlowPolicy 与 MP1 分别快 $4.3\times$ 与 $2.3\times$ 。项目主页：<https://uca-policy.github.io/UCA.github.io/>。

Correspondence: Jianfei Yang at jianfei.yang@ntu.edu.sg, Jiayu Chen at jiayuc@hku.hk



1 引言

机器人操作旨在从复杂观测中生成可执行动作，用于物理交互，如抓取、推动、装配、工具使用和灵巧物体操作 Suomalainen 等人 (2022); Bohg 等人 (2014); Qin 等人 (2023)，在工业自动化、服务机器人和物流领域具有广泛应用 Suomalainen 等人 (2022); Xu 等人 (2024)。一个关键挑战是在闭环执行的严格控制延迟下提取任务相关信息并生成动作。最近的生成式机器人策略，包括扩散策略 Chi 等人 (2025)、流匹配 Zhang 等人 (2025) 和平均流 Sheng 等人 (2025)，在建模动作分布方面展现出强大潜力 Chi 等人 (2025); Ze 等人 (2024); Zhang 等人 (2025); Sheng 等人 (2025); Yan 等人 (2025)。然而，它们仍面临效率与性能的瓶颈。

一些方法引入紧凑的三维点云特征或多模态状态嵌入作为动作生成的条件，从而改善空间理解和数据效率 Ze 等人 (2024); Zhang 等人 (2025); Sheng 等人 (2025)。另一些方法通过流匹配、一致性训练或平均流目标提高采样效率，实现少步或单步动作生成 Zhang 等人 (2025); Geng 等人 (2025a); Sheng 等人 (2025)。近期基于变换器的策略通过交叉注意力、自适应交叉注意力、AdaLN 或 AdaLN-Zero 调制进一步增强多模态条件化，使动作标记能够选择性地关注视觉、语言、时间步和本体感觉输入 Reuss 等人 (2024); Yan 等人 (2025)。尽管取得了这些进展，如图 1(a) 上半部分所示，大多数设计仍遵循条件到动作的范式：观测和时间步被编码为外部辅助信号，并通过调制注入动作生成主干，而不是被表示为一等标记，与演化中的动作动态交互。这种条件注入瓶颈尤其具有限制性

为应对这一挑战，先前工作从几个互补方向改进了生成式机器人策略。




图 1 UCA-Flow 的动机。(a) 现有策略通常将条件视为辅助条件信号。统一的条件-动作建模使条件与动作能够共同演化，从而让条件表示适应于当前的生成阶段和动作。(b) UCA-Flow 实现了更优的效率-性能权衡，在 Adroit 和 MetaWorld 上以最低延迟取得了最高的成功率。

用于单步动作生成。

本文提出统一条件-动作建模框架 UCA-Flow，用于精确的一步动作生成。如图 1(a) 下半部分所示，UCA-Flow 并未将条件作为外部引导注入动作生成器，而是将观测条件、时间步条件、区间条件与动作令牌表示为统一的令牌序列。该序列由紧凑的统一条件-动作变换器（Unified Condition-Action Transformer）处理，使条件与动作表示在统一的表示空间内联合优化。因此，条件重构成为生成过程的内部环节，而非预先计算的外部输入。为进一步优化统一条件-动作建模，本文引入改进的双通道监督方案，分别针对平均速度 u 与瞬时速度 v 。该双监督并非孤立的平均流目标，而是从两个互补的速度视角对共享的条件-动作表示进行正则化，促使令牌表示更加稳定且具有判别性（Geng 等，2025a,b）。如图 1(b) 总结所示，实验表明 UCA-Flow 显著改善了效率与性能的权衡。相较于最强基线，其平均成功率提升 9.3 个百分点，同时相较于 DP3 与 Simple DP3 分别实现 $45.6\times$ 与 $33.4\times$ 的加速，并比一步方法快 $4.3\times$ 与 $2.3\times$ 。

分别为流策略（FlowPolicy）和 MP1。

本文的贡献总结如下：• 我们提出 UCA-Flow，一种用于精确单步动作生成的统一条件-动作建模框架，该框架将观测、时间步、区间和动作作为统一条件-动作变换器中的一等标记，使条件表示能够根据生成阶段被动态优化。

- 本文提出了一种改进的双通道监督方案，分别针对平均速度 u 与瞬时速度 v 。该训练策略提供了互补的速度级约束，以更好地优化统一的条件-动作建模框架，在不增加推理成本的前提下提升单步动作准确率。
- 在 37 项 Adroit 和 Meta-World 任务以及 2 项真实世界操作任务上的大量实验表明，UCA-Flow 实现了卓越的效率与性能。

2 相关工作

机器人操作的生成式策略。机器人操作要求策略能够从复杂观测中推断任务相关信息，并为物理交互生成精确动作 Suomalainen

et al. (2022); Bohg et al. (2014); Qin et al. (2023); Xu et al. (2024)。模仿学习 (Imitation Learning) 提供了一种从示范中获取此类技能的实用方法 Atkeson and Schaal (1997); Argall et al. (2009); Mandlkar et al. (2021); Florence et al. (2022); Zhao et al. (2023); Haldar et al. (2023)。早期的行为克隆 (Behavior Cloning) 和隐式策略方法学习观测-动作映射, 但它们难以处理多模态动作分布和高维控制 Florence et al. (2022); Shafiullah et al. (2022); Zeng et al. (2021); Kalashnikov et al. (2018); Pari et al. (2022); Hansen et al. (2023)。近期策略通过使用表达性模型对动作分布进行建模来应对这些局限性。扩散策略 (Diffusion Policy) 将视觉运动控制表述为条件动作去噪, 并在模拟和真实任务中展现出强大的性能 Chi et al. (2025)。后续工作将这一思想扩展到人类行为模仿、目标条件扩散、策略优化、轨迹规划、抓取-运动优化以及基于流的策略学习 Pearce et al. (2023); Reuss et al. (2023); Ren et al. (2024); Janner et al. (2022); Uraïn et al. (2023); Prasad et al. (2024)。然而, 基于扩散的策略需要迭代采样, 从而增加了推理延迟。

用于策略学习的三维表征。由于操作本质上具有空间性, 三维表征被广泛用于提升几何推理能力和数据效率。诸如 RLBench 等基准提供了多样化的视觉引导操作任务, 用于评估此类能力 (James 等人, 2020)。近期策略探索了不同形式的三维表征, 包括体素、多视图图像、特征场和点云, 以更好地捕捉操作所需的结构 (Shridhar 等人, 2023; Gervet 等人, 2023; Goyal 等人, 2023, 2024; Ze 等人, 2023; Yan 等人, 2024; Ke 等人, 2025)。点云编码器如 PointNet、PointNet++ 和 PointNeXt 提供了紧凑的空间表征, 避免了稠密体素的高昂成本 (Qi 等人, 2017a, b; Qian 等人, 2022)。DP3 表明, 稀疏点云与扩散策略相结合可提升数据效率和部署安全性 (Ze 等人, 2024)。FlowPolicy 和 MP1 进一步利用紧凑的三维点云特征进行高效的基于流和动作的生成 (Zhang 等人, 2025; Sheng 等人, 2025)。然而, 这些方法仍将观测编码为外部条件, 并通过调制将其注入动作生成器。

高效单步动作生成。为降低采样成本, 近期研究探索了更高效的采样与快速生成方法, 包括去噪扩散概率模型 (DDPM)、去噪扩散隐式模型 (DDIM)、基于分数的建模、流匹配 (Flow Matching)、一致性

tency 模型, 以及 MeanFlow Ho 等人 (2020); Song 等人 (2021a,b); Lipman 等人 (2023); Liu 等人 (2022); Song 等人 (2023); Geng 等人 (2025a,b)。在机器人学习中, AdaFlow、FlowPolicy、ManiFlow 和 MP1 减少了函数评估次数, 以加快策略推理 Hu 等人 (2024); Zhang 等人 (2025); Yan 等人 (2025); Sheng 等人 (2025)。然而, 其中大多数改进了生成目标或采样过程, 条件作为外部上下文注入动作生成器。相比之下, UCA-Flow 将观测、时间步、区间和动作放入由统一条件-动作变换器 (Unified Condition-Action Transformer) 处理的统一条件-动作序列中, 实现联合条件-动作表示学习和动态条件重建, 以实现精确的一步动作生成。

3 方法

本文首先给出 UCA-Flow 的整体公式及其一步动作生成过程。随后描述观测条件、时间步与间隔变量以及含噪动作如何表示为统一的条件-动作令牌序列。基于该序列, 引入统一条件-动作交互机制以联合更新条件与动作表示。最后, 详细阐述用于优化间隔感知平均速度预测的双通道监督目标。

3.1 UCA-Flow 概述

如图 2 所示, UCA-Flow 以观测历史 o 、含噪动作轨迹 z_t 、时间步 t 和区间长度 h 作为输入, 并预测区间感知的平均速度 $u_\theta(z_t, t, h, o)$ 用于单步动作生成。它将观测、时间步、区间和动作标记统一为单一序列, 由统一条件-动作变换器 (Unified Condition-Action Transformer) 处理, 以联合更新条件与动作表示, 实现动态条件重建。

设 $x \in \mathbb{R}^{T \times d_a}$ 表示专家动作轨迹, $\epsilon \sim \mathcal{N}(0, I)$ 表示高斯噪声。遵循平均流方法, 本文构建 $z_t = (1-t)x + t\epsilon$, $t \in [0, 1]$, 其中较大的 t 表示噪声更大的动作状态, 瞬时速度为 $v = \epsilon - x$ 。UCA-Flow 在区间 $h = t - r$ 上学习 $u_\theta(z_t, t, h, o)$ 。在训练过程中, 双通道监督同时优化 u 和 v 。在推理过程中, 从 z_1 开始, 仅使用最终动作标记表示来预测 $\hat{x} = z_1 - u_\theta(z_1, 1, 1, o)$ 。




图 2 UCA-Flow 概览。观测、时间步、间隔与含噪动作被统一为条件-动作令牌，并由统一条件-动作变换器（Unified Condition-Action Transformer）处理，以预测区间感知速度。

3.2 统一条件-动作分词

如图 2 左侧所示，UCA-Flow 将观测令牌、时间步令牌、间隔令牌和动作令牌转换为统一的令牌序列。时间步和间隔使用正弦嵌入 PE 编码，随后通过独立可学习的多层感知机 ϕ ，生成 $e_t = \phi_t(\text{PE}(t))$ 和 $e_h = \phi_h(\text{PE}(h))$ 。时间步嵌入 e_t 指示当前噪声动作在概率路径上的位置，而间隔嵌入 e_h 指定估计平均速度所用的间隔。为提升表示容量，我们通过添加可学习的令牌特定偏差，使用 N_t 个时间步令牌和 N_h 个间隔令牌：

$$\tau_j = e_t + b_j^t, \quad j = 1, \dots, N_t, \quad (1)$$

$$\eta_j = e_h + b_j^h, \quad j = 1, \dots, N_h. \quad (2)$$

对于观测分词，每个观测步骤由点云特征 $p_i \in \mathbb{R}^{d_p}$ 和机器人状态特征 $s_i \in \mathbb{R}^{d_s}$ 表示。我们将这两个特征拼接并投影到变换器隐藏空间中，得到

$c_i = \phi_o([p_i; s_i]) + e_i^o$ ，其中 e_i^o 作为可学习的观测位置嵌入。对于两个观测步骤，观测令牌

序列为 $O = [c_1, c_2]$ 。条件令牌随后构建为

$$P_{t,h,o} = [c_1, c_2, \tau_1, \dots, \tau_{N_t}, \eta_1, \dots, \eta_{N_h}]. \quad (3)$$

对于带噪声的动作轨迹 z_t ，每个时间步被投影到相同的隐藏空间中，得到

$y_k = \phi_a(z_{t,k}) + e_k^a$ ， $k = 1, \dots, T$ ，其中 e_k^a 作为可学习的动作位置嵌入。按时间步收集动作令牌得到 $Y = [y_1, \dots, y_T]$ 。最终，变换器输入为

$$S^0 = [P_{t,h,o}, Y] = [c_1, c_2, \tau_1, \dots, \tau_{N_t}, \eta_1, \dots, \eta_{N_h}, y_1, \dots, y_T]. \quad (4)$$

3.3 统一条件-动作交互

如图 2 右侧所示，给定统一输入序列 S^0 ，统一条件-动作流应用一组统一条件-动作变换器块来联合更新条件令牌和动作令牌。为了符号清晰，我们将逐层条件表示和动作表示定义为

$$P_{t,h,o}^0 = P_{t,h,o}, \quad Y^0 = Y. \quad (5)$$




图 3 基于梯度的显著性可视化在真实世界任务上的结果。与辅助条件注入的自适应层归一化和交叉注意力相比，统一条件-动作流突出显示了更多与任务相关的区域，包括末端执行器、目标物体和上臂关节。

然后每个变换器块联合更新条件令牌和动作令牌：

$$\begin{aligned}
 [P_{t,h,o}^{\ell+1}, Y^{\ell+1}] = \\
 \text{UnifiedConditionActionTransformer}^{\ell}([P_{t,h,o}^{\ell}, Y^{\ell}]), \\
 \ell = 0, \dots, L-1.
 \end{aligned} \tag{6}$$

每个块由多头自注意力和前馈网络组成。与通过外部注入条件来更新动作令牌的设计不同，统一条件-动作流在同一个变换器序列中处理条件令牌和动作令牌。这使得条件表示能够根据当前动作状态进行更新，而不是保持固定的外部上下文，这一点也由图 3 支持，其中统一条件-动作流在末端执行器、目标物体和上臂关节周围显示出更多与任务相关的显著性。

这在各层之间创建了一条动作-条件-动作的信息路径。在第 ℓ 层，条件令牌从当前动作令牌 Y^{ℓ} 中吸收信息，形成动作感知的条件表示 $P_{t,h,o}^{\ell+1}$ 。在后续层中，动作令牌关注这些更新后的条件以细化轨迹。通过这种方式，UCA-Flow 将条件注入从外部注入转变为内部表示演化，在生成过程中联合更新条件和动作表示。

生成。

最后，我们丢弃条件输出，仅保留最终的动作表示：

$$Y^L = [y_1^L, \dots, y_T^L]. \tag{7}$$

模型预测通过将输出头 $\psi(\cdot)$ 应用于动作令牌序列来获得：

$$u_{\theta}(z_t, t, h, o) = \psi(Y^L) \in \mathbb{R}^{T \times d_a}. \tag{8}$$

这里 $\psi(\cdot)$ 表示一个单一的输出头，它将最终的动作令牌序列映射为与动作轨迹具有相同视野长度的速度轨迹。因此，条件令牌被用作动态中间表示，而输出仅由动作令牌产生。

3.4 双通道监督

为了优化 UCA-Flow 以实现精确的一步生成，我们对平均速度 u 和瞬时速度 v 采用了改进的双通道监督方案。给定专家动作轨迹 x 和高斯噪声 ϵ ，我们采样 $t \geq r$ 并定义 $h = t - r$ 。然后我们构造 $z_t = (1-t)x + t\epsilon$ 和 $v = \epsilon - x$ 。UCA-Flow 在训练期间执行两次前向传递。第一次传递设置 $h = 0$ 并预测瞬时速度 $v_{\theta} = u_{\theta}(z_t, t, 0, o)$ ，而第二次传递使用采样的区间长度 h 并预测区间感知的平均速度 $u_{\theta} = u_{\theta}(z_t, t, h, o)$ 。遵循平均流恒等式，我们通过沿 $(\text{sg}(v_{\theta}), \mathbf{1}, \mathbf{1})$ 的雅可比-向量积估计 u_{θ} 的路径导数来形成复合速度：

$$D_t u_{\theta} = \nabla_z u_{\theta} \cdot \text{sg}(v_{\theta}) + \partial_t u_{\theta} + \partial_h u_{\theta}, \tag{9}$$

$$V_{\theta} = u_{\theta} + h \text{sg}(D_t u_{\theta}). \tag{10}$$

这里 $\text{sg}(\cdot)$ 表示停止梯度。我们用相同的目标速度 v 监督两个速度视图：

$$\mathcal{L} = \rho(V_{\theta} - \text{sg}(v)) + \rho(v_{\theta} - \text{sg}(v)), \tag{11}$$

其中 $\rho(\cdot)$ 为自适应加权 L2 损失。给定误差张量 Δ ，其定义为 1

$$\rho(\Delta) = \text{sg}\left(\frac{1}{(\|\Delta\|_2^2 + c)^{1-\gamma}}\right) \|\Delta\|_2^2. \tag{12}$$

Here $\|\cdot\|_2^2$ 对每个训练样本在动作时域和动作维度上计算，随后进行批次平均。

u 分支学习区间感知的平均速度以进行单步生成，而 v 分支提供辅助的瞬时速度约束以稳定训练。在推理过程中，仅使用一次前向传播：从 $z_1 = \epsilon$ 开始，设定 $t = 1$ 和 $h = 1$ ，并生成 $\hat{x} = z_1 - u_{\theta}(z_1, 1, 1, o)$ 。

表 1 UCA-Flow 组件的消融实验。 -DualPass 移除双通道监督；-Unified/c 和 Unified/a 分别用交叉注意力和 AdaLN 替代统一条件-动作建模。结果为代表性 Adroit 和 Meta-World 任务上的成功率。

方法	Adroit MetaWorld 门笔 拨号 转动 插销 插入 侧面 杠杆 拉 拾取 放置 墙 棍 拉 架子 放置							
UCA-Flow	77.3 $\pm$ 2.0	63.0 $\pm$ 3.4	92.3 $\pm$ 4.7	90.6 $\pm$ 4.0	89.3 $\pm$ 3.2	90.6 $\pm$ 3.2	75.3 $\pm$ 2.3	74.0 $\pm$ 3.5
-DualPass	74.3 $\pm$ 5.0	57.0 $\pm$ 3.6	91.3 $\pm$ 7.3	88.0 $\pm$ 3.6	89.0 $\pm$ 0.0	89.6 $\pm$ 5.8	70.0 $\pm$ 3.5	64.0 $\pm$ 7.8
-Unified/c	68.2 $\pm$ 1.8	58.2 $\pm$ 6.9	87.3 $\pm$ 10.5	86.3 $\pm$ 3.2	79.0 $\pm$ 1.0	84.0 $\pm$ 3.4	62.3 $\pm$ 3.2	56.6 $\pm$ 3.8
-Unified/a	56.5 $\pm$ 2.1	48.6 $\pm$ 4.6	78.6 $\pm$ 9.3	61.0 $\pm$ 1.7	63.6 $\pm$ 6.0	60.3 $\pm$ 11.2	68.0 $\pm$ 3.5	32.3 $\pm$ 1.5




图 4 代表性仿真轨迹。行对应装配、Adroit 门和抽屉关闭，列显示每次执行的连续阶段。这些轨迹需要不同的交互模式：对齐并插入物体、协调灵巧手与门把手、以及在推动抽屉关闭时保持接触。UCA-Flow 使用单步动作生成完成从接近到任务完成的所有三个序列。

4 仿真实验

4.1 实验设置

我们在来自 Adroit (Rajeswaran 等人, 2017) 和 Meta-World (Yu 等人, 2020) 的 37 个模拟操作任务上评估 UCA-Flow, 遵循先前 3D 策略学习工作 (Ze 等人, 2024; Zhang 等人, 2025; Sheng 等人, 2025)。该基准包含 3 个 Adroit 灵巧手任务和 34 个 Meta-World 桌面任务, 涵盖不同难度级别, 包括 21 个简单、4 个中等、4 个困难和 5 个极难任务。这些任务评估动作生成准确率、任务

泛化性与推理效率度量。本文分别以成功率和推理时间作为主要性能与效率指标。所有方法在每个任务上使用 10 次专家演示, 并采用三个随机种子 (0、1、2)。点云通过最远点采样 (FPS) 下采样至 Adroit 的 1024 个点和 Meta-World 的 512 个点。模型在 Adroit/Meta-World 上分别训练 3000/1000 个训练轮次, 每 200 个训练轮次评估一次, 并报告每个种子下前五个检查点的结果。本文使用 AdamW 优化器, 批大小为 128, 学习率 1×10^{-4} , 观测窗口为 2, 预测时域为 4, 在单块 NVIDIA RTX A5000 GPU 上进行训练。推理延迟在稳定 GPU 负载下测量, 三个种子同时运行。

4.2 核心组件的消融实验

UCA-Flow 的

表 1 显示, 完整的 UCA-Flow 在大多数代表性任务中表现最佳。移除双通道监督会导致性能适度下降, 例如, 笔插入任务从 63.0% 降至 57.0%, 搁板放置任务从 74.0% 降至 64.0%, 这证实了互补 u 和 v 监督的益处。将统一的条件-动作建模替换为交叉注意力注入会导致更大的性能下降, 例如搁板放置任务从 74.0% 降至 56.6%。基于自适应层归一化的注入表现最差, 在门操作 (77.3% $\rightarrow$ 56.5%)、侧插销 (90.6% $\rightarrow$ 61.0%) 和搁板放置 (74.0% $\rightarrow$ 32.3%) 等任务上出现明显失败。这些结果支持了我们的动机, 即条件应与动作标记联合建模, 而不是作为辅助信号从外部注入。

4.3 与最先进方法的比较

性能与速度比较。表 2 和表 3 将 UCA-Flow 与代表性的基于扩散和基于流的策略进行了比较。UCA-Flow 达到了 88.2% 的最佳平均成功率, 将 MP1 从 78.9% 提高到 88.2%, 提升了 9.3 个百分点, 并比单步 FlowPolicy 高出 16.6 个百分点。在具有挑战性的 Meta-World 任务上, 提升尤为明显, 其中 UCA-

表 2 在 37 个 Adroit 和 Meta-World 任务上的成功率比较。 NFE 表示为动作生成所需的函数评估次数。所有方法均使用三个随机种子进行评估，最佳结果以粗体突出显示。

Methods	Publication	NFE	Adroit			MetaWorld				Average
			Hammer	Door	Pen	Easy (21)	Medium (4)	Hard (4)	Very Hard (5)	
DP3	RSS'24	10	100 ± 0	56 ± 5	46 ± 10	87.3 ± 2.2	44.5 ± 8.7	32.7 ± 7.7	39.4 ± 9.0	68.7 ± 4.7
Simple DP3	RSS'24	10	98 ± 2	40 ± 17	36 ± 4	86.8 ± 2.3	42.0 ± 6.5	38.7 ± 7.5	35.0 ± 11.6	67.4 ± 5.0
FlowPolicy	AAAI'25	1	98 ± 1	61 ± 2	54 ± 4	84.8 ± 2.2	58.2 ± 7.9	40.2 ± 4.5	52.2 ± 5.0	71.6 ± 3.5
MP1	AAAI'26	1	100 ± 0	69 ± 2	58 ± 5	88.2 ± 1.1	68.0 ± 3.1	58.1 ± 5.0	67.2 ± 2.7	78.9 ± 2.1
UCA-Flow	Ours	1	100 ± 0	77.3 ± 2.0	63.0 ± 3.4	92.4 ± 1.2	79.3 ± 3.4	68.0 ± 2.0	85.3 ± 2.0	88.2 ± 1.7

表 3 在 Adroit 和 MetaWorld 上的推理时间比较。 我们报告以毫秒为单位的推理延迟及其标准差。NFE 表示所需的函数评估次数。所有方法均使用三个随机种子进行评估，最佳结果以粗体突出显示。

Methods	Publication	NFE	Adroit /ms			MetaWorld /ms				Average /ms
			Hammer	Door	Pen	Easy (21)	Medium (4)	Hard (4)	Very Hard (5)	
DP3	RSS'24	10	129.5 ± 13.9	141.3 ± 14.8	145.1 ± 12.3	129.3 ± 10.7	134.7 ± 11.5	131.9 ± 12.4	138.4 ± 10.8	132.2 ± 11.2
Simple DP3	RSS'24	10	103.1 ± 11.4	111.3 ± 10.2	128.2 ± 13.1	91.9 ± 8.6	98.3 ± 9.1	101.3 ± 9.7	103.8 ± 10.2	97.0 ± 9.2
FlowPolicy	AAAI'25	1	15.3 ± 1.1	13.2 ± 4.0	12.0 ± 2.8	12.0 ± 1.4	12.2 ± 1.5	13.5 ± 1.4	14.5 ± 1.6	12.6 ± 1.5
MP1	AAAI'26	1	7.1 ± 0.2	7.2 ± 0.1	7.4 ± 0.3	6.7 ± 0.0	6.7 ± 0.1	6.7 ± 0.1	6.8 ± 0.1	6.8 ± 0.1
UCA-Flow	Ours	1	2.9 ± 0.2	2.9 ± 0.1	3.0 ± 0.3	3.1 ± 0.1	2.9 ± 0.1	3.0 ± 0.1	2.8 ± 0.1	2.9 ± 0.1

Flow 在中等、困难和极难任务上分别达到 79.3%，68.0% 和 85.3%。UCA-Flow 还以仅一次函数评估实现了最低的平均推理延迟 2.9 毫秒。它比 DP3 快 45.6×，比 Simple 快 33.4×，比 FlowPolicy 快 DP3, 4.3×，比 MP1 快 2.3×。这些结果表明，统一的“条件-动作”建模能够以紧凑的模型实现准确且实时的动作生成。




图 5 在 Adroit 和 Meta-World 上的训练成功曲线。 实线表示成功率，阴影区域表示不同种子间的变化。使用每个种子的前五检查点均值，UCA-Flow 在所有四个任务上均优于基线，包括在 Adroit Pen 上约 5% 的提升。

5 真实世界实验

5.1 实验设置

我们在 UR5e 机械臂上进行真实世界实验，并安装 RealSense L515 RGB-D 相机以获取俯视工作空间视图，如图 6 所示。我们评估两个任务：抓取与放置和抽屉关闭，涉及物体放置和不同开度下的抽屉关闭。对于每个任务，我们收集 40 次人类演示，并使用统一的设置，预测时域为 16，观测步长为 2。每个任务训练 300 个训练轮次。我们使用 AdamW 优化器，批大小为 128，学习率为 1×10^{-4} 。每个任务在 20 次独立试验中进行评估。

5.2 真实世界实验结果

图 6 展示了真实世界机器人任务，包括抓取放置和关闭抽屉。连续快照显示，UCA-Flow 能够在不同操作阶段生成可执行动作，例如接近物体、完成抓取、移动到目标区域以及关闭抽屉。表 4 将 UCA-Flow 与代表性基线在这两项真实世界任务上进行了比较，其中 UCA-Flow 在抓取放置任务上将成功率从 55.0% 提升至 65.0%（相对于 MP1），并在关闭抽屉任务上达到 100.0% 的成功率。

表 5 进一步评估了真实世界环境中的关键设计选择。与自适应层归一化（AdaLN）和交叉注意力（Cross Attention）相比，UCA-Flow 在两项任务上均取得了更高的成功率，表明统一的条件-动作建模比辅助条件注入更有效。




图 6 真实世界执行序列。顶行显示抓取放置任务从初始场景经过抓取和搬运到放入目标箱的过程。底行显示关闭抽屉任务从接近、接触、持续推动到完全关闭的过程。这些序列表明，尽管存在感知和执行不确定性，UCA-Flow 仍能在不同的自由空间和接触密集阶段保持任务相关的控制。

这些结果表明，UCA-Flow 在真实世界感知噪声和执行不确定性下仍然有效，为其真实世界操作能力提供了证据。

表 4 与策略基线的真实世界比较。成功率（%）基于每项任务 20 次独立试验测量。UCA-Flow 在抓取放置任务上比 MP1 提高了 10 个百分点，并在关闭抽屉任务上达到 100% 的成功率。

Method	Pick & Place	Drawer Close
DP3	50.0	95.0
MP1	55.0	95.0
UCA-Flow	65.0	100.0

表 5 条件集成设计的真实世界比较。成功率（%）基于每项任务 20 次独立试验测量。统一的条件-动作建模在两项任务上表现最佳，在抓取放置和关闭抽屉任务上分别比 AdaLN 高出 5 个和 10 个百分点。

Method	Pick & Place	Drawer Close
AdaLN	60.0	90.0
Cross Attention	50.0	95.0
UCA-Flow	65.0	100.0

6 结论

本文提出了 UCA-Flow，一个统一的条件-动作建模框架，用于精确高效的一步动作生成。UCA-Flow 将观测、时间步、区间和动作标记表示在统一序列中，并通过共享的变换器（Transformer）进行更新，使条件和动作能够协同建模。

在生成过程中联合细化表征。此外，本文引入了双通道监督以改进单步速度预测。在 Adroit 和 Meta-World 上的实验表明，UCA-Flow 在保持低推理延迟的同时，优于代表性的基于扩散和基于流的策略。真实世界实验进一步验证了其在物理机器人任务上的有效性，证明统一的条件-动作建模是快速生成式机器人策略的一种简单而有效的设计。

7 局限性

UCA-Flow 主要关注准确且高效的单步动作生成，当前的真实世界评估是在具有代表性的桌面操作任务上进行的。尽管这些实验验证了统一条件-动作建模在物理机器人环境中的有效性，未来工作可以进一步将 UCA-Flow 扩展到更广泛的真实世界场景，例如更长时程的操作和更多接触密集型任务。

参考文献

- Brenna D. Argall, Sonia Chernova, Manuela Veloso, and Brett Browning. A survey of robot learning from demonstration. *Robotics and Autonomous Systems*, 57(5):469–483, 2009.
- Christopher G. Atkeson and Stefan Schaal. Robot learning from demonstration. In *International Conference on Machine Learning*, 1997.
- Jeannette Bohg, Antonio Morales, Tamim Asfour, and Danica Kragic. Data-driven grasp synthesis—a survey. *IEEE Transactions on Robotics*, 30(2):289–309, 2014.
- Cheng Chi, Zhenjia Xu, Siyuan Feng, Eric Cousineau, Yilun Du, Benjamin Burchfiel, Russ Tedrake, and Shuran Song. Diffusion policy: Visuomotor policy learning via action diffusion. *The International Journal of Robotics Research*, 44(10-11):1684–1704, 2025.
- Pete Florence, Corey Lynch, Andy Zeng, Oscar A. Ramirez, Ayzaan Wahid, Laura Downs, Adrian Wong, Johnny Lee, Igor Mordatch, and Jonathan Tompson. Implicit behavioral cloning. In *Conference on Robot Learning*, pages 158–168, 2022.
- Zhengyang Geng, Mingyang Deng, Xingjian Bai, J Zico Kolter, and Kaiming He. Mean flows for one-step generative modeling. *arXiv preprint arXiv:2505.13447*, 2025a.
- Zhengyang Geng, Yiyang Lu, Zongze Wu, Eli Shechtman, J. Zico Kolter, and Kaiming He. Improved mean flows: On the challenges of fastforward generative models, 2025b. <https://arxiv.org/abs/2512.02012>.
- Theophile Gervet, Zhou Xian, Nikolaos Gkanatsios, and Katerina Fragkiadaki. Act3d: 3d feature field transformers for multi-task robotic manipulation. In *Conference on Robot Learning*, 2023.
- Ankit Goyal, Jie Xu, Yijie Guo, Valts Blukis, Yu-Wei Chao, and Dieter Fox. Rvt: Robotic view transformer for 3d object manipulation. In *Conference on Robot Learning*, pages 694–710, 2023.
- Ankit Goyal, Valts Blukis, Jie Xu, Yijie Guo, Yu-Wei Chao, and Dieter Fox. Rvt-2: Learning precise manipulation from few demonstrations. In *Robotics: Science and Systems*, 2024.
- Siddhant Halder, Jyothish Pari, Anant Rai, and Lerrel Pinto. Teach a robot to fish: Versatile imitation from one minute of demonstrations. In *Robotics: Science and Systems*, 2023.
- Nicklas Hansen, Zhecheng Yuan, Yanjie Ze, Tongzhou Mu, Aravind Rajeswaran, Hao Su, Huazhe Xu, and Xiaolong Wang. On pre-training for visuo-motor control: Revisiting a learning-from-scratch baseline. In *International Conference on Machine Learning*, pages 12511–12526, 2023.
- Jonathan Ho, Ajay Jain, and Pieter Abbeel. Denoising diffusion probabilistic models. In *Advances in Neural Information Processing Systems*, 2020.
- Xixi Hu, Bo Liu, Xingchao Liu, and Qiang Liu. Adaflow: Imitation learning with variance-adaptive flow-based policies. In *Advances in Neural Information Processing Systems*, 2024.
- Stephen James, Zicong Ma, David Rovick Arrojo, and Andrew J. Davison. Rlbench: The robot learning benchmark & learning environment. *IEEE Robotics and Automation Letters*, 5(2):3019–3026, 2020.
- Michael Janner, Yilun Du, Joshua B. Tenenbaum, and Sergey Levine. Planning with diffusion for flexible behavior synthesis. In *International Conference on Machine Learning*, pages 9902–9915, 2022.
- Dmitry Kalashnikov, Alex Irpan, Peter Pastor, Julian Ibarz, Alexander Herzog, Eric Jang, Deirdre Quillen, Ethan Holly, Mrinal Kalakrishnan, Vincent Vanhoucke, and Sergey Levine. Qt-opt: Scalable deep reinforcement learning for vision-based robotic manipulation. In *Conference on Robot Learning*, pages 651–673, 2018.
- Tsung-Wei Ke, Nikolaos Gkanatsios, and Katerina Fragkiadaki. 3d diffuser actor: Policy diffusion with 3d scene representations. In *Conference on Robot Learning*, 2025.
- Yaron Lipman, Ricky T. Q. Chen, Heli Ben-Hamu, Maximilian Nickel, and Matt Le. Flow matching for generative modeling. In *International Conference on Learning Representations*, 2023.
- Xingchao Liu, Chengyue Gong, and Qiang Liu. Flow straight and fast: Learning to generate and transfer data with rectified flow. *arXiv preprint arXiv:2209.03003*, 2022.
- Ajay Mandlekar, Danfei Xu, Josiah Wong, Soroush Nasiriany, Chen Wang, Rohun Kulkarni, Li Fei-Fei, Silvio Savarese, Yuke Zhu, and Roberto Martín-Martín. What matters in learning from offline human demonstrations for robot manipulation. *arXiv preprint arXiv:2108.03298*, 2021.
- Jyothish Pari, Nur Muhammad Shafiullah, Sridhar Pandian Arunachalam, and Lerrel Pinto. The surprising effectiveness of representation learning for visual imitation. In *Robotics: Science and Systems*, 2022.
- Tim Pearce, Tabish Rashid, Anssi Kanervisto, Dave Bignell, Mingfei Sun, Raluca Georgescu, Sergio Valcarcel Macua, Shan Zheng Tan, Ida Momennejad, Katja Hofmann, and Sam Devlin. Imitating human behaviour with diffusion models. In *International Conference on Learning Representations*, 2023.
- Aaditya Prasad, Kevin Lin, Jimmy Wu, Linqi Zhou, and Jeannette Bohg. Consistency policy: Accelerated visuomotor policies via consistency distillation. In *Robotics: Science and Systems*, 2024.

- Charles R. Qi, Hao Su, Kaichun Mo, and Leonidas J. Guibas. Pointnet: Deep learning on point sets for 3d classification and segmentation. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, pages 652–660, 2017a.
- Charles Ruizhongtai Qi, Li Yi, Hao Su, and Leonidas J. Guibas. Pointnet++: Deep hierarchical feature learning on point sets in a metric space. In *Advances in Neural Information Processing Systems*, 2017b.
- Guocheng Qian, Yuchen Li, Houwen Peng, Jinjie Mai, Hasan Hammoud, Mohamed Elhoseiny, and Bernard Ghanem. Pointnext: Revisiting pointnet++ with improved training and scaling strategies. In *Advances in Neural Information Processing Systems*, 2022.
- Meiyang Qin, Jake Brawer, and Brian Scassellati. Robot tool use: A survey. *Frontiers in Robotics and AI*, 9: 1009488, 2023.
- Aravind Rajeswaran, Vikash Kumar, Abhishek Gupta, Giulia Vezzani, John Schulman, Emanuel Todorov, and Sergey Levine. Learning complex dexterous manipulation with deep reinforcement learning and demonstrations. *arXiv preprint arXiv:1709.10087*, 2017.
- Allen Z Ren, Justin Lidard, Lars L Ankile, Anthony Simeonov, Pulkit Agrawal, Anirudha Majumdar, Benjamin Burchfiel, Hongkai Dai, and Max Simchowitz. Diffusion policy policy optimization. *arXiv preprint arXiv:2409.00588*, 2024.
- Moritz Reuss, Maximilian Li, Xiaogang Jia, and Rudolf Lioutikov. Goal-conditioned imitation learning using score-based diffusion policies. *arXiv preprint arXiv:2304.02532*, 2023.
- Moritz Reuss, Ömer Erdiñç Yağmurlu, Fabian Wenzel, and Rudolf Lioutikov. Multimodal diffusion transformer: Learning versatile behavior from multimodal goals. *arXiv preprint arXiv:2407.05996*, 2024.
- Nur Muhammad Mahi Shafiullah, Zichen Cui, Ariuntuya Arty Altanzaya, and Lerrel Pinto. Behavior transformers: Cloning k modes with one stone. In *Advances in Neural Information Processing Systems*, 2022.
- Juyi Sheng, Ziyi Wang, Peiming Li, and Mengyuan Liu. Mpl: Meanflow tames policy learning in 1-step for robotic manipulation, 2025. <https://arxiv.org/abs/2507.10543>.
- Mohit Shridhar, Lucas Manuelli, and Dieter Fox. Perceiver-actor: A multi-task transformer for robotic manipulation. In *Conference on Robot Learning*, pages 785–799, 2023.
- Jiaming Song, Chenlin Meng, and Stefano Ermon. Denoising diffusion implicit models. In *International Conference on Learning Representations*, 2021a.
- Yang Song, Jascha Sohl-Dickstein, Diederik P. Kingma, Abhishek Kumar, Stefano Ermon, and Ben Poole. Score-based generative modeling through stochastic differential equations. In *International Conference on Learning Representations*, 2021b.
- Yang Song, Prafulla Dhariwal, Mark Chen, and Ilya Sutskever. Consistency models. In *International Conference on Machine Learning*, pages 32211–32252, 2023.
- Markku Suomalainen, Yiannis Karayiannidis, and Ville Kyrki. A survey of robot manipulation in contact. *Robotics and Autonomous Systems*, 156:104224, 2022.
- Julen Urain, Niklas Funk, Jan Peters, and Georgia Chalvatzaki. SE(3)-diffusionfields: Learning smooth cost functions for joint grasp and motion optimization through diffusion. In *IEEE International Conference on Robotics and Automation*, pages 5923–5930, 2023.
- Zhiyuan Xu, Kun Wu, Junjie Wen, Jinming Li, Ning Liu, Zhengping Che, and Jian Tang. A survey on robotics with foundation models: Toward embodied ai. *arXiv preprint arXiv:2402.02385*, 2024.
- Ge Yan, Yueh-Hua Wu, and Xiaolong Wang. Dnact: Diffusion guided multi-task 3d policy learning. *arXiv preprint arXiv:2403.04115*, 2024.
- Ge Yan, Jiyue Zhu, Yuquan Deng, Shiqi Yang, Ri-Zhao Qiu, Xuxin Cheng, Marius Memmel, Ranjay Krishna, Ankit Goyal, Xiaolong Wang, et al. Manifold: A general robot manipulation policy via consistency flow training. *arXiv preprint arXiv:2509.01819*, 2025.
- Tianhe Yu, Deirdre Quillen, Zhanpeng He, Ryan Julian, Karol Hausman, Chelsea Finn, and Sergey Levine. Meta-world: A benchmark and evaluation for multi-task and meta reinforcement learning. In *Conference on robot learning*, pages 1094–1100. PMLR, 2020.
- Yanjie Ze, Ge Yan, Yueh-Hua Wu, Annabella Macaluso, Yuying Ge, Jianglong Ye, Nicklas Hansen, Li Erran Li, and Xiaolong Wang. Gnfactor: Multi-task real robot learning with generalizable neural feature fields. In *Conference on Robot Learning*, 2023.
- Yanjie Ze, Gu Zhang, Kangning Zhang, Chenyuan Hu, Muhan Wang, and Huazhe Xu. 3d diffusion policy: Generalizable visuomotor policy learning via simple 3d representations, 2024. <https://arxiv.org/abs/2403.03954>.
- Andy Zeng, Pete Florence, Jonathan Tompson, Stefan Welker, Jonathan Chien, Maria Attarian, Travis Armstrong, Ivan Krasin, Dan Duong, Ayzaan Wahid, Vikas Sindhwani, and Johnny Lee. Transporter networks: Rearranging the visual world for robotic manipulation. In *Conference on Robot Learning*, pages 726–747, 2021.
- Qinglun Zhang, Zhen Liu, Haoqiang Fan, Guanghui Liu, Bing Zeng, and Shuaicheng Liu. Flowpolicy: Enabling fast and robust 3d flow-based policy via consistency flow matching for robot manipulation. In *Proceedings of the AAAI Conference on Artificial Intelligence*, volume 39, pages 14754–14762, 2025.

Tony Z. Zhao, Vikash Kumar, Sergey Levine, and Chelsea Finn. Learning fine-grained bimanual manipulation with low-cost hardware. In *Robotics: Science and Systems*, 2023.