

# Schrödinger Bridge $\times$ RL $\times$ 机器人策略学习

awesome\_study 全库综述：51 篇精读 + 2026 趋势雷达

awesome\_study

2026-09

# 主线问题：生成式策略的 $\log \pi$ 障碍

## 为什么生成式策略

- 机器人动作天然多模态，高斯 actor 把模式平均成无效动作
- Diffusion Policy (RSS 2023): action chunk 条件去噪，12 任务平均 +46.9%
- $\pi_0$  / RDT-1B 等 VLA 沿用 diffusion/flow 动作头

## 为什么 RL 卡住

- 策略梯度、SAC 熵项、PPO ratio 全要  $\log \pi(a|s)$
- 生成式策略动作是 SDE 终端边际：似然只有 ELBO 或需解 ODE
- 表达力与可优化性的结构性冲突

五条解法路线 (2026 全部成型): 逐步分解 (DPPO/ReinFlow) · 路径空间 (FLAC/GSB-MDPO) · 噪声空间 (DSRL/LP-DS) · 条件化监督 (RECAP/AWR) · 生成-选择 (MVP/FMQ)

# 仓库地图：七类 51 篇

| 类别                 | 篇目与定位                                                                                                              |
|--------------------|--------------------------------------------------------------------------------------------------------------------|
| 01 生成模型基础 (7)      | DDPM · Score-SDE · FM · OT-CFM · Rectified Flow · MeanFlow · Diffusion Policy                                      |
| 02 SB 理论 (4)       | Léonard · DSB · GSBM · SB Foundations ——数学正典 → 神经化 → 广义化 → 教科书                                                     |
| 03 Bridge 算法 (7)   | I <sup>2</sup> SB · DSBM · SF <sup>2</sup> M · SB Flow · ASBM · Soft-SB · PRISM                                    |
| 04 RL 基础 (5)       | PPO · SAC · MDPO · GRPO · AWR ——SB×RL 的接口层                                                                         |
| 05 生成式策略 × RL (15) | DT · Diffuser · Diffusion-QL · FQL · CP · DPPO · Flow-GRPO · ReinFlow · DSRL · MP1 · DMPO · OFP · DBPO · OMP · FMQ |
| 06 SB × RL 前沿 (4)  | <b>FLAC</b> · <b>GSB-MDPO</b> · <b>RSBM</b> · <b>BDGxRL</b> ——选题主战场                                                |
| 07 2026 雷达 (9)     | MVP · MF-VLA · MFPO · ReactVLA · UCA-Flow · RECAP · LP-DS · DF-ExpEnse · BridgePolicy                              |

每篇配中文详细解读；19 篇前沿另配保版式中译 PDF。

# 线索一：一步化的终局

步数演化：DDPM(1000)  $\rightarrow$  DDIM/FM(10-50)  $\rightarrow$  OT-CFM(5-10)  $\rightarrow$  蒸馏/Consistency(1-2, 需教师)  $\rightarrow$  **MeanFlow 原生 1-NFE** (免蒸馏)

关键机制：学区间平均速度  $u(z_t, r, t) = \frac{1}{t-r} \int_r^t v d\tau$ , 恒等式  $u = v - (t-r) \frac{d}{dt} u$  给出免教师回归目标；ImageNet 256 一步 FID 3.43。

进入机器人（半年五连发）：MP1 (1-NFE 操纵, 6.8ms)  $\rightarrow$  DMPO (+PPO, >120Hz 真机)  $\rightarrow$  OFP (免 JVP 自蒸馏, 一步超  $\pi_{0.5}$  十步)  $\rightarrow$  DBPO (drift 固定点, 105.2Hz 双臂)

判断：「多步 vs 一步」争论已结束；SB 必须卖一步化没有的东西。

## 线索二：路径空间——SB 给 RL 的两个恒等式

### Girsanov 动能恒等式

$$\text{KL}(\mathbb{P}^u \parallel \mathbb{Q}) = \mathbb{E} \left[ \int_0^1 \frac{1}{2\sigma^2} \|u\|^2 dt \right] \quad \text{路径 KL} = \text{漂移动能, 不算任何密度}$$

FLAC: SAC 的策略熵  $\rightarrow$  动能预算 + 拉格朗日自动调节 (免似然 max-ent RL)。

数据处理不等式

$$\text{KL}(\mathbb{P} \parallel \mathbb{Q}) \geq \text{KL}(\mathbb{P}_1 \parallel \mathbb{Q}_1) \quad \text{压路径就压住了执行动作分布}$$

GSB-MDPO: MDPO 邻近项搬进路径空间, drift-MSE 即路径 KL 的离散形式。

格局: 理论位已被占满; 两篇全是 locomotion 仿真——操纵/视觉/真机全空。MFPO (ICML 2026) 走似然近似路线正面叫板。

## 线索三：桥式先验——informative source 的红利

- 图像 (**I<sup>2</sup>SB**): 退化图当边界而非条件, 修复 4 任务全胜, NFE 几百  $\rightarrow$  约 20。起点带信息  $\rightarrow$  路径短  $\rightarrow$  少步稳。
- 导航 (**RSBM**): 学习先验 +  $\epsilon$  旋钮 (布朗桥  $\leftrightarrow$  OT 连续换挡), 3 步 92% 成功率免蒸馏。 $\epsilon$  谱系 = SB 独有的 coverage-straightness 权衡。
- 操纵 (**BridgePolicy, ICML 2026**): 观测嵌入 SDE 从观测先验起步, 52 仿真 + 5 真机任务胜 DP/DP3/FlowPolicy——顶会正面验证桥式起点 (但只做了 BC 半场)。
- 跨域 (**BDGxRL**): DSB 在线翻译源域转移 + 奖励调制, MuJoCo 跨域全胜 DARC 系; 像素级 sim-to-real SB 至今无人做。

# 主战场：SB×RL 四条进路对照

|                      | FLAC                               | GSB-MDPO                       | RSBM                      | BDGxRL                    |
|----------------------|------------------------------------|--------------------------------|---------------------------|---------------------------|
| 问题定义                 | max-ent = 对高熵参考的 GSB               | 邻近更新进路径测度                      | few-step 桥矫正              | 动力学差距 = unpaired 翻译       |
| $\log \pi$ 处理<br>实验面 | 动能上界终端 KL<br>DMC + HumanoidBench   | path-KL 作邻近项<br>14 个 MuJoCo 任务 | 不涉及（纯监督）<br>导航 3 步 92%    | 不涉及（翻译后 SAC）<br>MuJoCo 跨域 |
| 最大短板<br>启示           | 无操纵/真机<br>informative reference 增量 | 路径比率高方差<br>装进操纵 = 占两格          | 无 RL<br>$\epsilon$ 谱是核心资产 | 低维状态<br>像素级窗口开着           |

## 2026 雷达 (2-8 月, 10 篇)

一步族扩张: MVP (2602.13810, 边界约束) · MF-VLA (2603.01469) · ReactVLA (2606.14255) · MFPO (2604.14698, ICML: MeanFlow+max-ent, FLAC 正面对手) · UCA-Flow (2608.16153, +9.3pp)

RL 微调路线:  $\pi_{0.6}^*$ /RECAP (2511.14759: 优势条件化免策略梯度, 真实任务吞吐翻倍) · LP-DS (2606.01151, ICML: DSRL 修正 + 首个动作熵多模态评测) · DF-ExpEnse (2606.19656) · BridgePolicy (2512.07212, ICML)

五条趋势: 一步化范式化 ·  $\log \pi$  四路线互相对表 (path-space 独缺真机) · informative source 上主会但只做 BC · mode coverage 从口号走向指标 · 工业界与学术界在「绕开似然」上合流



# 入库补检带来的两个新判断

(1) 一步时代 **path-space** 还剩什么：三个同构信赖域——GSB-MDPO（路径 KL）· LP-DS（latent 偏移）· FMQ（平均速度场，闭式解  $u^* = u^{\text{ref}} + \eta \nabla_a Q / \|\nabla_a Q\|$ ）。路径 KL 经 Girsanov 即速度场  $L^2$ ，FMQ 的信赖域恰是 GSB-MDPO 邻近项的一步极限。

(2) PRISM 把 SB 差异化钉死在 **few-step** 区间：不可见性原理——精确漂移 + 无限步下任何参考过程给同一后验，换参考只在有限步预算下有意义；有限步最优噪声谱  $\propto$  被摧毁信息谱  $\rightarrow$  informative source 先验设计的第一条可计算规则。

共性病理（OMP / MVP）：速度/漂移回归在低模长区梯度饥饿；MeanFlow 恒等式缺边界条件解不唯一。桥匹配收口段同病——one-step SB policy 必须内置方向对齐 + 边界约束。

# 空白与机会：五个无人占位的格子

| # | 组合                           | 零件（全部已有文献）                                      | 窗口     |
|---|------------------------------|-------------------------------------------------|--------|
| 1 | One-step SB policy           | MeanFlow 恒等式 $\times$ 桥边界 $\times$ $\epsilon$ 谱 | 6-12 月 |
| 2 | Few-step SB $\times$ path-RL | GSB-MDPO/FLAC 内核 $\times$ RSBM 骨架 $\times$ 操纵   | 12 月内  |
| 3 | Mode coverage 基准             | LP-DS 熵估计 $\times$ $\epsilon$ 谱做实验变量            | 先做先赢   |
| 4 | 像素级 sim-to-real SB           | SB Flow 规模化 $\times$ BDGxRL 框架                  | 竞争最少   |
| 5 | RL 加权耦合                      | advantage 注入 IMF/OT-CFM 耦合                      | 纯算法空格  |

风险：「SB 帽子」贬值加速；path-space 纯理论位已饱和；MeanFlow 族半年 6 篇——对表要指路线而非单篇。

SB×RL 不是成熟工具，是有清晰 niche 的研究空间。一步化与 path-space 的理论位在 2026 上半年被迅速占领，但三个交叉格子——**one-step SB policy**、**few-step×path-space** 的操纵落地、像素级 **sim-to-real** 桥——每个零件都有文献而组合无人做。

SB 的持久差异化资产只有两个：**informative source**（边界即条件）与  $\epsilon$  谱系（**coverage-straightness** 同旋钮）；不落在这两点上的 SB 包装工作都会贬值。

产物：51 篇中文详细解读（Codex GPT-6 逐篇二审）· 英文 PDF 51 篇 + 19 篇中译· 速览 / 开放问题 / 对比表 / 阅读路线 / 术语表· HTML PPT + 本 PDF。